

THE ANALYST HANDBOOK SERIES

Statistics & Visualization

Volume 2 — Semester 2 dari Kurikulum 7-Layer Analytics

Dari angka menjadi bukti: descriptive statistics, probability, inference, uji statistik, regresi — lalu mengubahnya menjadi visualisasi dan BI dashboard yang menggerakkan keputusan.

✓ LAYER 1 — DATA (Volume 1, selesai)

■ **LAYER 2 — STATISTICS** (volume ini)

□ LAYER 3 — BUSINESS

□ LAYER 4 — EXPERIMENTATION

□ LAYER 5 — DECISION SCIENCE

□ LAYER 6 — AI

□ LAYER 7 — DOMAIN EXPERTISE

Tentang Volume 2

Posisi volume ini dalam perjalanan — dan aturan main yang tetap berlaku

Dari Volume 1 ke Volume 2

Volume 1 mengakhiri Layer 1 dengan satu kemampuan: mengubah data mentah menjadi analytical dataset yang dapat dipercaya. Pertanyaan berikutnya tidak bisa dihindari: **apa yang sebenarnya dikatakan data ini — dan seberapa yakin kita?**

Revenue naik 4%. Apakah itu pertumbuhan nyata, atau fluktuasi acak yang bulan depan hilang sendiri? Rata-rata belanja segment Gold lebih tinggi 80 ribu daripada Silver. Apakah perbedaan itu bukti, atau kebetulan sampling? Layer 2 memberi alat untuk menjawab pertanyaan jenis ini secara disiplin.

Paruh kedua volume ini menangani sisi keluaran: statistik yang benar tetapi disajikan buruk tidak menggerakkan keputusan. Visualization dan BI dashboard adalah antarmuka antara analisis dan tindakan.

Aturan main yang tidak berubah

Semua konvensi Volume 1 tetap berlaku: struktur bab WHY→WHAT→WHEN→HOW→BEST PRACTICE→COMMON MISTAKE→CHECKLIST→ENDING CARD; callout boxes dengan warna yang sama; contoh bertingkat simple → business → production; dan satu perusahaan konsisten — **TokoNusa**, retail omnichannel dengan 85 toko, 2,1 juta pelanggan, 40 ribu transaksi/hari. Skema tabelnya (customers, orders, order_items, products, stores) persis seperti di Volume 1 Bab 2.

Tool utama volume ini: Python (pandas + scipy + statsmodels) untuk komputasi statistik, dan Power BI untuk dashboard. Semua kode dapat dijalankan; semua output ditampilkan.

Peringatan sejak awal: statistik adalah alat kejujuran

Statistik sering dipakai untuk membuat argumen terlihat ilmiah. Buku ini melatih arah sebaliknya: memakai statistik untuk *menguji dirimu sendiri* sebelum orang lain mengujimu. Setiap bab memuat cara-cara sebuah angka bisa menipu — dan disiplin untuk tidak ikut menipu, sengaja maupun tidak.

Daftar isi Volume 2

- Bab 1** Berpikir Statistik — variasi, sinyal vs noise, populasi vs sampel
- Bab 2** Descriptive Statistics — pusat, sebaran, persentil, skewness, distribusi
- Bab 3** Probability — aturan dasar, conditional, Bayes, expected value, distribusi teoretis
- Bab 4** Statistical Inference — sampling, CLT, confidence interval, hypothesis testing, p-value, power
- Bab 5** Uji Statistik dalam Praktik — t-test, ANOVA, chi-square, correlation dengan scipy
- Bab 6** Regression — linear, multiple, logistic; interpretasi, asumsi, multicollinearity
- Bab 7** Prinsip Visualisasi — persepsi visual, pemilihan chart, data-pixel ratio
- Bab 8** BI Dashboard — Power BI, data model, DAX dasar, desain dashboard tiga peran
- Bab 9** Capstone Semester 2 — statistical analysis + dashboard end-to-end

Bab 1 — Berpikir Statistik

Variasi, sinyal vs noise — mengapa mayoritas "insight" bisnis sebenarnya kebetulan

Learning objectives	Memahami variasi sebagai kondisi default data bisnis; membedakan sinyal dari noise secara konseptual; memahami populasi vs sampel; mengenali pola-pola menipu klasik sebelum belajar alat formalnya
Prerequisites	Volume 1 (terutama Bab 1-2)
Estimasi waktu	Baca 60 menit · Praktik 45 menit
Difficulty	● Beginner
Skills covered	Statistical thinking, variasi, populasi vs sampel, regression to the mean, bias seleksi
Business domain	Retail (TokoNusa)

Mengapa bab konsep ini datang sebelum rumus

Kesalahan statistik yang paling merusak di dunia bisnis bukan salah hitung — melainkan salah tafsir. Analyst yang hafal rumus standard deviation tetapi tidak paham variasi akan tetap melaporkan noise sebagai insight.

Bab ini membangun empat intuisi inti. Seluruh alat formal di bab-bab berikutnya hanyalah cara mendisiplinkan intuisi ini dengan angka.

Intuisi 1 — Variasi adalah kondisi default

Penjualan harian TokoNusa tidak pernah sama dua hari berturut-turut. Ini bukan anomali yang butuh penjelasan — ini sifat alami setiap proses bisnis. Cuaca, gaji, hari-minggu, mood pembeli, kebetulan murni: semuanya menyumbang fluktuasi.

Konsekuensinya tajam: **perbedaan dua angka bukanlah temuan**. Pertanyaan analyst selalu: apakah perbedaan ini lebih besar daripada fluktuasi normal proses ini?

Revenue harian (miliar Rp)	Pertanyaan yang salah:
4.1 3.8 4.4 3.9 4.2 3.7 4.0	"Kenapa Kamis turun ke 3.7?"
↑	
Kamis	Pertanyaan yang benar:
	"Apakah 3.7 di luar rentang fluktuasi normal proses ini?"

◆ BUSINESS INSIGHT — Biaya mengejar noise

Tim yang tidak paham variasi akan rapat setiap kali angka harian turun, mengubah strategi setiap minggu, dan membatalkan inisiatif bagus karena satu bulan yang buruk secara kebetulan. Manajemen berbasis noise lebih mahal daripada tidak ada data sama sekali — karena ia memberi ilusi sedang mengelola sesuatu. Batas formal "fluktuasi normal" dipelajari di Bab 2 (standard deviation) dan Bab 4 (inference).

Intuisi 2 — Populasi vs sampel: hampir semua data adalah sampel

Populasi = seluruh entitas yang ingin kamu simpulkan. **Sampel** = bagian yang benar-benar kamu amati. Kesimpulan selalu ditarik untuk populasi, tetapi data hampir selalu sampel — dan setiap sampel membawa ketidakpastian.

Yang sering terlewat: data yang terlihat "lengkap" pun biasanya sampel dari populasi yang lebih dalam:

Data yang kamu punya	Populasi yang sebenarnya ingin disimpulkan
Semua transaksi Juli	Perilaku pembelian pelanggan secara umum — Juli hanyalah satu realisasi
Survei kepuasan 2.000 responden	Seluruh 2,1 juta pelanggan (termasuk yang menolak mengisi!)
Hasil promo di 10 toko uji	Efek promo jika diterapkan di semua 85 toko
Review produk di aplikasi	Opini semua pembeli — bukan hanya yang cukup termotivasi menulis

✗ COMMON MISTAKE — "Ini bukan sampel, ini semua data kami"

Gejala: analyst menolak konsep ketidakpastian karena "kami punya seluruh transaksi".

Mengapa terjadi: mengira populasi = database. Padahal pertanyaan bisnis ("apakah pelanggan kami makin loyal?") menunjuk proses yang menghasilkan data, bukan tabelnya.

Perbaikan: tanyakan: kesimpulan ini mau dipakai untuk memprediksi/memutuskan apa? Jika jawabannya menyangkut masa depan atau entitas di luar data — dan hampir selalu begitu — kamu sedang bekerja dengan sampel.

Cara senior menghindarinya: senior menganggap semua angka sebagai estimasi sampai terbukti sebaliknya.

Intuisi 3 — Regression to the mean: performa ekstrem cenderung kembali normal

Toko dengan penjualan terburuk bulan ini hampir pasti membaik bulan depan — *bahkan tanpa intervensi apa pun*. Bukan karena magis: performa ekstrem biasanya kombinasi kondisi nyata + kebetulan buruk, dan kebetulan tidak bertahan.

Ini jebakan evaluasi program paling klasik di korporasi:

Skenario yang terjadi di mana-mana:

1. Pilih 10 toko berperforma TERBURUK Q2
2. Beri program pembinaan khusus
3. Q3: 8 dari 10 toko membaik!
4. Kesimpulan (SALAH): "program terbukti berhasil"

Yang sebenarnya: sebagian besar perbaikan akan terjadi dengan sendirinya (regression to the mean).

Bukti sejati butuh pembandingan: toko buruk yang TIDAK diberi program → itulah eksperimen (Semester 4).

⚠ WARNING

Setiap kali intervensi ditargetkan pada kasus ekstrem (toko terburuk, pelanggan paling tidak aktif, SKU paling lambat), evaluasi sebelum-sesudah akan *selalu* terlihat berhasil. Tanpa kelompok pembandingan, "keberhasilan" itu tidak bisa dibedakan dari matematika belaka.

Intuisi 4 — Bias seleksi: data yang sampai kepadamu sudah tersaring

Sebelum menganalisis isi data, tanyakan proses yang membuat data itu ada. Contoh-contoh yang terus berulang:

- **Survivorship bias:** menganalisis "kebiasaan pelanggan loyal" tanpa membandingkan dengan yang churn — mungkin pelanggan churn punya kebiasaan yang sama.
- **Non-response bias:** survei kepuasan diisi oleh yang sangat puas dan sangat kecewa; mayoritas diam tak terwakili.
- **Seleksi channel:** pelanggan app berbeda demografi dari pelanggan toko — perbandingan langsung mencampur efek channel dengan efek demografi (confounding, diformalkan di Semester 4).

● INTERVIEW TIP

"Rata-rata rating produk kami 4,6 — apa yang perlu dicek sebelum merayakannya?" Jawaban kuat menyebut: siapa yang menulis review (bias seleksi), distribusi bukan hanya rata-rata (Bab 2), dan pembandingan kategori. Pertanyaan seperti ini menguji berpikir statistik, bukan rumus.

Kerangka kerja: empat pertanyaan sebelum mempercayai angka

1. **Dibandingkan dengan apa?** Angka tanpa baseline tidak bermakna (pelajaran Vol 1 Bab 1 — kini dengan alasan statistik).
2. **Seberapa besar fluktuasi normalnya?** Perbedaan harus diukur relatif terhadap variasi (Bab 2, 4).
3. **Bagaimana data ini terpilih?** Proses seleksi bisa menciptakan pola yang tidak ada di populasi.
4. **Apakah ada regression to the mean?** Selalu curiga saat mengevaluasi kasus yang dipilih karena ekstrem.

Checklist berpikir statistik

- ✓ Perbedaan angka tidak dilaporkan sebagai temuan sebelum dibandingkan dengan variasi normal
- ✓ Populasi target kesimpulan dinyatakan eksplisit; status data sebagai sampel diakui
- ✓ Evaluasi program pada kelompok ekstrem selalu memakai pembandingan
- ✓ Proses lahirnya data (siapa masuk, siapa tidak) diperiksa sebelum isi data
- ✓ Klaim "naik/turun" disertai konteks: baseline, periode, dan sumber variasi yang diketahui

Ending Card — Bab 1

What you learned

Variasi sebagai default; populasi vs sampel dan mengapa "semua data" tetap sampel; regression to the mean dan jebakan evaluasi program; tiga bentuk bias seleksi; empat pertanyaan sebelum mempercayai angka.

Skills mastered

Skeptisisme terstruktur · identifikasi noise-chasing · deteksi bias seleksi pada permintaan analisis nyata.

Real business value

Menghentikan keputusan berbasis noise — kategori pemborosan manajemen yang paling tak terlihat — dan menaikkan standar bukti seluruh tim.

Interview readiness

● INTERVIEW QUESTIONS

1. "Penjualan kemarin turun 8%. Manager panik. Apa responmu?" — bandingkan dengan distribusi fluktuasi harian normal; cek pipeline dulu (Vol 1 Bab 5); baru investigasi bisnis.
2. "Program coaching untuk sales terburuk berhasil — semua membaik. Yakin?" — regression to the mean; minta kelompok pembandingan.
3. "Apa bedanya populasi dan sampel? Kenapa transaksi lengkap tetap sampel?" — proses vs tabel.

Exercises

Exercise 1.1 (Beginner · 15 menit)

Objective: mendeteksi jebakan statistik dalam klaim bisnis

Identifikasi masalah utama tiap klaim: (a) "Pelanggan yang pakai fitur wishlist belanja 3× lebih banyak — mari paksa semua orang pakai wishlist"; (b) "Kami survei pengguna aktif: 92% puas dengan aplikasi"; (c) "Setelah kami tegur, kasir dengan error tertinggi bulan lalu membaik semua".

Answer key 1.1

(a) Bias seleksi/confounding: pengguna wishlist memang tipe pembelanja berat; wishlist belum tentu penyebabnya — korelasi $\neq$ kausalitas (formal di Semester 4). (b) Non-response + survivorship: pengguna kecewa sudah uninstall dan tidak tersurvei. (c) Regression to the mean: error tertinggi sebagian karena kebetulan buruk; perbaikan akan terjadi tanpa teguran — butuh pembandingan.

Exercise 1.2 (Intermediate · 30 menit)

Objective: merancang pembandingan

CMO ingin mengevaluasi program winback yang dikirim ke semua pelanggan yang tidak belanja 90+ hari. Tanpa pengetahuan eksperimen formal, usulkan desain evaluasi yang meminimalkan jebakan bab ini — dan jelaskan apa yang tetap tidak bisa disimpulkan.

Answer key 1.2

Desain yang bisa dilakukan sekarang: sisihkan secara acak sebagian pelanggan eligible yang TIDAK dikirim (holdout), lalu bandingkan tingkat kembali kedua kelompok pada window yang sama. Ini menetralkan regression to the mean (kedua kelompok sama-sama "tidak aktif 90 hari") dan seasonality. Yang tetap terbatas: ukuran ketidakpastian perbedaan (butuh Bab 4-5) dan generalisasi ke periode lain. Kesalahan umum: membandingkan penerima email yang membuka vs tidak membuka — itu bias seleksi (yang membuka memang lebih engaged).

Portfolio idea

★ PORTFOLIO TIP

Tulis artikel pendek "3 cara data menipu di retail" dengan contoh dari dataset publik (tunjukkan regression to the mean sungguhan dengan data). Artefak yang menunjukkan kematangan berpikir — pembeda kuat di level junior.

Further reading

Darrell Huff, *How to Lie with Statistics* · Kahneman, *Thinking, Fast and Slow* (bab regression to the mean) · Wheelan, *Naked Statistics*.

Next chapter

Bab 2 memberi bahasa formal untuk intuisi ini: mean, median, variance, percentile, skewness — dan kapan masing-masing menipu.

Bab 2 — Descriptive Statistics

Pusat, sebaran, dan bentuk — meringkas jutaan baris tanpa berbohong

Learning objectives	Memilih ukuran pusat yang tepat (mean/median/mode); mengukur sebaran (variance, SD, IQR, range); membaca persentil dan skewness; mengenali bentuk distribusi data bisnis dan konsekuensinya
Prerequisites	Bab 1; pandas dasar (Vol 1 Bab 7)
Estimasi waktu	Baca 2 jam · Praktik 4 jam
Difficulty	● Beginner → ● Intermediate
Skills covered	Mean, median, mode, variance, SD, percentile, IQR, range, skewness, distribusi
Business domain	Retail (TokoNusa)

Mengapa ringkasan bisa berbahaya

Descriptive statistics memampatkan jutaan baris menjadi beberapa angka. Pemampatan selalu membuang informasi — dan angka ringkasan yang salah pilih membuang justru informasi yang penting.

Kasus pembuka yang akan kita pakai sepanjang bab: order value TokoNusa Juli 2026, 1,05 juta order completed. "Rata-rata order value: Rp 312.000." Satu angka ini akan kita bongkar sampai terlihat apa yang disembunyikannya.

Ukuran pusat: mean, median, mode

Definisi dan sifat

Ukuran	Definisi	Sifat penting	Kapan tepat
Mean	Jumlah ÷ banyak	Sensitif outlier; satu-satunya yang "additive" (mean × n = total)	Data simetris; kebutuhan proyeksi total
Median	Nilai tengah (P50)	Robust terhadap outlier	Data skewed — mayoritas data bisnis
Mode	Nilai tersering	Satu-satunya yang sah untuk nominal	Kategori; deteksi nilai "default"

Business example — satu dataset, dua cerita

```
orders["net_amount"].describe(percentiles=[.25, .5, .75, .9, .99]).round(0)
```

Expected output (Rp)

count	1,051,224	
mean	312,000	← "rata-rata 312 ribu"
std	694,000	
min	5,000	
25%	98,000	
50%	187,000	← median: setengah order di bawah 187 ribu!
75%	341,000	

90%	632,000	← order korporat (Vol 1 Bab 6)
99%	2,410,000	
max	890,000,000	

Mean (312 ribu) berada di atas persentil ke-60 — artinya "rata-rata" lebih tinggi daripada yang dibelanjakan mayoritas pelanggan. Penariknya: ekor kanan panjang (order besar dan B2B). Untuk menggambarkan pelanggan tipikal, median 187 ribu jauh lebih jujur. Untuk memproyeksikan total revenue, mean tetap yang benar — karena $\text{mean} \times \text{jumlah order} = \text{total}$.

✓ BEST PRACTICE — Aturan pemilihan yang dipakai senior

✓ Pertanyaan tentang "pelanggan/order tipikal" → median ✓ Pertanyaan tentang total/proyeksi → mean (dan laporkan bersama median jika skewed) ✓ Selalu lihat describe() lengkap sebelum memilih — jangan pernah melaporkan mean tanpa pernah melihat distribusinya ✓ Jika mean dan median berbeda jauh, itu sendiri adalah temuan: laporkan keduanya dan jelaskan ekornya.

✗ COMMON MISTAKE — Average of averages

Gejala: "AOV rata-rata semua toko" dihitung dengan merata-ratakan AOV per toko.

Mengapa terjadi: terasa alami — tetapi memberi toko kecil bobot sama dengan toko besar.

Perbaikan: AOV keseluruhan = $\text{total revenue} \div \text{total order (weighted)}$. Rata-rata sederhana dari rasio hampir selalu salah kecuali semua grup berukuran sama — lanjutan langsung dari pelajaran CTE dua tahap Vol 1 Bab 4.

Cara senior menghindarinya: setiap merata-ratakan rasio, tanya: "apakah bobot tiap grup harus sama?"

Ukuran sebaran: variance, standard deviation, IQR, range

Mengapa sebaran sama pentingnya dengan pusat

Dua toko bisa memiliki mean penjualan harian identik — satu stabil, satu roller-coaster. Perencanaan stok, staffing, dan cash flow keduanya sama sekali berbeda. Pusat tanpa sebaran adalah setengah cerita.

Ukuran	Definisi	Catatan praktis
Range	max – min	Ditentukan 2 titik ekstrem — hampir tak berguna sendiri
Variance	Rata-rata kuadrat simpangan dari mean	Satuan kuadrat (Rp^2) — tidak intuitif; batu loncatan matematis
Standard deviation (SD)	$\sqrt{\text{variance}}$	Kembali ke satuan asli; bahasa universal variasi
IQR	P75 – P25	Robust; rentang "50% tengah"; dasar deteksi outlier Vol 1 Bab 6

Membaca SD dalam konteks bisnis

```
daily = (orders.set_index("order_ts")
         .resample("D")["net_amount"].sum() / 1e9) # miliar Rp
print(daily.mean().round(2), daily.std().round(2))
# 4.05 0.38 → mean 4,05 M, SD 0,38 M
```

Interpretasi kerja: pada distribusi yang kira-kira simetris, ± 2 SD mencakup ~95% hari normal. Rentang normal TokoNusa $\approx 4,05 \pm 0,76 \rightarrow \mathbf{3,3 - 4,8 \text{ miliar}}$. Hari 3,7 miliar (kasus Bab 1) berada dalam rentang —

bukan berita. Hari 2,9 miliar berada di luar — layak investigasi. Inilah jawaban formal pertama untuk "apakah ini fluktuasi normal?"

■ TECHNICAL NOTE — Coefficient of variation

Membandingkan variasi antar entitas dengan skala berbeda (toko besar vs kecil) memakai $CV = SD \div \text{mean}$. Toko A: mean 500 juta, SD 50 juta (CV 10%). Toko B: mean 80 juta, SD 24 juta (CV 30%) — toko B relatif jauh lebih fluktuatif meski SD absolutnya lebih kecil.

Persentil: bahasa yang dipakai operasi dan produk

Persentil menjawab "berapa nilai yang membatasi X% data". Dalam praktik industri, persentil sering lebih actionable daripada mean:

Kasus	Metric standar	Mengapa bukan mean
Lead time pengiriman	Median & P90/P95	Janji ke pelanggan harus menutup kasus lambat, bukan kasus rata-rata
Waktu muat aplikasi	P95, P99	Pengalaman terburuk menentukan persepsi
Segmentasi nilai pelanggan	Decile/quintile spend	Dasar skor RFM (Vol 1 Bab 6)
Target sales wajar	P75 performa historis	Menantang tapi tercapai; mean tertarik outlier

Production example — SLA report pengiriman per region

```
sla = (ship.groupby("region")["lead_time_days"]
      .quantile([0.5, 0.9, 0.95]).unstack().round(1))
sla.columns = ["median", "p90", "p95"]
```

region	median	p90	p95
Jakarta	1.8	3.1	4.0
Jawa Barat	2.1	3.9	5.2
Jawa Timur	2.4	4.8	7.5

← ekor panjang: masalah proses, bukan rata-rata


Median Jawa Timur hanya 0,6 hari lebih lambat dari Jakarta — terlihat kecil. Tetapi P95-nya hampir 2× lipat: 5% order terlambat parah. Mean akan menyembunyikan cerita ini; persentil mengeksposnya. Perbaiki proses menyasar ekor, bukan pusat.

Skewness dan bentuk distribusi


Mengapa bentuk menentukan segalanya

Semua keputusan di bab ini — mean vs median, interpretasi SD, pilihan uji statistik nanti di Bab 5 — bergantung pada bentuk distribusi. Kebiasaan wajib: **lihat histogramnya sebelum memilih angka ringkasan.**


RIGHT-SKEWED (positif)



SIMETRIS



LEFT-SKEWED (negatif)



order value, income,
lead time, CLV

tinggi badan,
error pengukuran

nilai ujian mudah,
umur pensiun

Hampir semua metric uang di bisnis right-skewed: banyak transaksi kecil, sedikit yang sangat besar. Konsekuensi praktis yang perlu dihafal: (1) mean > median adalah kondisi normal untuk data uang, (2) SD membesar karena ekor sehingga aturan ± 2 SD menjadi kasar, (3) log-transform sering membuat data uang mendekati simetris untuk analisis (dipakai lagi di Bab 6).

```
orders["net_amount"].skew().round(2)    # 14.3 → sangat right-skewed
np.log(orders["net_amount"]).skew().round(2)  # 0.4 → hampir simetris
```

⚠ **WARNING — Bimodal: dua populasi menyamar jadi satu**

Distribusi berpuncak dua (bimodal) hampir selalu berarti dua populasi tercampur — retail + B2B, weekday + weekend, dua region berbeda. SEMUA angka ringkasan atas campuran bimodal menyesatkan: mean-nya bisa jatuh di lembah tempat hampir tidak ada data. Solusi: pisahkan populasinya dulu (lihat kembali Vol 1 Bab 6 tentang klasifikasi outlier "populasi berbeda").

Ringkasan deskriptif standar — template kerja

Satu fungsi yang dipakai berulang sepanjang karier

```
def describe_business(s: pd.Series) -> pd.Series:
    """Ringkasan deskriptif standar untuk metric bisnis (right-skew aware)."""
    return pd.Series({
        "n": s.count(),
        "null_pct": s.isna().mean().round(3),
        "mean": s.mean(),
        "median": s.median(),
        "sd": s.std(),
        "cv": (s.std()/s.mean()).round(2),
        "p25": s.quantile(.25),
        "p75": s.quantile(.75),
        "p95": s.quantile(.95),
        "skew": s.skew().round(1),
        "mean_med_gap": ((s.mean()-s.median())/s.median()).round(2),
    })
```

`mean_med_gap` adalah alarm cepat: nilai > 0,3 berarti mean 30%+ di atas median — laporkan keduanya dan periksa ekor sebelum menyimpulkan apa pun.

Checklist descriptive statistics

- ✓ Histogram/describe dilihat sebelum memilih ukuran ringkasan
- ✓ Mean dipakai untuk total/proyeksi; median untuk "tipikal"; keduanya dilaporkan jika skewed
- ✓ Rasio dirata-ratakan secara weighted, bukan average of averages
- ✓ Sebaran (SD/IQR/CV) dilaporkan bersama pusat
- ✓ Metric SLA/pengalaman memakai persentil ekor (P90/P95), bukan mean
- ✓ Distribusi bimodal dipecah per populasi sebelum diringkaskan
- ✓ Skewness dicek; log-transform dipertimbangkan untuk data uang

Ending Card — Bab 2

What you learned

Mean/median/mode dan aturan pemilihannya; variance, SD, IQR, CV; interpretasi ± 2 SD sebagai rentang normal; persentil sebagai bahasa operasi; skewness, bentuk distribusi, bahaya bimodal; template describe_business.

Skills mastered

Meringkas tanpa menyesatkan · membaca distribusi sebelum angka · deteksi dua-populasi · pelaporan sebaran.

Real business value

Laporan yang tahan interogasi ("kenapa pakai median?") dan deteksi dini masalah proses lewat ekor distribusi — kemampuan yang langsung terpakai di SLA, pricing, dan target setting.

Interview readiness

● INTERVIEW QUESTIONS

1. "Kapan median lebih tepat dari mean?" — data skewed; beri contoh order value + konsekuensi bisnisnya.
2. "Mean gaji perusahaan 12 juta tapi kebanyakan karyawan merasa digaji di bawah itu — jelaskan." — right-skew; beberapa gaji eksekutif menarik mean.
3. "Apa itu P95 dan kenapa dipakai untuk SLA?" — ekor menentukan janji layanan.
4. "Bagaimana membandingkan variabilitas dua toko yang skalanya beda?" — CV.

Exercises

Exercise 2.1 (Beginner · 15 menit)

Objective: pemilihan ukuran yang tepat

Pilih ukuran ringkasan yang tepat + alasannya: (a) menetapkan janji pengiriman di halaman checkout; (b) memproyeksikan revenue tahunan dari data harian; (c) melaporkan "berapa lama pelanggan tipikal bertahan"; (d) menentukan kategori produk paling umum di keranjang.

Answer key 2.1

(a) P90/P95 lead time — janji harus menutup mayoritas kasus termasuk yang lambat. (b) Mean harian $\times 365$ — hanya mean yang additive (plus koreksi seasonality, Bab 4). (c) Median tenure — tenure right-skewed oleh pelanggan sangat lama. (d) Mode — data nominal.

Exercise 2.2 (Intermediate · 30 menit)

Objective: membongkar angka ringkasan

CFO: "AOV kita naik dari 298 ribu ke 312 ribu bulan ini — pelanggan makin royal!" Susun analisis yang menguji klaim ini. Sebutkan minimal tiga penjelasan alternatif dan cara mengujinya masing-masing.

Answer key 2.2

Alternatif: (1) Beberapa order B2B besar menarik mean — uji: bandingkan median dan mean exclude-B2B; (2) Mix shift — proporsi kategori mahal naik tanpa perilaku individu berubah — uji: AOV per kategori + dekomposisi mix; (3) Order kecil hilang (mis. gangguan channel online) sehingga mean naik meski tak ada yang "makin royal" — uji: jumlah order per bucket nilai. (4) Fluktuasi normal — uji: bandingkan kenaikan dengan SD bulanan historis (formal di Bab 4–5). Pelajaran inti: kenaikan mean punya banyak penyebab yang tidak menyenangkan; median + distribusi + volume membedakannya.

Exercise 2.3 (Advanced · 45 menit)

Objective: analisis distribusi penuh

Dengan dataset transaksi publik (Olist): buat `describe_business` untuk order value, deteksi apakah ada bimodalitas (petunjuk: histogram + pisahkan per kategori/tipe pembayaran), dan tulis 5 kalimat temuan yang siap dibaca manajer non-teknis.

Answer key 2.3 (kriteria)

Kriteria kuat: histogram dengan binning masuk akal (dan log-scale untuk ekor); identifikasi minimal satu pemisahan populasi yang mengubah kesimpulan; temuan ditulis tanpa jargon ("setengah pesanan di bawah X" bukan "median = X"); mean dan median keduanya muncul dengan penjelasan gap. Kesalahan umum: histogram default 10 bin yang menyembunyikan bentuk; melaporkan skewness sebagai angka tanpa arti bisnis.

Portfolio idea

★ PORTFOLIO TIP

Notebook "Distribution audit" atas dataset publik: 5 metric, masing-masing dengan histogram, `describe_business`, pilihan ringkasan yang dibela secara tertulis. Menunjukkan kebiasaan melihat-dulu-baru-meringkas — kebiasaan yang diuji di setiap interview analytics yang baik.

Further reading

Freedman, Pisani, Purves, *Statistics* bab 3–5 · *Practical Statistics for Data Scientists* (Bruce & Bruce) bab 1.

Next chapter

Bab 3: probability — bahasa formal ketidakpastian, fondasi semua inference: aturan dasar, Bayes, expected value, dan distribusi teoretis yang akan dipakai Bab 4–6.

Bab 3 — Probability

Bahasa formal ketidakpastian: aturan dasar, Bayes, expected value, dan distribusi teoretis

Learning objectives	Menguasai aturan probabilitas dan conditional probability; menerapkan Bayes theorem pada masalah bisnis; memakai expected value untuk keputusan; mengenali tiga distribusi teoretis inti (binomial, Poisson, normal) dan kegunaannya
Prerequisites	Bab 1-2
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Intermediate
Skills covered	Probability rules, conditional probability, independence, Bayes, expected value, binomial/Poisson/normal
Business domain	Retail (TokoNusa)

Mengapa analyst butuh probability

Setiap pertanyaan inference di Bab 4 ("apakah kenaikan 4% ini nyata?") dijawab dengan menghitung: seberapa mungkin hasil seperti ini muncul karena kebetulan? Itu pertanyaan probabilitas. Tanpa fondasi ini, p-value dan confidence interval hanya ritual yang dihafal — dan ritual yang dihafal mudah disalahgunakan.

Probability juga bahasa langsung beberapa masalah bisnis: churn adalah probabilitas, konversi adalah probabilitas, fraud detection adalah probabilitas bersyarat.

Dasar: probabilitas sebagai proporsi jangka panjang

Untuk analyst, interpretasi paling berguna: $P(A)$ = proporsi kejadian A jika proses diulang sangat banyak kali. "Probabilitas konversi 3,2%" = dari banyak pengunjung serupa, 3,2% membeli. Interpretasi frekuensi ini membuat semua aturan menjadi aritmetika proporsi — dan bisa selalu dicek dengan query.

Aturan	Rumus	Syarat	Contoh TokoNusa
Komplemen	$P(\text{bukan } A) = 1 - P(A)$	—	$P(\text{tidak churn}) = 1 - P(\text{churn})$
Penjumlahan	$P(A \text{ atau } B) = P(A) + P(B) - P(A \text{ dan } B)$	—	$P(\text{beli kopi atau teh})$ — jangan double hitung yang beli keduanya
Perkalian (independen)	$P(A \text{ dan } B) = P(A) \times P(B)$	hanya jika independen	Dua pengunjung berbeda sama-sama konversi
Perkalian (umum)	$P(A \text{ dan } B) = P(A) \times P(B A)$	selalu benar	$P(\text{buka email DAN klik}) = P(\text{buka}) \times P(\text{klik} \text{buka})$

✗ COMMON MISTAKE — Mengalikan yang tidak independen

Gejala: "P(pelanggan beli 2 bulan berturut-turut) = $0,3 \times 0,3 = 9\%$ " — padahal data menunjukkan 18%.

Mengapa terjadi: pembelian bulan ini dan bulan depan TIDAK independen — pembeli bulan ini lebih mungkin membeli lagi (loyalitas).

Perbaikan: pakai aturan umum dengan conditional: $P(\text{beli lagi} \mid \text{beli bulan ini})$ yang diukur dari data.

Cara senior menghindarinya: independence dianggap klaim yang harus dibuktikan, bukan default. Di data pelanggan, hampir tidak ada yang independen.

Conditional probability: konsep terpenting bab ini

Apa

$P(A|B)$ = probabilitas A di antara kasus-kasus di mana B terjadi. Dalam bahasa SQL: proporsi A dihitung pada subset WHERE B. Hampir semua metric bisnis adalah conditional probability:

```
-- Conversion rate = P(beli | kunjungi)
SELECT COUNT(DISTINCT buyer_id)::float / COUNT(DISTINCT visitor_id)
FROM sessions;

-- Churn rate segment Gold = P(churn | Gold)
SELECT AVG(CASE WHEN churned THEN 1.0 ELSE 0 END)
FROM customers WHERE segment = 'Gold';
```

Arah kondisi tidak bisa dibalik

$P(A|B) \neq P(B|A)$ — dan mencampurnya adalah kesalahan penalaran paling umum di dunia bisnis dan di luar sana:

- $P(\text{pakai voucher} \mid \text{churn}) = 60\%$ bukan berarti $P(\text{churn} \mid \text{pakai voucher}) = 60\%$.
- "80% pelanggan yang komplain lalu churn" $\neq$ "pelanggan yang churn 80% pernah komplain".

Keduanya dihubungkan oleh ukuran masing-masing kelompok — dan itulah isi Bayes theorem.

Bayes theorem — membalik arah kondisi dengan benar

$$P(A|B) = P(B|A) \times P(A) / P(B)$$

Business example — fraud alert yang "akurat 95%"

Sistem fraud TokoNusa mendeteksi 95% transaksi fraud (sensitivitas), dengan false positive 2%. Fraud terjadi pada 0,1% transaksi. Sebuah transaksi ditandai alert. Berapa probabilitas ia benar-benar fraud?

Intuisi kebanyakan orang: ~95%. Mari hitung dengan frekuensi alami per 100.000 transaksi:

```
100.000 transaksi
├─ Fraud: 100 (0,1%)
│   ├── Terdeteksi (alert): 95
│   └── Lolos: 5
└─ Sah: 99.900
    ├── False alarm (alert): 1.998 (2%)
    └── Tidak alert: 97.902

Total alert = 95 + 1.998 = 2.093
P(fraud | alert) = 95 / 2.093 ≈ 4,5%    ← bukan 95%!
```


Karena fraud sangat langka (base rate 0,1%), mayoritas alert adalah false alarm — meski sistemnya "akurat". Inilah **base rate neglect**: mengabaikan $P(A)$ awal. Konsekuensi operasional: tim fraud butuh proses review berlapis, dan "menurunkan false positive 2% → 1%" menggandakan presisi alert — insight yang hanya terlihat lewat Bayes.

◆ BUSINESS INSIGHT — Di mana pola ini muncul lagi

Pola "kondisi langka + tes tidak sempurna → mayoritas positif adalah palsu" muncul di: deteksi churn dini, lead scoring, anomali stok, QA produk cacat, dan screening apa pun. Setiap kali membangun sistem alert, hitung dulu $P(\text{benar} | \text{alert})$ dengan base rate — sebelum menjanjikan akurasi ke stakeholder.

Expected value — jembatan probabilitas ke keputusan

Apa

$EV = \sum (\text{nilai tiap hasil} \times \text{probabilitasnya})$. Ini rata-rata jangka panjang jika keputusan yang sama diulang berkali-kali — dan fondasi seluruh Decision Science di Semester 5.

Business example — apakah free shipping menguntungkan?

Usulan: gratis ongkir (biaya rata-rata Rp 18.000/order) untuk order ≥ 250 ribu.
Data historis menunjukkan estimasi per pengunjung halaman checkout:

	Tanpa promo	Dengan promo	
$P(\text{checkout selesai})$	62%	71%	
AOV	Rp 287.000	Rp 305.000	(orang menambah item)
Margin kotor 28%	Rp 80.360	Rp 85.400	
Biaya ongkir	0	Rp 18.000 $\times P(\text{order} \geq 250\text{rb} = 58\%)$	
EV tanpa promo	$= 0,62 \times 80.360$	$= \text{Rp } 49.823$	
EV dengan promo	$= 0,71 \times (85.400 - 0,58 \times 18.000)$	$= \text{Rp } 53.221$	
Selisih EV $\approx +\text{Rp } 3.400$ per pengunjung checkout → promo layak diuji			

Perhatikan kata terakhir: *diuji*. EV di atas dibangun dari estimasi historis; angka 71% adalah hipotesis. EV memberi tahu apakah ide layak dieksperimenkan (Semester 4), bukan kepastian hasil.

⚠ WARNING — EV bukan segalanya

EV mengabaikan risiko dan sebaran hasil. Keputusan ber-EV positif dengan kemungkinan rugi besar (mis. 5% kemungkinan kehilangan seluruh margin kuartal) bisa tetap tidak layak. Risk-adjusted decision dibahas penuh di Semester 5; untuk sekarang: laporkan EV bersama skenario terburuknya.

Tiga distribusi teoretis yang wajib dikenali

Distribusi teoretis adalah model matematis untuk pola kejadian tertentu. Kenali tiga ini — mereka menutup mayoritas kebutuhan analyst:

Distribusi	Memodelkan	Parameter	Contoh TokoNusa
Binomial	Jumlah "sukses" dari n percobaan independen berpeluang sama	n, p	Jumlah konversi dari 10.000 pengunjung ($p=3,2\%$)
Poisson	Jumlah kejadian per satuan waktu/ruang, kejadian jarang & independen	λ (rata-rata)	Jumlah komplain per jam; kedatangan pelanggan per menit

Normal	Jumlah/rata-rata dari banyak faktor kecil independen	μ, σ	Rata-rata sampel apa pun (via CLT — Bab 4)
---------------	--	---------------	--

Kegunaan praktis: menghitung "seberapa aneh angka ini"

Kasus: biasanya 12 komplain/hari (Poisson). Hari ini 23. Perlu panik?

```
from scipy import stats

# P(komplain >= 23) jika proses normal dengan rata-rata 12/hari
p = 1 - stats.poisson.cdf(22, mu=12)
print(round(p, 3))          # 0.003 → ~3 dari 1000 hari
```

Hasil 23 komplain hanya terjadi ~0,3% waktu di bawah proses normal — hampir pasti ada sesuatu yang berubah (produk cacat batch baru? gangguan pengiriman?). Bandingkan dengan 16 komplain: $P \approx 16\%$ — masih wajar. Ini pola berpikir yang di Bab 4 diberi nama resmi: p-value.

■ TECHNICAL NOTE — Kapan model teoretis TIDAK cocok

Binomial/Poisson mengasumsikan independensi dan laju konstan. Pelanggaran umum: komplain menular (satu insiden viral → burst), konversi berbeda antar segmen (p tidak seragam), kedatangan berpola jam sibuk (λ berubah). Model tetap berguna sebagai baseline per-segmen/per-jam — pecah dulu datanya seperti pelajaran bimodal Bab 2.

Simulasi: alat probabilitas paling praktis untuk analyst

Saat rumus menjadi rumit, simulasi Monte Carlo menjawab hampir semua pertanyaan probabilitas dengan pola yang sama: tiru prosesnya ribuan kali, hitung proporsinya.

Berapa probabilitas revenue bulanan < 110 M jika revenue harian ~ Normal(4,05, 0,38) M?

```
import numpy as np
rng = np.random.default_rng(42)

sims = rng.normal(4.05, 0.38, size=(100_000, 30)).sum(axis=1) # 100rb bulan simulasi
print((sims < 110).mean().round(3))    # 0.002 → risiko sangat kecil
print(np.percentile(sims, [5, 50, 95]).round(1)) # [118.1 121.5 124.9]
```

Tiga baris ini menjawab pertanyaan CFO ("berapa peluang kita meleset dari target?") tanpa satu rumus pun. Simulasi juga alat validasi: jika hasil rumusmu dan simulasimu berbeda, salah satunya salah. Monte Carlo dipakai besar-besaran di Semester 5.

Checklist probability

- ✓ Independence tidak diasumsikan tanpa dasar — terutama pada perilaku pelanggan
- ✓ Arah kondisi eksplisit: $P(A|B)$ tidak dibaca sebagai $P(B|A)$
- ✓ Setiap sistem alert/skor dihitung $P(\text{benar} | \text{positif})$ -nya dengan base rate
- ✓ EV dihitung untuk keputusan berulang, dilaporkan bersama skenario terburuk
- ✓ Kejadian "aneh" diukur terhadap distribusi baseline, bukan insting
- ✓ Simulasi dipakai saat rumus rumit atau untuk memvalidasi rumus

Ending Card — Bab 3

What you learned

Aturan probabilitas dan jebakan independence; conditional probability sebagai metric bisnis; Bayes theorem dan base rate neglect dengan metode frekuensi alami; expected value untuk kelayakan keputusan; distribusi binomial/Poisson/normal; simulasi Monte Carlo dasar.

Skills mastered

Menghitung probabilitas gabungan dan bersyarat dari data · evaluasi sistem alert · EV analysis · simulasi baseline.

Real business value

Mencegah dua kesalahan mahal: sistem deteksi yang membanjiri tim dengan false alarm, dan keputusan promo/pricing tanpa perhitungan nilai harapan.

Interview readiness

● INTERVIEW QUESTIONS

1. Soal klasik: "Tes penyakit 99% akurat, prevalensi 0,5%, hasil positif — berapa peluang benar sakit?" — kerjakan dengan frekuensi alami; jawaban jauh di bawah 99%.
2. "Apa itu expected value? Kapan EV positif tetap keputusan buruk?" — risiko/sebaran; ruin risk.
3. "Conversion rate itu probabilitas apa?" — $P(\text{beli} \mid \text{kunjungi})$; tunjukkan paham conditional.
4. "Bagaimana menguji apakah lonjakan komplain hari ini abnormal?" — baseline Poisson / distribusi historis.

Exercises

Exercise 3.1 (Beginner · 20 menit)

Objective: conditional probability dari data

Dari data TokoNusa: $P(\text{buka email}) = 22\%$, $P(\text{klik} \mid \text{buka}) = 8\%$, $P(\text{beli} \mid \text{klik}) = 11\%$. (a) Berapa $P(\text{beli} \mid \text{lewat jalur email})$ untuk penerima acak? (b) Kampanye ke 500.000 penerima — estimasi jumlah pembeli? (c) Asumsi apa yang paling rapuh?

Answer key 3.1

(a) $0,22 \times 0,08 \times 0,11 \approx 0,19\%$. (b) ≈ 968 pembeli. (c) Bahwa rate historis berlaku untuk kampanye/ audiens ini — rate bervariasi per segmen dan konten; dan pembeli mungkin akan membeli juga tanpa email (incrementality — tema besar Semester 4).

Exercise 3.2 (Intermediate · 30 menit)

Objective: Bayes pada masalah bisnis

Model churn-risk menandai pelanggan "high risk" dengan: mendeteksi 80% churner sesungguhnya, false positive 15%. Base rate churn 90 hari = 12%. (a) Hitung $P(\text{churn} \mid \text{ditandai})$. (b) Tim retention hanya sanggup menghubungi 10.000 pelanggan dari 50.000 yang ditandai — apa implikasi hasilmu?

Answer key 3.2

(a) Per 1.000 pelanggan: 120 churner → 96 ditandai; 880 non-churner → 132 ditandai; $P(\text{churn}|\text{ditandai}) = 96/228 \approx 42\%$. (b) Dari 50.000 yang ditandai, ~21.000 benar-benar akan churn — tetapi tim hanya bisa menghubungi 10.000, jadi butuh *ranking* dalam kelompok ditandai (skor kontinu, bukan flag biner) agar 10.000 teratas berisi proporsi churner tertinggi. Ini motivasi alami untuk model skor Bab 6 (logistic regression).

Exercise 3.3 (Advanced · 45 menit)

Objective: EV + simulasi

Bangun simulasi Monte Carlo untuk keputusan free shipping di bab ini, tetapi dengan ketidakpastian: $P(\text{checkout dengan promo}) \sim$ antara 66%–76% (uniform), AOV dengan promo $\sim \text{Normal}(305\text{rb}, 15\text{rb})$. Berapa probabilitas promo justru menurunkan EV? Tulis rekomendasi 3 kalimat.

Answer key 3.3 (kerangka)

Simulasikan 100 ribu skenario: draw p dan AOV, hitung EV_{promo} per skenario, bandingkan dengan EV_{tanpa} (49.823). Hasil khas: promo unggul di ~85–90% skenario; $P(\text{rugi}) \sim 10\text{--}15\%$. Rekomendasi kuat: EV positif secara ekspektasi tetapi tidak pasti — jalankan sebagai uji terbatas (subset toko/traffic) untuk mengukur p sesungguhnya sebelum rollout; kriteria sukses ditetapkan di depan. Yang dinilai: menyatakan ketidakpastian secara kuantitatif, bukan menjawab "ya/tidak".

Portfolio idea

★ PORTFOLIO TIP

Notebook "Alert system calculator": input sensitivitas, false positive rate, base rate → output $P(\text{benar}|\text{alert})$ + visualisasi frekuensi alami + rekomendasi kapasitas tim. Alat kecil yang menunjukkan pemahaman Bayes aplikatif — jarang ada di portofolio junior.

Further reading

Gigerenzer, *Calculated Risks* (frekuensi alami) · *Introduction to Probability* (Blitzstein & Hwang) bab 1–4 · Jaynes untuk yang haus teori.

Next chapter

Bab 4 memakai semua ini untuk pertanyaan inti Layer 2: dari sampel yang kita punya, apa yang boleh disimpulkan tentang populasi — dan dengan keyakinan berapa? CLT, confidence interval, hypothesis testing, p-value, dan power.

Bab 4 — Statistical Inference

Dari sampel ke populasi: CLT, confidence interval, hypothesis testing, p-value, dan power

Learning objectives	Memahami sampling distribution dan Central Limit Theorem; membangun dan menafsirkan confidence interval dengan benar; menjalankan logika hypothesis testing; menafsirkan p-value tanpa kesalahan klasik; membedakan signifikansi statistik dari signifikansi praktis; memahami statistical power
Prerequisites	Bab 2-3 dikuasai penuh
Estimasi waktu	Baca 3 jam · Praktik 5 jam
Difficulty	● Intermediate → ● Advanced
Skills covered	Sampling, CLT, standard error, confidence interval, hypothesis testing, p-value, effect size, power
Business domain	Retail (TokoNusa)

Mengapa bab ini adalah jantung Layer 2

Semua pertanyaan "apakah ini nyata atau kebetulan?" — kenaikan konversi, perbedaan segment, efek promo — dijawab dengan mesin yang dibangun bab ini. Bab 5 tinggal memilih varian mesinnya; Semester 4 (A/B testing) menjalankannya dalam eksperimen. Pahami bab ini dalam-dalam, dan sisanya menjadi variasi.

Sampling distribution: ide sentral seluruh inference

Eksperimen pikiran yang harus dijalankan sekali seumur hidup

Rata-rata order value dari sampel 1.000 order = Rp 309.000. Ambil 1.000 order lain: Rp 315.200. Lagi: Rp 306.800. **Statistik sampel itu sendiri berfluktuasi** — dan pola fluktuasinya disebut sampling distribution.

Simulasi (jalankan sungguhan — ini 5 baris yang mengubah cara berpikir):

```
pop = orders["net_amount"] # "populasi": 1,05 juta order
means = [pop.sample(1000).mean() for _ in range(10_000)]
pd.Series(means).describe().round(0)
# mean 312.000 ← rata-rata dari rata-rata ≈ mean populasi
# std 21.900 ← fluktuasi antar-sampel: STANDARD ERROR
```

Central Limit Theorem

Tiga fakta CLT — dan mengapa masing-masing penting:

1. **Sampling distribution dari mean mendekati normal**, bahkan jika data aslinya sangat skewed (order value: skew 14!). Inilah alasan distribusi normal mendominasi inference.
2. **Pusatnya = mean populasi**. Sampling yang benar tidak bias.
3. **Sebarannya = $\sigma/\sqrt{n}$** , disebut **standard error (SE)**. Membesar 4× sampel → SE mengecil hanya 2×. Presisi itu mahal — akar kuadrat, bukan linear.

■ TECHNICAL NOTE — SD vs SE, sekali dan untuk selamanya

SD mengukur sebaran *data individual* (order berbeda-beda nilainya). **SE** mengukur ketidakpastian *estimasi statistik* (seberapa goyah angka mean kita). SD tidak mengecil dengan sampel besar; SE mengecil. Mencampur keduanya adalah kesalahan interpretasi paling umum saat membaca laporan — dan pertanyaan interview favorit.

Confidence interval — melaporkan estimasi dengan jujur

Konstruksi

CI 95% untuk mean $\approx$ estimasi $\pm 1,96 \times SE$. Untuk contoh di atas: $312.000 \pm 1,96 \times 21.900 \rightarrow [269.000, 355.000]$.

```
import scipy.stats as stats
s = pop.sample(1000)
ci = stats.t.interval(0.95, df=len(s)-1, loc=s.mean(), scale=stats.sem(s))
```

Interpretasi yang benar (dan yang salah)

Pernyataan	Status
"Prosedur yang menghasilkan interval ini menangkap nilai sebenarnya 95% dari waktu"	Benar
"Kami cukup yakin mean populasi ada di sekitar rentang ini"	Benar (bahasa kerja yang jujur)
"95% data berada dalam interval ini"	Salah — itu SD, bukan SE
"Ada probabilitas 95% mean sejati di interval ini" (interpretasi ketat frequentist)	Secara teknis keliru, tapi diterima sebagai bahasa sehari-hari

✓ BEST PRACTICE — CI di setiap deliverable

Setiap estimasi dari sampel (survei, uji coba terbatas, subset) dilaporkan dengan CI: "konversi varian baru 3,4% [3,1%–3,7%]". Kebiasaan ini sendirian sudah menaikkan kelas laporanmu — ia memaksa pembaca melihat ketidakpastian dan mencegah pertengkaran atas perbedaan yang tidak bermakna.

Hypothesis testing — logika pengadilan untuk angka

Kerangka logikanya

1. H_0 (null): "tidak ada efek / tidak ada perbedaan" ← terdakwa dianggap tak bersalah
2. H_1 (alternatif): "ada efek"
3. Kumpulkan data
4. Hitung: JIKA H_0 benar, seberapa mungkin data se-ekstrem ini muncul?
→ itulah p-value
5. p kecil ($< \alpha$, biasanya 0,05) → data sulit dijelaskan kebetulan
→ tolak H_0 p besar → BUKTI TIDAK CUKUP (bukan " H_0 benar")

Business example lengkap

Halaman checkout baru diuji pada 12.000 pengunjung: konversi 3,51% vs baseline historis stabil 3,20%. Apakah kenaikannya nyata?

```
from statsmodels.stats.proportion import proportions_ztest

conv, n = 421, 12_000                                # 421/12000 = 3,51%
stat, pval = proportions_ztest(conv, n, value=0.032, alternative='larger')
print(round(pval, 3))                                # 0.033
```

$p = 0,033$: jika halaman baru sebenarnya tidak lebih baik (H_0), hasil sebaik ini muncul hanya $\sim 3,3\%$ dari waktu. Di bawah $\alpha = 0,05 \rightarrow$ tolak H_0 ; kenaikan kemungkinan besar nyata. Tetapi laporan yang lengkap tidak berhenti di sini — lanjut ke effect size.

p-value: apa artinya, dan lima cara ia disalahpahami

Definisi presisi: **p-value = P(data se-ekstrem ini atau lebih | H_0 benar)**. Bukan yang lain. Lima kesalahan yang harus bisa kamu deteksi di laporan orang lain:

Kesalahan	Mengapa salah
"p = 0,03 berarti 97% yakin efeknya nyata"	p bukan P(H_1 benar) — arah kondisinya terbalik (pelajaran Bayes Bab 3!)
"p = 0,2 berarti tidak ada efek"	Absence of evidence $\neq$ evidence of absence; mungkin sampel kurang (power!)
"p = 0,001 berarti efeknya besar"	p mencampur ukuran efek dan ukuran sampel; n raksasa membuat efek mikroskopis "signifikan"
"p = 0,049 sukses, p = 0,051 gagal"	0,05 adalah konvensi, bukan hukum alam; keduanya bukti berkekuatan hampir sama
Menguji 20 hal, melaporkan yang p < 0,05	Multiple testing: dari 20 uji atas efek nol, ~ 1 akan "signifikan" karena kebetulan

⚠ WARNING — p-hacking: dosa profesional

Menjalankan banyak uji/segmen/varian lalu hanya melaporkan yang signifikan disebut p-hacking — dan analytics korporat sangat rawan: "coba pecah per region... per segment... per minggu... nah ini signifikan!" Disiplin minimum: tetapkan hipotesis sebelum melihat hasil; laporkan semua uji yang dilakukan; anggap temuan dari eksplorasi sebagai *hipotesis baru untuk diuji ulang*, bukan kesimpulan. Koreksi formal (Bonferroni dkk.) dibahas di Semester 4.

Effect size — pertanyaan yang lebih penting dari p

Setelah "apakah nyata?", pertanyaan bisnis sejati: **seberapa besar?** Untuk kasus checkout: kenaikan 0,31 poin persentase = +9,7% relatif. Pada 8 juta kunjungan checkout/tahun dan AOV 312 ribu: $\approx +7,7$ miliar revenue/tahun — jauh melampaui biaya redesign. Itu kalimat yang dibaca eksekutif; p-value cukup di appendix.

◆ BUSINESS INSIGHT — Signifikan $\neq$ penting, penting $\neq$ signifikan

Dengan n besar, perbedaan konversi 0,01 poin bisa "signifikan" tetapi tak bernilai bisnis. Dengan n kecil, efek besar yang menguntungkan bisa "belum signifikan" — jangan dibuang; kumpulkan data lagi. Keputusan bisnis membutuhkan KEDUANYA: bukti kenyataan (p/CI) dan ukuran dampak (effect size dalam rupiah).

Statistical power — mengapa uji yang gagal sering gagal sejak desain

Apa

Power = $P(\text{mendeteksi efek} \mid \text{efek benar-benar ada})$. Konvensi target: 80%. Power ditentukan oleh: ukuran efek yang ingin dideteksi, ukuran sampel, variasi data, dan α .

Mengapa analyst wajib menghitungnya SEBELUM uji

```
from statsmodels.stats.power import NormalIndPower
from statsmodels.stats.proportion import proportion_effectsize

# Berapa sampel untuk mendeteksi kenaikan konversi 3,2% → 3,5%?
es = proportion_effectsize(0.035, 0.032)
n = NormalIndPower().solve_power(es, power=0.8, alpha=0.05)
print(int(n))          # ≈ 56.000 per grup!
```

Intuisi yang mengejutkan pemula: mendeteksi perubahan kecil pada rate kecil butuh sampel *sangat besar*. Uji dengan 2.000 pengunjung per grup untuk efek sebesar ini punya power ~10% — hampir pasti "tidak signifikan" *meskipun efeknya ada*. Uji semacam itu membuang waktu semua orang dan, lebih buruk, menghasilkan kesimpulan salah "fitur tidak berpengaruh".

✗ COMMON MISTAKE — "Ujinya gagal" padahal desainnya yang gagal

Gejala: serangkaian inisiatif dinyatakan "tidak berpengaruh" berdasarkan uji-uji kecil.

Mengapa terjadi: tidak ada perhitungan power; sampel ditentukan oleh ketidaksabaran.

Perbaikan: hitung kebutuhan sampel di depan; jika tidak realistis, ubah desain (efek lebih besar, metric lebih sensitif, durasi lebih panjang) atau jangan uji.

Cara senior menghindarinya: pertanyaan refleksi sebelum menyetujui uji: "berapa power-nya untuk efek yang worth acting on?"

Template laporan inference — format kerja standar

```
KLAIM      : Checkout baru menaikkan konversi
DESAIN     : n = 12.000 kunjungan, baseline historis 3,20% (stabil 6 bulan)
HASIL      : 3,51% [CI 95%: 3,19% – 3,84%]
UJI        : one-sided z-test vs 3,20% → p = 0,033
EFFECT SIZE: +0,31 pp (+9,7% relatif) ≈ +Rp 7,7 M/tahun pada volume saat ini
KETERBATASAN: bukan eksperimen terkontrol – pembanding adalah baseline
              historis; perubahan musiman/traffic-mix dapat mencemari.
              Rekomendasi: konfirmasi dengan A/B test (Semester 4).
```

Enam baris ini adalah bentuk jadi dari seluruh bab: estimasi + ketidakpastian + uji + ukuran dampak + kejujuran tentang keterbatasan.

Checklist inference

- ✓ SD dan SE tidak tertukar; SE dipakai untuk ketidakpastian estimasi
- ✓ Setiap estimasi sampel dilaporkan dengan confidence interval
- ✓ Hipotesis dan α ditetapkan sebelum melihat hasil
- ✓ p-value ditafsirkan sebagai $P(\text{data} \mid H_0)$, bukan $P(H_0 \mid \text{data})$
- ✓ "Tidak signifikan" tidak dilaporkan sebagai "tidak ada efek" tanpa cek power

- ✓ Effect size dalam satuan bisnis menyertai setiap hasil uji
- ✓ Jumlah uji yang dilakukan dilaporkan semua (anti p-hacking)
- ✓ Kebutuhan sampel dihitung sebelum uji dimulai

Ending Card — Bab 4

What you learned

Sampling distribution dan CLT; SE vs SD; konstruksi dan interpretasi CI; logika hypothesis testing; definisi presisi p-value dan lima kesalahannya; p-hacking; effect size dalam rupiah; power dan perhitungan sampel; template laporan inference.

Skills mastered

Kuantifikasi ketidakpastian · uji hipotesis proporsi/mean · desain uji dengan power · pelaporan jujur.

Real business value

Organisasi berhenti bereaksi pada noise dan berhenti membunuh inisiatif bagus dengan uji under-powered — dua perbaikan yang nilainya melampaui gaji seorang analyst.

Interview readiness

● INTERVIEW QUESTIONS

1. "Jelaskan p-value ke orang non-teknis" — pertanyaan interview data paling sering di dunia; latih versi 2 kalimatmu.
2. "Apa beda standard deviation dan standard error?"
3. "Hasil uji $p = 0,3$ — apa kesimpulanmu?" — bukti tidak cukup; cek power; JANGAN bilang "tidak ada efek".
4. "Konversi naik signifikan dengan $p = 0,001$ tapi cuma $+0,02$ pp. Rekomendasi?" — signifikansi praktis; hitung nilai bisnisnya.
5. "Kenapa CLT penting?" — membolehkan inference normal-based pada data non-normal.

Exercises

Exercise 4.1 (Beginner · 20 menit)

Objective: CI dan interpretasi

Survei NPS pada 900 pelanggan acak: skor rata-rata 42, SD 28. (a) Hitung SE dan CI 95%. (b) Tim CX mengklaim "NPS kita 42, naik dari 39 kuartal lalu ($n=850$, SD serupa)". Tanggapi klaim kenaikan ini.

Answer key 4.1

(a) $SE = 28/\sqrt{900} = 0,93$; $CI\ 95\% \approx 42 \pm 1,83 \rightarrow [40,2, 43,8]$. (b) $SE\ perbedaan \approx \sqrt{(0,93^2 + 0,96^2)} \approx 1,34$; perbedaan 3 poin $\approx 2,2\ SE \rightarrow z \approx 2,24$, $p \approx 0,025$ (two-sided): kenaikan kemungkinan nyata secara statistik, tetapi tambahkan: apakah 3 poin bermakna praktis, dan apakah komposisi responden kedua kuartal setara (bias seleksi Bab 1).

Exercise 4.2 (Intermediate · 30 menit)

Objective: mendeteksi kesalahan interpretasi

Review lima kalimat dari laporan internal, temukan dan perbaiki kesalahannya: (a) " $p=0,04$, jadi ada 96% kemungkinan promo berhasil"; (b) " $p=0,45$: terbukti promo tidak berpengaruh"; (c) "kami uji 15 segmen; segmen ibu muda signifikan ($p=0,03$) — fokuskan budget ke sana"; (d) " $n=2$ juta, $p<0,0001$ — efek pasti besar"; (e) "CI 95% konversi: $[3,1\%, 3,7\%]$ — artinya 95% pengunjung konversi di rentang itu".

Answer key 4.2

(a) p bukan $P(H_1|data)$ — arah terbalik. (b) Bukti tidak cukup $\neq$ bukti ketiadaan; laporkan power/CI. (c) Multiple testing: 15 uji $\rightarrow$ ekspektasi ~ 1 false positive; perlakukan sebagai hipotesis, uji ulang terpisah. (d) p kecil karena n raksasa; laporkan effect size — bisa saja $+0,01$ pp. (e) CI adalah ketidakpastian ESTIMASI rate, bukan sebaran individu.

Exercise 4.3 (Advanced · 45 menit)

Objective: desain uji dengan power

Ops ingin menguji apakah packaging baru menurunkan tingkat retur dari 4,0%. Penurunan yang worth acting on: $\geq 0,5$ pp. Volume: 6.000 order/minggu bisa dialokasikan ke uji. (a) Hitung kebutuhan sampel per grup (power 80%, α 0,05, two-sided). (b) Berapa minggu uji harus berjalan? (c) Manajemen minta hasil dalam 2 minggu — tuliskan responmu.

Answer key 4.3

(a) `proportion_effectsize(0.035, 0.04)` $\rightarrow n \approx 22.500$ per grup. (b) $45.000 \text{ total} \div 6.000/\text{minggu} \approx 7,5$ minggu. (c) Respon profesional: dalam 2 minggu (6.000 per grup) power hanya $\sim 30\%$ — jauh dari cukup untuk mendeteksi efek yang ada; opsi: (1) jalankan ± 8 minggu penuh, (2) terima bahwa dalam 2 minggu hanya efek ≥ 1 pp yang terdeteksi andal, (3) naikan alokasi order per minggu. Menyajikan trade-off, bukan menolak — itu cara senior berkomunikasi.

Portfolio idea

★ PORTFOLIO TIP

Notebook "CLT dari nol": simulasikan sampling distribution dari data skewed nyata, tunjukkan konvergensi ke normal, bangun CI dengan simulasi vs rumus. Kemampuan MENUNJUKKAN teori dengan simulasi adalah sinyal pemahaman sejati yang dicari hiring manager teknis.

Further reading

ASA Statement on p-values (2016) — wajib baca · *Statistical Rethinking* (McElreath) bab 1-3 untuk perspektif · *Practical Statistics for Data Scientists* bab 2-3.

Next chapter

Bab 5 mengoperasikan mesin ini: katalog uji statistik (t-test, ANOVA, chi-square, correlation) — cara memilih, menjalankan, dan melaporkannya dengan scipy.

Bab 5 — Uji Statistik dalam Praktik

t-test, ANOVA, chi-square, correlation — memilih senjata yang tepat dan melaporkannya dengan benar

Learning objectives	Memilih uji yang tepat berdasarkan tipe data dan pertanyaan; menjalankan t-test (independent & paired), ANOVA, chi-square, dan uji korelasi dengan scipy; memeriksa asumsi; melaporkan hasil dengan effect size
Prerequisites	Bab 4 dikuasai penuh
Estimasi waktu	Baca 2,5 jam · Praktik 5 jam
Difficulty	● Intermediate → ● Advanced
Skills covered	t-test, paired t-test, ANOVA, chi-square, Pearson/Spearman correlation, uji non-parametrik, pemeriksaan asumsi
Business domain	Retail (TokoNusa)

Peta pemilihan uji — mulai dari sini, selalu

Semua uji di bab ini adalah mesin Bab 4 dengan varian rumus. Yang membedakan analyst kompeten: memilih uji dari *struktur pertanyaan dan tipe data*, bukan dari kebiasaan.

Pertanyaan	Data	Uji utama	Alternatif robust
Rata-rata 2 grup independen berbeda?	Numerik × biner	Independent t-test (Welch)	Mann-Whitney U
Rata-rata entitas yang sama, sebelum vs sesudah?	Numerik berpasangan	Paired t-test	Wilcoxon signed-rank
Rata-rata ≥ 3 grup berbeda?	Numerik × kategori	One-way ANOVA	Kruskal-Wallis
Dua variabel kategori berasosiasi?	Kategori × kategori	Chi-square independence	Fisher exact (sel kecil)
Dua variabel numerik berhubungan?	Numerik × numerik	Pearson correlation	Spearman (monotonic/outlier)
Dua proporsi berbeda?	Biner × biner	Two-proportion z-test	Chi-square 2×2 (setara)

✓ **BEST PRACTICE — Protokol empat langkah untuk SEMUA uji**

1) Tulis H_0/H_1 dan α sebelum melihat hasil → 2) Cek asumsi (dan pilih varian robust bila ragu) → 3) Jalankan uji → 4) Laporkan: statistik uji, p, CI, effect size dalam satuan bisnis, keterbatasan. Empat langkah ini tidak pernah dilewati, apa pun ujinya.

Independent t-test — dua grup, satu metric numerik

Business question

Apakah AOV pelanggan app berbeda dari pelanggan web? (Sampel: 4.200 pengguna app, 5.100 web, satu bulan.)

```
from scipy import stats

app = df.loc[df.platform=="app", "aov"]
web = df.loc[df.platform=="web", "aov"]

# Welch t-test: TIDAK mengasumsikan varians sama – default yang aman
t, p = stats.ttest_ind(app, web, equal_var=False)
print(f"t={t:.2f}, p={p:.4f}")           # t=3.41, p=0.0007
print(app.mean()-web.mean())           # +Rp 14.200
```

Asumsi — dan seberapa peduli kamu harus

Asumsi	Cara cek	Seberapa kritis
Independensi observasi	Desain data: satu pelanggan satu baris?	KRITIS — pelanggaran merusak semuanya
Normalitas per grup	Histogram	Longgar jika n besar (CLT); hati-hati di $n < 30$ + skew berat
Varians sama	—	Abaikan: selalu pakai Welch (equal_var=False)

✗ COMMON MISTAKE — Grain salah = independensi runtuh

Gejala: uji dijalankan pada grain transaksi (1,05 juta baris) padahal pertanyaannya tentang pelanggan; p-value menjadi sangat kecil secara artifisial.

Mengapa terjadi: transaksi dari pelanggan yang sama berkorelasi — 20 transaksi si A bukan 20 bukti independen. Uji "melihat" lebih banyak informasi daripada yang sebenarnya ada.

Perbaikan: agregasi ke grain pelanggan dulu (AOV per pelanggan), baru uji. Pelajaran grain Vol 1 Bab 2 — kini dengan konsekuensi inferensial.

Cara senior menghindarinya: sebelum uji apa pun: "apakah tiap baris adalah unit independen dari pertanyaan ini?"

◆ BUSINESS INSIGHT — Signifikan, lalu kenapa?

$p = 0,0007$ menyatakan perbedaan app-web nyata. Tetapi +14 ribu itu *bukan bukti bahwa app MENYEBABKAN belanja lebih besar* — pengguna app mungkin memang pelanggan yang lebih loyal sejak awal (self-selection, Bab 1). Uji perbedaan menjawab "apakah berbeda", bukan "mengapa berbeda". Klaim kausal butuh Semester 4. Kalimat pengaman untuk laporanmu: "pengguna app berbelanja lebih besar; sebagian atau seluruhnya dapat dijelaskan oleh siapa yang memilih memakai app".

Paired t-test — entitas sama, dua kondisi

Business question

60 toko dipasang layout baru. Bandingkan penjualan 4 minggu sebelum vs 4 minggu sesudah *di toko yang sama*.

```
t, p = stats.ttest_rel(sales_after, sales_before)
diff = (sales_after - sales_before)
print(f"mean diff = {diff.mean():.0f}, p = {p:.3f}")
# mean diff = +38.400.000 per toko, p = 0.011
```

Mengapa paired jauh lebih kuat daripada membandingkan dua kelompok toko berbeda: variasi antar-toko (lokasi, ukuran) dihilangkan — setiap toko menjadi kontrolnya sendiri. Kebutuhan sampel turun drastis. Tetapi ancaman barunya adalah **waktu**: apa pun yang berubah antara periode (musim, promo nasional, cuaca) ikut tertangkap. Paired design kuat terhadap perbedaan antar-entitas, lemah terhadap perubahan waktu — sebutkan ini di setiap laporan before-after.

One-way ANOVA — tiga grup atau lebih

Business question

Apakah AOV berbeda antar lima region? (H_0 : semua mean region sama.)

```
groups = [g["aov"].values for _, g in cust.groupby("region")]
F, p = stats.f_oneway(*groups)
print(f"F={F:.1f}, p={p:.4f}")          # F=8.7, p<0.0001
```

ANOVA hanya menjawab "setidaknya satu region berbeda" — bukan region mana. Lanjutan yang benar: post-hoc test (Tukey HSD) yang mengoreksi multiple comparison:

```
from statsmodels.stats.multicomp import pairwise_tukeyhsd
print(pairwise_tukeyhsd(cust["aov"], cust["region"]))
# hanya Jakarta vs Jawa Timur & Jakarta vs Sumatera yang signifikan
```

⚠ WARNING — Jangan ganti ANOVA dengan 10 t-test

Membandingkan 5 region berpasangan = 10 uji; pada $\alpha=0,05$, peluang minimal satu false positive $\approx 40\%$. Inilah multiple testing Bab 4 dalam bentuk paling umum. ANOVA + Tukey ada justru untuk mengendalikan ini.

Chi-square — asosiasi dua variabel kategori

Business question

Apakah pilihan metode pembayaran berasosiasi dengan segment pelanggan?

```
ct = pd.crosstab(cust["segment"], cust["payment_pref"])
chi2, p, dof, expected = stats.chi2_contingency(ct)
print(f"chi2={chi2:.1f}, p={p:.4f}")      # chi2=214.6, p<0.0001

# Effect size: Cramér's V (0=tak ada asosiasi, 1=sempurna)
n = ct.values.sum()
V = (chi2 / (n * (min(ct.shape)-1))) ** 0.5
print(f"V={V:.2f}")                     # V=0.08 → asosiasi LEMAH
```

Kasus ini contoh sempurna pelajaran Bab 4: $n = 35.000$ membuat p sangat kecil, tetapi Cramér's $V = 0,08$ menunjukkan asosiasinya lemah — pola pembayaran antar segment hampir sama. Laporan yang hanya menyebut "berasosiasi signifikan ($p<0,0001$)" akan menyesatkan pembaca ke arah kesimpulan yang

datanya sendiri tidak dukung. Syarat teknis: expected count per sel ≥ 5 ; jika ada sel kecil, gabungkan kategori atau pakai Fisher exact.

Correlation — hubungan dua variabel numerik

Pearson vs Spearman

	Pearson r	Spearman ρ
Mengukur	Hubungan LINEAR	Hubungan MONOTONIC (berbasis ranking)
Sensitif outlier?	Sangat	Robust
Default untuk data bisnis	Setelah cek scatter plot	Pilihan aman untuk data skewed/ber-outlier

```
r, p = stats.pearsonr(cust["tenure_months"], cust["annual_spend"])
rho, p2 = stats.spearmanr(cust["tenure_months"], cust["annual_spend"])
print(f"pearson={r:.2f} spearman={rho:.2f}") # 0.61 vs 0.38 → outlier menggelembungkan Pearson
```

Selisih besar Pearson-Spearman adalah alarm: beberapa pelanggan ekstrem mendominasi r. **Selalu lihat scatter plot sebelum melaporkan korelasi** — Anscombe's quartet (empat dataset dengan r identik 0,82 tetapi bentuk sama sekali berbeda) adalah pengingat abadi bahwa satu angka tidak pernah cukup.

⚠ WARNING — Tiga cara korelasi menipu

(1) **Korelasi $\neq$ kausalitas** — es krim berkorelasi dengan kasus tenggelam (keduanya digerakkan musim panas). (2) **Korelasi agregat $\neq$ korelasi individual** (ecological fallacy): korelasi di level toko bisa berlawanan arah dengan level pelanggan. (3) **Range restriction**: korelasi di subset sempit (hanya pelanggan Gold) bisa jauh lebih lemah dari populasi penuh. Ketiganya muncul terus di data korporat.

Uji non-parametrik: kapan beralih

Mann-Whitney, Wilcoxon, dan Kruskal-Wallis bekerja pada ranking — bebas asumsi bentuk distribusi. Beralihlah ketika: n kecil DAN data sangat skewed, ada outlier ekstrem yang sah (tidak boleh dibuang — Vol 1 Bab 6), atau data ordinal (rating). Trade-off: hipotesisnya tentang distribusi/median, bukan mean — pastikan itu memang pertanyaanmu. Untuk metric uang yang skewed, alternatif modern yang semakin standar di industri: **bootstrap CI** (resampling — diperkenalkan di Semester 4).

Studi kasus terintegrasi — satu pertanyaan, protokol penuh

PERTANYAAN : Apakah program membership baru (diluncurkan ke 8.000 pelanggan terpilih acak dari waiting list 20.000) menaikkan frekuensi belanja?

DESAIN : Terpilih acak → perbandingan fair (bukan self-selection!)
Grain: pelanggan. Metric: order per pelanggan, 90 hari.

ASUMSI : Independensi OK (randomized); distribusi right-skewed, n besar → Welch aman

HASIL : member 4,31 vs non 3,87 order [selisih +0,44, CI 95%: 0,29–0,59]
Welch t=5,7, p<0,0001

EFFECT : +11% frekuensi $\approx$ +Rp 4,1 M revenue 90 hari pada grup uji

KETERBATASAN: baru 90 hari (novelty effect mungkin); biaya program belum dihitung di sini → lanjut analisis unit economics (Semester 3)

Perhatikan bagaimana "terpilih acak" mengubah segalanya: perbandingan menjadi fair, dan klaim mendekati kausal. Satu kata di desain lebih berharga daripada seribu kata di analisis — tema besar Semester 4.

Checklist uji statistik

- ✓ Uji dipilih dari peta (tipe data × pertanyaan), dengan alasan tertulis
- ✓ Grain = unit independen dari pertanyaan; agregasi dilakukan bila perlu
- ✓ Welch dipakai sebagai default t-test; scatter dilihat sebelum korelasi
- ✓ ≥ 3 grup memakai ANOVA + post-hoc, bukan t-test berantai
- ✓ Setiap hasil memuat: statistik, p, CI, effect size satuan bisnis
- ✓ Chi-square besar-n selalu didampingi Cramér's V
- ✓ Klaim dibatasi pada "berbeda", bukan "disebabkan", kecuali desain acak

Ending Card — Bab 5

What you learned

Peta pemilihan uji; Welch t-test, paired t-test, ANOVA+Tukey, chi-square+Cramér's V, Pearson/Spearman; asumsi mana yang kritis (independensi!) dan mana yang longgar; non-parametrik; protokol empat langkah dan studi kasus penuh.

Skills mastered

Eksekusi uji dengan scipy/statsmodels · pemeriksaan asumsi proporsional · pelaporan lengkap · pembatasan klaim.

Real business value

Perbandingan segment, region, sebelum-sesudah, dan program — tulang punggung analytics korporat — kini dijawab dengan standar bukti yang bisa dipertahankan di depan siapa pun.

Interview readiness

● INTERVIEW QUESTIONS

1. "Kapan pakai t-test vs chi-square?" — tipe data menentukan; jawab dengan peta.
2. "Apa itu paired t-test dan kapan lebih kuat?" — kontrol variasi antar-entitas; sebut kelemahan terhadap waktu.
3. "Membandingkan 5 grup — kenapa tidak 10 t-test?" — inflasi false positive; ANOVA+Tukey.
4. "Korelasi 0,7 antara X dan Y — apa artinya dan apa yang TIDAK bisa disimpulkan?"
5. "Asumsi t-test apa yang paling penting?" — independensi; beri contoh pelanggaran grain.

Exercises

Exercise 5.1 (Beginner · 20 menit)

Objective: refleksi pemilihan uji

Pilih uji untuk tiap pertanyaan + satu risiko interpretasi: (a) apakah proporsi churn beda antara pelanggan voucher vs non-voucher? (b) apakah rating produk (1-5) beda antar 4 kategori? (c) apakah lead time gudang A vs B berbeda (data sangat skewed, $n=180$ per gudang)? (d) apakah belanja bulanan pelanggan berubah setelah download app (pelanggan yang sama)?

Answer key 5.1

(a) Two-proportion z-test / chi-square 2×2 — risiko: voucher user self-selected, bukan kausal. (b) Kruskal-Wallis (ordinal!) — risiko: memperlakukan rating sebagai interval. (c) Mann-Whitney atau Welch (n cukup, tapi skew berat + n moderat $\rightarrow$ non-parametrik lebih aman) — risiko: hipotesis tentang distribusi, bukan mean. (d) Paired t-test / Wilcoxon — risiko besar: waktu & self-selection (yang download memang makin engaged); sebutkan di laporan.

Exercise 5.2 (Intermediate · 40 menit)

Objective: menemukan cacat analisis

Seorang analyst melaporkan: "Kami menguji AOV antar 6 kota dengan 15 t-test berpasangan pada grain transaksi ($n=890$ ribu); 7 pasangan signifikan $p<0,05$; kota dengan AOV tertinggi adalah target ekspansi terbaik." Tulis review 5 poin sebagai senior.

Answer key 5.2

(1) Grain transaksi melanggar independensi (pelanggan berulang) → p artifisial kecil; agregasi ke pelanggan. (2) 15 uji tanpa koreksi → gunakan ANOVA + Tukey. (3) n raksasa → laporkan effect size; perbedaan mungkin sepele. (4) AOV tinggi ≠ pasar ekspansi baik — metric salah untuk keputusan (butuh ukuran pasar, CAC, kompetisi — Semester 3). (5) Tidak ada CI atau distribusi; mean kota bisa didorong outlier B2B. Bonus: rekomendasi harus memisahkan temuan statistik dari keputusan bisnis.

Exercise 5.3 — Production challenge (Advanced · 60 menit)

Objective: protokol penuh pada data nyata

Dengan dataset Olist: uji apakah review score berasosiasi dengan waktu pengiriman. Jalankan protokol empat langkah lengkap: pilih uji (hati-hati: score ordinal, delivery time skewed), cek asumsi, effect size, dan tulis paragraf kesimpulan untuk manajer logistik.

Answer key 5.3 (kriteria)

Pendekatan kuat: Spearman correlation (ordinal × skewed) atau bandingkan delivery time antar kelompok score dengan Kruskal-Wallis; temuan khas Olist: korelasi negatif nyata (keterlambatan → score rendah), efek terbesar pada order yang melewati estimasi. Kesimpulan manajerial yang baik memuat: arah dan ukuran efek dalam hari, bukan koefisien; identifikasi threshold (terlambat vs cepat); dan batas klaim ("asosiasi kuat; eksperimen pengiriman prioritas dapat mengonfirmasi kausalitas").

Portfolio idea

★ PORTFOLIO TIP

"Statistical testing cookbook" di GitHub: 6 uji bab ini, masing-masing dengan kasus bisnis nyata, kode, cek asumsi, dan template pelaporan. Dokumen yang akan terus kamu pakai kerja — dan bukti kompetensi yang bisa diklik recruiter.

Further reading

scipy.stats & statsmodels docs · *Practical Statistics for Data Scientists* bab 3 · Anscombe (1973) untuk quartet-nya.

Next chapter

Bab 6: regresi — dari menguji perbedaan ke memodelkan hubungan: berapa besar pengaruh X terhadap Y sambil mengontrol variabel lain, dan model skor pertama untuk churn.

Bab 6 — Regression

Memodelkan hubungan: linear, multiple, logistic — interpretasi, asumsi, dan batasnya

Learning objectives	Membangun dan menafsirkan regresi linear sederhana dan berganda; membaca koefisien, R^2 , dan residual dengan benar; memeriksa asumsi dan multicollinearity; membangun logistic regression untuk skor churn; memahami batas kausal regresi
Prerequisites	Bab 4-5
Estimasi waktu	Baca 3 jam · Praktik 6 jam
Difficulty	● Advanced
Skills covered	Simple/multiple linear regression, logistic regression, koefisien, residual, R^2 , asumsi, multicollinearity/VIF
Business domain	Retail (TokoNusa)

Mengapa regresi adalah alat paling serbaguna di kotakmu

Uji di Bab 5 menjawab satu perbandingan dalam satu waktu. Regresi menjawab pertanyaan yang lebih kaya: *berapa besar* hubungan X dengan Y, *sambil memperhitungkan* variabel lain sekaligus. "Apakah diskon menaikkan quantity — setelah memperhitungkan kategori, musim, dan segment?" adalah pertanyaan regresi.

Regresi juga jembatan resmi ke dua semester mendatang: causal inference (Semester 4) adalah regresi dengan desain yang benar; machine learning (Semester 6) dimulai dari regresi sebagai model pertama.

Simple linear regression — satu prediktor

Model dan makna

$$\text{annual_spend} = \beta_0 + \beta_1 \times \text{tenure_months} + \epsilon$$

β_0 (intercept) : estimasi spend saat tenure = 0
 β_1 (slope) : perubahan spend per +1 bulan tenure
 ϵ : semua hal lain (residual)

```
import statsmodels.formula.api as smf

m = smf.ols("annual_spend ~ tenure_months", data=cust).fit()
print(m.summary().tables[1])
```

Expected output (inti)

	coef	std err	t	P> t	[0.025	0.975]
Intercept	1.842.000	41.200	44.7	0.000	1.761.000	1.923.000
tenure_months	28.400	1.310	21.7	0.000	25.800	31.000

Bacaan lengkap satu baris koefisien — template untuk semua regresi:

- **coef 28.400:** tiap tambahan 1 bulan tenure berasosiasi dengan +Rp 28.400 belanja tahunan.

- **std err:** SE koefisien — ketidakpastiannya (Bab 4 bekerja di sini).
- **P>|t| 0.000:** hubungan hampir pasti bukan kebetulan sampling.
- **CI [25.800, 31.000]:** rentang nilai slope yang konsisten dengan data.

⚠ **WARNING — Kata "berasosiasi" itu disengaja**

Koefisien regresi observasional adalah *asosiasi*, bukan efek kausal. Pelanggan ber-tenure panjang mungkin memang tipe orang yang belanja banyak sejak awal. "Menahan pelanggan 12 bulan lagi akan menambah 340 ribu belanja" TIDAK didukung model ini. Disiplin bahasa: *berasosiasi dengan*, bukan *menyebabkan* — sampai desainmu membenarkan lebih (Semester 4).

R² dan residual — seberapa baik model menjelaskan

R² = proporsi variasi Y yang dijelaskan model (0–1). Tiga hal yang wajib dipahami tentangnya:

- **R² = 0,31** berarti 69% variasi spend dijelaskan hal LAIN — dan itu normal untuk perilaku manusia. R² rendah ≠ model tak berguna; slope tetap informatif.
- R² selalu naik saat prediktor ditambah, relevan atau tidak — bandingkan model dengan **adjusted R²**.
- R² tinggi ≠ model benar. Hubungan non-linear, outlier, atau kebocoran data bisa menghasilkan R² tinggi yang menipu.

Residual: alat diagnosis utama

Residual = aktual – prediksi. Plot residual vs prediksi harus terlihat seperti *noise acak tanpa pola*. Pola apa pun adalah pesan:

SEHAT	KURVA (non-linear)	CORONG (heteroskedastis)
• • • • • • • • • • • • •	• • • • • • • • • • • • • • •	• • • • • • • • • • • • • • •
_____	_____	_____
tidak ada pola	model salah bentuk → tambah kuadrat/log	varians membesar → SE tak akurat → CI salah

Untuk data uang yang right-skewed (Bab 2), log-transform pada Y sering menyembuhkan keduanya sekaligus — dan mengubah interpretasi koefisien menjadi persentase: pada model `log(spend) ~ tenure`, koefisien 0,015 ≈ +1,5% spend per bulan tenure.

Multiple regression — kekuatan sesungguhnya

Business question

Marketing bertanya: "Apakah pelanggan app memang belanja lebih banyak — ataukah itu karena pengguna app kebetulan ber-tenure lebih panjang dan tinggal di kota besar?"

```
m2 = smf.ols("annual_spend ~ is_app_user + tenure_months + C(city_tier)",
             data=cust).fit()
```

Expected output (inti)

	coef	P> t	[0.025	0.975]	
Intercept	1.520.000	0.000			
is_app_user	212.000	0.000	164.000	260.000	← turun dari 486rb!
tenure_months	24.100	0.000	22.700	25.500	

C(city_tier)[T.2]	-310.000	0.000	-368.000	-252.000
C(city_tier)[T.3]	-520.000	0.000	-601.000	-439.000

Interpretasi koefisien multiple regression — kalimat yang harus keluar otomatis: **"+Rp 212.000 untuk pengguna app, membandingkan pelanggan dengan tenure dan tier kota yang sama."** Perbedaan mentah 486 ribu menyusut menjadi 212 ribu setelah dikontrol — separuh "efek app" ternyata komposisi penggunaanya. Inilah nilai multiple regression: memisahkan asosiasi yang tumpang tindih.

◆ BUSINESS INSIGHT — "Controlling for" adalah setengah kausalitas

Mengontrol tenure dan kota membuat perbandingan lebih fair, tetapi hanya untuk variabel yang *terukur dan dimasukkan*. Motivasi belanja — tak terukur — tetap mengintai (unobserved confounding). Regresi mempersempit penjelasan alternatif; eksperimen (Semester 4) menutupnya. Nilai praktis hari ini: estimasi 212 ribu jauh lebih dapat dipercaya untuk perencanaan daripada 486 ribu.

Multicollinearity — ketika prediktor saling meniru

Jika dua prediktor sangat berkorelasi (tenure_months dan n_orders_lifetime, $r = 0,85$), model kesulitan memisahkan kontribusi masing-masing: koefisien menjadi tidak stabil, SE membengkak, tanda bisa terbalik — meski prediksi total tetap baik.

```
from statsmodels.stats.outliers_influence import variance_inflation_factor as vif
X = cust[["tenure_months", "n_orders_lifetime", "aov"]].assign(const=1)
for i, c in enumerate(X.columns[:-1]):
    print(c, round(vif(X.values, i), 1))
# tenure_months 5.8 | n_orders_lifetime 6.1 | aov 1.3
```

Panduan kerja: $VIF > 5$ = waspada, > 10 = bermasalah serius. Solusi: buang salah satu, gabungkan (mis. order per bulan tenure), atau — sering paling benar — akui bahwa keduanya membawa informasi yang sama dan pilih yang paling actionable. Catatan penting: multicollinearity merusak *interpretasi koefisien*, bukan akurasi *prediksi* — relevansinya tergantung tujuan model.

Logistic regression — memodelkan probabilitas

Mengapa linear tidak cukup untuk outcome biner

Churn (ya/tidak) bukan angka kontinu. Linear regression bisa memprediksi probabilitas $-0,2$ atau $1,3$ — absurd. Logistic regression memodelkan log-odds sehingga output selalu probabilitas $[0,1]$ — dan inilah model skor churn yang dijanjikan Bab 3.

```
m3 = smf.logit("churned_90d ~ recency_days + frequency + monetary_m + is_app_user",
              data=rfm).fit()
```

Expected output (inti) + odds ratio

	coef	P> z	OR = exp(coef)
Intercept	-2.10	0.000	
recency_days	0.031	0.000	1.031 → tiap +1 hari recency: odds churn x1,03
frequency	-0.24	0.000	0.79 → tiap +1 order: odds churn -21%
monetary_m	-0.08	0.003	0.92
is_app_user	-0.45	0.000	0.64 → pengguna app: odds churn -36%

Dua cara membaca yang harus dikuasai: (1) **odds ratio** = $\exp(\text{koefisien})$ — bahasa standar pelaporan; (2) **predicted probability** per pelanggan — bahasa operasional:

```
rfm["churn_score"] = m3.predict(rfm)
target = rfm.nlargest(10_000, "churn_score") # jawaban Exercise 3.2!
```

Skor kontinu ini persis yang dibutuhkan tim retention berkapasitas 10.000 kontak: ranking, bukan flag. Evaluasi formal kualitas skor (precision/recall, ROC-AUC) menunggu di Semester 6 — untuk sekarang, validasi sederhana: bandingkan churn rate aktual per decile skor; decile teratas harus jauh melebihi decile terbawah.

✗ COMMON MISTAKE — Kebocoran waktu (data leakage)

Gejala: model churn "akurat luar biasa" di data historis, gagal total dipakai nyata.

Mengapa terjadi: fitur dihitung dari periode yang SAMA dengan outcome — mis. recency dihitung pada akhir window yang juga mendefinisikan churn; pelanggan churn otomatis ber-recency besar. Model "memprediksi" masa lalu dari masa depan.

Perbaikan: garis waktu tegas — fitur dari periode t , outcome dari periode $t+1$. Snapshot date eksplisit (kebiasaan RFM Vol 1 Bab 6 menyelamatkanmu di sini).

Cara senior menghindarinya: gambar timeline fitur-vs-outcome sebelum menulis kode. Selalu.

Asumsi regresi — ringkasan kerja

Asumsi	Dicek dengan	Jika dilanggar
Linearitas hubungan	Residual plot (kurva?)	Transformasi (log, kuadrat), atau model non-linear
Independensi residual	Desain data; time series → autokorelasi	SE salah; perlu metode time-series/cluster
Homoskedastisitas	Residual plot (corong?)	Robust SE (cov_type="HC3") atau log Y
Normalitas residual	Histogram residual	Longgar di n besar; penting untuk prediksi interval
Tanpa multicollinearity parah	VIF	Koefisien tak stabil (lihat atas)

■ TECHNICAL NOTE — Robust SE sebagai kebiasaan

Data bisnis hampir selalu sedikit heteroskedastis. Kebiasaan murah yang menyelamatkan: `.fit(cov_type="HC3")` — SE yang valid meski varians tak konstan. Banyak tim analytics menjadikannya default.

Checklist regression

- ✓ Scatter/EDA dilihat sebelum model; bentuk hubungan dipertimbangkan
- ✓ Koefisien dibaca dengan template "per +1 unit X, Y berubah β , dengan variabel lain konstan"
- ✓ Bahasa asosiasi dipakai; klaim kausal ditahan
- ✓ Residual plot diperiksa; log-transform dipertimbangkan untuk Y uang
- ✓ VIF dicek saat interpretasi koefisien penting
- ✓ Outcome biner memakai logistic; skor divalidasi per decile
- ✓ Garis waktu fitur vs outcome digambar (anti-leakage)
- ✓ R^2 dilaporkan dengan konteks, bukan sebagai skor kualitas tunggal

Ending Card — Bab 6

What you learned

Regresi linear sederhana dan pembacaan tabel koefisien; R^2 , adjusted R^2 , diagnosis residual; multiple regression dan makna "controlling for"; multicollinearity/VIF; logistic regression, odds ratio, skor churn; data leakage; asumsi dan robust SE.

Skills mastered

Pemodelan statsmodels · interpretasi koefisien yang presisi · diagnosis model · skor probabilitas operasional.

Real business value

Kemampuan menjawab "berapa besar pengaruhnya, dengan yang lain setara?" dan membangun skor prioritas — dua kemampuan yang mengangkat analyst dari pelapor ke penasihat.

Interview readiness

● INTERVIEW QUESTIONS

1. "Interpretasikan koefisien 212.000 pada `is_app_user` dalam multiple regression" — wajib menyebut "dengan variabel lain konstan".
2. " R^2 model-mu 0,25 — apakah modelnya jelek?" — tergantung tujuan; slope tetap informatif; perilaku manusia memang bervariasi.
3. "Kenapa pakai logistic untuk churn, bukan linear?" — probabilitas $[0,1]$, log-odds.
4. "Apa itu multicollinearity dan kapan kamu peduli?" — interpretasi vs prediksi.
5. "Bagaimana kamu mencegah data leakage di model churn?" — timeline fitur/outcome.

Exercises

Exercise 6.1 (Intermediate · 30 menit)

Objective: interpretasi presisi

Dari model `log(annual_spend) ~ is_app_user + tenure_months + C(segment)`, koefisien: `is_app_user` 0,18 ($p < 0,001$); `tenure` 0,012 ($p < 0,001$); `segment[Gold]` 0,71. Tulis interpretasi tiga koefisien dalam bahasa bisnis yang benar — termasuk jebakan log dan jebakan kausal.

Answer key 6.1

App user berasosiasi dengan spend ~20% lebih tinggi ($\exp(0,18)=1,20$ — untuk koefisien $>0,1$, $\exp()$ wajib, bukan aproksimasi langsung), dengan tenure dan segment sama. Tiap bulan tenure: +1,2%. Gold: ~2× ($\exp(0,71)=2,03$) dibanding segment referensi. Jebakan yang harus disebut: semua adalah asosiasi (self-selection app dan segment); dan segment sebagian ditentukan OLEH spend — sirkularitas yang membuat koefisien Gold hampir tak bermakna (bad control). Poin terakhir ini membedakan jawaban senior.

Exercise 6.2 (Advanced · 60 menit)

Objective: membangun skor churn tanpa leakage

Dengan dataset Olist/serupa: definisikan churn = tidak ada pembelian dalam 6 bulan setelah snapshot; bangun fitur RFM dari 12 bulan SEBELUM snapshot; fit logistic; laporkan odds ratio; validasi churn rate per decile skor. Gambar timeline-mu secara eksplisit.

Answer key 6.2 (kriteria)

Kriteria lulus: timeline digambar (fitur $\leq$ snapshot $<$ outcome window); tidak ada fitur yang menyentuh outcome window; odds ratio dilaporkan dengan arah masuk akal (recency $\uparrow \rightarrow$ churn $\uparrow$); tabel decile menunjukkan monotonic lift (decile 1 vs 10 berbeda $\geq 3\times$). Kesalahan yang menggagalkan: fitur "days_since_last_order" dihitung di akhir outcome window — leakage klasik.

Portfolio idea

★ PORTFOLIO TIP

Exercise 6.2 yang dikemas rapi = proyek portofolio paling bernilai semester ini: masalah bisnis nyata, model interpretable, validasi jujur, dan tabel decile yang bisa dijelaskan ke non-teknis. Sertakan bagian "keterbatasan" — recruiter senior justru mencari itu.

Further reading

Gelman & Hill, *Data Analysis Using Regression* bab 3–5 · statsmodels docs · "Bad controls" — Cinelli et al. untuk yang penasaran.

Next chapter

Bab 7 berpindah ke sisi keluaran: statistik yang benar harus SAMPAI ke pembaca. Prinsip persepsi visual, pemilihan chart, dan desain yang membuat angka dipahami dalam sekejap.

Bab 7 — Prinsip Visualisasi

Persepsi visual, pemilihan chart, dan data-pixel ratio — desain yang membuat angka dipahami sekejap

Learning objectives	Memahami cara mata dan otak memproses grafik (preattentive processing, Gestalt); memilih tipe chart dari struktur pertanyaan; menerapkan prinsip data-pixel ratio; menghindari chart yang menipu; membangun narasi visual (data storytelling)
Prerequisites	Bab 2 (distribusi); Vol 1 Bab 7 (Python) membantu
Estimasi waktu	Baca 2 jam · Praktik 4 jam
Difficulty	● Intermediate
Skills covered	Chart selection, visual perception, Gestalt, data-ink, deceptive charts, storytelling
Business domain	Retail (TokoNusa)

Mengapa visualisasi adalah keterampilan statistik, bukan dekorasi

Chart yang baik adalah argumen statistik yang diproses mata dalam 200 milidetik. Chart yang buruk adalah kebohongan yang tidak disengaja — atau disengaja. Analyst yang menguasai Bab 2-6 tetapi menyajikan dengan chart yang salah menghancurkan pekerjaannya sendiri di meter terakhir.

Prinsip bab ini berdiri di atas riset persepsi (Cleveland & McGill, Few, Tufte), bukan selera. Selera bisa diperdebatkan; cara kerja mata manusia tidak.

Cara mata membaca angka: hierarki akurasi persepsi

Manusia membandingkan kuantitas dengan akurasi yang sangat berbeda tergantung encoding visualnya. Urutan dari paling akurat ke paling buruk:

AKURAT —————> KASAR				
1. Posisi pada skala yang sama (scatter, dot)	2. Panjang (bar)	3. Sudut/kemiringan (pie!)	4. Luas (bubble)	5. Warna (heatmap)
Konsekuensi: bandingkan kuantitas dengan POSISI/PANJANG. Sudut, luas, dan intensitas warna hanya untuk kesan umum.				

Satu tabel ini menjelaskan hampir semua aturan pemilihan chart — termasuk mengapa pie chart bermasalah: ia meminta mata membandingkan sudut dan luas, dua encoding terburuk.

Preattentive processing: menyorot tanpa berteriak

Beberapa atribut visual diproses otak *sebelum* perhatian sadar (<250 ms): warna yang berbeda sendiri, ukuran yang berbeda sendiri, orientasi, posisi. Gunakan ini untuk mengarahkan mata ke SATU hal penting:

- Semua bar abu-abu, satu bar (temuan utama) berwarna — pembaca melihatnya sebelum membaca apa pun.

- Garis pesaing abu-abu tipis, garis kita tebal berwarna.
- Satu titik anotasi ("promo mulai di sini") pada garis tren.

⚠ **WARNING — Sorotan hanya bekerja jika langka**

Jika lima elemen disorot, tidak ada yang tersorot. Dashboard penuh warna cerah = dashboard tanpa prioritas. Aturan kerja: warna kuat maksimal untuk 1-2 elemen per chart; sisanya kalem (abu-abu, biru redup). Dan karena ~10% pria buta warna merah-hijau: bedakan dengan *intensitas* dan posisi, jangan hanya hue merah-vs-hijau.

Prinsip Gestalt: mengelompokkan tanpa garis

Prinsip	Isi	Aplikasi praktis
Proximity	Yang berdekatan dianggap satu kelompok	Kelompokkan KPI terkait dengan jarak, bukan border
Similarity	Yang mirip (warna/bentuk) dikelompokkan mata	Satu warna = satu kategori, konsisten di seluruh laporan
Enclosure	Latar tipis menyatukan area	Background lembut untuk zona "actual vs forecast"
Continuity	Keselarasan menciptakan hubungan	Indentasi dan alignment tabel menggantikan garis grid

Konsekuensi praktisnya satu: **hampir semua border, grid tebal, dan kotak-kotak di laporan bisa dihapus** — ruang kosong dan penataan melakukan pekerjaannya dengan lebih tenang.

Data-pixel ratio: hapus sampai tersisa data

Prinsip Tufte/Few: maksimalkan piksel yang menyampaikan data, minimalkan sisanya. Daftar penghapusan yang hampir selalu benar:

- ✓ Efek 3D — SELALU hapus; memiringkan pembacaan nilai tanpa menambah apa pun
- ✓ Background berwarna/gradasi, drop shadow, ornamen
- ✓ Grid tebal → ganti tipis samar, atau hapus dan beri label langsung
- ✓ Legend terpisah → label langsung di ujung garis/bar bila memungkinkan
- ✓ Border chart, tick mark berlebih, angka desimal tak perlu (312.418.203 → 312 M)
- ✓ Judul generik ("Grafik Penjualan") → judul temuan ("Penjualan Q3 turun 12%, terkonsentrasi di Jawa Timur")

✓ **BEST PRACTICE — Judul adalah kesimpulan**

Chart profesional memakai judul yang menyatakan temuannya, bukan topiknya. Pembaca yang hanya membaca judul-judul chart-mu harus sudah menangkap seluruh cerita — ini pyramid principle (Vol 1 Bab 8) versi visual.

Pemilihan chart: dari struktur pertanyaan

Pertanyaan	Chart utama	Catatan
Tren melintasi waktu	Line chart	Waktu selalu di sumbu-X; maksimal 4-5 garis
Perbandingan antar kategori	Bar chart (horizontal jika label panjang)	Urutkan by nilai, bukan alfabet; baseline WAJIB 0

Komposisi (part-to-whole)	Stacked bar / bar 100%	Pie hanya jika 2-3 bagian dan presisi tak penting
Distribusi	Histogram, box plot	Bab 2 dalam bentuk visual; box plot untuk banyak grup
Hubungan 2 variabel	Scatter plot	Wajib sebelum korelasi/regresi (Bab 5-6)
KPI tunggal + konteks	Big number + sparkline + pembandingan	Angka tanpa pembandingan tidak komunikatif
Metric vs target + rentang	Bullet graph	Pengganti gauge/spidometer yang boros tempat
Banyak metric sekilas	Sparklines dalam tabel	Konteks historis seukuran kata

Mengapa pie chart hampir selalu kalah

Uji sendiri: lima region dengan share 24%, 22%, 20%, 18%, 16%. Di pie, kelimanya nyaris tak terbedakan; di bar terurut, perbandingannya instan. Persepsi sudut dan luas (encoding #3-4) kalah telak dari panjang (#2). Pengecualian yang jujur: menunjukkan "satu bagian vs sisanya" (mis. 78% revenue dari 3 kategori) — dan bahkan itu bisa dilakukan bar 100%.

■ TECHNICAL NOTE — Dual axis: senjata makan tuan

Chart dua sumbu-Y (revenue + conversion di satu chart) memungkinkan pembuat "menceritakan apa saja" dengan memilih skala. Persilangan dua garisnya tidak bermakna apa pun. Alternatif yang lebih jujur: dua panel kecil bertumpuk dengan sumbu-X sama (small multiples). Jika terpaksa dual axis: beri warna sumbu = warna garis, dan nol yang selaras.

Chart yang menipu — kenali sebagai pembaca, hindari sebagai pembuat

Teknik menipu	Efeknya	Aturan jujur
Bar chart mulai dari $\neq 0$	Perbedaan 3% terlihat seperti 3x	Bar: baseline SELALU 0. (Line boleh zoom, dengan label jelas)
Cherry-pick rentang waktu	"Naik 20%!" (dari titik terendah 5 tahun)	Tampilkan konteks historis penuh yang relevan
Sumbu waktu tak merata	Menyembunyikan periode buruk	Interval waktu konsisten
Skala luas/3D untuk kuantitas	Membesar-besarkan perbedaan	Panjang/posisi untuk kuantitas
Persentase tanpa basis n	"Konversi naik 50%!" (dari 2 jadi 3)	Selalu tampilkan n atau nilai absolut

► EXECUTIVE PERSPECTIVE

Eksekutif berpengalaman mengenali chart menipu — dan begitu satu chart-mu ketahuan memanipulasi skala, seluruh analisismu didiskon selamanya. Integritas visual adalah aset kredibilitas, sama seperti rekonsiliasi angka di Vol 1.

Data storytelling: struktur naratif untuk angka

Deck analisis yang efektif mengikuti struktur yang sama dengan executive summary (Vol 1 Bab 8), kini dengan chart sebagai kalimatnya:

1. CONTEXT satu chart baseline: "beginilah kondisi normal"
- ▼
2. CONFLICT chart temuan: "ini yang berubah / bermasalah"
(di sinilah sorotan preattentive bekerja)
- ▼
3. CAUSE chart dekomposisi: "terkonsentrasi di X, didorong Y"
(bar terurut, small multiples)
- ▼
4. ACTION chart proyeksi/opsi: "jika kita lakukan Z"
+ rekomendasi eksplisit

Aturan per slide: satu pesan, satu chart, judul = pesan. Slide dengan tiga chart dan judul topik adalah tempat perhatian audiens mati.

Contoh penerapan: memperbaiki satu chart nyata

SEBELUM: "Grafik Penjualan per Region" – pie 3D, 8 slice, legend terpisah, persentase 2 desimal, gradasi warna pelangi.

Masalah: encoding sudut+luas+3D; 8 kategori tak terbandingkan; mata bolak-balik ke legend; tak ada pesan.

SESUDAH: Bar horizontal terurut, label langsung, satu bar disorot.

Judul: "Jawa Timur menyumbang 31% penurunan Q3 – region lain stabil"

Baseline 0; angka dibulatkan ke miliar; abu-abu + 1 warna sorot.

Hasil : pesan sampai dalam 3 detik, tanpa membaca angka satu pun.

Checklist visualisasi

- ✓ Chart dipilih dari struktur pertanyaan (tren/perbandingan/komposisi/distribusi/hubungan)
- ✓ Kuantitas di-encode dengan posisi/panjang; bar berbasis nol
- ✓ Satu sorotan preattentive per chart; palet kalem + aman buta warna
- ✓ Non-data pixels dihapus: 3D, shadow, grid tebal, legend yang bisa jadi label
- ✓ Judul menyatakan temuan; n/basis absolut ditampilkan untuk persentase
- ✓ Tidak ada dual axis tanpa alasan kuat; small multiples dipertimbangkan
- ✓ Rangkaian chart mengikuti context → conflict → cause → action

Ending Card — Bab 7

What you learned

Hierarki akurasi persepsi; preattentive processing dan disiplin sorotan; Gestalt; data-pixel ratio; tabel pemilihan chart dan kasus melawan pie/dual-axis; lima teknik chart menipu; struktur storytelling 4 babak.

Skills mastered

Chart selection berbasis riset persepsi · penyuntingan visual (menghapus, bukan menambah) · integritas visual · narasi data.

Real business value

Temuan yang sama, disajikan benar, menghasilkan keputusan; disajikan salah, menghasilkan rapat lanjutan. Bab ini menaikkan konversi analisis→tindakan — metric sejati seorang analyst.

Interview readiness

● INTERVIEW QUESTIONS

1. "Kenapa pie chart sering dikritik? Kapan masih OK?" — encoding sudut/luas; kasus 2-3 bagian.
2. "Bar chart boleh tidak mulai dari nol?" — tidak; panjang bar ADALAH datanya. Line berbeda — jelaskan kenapa.
3. "Bagaimana menampilkan 12 produk × 24 bulan tren?" — small multiples / sorot 3 penting + abu-abu sisanya.
4. "Apa yang kamu perbaiki dari dashboard yang 'ramai'?" — jawab dengan kerangka data-pixel ratio + sorotan tunggal.

Exercises

Exercise 7.1 (Beginner · 15 menit)

Objective: refleksi pemilihan chart

Pilih chart + satu keputusan desain penting: (a) tren NPS 8 kuartal; (b) kontribusi 12 kategori terhadap revenue; (c) distribusi lead time pengiriman dua gudang; (d) hubungan diskon% vs quantity per SKU; (e) pencapaian target 6 KPI utama dalam satu layar.

Answer key 7.1

(a) Line; anotasi event penting. (b) Bar horizontal terurut; gabungkan ekor kecil jadi "Others" dengan jujur (disebutkan isinya). (c) Dua histogram bertumpuk sumbu sama, atau box plot berdampingan; JANGAN dua pie. (d) Scatter; log-scale bila perlu; sorot outlier. (e) Enam bullet graph seragam; bukan enam gauge.

Exercise 7.2 (Intermediate · 45 menit)

Objective: kritik dan redesign

Cari satu chart buruk dari media/laporan publik. Tulis kritik menggunakan kosakata bab ini (encoding, data-pixel, sorotan, baseline), lalu buat ulang versi jujurnya dengan matplotlib/seaborn. Dokumentasikan keputusan desainmu.

Answer key 7.2 (kriteria)

Kriteria kuat: kritik menyebut minimal 3 pelanggaran spesifik dengan istilah yang tepat; redesign mengubah encoding (bukan sekadar warna); judul menjadi temuan; before-after diletakkan berdampingan. Kesalahan umum: redesign yang menambah elemen alih-alih menghapus.

Exercise 7.3 (Advanced · 60 menit)

Objective: storytelling penuh

Dari analisis Bab 5–6 (mis. asosiasi keterlambatan vs review score di Olist), bangun deck 4 slide mengikuti context→conflict→cause→action. Setiap slide: satu chart, judul temuan, maksimal 20 kata teks pendukung.

Answer key 7.3 (kriteria)

Lulus jika: membaca 4 judul saja sudah menyampaikan cerita utuh; chart conflict memakai sorotan tunggal; chart cause berupa dekomposisi (bukan mengulang conflict); slide action memuat rekomendasi dengan angka (bukan "perlu perbaikan"). Ini format yang akan dipakai di capstone Bab 9.

Portfolio idea

★ PORTFOLIO TIP

Seri "Chart makeover" (3–5 before-after dengan penjelasan prinsip) adalah konten portofolio yang paling mudah dinilai orang non-teknis — termasuk hiring manager yang cuma punya 90 detik.

Further reading

Stephen Few, *Show Me the Numbers* · Cole Nussbaumer Knaflic, *Storytelling with Data* · Cleveland & McGill (1984) — riset di balik hierarki encoding.

Next chapter

Bab 8 membawa prinsip ini ke medan sesungguhnya: BI dashboard di Power BI — data model, DAX dasar, dan desain dashboard untuk tiga peran berbeda.

Bab 8 — BI Dashboard

Power BI: data model, DAX dasar, dan desain dashboard yang benar-benar dipantau orang

Learning objectives	Membedakan tiga peran dashboard dan konsekuensi desainnya; membangun data model star schema di Power BI; menulis measure DAX dasar dengan benar; menerapkan prinsip Bab 7 dalam layout satu layar; menghindari dashboard yang mati tak dipakai
Prerequisites	Bab 7; Vol 1 Bab 5 (star schema)
Estimasi waktu	Baca 2,5 jam · Praktik 8 jam
Difficulty	● Intermediate → ● Advanced
Skills covered	Power BI data model, relationships, DAX measures, filter context, dashboard layout, KPI design
Business domain	Retail (TokoNusa)

Mengapa dashboard — dan mengapa kebanyakan dashboard gagal

Dashboard adalah tampilan visual informasi terpenting untuk mencapai tujuan tertentu, tertata dalam **satu layar** agar bisa dipantau sekilas. Definisi ini (Few) mengandung tiga kata yang sering dilanggar: *terpenting* (bukan semua), *tujuan* (bukan "biar ada"), *satu layar* (bukan scrolling).

Statistik industri yang jujur: mayoritas dashboard korporat berhenti dibuka dalam 3 bulan. Penyebabnya hampir tidak pernah teknis — melainkan tidak ada keputusan yang bergantung padanya. Ingat Vol 1 Bab 1: dashboard adalah interface untuk monitoring dan decision support, bukan endpoint.

Tiga peran dashboard — desain mengikuti peran

	Strategis	Analitis	Operasional
Pengguna	Eksekutif	Analyst, manager	Tim lapangan/ops
Pertanyaan	"Sehatkah bisnis?"	"Mengapa ini terjadi?"	"Ada masalah SEKARANG?"
Refresh	Harian/mingguan	Harian	Real-time / menit
Isi	KPI level atas + tren + status vs target	Dimensi kaya, drill-down, filter interaktif	Sedikit angka, besar, alert menonjol
Kesalahan khas	Terlalu detail	Terlalu dangkal	Terlalu ramai untuk dilihat 5 detik

✗ COMMON MISTAKE — Satu dashboard untuk semua orang

Gejala: "Dashboard Penjualan" 40 visual yang eksekutif anggap terlalu rumit dan analyst anggap terlalu dangkal — tidak dipakai keduanya.


Mengapa terjadi: menghindari kerja membangun dua tampilan.

Perbaikan: satu data model (satu kebenaran), beberapa halaman per peran. Di Power BI ini murah: halaman "Executive", "Deep-dive", "Ops".

Cara senior menghindarinya: desain dimulai dari daftar KEPUTUSAN per pengguna, bukan daftar chart.

Data model: star schema hidup kembali

Power BI bekerja paling baik persis dengan pola Vol 1 Bab 5: fact table (fct_sales) dikelilingi dimension (dim_date, dim_store, dim_product, dim_customer), relasi one-to-many dari dimension ke fact, filter mengalir dari sisi "one" ke sisi "many".



Aturan emas Power BI:

- ✓ JANGAN satu tabel lebar hasil join semua (flat table)
- ✓ dim_date dedikasi + mark as date table (kunci time intelligence)
- ✓ Measure hidup di model, BUKAN kolom kalkulasi per-baris bila bisa dihindari
- ✓ Relasi many-to-many & bidirectional = bendera merah, hindari

■ TECHNICAL NOTE — Kenapa bukan flat table?

Tabel lebar hasil pre-join membengkakkan memori (dimensi terduplikasi jutaan kali), mematikan fleksibilitas filter, dan mengubur definisi metric di query upstream. Engine kolumnar Power BI (VertiPaq) justru dioptimalkan untuk star schema — kompresi dimensi kecil + fact numerik ramping. Pelajaran arsitektur Vol 1 terbayar tunai di sini.

DAX dasar: measure dan filter context

Konsep tunggal yang menjelaskan semua DAX

Sebuah **measure** dihitung ulang untuk setiap sel visual, di dalam **filter context** sel itu — kombinasi semua filter aktif (baris, kolom, slicer, halaman). Total Revenue di baris "Jakarta" otomatis berarti "revenue DENGAN filter Jakarta". Memahami ini = memahami 80% DAX.

```
-- Measures dasar TokoNusa
Total Revenue = SUMX(fct_sales, fct_sales[quantity] * fct_sales[unit_price]
                    - fct_sales[discount_amount])

Total Orders = DISTINCTCOUNT(fct_sales[order_id])

AOV = DIVIDE([Total Revenue], [Total Orders])    -- DIVIDE = aman ÷0
```

Tiga kebiasaan produksi terlihat lagi: revenue dihitung di grain item (SUMX per baris), order di-DISTINCTCOUNT (fan-out awareness), dan DIVIDE menggantikan operator ÷ (NULLIF versi DAX). Semua disiplin Vol 1 punya padanan di sini.

CALCULATE dan time intelligence — perbandingan yang dibutuhkan semua dashboard

```
Revenue LY = CALCULATE([Total Revenue], SAMEPERIODLASTYEAR(dim_date[date]))
```

```
Revenue YoY% = DIVIDE([Total Revenue] - [Revenue LY], [Revenue LY])
```

```
Revenue MTD = TOTALMTD([Total Revenue], dim_date[date])
```


```
Revenue vs Target% = DIVIDE([Total Revenue], SUM(dim_target[target_amount]))
```

CALCULATE memodifikasi filter context — konsep paling penting sekaligus paling membingungkan di DAX. Bacaan yang benar untuk Revenue LY: "hitung Total Revenue, tetapi geser filter tanggal ke periode sama tahun lalu". Empat measure di atas menutup mayoritas kebutuhan dashboard strategis.

⚠ **WARNING — Validasi DAX seperti memvalidasi query**

Measure yang salah di model salah di SEMUA halaman — pusat kesalahan tunggal. Protokol Vol 1 Bab 4 berlaku: rekonsiliasi Total Revenue model vs SQL sumber vs laporan finance sebelum dashboard dipublikasikan; uji filter context di beberapa irisan (satu toko, satu hari) yang bisa dihitung manual.

Desain layout: prinsip Bab 7 di atas kanvas



SATU layar. Interaksi: slicer periode & region di tepi, bukan tengah.

Aturan yang merangkum skill desain dashboard:

- **Satu layar, tanpa scroll.** Memori kerja manusia 3-9 chunk; yang tak terlihat, terlupakan. Detail pindah ke halaman drill-down, bukan ke bawah.
- **Kiri-atas untuk yang terpenting** — jangan diberikan ke logo.
- **Setiap angka punya konteks:** vs target, vs periode lalu, atau sparkline. "Revenue 121,5 M" sendirian bukan informasi.
- **Warna kalem + alert menyala.** Merah hanya muncul saat ada masalah — sehingga saat muncul, ia berarti.
- **Bullet graph untuk target, bukan gauge.** Enam gauge = satu baris bullet graph dalam ruang yang sama.
- **Konsistensi antar halaman:** posisi filter, palet, dan format angka identik — pengguna belajar sekali.

◆ BUSINESS INSIGHT — Metric definition = kontrak

Saat dashboard resmi diluncurkan, definisi measure-nya menjadi kebenaran organisasi. Sertakan halaman "Definitions" di setiap dashboard: formula bisnis tiap KPI, sumber, jadwal refresh, pemilik. Ini menutup sumber pertengkaran "angka siapa yang benar" (Vol 1 Bab 5) — dan melindungimu saat diaudit.

Dari statistik ke dashboard: menampilkan ketidakpastian

Dashboard yang matang secara statistik (bekal Bab 2-6) membedakan sinyal dari noise di hadapan penggunanya:

- Garis tren harian didampangi moving average 7-hari — noise harian diredam.
- Batas kendali ($\text{mean} \pm 2 \text{ SD}$ dari Bab 2) sebagai band tipis: manajer belajar tidak panik di dalam band.
- Metric dari sampel (NPS, survei) ditampilkan dengan CI — bukan angka telanjang.
- Perbandingan periode diberi label hari kalender yang setara (Vol 2 Bab 4: konteks growth).

Siklus hidup dashboard — agar tidak mati dalam 3 bulan

1. **Kontrak desain** (sebelum membangun): siapa penggunanya, keputusan apa, kapan dilihat, KPI apa + definisi, target refresh. Satu halaman, disetujui pemilik.
2. **Prototype cepat** dengan data nyata → review dengan pengguna sungguhan menonton mereka memakainya (bukan menanyakan pendapat).
3. **Publikasi + definisi + pemilik.**
4. **Audit kuartalan:** lihat usage stats; visual yang tak pernah dilihat dihapus; dashboard tanpa pengguna dipensiunkan dengan hormat.

Checklist BI dashboard

- ✓ Peran (strategis/analitis/operasional) dan daftar keputusan ditetapkan sebelum membangun
- ✓ Data model star schema; dim_date ter-mark; tanpa bidirectional liar
- ✓ KPI sebagai measure DAX terpusat; DIVIDE untuk semua rasio
- ✓ Total model direkonsiliasi vs sumber sebelum publikasi
- ✓ Satu layar; kiri-atas untuk yang terpenting; setiap angka berkonteks
- ✓ Palet kalem, alert bermakna, aman buta warna
- ✓ Halaman definisi metric + pemilik + jadwal refresh tersedia
- ✓ Usage direview berkala; yang tak dipakai dihapus

Ending Card — Bab 8

What you learned

Tiga peran dashboard; star schema di Power BI dan alasan anti-flat-table; measure, filter context, CALCULATE, time intelligence; layout satu layar dengan zona prioritas; menampilkan ketidakpastian; siklus hidup dashboard.

Skills mastered

Data modeling BI · DAX fundamental · KPI design berkonteks · desain berbasis keputusan · governance dashboard.

Real business value

Dashboard yang benar-benar dipantau menggantikan puluhan laporan ad-hoc dan menjadi bahasa bersama manajemen — sementara dashboard yang mati adalah utang perawatan. Bab ini mengajarkan membangun yang pertama.

Interview readiness

● INTERVIEW QUESTIONS

1. "Apa itu filter context di DAX?" — dihitung per sel visual; contoh baris Jakarta.
2. "Kenapa star schema lebih baik dari satu tabel lebar di Power BI?"
3. "Bedanya measure dan calculated column? Kapan masing-masing?" — measure: agregasi dinamis; column: atribut per baris untuk slicing.
4. "Dashboard-mu tidak dipakai user — apa yang kamu lakukan?" — jawaban kuat mulai dari keputusan & observasi pengguna, bukan fitur.
5. "Bagaimana menampilkan target vs aktual 8 KPI dalam satu layar?" — bullet graphs.

Exercises

Exercise 8.1 (Intermediate · 30 menit)

Objective: kontrak desain

Tulis kontrak desain satu halaman untuk dashboard Head of Operations TokoNusa (fulfillment): pengguna, keputusan yang didukung, 5-7 KPI + definisi + konteks pembandingan masing-masing, peran dashboard, refresh.

Answer key 8.1 (jawaban kuat)

Peran: operasional-analitis hibrid, refresh per jam. Keputusan: alokasi shift harian, eskalasi gudang bermasalah, prioritas backlog. KPI: order backlog (vs kapasitas harian), lead time P50 & P90 (vs SLA — bukan mean, pelajaran Bab 2!), % on-time (vs target 95%, tren 4 minggu), throughput per gudang (vs baseline), tingkat retur (band ± 2 SD). Yang dinilai: setiap KPI punya pembandingan dan alasan statistik; tidak lebih dari 7 KPI.

Exercise 8.2 (Advanced · 90 menit)

Objective: DAX + validasi

Dengan dataset Olist di Power BI (atau simulasi TokoNusa): bangun star schema, tulis 6 measure (Revenue, Orders, AOV, Revenue LY, YoY%, On-time%), lalu dokumentasikan protokol validasimu — minimal 3 rekonsiliasi yang kamu jalankan.

Answer key 8.2 (kriteria)

Kriteria: relasi 1:* semua mengarah ke fact; dim_date di-mark; AOV & On-time% memakai DIVIDE; Revenue LY memakai SAMEPERIODLASTYEAR di atas dim_date (bukan kolom fact). Validasi yang diharapkan: (1) Total Revenue vs SUM SQL sumber, (2) satu irisan kecil (1 toko × 1 hari) dihitung manual, (3) DISTINCTCOUNT order vs COUNT DISTINCT sumber; bonus: cek bulan tanpa data tahun lalu (LY harus BLANK, bukan 0).

Exercise 8.3 — Production challenge (Advanced · 3 jam)

Objective: dashboard penuh

Bangun dashboard executive satu layar untuk TokoNusa/Olist mengikuti seluruh checklist: 4 KPI cards berkonteks, tren dengan MA-7 dan band $\pm 2SD$, dekomposisi region terurut, bullet target kategori, halaman definisi. Screenshot + kontrak desain = deliverable.

Answer key 8.3 (rubrik singkat)

Rubrik: satu layar tanpa scroll; kiri-atas KPI; setiap angka berpembandingan; ≤ 2 warna aksent; tidak ada pie >3 slice, tidak ada gauge, tidak ada 3D; band $\pm 2SD$ terlihat dan dijelaskan di tooltip; halaman definisi lengkap. Uji akhir: tunjukkan 10 detik ke orang lain — ia harus bisa menyebut kondisi bisnis (sehat/tidak, di mana masalahnya).

Portfolio idea

★ PORTFOLIO TIP

Publikasikan dashboard Exercise 8.3 (Power BI publish-to-web atau screenshot beranotasi) + kontrak desain + halaman definisi. Kombinasi "dashboard cantik + dokumen keputusan di baliknya" hampir tidak pernah dimiliki kandidat junior — dan itulah yang membedakan dashboard engineer dari analyst.

Further reading

Stephen Few, *Information Dashboard Design* · SQLBI (Russo & Ferrari) untuk DAX serius · Microsoft Learn: Power BI data modeling.

Next chapter

Bab 9 — capstone: seluruh Layer 2 dirangkai. Analisis statistik penuh atas pertanyaan bisnis nyata + dashboard yang mengomunikasikannya — dengan rubrik enam reviewer.

Bab 9 — Capstone Semester 2

Statistical analysis + BI dashboard end-to-end — dari pertanyaan kabur ke bukti terukur yang terpantau

Learning objectives	Mengintegrasikan seluruh Layer 2: inference yang disiplin + visualisasi yang jujur + dashboard yang dipakai; self-review dengan rubrik enam reviewer
Prerequisites	Bab 1-8 beserta exercises; capstone Vol 1
Estimasi waktu	Proyek 15-25 jam (2 minggu part-time)
Difficulty	● Advanced (integrasi) → ● Production Ready
Skills covered	Integrasi penuh Layer 2 + komunikasi
Business domain	E-commerce (Olist) atau retail setara

Skenario

Melanjutkan capstone Vol 1: fondasi data retensi sudah kamu bangun. Head of CRM kembali dengan pertanyaan lanjutan yang lebih tajam:

"Oke, 62% pembeli cuma beli sekali. Sebelum kuajukan budget program retensi ke direksi, aku butuh tiga hal: (1) apa yang **MEMBEDAKAN** pembeli yang kembali dari yang tidak — dengan bukti, bukan feeling; (2) seberapa yakin kita pada temuan itu; (3) dashboard yang bisa kupantau bulanan begitu programnya jalan."

Tiga permintaan itu memetakan persis ke tiga kelompok skill semester ini: analisis perbedaan (Bab 5-6), kuantifikasi keyakinan (Bab 4), dan monitoring (Bab 7-8).

Deliverables — enam artefak

#	Artefak	Menguji bab
D1	Analysis plan: hipotesis (ditetapkan di depan!), uji yang direncanakan, α , kebutuhan power	Bab 1, 4
D2	Notebook EDA: distribusi metric kunci dengan describe_business + histogram yang benar	Bab 2, 7
D3	Notebook inference: minimal 3 uji berbeda jenis + 1 regresi, protokol 4 langkah penuh	Bab 4-6
D4	Model skor repeat-purchase (logistic) dengan validasi decile, tanpa leakage	Bab 6
D5	Dashboard retention satu layar + halaman definisi + kontrak desain	Bab 7-8
D6	Deck 4-slide (context→conflict→cause→action) + executive summary 1 halaman	Bab 7; Vol 1 Bab 8

Spesifikasi analisis inti (D3) — pertanyaan minimum yang diuji

- Pembeli kembali vs sekali-beli:** apakah berbeda dalam nilai order pertama? (Welch/Mann-Whitney — cek skew dulu; grain: pelanggan.)
- Pengalaman pertama dan kembali:** apakah keterlambatan pengiriman order pertama berasosiasi dengan tidak kembalinya pelanggan? (chi-square/two-proportion + effect size dalam pp.)
- Kategori pertama:** apakah repeat rate berbeda antar kategori produk pertama? (chi-square omnibus; hati-hati multiple comparison saat mengulik per kategori.)

4. **Gabungan:** logistic regression repeat ~ nilai order pertama + keterlambatan + kategori + region — mana yang bertahan setelah saling dikontrol?

Setiap pertanyaan mengikuti template pelaporan Bab 4: estimasi + CI + p + effect size bisnis + keterbatasan. Dan satu disiplin ekstra: **semua hipotesis tercatat di D1 sebelum data disentuh** — temuan di luar rencana dilabeli "exploratory, perlu konfirmasi".

⚠ **WARNING — Dua jebakan yang menggagalkan capstone ini**

(1) **Klaim kausal:** "keterlambatan MENYEBABKAN churn" tidak didukung data observasional — tulis "berasosiasi; kandidat eksperimen prioritas pengiriman (Semester 4)". (2) **Leakage di D4:** fitur harus dihitung hanya dari order pertama + window pendek sesudahnya; outcome dari window berikutnya. Gambar timeline sebelum koding.

Spesifikasi dashboard (D5)

RETENTION MONITOR – kontrak: Head of CRM, review bulanan, keputusan: kalibrasi budget & target program retensi

KPI: repeat rate kohort vs kohort lalu	time-to-2nd (median) vs baseline	CI shown
TREN: repeat rate per kohort bulanan (line + CI band)		
CAUSE: repeat rate by kategori-pertama (bar terurut) by status pengiriman pertama (2 bar + selisih)		
ACTION: distribusi skor D4 per decile + volume target		

Catatan desain yang diuji: repeat rate kohort muda belum "matang" (pelanggan baru belum sempat kembali) — tampilkan hanya kohort yang window-nya lengkap, atau beri label maturity. Kesalahan ini sangat umum di dashboard retention nyata dan langsung terlihat oleh reviewer berpengalaman.

Rubrik enam reviewer

Reviewer	Pertanyaan kunci	Lulus jika
Senior Data Analyst	Grain benar? Uji sesuai tipe data? Asumsi dicek?	Tidak ada uji di grain transaksi; Welch/non-param dipilih sadar
Statistician	Interpretasi p/CI benar? Multiple testing terkendali? Power dihitung?	Tak ada satu pun dari 5 kesalahan p-value Bab 4
Analytics Manager	Reproducible? Hipotesis pre-registered?	D1 ditulis sebelum D3; notebook jalan atas-bawah
BI Consultant	Dashboard menjawab keputusan? Satu layar? Definisi ada?	Kontrak → layout bisa ditelusuri 1:1; kohort maturity ditangani
Hiring Manager	Apakah ini bukti kompetensi Layer 2 penuh?	Semua bab terpakai alami; keterbatasan diakui
Eksekutif	Apakah 4 slide meyakinkan untuk keputusan budget?	Judul = temuan; angka berpembanding; rekomendasi + risiko jelas

Kesalahan capstone yang paling sering

- **Menguji segalanya.** 30 uji tanpa rencana = p-hacking terstruktur. Kekuatan capstone ini justru di D1 yang disiplin.

- **Model D4 terlalu ambisius.** Logistic sederhana + validasi decile jujur mengalahkan ensemble canggih tanpa validasi. ML sungguhan menunggu Semester 6.
- **Dashboard menampilkan analisis, bukan monitoring.** D5 bukan tempat memajang scatter regresimu — ia alat pantau bulanan untuk keputusan budget.
- **CI hilang di slide eksekutif.** Justru di hadapan direksi, "repeat rate naik 3pp ± 1pp" adalah kalimat yang membangun kredibilitas jangka panjang.

Ending Card — Bab 9 & Penutup Semester 2

What you learned (semester)

Berpikir statistik (1) → deskriptif (2) → probability (3) → inference (4) → uji praktis (5) → regresi (6) → visualisasi (7) → dashboard (8) → integrasi (9). Output semester tercapai: **mampu mengukur besarnya efek, ketidakpastian, dan kekuatan bukti — lalu mengomunikasikannya lewat analisis dan dashboard yang jujur.**

Portfolio readiness

Capstone Vol 1 + Vol 2 kini membentuk cerita utuh: "membangun fondasi data → menghasilkan bukti terukur → alat monitoring". Tiga artefak yang paling dilirik: notebook inference (D3), model skor tervalidasi (D4), dashboard + kontrak (D5).

Interview readiness (semester)

● SIMULASI INTERVIEW LAYER 2 — uji dirimu

1. Jelaskan p-value dan CI ke orang non-teknis dalam 4 kalimat. (Bab 4)
 2. "Konversi A 3,2% (n=8.000) vs B 3,6% (n=7.900) — jalan mana?" — uji, CI, effect size, lalu rekomendasi. (Bab 4-5)
 3. "Kapan Mann-Whitney dibanding t-test?" (Bab 5)
 4. Interpretasi koefisien logistic + odds ratio. (Bab 6)
 5. "Redesign dashboard 30-visual yang tak dipakai." (Bab 7-8)
 6. "Temuanmu signifikan tapi kecil — apa rekomendasimu?" (Bab 4)
- Lancar di keenamnya dengan contoh konkret = siap interview analyst mid-level di sisi statistik & BI.

Menuju Semester 3

Kamu kini bisa membuktikan bahwa sesuatu berbeda dan mengukur seberapa besar. Pertanyaan berikutnya bersifat bisnis: *mengapa metric ini penting, bagaimana ia terhubung ke mesin ekonomi perusahaan, dan di mana akar masalahnya?* Volume 3 membangun Layer 3: finance, marketing, sales, operations metrics — KPI tree, unit economics, root-cause analysis, dan (janji dari Vol 1) Goodhart's Law: apa yang terjadi ketika metric menjadi target. Sampai jumpa di Layer 3.