

Experimentation & Causal Inference

Volume 4 — Semester 4 dari Kurikulum 7-Layer Analytics

Apakah X benar-benar menyebabkan Y. A/B testing dari desain sampai keputusan ship, lalu causal inference ketika randomisasi tidak mungkin: DAG, difference-in-differences, synthetic control, propensity score, instrumental variables, incrementality.

✓ LAYER 1 — DATA (Volume 1, selesai)

✓ LAYER 2 — STATISTICS (Volume 2, selesai)

✓ LAYER 3 — BUSINESS (Volume 3, selesai)

■ **LAYER 4 — EXPERIMENTATION (volume ini)**

□ LAYER 5 — DECISION SCIENCE

□ LAYER 6 — AI

□ LAYER 7 — DOMAIN EXPERTISE

Tentang Volume 4

Layer tempat analisis berhenti menjadi deskripsi dan mulai menjadi bukti

Utang yang jatuh tempo di volume ini

Tiga volume sebelumnya menumpuk utang intelektual yang disengaja. Volume 1 mengajarkan cara membuat dataset yang dapat dipercaya, lalu berkata: "korelasi ini menarik, tapi jangan disebut sebab." Volume 2 mengajarkan cara mengukur kekuatan bukti, lalu berkata: "signifikan bukan berarti kausal." Volume 3 mengajarkan mesin bisnis, lalu berkata: "flash sale bertepatan dengan penurunan margin — apakah ia penyebabnya, kita belum boleh menyimpulkan."

Volume ini melunasi semuanya. Setiap janji dilacak dan dijawab dengan metode, bukan dengan opini.

Klaim yang tertunda	Asalnya	Dijawab di
Keterlambatan pengiriman → churn	Vol 2, capstone	Bab 8 (DAG) & Bab 10 (propensity score) & Bab 11 (IV)
Flash sale menukar margin dengan traffic	Vol 3, Bab 11	Bab 9 (difference-in-differences)
Attribution marketing bukan incrementality	Vol 3, Bab 5	Bab 12 (geo experiment, ghost ads)
Elastisitas harga tidak boleh diambil dari data observasional	Vol 3, Bab 9	Bab 11 (IV & regression discontinuity)
Expected value gratis ongkir belum diuji	Vol 2, Bab 3	Bab 2, 5, 7 (EXP-041, dibedah tuntas)
Skor churn perlu evaluasi model formal	Vol 3, Bab 6	Volume 6 (tetap ditunda — dan alasannya dijelaskan di Bab 10)

Mengapa layer ini yang memisahkan analyst dari senior analyst

Perusahaan besar tidak kekurangan orang yang bisa membuat chart. Yang langka adalah orang yang bisa berdiri di depan direksi dan berkata: "fitur ini menaikkan contribution margin sebesar Rp 6,1 miliar per tahun, interval kepercayaannya Rp 2,4–9,8 miliar, dan berikut alasan mengapa angka ini bukan kebetulan atau bias seleksi."

Kalimat itu bernilai karena tiga hal yang semuanya dipelajari di volume ini: desain yang membuat perbandingan valid, statistik yang mengukur ketidakpastian dengan jujur, dan penerjemahan efek menjadi rupiah.

Ada alasan struktural mengapa perusahaan seperti Booking.com, Airbnb, dan Microsoft menjalankan puluhan ribu eksperimen per tahun: sebagian besar ide bagus ternyata tidak bekerja. Angka yang sering dikutip dari program eksperimentasi matang — sekitar sepertiga ide menang, sepertiga netral, sepertiga merugikan — bukan kabar buruk. Itu justru alasan mengapa eksperimen ada. Organisasi yang tidak menguji tetap mengirim sepertiga ide yang merugikan, hanya saja tidak pernah tahu.

► EXECUTIVE PERSPECTIVE — apa yang sebenarnya dibeli direksi

Direksi tidak membeli "eksperimen". Mereka membeli **pengurangan risiko keputusan**. Rilis fitur ke 100% pengguna adalah taruhan penuh tanpa informasi; rilis ke 5% dulu adalah membeli informasi dengan harga kecil sebelum bertaruh besar. Bingkai inilah yang membuat permintaan "tolong kita A/B test dulu" disetujui, bukan bingkai statistik.

Dua bagian yang membentuk volume ini

Bagian I — Eksperimen terkontrol (Bab 1-7). Ketika kita bisa mengacak. Ini standar emas: randomisasi menghapus semua confounder sekaligus, termasuk yang tidak kita ketahui keberadaannya. Bagian ini membangun kemampuan menjalankan program A/B testing yang dapat dipercaya, dari perumusan hipotesis sampai memo keputusan.

Bagian II — Causal inference observasional (Bab 8-12). Ketika kita tidak bisa mengacak: harga sudah terlanjur naik, promo sudah terlanjur berjalan, pelanggan memilih sendiri kurirnya. Bagian ini mengajarkan metode yang meniru eksperimen dari data yang tidak dirancang untuk itu — beserta asumsi yang harus dipertahankan dan cara memeriksanya.

Bagian III — Kelembagaan (Bab 13-14). Metode yang benar di organisasi yang salah tetap menghasilkan keputusan buruk. Bab 13 membahas program, governance, dan etika. Bab 14 adalah capstone.

PERTANYAAN: "Apakah X menyebabkan Y?"

- └ Bisa mengacak siapa yang menerima X?
 - └ YA → A/B TEST / RCT Bab 1-7 (bukti terkuat)
 - └ TIDAK
 - └ X berlaku pada sekelompok unit pada waktu tertentu?
 - └ DIFFERENCE-IN-DIFFERENCES Bab 9
 - └ SYNTHETIC CONTROL / ITS Bab 9
 - └ X ditentukan oleh ambang batas tajam?
 - └ REGRESSION DISCONTINUITY Bab 11
 - └ Ada variabel yang mendorong X tapi tidak menyentuh Y?
 - └ INSTRUMENTAL VARIABLE Bab 11
 - └ Semua confounder terukur (asumsi berani)?
 - └ PROPENSITY SCORE / REGRESI Bab 10
 - └ Tidak satu pun terpenuhi?
 - └ JANGAN mengklaim kausal. Bab 8
 - └ Laporkan asosiasi + rancang eksperimen ke depan.
- └ Rangkuman keputusan lengkap: Bab 8, tabel pemilihan metode.

Aturan main yang tidak berubah

Struktur bab tetap: chapter card → WHY → WHAT → WHEN → HOW (simple → business → production) → BEST PRACTICE → COMMON MISTAKE → CHECKLIST → ENDING CARD. Callout box sama. Bahasa Indonesia dengan istilah teknis Inggris dipertahankan dalam bentuk aslinya, karena itulah kosakata yang dipakai di ruang rapat dan wawancara kerja.

TokoNusa tetap menjadi perusahaan berjalan: retail omnichannel, 85 toko, 2,1 juta pelanggan terdaftar, ±13 ribu order per hari (4,74 juta per tahun), AOV Rp 312.000, contribution margin Rp 69.700 per order, revenue FY2025 Rp 1.480 miliar. Volume ini menambah satu lapisan baru: **backlog eksperimen TokoNusa** — daftar tes nyata dengan nomor (EXP-041, EXP-052, EXP-067) yang diikuti dari hipotesis sampai keputusan, dan dipakai ulang di seluruh volume.

■ TECHNICAL NOTE — orientasi volume ini

Volume ini menekankan **intuisi, diagram keputusan, dan konsekuensi bisnis** di atas implementasi kode. Kode tetap ada di titik-titik yang tanpanya konsep menjadi kabur, tetapi porsinya sengaja dijaga: kesalahan mahal dalam eksperimen hampir tidak pernah berupa salah sintaks — melainkan salah unit randomisasi, salah metric, salah waktu berhenti, atau salah asumsi identifikasi. Di situlah halaman-halaman ini dihabiskan.

Daftar isi Volume 4

BAGIAN I — EKSPERIMEN TERKONTROL

- Bab 1** Berpikir Eksperimental — korelasi, kausalitas, counterfactual, potential outcomes, confounder, selection bias
- Bab 2** Anatomi Eksperimen yang Benar — hipotesis, unit randomisasi, OEC, guardrail metric, randomisasi yang tidak bocor
- Bab 3** Sample Size, Power, dan MDE — matematika sebelum tes dijalankan; kapan tes tidak layak dijalankan
- Bab 4** Menjalankan Eksperimen di Dunia Nyata — durasi, musiman, novelty effect, sample ratio mismatch, QA instrumentasi
- Bab 5** Membaca Hasil & Keputusan Ship/No-Ship — CI, effect size, peeking, multiple testing, hasil flat
- Bab 6** Analisis Lanjutan — variance reduction (CUPED), heterogenitas efek, metric ratio, interferensi antar unit
- Bab 7** Ekonomi Eksperimen — dari lift menjadi rupiah; incremental CM; nilai informasi; kapan tidak perlu menguji

BAGIAN II — CAUSAL INFERENCE OBSERVASIONAL

- Bab 8** Peta Kausal — DAG, confounder, collider, mediator, backdoor criterion, memilih metode
- Bab 9** Difference-in-Differences, Event Study, dan Synthetic Control — metode panel
- Bab 10** Propensity Score — matching, weighting, regression adjustment, dan batas kejujurannya
- Bab 11** Instrumental Variables & Regression Discontinuity — elastisitas harga dan ambang gratis ongkir
- Bab 12** Incrementality Marketing — geo experiment, switchback, ghost ads, MMM vs attribution

BAGIAN III — KELEMBAGAAN

- Bab 13** Program Eksperimentasi, Governance & Etika — dari satu tes menjadi kapabilitas organisasi
- Bab 14** Capstone Semester 4 — Causal Evidence Package untuk program retensi TokoNusa

Cara membaca volume ini

Bagian I harus dibaca berurutan; Bab 3 dan Bab 5 saling mengunci dan tidak masuk akal terbalik. Bagian II bisa dibaca melompat setelah Bab 8 dikuasai — tetapi Bab 8 wajib, karena ia yang menentukan metode mana yang sah dipakai.

Setiap bab menutup dengan latihan berjenjang beserta answer key. Latihan bertanda *Production Challenge* membutuhkan waktu berjam-jam dan sengaja dibuat setara dengan tugas kerja nyata; itulah bahan portfolio terkuat dari semester ini.

Bab 1 — Berpikir Eksperimental

Setiap klaim sebab-akibat adalah perbandingan dengan dunia yang tidak pernah terjadi. Bab ini mengajarkan cara membangun dunia itu.

Learning objectives	Menjelaskan mengapa korelasi tidak cukup dengan kerangka formal; menggunakan potential outcomes dan counterfactual; mengidentifikasi confounder, selection bias, dan reverse causality pada kasus nyata; menjelaskan mengapa randomisasi menyelesaikan masalah identifikasi; membedakan ATE, ATT, dan LATE; menilai kekuatan bukti kausal secara berjenjang
Prerequisites	Vol 2 Bab 3–4 (probabilitas, inference); Vol 3 Bab 11 (root-cause analysis)
Estimasi waktu	Baca 2 jam · Praktik 3 jam
Difficulty	● Intermediate
Skills covered	Causal reasoning, potential outcomes framework, identifikasi bias, hierarki bukti, penulisan klaim kausal yang jujur
Business domain	Retail omnichannel (TokoNusa) — kasus keterlambatan pengiriman, program loyalitas, dan email marketing

Mengapa bab ini ada: tiga keputusan mahal yang lahir dari korelasi

Ketiganya nyata, hanya nama perusahaannya yang diganti. Ketiganya lolos rapat karena datanya benar dan chart-nya meyakinkan. Ketiganya salah.

Temuan (benar secara data)	Kesimpulan yang diambil	Apa yang sebenarnya terjadi
Pelanggan yang menginstal aplikasi mobile ber-CLV 3,1x lebih tinggi	"Dorong instalasi aplikasi — anggarkan Rp 8 miliar untuk kampanye instal"	Pelanggan loyal memasang aplikasi <i>karena</i> sudah loyal. Kampanye menarik pemasang yang tidak loyal; CLV mereka biasa saja. Arah sebab terbalik (reverse causality).
Penerima email promo membeli 42% lebih sering daripada non-penerima	"Email menaikkan pembelian 42% — perbanyak frekuensi"	Daftar penerima disaring: hanya pelanggan aktif 90 hari terakhir yang dikirim. Perbandingan ini membandingkan pelanggan aktif dengan pelanggan tidak aktif (selection bias).
Toko dengan staf lebih banyak punya penjualan per m ² lebih tinggi	"Tambah staf di toko berkinerja rendah"	Perusahaan menempatkan staf lebih banyak di toko dengan traffic tinggi. Traffic adalah penyebab keduanya (confounding).

Ketiga kesalahan ini bukan kesalahan statistik. Tidak satu pun bisa dideteksi dengan p-value, R², atau ukuran sampel yang lebih besar. Menambah data justru membuat estimasi yang bias menjadi *lebih presisi* — bias yang sama, dengan interval kepercayaan yang lebih sempit dan karena itu lebih meyakinkan.

⚠ WARNING — Presisi bukan akurasi

Ukuran sampel mengecilkan *variance*, tidak menyentuh *bias*. Sepuluh juta baris data observasional yang terkonfound menghasilkan jawaban yang salah dengan sangat yakin. Ini alasan mengapa "kita punya big data" bukan jawaban atas pertanyaan kausal — dan mengapa eksperimen dengan 20 ribu pengguna sering mengalahkan analisis dengan 20 juta baris.

Kerangka potential outcomes: bahasa formal untuk sebab

Definisi

Untuk setiap unit i (pelanggan, order, toko, sesi) dan sebuah treatment biner T , ada dua hasil yang secara konsep ada:

$Y_{i(1)}$ = hasil untuk unit i JIKA menerima treatment
 $Y_{i(0)}$ = hasil untuk unit i JIKA TIDAK menerima treatment

Efek kausal pada unit i : $\tau_i = Y_{i(1)} - Y_{i(0)}$

Perhatikan bahwa efek kausal didefinisikan pada **unit yang sama**, pada **waktu yang sama**, dengan satu-satunya perbedaan adalah treatment. Inilah makna "sebab" yang dipakai di seluruh volume ini.

Masalah fundamental causal inference

Untuk setiap unit, kita hanya pernah mengamati salah satu dari dua. Pelanggan yang menerima voucher tidak bisa sekaligus tidak menerimanya. Hasil yang tidak teramati disebut **counterfactual** — dunia tandingan yang tidak pernah terjadi.

Pelanggan	Terima voucher?	$Y(1)$ belanja	$Y(0)$ belanja	τ_i
Andi	ya	Rp 420rb	???	???
Budi	tidak	???	Rp 280rb	???
Citra	ya	Rp 150rb	???	???
Dewi	tidak	???	Rp 310rb	???

Kolom "???" tidak pernah bisa diisi dengan pengamatan.
SEMUA metode di volume ini adalah cara mengisinya dengan ESTIMASI yang bisa dipertahankan — bukan cara mengamatinya.

■ TECHNICAL NOTE — causal inference sebagai masalah missing data

Rumusan Rubin: inferensi kausal adalah masalah data hilang, di mana separuh tabel di atas selalu hilang. Konsekuensinya penting untuk sikap profesional: **tidak ada metode yang membuktikan kausalitas dari data saja**. Setiap metode menambahkan *asumsi* yang tidak dapat diuji sepenuhnya dari data. Perbedaan antara metode adalah seberapa berat asumsinya dan seberapa banyak cara kita memeriksanya. Analyst yang matang menyebut asumsinya di muka, bukan menyembunyikannya di balik nama teknik.

Dari efek individu ke efek rata-rata

τ_i individual tidak bisa diperoleh. Yang bisa diperoleh adalah rata-ratanya pada sebuah populasi:

Estimand	Definisi	Kapan ini yang kita inginkan
ATE Average Treatment Effect	$E[Y(1) - Y(0)]$ pada seluruh populasi	Keputusan meluncurkan ke <i>semua</i> orang: "jika fitur ini dirilis 100%, apa dampaknya?" Ini estimand default A/B test.

ATT Average Treatment effect on the Treated	$E[Y(1) - Y(0) T=1]$ pada yang menerima treatment	Mengevaluasi program yang sudah berjalan pada peserta tertentu: "apakah program loyalitas berdampak pada anggota yang mendaftar?" Estimand standar untuk difference-in-differences dan propensity matching.
LATE / CACE Local Average Treatment Effect	Efek pada <i>complier</i> : unit yang berubah perilakunya karena dorongan	Ketika treatment tidak bisa dipaksakan, hanya didorong (misalnya undangan program). Estimand alami instrumental variables dan eksperimen dengan kepatuhan tidak sempurna.
CATE Conditional ATE	$E[Y(1) - Y(0) X = x]$ per segmen	Targeting: "untuk siapa fitur ini berguna?" Dibahas penuh di Bab 6.

✗ COMMON MISTAKE — Melaporkan ATT seolah-olah ATE

Gejala: "Program loyalitas menaikkan belanja 18%" — lalu manajemen memutuskan mendaftarkan otomatis seluruh basis pelanggan, dan hasilnya jauh di bawah 18%.

Mengapa terjadi: 18% adalah efek pada orang yang *memilih mendaftar* (ATT). Orang yang tidak mendaftar berbeda: minat lebih rendah, dan efek pada mereka hampir pasti lebih kecil.

Perbaikan: selalu tulis populasi estimand dalam kalimat kesimpulan: "pada pelanggan yang mendaftar sukarela ($\pm 14\%$ basis), program menaikkan belanja 18%; efek pada pelanggan lain tidak dapat disimpulkan dari analisis ini."

Cara senior menghindarinya: menuliskan estimand di dokumen desain *sebelum* analisis dimulai — satu kalimat: "kami mengestimasi ATE pada seluruh pengunjung mobile web."

Tiga cara perbandingan menjadi tidak valid

Ketika kita membandingkan kelompok yang menerima X dengan yang tidak, perbedaan yang terlihat adalah campuran dari efek sesungguhnya dan *bias seleksi*: perbedaan yang sudah ada sebelum treatment.

Perbedaan yang diamati
 $= E[Y | T=1] - E[Y | T=0]$
 $= \{ E[Y(1)|T=1] - E[Y(0)|T=1] \} \quad \leftarrow \text{efek kausal (ATT)} \quad \checkmark \text{ yang dicari}$
 $+ \{ E[Y(0)|T=1] - E[Y(0)|T=0] \} \quad \leftarrow \text{BIAS SELEKSI} \quad \times \text{ pengotor}$

Bias seleksi = perbedaan kelompok SEANDAINYA keduanya sama-sama tidak diberi treatment.
 Nol hanya jika kedua kelompok memang sebanding.

1. Confounding — ada penyebab bersama

Variabel ketiga mempengaruhi baik treatment maupun outcome. Contoh toko dan staf di atas: traffic menentukan penempatan staf *dan* penjualan.

```

      traffic toko (confounder)
        /           \
       v             v
jumlah staf --> penjualan/m²
(asosiasi yang teramati sebagian besar palsu)

```

2. Selection bias — siapa yang masuk kelompok tidak acak

Contoh email di atas: keanggotaan kelompok ditentukan oleh variabel yang berkorelasi dengan outcome. Bentuk yang paling berbahaya adalah **self-selection**: unit memilih sendiri treatment-nya berdasarkan hal yang tidak kita ukur (motivasi, niat beli, keluhan yang belum tersampaikan).

3. Reverse causality — arah panahnya terbalik

Contoh aplikasi mobile di atas. Uji cepat yang sering menyelamatkan: *mana yang terjadi lebih dulu dalam waktu?* Jika instalasi aplikasi terjadi setelah pelanggan sudah membeli 5 kali, klaim "aplikasi menyebabkan loyalitas" runtuh tanpa perlu metode canggih.

◆ BUSINESS INSIGHT — Kasus TokoNusa: keterlambatan → churn

Vol 2 capstone menemukan: pelanggan yang mengalami keterlambatan pengiriman punya churn 180-hari **19,1 pp lebih tinggi**. Ini asosiasi yang kuat dan konsisten. Tetapi ketiga masalah di atas hadir sekaligus:

Confounding: keterlambatan lebih sering terjadi pada kiriman ke luar Jawa; pelanggan luar Jawa juga punya frekuensi belanja lebih rendah karena alasan lain (assortment, harga kompetitor lokal).

Selection: pelanggan yang memesan barang besar/berat lebih sering terlambat — dan barang besar adalah pembelian jarang yang jarang diulang.

Reverse causality: pelanggan yang sudah berniat berhenti cenderung memesan mendekati batas promo, memicu lonjakan volume yang menyebabkan keterlambatan.

Angka 19,1 pp karena itu adalah *batas atas yang sangat longgar*, bukan estimasi dampak. Bab 8 memetakan struktur kausalnya, Bab 10 mengoreksi dengan propensity score, Bab 11 mencari instrumen. Hasil akhirnya di Bab 11 jauh lebih kecil — dan itulah yang akan dipakai untuk membenarkan investasi logistik di capstone.

Mengapa randomisasi menyelesaikan semuanya sekaligus

Randomisasi tidak membuat kedua kelompok identik. Ia membuat kedua kelompok **sebanding dalam ekspektasi** pada *semua* variabel — yang terukur maupun tidak terukur, yang terpikirkan maupun tidak.

Karena penugasan T acak dan independen dari potential outcomes:

$$E[Y(0) \mid T=1] = E[Y(0) \mid T=0] \quad \Rightarrow \text{bias seleksi} = 0$$

sehingga

$$E[Y|T=1] - E[Y|T=0] = ATE \quad (\text{identifikasi tercapai})$$

Kalimat "termasuk yang tidak terukur" adalah keunggulan yang tidak dimiliki metode observasional mana pun. Propensity score hanya menyeimbangkan variabel yang kita masukkan ke model; randomisasi menyeimbangkan hal-hal yang tidak pernah kita pikirkan — motivasi, situasi keluarga, cuaca di kota pelanggan, dan seribu hal lain.

✓ BEST PRACTICE — Uji "seandainya" sebelum menerima klaim kausal apa pun

Untuk setiap klaim kausal — milik sendiri maupun orang lain — jawab satu pertanyaan: "**Apa yang membuat seseorang masuk kelompok treatment, dan apakah hal itu juga mempengaruhi outcome?**" Jika jawabannya "mereka memilih sendiri", "sistem memilih berdasarkan skor", atau "kami targetkan pada yang paling mungkin merespons" — perbandingan mentahnya tidak valid, dan diskusi harus pindah ke metode Bagian II.

Hierarki bukti kausal

Tidak semua bukti setara. Analyst yang matang menempatkan temuannya pada tingkat yang tepat, bukan menaikkan pangkatnya demi kesan.

Tkt	Jenis bukti	Asumsi identifikasi	Kekuatan klaim yang boleh ditulis
1	RCT / A/B test dengan randomisasi valid	Randomisasi berjalan; tidak ada interferensi (SUTVA)	"menyebabkan" — boleh ditulis lugas

2	Eksperimen dengan kepatuhan tidak sempurna, switchback, geo experiment	Randomisasi valid pada tingkat unit yang diacak; exclusion restriction (untuk LATE)	"menyebabkan, pada subpopulasi complier / pada tingkat geo"
3	Regression discontinuity	Kontinuitas di sekitar ambang; tidak ada manipulasi running variable	"menyebabkan, di sekitar ambang" (efek lokal)
4	Difference-in-differences / synthetic control	Parallel trends; tidak ada guncangan bersamaan yang khusus mengenai kelompok treatment	"konsisten dengan efek kausal sebesar ..., dengan asumsi tren paralel yang diperiksa lewat pre-trend"
5	Instrumental variable observasional	Relevansi, exclusion restriction, independensi instrumen	"efek kausal pada complier, bergantung pada validitas instrumen yang tidak dapat diuji penuh"
6	Propensity score / regresi dengan kontrol	Unconfoundedness: <i>semua</i> confounder terukur — asumsi yang hampir selalu berlebihan	"asosiasi setelah penyesuaian" — hindari kata menyebabkan
7	Perbandingan mentah, korelasi, before-after tanpa kontrol	—	"berasosiasi dengan" — tidak lebih

► **EXECUTIVE PERSPECTIVE — cara menyampaikan tingkat bukti tanpa terdengar ragu**

Eksekutif tidak menghukum ketidakpastian; mereka menghukum ketidakpastian yang *disembunyikan lalu meledak*. Format yang bekerja: "*Bukti tingkat 4: dampaknya sekitar +2,1%, rentang -0,3% sampai +4,5%. Asumsi utamanya X, dan saya sudah memeriksanya dengan Y. Untuk keputusan senilai Rp 8 miliar, saya sarankan tes terkontrol 3 minggu sebelum komitmen penuh.*" Kalimat itu memberi keputusan, angka, batas, dan jalan keluar sekaligus.

Ketika bukti observasional cukup: kriteria Bradford Hill versi analyst

Tidak semua pertanyaan boleh menunggu eksperimen. Ketika keputusan harus diambil dari data observasional, kekuatan bukti bisa dinaikkan dengan memenuhi sebanyak mungkin kriteria berikut — bukan sebagai daftar centang, melainkan sebagai argumen berlapis.

- **Kekuatan asosiasi** — efek besar lebih sulit dijelaskan oleh confounder kecil.
- **Konsistensi** — muncul di segmen, periode, dan geografi yang berbeda.
- **Temporalitas** — sebab mendahului akibat; wajib, bukan opsional.
- **Gradien dosis-respons** — makin besar paparan, makin besar efek (keterlambatan 1 hari vs 5 hari).
- **Plausibilitas mekanisme** — ada cerita bisnis yang masuk akal, dan mekanismenya bisa diuji terpisah.
- **Analogi & eksperimen parsial** — tes kecil pada bagian rantai sebab memberi dukungan.
- **Bukti negatif (falsification test)** — pada kelompok yang seharusnya tidak terpengaruh, efeknya memang nol.

Poin terakhir paling sering dilupakan dan paling meyakinkan. Jika keterlambatan menyebabkan churn, maka keterlambatan pada order *hadiah untuk orang lain* seharusnya berdampak lebih kecil pada churn pemesan. Menemukan pola itu memperkuat klaim; tidak menemukannya adalah peringatan.

Menulis klaim kausal yang jujur

LEMAH (dan sering salah)

"Pelanggan yang mengalami keterlambatan 19 pp lebih mungkin churn.
Perbaikan logistik akan menurunkan churn 19 pp."

KUAT

"Asosiasi mentah: +19 pp churn (n=214.000, periode Jan–Jun 2025).
Setelah penyesuaian confounder terukur (wilayah, kategori, nilai order, riwayat belanja): +8,2 pp. Menggunakan kapasitas hub kurir sebagai instrumen: +4,0 pp (95% CI 2,6–5,4), estimand = LATE pada order yang status keterlambatannya berubah karena kapasitas hub.
Interpretasi: dampak kausal ada tetapi jauh lebih kecil dari angka mentah; sekitar tiga perempat asosiasi awal berasal dari seleksi.
Nilai bisnis pada estimasi terendah: Rp 6,9 miliar CLV per tahun.
Rekomendasi: uji terkontrol SLA pengiriman di 8 kota (desain Bab 2)."

Perhatikan strukturnya: angka mentah tidak disembunyikan, tetapi diturunkan pangkatnya secara transparan; estimand disebut; ketidakpastian dinyatakan; nilai bisnis dihitung pada skenario konservatif; dan langkah berikutnya diberikan. Format ini dipakai berulang di seluruh volume.

Checklist berpikir eksperimental

- ✓ Estimand ditulis eksplisit sebelum analisis: ATE, ATT, atau LATE — dan pada populasi apa
- ✓ Pertanyaan "apa yang menentukan siapa menerima treatment" sudah dijawab tertulis
- ✓ Confounder, selection bias, dan reverse causality diperiksa satu per satu, bukan disebut umum
- ✓ Urutan waktu sebab dan akibat diverifikasi dari data, bukan diasumsikan
- ✓ Tingkat bukti (1–7) dinyatakan, dan kata kerja kausal disesuaikan dengan tingkat itu
- ✓ Minimal satu falsification test dirancang: di mana efeknya seharusnya nol?
- ✓ Angka mentah dan angka terkoreksi dilaporkan berdampingan, bukan salah satu saja

Ending Card — Bab 1

What you learned

Kerangka potential outcomes dan masalah fundamental causal inference; dekomposisi perbedaan teramati menjadi efek kausal plus bias seleksi; tiga mekanisme invaliditas (confounding, selection, reverse causality); mengapa randomisasi menyeimbangkan variabel tak terukur; perbedaan ATE/ATT/LATE/CATE; hierarki bukti tujuh tingkat; kriteria penguatan bukti observasional; format klaim kausal yang jujur.

Skills mastered

Causal reasoning formal · deteksi bias struktural · pemilihan estimand · kalibrasi bahasa klaim.

Real business value

Kemampuan ini mencegah kelas kesalahan yang paling mahal di perusahaan: mengalokasikan anggaran besar berdasarkan asosiasi yang bukan sebab. Satu keputusan Rp 8 miliar yang dibatalkan karena analyst mengenali reverse causality sudah membayar seluruh biaya pelatihan seorang analyst selama bertahun-tahun.

Interview readiness

● INTERVIEW QUESTIONS

1. "Apa bedanya korelasi dan kausalitas — jelaskan secara formal, bukan dengan contoh es krim." (Jawaban kuat memakai potential outcomes dan dekomposisi bias seleksi.)
2. "Kami menemukan pengguna fitur X retensinya 2× lebih tinggi. Apakah kami harus mendorong fitur X?" (Jawaban: identifikasi self-selection; usulkan eksperimen; sebutkan estimand yang relevan untuk keputusan.)
3. "Kapan kamu *tidak* perlu eksperimen untuk mengklaim sebab?" (Jawaban: efek sangat besar dengan mekanisme jelas dan tidak ada jalur confounding yang masuk akal; ambang batas tajam yang memungkinkan RDD; atau ketika biaya kesalahan rendah.)
4. "Apa itu ATT dan kapan ia estimand yang salah?" (Ketika keputusannya adalah rollout ke semua orang.)
5. "Randomisasi menyeimbangkan variabel tak terukur — jelaskan mengapa, dan apa batasnya." (Batas: hanya dalam ekspektasi; sampel kecil tetap bisa tidak seimbang — jembatan ke Bab 3.)

Exercises

Exercise 1.1 (Beginner · 20 menit)

Objective: mengenali mekanisme bias · Dataset: pernyataan kasus

Untuk tiap pernyataan, sebutkan mekanisme bias yang dominan (confounding / selection / reverse causality) dan rancang satu pemeriksaan cepat:

- (a) "Toko yang direnovasi tahun lalu tumbuh 12% lebih cepat."
- (b) "Pelanggan yang menghubungi customer service punya retensi lebih tinggi."
- (c) "Kategori dengan diskon terbesar punya pertumbuhan penjualan tertinggi."
- (d) "Karyawan yang ikut pelatihan analytics dipromosikan 2× lebih sering."

Answer key 1.1

- (a) **Selection/confounding** — toko dipilih untuk direnovasi karena potensinya tinggi atau lokasinya membaik. Cek: bandingkan tren pra-renovasi toko renovasi vs tidak (ini benih pre-trend test, Bab 9).
- (b) **Reverse causality + selection** — pelanggan yang masih aktif punya alasan menghubungi CS; pelanggan yang sudah pergi diam-diam. Cek: batasi pada pelanggan dengan tingkat aktivitas sama pada periode sebelum kontak.
- (c) **Confounding + reverse causality** — kategori yang sedang tumbuh menerima anggaran promo lebih besar (arah terbalik), dan permintaan musiman mempengaruhi keduanya. Cek: apakah diskon ditetapkan sebelum atau sesudah tren terlihat.
- (d) **Selection** — karyawan ambisius memilih ikut pelatihan; ambisi juga mendorong promosi. Cek: apakah ada pelatihan yang diwajibkan (kelompok yang tidak memilih sendiri) sebagai pembanding.

Exercise 1.2 (Intermediate · 45 menit)

Objective: potential outcomes numerik

Sebuah dunia hipotetis dengan 6 pelanggan; kedua potential outcomes diketahui (belanja 6 bulan, ribu Rp):

A: $Y(0)=200$ $Y(1)=260$ · B: $400/430$ · C: $100/180$ · D: $700/700$ · E: $250/300$ · F: $150/240$

- (a) Hitung ATE sebenarnya. (b) Andaikan treatment diberikan kepada pelanggan dengan $Y(0)$ tertinggi (B dan D) — hitung perbedaan teramati antara kelompok treatment dan kontrol, lalu hitung besar bias seleksinya. (c) Andaikan treatment diberikan acak kepada A, C, E — hitung perbedaan teramati dan bandingkan dengan ATE.

Answer key 1.2

(a) τ per unit: 60, 30, 80, 0, 50, 90 → **ATE = $310/6 = 51,67$** .

(b) Treated {B,D}: teramati $Y(1) = 430, 700$ → rata-rata 565. Kontrol {A,C,E,F}: teramati $Y(0) = 200, 100, 250, 150$ → rata-rata 175. Perbedaan teramati = **+390**, padahal ATT sesungguhnya = $(30+0)/2 = 15$. Bias seleksi = $E[Y(0)|T=1] - E[Y(0)|T=0] = 550 - 175 = 375$; dan $390 = 15 + 375$ ✓ (dekomposisi terverifikasi). Pelajaran: menargetkan pelanggan terbaik menghasilkan angka spektakuler yang hampir seluruhnya palsu.

(c) Treated {A,C,E}: 260, 180, 300 → 246,67. Kontrol {B,D,F}: 400, 700, 150 → 416,67. Perbedaan = **-170**. Ini menunjukkan poin penting: randomisasi tidak menjamin keseimbangan pada sampel kecil — ia hanya menghapus bias *dalam ekspektasi* (rata-rata atas banyak pengacakan). Dengan $n=6$, variance mendominasi. Inilah mengapa Bab 3 (power) tidak bisa dilewati.

Exercise 1.3 (Advanced · 60 menit)

Objective: audit klaim kausal nyata

TokoNusa mengklaim: "Anggota program membership berbayar (Rp 99rb/tahun) berbelanja 2,4× lebih banyak dan churn-nya separuh non-anggota. Membership harus digratiskan agar semua pelanggan menjadi anggota."

Tulis audit satu halaman: estimand apa yang sebenarnya diukur; tiga mekanisme bias yang paling mungkin dan arah biasnya; dua falsification test yang bisa dijalankan dari data yang ada; dan desain eksperimen minimal yang akan menjawabnya. Sertakan taksiran kasar berapa besar efek sesungguhnya mungkin dibandingkan 2,4×.

Answer key 1.3 (jalur kuat)

Estimand teramati: perbedaan mentah antar kelompok yang menentukan sendiri keanggotaannya — bukan ATT, bukan ATE, dan bukan estimand kausal apa pun.

Bias: (1) *self-selection* — hanya pelanggan yang sudah sering belanja yang rasional membayar Rp 99rb; arah bias ke atas, besar. (2) *Reverse causality* — keputusan menjadi anggota dipicu oleh rencana belanja besar. (3) *Confounding* oleh tenure — anggota rata-rata lebih lama terdaftar; tenure menurunkan churn secara mekanis. Ketiganya searah: 2,4× hampir pasti jauh melebihi efek sesungguhnya.

Falsification test: (i) bandingkan belanja anggota pada 6 bulan *sebelum* mereka mendaftar dengan non-anggota sepadan — jika sudah 2× lebih tinggi sebelum treatment, sebagian besar "efek" adalah seleksi; (ii) periksa apakah efek muncul pada kategori yang tidak mendapat benefit membership (jika ya, itu tanda seleksi, bukan mekanisme).

Desain minimal: acak tawaran membership gratis 12 bulan pada sampel pelanggan (encouragement design). Karena tidak semua penerima akan mengaktifkan, estimand yang diperoleh adalah LATE pada complier lewat IV (Bab 11); ITT-nya langsung memberi jawaban keputusan "apakah menggratiskan menaikkan CM".

Taksiran: pengalaman industri pada program serupa menunjukkan efek kausal tipikal jauh di bawah rasio mentah — orde 5–20% kenaikan frekuensi, bukan 140%. Rekomendasi: jangan gratiskan berdasarkan angka 2,4×; jalankan encouragement test dengan biaya jauh lebih kecil.

Exercise 1.4 (Production Challenge · 3 jam)

Objective: membangun kebiasaan audit

Ambil lima klaim kausal dari sumber nyata (postingan LinkedIn, artikel berita bisnis, dashboard perusahaan tempatmu, atau blog produk). Buat tabel audit: klaim · estimand yang diklaim · mekanisme penugasan treatment · bias dominan · tingkat bukti (1–7) · kalimat perbaikan yang jujur. Simpan sebagai dokumen; ini menjadi bagian portfolio "causal audit" yang akan diperluas di Bab 8.

Answer key 1.4 — rubrik penilaian

Audit yang baik memenuhi: setiap klaim punya mekanisme penugasan yang *disebut konkret* (bukan "mungkin bias"); arah bias diprediksi (ke atas/ke bawah) dengan alasan; tingkat bukti konsisten dengan metode yang dipakai sumber; dan kalimat perbaikan tetap memberi informasi yang berguna alih-alih sekadar menolak. Kesalahan umum peserta: berhenti pada "korelasi bukan kausalitas" — itu bukan analisis, itu slogan.

Portfolio idea

★ PORTFOLIO TIP

Tulis esai pendek (600–800 kata) berjudul "Tiga klaim kausal yang saya audit dan mengapa dua di antaranya salah", memakai kerangka bab ini. Dokumen jenis ini sangat jarang di portfolio analyst pemula dan langsung menandakan kematangan berpikir — jauh lebih membedakan daripada dashboard ke-sepuluh.

Further reading

Judea Pearl & Dana Mackenzie, *The Book of Why* (bab tentang ladder of causation) · Angrist & Pischke, *Mastering 'Metrics* (Bab 1: randomized trials) · Imbens & Rubin, *Causal Inference for Statistics, Social, and Biomedical Sciences* (kerangka potential outcomes) · Scott Cunningham, *Causal Inference: The Mixtape* (versi daring gratis).

Next chapter

Bab 2 — dari prinsip ke rancangan. Bagaimana menyusun hipotesis yang bisa salah, memilih unit randomisasi yang tepat (kesalahan paling mahal dan paling sering), mendefinisikan OEC, dan memasang guardrail yang mencegah kemenangan semu.

Bab 2 — Anatomi Eksperimen yang Benar

Sembilan puluh persen eksperimen yang gagal, gagal sebelum satu pengguna pun masuk ke dalamnya.

Learning objectives	Menulis hipotesis yang dapat difalsifikasi beserta mekanismenya; memilih unit randomisasi yang benar dan menjelaskan konsekuensinya; mendefinisikan OEC beserta metric pendukung dan guardrail; merancang alokasi traffic dan holdout; menyusun dokumen desain eksperimen lengkap; mengenali situasi di mana A/B test tidak sah dipakai
Prerequisites	Bab 1; Vol 3 Bab 10 (KPI tree) dan Bab 4 (unit economics)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Intermediate
Skills covered	Hypothesis writing, randomization unit selection, OEC design, guardrail metrics, experiment design doc
Business domain	E-commerce & retail — EXP-041 (ambang gratis ongkir) dan EXP-052 (checkout satu halaman)

Mengapa desain lebih menentukan daripada analisis

Analisis yang salah bisa diulang; desain yang salah tidak bisa diperbaiki setelah data terkumpul. Jika unit randomisasi salah, tidak ada teknik statistik yang menyelamatkan hasilnya. Jika metric yang dipilih tidak mewakili tujuan bisnis, tes yang sempurna secara statistik akan memenangkan perubahan yang merugikan.

Sebuah kalimat yang layak dihafal: **eksperimen tidak mengukur apa yang kamu inginkan; ia mengukur apa yang kamu definisikan.** Bab ini adalah tentang mendefinisikan dengan benar.

◆ BUSINESS INSIGHT — biaya desain yang buruk, dihitung

Satu siklus eksperimen TokoNusa: 3 minggu kalender, 2 engineer × 1 minggu implementasi, 1 analyst × 4 hari, plus biaya kesempatan (slot traffic tidak bisa dipakai tes lain). Nilai wajarnya ±Rp 85 juta per tes. Program yang menjalankan 40 tes/tahun dengan 30% desain cacat membuang ±Rp 1 miliar per tahun — sebelum menghitung kerugian dari keputusan salah yang dihasilkannya.

Bagian 1 — Hipotesis yang bisa salah

Struktur hipotesis lengkap

Hipotesis yang berguna memuat empat komponen. Kekurangan salah satu membuat hasil tes sulit ditafsirkan apa pun jawabannya.

- | | |
|-----------------|---|
| [1] PERUBAHAN | Apa persisnya yang berubah, untuk siapa |
| [2] MEKANISME | MENGAPA perubahan itu akan mengubah perilaku |
| [3] PREDIKSI | Metric mana bergerak, ke arah mana, sebesar apa |
| [4] KONSEKUENSI | Keputusan apa yang diambil untuk tiap hasil |

Hipotesis lemah	Hipotesis kuat
"Checkout satu halaman akan meningkatkan konversi."	"Mengganti checkout 3 langkah menjadi 1 halaman untuk pengunjung mobile web akan menaikkan conversion rate visit→pay dari 3,20% menjadi minimal 3,30% (+3% relatif), karena <i>drop-off terbesar terjadi pada transisi antar langkah</i> (data funnel Vol 3 Bab 5: 37,5% pengguna hilang antara cart dan checkout). Jika lift $\geq +2\%$ relatif dan tidak ada guardrail yang memburuk, rilis 100%; jika CI mencakup nol, tahan dan analisis segmen; jika refund rate naik $>0,3$ pp, batalkan."

Komponen **mekanisme** yang paling sering hilang, padahal ia yang membuat hasil bisa dipelajari. Tes tanpa mekanisme hanya menghasilkan "menang" atau "kalah"; tes dengan mekanisme menghasilkan pengetahuan yang bisa dipakai untuk tes berikutnya. Jika mekanismenya "drop-off antar langkah", maka hasil menang harus disertai bukti bahwa drop-off antar langkah memang berkurang — kalau tidak, kemenangannya kebetulan dan tidak akan berulang.

✓ BEST PRACTICE — Prediksi angka sebelum melihat hasil

Minta setiap pemangku kepentingan menuliskan tebakan lift sebelum tes dijalankan (satu angka, tertutup). Dua manfaat: menghentikan rasionalisasi pasca-hasil ("saya sudah menduga"), dan mengkalibrasi organisasi — setelah 20 tes, tim akan melihat bahwa tebakan mereka rata-rata 3-5× terlalu optimistis. Kalibrasi ini adalah aset yang tumbuh dan tidak bisa dibeli.

Menuliskan hipotesis nol dan alternatif dengan benar

$H_0 : \text{conversion_treatment} - \text{conversion_control} = 0$
 $H_1 : \text{conversion_treatment} - \text{conversion_control} \neq 0$ (dua sisi)

Gunakan dua sisi hampir selalu. Uji satu sisi hanya sah jika keputusan untuk arah sebaliknya IDENTIK dengan keputusan untuk hasil nol — kondisi yang jarang benar, karena hasil negatif besar biasanya memicu investigasi, bukan sekadar "tidak dirilis".

Bagian 2 — Unit randomisasi: keputusan paling mahal

Unit randomisasi adalah *entitas yang dilempar koin*. Ia menentukan validitas, ukuran sampel efektif, dan metric apa yang boleh dianalisis. Kesalahan di sini adalah penyebab nomor satu eksperimen yang tidak dapat dipercaya.

Unit	Kapan dipakai	Kelebihan	Risiko
Pengguna (user_id / cookie)	Default untuk hampir semua tes produk	Pengalaman konsisten; metric per pengguna sah dianalisis; mendukung efek jangka panjang	Cookie hilang → pengguna berpindah varian; lintas perangkat tidak terlacak
Sesi	Perubahan yang tidak diingat pengguna antar kunjungan	Sampel lebih besar, tes lebih cepat	Pengguna sama melihat dua varian → pengalaman tidak konsisten dan efek saling mencemari; jangan dipakai untuk perubahan UI besar
Order / request	Perubahan back-end tanpa jejak ke pengguna (mis. algoritma routing gudang)	Sampel sangat besar, cepat	Metric per pengguna menjadi tidak valid; korelasi antar order dari pengguna sama

Geo / kota	Kampanye offline, harga, logistik, marketing incrementality	Menangkap efek limpahan (spillover); satu-satunya cara menguji hal yang bocor antar pengguna	Jumlah unit sangat kecil (puluhan) → power rendah; butuh metode Bab 12
Toko	Planogram, staffing, promosi in-store	Realistis untuk operasi ritel	85 toko = 85 unit; heterogenitas besar antar toko; wajib stratifikasi
Waktu (switchback)	Marketplace/logistik di mana treatment mempengaruhi seluruh sistem	Mengatasi interferensi total	Autokorelasi temporal; analisis lebih rumit (Bab 12)
Klaster (rumah tangga, akun perusahaan)	Ketika unit saling berkomunikasi	Menghindari kontaminasi	Effective sample size turun drastis; wajib cluster-robust SE

Aturan besi: unit analisis harus sama dengan unit randomisasi

SALAH

Acak per PENGGUNA
Analisis per ORDER
(order dari pengguna sama saling berkorelasi → SE terlalu kecil → p-value terlalu kecil → menang palsu)

BENAR

Acak per PENGGUNA
Analisis per PENGGUNA
(conversion per pengguna, revenue per pengguna)

atau: acak per order
bila memang sah

Pelanggaran aturan ini menghasilkan bentuk kesalahan yang sangat sulit dideteksi: hasilnya terlihat sangat signifikan ($p < 0,001$) padahal efeknya nol. Penyebabnya sederhana — standard error dihitung seolah setiap order adalah informasi independen, padahal 4,74 juta order hanya berasal dari 1,48 juta pelanggan aktif. Faktor koreksinya bisa 1,5–2× pada SE.

× COMMON MISTAKE — Menganalisis metric rasio pada tingkat yang salah

Gejala: tes conversion menunjukkan $p=0,0004$ dengan lift 0,3%; setelah dirilis 100%, tidak ada perubahan apa pun pada metric perusahaan.

Mengapa terjadi: analisis dilakukan pada tingkat sesi/order sementara randomisasi pada tingkat pengguna; SE understated.

Perbaikan: agregasikan ke tingkat randomisasi terlebih dulu (satu baris per pengguna), lalu bandingkan rata-ratanya; atau gunakan delta method / cluster-robust standard error untuk metric rasio (dibahas teknisnya di Bab 6).

Cara senior menghindarinya: menuliskan satu kalimat di dokumen desain — "unit randomisasi = user_id; setiap metric dihitung sebagai rata-rata per user_id" — dan menolak review analisis yang melanggarnya.

Cara memilih unit: pohon keputusan

Apakah treatment bisa "bocor" ke unit lain?

| (pesan berantai, marketplace, inventory bersama, iklan yang terlihat orang lain, kompetisi antar penjual)
— YA → naikkan unit: geo, toko, klaster, atau switchback (interferensi = SUTVA dilanggar; lihat Bab 6 & 12)

| — TIDAK

| — Apakah pengguna akan menyadari perbedaan antar kunjungan?

| — — YA → unit = PENGGUNA (wajib)

| — — TIDAK

| — — Apakah metric utamanya per pengguna (retensi, CLV, frekuensi)?

| — — — YA → unit = PENGGUNA

└─ TIDAK → unit = SESI/ORDER boleh
└─ Apakah efeknya butuh waktu terakumulasi (pembelajaran, kebiasaan)? → unit = PENGGUNA, durasi diperpanjang

Bagian 3 — OEC: satu angka yang menentukan keputusan

OEC (Overall Evaluation Criterion) adalah metric tunggal yang keputusan ship/no-ship digantungkan padanya. Keberadaannya wajib: tanpa satu metric yang disepakati *sebelum* tes, hasil apa pun bisa dinarasikan sebagai kemenangan dengan memilih metric yang kebetulan naik.

Kriteria OEC yang baik

- **Sensitif** — bergerak dalam durasi tes yang realistis. CLV 12 bulan bukan OEC yang bisa dipakai untuk tes 3 minggu.
- **Selaras jangka panjang** — kenaikannya benar-benar baik untuk perusahaan, bukan hanya untuk metric itu sendiri.
- **Sulit di-game** — tidak bisa dinaikkan dengan cara yang merusak (Goodhart, Vol 3 Bab 13).
- **Dapat dihitung ulang secara identik** oleh orang lain dari definisi tertulis.

⚠ **WARNING — Conversion rate adalah OEC yang menipu**

Conversion rate bisa dinaikkan dengan menurunkan harga, menurunkan ambang gratis ongkir, atau menampilkan produk termurah lebih dulu — semuanya menaikkan konversi sambil *menurunkan* contribution margin. Dalam banyak tes komersial, OEC yang benar adalah **contribution margin per pengunjung**, bukan conversion rate. Bab 7 membahas konstruksi metric ini secara penuh; kasus EXP-041 di bawah menunjukkan mengapa ini bukan kehati-hatian teoretis.

Struktur metric tiga lapis

LAPIS 1 — OEC (1 metric)

Keputusan ship/no-ship. Contoh: CM per pengunjung.

LAPIS 2 — SUPPORTING / MEKANISME (3–6 metric)

Menjelaskan MENGAPA OEC bergerak. Contoh: conversion per langkah funnel, AOV, item per order, subsidi ongkir per order.
TIDAK dipakai untuk keputusan; dipakai untuk pemahaman.

LAPIS 3 — GUARDRAIL (5–10 metric)

Hal yang tidak boleh rusak, apa pun hasil OEC. Contoh: waktu muat halaman, error rate, refund rate, komplain CS, pendapatan kategori lain, sample ratio, crash rate.
Ambang ditetapkan DI MUKA. Pelanggaran = pembatalan otomatis.

Pemisahan tiga lapis ini menyelesaikan konflik politik sebelum terjadi. Ketika OEC naik tetapi metric favorit seseorang turun, dokumen desain sudah menjawab pertanyaannya: metric itu ada di lapis 2 (informatif, bukan penentu) atau lapis 3 (penentu, dengan ambang yang sudah disepakati).

Guardrail yang wajib ada di hampir semua tes

Guardrail	Ambang tipikal	Alasan
Sample Ratio Mismatch (SRM)	$p > 0,001$ pada chi-square rasio penugasan	Deteksi kerusakan randomisasi/instrumentasi; pelanggaran membatalkan seluruh hasil (Bab 4)
Latency p95 halaman	tidak memburuk > 100 ms	Kecepatan mempengaruhi konversi lintas seluruh situs; efeknya sering lebih besar dari fitur yang diuji

Error / crash rate	tidak naik > 0,1 pp	Kerusakan teknis yang tersembunyi di balik metric agregat
Refund & pembatalan	tidak naik > 0,3 pp	Menangkap konversi berkualitas rendah yang kembali sebagai biaya
Kontak customer service per 1.000 order	tidak naik > 5%	Kebingungan pengguna sering tidak terlihat di metric konversi
Revenue kategori lain	tidak turun signifikan	Kanibalisasi antar kategori
Unsubscribe / opt-out	tidak naik > 10% relatif	Untuk tes komunikasi; kerusakan aset jangka panjang

► EXECUTIVE PERSPECTIVE — guardrail adalah kontrak, bukan formalitas

Nilai guardrail muncul justru saat hasil OEC menyenangkan. Tanpa ambang tertulis di muka, tim yang baru saja melihat lift +4% akan menawarkan: "kenaikan refund 0,5 pp itu kecil, kan?" Dengan ambang tertulis, percakapan berubah menjadi keputusan sadar yang tercatat. Organisasi yang tidak punya kebiasaan ini secara sistematis mengakumulasi kerusakan kecil yang tidak pernah dikaitkan dengan penyebabnya.

Bagian 4 — Alokasi traffic, holdout, dan ramp-up

Alokasi

Alokasi 50/50 memberi power maksimum untuk ukuran sampel total tertentu. Alokasi tidak seimbang (90/10) dipakai ketika risiko treatment tinggi — dengan konsekuensi power turun tajam.

Efisiensi relatif terhadap 50/50 (total traffic sama):
 50/50 → 100% 70/30 → 84% 90/10 → 36% 95/5 → 19%

Membaca angka ini: tes 90/10 membutuhkan hampir 3× lebih banyak traffic total untuk MDE yang sama dibanding 50/50.

Ramp-up: melindungi tanpa merusak analisis

Hari 1–2 : 1% treatment → QA teknis, SRM, error rate
 Hari 3–4 : 5% treatment → guardrail, tidak ada pembacaan OEC
 Hari 5–7 : 20% treatment → guardrail
 Hari 8–28 : 50% treatment → PERIODE ANALISIS RESMI
 analisis dilakukan HANYA pada data fase ini

■ TECHNICAL NOTE — mengapa data fase ramp-up dibuang

Menggabungkan periode dengan rasio alokasi berbeda menciptakan bentuk Simpson's paradox (Vol 3 Bab 11): komposisi hari berbeda antar kelompok. Aturan praktis yang aman: tetapkan tanggal mulai analisis = hari pertama alokasi final, dan hanya masukkan pengguna yang *pertama kali* masuk eksperimen sejak tanggal itu. Pengguna yang sudah terpapar pada fase ramp dikeluarkan dari analisis utama (dan dianalisis terpisah bila perlu).

Holdout jangka panjang

Setelah tes dimenangkan dan dirilis, sisakan 1–5% pengguna yang tidak menerima perubahan selama 3–12 bulan. Tiga alasan yang membenarkan biayanya:

- Efek jangka pendek sering meluruh (novelty effect, Bab 4); holdout mengukur berapa yang tersisa.
- Efek kumulatif dari puluhan kemenangan kecil sering tidak menjumlah — holdout global mengukur dampak nyata seluruh program eksperimen terhadap metric perusahaan.

- Menjadi pembanding untuk mendeteksi regresi yang tidak disadari.

Temuan yang berulang di banyak perusahaan: jumlah lift yang diklaim seluruh tes dalam setahun jauh melebihi pertumbuhan metric yang sebenarnya terjadi. Holdout global adalah satu-satunya cara jujur mengukur selisih ini — dan menemukan penyebabnya (Bab 5: multiple testing dan winner's curse).

Bagian 5 — Kapan A/B test tidak sah dipakai

Situasi	Mengapa A/B test gagal	Alternatif
Perubahan harga yang terlihat publik	Pengguna saling membandingkan; risiko reputasi dan hukum; kontaminasi	Geo/store experiment (Bab 12); RDD pada ambang harga (Bab 11)
Marketplace dua sisi (penjual berkompetisi)	Keuntungan treatment diambil dari kontrol → efek terlihat 2× dari sebenarnya	Switchback, cluster/geo randomization (Bab 12)
Efek jaringan (fitur sosial, referral)	Kontrol ikut terpapar lewat teman	Cluster randomization berbasis graf
Perubahan brand / kampanye TV	Tidak bisa disegmentasi per pengguna	Geo experiment, MMM (Bab 12)
Kejadian sangat jarang (fraud besar, churn tahunan)	Power tidak tercapai dalam waktu wajar	Surrogate metric; observasional dengan Bab 9–11
Keputusan satu kali yang tidak berulang (akuisisi, buka pasar baru)	Tidak ada unit untuk diacak	Decision modeling (Volume 5)
Perubahan yang jelas benar & berbiaya rendah (perbaikan bug, kepatuhan hukum)	Menguji hal yang wajib dilakukan hanya membuang waktu	Rilis langsung, pantau guardrail

HOW — dokumen desain eksperimen TokoNusa

Berikut dokumen desain nyata yang menjadi rujukan sepanjang volume ini. Formatnya sengaja padat: satu halaman, semua keputusan terkunci sebelum data dilihat.

EXP-041 — Menaikkan ambang gratis ongkir Rp 150.000 → Rp 199.000

KONTEKS	Subsidi ongkir Rp 14.200/order = 20,4% dari CM. Vol 2 Bab 3 menghitung expected value gratis ongkir berdasarkan asumsi; asumsi itu belum pernah diuji.
HIPOTESIS	Menaikkan ambang ke Rp 199rb akan menurunkan conversion (sebagian keranjang di bawah 199rb batal) TETAPI menaikkan AOV (sebagian pembeli menambah item untuk mencapai ambang) dan menurunkan subsidi ongkir per order. Mekanisme: 31% keranjang berada di rentang 150–199rb – kelompok inilah yang akan terbelah antara "menambah item" dan "membatalkan". Prediksi: conversion -1% s/d -3% relatif; AOV +4% s/d +6%; CM per pengunjung +5% s/d +12%.
ESTIMAND	ATE pada seluruh pengunjung situs & aplikasi.
UNIT ACAK	user_id (pengguna akan menyadari perubahan antar kunjungan)
ALOKASI	50/50, ramp 1%→5%→50% dalam 5 hari
POPULASI	seluruh pengunjung Indonesia; dikecualikan: karyawan, akun B2B, pengguna dengan voucher ongkir aktif

OEC	Contribution margin per pengunjung (Rp) = (order/pengunjung) × CM per order CM per order = AOV – COGS – packing – subsidi ongkir – payment fee [definisi Vol 3 Bab 4]
SUPPORTING	conversion visit→pay · AOV · item per order · % keranjang 150–199rb yang naik ke ≥199rb · subsidi ongkir per order · abandonment di halaman ongkir
GUARDRAIL	SRM $p > 0,001$ · refund $\leq +0,3pp$ · kontak CS $\leq +5\%$ · revenue kategori grocery $\leq -2\%$ (barang murah paling terdampak) · NPS survei in-app ≤ -3 poin
DURASI	21 hari (3 siklus mingguan penuh), mulai setelah ramp Tidak berhenti lebih awal apa pun hasilnya (Bab 5). Blackout: tidak boleh beririsan dengan Harbolnas.
KEPUTUSAN	CM/pengunjung lift $> +3\%$ & CI bawah > 0 & guardrail aman → rilis 100%, holdout 2% selama 6 bulan CI mencakup nol → tahan; analisis segmen; pertimbangkan ambang antara (Rp 175rb) sebagai varian berikutnya Lift negatif atau guardrail dilanggar → batalkan, tulis memo pembelajaran
UKURAN	Lihat Bab 3: MDE 3% relatif tercapai dalam 14 hari pada traffic 80rb pengunjung/hari; 21 hari memberi bantalan.
PEMILIK	Analyst: (nama) · Decision maker: VP Commerce Pre-registered: 12 Mei 2026, disimpan di experiment log

✓ **BEST PRACTICE — Pre-registration internal**

Simpan dokumen desain dengan timestamp yang tidak bisa diubah (tiket, commit, atau experiment platform) *sebelum* data mengalir. Ini menghilangkan seluruh kelas perdebatan pasca-hasil: apa OEC-nya, berapa lama tesnya, segmen mana yang direncanakan. Praktik yang dipinjam dari uji klinis ini adalah pembeda tunggal terbesar antara program eksperimen yang dipercaya dan yang tidak.

Checklist desain eksperimen

- ✓ Hipotesis memuat perubahan, mekanisme, prediksi berangka, dan konsekuensi keputusan
- ✓ Estimand dan populasi ditulis eksplisit, termasuk siapa yang dikecualikan
- ✓ Unit randomisasi dipilih lewat pohon keputusan; interferensi diperiksa secara sadar
- ✓ Unit analisis = unit randomisasi (atau koreksi SE direncanakan)
- ✓ OEC tunggal ditetapkan; metric pendukung dan guardrail dipisahkan dengan ambang tertulis
- ✓ Alokasi, rencana ramp-up, dan tanggal mulai analisis resmi ditetapkan
- ✓ Durasi ditetapkan di muka dan mencakup kelipatan siklus mingguan penuh
- ✓ Aturan keputusan untuk ketiga hasil (menang / flat / kalah) sudah tertulis
- ✓ Blackout period musiman diperiksa
- ✓ Dokumen di-pre-register dengan timestamp sebelum data pertama masuk

Ending Card — Bab 2

What you learned

Struktur hipotesis empat komponen dan pentingnya mekanisme; tabel dan pohon keputusan pemilihan unit randomisasi; aturan besi unit analisis = unit randomisasi; struktur metric tiga lapis (OEC, supporting, guardrail) beserta daftar guardrail wajib; efisiensi alokasi traffic; protokol ramp-up dan mengapa datanya dibuang; holdout jangka panjang; tujuh situasi di mana A/B test tidak sah; dokumen desain lengkap EXP-041.

Skills mastered

Experiment design doc · pemilihan unit randomisasi · konstruksi OEC · penetapan guardrail · pre-registration.

Real business value

Dokumen desain satu halaman adalah artefak dengan rasio nilai-terhadap-usaha tertinggi dalam seluruh praktik eksperimentasi. Ia mencegah tes yang tidak bisa ditafsirkan, menghentikan perdebatan pasca-hasil, dan membuat keputusan dapat diaudit berbulan-bulan kemudian.

Interview readiness

● INTERVIEW QUESTIONS

1. "Rancang A/B test untuk fitur X." — struktur jawaban: hipotesis+mekanisme → estimand → unit randomisasi (dan alasannya) → OEC + guardrail → ukuran sampel & durasi → aturan keputusan. Menyebut guardrail dan aturan keputusan adalah yang membedakan kandidat senior.
2. "Kapan kamu mengacak per sesi, bukan per pengguna?" (Perubahan tak disadari lintas kunjungan, metric bukan per-pengguna, dan tidak ada efek pembelajaran.)
3. "Metric utama naik tapi kamu menolak merilis — kapan itu terjadi?" (Guardrail dilanggar; OEC bukan metric utama tim; efek terkonsentrasi pada segmen yang merugikan jangka panjang.)
4. "Mengapa 90/10 bukan pilihan gratis?" (Power turun ke 36%.)
5. "Apa itu OEC dan bagaimana kamu memilihnya untuk marketplace?" (Selaras jangka panjang; sering gabungan sisi pembeli dan penjual.)

Exercises

Exercise 2.1 (Beginner · 25 menit)

Objective: memilih unit randomisasi

Tentukan unit randomisasi yang benar dan alasannya untuk: (a) mengubah algoritma urutan hasil pencarian; (b) menaikkan biaya layanan penjual di marketplace dari 3% ke 4%; (c) mengubah warna tombol "beli"; (d) memberi kupon Rp 25rb kepada pelanggan yang belum belanja 90 hari; (e) menambah 1 staf kasir pada jam sibuk; (f) fitur "bagikan keranjang ke teman".

Answer key 2.1

(a) **Pengguna** — hasil pencarian diingat antar kunjungan dan efek pembelajaran nyata. (b) **Tidak bisa A/B per penjual** — penjual berkompetisi memperebutkan pembeli yang sama (interferensi), dan perbedaan tarif menimbulkan masalah keadilan; gunakan geo atau switchback (Bab 12). (c) **Pengguna** (sesi bisa dibenarkan bila perubahan sangat kecil, tetapi pengguna adalah default yang aman dan biayanya nol). (d) **Pengguna**, dan perhatikan bahwa ini encouragement design — tidak semua akan menebus kupon, sehingga ITT dan LATE berbeda (Bab 11). (e) **Toko x slot waktu** — stratifikasi berdasarkan traffic; jumlah unit kecil, power rendah, pertimbangkan switchback antar hari. (f) **Klaster sosial** — fitur berbagi bocor ke kontrol; randomisasi per pengguna akan meremehkan atau melebihkan efek tergantung arah limpahan.

Exercise 2.2 (Intermediate · 40 menit)

Objective: mendeteksi OEC yang cacat

Untuk tiap OEC berikut, sebutkan cara ia bisa naik sambil merugikan perusahaan, lalu usulkan perbaikannya: (a) conversion rate; (b) jumlah klik pada rekomendasi produk; (c) waktu yang dihabiskan di aplikasi; (d) jumlah order per hari; (e) skor kepuasan setelah kontak CS; (f) revenue per pengunjung.

Answer key 2.2

(a) Turunkan harga/ambang ongkir → konversi naik, CM turun. Perbaikan: **CM per pengunjung**. (b) Judul umpan-klik dan gambar menyesatkan → klik naik, refund naik. Perbaikan: klik yang **berujung pembelian yang tidak dikembalikan** dalam 30 hari. (c) UI yang membingungkan menaikkan waktu. Perbaikan: **task success rate** atau waktu-ke-pembelian (lebih pendek lebih baik). (d) Pecah satu order menjadi beberapa pengiriman; promo besar-besaran. Perbaikan: **CM total**, dengan order sebagai supporting. (e) Hanya pelanggan yang puas yang menjawab survei (selection); agen "membeli" skor dengan kompensasi berlebihan. Perbaikan: **tingkat penyelesaian kontak pertama** + biaya kompensasi sebagai guardrail. (f) Terbaik dari daftar ini, tapi masih bisa naik lewat produk bermargin rendah atau bundling yang menaikkan retur. Perbaikan: **CM per pengunjung** dengan refund rate sebagai guardrail. Pola umum: metric yang bagus hampir selalu *margin-based* dan *net of reversal*.

Exercise 2.3 (Advanced · 90 menit)

Objective: menulis dokumen desain lengkap

Tulis dokumen desain lengkap (format EXP-041) untuk **EXP-052 — checkout satu halaman untuk mobile web**. Wajib memuat: mekanisme yang dapat diverifikasi dari metric pendukung, estimand, unit randomisasi + alasan, OEC, minimal 5 guardrail dengan ambang, alokasi & ramp, durasi dengan alasan siklus mingguan, dan aturan keputusan untuk tiga hasil. Sertakan satu risiko desain yang kamu sadari dan bagaimana kamu memitigasinya.

Answer key 2.3 (kerangka penilaian)

Elemen yang harus ada: **mekanisme** = drop-off antar langkah (verifikasi lewat metric pendukung "drop-off per langkah", bukan hanya conversion akhir). **Unit** = pengguna (perubahan besar yang disadari). **OEC** = CM per pengunjung mobile web; conversion sebagai supporting. **Guardrail** = SRM, latency p95 (halaman tunggal memuat lebih banyak elemen — risiko nyata), error rate pembayaran, refund, kontak CS terkait pembayaran, tingkat kegagalan transaksi per metode bayar. **Durasi** = 14-21 hari, kelipatan minggu penuh karena pola belanja akhir pekan berbeda. **Risiko desain yang matang untuk disebut:** checkout satu halaman berperilaku berbeda pada perangkat lama/koneksi lambat → mitigasi: analisis pra-rencana per kelas perangkat dan guardrail latency terpisah untuk perangkat kelas bawah. Kandidat yang menyebut risiko ini menunjukkan pengalaman nyata.

Exercise 2.4 (Production Challenge · 4 jam)

Objective: membangun template organisasi

Buat template dokumen desain eksperimen untuk sebuah organisasi (boleh fiktif), lengkap dengan: formulir satu halaman, daftar guardrail standar perusahaan beserta ambangnya, tabel pemilihan unit randomisasi, dan checklist review yang harus dilewati sebelum tes boleh dijalankan. Tambahkan halaman "aturan tim": siapa yang boleh menghentikan tes, siapa pemilik keputusan, dan bagaimana konflik metric diselesaikan.

Answer key 2.4 — rubrik

Template yang kuat: muat dalam satu halaman (template panjang tidak dipakai orang); ambang guardrail berupa angka, bukan "tidak boleh memburuk signifikan"; ada kolom "siapa yang memutuskan" yang terisi nama peran; ada aturan eksplisit bahwa tes tidak boleh dihentikan lebih awal kecuali guardrail dilanggar; dan ada bagian "apa yang akan kita pelajari jika hasilnya nol" — pertanyaan ini menyaring tes yang tidak layak dijalankan sejak awal.

Portfolio idea

★ PORTFOLIO TIP

Publikasikan template desain eksperimenmu (Exercise 2.4) sebagai artefak portfolio. Hiring manager membaca dokumen ini sebagai bukti bahwa kandidat pernah berpikir tentang eksperimen sebagai *proses organisasi*, bukan sekadar uji statistik — sinyal senioritas yang sulit dipalsukan.

Further reading

Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* (Bab 1-7; rujukan utama praktik industri) · Georgi Georgiev, *Statistical Methods in Online A/B Testing* · Dokumentasi publik experimentation platform Microsoft ExP dan Netflix tentang pemilihan metric.

Next chapter

Bab 3 — matematika yang menentukan apakah tes layak dijalankan sama sekali. Sample size, power, MDE, dan pelajaran yang paling menyakitkan: sebagian besar tes yang dijalankan perusahaan kecil tidak akan pernah bisa mendeteksi efek yang realistis.

Bab 3 — Sample Size, Power, dan MDE

Aritmetika yang menentukan apakah sebuah tes layak dijalankan — dan yang menjelaskan mengapa banyak tes tidak pernah bisa menjawab pertanyaannya.

Learning objectives	Menjelaskan power, alpha, beta, dan MDE beserta trade-off-nya; menghitung ukuran sampel untuk metric proporsi dan metric kontinu; membalik perhitungan menjadi MDE dari traffic yang tersedia; menerjemahkan MDE menjadi durasi; mengenali tes yang underpowered dan konsekuensinya; menjelaskan winner's curse; memutuskan tes mana yang tidak layak dijalankan
Prerequisites	Bab 2; Vol 2 Bab 4 (inference, CI, standard error) dan Bab 5 (uji hipotesis)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	Power analysis, MDE calculation, duration planning, portfolio prioritization, deteksi underpowered test
Business domain	E-commerce (traffic besar) dan retail fisik (85 toko, traffic unit kecil) — kontras yang mengajarkan paling banyak

Mengapa bab ini menyelamatkan lebih banyak waktu daripada bab mana pun

Perhitungan yang diajarkan di sini memakan waktu lima menit dan sering menghasilkan kesimpulan: *tes ini tidak akan pernah bisa mendeteksi efek yang kita harapkan*. Lima menit itu menyelamatkan tiga minggu kalender, dua engineer, dan — yang paling penting — mencegah kesimpulan "tidak ada efek" dari sebuah tes yang memang tidak dirancang untuk melihat efek.

Kalimat yang harus melekat: **tes yang underpowered tidak menghasilkan jawaban "tidak ada efek". Ia menghasilkan "kami tidak tahu", yang lalu sering disalahartikan sebagai "tidak ada efek".**

Empat besaran dan hubungannya

Simbol	Nama	Arti dalam bahasa keputusan	Nilai konvensional
α	Significance level (false positive rate)	Peluang menyatakan ada efek padahal tidak ada — merilis perubahan yang sebenarnya sia-sia	0,05 (dua sisi)
β	False negative rate	Peluang melewatkan efek yang benar-benar ada — membuang ide yang sebenarnya baik	0,20
$1-\beta$	Power	Peluang <i>menemukan</i> efek sebesar MDE bila efek itu memang ada	0,80 (minimum), 0,90 (keputusan besar)

δ / MDE	Minimum Detectable Effect	Efek terkecil yang tes ini sanggup deteksi dengan andal	ditentukan bisnis, bukan statistik
σ	Standard deviation metric	Kebisingan bawaan metric	diukur dari data historis
n	Ukuran sampel per kelompok	Anggaran traffic	hasil perhitungan

Keempatnya terikat satu persamaan. Tetapkan tiga, yang keempat ditentukan. Tidak ada cara menghindari dari trade-off ini:

$$n \propto \sigma^2 / \text{MDE}^2$$

Konsekuensi yang harus dihafal:

MDE dibagi 2 → n dikali 4 (kuadratik, brutal)
 σ^2 dibagi 2 → n dibagi 2 (dasar dari CUPED, Bab 6)
 power 80%→90% → $n \times 1,34$
 α 0,05→0,01 → $n \times 1,49$

◆ BUSINESS INSIGHT — α dan β adalah keputusan bisnis, bukan tradisi

Nilai 0,05 dan 0,80 adalah konvensi, bukan hukum. Pilihannya seharusnya mencerminkan biaya kesalahan. **Perubahan berbiaya rilis nol** (mengubah teks tombol): false positive murah, false negative mahal → longgarkan α ke 0,10, pertahankan power tinggi. **Perubahan yang mengunci arsitektur selama dua tahun**: false positive sangat mahal → perketat α ke 0,01 dan power 0,90. Menyebutkan pertimbangan ini di rapat desain langsung menandai analyst yang berpikir, bukan yang menyalin template.

Rumus yang dipakai sehari-hari

Metric proporsi (conversion rate, churn rate, klik)

$$n_{\text{per_arm}} = \frac{2 \cdot (z_{\{\alpha/2\}} + z_{\beta})^2 \cdot \bar{p} \cdot (1 - \bar{p})}{\delta^2}$$

dengan $z_{\{0,025\}} = 1,960$ $z_{\{0,80\}} = 0,8416$
 $(z_{\alpha} + z_{\beta})^2 = 7,8489$ ← angka yang layak dihafal
 $\bar{p}$ = baseline conversion, δ = MDE absolut

Faktor 2 muncul karena dua kelompok sama besar, masing-masing menyumbang ketidakpastian. Rumus ini adalah aproksimasi normal — akurat selama $n \cdot p > 30$, yang selalu terpenuhi dalam konteks web.

Metric kontinu (revenue per pengunjung, CM per pengunjung, AOV)

$$n_{\text{per_arm}} = \frac{2 \cdot (z_{\{\alpha/2\}} + z_{\beta})^2 \cdot \sigma^2}{\delta^2}$$

Perbedaan praktisnya besar. Metric proporsi memiliki variance yang terkunci pada $p(1-p)$; metric revenue memiliki variance yang jauh lebih besar karena distribusinya sangat miring: mayoritas pengunjung menghasilkan nol, sebagian kecil menghasilkan nilai besar.

■ TECHNICAL NOTE — mengapa metric revenue butuh sampel jauh lebih besar

Untuk TokoNusa: conversion 3,2%, CM per order Rp 69.700 dengan koefisien variasi antar order $\pm 0,6$. Maka CM per pengunjung memiliki mean Rp 2.230 dan **standard deviation Rp 14.368** — koefisien variasi 6,4. Bandingkan dengan metric conversion yang CV-nya 5,5. Akibatnya, MDE 5% relatif membutuhkan ± 190.000 pengunjung per kelompok untuk conversion tetapi **± 261.000** untuk CM per pengunjung. Inilah harga yang dibayar untuk memakai OEC yang benar — dan alasan mengapa teknik variance reduction di Bab 6 bukan kemewahan.

Tabel referensi: berapa sampel yang dibutuhkan

Ukuran sampel per kelompok — $\alpha=0,05$ dua sisi, power=80%, metric proporsi

Baseline	MDE 1% rel	MDE 2% rel	MDE 5% rel	MDE 10% rel	MDE 20% rel
3,2% (TokoNusa)	4.748.572	1.187.143	189.943	47.486	11.871
5%	2.982.574	745.644	119.303	29.826	7.456
10%	1.412.798	353.200	56.512	14.128	3.532
30%	366.281	91.570	14.651	3.663	916

Baca tabel ini sekali dengan saksama; ia memuat pelajaran terpenting bab ini. Untuk mendeteksi perbaikan 1% relatif pada conversion 3,2% dibutuhkan 4,7 juta pengunjung per kelompok — 9,5 juta total, atau hampir empat bulan seluruh traffic TokoNusa untuk *satu* tes. Sebagian besar perusahaan tidak memiliki traffic untuk mendeteksi efek kecil, dan tidak ada teknik statistik yang mengubah kenyataan itu.

Membalik perhitungan: dari traffic yang ada menjadi MDE

Dalam praktik, arah perhitungan yang benar hampir selalu terbalik. Traffic adalah kenyataan yang tidak bisa dinegosiasikan; yang bisa dipilih adalah durasi. Maka pertanyaannya: *dengan durasi X, seberapa kecil efek yang bisa kita lihat?*

$$\text{MDE} = (z_{\{\alpha/2\}} + z_{\beta}) \cdot \sqrt{(2 \sigma^2 / n)} \quad \text{dengan } n = \text{traffic per kelompok}$$

TokoNusa — traffic 2,4 juta kunjungan/bulan $\approx 80.000/\text{hari}$, alokasi 50/50

Durasi	n per kelompok	MDE conversion (abs)	MDE conversion (rel)	MDE CM/pengunjung (rel)
7 hari	280.000	0,132 pp	4,12%	4,82%
14 hari	560.000	0,093 pp	2,91%	3,41%
21 hari	840.000	0,076 pp	2,38%	2,78%
28 hari	1.120.000	0,066 pp	2,06%	2,41%
42 hari	1.680.000	0,054 pp	1,68%	1,97%

Perhatikan hasil yang paling instruktif: menggandakan durasi dari 21 ke 42 hari hanya memperbaiki MDE dari 2,38% ke 1,68% — turun 1,4 $\times$, bukan 2 $\times$, karena hubungannya akar kuadrat. **Waktu memberi hasil yang makin menurun.** Ini alasan struktural mengapa perusahaan besar mengejar variance reduction dan bukan durasi yang lebih panjang.

✓ BEST PRACTICE — Urutan percakapan yang benar dengan pemangku kepentingan

Jangan bertanya "berapa lift yang kamu harapkan?" — jawabannya selalu optimistis dan tidak berguna. Tanyakan: **"Berapa lift terkecil yang membuatmu benar-benar merilis perubahan ini, mengingat biaya implementasi dan pemeliharannya?"** Itulah MDE yang benar — sebuah angka bisnis. Lalu tunjukkan tabel durasi. Percakapan berubah dari harapan menjadi trade-off yang bisa diputuskan.

MDE bukan tebakan efek — ia adalah ambang keputusan

Kesalahpahaman yang paling umum: menetapkan MDE sama dengan lift yang diharapkan. Keduanya berbeda peran.

MDE = efek terkecil yang PENTING SECARA BISNIS
(di bawah ini kita tidak akan merilis, jadi tidak perlu kemampuan mendeteksinya)

Lift harapan = tebakan tentang efek sebenarnya
(tidak masuk ke dalam rumus sama sekali)

Cara menetapkan MDE dari bisnis, contoh EXP-052:
Biaya implementasi + pemeliharaan checkout baru: Rp 380 juta/th
CM tahunan dari traffic online: $2,4jt \times 12 \times Rp\ 2.230 = Rp\ 64,2\ M$
Titik impas: $380\ jt / 64,2\ M = 0,59\%$ lift relatif
Margin keamanan $3\times$ (untuk risiko & winner's curse) $\rightarrow MDE = 1,8\%$
Dibulatkan ke atas untuk kepraktisan $\rightarrow MDE = 2\%$ relatif

Underpowered test: kerusakan yang tidak terlihat

Kerusakan pertama — hasil nol yang menyesatkan

Tes dengan power 30% yang menghasilkan $p > 0,05$ hampir tidak memberi informasi: bahkan jika efek sebesar MDE benar-benar ada, tes itu akan gagal menemukannya 70% kali. Melaporkan "tidak ada efek" dari tes semacam itu adalah kesalahan interpretasi, bukan temuan.

Kerusakan kedua — winner's curse

Ini yang jarang diajarkan dan paling merusak kepercayaan pada program eksperimen. Pada tes underpowered, satu-satunya cara mencapai signifikansi adalah dengan mengamati efek yang *kebetulan besar*. Akibatnya, di antara tes yang menang, estimasi efeknya sistematis melebihi kebenaran.

Efek sebenarnya: +2% relatif
Tes dengan power 25% $\rightarrow$ tes yang "menang" rata-rata melaporkan lift sekitar +5% s/d +6%
Tes dengan power 80% $\rightarrow$ tes yang "menang" rata-rata melaporkan lift sekitar +2,3%

Konsekuensi organisasi:
Jumlah lift yang diklaim seluruh tes setahun = +34%
Pertumbuhan metric yang benar-benar terjadi = +6%
Selisihnya bukan kebohongan — itu winner's curse
plus multiple testing (Bab 5) plus efek yang meluruh (Bab 4).

✗ COMMON MISTAKE — Menjalankan tes "sekadar untuk melihat"

Gejala: tim menjalankan tes pada segmen kecil atau fitur dengan traffic rendah tanpa menghitung power; hasilnya flat; kesimpulan yang ditulis: "fitur ini tidak berdampak".

Mengapa terjadi: perhitungan power dianggap formalitas statistik, bukan syarat kelayakan.

Perbaikan: hitung MDE *sebelum* tes. Jika MDE yang tercapai jauh lebih besar dari efek yang masuk akal secara bisnis, tes tidak dijalankan — dan itu adalah keputusan yang benar, bukan kegagalan.

Cara senior menghindarinya: memasukkan baris "MDE tercapai pada durasi rencana" ke dalam formulir desain sebagai kolom wajib, sehingga tes underpowered tidak bisa lolos review tanpa seseorang menyadarinya.

Kasus kontras: eksperimen pada 85 toko

Traffic web membuat eksperimen terasa mudah. Retail fisik mengajarkan sebaliknya, dan pelajarannya berlaku untuk semua eksperimen berunit besar (toko, kota, cabang, tim).

TokoNusa: 85 toko, revenue rata-rata Rp 1.335 juta/toko/bulan
Alokasi 50/50 → $n = 42$ toko per kelompok (bukan 42 ribu – 42)

Variasi antar toko (CV) = 0,25 → MDE = 15,3% relatif
Variasi antar toko (CV) = 0,40 → MDE = 24,5% relatif

Artinya: promosi in-store yang menaikkan penjualan 5% TIDAK AKAN PERNAH terdeteksi dengan desain ini. Tidak peduli berapa lama dijalankan – jumlah TOKO yang membatasi, bukan jumlah hari.

Tiga cara menyelamatkan eksperimen berunit kecil, yang wajib dikuasai:

Teknik	Cara kerja	Dampak pada MDE (kasus 85 toko)
Kontrol periode-sebelum (ANCOVA / CUPED, Bab 6)	Gunakan penjualan toko sebelum tes sebagai kovariat; korelasi antar-periode pada toko biasanya sangat tinggi ($\rho \approx 0,7-0,9$)	MDE turun dari 15,3% ke 10,9% pada $\rho=0,7$; ke $\pm 6,7\%$ pada $\rho=0,9$
Stratifikasi / blocking	Kelompokkan toko berdasarkan ukuran & wilayah, lalu acak di dalam blok	Menghilangkan ketidakseimbangan yang paling merusak; efek serupa dengan menurunkan σ
Switchback (Bab 12)	Setiap toko bergantian treatment/kontrol antar minggu; unit menjadi toko×minggu	Jumlah unit efektif naik berlipat; hanya sah bila efek tidak bertahan lintas periode
Synthetic control (Bab 9)	Bangun toko kontrol tiruan dari kombinasi tertimbang toko lain	Berguna ketika treatment hanya bisa diberikan pada sedikit toko

Dari MDE ke durasi: koreksi yang sering dilupakan

$$\text{durasi_kasar} = (2 \times n_per_arm) / (\text{pengunjung per hari} \times \% \text{ traffic yang masuk eksperimen})$$

lalu terapkan KOREKSI berikut – semuanya menaikkan durasi:

1. Bulatkan ke atas ke kelipatan 7 hari (siklus mingguan)
2. Tambahkan periode ramp-up (3–5 hari) (data dibuang)
3. Tambahkan lag konversi (jika metric butuh waktu matang: pembelian berulang, retur 30 hari)
4. Jangan beririsan dengan periode anomali (Harbolnas, Lebaran, gajian akhir bulan)

5. Minimum absolut: 7 hari (bahkan bila sampel tercapai dalam 2 hari – komposisi hari kerja/akhir pekan)

⚠ **WARNING — Sampel tercapai bukan alasan untuk berhenti**

Pada traffic besar, ukuran sampel untuk MDE 5% bisa tercapai dalam 5 hari. Menghentikan tes di hari ke-5 tetap salah: lima hari pertama memiliki komposisi hari yang tidak mewakili (misalnya Senin-Jumat saja), dan efek yang berbeda antara pembeli akhir pekan dan hari kerja akan hilang. **Aturan: durasi minimum satu siklus mingguan penuh, dan idealnya kelipatan tujuh hari.** Bab 4 memperluas alasan ini.

Prioritisasi portofolio eksperimen

Ketika traffic terbatas, setiap tes yang dijalankan memakan slot yang tidak bisa dipakai tes lain. Ini menjadikan power analysis sebagai alat *prioritisasi*, bukan hanya validasi.

Tes	Nilai bila menang (CM/tahun)	MDE realistis	Traffic-minggu dibutuhkan	Prioritas
EXP-041 ambang ongkir	Rp 6,1 M	3%	3	Tinggi — nilai besar, biaya sedang
EXP-052 checkout 1 halaman	Rp 2,0 M	2%	4	Sedang
Warna tombol beli	Rp 0,1 M	0,5%	>20	Tolak — tidak akan pernah terdeteksi, dan nilainya tidak sepadan
Rekomendasi personalisasi	Rp 9,0 M	4%	2	Tertinggi — nilai tertinggi, deteksi termudah

Kolom "traffic-minggu" adalah mata uang sesungguhnya dari program eksperimentasi. Tim yang mengelolanya secara eksplisit menjalankan 2–3× lebih banyak tes bernilai per tahun dibanding tim yang menjalankan tes sesuai urutan permintaan datang.

Checklist power analysis

- ✓ MDE ditetapkan dari titik impas bisnis, bukan dari lift yang diharapkan
- ✓ Baseline dan σ diambil dari data historis periode sebanding, bukan ditebak
- ✓ Metric proporsi dan metric kontinu dihitung dengan rumus yang tepat masing-masing
- ✓ MDE dilaporkan untuk durasi rencana, bukan hanya n minimum
- ✓ Durasi dibulatkan ke kelipatan minggu penuh dan menghindari periode anomali
- ✓ Ramp-up dan lag konversi ditambahkan ke durasi
- ✓ Untuk unit besar (toko/geo): kontrol periode-sebelum dan stratifikasi direncanakan sejak awal
- ✓ Tes yang MDE-nya jauh melampaui efek realistis dibatalkan sebelum implementasi
- ✓ Winner's curse diantisipasi: estimasi dari tes yang menang dipotong sebelum dipakai untuk proyeksi

Ending Card — Bab 3

What you learned

Hubungan α , β , power, MDE, σ , dan n beserta konsekuensi kuadratnya; rumus dan tabel ukuran sampel untuk metric proporsi dan kontinu; pembalikan perhitungan menjadi MDE per durasi; MDE sebagai ambang keputusan bisnis; winner's curse dan mengapa klaim lift agregat tidak pernah terwujud; eksperimen berunit kecil (85 toko) dan empat teknik penyelamatnya; koreksi durasi; prioritasasi portofolio berbasis traffic-minggu.

Skills mastered

Power analysis dua arah · penetapan MDE dari titik impas · perencanaan durasi · penilaian kelayakan tes · prioritasasi portofolio eksperimen.

Real business value

Kemampuan berkata "tes ini tidak layak dijalankan, dan ini perhitungannya" adalah salah satu kontribusi paling bernilai seorang analyst. Ia menghemat siklus rekayasa, mencegah kesimpulan palsu, dan mengarahkan traffic yang terbatas ke pertanyaan yang benar-benar bisa dijawab.

Interview readiness

● INTERVIEW QUESTIONS

1. "Baseline conversion 5%, kami ingin mendeteksi lift 10% relatif — berapa sampel dan berapa lama?" (Hitung di kepala: $n \approx 2 \times 7,85 \times 0,05 \times 0,95 / (0,005)^2 \approx 29.800$ per kelompok. Lalu bagi dengan traffic harian.)
2. "Tes berjalan 2 minggu, $p=0,08$. Apa yang kamu lakukan?" (Jangan perpanjang secara ad hoc — itu peeking, Bab 5. Laporkan CI, bandingkan dengan MDE rencana, dan putuskan sesuai aturan yang sudah tertulis.)
3. "Mengapa menggandakan durasi tidak menggandakan sensitivitas?" (Akar kuadrat.)
4. "Apa itu winner's curse dan bagaimana kamu mengoreksinya saat membuat proyeksi bisnis?" (Gunakan batas bawah CI, bukan titik estimasi; naikan power; verifikasi dengan holdout.)
5. "Kami hanya punya 40 toko. Bagaimana kamu menguji promosi in-store?" (Kontrol pra-periode, stratifikasi, switchback, synthetic control — dan kejujuran tentang MDE yang tercapai.)

Exercises

Exercise 3.1 (Beginner · 20 menit)

Objective: perhitungan dasar

Baseline conversion 8%. (a) Hitung n per kelompok untuk MDE 10% relatif, $\alpha=0,05$, power 80%. (b) Traffic 25.000 pengunjung/hari, alokasi 50/50 — berapa hari? (c) Ulangi (a) untuk power 90%. (d) Jelaskan dalam satu kalimat kepada seorang manajer mengapa (c) lebih lama.

Answer key 3.1

(a) $\delta = 0,08 \times 0,10 = 0,008$. $n = 2 \times 7,8489 \times 0,08 \times 0,92 / 0,008^2 = 2 \times 7,8489 \times 0,0736 / 0,000064 = 1,15536 / 0,000064 = \mathbf{18.052 \text{ per kelompok}}$. (b) total $36.104 \div 25.000 = 1,44$ hari $\rightarrow$ dibulatkan ke **7 hari** (aturan siklus mingguan; sampel bukan pengikat di sini, komposisi hari yang mengikat). (c) power 0,90: $(1,96 + 1,2816)^2 = 10,507 \rightarrow n = 10,507 / 7,8489 \times 18.052 = \mathbf{24.166 \text{ per kelompok}}$, naik 1,34 $\times$. (d) "Untuk mengurangi peluang melewatkan efek yang nyata dari 20% menjadi 10%, kita perlu sekitar sepertiga lebih banyak data — kepastian tambahan selalu dibeli dengan sampel."

Exercise 3.2 (Intermediate · 45 menit)

Objective: MDE dari titik impas

TokoNusa mempertimbangkan personalisasi halaman depan. Biaya: Rp 1,2 miliar setup + Rp 600 juta/tahun pemeliharaan; diamortisasi 3 tahun → Rp 1,0 miliar/tahun. CM tahunan dari traffic online = 2,4 juta kunjungan × 12 × Rp 2.230.

(a) Hitung lift relatif titik impas. (b) Tetapkan MDE dengan margin keamanan 2,5×. (c) Berapa lama tes harus berjalan (pakai tabel MDE CM/pengunjung di bab ini)? (d) Jika waktu yang tersedia hanya 3 minggu, apa rekomendasimu?

Answer key 3.2

CM tahunan = 2,4 jt × 12 × 2.230 = Rp 64,2 miliar. (a) Titik impas = $1,0/64,2 = 1,56\%$ lift relatif. (b) MDE = $1,56\% \times 2,5 \approx 3,9\%$, **dibulatkan 4%**. (c) Dari tabel, MDE CM/pengunjung 3,41% tercapai pada 14 hari; 4% tercapai lebih cepat, sekitar 10–11 hari → **14 hari** (dibulatkan ke minggu penuh) plus ramp 4 hari = **18 hari**. (d) 3 minggu cukup. Rekomendasi: jalankan 21 hari untuk memberi bantalan, tetapkan CM/pengunjung sebagai OEC, dan siapkan analisis segmen (pengunjung baru vs kembali) karena personalisasi secara mekanis tidak bisa bekerja pada pengunjung tanpa riwayat — heterogenitas yang harus diantisipasi (Bab 6).

Exercise 3.3 (Advanced · 75 menit)

Objective: menyelamatkan eksperimen berunit kecil

Manajemen ingin menguji layout planogram baru di toko. Tersedia 85 toko; revenue rata-rata Rp 1.335 juta/toko/bulan dengan CV antar toko 0,35. Efek yang diharapkan realistis: +4%.

(a) Hitung MDE dengan desain 50/50 sederhana selama 1 bulan. (b) Apakah tes layak? (c) Rancang ulang desainnya menggunakan minimal dua teknik dari bab ini dan hitung ulang MDE-nya (asumsikan korelasi penjualan toko antar bulan $\rho=0,85$). (d) Jika masih tidak cukup, apa rekomendasi finalmu kepada manajemen — dan bagaimana kamu menyampaikannya tanpa terdengar seperti menolak pekerjaan?

Answer key 3.3

(a) $n=42$ /kelompok, $\sigma = 0,35 \times 1.335 = 467$ juta. $MDE = 2,8016 \times \sqrt{(2 \times 467^2/42)} = 2,8016 \times \sqrt{(10.386)} = 2,8016 \times 101,9 = 285,5$ juta → **21,4% relatif**. (b) **Tidak layak**: MDE 21,4% versus efek harapan 4% — power efektifnya sangat rendah; probabilitas menemukan efek nyata mendekati tingkat kebetulan.

(c) Dengan kontrol pra-periode $\rho=0,85$, $\sigma_{\text{residual}} = \sigma \times \sqrt{(1-0,85^2)} = 467 \times 0,527 = 246$ juta → $MDE = 2,8016 \times \sqrt{(2 \times 246^2/42)} = 2,8016 \times 53,7 = 150,4$ juta → **11,3% relatif**. Tambahkan stratifikasi (blok berdasarkan ukuran toko × wilayah) yang secara praktis mengurangi varians residual lebih lanjut; dan perpanjang ke 3 bulan pengukuran untuk merata-ratakan kebisingan bulanan (σ efektif turun $\pm\sqrt{3}$) → MDE ≈ **6,5%**. Masih di atas 4%.

(d) Rekomendasi final: gunakan **switchback** — setiap toko bergantian layout tiap 2 minggu selama 3 bulan, sehingga unit menjadi toko×periode dan seluruh 85 toko berkontribusi pada kedua kondisi; ini juga menghapus variasi antar toko yang merupakan sumber kebisingan terbesar. Syarat kelayakannya: layout dapat diubah dengan biaya rendah dan tidak ada efek carryover besar — bila syarat ini gagal, alternatifnya adalah menerima bahwa keputusan diambil dengan bukti tingkat 4 (Bab 9, synthetic control atas rollout bertahap).

Cara menyampaikan: "Dengan desain sederhana kita hanya bisa melihat efek $\geq 21\%$; efek yang kita harapkan 4%. Berikut tiga desain alternatif beserta MDE dan biayanya — saya merekomendasikan yang ketiga karena satu-satunya yang bisa menjawab pertanyaan sebenarnya." Menawarkan pilihan, bukan penolakan.

Exercise 3.4 (Production Challenge · 3 jam)

Objective: kalkulator dan dokumen prioritas

Bangun kalkulator power (spreadsheet atau notebook) yang menerima: baseline, σ , traffic harian, alokasi, α , power; dan mengeluarkan tabel MDE per durasi (7/14/21/28/42 hari) untuk metric proporsi dan kontinu. Lalu terapkan pada backlog 8 ide eksperimen (buat sendiri), hitung nilai bisnis jika menang, dan susun dokumen prioritas satu halaman dengan kolom traffic-minggu. Tutup dengan rekomendasi tiga tes yang dijalankan kuartal depan dan tiga yang ditolak beserta alasannya.

Answer key 3.4 — rubrik

Kalkulator yang benar: memakai $(z_{\alpha/2} + z_{\beta})^2$ bukan z^2 saja; membedakan $p(1-p)$ dari σ^2 yang diukur; menampilkan MDE relatif *dan* absolut. Dokumen prioritas yang kuat: memuat kolom "MDE tercapai" berdampingan dengan "efek realistis yang diharapkan", sehingga tes yang tidak layak terlihat sendiri; dan menyertakan tiga penolakan dengan alasan kuantitatif. Kesalahan umum: menghitung nilai bisnis dari titik estimasi tanpa memotong untuk winner's curse, dan lupa bahwa traffic yang dipakai satu tes tidak tersedia untuk tes lain pada periode yang sama.

Portfolio idea

★ PORTFOLIO TIP

Kalkulator power dengan antarmuka sederhana (Streamlit atau spreadsheet rapi) plus dokumen prioritas adalah dua artefak yang langsung dikenali oleh siapa pun yang pernah menjalankan program eksperimen. Tambahkan satu halaman "tiga tes yang saya tolak dan mengapa" — bagian itu yang paling sering memancing pertanyaan lanjutan dalam wawancara.

Further reading

Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* (Bab 17: power, sample size) · Jacob Cohen, *Statistical Power Analysis for the Behavioral Sciences* · Gelman & Carlin, "Beyond Power Calculations" (type S dan type M error — dasar formal winner's curse).

Next chapter

Bab 4 — apa yang terjadi setelah tes berjalan. Sample ratio mismatch, novelty effect, musiman, kebocoran penugasan, dan daftar pemeriksaan QA yang membedakan hasil yang bisa dipercaya dari angka yang kebetulan keluar dari dashboard.

Bab 4 — Menjalankan Eksperimen di Dunia Nyata

Randomisasi yang benar di atas kertas rusak dengan sepuluh cara berbeda di produksi. Bab ini adalah daftar kerusakan itu, dan cara mendeteksinya sebelum keputusan diambil.

Learning objectives	Menjalankan pemeriksaan Sample Ratio Mismatch dan menafsirkannya; mengenali dan menangani novelty serta primacy effect; merancang durasi yang tahan musiman dan efek hari; mendeteksi kebocoran penugasan, kontaminasi, dan interaksi antar eksperimen; menjalankan A/A test dan menafsirkannya; menyusun protokol QA instrumentasi; membaca grafik kumulatif dengan benar
Prerequisites	Bab 2 (desain) dan Bab 3 (power); Vol 1 Bab 5 (pipeline debugging)
Estimasi waktu	Baca 2 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	SRM diagnosis, A/A testing, novelty detection, instrumentation QA, experiment monitoring
Business domain	E-commerce — EXP-041 dan EXP-052 dalam pelaksanaan

Mengapa bab ini ada

Hasil eksperimen yang salah jarang lahir dari statistik yang salah. Ia lahir dari hal-hal yang membosankan: bot yang hanya masuk ke satu varian, redirect yang membuat 3% pengguna hilang, cache yang menyimpan halaman treatment lalu menyajikannya kepada kontrol, atau tes lain yang berjalan bersamaan di area yang sama.

Perusahaan dengan program eksperimen matang melaporkan bahwa **sekitar 6-10% eksperimen mereka gagal pemeriksaan validitas dan dibatalkan sebelum dianalisis**. Angka itu bukan tanda program yang buruk — ia tanda program yang memeriksa. Program yang tidak pernah membatalkan tes hampir pasti sedang mengirimkan hasil yang rusak ke ruang rapat.

Sample Ratio Mismatch — pemeriksaan tunggal paling berharga

SRM adalah penyimpangan rasio penugasan aktual dari rasio yang direncanakan. Jika alokasi 50/50 tetapi kelompok treatment menerima 50,3% pengguna, ada sesuatu yang rusak — dan yang rusak itu hampir selalu juga merusak metric.

Cara menghitung

Chi-square goodness of fit, 1 derajat kebebasan:

$$\chi^2 = \sum (\text{observed} - \text{expected})^2 / \text{expected}$$

Ambang: $p < 0,001 \rightarrow$ BATALKAN eksperimen, jangan dianalisis.

Ambang ketat sengaja dipakai karena tes ini dijalankan pada setiap eksperimen; $\alpha=0,05$ akan memicu alarm palsu terlalu sering.

Contoh nyata dengan angka TokoNusa (total 1.120.000 pengguna, alokasi 50/50)

Kontrol	Treatment	Rasio treatment	χ^2	p-value	Putusan
560.000	560.000	0,5000	0,00	1,000	Bersih
558.797	561.203	0,5011	5,17	0,023	Waspada — periksa, tetapi belum membatalkan (di atas ambang 0,001)
556.600	563.400	0,5030	41,29	<0,000001	BATALKAN

Perhatikan betapa kecil penyimpangan yang sudah fatal: **0,30 percentage point** dari 50% sudah menghasilkan p di bawah sepersejuta. Intuisi manusia sangat buruk di sini — "hanya beda 6.800 dari 1,1 juta" terasa remeh, padahal itu sinyal kuat bahwa mekanisme penugasan tidak berperilaku acak.

⚠ **WARNING — SRM tidak bisa "dikoreksi", hanya bisa didiagnosis**

Godaan yang harus ditolak: menimbang ulang data agar rasionya kembali 50/50. Ini tidak menyelesaikan apa pun. SRM berarti *pengguna tertentu hilang secara sistematis*; pengguna yang hilang berbeda dari yang tersisa, sehingga kelompok tidak lagi sebanding. Menimbang ulang hanya menyembunyikan gejalanya. Satu-satunya respons yang benar: temukan penyebabnya, perbaiki, jalankan ulang.

Daftar penyebab SRM, diurutkan dari yang paling sering

Penyebab	Tanda pengenal	Cara memeriksa
Filter bot/crawler diterapkan tidak simetris	SRM muncul hanya pada segmen traffic tertentu; jam puncak aneh	Hitung rasio sebelum dan sesudah filter bot; keduanya harus 50/50
Redirect pada varian treatment	Treatment kehilangan pengguna; latency treatment lebih tinggi	Bandingkan jumlah event "assigned" vs "exposed" per varian
Kegagalan/timeout pada kode varian baru	SRM memburuk pada perangkat lama atau koneksi lambat	Segmentasi SRM per jenis perangkat, browser, kecepatan koneksi
Penugasan terjadi sebelum syarat kelayakan diperiksa	Pengguna tidak memenuhi syarat masuk ke satu varian saja	Pastikan urutan: cek kelayakan → tugaskan → paparkan
Cache/CDN menyajikan varian yang salah	Rasio menyimpang di wilayah geografis tertentu	Segmentasi SRM per region/PoP CDN
Interaksi dengan eksperimen lain	Rasio bersih di satu tes tetapi rusak pada irisan dengan tes lain	Tabulasi silang penugasan antar eksperimen aktif
Sisa pengguna dari fase ramp-up	SRM hilang bila dibatasi ke pengguna yang masuk setelah alokasi final	Terapkan aturan tanggal mulai analisis (Bab 2)

✓ **BEST PRACTICE — Segmentasi SRM adalah alat diagnosis, bukan hanya alarm**

Ketika SRM terdeteksi, jangan berhenti pada angka agregat. Hitung ulang rasio penugasan per: hari, jam, perangkat, browser, versi aplikasi, region, sumber traffic, dan status login. Segmen tempat SRM terkonsentrasi hampir selalu menunjuk langsung ke penyebab teknisnya. Diagnosis yang biasanya memakan dua hari selesai dalam dua puluh menit dengan tabel ini.

A/A test — mengukur kebisingan sistem sendiri

A/A test adalah eksperimen di mana kedua kelompok menerima perlakuan identik. Efeknya nol secara definisi, sehingga apa pun yang terdeteksi adalah kesalahan sistem.

Apa yang diperiksa	Hasil yang diharapkan	Bila menyimpang
Distribusi p-value dari banyak A/A test	Seragam antara 0 dan 1; $\pm 5\%$ di bawah 0,05	Terlalu banyak signifikan $\rightarrow$ SE terlalu kecil (unit analisis salah, korelasi tidak ditangani)
Rasio penugasan	Sesuai rencana	Bug hashing/bucketing
Keseimbangan kovariat pra-eksperimen	Tidak ada perbedaan sistematis pada usia akun, riwayat belanja, wilayah	Randomisasi tidak independen dari atribut pengguna
Kelengkapan instrumentasi	Jumlah event per varian sebanding	Kehilangan event pada satu varian

Praktik yang direkomendasikan: jalankan A/A secara terus-menerus di latar belakang pada porsi kecil traffic, bukan sesekali. Ia menjadi sistem alarm untuk platform eksperimen itu sendiri.

■ TECHNICAL NOTE — cara membaca distribusi p-value A/A

Kumpulkan p-value dari 100+ A/A test (atau 100+ metric pada satu A/A). Plot histogramnya. **Seragam** = sistem sehat. **Menumpuk di dekat nol** = standard error understated; penyebab tersering adalah unit analisis $\neq$ unit randomisasi (Bab 2) atau metric rasio yang dihitung tanpa delta method (Bab 6). **Menumpuk di dekat satu** = SE overstated; biasanya karena koreksi klaster yang terlalu konservatif. Diagnosis ini tidak bisa dilakukan dari satu eksperimen — ia membutuhkan populasi eksperimen, dan itulah sebabnya program yang matang menyimpan semua hasilnya.

Novelty effect dan primacy effect

Dua bias temporal yang berlawanan arah, keduanya membuat pembacaan awal menyesatkan.

NOVELTY EFFECT — efek awal berlebihan, lalu meluruh

Pengguna mencoba hal baru karena baru, bukan karena lebih baik.


Pola: lift besar di minggu 1, menurun, mendatar di minggu 3–4.



PRIMACY EFFECT — efek awal negatif, lalu membaik

Pengguna lama terganggu perubahan; butuh waktu belajar.

Pola: lift negatif di minggu 1, naik, mendatar di minggu 3–5.



Cara membedakan keduanya dari efek yang nyata

- **Analisis per kohort masuk.** Bandingkan efek pada pengguna yang pertama terpapar di minggu 1, minggu 2, minggu 3. Jika efek pada tiap kohort sama-sama meluruh setelah beberapa hari paparan, itu novelty. Jika kohort yang masuk belakangan menunjukkan efek stabil sejak awal, efeknya nyata dan yang meluruh hanyalah komposisi.
- **Pisahkan pengguna baru dan lama.** Novelty dan primacy hampir seluruhnya menimpa pengguna lama; pengguna baru tidak punya pembandingan. Efek pada pengguna baru adalah estimasi terbaik untuk keadaan tunak (steady state).
- **Holdout jangka panjang.** Cara paling meyakinkan, dan satu-satunya yang mengukur langsung apa yang tersisa setelah enam bulan.

✗ COMMON MISTAKE — Merilis berdasarkan minggu pertama

Gejala: tes menunjukkan +8% di hari ke-4; tim merayakan dan merilis; tiga bulan kemudian metric perusahaan tidak bergerak sama sekali.

Mengapa terjadi: tekanan kecepatan bertemu dengan lift awal yang meyakinkan; novelty effect terlihat persis seperti kemenangan besar.

Perbaikan: durasi minimum ditetapkan di muka dan tidak dinegosiasikan ulang setelah melihat data; plot lift per minggu, bukan hanya lift kumulatif; laporkan lift minggu terakhir berdampingan dengan lift keseluruhan.

Cara senior menghindarinya: menyiapkan grafik "lift per minggu" sebagai bagian standar dari template laporan, sehingga peluruhan terlihat oleh semua orang tanpa perlu diperdebatkan.

Musiman, efek hari, dan pemilihan jendela waktu

Perilaku belanja berbeda secara sistematis antar hari dan antar periode. Jika kedua kelompok mengalami distribusi hari yang sama, ini bukan sumber bias — tetapi ia menjadi masalah begitu durasi bukan kelipatan minggu penuh, atau begitu hasil digeneralisasi ke periode lain.

Fenomena	Dampak pada eksperimen	Penanganan
Efek hari dalam minggu	Komposisi hari tidak seimbang bila durasi bukan kelipatan 7	Durasi = kelipatan 7 hari, selalu
Siklus gaji (akhir/awal bulan)	AOV dan konversi naik tajam; tes 2 minggu bisa jatuh seluruhnya di satu fase	Untuk metric bernilai uang, pertimbangkan 28 hari (satu siklus bulanan penuh)
Harbolnas, Ramadan, Lebaran	Perilaku sangat berbeda; efek yang diukur tidak berlaku di luar periode	Blackout: jangan menjalankan tes keputusan besar; jika terpaksa, laporkan sebagai efek periode kampanye saja
Kampanye marketing bersamaan	Mengubah komposisi pengunjung di kedua kelompok; menaikkan variance	Randomisasi tetap valid; tetapi catat di laporan dan periksa stabilitas efek antar minggu
Rilis produk lain di tengah tes	Interaksi tidak terkendali	Koordinasi kalender rilis; catat sebagai peristiwa di experiment log

◆ BUSINESS INSIGHT — generalisasi ke periode lain adalah asumsi, bukan hasil

Eksperimen memberi jawaban valid *untuk periode ia dijalankan*. Lift 3% pada bulan biasa tidak otomatis berlaku pada Harbolnas ketika perilaku, komposisi pengunjung, dan kompetisi berubah total. Kalimat yang jujur dalam memo: "estimasi ini berlaku untuk kondisi perdagangan normal; dampak pada periode kampanye besar belum diukur." Menyebut batas ini justru menaikkan kredibilitas, bukan menurunkannya.

Kebocoran, kontaminasi, dan interaksi antar eksperimen

Kebocoran penugasan

Bentuk kebocoran yang paling sering di produksi:

- | | |
|-----------------------|---|
| ■ Lintas perangkat | pengguna login di HP (treatment) dan laptop (kontrol) → pengalaman campuran |
| ■ Cookie terhapus | pengguna diacak ulang, bisa pindah varian |
| ■ Sesi anonim → login | ID berubah di tengah perjalanan |
| ■ Cache bersama | halaman treatment tersimpan, disajikan ke pengguna kontrol |
| ■ Berbagi tautan/akun | satu rumah tangga, satu akun bersama |
| ■ Dukungan pelanggan | agen CS memberi tahu fitur yang tidak dimiliki pengguna kontrol |

Kebocoran hampir selalu **mengecilkan** efek yang terukur (dilusi), karena sebagian kelompok kontrol sebenarnya menerima treatment. Konsekuensi praktisnya: hasil positif yang terukur adalah *batas bawah*; hasil nol menjadi ambigu — bisa berarti tidak ada efek, bisa berarti kebocoran terlalu besar.

Interaksi antar eksperimen

Perusahaan besar menjalankan puluhan eksperimen bersamaan. Pertanyaan yang selalu muncul: apakah mereka saling merusak?

- **Untuk sebagian besar pasangan tes, tidak.** Randomisasi independen membuat pengguna tes A tersebar merata di kedua kelompok tes B; efek tes lain menjadi kebisingan tambahan, bukan bias.
- **Kecuali bila keduanya menyentuh elemen yang sama.** Dua tes yang mengubah halaman checkout dapat menghasilkan kombinasi yang rusak secara visual atau fungsional — dan efek interaksinya nyata.
- **Penanganan praktis:** gunakan konsep "layer" — tes yang menyentuh area sama ditempatkan pada layer yang sama dan tidak boleh tumpang tindih; tes di layer berbeda boleh berjalan bersamaan. Untuk tes berisiko tinggi, jalankan pemeriksaan interaksi: bandingkan efek tes A pada pengguna yang berada di kontrol tes B versus treatment tes B.

Protokol QA sebelum dan selama eksperimen

SEBELUM PELUNCURAN

- └ Verifikasi manual kedua varian pada: desktop, mobile web, aplikasi Android/iOS, browser lama, koneksi lambat
- └ Verifikasi event tracking menyala di kedua varian (jumlah event per pengguna sebanding)
- └ Verifikasi syarat kelayakan: siapa yang seharusnya masuk
- └ Jalankan A/A 24 jam pada 5% traffic
- └ Konfirmasi tidak ada tes lain pada layer yang sama

HARI 1-2 (fase ramp 1%)

- └ SRM ✓ └ error rate ✓ └ latency ✓
- └ JANGAN melihat OEC — belum ada informasi, hanya godaan

SETIAP HARI SELAMA TES

- └ SRM (agregat + per segmen)
- └ Guardrail teknis: error, latency, crash
- └ Kelengkapan data: apakah semua hari tercatat
- └ Peristiwa eksternal: rilis lain, kampanye, insiden

AKHIR TES

- └ SRM final ✓
- └ Keseimbangan kovariat pra-eksperimen ✓
- └ Lift per minggu (deteksi novelty/primacy)

- └ Konsistensi antar platform
- └ Baru kemudian: analisis OEC (Bab 5)

✓ BEST PRACTICE — Pemisahan peran pemantauan dan analisis

Selama tes berjalan, yang dipantau adalah **kesehatan** (SRM, error, latency), bukan **hasil** (OEC). Pemisahan ini bukan formalitas: melihat OEC setiap hari menciptakan tekanan untuk berhenti pada momen yang menguntungkan — masalah peeking yang dibedah tuntas di Bab 5. Banyak platform eksperimen menyembunyikan OEC sampai durasi rencana tercapai, dan itu adalah desain yang bijak.

Membaca grafik kumulatif tanpa tertipu

Grafik lift kumulatif memiliki bentuk khas yang menipu: sangat bergejolak di awal lalu menyempit. Gejala awal adalah murni kebisingan sampel kecil, bukan "efek yang sedang stabil".



Interpretasi yang BENAR: lebar pita ketidakpastian menyempit dengan $\sqrt{n}$. Nilai di hari ke-3 bukan "efek awal yang besar" — ia hanya titik dengan CI yang sangat lebar.

Yang HARUS ditambahkan ke grafik agar tidak menyesatkan:

- pita CI 95% (menyempit seiring waktu)
- garis MDE rencana
- garis vertikal pada tanggal analisis resmi

Checklist menjalankan eksperimen

- ✓ A/A test 24 jam dijalankan sebelum peluncuran, hasilnya bersih
- ✓ Kedua varian diverifikasi manual di seluruh platform dan kelas perangkat
- ✓ SRM diperiksa setiap hari, agregat dan tersegmentasi; ambang $p < 0,001$ = batal
- ✓ Keseimbangan kovariat pra-eksperimen diperiksa di akhir tes
- ✓ OEC tidak dilihat sebelum tanggal analisis resmi; hanya guardrail yang dipantau
- ✓ Lift dipetakan per minggu untuk mendeteksi novelty/primacy
- ✓ Pengguna dari fase ramp dikeluarkan dari analisis utama
- ✓ Tes lain pada layer yang sama dipastikan tidak tumpang tindih
- ✓ Peristiwa eksternal (rilis, kampanye, insiden) dicatat dalam experiment log
- ✓ Durasi kelipatan tujuh hari, di luar periode blackout

Ending Card — Bab 4

What you learned

SRM: perhitungan, ambang, tabel penyebab, dan mengapa tidak boleh dikoreksi dengan penimbangan ulang; A/A test dan pembacaan distribusi p-value; novelty versus primacy effect beserta tiga cara membedakannya dari efek nyata; musiman dan aturan kelipatan minggu; bentuk-bentuk kebocoran penugasan dan arah biasanya; interaksi antar eksperimen dan konsep layer; protokol QA lengkap; cara membaca grafik kumulatif.

Skills mastered

Diagnosis validitas eksperimen · pemantauan operasional · deteksi bias temporal · QA instrumentasi.

Real business value

Satu pemeriksaan SRM yang menangkap bug penugasan mencegah keputusan rilis berdasarkan data rusak. Dalam program yang menjalankan puluhan tes per tahun, disiplin ini adalah pembeda antara program eksperimen yang dipercaya direksi dan program yang perlahan diabaikan karena hasilnya tidak pernah terwujud.

Interview readiness

● INTERVIEW QUESTIONS

1. "Kamu melihat rasio 50,4/49,6 pada tes dengan 1 juta pengguna. Apa yang kamu lakukan?" (Hitung χ^2 , kemungkinan besar p sangat kecil → batalkan, lalu diagnosis tersegmentasi. Jawaban yang menyebut "selisihnya kecil, lanjutkan" langsung gagal.)
2. "Lift 8% di minggu pertama, 2% di minggu ketiga. Angka mana yang kamu laporkan?" (Keduanya, dengan penjelasan novelty; estimasi keadaan tunak dari kohort baru dan holdout.)
3. "Bagaimana kamu tahu platform eksperimenmu bisa dipercaya?" (A/A berkelanjutan, distribusi p-value seragam, keseimbangan kovariat.)
4. "Dua tes berjalan bersamaan di halaman produk — masalah?" (Umumnya tidak bias, tetapi risiko interaksi bila menyentuh elemen sama; jelaskan konsep layer dan pemeriksaan interaksi.)
5. "Efek terukur nol. Sebutkan lima kemungkinan penjelasan selain 'fitur tidak berdampak'." (Underpowered, kebocoran/dilusi, instrumentasi rusak, metric tidak sensitif, efek terkonsentrasi pada segmen yang tenggelam di agregat, durasi terlalu pendek untuk efek yang butuh pembelajaran.)

Exercises

Exercise 4.1 (Beginner · 20 menit)

Objective: menghitung dan menafsirkan SRM

Hitung χ^2 dan p untuk: (a) 28.104 vs 27.896 (rencana 50/50); (b) 283.000 vs 277.000 (rencana 50/50); (c) 90.400 vs 9.600 (rencana 90/10). Tentukan putusan untuk masing-masing dan sebutkan satu langkah diagnosis pertama untuk kasus yang bermasalah.

Answer key 4.1

(a) total 56.000, expected 28.000 masing-masing. $\chi^2 = (104^2 + 104^2) / 28.000 = 21.632 / 28.000 = \mathbf{0,77}$; $p = \mathbf{0,379} \rightarrow$ bersih. (b) total 560.000, expected 280.000. $\chi^2 = (3.000^2 \times 2) / 280.000 = 18.000.000 / 280.000 = \mathbf{64,3}$; $p < \mathbf{0,000001} \rightarrow$ BATALKAN. (c) expected 90.000 dan 10.000. $\chi^2 = 400^2 / 90.000 + 400^2 / 10.000 = 1,78 + 16,0 = \mathbf{17,8}$; $p = \mathbf{0,000025} \rightarrow$ di bawah 0,001 $\rightarrow$ BATALKAN; perhatikan bahwa kelompok kecil mendominasi statistik, sehingga tes alokasi tidak seimbang lebih sensitif terhadap kehilangan pada lengan kecil. Diagnosis pertama untuk (b) dan (c): pecah rasio per hari dan per jenis perangkat — SRM yang muncul mulai tanggal tertentu menunjuk ke rilis kode; yang terkonsentrasi pada satu perangkat menunjuk ke kegagalan render varian.

Exercise 4.2 (Intermediate · 40 menit)

Objective: membedakan novelty dari efek nyata

EXP-052 (checkout satu halaman) berjalan 4 minggu. Lift conversion per minggu: +6,2%, +4,1%, +3,3%, +3,2%. Data tambahan: pada pengguna *baru* (belum pernah melihat checkout lama) lift per minggu: +3,4%, +3,1%, +3,3%, +3,0%.

(a) Apa yang terjadi? (b) Angka mana yang dipakai untuk proyeksi bisnis? (c) Rancang satu pemeriksaan tambahan yang akan menguatkan kesimpulanmu. (d) Bagaimana kamu menjelaskan ini kepada VP yang sudah terlanjur mengumumkan "+6%" ke direksi?

Answer key 4.2

(a) Pola klasik **novelty effect pada pengguna lama**: mereka bereaksi terhadap perubahan itu sendiri, lalu kembali ke perilaku dasar. Pengguna baru tidak memiliki pembanding, sehingga lift mereka stabil di $\pm 3,2\%$ sejak awal — itulah efek keadaan tunak. (b) Gunakan $\pm 3,2\%$, konsisten antara pengguna baru dan minggu terakhir keseluruhan. (c) Pemeriksaan penguat: **analisis kohort masuk** — bandingkan pengguna lama yang pertama terpapar di minggu 3; jika mereka juga menunjukkan lonjakan awal lalu meluruh, mekanisme novelty terkonfirmasi. Tambahan: holdout 2% selama 6 bulan. (d) Penyampaian: "Angka +6% benar untuk minggu pertama dan mencerminkan reaksi terhadap perubahan. Estimasi yang akan bertahan adalah +3,2%, yang saya peroleh dari dua sumber independen — pengguna baru dan minggu terakhir. Nilai tahunannya tetap Rp X miliar. Saya sarankan kita melaporkan +3,2% dengan holdout yang akan mengonfirmasinya dalam 6 bulan." Kuncinya: tidak menyalahkan siapa pun, memberi angka pengganti yang didukung dua sumber, dan menyediakan mekanisme verifikasi.

Exercise 4.3 (Advanced · 60 menit)

Objective: diagnosis kasus kompleks

Sebuah tes menunjukkan: SRM $p = 0,4$ (bersih pada agregat); lift OEC +5,2% ($p = 0,001$); tetapi lift pada pengguna Android +12%, iOS +0,3%, desktop -1,1%. Jumlah event per pengguna di Android treatment 18% lebih tinggi dari Android kontrol. Latency p95 Android treatment +260 ms.

Susun daftar hipotesis diagnosis berurutan dari yang paling mungkin, tentukan pemeriksaan untuk masing-masing, dan tuliskan rekomendasi akhirmu.

Answer key 4.3

Hipotesis 1 (paling mungkin): masalah instrumentasi di Android. Kenaikan 18% event per pengguna pada satu platform adalah tanda duplikasi event atau penambahan event baru yang ikut terhitung ke dalam metric. Jika OEC dihitung dari event yang terduplikasi, lift +12% adalah artefak. *Pemeriksaan:* bandingkan jumlah event per jenis pada kedua varian; rekonsiliasi dengan data transaksi backend (sumber kebenaran yang tidak melewati SDK klien).

Hipotesis 2: masalah performa yang menutupi efek positif di platform lain. Latency +260 ms bertentangan dengan lift positif — kombinasi ini mencurigakan karena latency yang lebih tinggi biasanya menurunkan konversi. *Pemeriksaan:* segmentasi lift per bucket latency.

Hipotesis 3: heterogenitas nyata. Mungkin saja fitur memang hanya berguna di Android. *Pemeriksaan:* apakah metric mekanisme (drop-off per langkah) juga hanya membaik di Android? Efek nyata harus disertai perbaikan mekanisme, bukan hanya outcome.

Rekomendasi: jangan merilis. Rekonsiliasi metric dengan data backend terlebih dahulu; SRM yang bersih tidak menjamin instrumentasi yang benar — keduanya memeriksa hal berbeda. Ini poin utama latihan: *agregat yang sehat dapat menyembunyikan kerusakan yang terkonsentrasi*, dan pemeriksaan per platform wajib dilakukan sebelum keputusan.

Exercise 4.4 (Production Challenge · 4 jam)

Objective: membangun dashboard kesehatan eksperimen

Rancang (dan bangun bila datanya tersedia) dashboard pemantauan kesehatan eksperimen dengan panel: rasio penugasan harian + p-value SRM; SRM tersegmentasi (perangkat, region, sumber traffic); guardrail teknis (error, latency p50/p95, crash); kelengkapan event per varian; lift per minggu dengan pita CI; dan daftar peristiwa eksternal. Sertakan aturan alarm tertulis: kondisi apa yang memicu pembatalan otomatis, dan siapa yang diberi tahu.

Answer key 4.4 — rubrik

Dashboard yang kuat: **tidak menampilkan OEC pada halaman pemantauan** (pemisahan peran); menampilkan p-value SRM sebagai angka, bukan hanya rasio; memiliki panel tersegmentasi yang bisa langsung menunjuk penyebab; dan memuat aturan alarm dalam teks di dashboard itu sendiri sehingga tidak bergantung pada ingatan orang. Kesalahan umum: membuat dashboard yang indah tetapi menampilkan lift OEC di posisi paling atas — desain yang secara aktif mendorong peeking.

Portfolio idea

★ PORTFOLIO TIP

Tulis studi kasus "eksperimen yang saya batalkan" berdasarkan Exercise 4.3: gejala, hipotesis, pemeriksaan, dan keputusan. Narasi tentang tes yang dibatalkan menunjukkan integritas analitis jauh lebih kuat daripada narasi tentang tes yang menang — dan hampir tidak ada kandidat yang membawanya.

Further reading

Fabijan et al., "Diagnosing Sample Ratio Mismatch in Online Controlled Experiments" (KDD) · Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* (Bab 3: twyman's law; Bab 21: SRM) · Publikasi teknik Netflix dan Booking.com tentang experiment health monitoring.

Next chapter

Bab 5 — data sudah bersih, tes sudah selesai. Sekarang bagian yang paling sering salah: membaca hasilnya. p-value yang disalahpahami, peeking, multiple testing, hasil flat yang bermakna, dan cara menulis memo keputusan yang dipercaya.

Bab 5 — Membaca Hasil & Keputusan Ship/No-Ship

Angka sudah keluar. Sekarang bagian yang paling sering merusak keputusan: menafsirkannya.

Learning objectives	Menafsirkan p-value dan confidence interval dengan benar dalam konteks keputusan; menjelaskan dan menghindari peeking; menangani multiple testing pada banyak metric dan banyak segmen; menafsirkan hasil flat secara berguna; menghitung nilai prediktif positif sebuah kemenangan; menerapkan aturan keputusan ship/no-ship; menulis memo hasil eksperimen yang dipercaya
Prerequisites	Bab 3 (power, MDE); Vol 2 Bab 4-5 (CI, uji hipotesis, p-value)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	Interpretasi CI, kontrol peeking, koreksi multiple testing, decision rules, experiment readout writing
Business domain	E-commerce — hasil EXP-052 dan EXP-041 dibaca sampai keputusan

Aturan pertama: CI lebih informatif daripada p-value

p-value menjawab satu pertanyaan sempit: seberapa mengejutkan data ini seandainya tidak ada efek sama sekali. Confidence interval menjawab pertanyaan yang sebenarnya dibutuhkan keputusan: *seberapa besar efeknya, dan seberapa yakin kita tentang besarnya?*

EXP-052 — checkout satu halaman, hasil akhir 14 hari

```
Kontrol    : 17.920 order dari 560.000 pengunjung = 3,2000%
Treatment  : 18.480 order dari 560.000 pengunjung = 3,3000%


Selisih absolut : +0,1000 pp
Lift relatif    : +3,13%
z              : 2,984
p-value        : 0,0028
CI 95% absolut : [+0,0343 pp ; +0,1657 pp]
CI 95% relatif  : [+1,07% ; +5,18%]
```

Kalimat yang benar untuk memo: "Checkout satu halaman menaikkan conversion sebesar 3,1%, dengan rentang yang konsisten dengan data antara 1,1% dan 5,2%." Kalimat yang salah dan sering dipakai: "kami 95% yakin efeknya 3,1%" — kepercayaan melekat pada prosedur pembentukan interval, bukan pada titik estimasi.

✓ BEST PRACTICE — Baca batas bawah CI, bukan titik tengahnya

Untuk keputusan bisnis, angka yang paling berguna adalah **batas bawah interval**. Jika proyek tetap menguntungkan pada +1,07% (batas bawah EXP-052), keputusan rilis aman tanpa bergantung pada keberuntungan. Kebiasaan ini sekaligus mengoreksi winner's curse (Bab 3) secara otomatis: proyeksi bisnis dibangun di atas skenario konservatif, sehingga hasil aktual cenderung melampaui janji, bukan mengecewakan.

Empat pola hasil dan artinya



Pola	Kesimpulan yang benar	Keputusan
A	Efek positif, besarnya melampaui ambang bisnis	Rilis; pasang holdout untuk verifikasi jangka panjang
B	Efek positif, tetapi mungkin lebih kecil dari ambang kelayakan	Rilis bila biaya pemeliharaan rendah; jika tinggi, hitung ulang kelayakan pada batas bawah CI
C	Tidak ada informasi berguna — tes underpowered untuk pertanyaan ini	Jangan simpulkan "tidak berdampak". Perpanjang sesuai rencana baru, tingkatkan presisi (Bab 6), atau batalkan program
D	Efek yang bernilai bisnis dapat disingkirkan — ini temuan nyata	Jangan rilis; catat sebagai pengetahuan; hentikan investasi lanjutan di arah ini

Perbedaan antara C dan D adalah salah satu keterampilan interpretasi terpenting dalam bab ini. Keduanya "tidak signifikan", tetapi C berarti tidak tahu dan D berarti tahu bahwa efeknya kecil. Membedakannya hanya membutuhkan satu hal: membandingkan lebar CI dengan MDE yang direncanakan.

Peeking: mengapa melihat hasil setiap hari merusak tes

Uji signifikansi klasik dirancang untuk *satu* pemeriksaan pada ukuran sampel yang ditetapkan di muka. Setiap pemeriksaan tambahan adalah kesempatan tambahan bagi kebisingan untuk melewati ambang.

Tingkat false positive aktual bila tes dihentikan pada pemeriksaan pertama yang menunjukkan $p < 0,05$ (simulasi 40.000 eksperimen di bawah H_0 sejati):

1 kali periksa → 5,0% ← yang dijanjikan α
 2 kali periksa → 8,3%
 5 kali periksa → 14,3%
 10 kali periksa → 19,2%
 20 kali periksa → 24,5%
 50 kali periksa → 31,7%

Pemantauan berkelanjutan tanpa koreksi → mendekati 100% bila tes dibiarkan berjalan cukup lama.

Konsekuensinya bukan teoretis. Tim yang membuka dashboard setiap pagi dan berhenti ketika hijau sedang menjalankan prosedur dengan false positive sekitar 20-25%, bukan 5%. Satu dari empat "kemenangan" mereka adalah kebisingan.

✗ COMMON MISTAKE — "Signifikan lebih cepat, jadi kami hentikan"

Gejala: tes direncanakan 21 hari; di hari ke-6 $p=0,03$; tes dihentikan dan fitur dirilis. Enam bulan kemudian holdout menunjukkan efeknya nol.

Mengapa terjadi: tekanan kecepatan bertemu ketidaktahuan tentang inflasi α ; berhenti pada momen menguntungkan terasa efisien, bukan curang.

Perbaikan: tetapkan durasi di muka dan patuhi; atau gunakan metode sequential yang memang dirancang untuk pemantauan berkelanjutan (di bawah).

Cara senior menghindarinya: menyembunyikan OEC dari dashboard sampai tanggal analisis, dan menuliskan tanggal itu di tiket sehingga penghentian dini menjadi keputusan yang terlihat, bukan kebiasaan diam-diam.

Tiga cara sah untuk memantau hasil selama tes berjalan

Pendekatan	Cara kerja	Biaya
Fixed horizon (default)	Tetapkan n dan durasi di muka; lihat hasil satu kali di akhir	Tidak ada biaya statistik; biaya organisasi berupa disiplin
Group sequential (batas O'Brien-Fleming / Pocock)	Tetapkan 3-5 titik pemeriksaan terjadwal dengan ambang yang lebih ketat di awal dan melonggar di akhir	Kehilangan power kecil ($\pm 2-5\%$); memungkinkan penghentian dini untuk hasil yang sangat kuat atau sangat buruk
Always-valid inference (mixture sequential probability ratio test, confidence sequences)	Interval kepercayaan yang valid pada setiap titik waktu; boleh dilihat kapan saja	Interval lebih lebar; membutuhkan $\pm 20-40\%$ lebih banyak sampel untuk MDE yang sama

■ TECHNICAL NOTE — memilih di antara ketiganya

Fixed horizon adalah pilihan yang benar untuk sebagian besar tes produk: durasinya pendek, dan biaya menunggu dua minggu rendah. Group sequential bernilai ketika ada **risiko nyata** yang membenarkan penghentian dini — perubahan yang bisa merugikan pengguna. Always-valid inference cocok untuk platform eksperimen yang menyediakan dashboard untuk banyak tim non-statistik, karena ia membuat "melihat kapan saja" menjadi aman secara struktural. Yang tidak sah hanyalah satu hal: memakai ambang fixed-horizon sambil berperilaku sequential.

Multiple testing: masalah yang lebih besar dari peeking

Sebuah eksperimen jarang memiliki satu metric. Laporan tipikal memuat OEC, 5 metric pendukung, 8 guardrail, dan pemecahan per 6 segmen — dengan mudah 40-100 uji statistik pada satu tes.

Peluang minimal satu false positive pada $\alpha=0,05$
(metric independen; korelasi antar metric mengurangi angka ini tetapi tidak menghilangkan masalahnya):

1 metric → 5,0%
5 metric → 22,6%
10 metric → 40,1%

20 metric → 64,2%
 50 metric → 92,3%
 100 metric → 99,4%

Inilah dasar statistik dari fenomena yang dikenal semua analyst: *selalu ada segmen yang menang*. Jika sebuah tes dipecah ke cukup banyak segmen, salah satunya pasti menunjukkan hasil signifikan, dan otak manusia sangat pandai membuat cerita untuk segmen itu.

Strategi penanganan, dari yang paling praktis

- **Hierarki metric (paling penting).** Hanya OEC yang menentukan keputusan; metric pendukung bersifat penjelas; guardrail memakai ambang praktis, bukan uji signifikansi. Dengan struktur ini, jumlah uji yang menentukan keputusan tetap satu — masalah multiple testing sebagian besar lenyap secara desain, bukan lewat koreksi.
- **Pra-registrasi segmen.** Segmen yang direncanakan sebelum data dilihat diperlakukan sebagai temuan; segmen yang ditemukan setelahnya diperlakukan sebagai hipotesis untuk tes berikutnya. Perbedaan status ini ditulis di memo.
- **Koreksi formal ketika banyak metric benar-benar menentukan.** Bonferroni (α/m) terlalu konservatif untuk metric yang berkorelasi; **Benjamini-Hochberg** (kontrol false discovery rate) adalah pilihan standar untuk skrining banyak metric.
- **Replikasi.** Obat terkuat dan paling meyakinkan: jalankan ulang tes pada periode atau populasi berbeda. Temuan yang bertahan dua kali jauh lebih bernilai daripada temuan yang dikoreksi secara matematis.

⚠ WARNING — Analisis segmen adalah tempat lahirnya sebagian besar klaim palsu

"Fitur ini tidak menang secara keseluruhan, tetapi menang kuat pada pengguna Android baru di Jawa Timur" adalah kalimat yang hampir selalu salah. Dua pertahanan yang wajib: (1) sebutkan berapa banyak segmen yang diperiksa — angka ini mengubah seluruh interpretasi; (2) perlakukan temuan segmen sebagai *hipotesis* yang memerlukan tes konfirmasi tersendiri, dan tulis kalimat itu secara eksplisit di memo.

Seberapa besar peluang sebuah kemenangan benar-benar nyata

Pertanyaan yang jarang ditanyakan tetapi paling menentukan kepercayaan pada program eksperimen. Jawabannya bergantung pada tiga hal: α , power, dan *proporsi ide yang benar-benar bekerja*.

$$P(\text{efek nyata} \mid \text{menang}) = \frac{\text{prior} \times \text{power}}{\text{prior} \times \text{power} + (1 - \text{prior}) \times \alpha}$$

Proporsi ide yang benar-benar bekerja	Power 30%	Power 50%	Power 80%
10% (organisasi yang menguji ide spekulatif)	40,0%	52,6%	64,0%
20%	60,0%	71,4%	80,0%
33% (program matang, ide tersaring)	75,0%	83,3%	88,9%

Baca baris pertama dengan saksama: pada organisasi yang menguji banyak ide spekulatif dengan tes underpowered, **60% dari kemenangan yang dirayakan adalah kebisingan**. Ini menjelaskan secara kuantitatif mengapa lift yang diklaim tidak pernah terlihat di metric perusahaan — dan mengapa dua investasi berikut membayar dirinya sendiri: menaikkan power, dan menyaring ide sebelum diuji.

Hasil flat: kapan ia berharga

Sekitar sepertiga eksperimen di program matang menghasilkan efek yang tidak dapat dibedakan dari nol. Ini bukan kegagalan; ia informasi yang mahal untuk diperoleh dengan cara lain.

Nilai dari hasil flat	Tindakan yang mengikutinya
Menghentikan investasi pada arah yang tidak berbuah	Bebaskan sumber daya rekayasa ke arah lain; catat di knowledge base agar tidak diulang dua tahun lagi
Membenarkan penyederhanaan	Jika fitur mahal tidak berdampak, hapus — pemeliharaan yang berkurang adalah keuntungan nyata
Mengoreksi model mental organisasi	Keyakinan yang runtuh oleh data adalah aset; dokumentasikan keyakinan sebelum dan sesudah
Memvalidasi perubahan berbiaya rendah yang tidak merusak	Perubahan netral yang menyederhanakan kode tetap layak dirilis

Syarat agar hasil flat berharga hanya satu: **tes harus cukup powered**. Hasil flat dari tes underpowered (pola C di atas) tidak memberi informasi apa pun, dan menuliskannya sebagai "tidak berdampak" adalah kesalahan yang merugikan — karena ia menutup arah yang mungkin benar.

Kasus lengkap: EXP-041 dan pelajaran tentang OEC

Kasus ini adalah alasan utama Bab 2 bersikeras bahwa OEC harus berbasis margin. Hasilnya bertentangan antar metric, dan hanya kerangka keputusan yang ditulis di muka yang menyelamatkan keputusannya.

EXP-041 — ambang gratis ongkir Rp 150rb → Rp 199rb, 21 hari, 560.000 pengunjung per kelompok

METRIC	KONTROL	TREATMENT	SELISIH
Conversion visit→pay	3,200%	3,150%	-1,56% rel
$z = -1,509 \cdot p = 0,131 \cdot \text{CI } 95\% \text{ rel} = [-3,59\% ; +0,47\%]$ → TIDAK signifikan; CI mencakup nol			
AOV	Rp 312.000	Rp 327.000	+4,81%
Subsidi ongkir per order	Rp 14.200	Rp 10.900	-23,2%
CM per order	Rp 69.700	Rp 77.500	+11,2%
OEC — CM per pengunjung	Rp 2.230	Rp 2.441	+9,45%
→ signifikan; dampak tahunan pada traffic online: Rp 211 × 28,8 juta kunjungan = Rp 6,07 miliar CM/tahun			
GUARDRAIL			
SRM $p = 0,62$			✓ aman
Refund	2,10%	2,14%	✓ +0,04 pp
Kontak CS / 1.000 order	18,2	18,9	✓ +3,8%
Revenue kategori grocery	-1,2%		✓ di atas ambang -2%
NPS in-app	-1 poin		✓ di atas ambang -3

◆ BUSINESS INSIGHT — keputusan yang akan salah bila OEC-nya conversion

Andaikan OEC-nya conversion rate, hasilnya "tidak signifikan dan cenderung negatif" — perubahan dibatalkan, dan Rp 6,07 miliar contribution margin per tahun tidak pernah terwujud. Andaikan OEC-nya revenue per pengunjung, keputusan kebetulan sama tetapi alasannya dangkal, karena revenue tidak menangkap penurunan subsidi ongkir yang justru menjadi separuh nilai perubahan ini.

Yang menyelamatkan keputusan bukan kecanggihan statistik, melainkan **satu keputusan desain yang dibuat tiga minggu sebelumnya**: menetapkan contribution margin per pengunjung sebagai OEC. Inilah bukti konkret bahwa nilai terbesar seorang analyst sering dihasilkan sebelum data pertama masuk.

Catatan interpretasi yang harus masuk memo: conversion turun 1,56% relatif dengan CI $[-3,59\%; +0,47\%]$ *tidak berarti tidak ada penurunan*. Rentangnya konsisten dengan penurunan sampai 3,6%. Yang bisa disimpulkan adalah bahwa penurunan sebesar apa pun dalam rentang itu tetap dikalahkan oleh kenaikan margin per order — dan itu terlihat langsung pada OEC yang menggabungkan keduanya.

Aturan keputusan dan template memo

```
Guardrail dilanggar? —YA→ BATALKAN (apa pun hasil OEC)
  |TIDAK
  ▼
SRM / validitas bersih? —TIDAK→ BATALKAN, jalankan ulang
  |YA
  ▼
CI OEC seluruhnya > 0?
├─ YA → Batas bawah > ambang kelayakan bisnis?
│   ├── YA ► RILIS 100% + holdout
│   └── TIDAK ► Rilis bila biaya pemeliharaan rendah;
│               bila tinggi → tolak dengan alasan ekonomi
├─ CI mencakup 0 tapi TIDAK mencakup MDE ► NETRAL TERVERIFIKASI
│   ► jangan rilis; catat pengetahuan; hentikan arah ini
└─ CI mencakup 0 DAN MDE ► TIDAK KONKLUSIF
    ► jangan simpulkan apa pun; putuskan: tambah presisi
    (Bab 6), perpanjang dengan rencana baru, atau hentikan
```

Template memo hasil eksperimen — satu halaman, urutan tetap

EXP-041 · Ambang gratis ongkir 150rb → 199rb
KEPUTUSAN : RILIS 100%, holdout 2% selama 6 bulan
DAMPAK : CM per pengunjung +9,45% (CI 95%: +6,1% s/d +12,8%)
 ≈ Rp 6,07 miliar CM/tahun pada titik estimasi;
 Rp 3,9 miliar pada batas bawah CI ← angka untuk rencana
MEKANISME : 41% keranjang di rentang 150–199rb naik ke ≥199rb;
 subsidi ongkir per order turun 23,2%.
 Mekanisme yang dihipotesiskan TERKONFIRMASI.
TRADE-OFF : conversion -1,56% (CI -3,59% s/d +0,47%, tidak
 signifikan). Penurunan sampai 3,6% konsisten dengan
 data dan tetap dikalahkan kenaikan margin.
GUARDRAIL : seluruhnya aman; rincian terlampir.
VALIDITAS : SRM $p=0,62$; kovariat pra-eksperimen seimbang;
 lift stabil antar minggu (tidak ada novelty).
BATAS : diukur pada periode perdagangan normal; dampak pada
 Harbolnas belum diketahui. Efek jangka panjang pada
 retensi belum terukur — holdout akan menjawabnya.
TINDAK LANJUT: (1) uji ambang Rp 175rb sebagai titik tengah;
 (2) analisis heterogenitas per kategori (Bab 6);
 (3) baca ulang holdout pada bulan ke-3 dan ke-6.
PRA-REGISTRASI: desain 12 Mei 2026; analisis sesuai rencana,
 tanpa segmen tambahan yang tidak direncanakan.

► **EXECUTIVE PERSPECTIVE — mengapa baris "BATAS" menaikkan kepercayaan**

Analyst pemula menghapus baris keterbatasan karena takut melemahkan rekomendasi. Efeknya justru sebaliknya. Eksekutif berpengalaman tahu setiap analisis punya batas; laporan yang tidak menyebutkannya membuat mereka bertanya-tanya apa lagi yang tidak diberitahukan. Menyebut batas secara spesifik — bukan disclaimer umum — adalah sinyal kompetensi yang paling murah dan paling efektif.

Checklist membaca hasil

- ✓ Validitas diperiksa lebih dulu: SRM, keseimbangan kovariat, kelengkapan data
- ✓ CI dilaporkan bersama titik estimasi; keputusan bisnis dihitung pada batas bawah
- ✓ Hasil diklasifikasikan ke salah satu dari empat pola; C dan D dibedakan secara eksplisit
- ✓ Tes tidak dihentikan lebih awal kecuali metode sequential dipakai sejak desain
- ✓ Jumlah metric dan segmen yang diuji disebutkan; temuan tak terencana ditandai sebagai hipotesis
- ✓ Lift diperiksa per minggu untuk mendeteksi peluruhan
- ✓ Mekanisme yang dihipotesiskan dikonfirmasi lewat metric pendukung, bukan diasumsikan
- ✓ Memo memuat keputusan, dampak rupiah, mekanisme, trade-off, guardrail, batas, dan tindak lanjut
- ✓ Holdout dipasang untuk semua kemenangan yang bernilai material

Ending Card — Bab 5

What you learned

Keunggulan CI atas p-value untuk keputusan; empat pola hasil dan perbedaan kritis antara tidak konklusif dan netral terverifikasi; inflasi false positive akibat peeking beserta angkanya; tiga pendekatan pemantauan yang sah; skala masalah multiple testing dan strategi penanganannya; perhitungan peluang sebuah kemenangan benar-benar nyata; nilai hasil flat; kasus EXP-041 sebagai bukti pentingnya OEC berbasis margin; pohon keputusan ship/no-ship dan template memo.

Skills mastered

Interpretasi statistik untuk keputusan · pengendalian peeking dan multiple testing · penulisan experiment readout · penerjemahan hasil menjadi rupiah.

Real business value

Memo hasil eksperimen adalah artefak yang dibaca eksekutif dan menjadi dasar keputusan bernilai miliaran. Kemampuan menulisnya dengan struktur yang jujur dan lengkap adalah salah satu keterampilan dengan pengembalian tertinggi dalam karier analytics.

Interview readiness

● INTERVIEW QUESTIONS

1. "Jelaskan p-value kepada VP Marketing." (Peluang melihat data seekstrem ini seandainya tidak ada efek. Lanjutkan segera ke CI karena itu yang dibutuhkan keputusan.)
2. "Tes tidak signifikan. Apakah fiturnya tidak berdampak?" (Bandingkan lebar CI dengan MDE; bedakan pola C dari D. Ini pertanyaan penyaring favorit.)
3. "Mengapa berhenti saat signifikan itu salah?" (Inflasi α ; sebutkan angka: 10 kali intip $\rightarrow$ 19%.)
4. "Kami menguji 30 metric dan 3 signifikan. Kesimpulan?" (Ekspektasi false positive $\pm 1,5$ pada $\alpha=0,05$; periksa apakah OEC termasuk; perlakukan sisanya sebagai hipotesis; pertimbangkan Benjamini-Hochberg.)
5. "Conversion turun tapi kamu merekomendasikan rilis — jelaskan." (Kasus EXP-041: OEC berbasis margin; trade-off dikuantifikasi; guardrail aman.)
6. "Berapa peluang kemenangan kalian benar-benar nyata?" (Rumus PPV; tunjukkan bahwa jawabannya bergantung pada power dan kualitas ide, bukan hanya pada p-value.)

Exercises

Exercise 5.1 (Beginner · 25 menit)

Objective: klasifikasi pola hasil

MDE rencana +3% relatif. Klasifikasikan tiap hasil ke pola A/B/C/D dan tulis satu kalimat kesimpulan yang benar:

(a) lift +5,2%, CI [+3,4%; +7,0%] · (b) lift +1,8%, CI [+0,2%; +3,4%] · (c) lift +1,1%, CI [-4,2%; +6,4%]
· (d) lift +0,3%, CI [-0,9%; +1,5%] · (e) lift -4,0%, CI [-6,1%; -1,9%].

Answer key 5.1

- (a) **A** — menang jelas; seluruh CI di atas MDE. "Efeknya positif dan melampaui ambang kelayakan; rilis."
(b) **B** — menang tipis; CI mencakup MDE. "Efeknya positif tetapi mungkin di bawah ambang kelayakan; keputusan rilis bergantung pada biaya pemeliharaan, dihitung pada batas bawah +0,2%."
(c) **C** — tidak konklusif; CI mencakup 0 dan MDE, lebarnya 10,6 pp. "Tes ini tidak cukup presisi untuk menjawab pertanyaannya; tidak ada kesimpulan yang bisa ditarik."
(d) **D** — netral terverifikasi; CI sempit, tidak mencakup +3%. "Efek sebesar ambang kelayakan dapat disingkirkan; hentikan investasi di arah ini." Ini temuan bernilai.
(e) **Kalah jelas** — seluruh CI negatif. "Perubahan merugikan; batalkan dan selidiki mekanismenya, karena kerugian yang terukur juga merupakan pengetahuan."

Exercise 5.2 (Intermediate · 45 menit)

Objective: multiple testing dan analisis segmen

Sebuah tes tidak signifikan pada OEC (lift +0,4%, $p=0,52$). Tim memecah hasil ke 24 segmen; tiga segmen signifikan pada $\alpha=0,05$: pengguna iOS baru (+7,1%, $p=0,012$), pengguna di Sumatera (+9,3%, $p=0,008$), pengguna dengan AOV di kuartil teratas (+5,8%, $p=0,041$).

- (a) Berapa banyak segmen signifikan yang diharapkan muncul secara kebetulan? (b) Terapkan Benjamini-Hochberg pada ketiga p-value tersebut dengan $m=24$ dan $FDR=0,10$ — mana yang bertahan? (c) Tulis paragraf memo yang jujur tentang temuan ini. (d) Apa langkah berikutnya yang kamu rekomendasikan?

Answer key 5.2

- (a) $24 \times 0,05 = 1,2$ segmen diharapkan signifikan secara kebetulan. Menemukan 3 sedikit di atas ekspektasi tetapi sepenuhnya konsisten dengan kebetulan (dan segmen saling berkorelasi, sehingga variasinya lebih besar).
(b) BH: urutkan p menaik $\rightarrow 0,008$ (rank 1), $0,012$ (rank 2), $0,041$ (rank 3). Ambang BH = $(i/m) \times FDR$: rank 1 $\rightarrow (1/24) \times 0,10 = 0,00417$; rank 2 $\rightarrow 0,00833$; rank 3 $\rightarrow 0,0125$. Bandingkan: $0,008 > 0,00417$ ✗; $0,012 > 0,00833$ ✗; $0,041 > 0,0125$ ✗. **Tidak satu pun bertahan.**
(c) Paragraf memo: "OEC tidak menunjukkan efek (+0,4%, $p=0,52$). Analisis eksploratif atas 24 segmen menemukan tiga segmen dengan $p < 0,05$; jumlah ini sesuai dengan ekspektasi kebetulan (1,2) dan tidak satu pun bertahan setelah koreksi false discovery rate. Segmen-segmen ini diperlakukan sebagai *hipotesis*, bukan temuan, dan tidak menjadi dasar keputusan."
(d) Jika salah satu segmen memiliki alasan mekanistik yang kuat (misalnya iOS baru karena alur onboarding memang berbeda), rancang **tes konfirmasi terarah** pada segmen itu dengan power memadai. Jika tidak ada alasan mekanistik, hentikan. Poin utama: temuan segmen bukan tidak berguna — ia sumber hipotesis yang murah, asalkan statusnya tidak dinaikkan menjadi kesimpulan.

Exercise 5.3 (Advanced · 75 menit)

Objective: keputusan dengan metric yang bertentangan

Tes "rekomendasi produk lebih agresif di halaman keranjang" 21 hari: conversion +2,1% ($p=0,004$); AOV +3,4% ($p=0,001$); revenue per pengunjung +5,6% ($p < 0,001$); **refund rate +0,42 pp** (ambang guardrail +0,30 pp); kontak CS +7,2% (ambang +5%); CM per pengunjung +3,1% ($p=0,02$) — tetapi CM dihitung *sebelum* memperhitungkan biaya retur.

Biaya penanganan retur TokoNusa: Rp 38.000 per retur. (a) Hitung ulang dampak CM per pengunjung setelah memasukkan biaya retur. (b) Apa keputusanmu dan mengapa? (c) Bagaimana kamu menanggapi manajer produk yang menunjuk revenue +5,6% sebagai bukti kemenangan? (d) Apa yang akan kamu ubah pada desain tes berikutnya?

Answer key 5.3

(a) Order per pengunjung treatment = $0,032 \times 1,021 = 0,032672$. Kenaikan refund 0,42 pp berarti tambahan retur = $0,0042 \times 0,032672 = 0,0001372$ retur per pengunjung; biaya = $0,0001372 \times \text{Rp } 38.000 = \text{Rp } 5,21 \text{ per pengunjung}$. CM per pengunjung kontrol Rp 2.230; treatment sebelum retur = $2.230 \times 1,031 = \text{Rp } 2.299$; setelah biaya retur = $2.299 - 5,21 \approx \text{Rp } 2.294 \rightarrow \text{lift } +2,87\%$, turun dari 3,1%. Efeknya nyata tetapi tidak menghapus keuntungan.

(b) **Keputusan: tidak dirilis dalam bentuk sekarang** — bukan karena ekonominya negatif, melainkan karena **dua guardrail dilanggar** dan aturan yang ditulis di muka mengatakan pelanggaran guardrail membatalkan. Ini adalah ujian integritas proses: menghormati aturan justru saat hasilnya menguntungkan. Rekomendasi konstruktif: bawa ke forum keputusan dengan angka lengkap dan minta keputusan sadar — pelanggaran guardrail dapat di-override secara eksplisit oleh pemilik keputusan, tetapi tidak boleh diabaikan diam-diam.

(c) Tanggapan: "Revenue +5,6% benar. Tetapi sebagian revenue itu kembali sebagai retur dengan biaya Rp 38.000 masing-masing, dan kenaikan kontak CS 7,2% adalah biaya operasional yang belum masuk hitungan. Setelah keduanya, keuntungan bersihnya +2,9%, bukan +5,6%. Yang lebih penting: kenaikan refund menandakan sebagian pembelian tidak diinginkan pengguna — itu risiko kepercayaan jangka panjang yang tidak muncul di tes tiga minggu."

(d) Desain berikutnya: (i) masukkan biaya retur ke dalam definisi OEC sejak awal; (ii) perpanjang jendela pengamatan hingga melewati periode retur 30 hari; (iii) uji versi yang kurang agresif untuk mencari titik optimal; (iv) tambahkan guardrail "tingkat pembelian berulang 60 hari" untuk menangkap kerusakan kepercayaan.

Exercise 5.4 (Production Challenge · 4 jam)

Objective: readout lengkap dari data mentah

Ambil dataset publik (Olist atau Online Retail II), buat simulasi eksperimen: bagi pelanggan secara acak, terapkan efek sintetis pada satu kelompok (misalnya +3% conversion pada 60% pengguna dan 0% pada sisanya), lalu tulis readout lengkap seolah-olah ini tes nyata: validitas, OEC dengan CI, metric pendukung, guardrail, analisis per minggu, dan memo keputusan. Tambahkan bagian "apa yang akan saya lakukan berbeda". Verifikasi bahwa analisismu berhasil memulihkan efek yang kamu tanamkan.

Answer key 5.4 — rubrik

Latihan ini memiliki sifat langka: **kebenaran diketahui**, sehingga analisis dapat dinilai secara objektif. Kriteria: efek yang dipulihkan berada dalam CI dari efek yang ditanamkan; unit analisis sama dengan unit randomisasi; heterogenitas yang ditanamkan (60%/40%) terdeteksi pada analisis segmen; memo tidak mengklaim presisi melebihi yang dimiliki data. Kesalahan yang paling sering muncul: menganalisis per order padahal randomisasi per pelanggan, yang akan menghasilkan CI terlalu sempit dan efek yang tampak lebih signifikan daripada seharusnya — persis kesalahan Bab 2 yang kini terlihat konsekuensinya.

Portfolio idea

★ PORTFOLIO TIP

Readout dari Exercise 5.4, ditulis dalam format memo satu halaman plus lampiran analisis, adalah salah satu artefak portfolio terkuat untuk peran product analyst dan data scientist. Tambahkan satu paragraf tentang keputusan yang *tidak* kamu rekomendasikan dan alasannya.

Further reading

Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* (Bab 17–19) · Johari et al., "Peeking at A/B Tests" (KDD 2017; dasar always-valid inference) · Benjamini & Hochberg (1995) tentang false discovery rate · Ioannidis, "Why Most Published Research Findings Are False" (dasar formal tabel PPV).

Next chapter

Bab 6 — cara mendapatkan jawaban yang sama dengan sampel jauh lebih kecil. Variance reduction (CUPED), stratifikasi, analisis heterogenitas yang sah, metric ratio, dan interferensi antar unit yang membuat seluruh perbandingan runtuh.

Bab 6 — Analisis Lanjutan: Presisi, Heterogenitas, Interferensi

Cara memperoleh jawaban yang sama dengan separuh sampel — dan cara mengenali situasi ketika seluruh perbandingan sebenarnya tidak sah.

Learning objectives	Menerapkan variance reduction (CUPED/ANCOVA) dan menghitung penghematannya; merancang stratifikasi dan post-stratification; menganalisis heterogenitas efek secara sah dan membedakannya dari data dredging; menangani metric rasio dengan unit analisis yang benar; menangani outlier dan metric berekor panjang; mengenali pelanggaran SUTVA dan memilih desain yang tahan interferensi
Prerequisites	Bab 3 (power), Bab 5 (interpretasi); Vol 2 Bab 6 (regresi)
Estimasi waktu	Baca 2,5 jam · Praktik 5 jam
Difficulty	● Advanced
Skills covered	CUPED, stratifikasi, CATE/heterogeneity analysis, delta method, winsorization, interference detection
Business domain	E-commerce & marketplace — termasuk kasus di mana A/B test biasa memberi jawaban yang salah arah

Bagian 1 — Variance reduction: uang yang tergeletak di lantai

Bab 3 menunjukkan bahwa n sebanding dengan σ^2 . Konsekuensi yang jarang dimanfaatkan: **mengurangi variance memberikan penghematan yang sama besarnya dengan menambah traffic** — tetapi gratis, karena datanya sudah ada.

Ide dasar CUPED

Sebagian besar variasi dalam metric hari ini sudah dapat diprediksi dari perilaku pengguna sebelum eksperimen dimulai. Pelanggan yang belanja Rp 5 juta bulan lalu kemungkinan besar belanja besar bulan ini juga — dan variasi itu tidak ada hubungannya dengan treatment.

$$Y_{\text{adjusted}} = Y - \theta \cdot (X - \bar{X})$$

Y = metric selama eksperimen

X = kovariat pra-eksperimen (metric yang sama, periode sebelum)

$\theta = \text{cov}(Y, X) / \text{var}(X)$ ← koefisien regresi Y pada X

$\bar{X}$ = rata-rata X pada seluruh peserta

Sifat penting:

- Estimasi efek tetap TIDAK BIAS (X tidak dipengaruhi treatment)
- Variance berkurang dengan faktor $(1 - \rho^2)$
- Ekuivalen dengan ANCOVA: regresi $Y \sim \text{treatment} + X$

⚠ WARNING — Kovariat harus dari periode SEBELUM eksperimen

Menggunakan variabel yang terjadi *selama* eksperimen sebagai kovariat menghancurkan validitas: jika treatment mempengaruhi kovariat itu, penyesuaian akan menghapus sebagian efek yang justru ingin diukur (ini adalah bentuk pengendalian atas mediator — bahaya yang dibahas formal di Bab 8). Aturan yang tidak boleh dilanggar: **kovariat harus terkunci pada tanggal sebelum pengguna masuk eksperimen.**

Berapa besar penghematannya

Korelasi ρ (pra vs selama)	Pengurangan variance	Sampel yang dibutuhkan	MDE relatif thd tanpa CUPED	Durasi setara dari 21 hari
0,3	9,0%	91,0%	95,4%	19,1 hari
0,5	25,0%	75,0%	86,6%	15,8 hari
0,6	36,0%	64,0%	80,0%	13,4 hari
0,7	49,0%	51,0%	71,4%	10,7 hari
0,8	64,0%	36,0%	60,0%	7,6 hari
0,9	81,0%	19,0%	43,6%	4,0 hari

Nilai ρ yang realistis bergantung pada metric dan unit:

- **Conversion per pengunjung anonim:** $\rho \approx 0,1-0,2$ — CUPED nyaris tidak membantu karena tidak ada riwayat.
- **Revenue per pelanggan terdaftar:** $\rho \approx 0,4-0,6$ — penghematan 16–36%.
- **Penjualan per toko, per bulan:** $\rho \approx 0,8-0,95$ — penghematan besar; inilah penyelamat eksperimen berunit kecil (Bab 3).
- **Metric penggunaan pada produk berlangganan:** $\rho \approx 0,7-0,9$.

◆ BUSINESS INSIGHT — nilai CUPED dalam mata uang program

Untuk TokoNusa dengan $\rho=0,6$ pada metric CM per pelanggan terdaftar: setiap tes membutuhkan 64% traffic-minggu. Program yang menjalankan 40 tes per tahun tiba-tiba dapat menjalankan 62 tes dengan sumber daya yang sama — kenaikan 56% pada kapasitas belajar organisasi, dari satu perubahan metodologis yang tidak membutuhkan satu pun engineer tambahan. Sedikit investasi analytics yang memberi pengembalian sebesar ini.

Varian dan perluasan

Teknik	Cara kerja	Kapan dipilih
CUPED klasik	Satu kovariat: metric yang sama pada periode sebelum	Default; sederhana dan mudah diaudit
ANCOVA / regresi	Regresi $Y \sim T + X_1 + X_2 + \dots$; koefisien T adalah efeknya	Beberapa kovariat; hasilnya setara CUPED tetapi lebih fleksibel
CUPAC / ML-based	Kovariat = prediksi Y dari model ML atas fitur pra-eksperimen	Ketika hubungan non-linear; hati-hati terhadap kebocoran data
Stratifikasi (blocking)	Acak di dalam blok yang homogen (wilayah $\times$ ukuran toko)	Saat randomisasi masih bisa dirancang; menghilangkan ketidakseimbangan sejak awal

Post-stratification	Timbang ulang hasil agar komposisi kelompok sama	Saat randomisasi sudah terjadi dan ada ketidakseimbangan kecil
Trigger analysis	Batasi analisis hanya pada pengguna yang benar-benar <i>bisa</i> terpengaruh	Efek terkonsentrasi pada subset kecil; sering merupakan penghematan variance terbesar dari semuanya

✓ BEST PRACTICE — Trigger analysis sering mengalahkan CUPED

Jika perubahan hanya mempengaruhi alur pembayaran, pengunjung yang tidak pernah mencapai halaman pembayaran hanya menambah kebisingan tanpa menambah informasi. Membatasi analisis pada pengguna yang *terpicu* (mencapai titik di mana varian berbeda) dapat menaikkan sensitivitas berlipat-lipat.

Syaratnya ketat: pemicu harus didefinisikan pada perilaku yang tidak dipengaruhi treatment — biasanya berarti mencatat pemicu di kedua varian pada titik yang identik. Setelah efek pada populasi terpicu diperoleh, konversikan kembali ke dampak keseluruhan dengan mengalikan proporsi terpicu.

Bagian 2 — Heterogenitas efek: untuk siapa ini bekerja?

ATE adalah rata-rata. Rata-rata bisa menyembunyikan kenyataan bahwa fitur sangat membantu sebagian pengguna dan merugikan sebagian lain. Menemukannya membuka peluang targeting; mencarinya secara sembrono menghasilkan klaim palsu (Bab 5).

Protokol analisis heterogenitas yang sah

1. PRA-REGISTRASI Tentukan 3–5 dimensi segmen SEBELUM melihat hasil, dengan alasan mekanistik tertulis ("personalisasi tidak bisa bekerja pada pengunjung tanpa riwayat")
2. UJI INTERAKSI Jalankan satu uji formal: apakah efek berbeda antar segmen? (koefisien interaksi $T \times \text{segmen}$)
Bukan: membandingkan p-value tiap segmen
3. ARAH & BESARAN Apakah pola sesuai mekanisme yang diduga?
Efek yang nyata biasanya bergradasi, bukan melompat di satu segmen acak
4. KOREKSI Terapkan koreksi multiple testing pada dimensi yang tidak diregistrasi
5. STATUS Temuan teregistrasi → hasil.
Temuan tak teregistrasi → hipotesis untuk tes konfirmasi berikutnya. Tulis statusnya di memo.

■ TECHNICAL NOTE — mengapa uji interaksi, bukan p-value per segmen

Membandingkan "segmen A signifikan ($p=0,02$), segmen B tidak ($p=0,21$)" adalah kesalahan logika yang umum: perbedaan antara signifikan dan tidak signifikan bukanlah bukti bahwa keduanya berbeda. Segmen B mungkin memiliki efek yang sama besar tetapi sampel lebih kecil. Pertanyaan "apakah efeknya berbeda antar segmen" hanya bisa dijawab oleh uji atas *selisih efeknya* — yaitu koefisien interaksi. Ini salah satu kesalahan paling sering muncul di readout eksperimen, dan mudah dikenali oleh pewawancara.

Dimensi heterogenitas yang layak diregistrasi

Dimensi	Mekanisme yang membenarkan	Tindakan bila terbukti
Pengguna baru vs kembali	Pengguna lama punya kebiasaan; novelty dan primacy hanya menimpa mereka	Estimasi keadaan tunak dari pengguna baru
		Rilis bertahap per kelas perangkat

Kelas perangkat / kecepatan koneksi	Perubahan berat mempengaruhi perangkat lemah secara berbeda	
Intensitas penggunaan (kuartil)	Pengguna berat sudah menemukan jalannya sendiri; pemula paling terbantu	Targeting fitur pada segmen yang diuntungkan
Kategori produk	Ekonomi per kategori berbeda (margin, ukuran keranjang)	Terapkan hanya pada kategori yang untung
Wilayah / kota	Logistik dan kompetisi berbeda	Rollout selektif

✗ COMMON MISTAKE — Menyelamatkan tes kalah dengan mencari segmen menang

Gejala: OEC negatif; tim memecah data sampai menemukan segmen positif; rekomendasi berubah menjadi "rilis untuk segmen ini saja".

Mengapa terjadi: investasi emosional dan sumber daya yang sudah terlanjur dikeluarkan; secara statistik, pencarian pasti berhasil bila segmennya cukup banyak.

Perbaikan: pemecahan yang tidak diregistrasi hanya boleh melahirkan hipotesis. Rilis selektif memerlukan tes konfirmasi pada segmen itu dengan power memadai.

Cara senior menghindarinya: menuliskan daftar segmen di dokumen desain, dan pada readout mencantumkan kalimat: "segmen yang dianalisis: 4 teregistrasi, 0 tambahan" — transparansi yang membuat kecurangan tidak mungkin dilakukan diam-diam.

Bagian 3 — Metric rasio dan unit analisis

Metric seperti click-through rate, items per order, atau conversion per sesi berbentuk rasio dua jumlah. Bila unit randomisasi adalah pengguna tetapi rasio dihitung dengan menjumlahkan pembilang dan penyebut lintas pengguna, standard error yang dihasilkan terlalu kecil.

Simulasi 3.000 eksperimen A/A, metric CTR = klik/impresi, randomisasi per pengguna, ada heterogenitas CTR antar pengguna:

Perlakuan impresi sebagai unit independen → false positive 16,0%
Delta method dengan pengguna sebagai unit → false positive 4,4%

Target: 5,0%. Metode naif memberi TIGA KALI lipat alarm palsu.

Solusinya ada dua, keduanya sah:

- **Agregasi ke tingkat pengguna** — hitung rasio per pengguna, lalu bandingkan rata-ratanya. Sederhana dan aman, tetapi mengubah definisi metric (rata-rata dari rasio ≠ rasio dari total) dan memberi bobot sama pada pengguna aktif dan pengguna satu-kunjungan.
- **Delta method** — pertahankan definisi rasio-dari-total, tetapi hitung variance-nya dengan memperhitungkan korelasi antara pembilang dan penyebut pada tingkat pengguna. Inilah yang dipakai platform eksperimen besar.

Untuk $R = \bar{Y} / \bar{X}$ dengan n pengguna:

$$\text{Var}(R) \approx [\text{Var}(Y) - 2R \cdot \text{Cov}(Y, X) + R^2 \cdot \text{Var}(X)] / (n \cdot \bar{X}^2)$$

Y = pembilang per pengguna (klik), X = penyebut per pengguna (impresi). Semua momen dihitung ANTAR PENGGUNA, bukan antar impresi.

Bagian 4 — Outlier dan metric berekor panjang

Revenue per pengguna memiliki distribusi yang sangat miring: satu pembelian korporat Rp 400 juta dapat menggeser rata-rata seluruh kelompok. Ini bukan masalah teoretis — ia rutin membuat hasil eksperimen tidak dapat ditafsirkan.

Teknik	Cara kerja	Trade-off
Winsorization (direkomendasikan)	Potong nilai di atas persentil ke-99 menjadi nilai persentil ke-99	Sedikit bias ke bawah pada estimasi total; variance turun drastis; ambang harus ditetapkan di muka dan sama untuk kedua kelompok
Capping berbasis bisnis	Batasi pada nilai yang masuk akal (misalnya Rp 10 juta per order ritel)	Lebih mudah dijelaskan ke bisnis; ambang subjektif
Transformasi log	Analisis $\log(1+Y)$	Mengubah estimand menjadi efek pada skala log — sulit diterjemahkan ke rupiah; sering menyesatkan
Metric biner pendamping	Analisis "apakah membeli" terpisah dari "berapa besar bila membeli"	Dua metric, dua cerita; sangat informatif untuk memahami mekanisme
Bootstrap / uji permutasi	Tidak mengandalkan asumsi normal	Menangani inferensi, tetapi tidak menghilangkan dominasi outlier terhadap estimasi

⚠ **WARNING — Ambang winsorization ditetapkan di muka, dari data historis**

Menetapkan ambang setelah melihat data eksperimen adalah bentuk halus dari p-hacking: menggeser ambang beberapa persentil dapat mengubah hasil dari signifikan menjadi tidak, dan godaan untuk memilih yang "masuk akal" hampir tak tertahankan. Tetapkan persentil ke-99 dari data historis pra-eksperimen, tulis di dokumen desain, dan terapkan identik pada kedua kelompok.

Bagian 5 — Interferensi: ketika A/B test memberi jawaban yang salah arah

Seluruh kerangka Bab 1 bersandar pada asumsi yang belum disebut namanya: **SUTVA** (Stable Unit Treatment Value Assumption) — hasil satu unit tidak dipengaruhi oleh treatment yang diterima unit lain. Ketika asumsi ini dilanggar, perbandingan treatment versus kontrol bukan hanya bias; ia bisa menunjuk ke arah yang berlawanan dengan kebenaran.

Bentuk-bentuk interferensi

Jenis	Contoh	Arah kesalahan
Kompetisi sumber daya	Marketplace: penjual treatment mendapat peringkat lebih baik, mengambil pembeli dari penjual kontrol	Efek terlihat jauh lebih besar dari sebenarnya; pada rollout 100% keuntungan menguap
Inventory bersama	Treatment mendorong pembelian SKU terbatas; kontrol kehabisan stok	Melebih-lebihkan; kontrol dirugikan oleh treatment
Efek jaringan	Fitur berbagi; pengguna kontrol menerima tautan dari teman di treatment	Meremehkan (dilusi) — kontrol ikut menikmati manfaat

Kapasitas operasional	Treatment menaikkan order; gudang jenuh; SLA seluruh perusahaan memburuk	Efek negatif menimpa kedua kelompok; efek terukur meremehkan biaya sistem
Pembelajaran model bersama	Model rekomendasi dilatih pada data gabungan kedua varian	Kontrol "belajar" dari treatment; dilusi
Anggaran bersama	Kampanye iklan dengan satu anggaran; treatment mengambil porsi dari kontrol	Melebih-lebihkan secara serius

◆ BUSINESS INSIGHT — kasus klasik yang harus dikenali

TokoNusa menguji "notifikasi stok menipis" pada halaman produk. Tes per pengguna menunjukkan conversion +12% — hasil terbaik sepanjang tahun. Setelah dirilis 100%, kenaikannya hanya +1,5%.

Penyebabnya: notifikasi mempercepat keputusan beli pada SKU dengan stok terbatas. Selama tes, pengguna treatment mengambil stok yang seharusnya dibeli pengguna kontrol. Yang terukur bukan penciptaan permintaan, melainkan *pemindahan* permintaan dari satu kelompok ke kelompok lain. Ketika semua orang menerima notifikasi, tidak ada lagi siapa pun untuk didahului.

Tanda peringatan yang seharusnya menimbulkan kecurigaan sejak awal: metric kontrol **memburuk** dibandingkan periode sebelum eksperimen. Pada eksperimen yang sah, kelompok kontrol seharusnya berperilaku seperti biasa. Memeriksa hal ini adalah salah satu diagnosis interferensi termurah yang tersedia.

Desain yang tahan interferensi

Desain	Cara kerja	Biaya
Cluster randomization	Acak per kelompok yang saling berinteraksi (kota, sekolah, graf sosial)	Jumlah unit efektif turun drastis; butuh cluster-robust SE
Geo experiment	Acak per kota/wilayah	Power rendah; perlu metode Bab 12
Switchback	Seluruh sistem bergantian treatment/kontrol antar interval waktu	Autokorelasi; hanya sah bila carryover kecil
Budget-split / two-sided design	Pisahkan sumber daya bersama (anggaran, inventory) per kelompok	Rumit secara operasional; tidak selalu mungkin
Uji dua tingkat	Acak proporsi treatment antar klaster, lalu acak unit di dalamnya	Memungkinkan mengukur besar limpahan itu sendiri; butuh sampel besar

✓ BEST PRACTICE — Tiga pertanyaan deteksi interferensi sebelum mendesain

(1) Apakah ada sesuatu yang *terbatas* yang diperebutkan kedua kelompok — stok, anggaran, kapasitas, perhatian pembeli, slot pencarian? **(2)** Apakah pengguna dapat saling berkomunikasi atau melihat hasil pengguna lain? **(3)** Apakah ada sistem yang belajar dari data kedua kelompok sekaligus? Satu "ya" saja sudah cukup untuk memindahkan diskusi ke desain berunit lebih besar. Dan selama tes berjalan, pantau satu hal: *apakah kelompok kontrol berperilaku sama dengan periode sebelum eksperimen?*

Checklist analisis lanjutan

- ✓ Kovariat pra-eksperimen tersedia dan CUPED/ANCOVA diterapkan bila $p > 0,3$
- ✓ Kovariat terkunci pada tanggal sebelum pengguna masuk eksperimen
- ✓ Trigger analysis dipertimbangkan; definisi pemicu tidak dipengaruhi treatment

- ✓ Segmen heterogenitas diregistrasi di muka dengan alasan mekanistik
- ✓ Perbedaan antar segmen diuji dengan koefisien interaksi, bukan perbandingan p-value
- ✓ Metric rasio dianalisis dengan delta method atau agregasi ke unit randomisasi
- ✓ Ambang winsorization ditetapkan dari data historis dan sama untuk kedua kelompok
- ✓ Tiga pertanyaan deteksi interferensi dijawab sebelum desain dikunci
- ✓ Perilaku kelompok kontrol dibandingkan dengan periode pra-eksperimen

Ending Card — Bab 6

What you learned

CUPED/ANCOVA beserta tabel penghematan dan syarat kovariat pra-eksperimen; hierarki teknik variance reduction termasuk trigger analysis; protokol lima langkah analisis heterogenitas dan mengapa uji interaksi wajib; delta method untuk metric rasio beserta bukti simulasi inflasi false positive; penanganan outlier dengan winsorization yang ditetapkan di muka; SUTVA, enam bentuk interferensi beserta arah kesalahannya, dan lima desain yang tahan interferensi.

Skills mastered

Variance reduction · analisis heterogenitas yang sah · inferensi metric rasio · deteksi dan penanganan interferensi.

Real business value

CUPED menaikkan kapasitas belajar organisasi puluhan persen tanpa sumber daya tambahan. Deteksi interferensi mencegah kelas kesalahan yang paling mahal dalam eksperimentasi: merilis perubahan yang tampak menang besar tetapi sebenarnya hanya memindahkan nilai dari satu kelompok pengguna ke kelompok lain.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagaimana kamu mempercepat eksperimen tanpa menambah traffic?" (CUPED/ANCOVA, stratifikasi, trigger analysis, metric yang lebih sensitif, winsorization — sebutkan angka penghematannya.)
2. "Segmen A signifikan, segmen B tidak. Apakah efeknya berbeda?" (Tidak dapat disimpulkan; butuh uji interaksi. Pertanyaan penyaring klasik.)
3. "Kamu menguji fitur baru di marketplace dan hasilnya +15%. Apa kekhawatiranmu?" (Interferensi/kanibalisasi antar penjual; usulkan geo atau switchback; periksa apakah kontrol memburuk.)
4. "Metric CTR dihitung sebagai total klik dibagi total impresi. Ada masalah?" (Unit analisis; delta method; tunjukkan konsekuensinya pada false positive rate.)
5. "Satu pelanggan korporat membeli Rp 400 juta di kelompok treatment. Apa yang kamu lakukan?" (Ambang winsorization yang sudah ditetapkan di muka; jangan memutuskan setelah melihat data; laporkan hasil dengan dan tanpa pemotongan sebagai analisis sensitivitas.)

Exercises

Exercise 6.1 (Beginner · 25 menit)

Objective: menghitung manfaat CUPED

Sebuah tes membutuhkan 21 hari tanpa CUPED. Korelasi antara metric periode pra dan periode eksperimen adalah 0,65. (a) Berapa pengurangan variance? (b) Berapa durasi setara? (c) Jika tim ingin MDE 20% lebih kecil dan tetap 21 hari, berapa p minimum yang dibutuhkan? (d) Sebutkan satu metric TokoNusa yang p -nya kemungkinan tinggi dan satu yang rendah, beserta alasannya.

Answer key 6.1

(a) $1 - (1 - 0,65^2) = 42,3\%$. (b) $21 \times (1 - 0,65^2) = 21 \times 0,5775 = 12,1$ hari. (c) $MDE \propto \sqrt{\text{variance}}$; MDE 20% lebih kecil berarti faktor 0,8 $\rightarrow$ variance harus menjadi 0,64 dari semula $\rightarrow 1 - p^2 = 0,64 \rightarrow p = 0,6$. (d) p tinggi: **penjualan per toko per bulan** (struktur toko stabil; lokasi, ukuran, dan basis pelanggannya tidak berubah). p rendah: **conversion per pengunjung anonim** (tidak ada riwayat yang bisa dijadikan kovariat sama sekali).

Exercise 6.2 (Intermediate · 50 menit)

Objective: mendeteksi interferensi

Untuk tiap skenario, tentukan apakah ada interferensi, arah kesalahannya, dan desain alternatif:

- (a) Menguji algoritma pencocokan pengemudi baru di aplikasi ojek online, acak per penumpang.
- (b) Menguji email promo, acak per pelanggan, produk stok melimpah.
- (c) Menguji badge "terlaris" pada 50% produk, acak per produk.
- (d) Menguji fitur undangan teman, acak per pengguna.
- (e) Menguji harga dinamis pada 50% pengunjung di halaman yang sama.
- (f) Menguji kenaikan bid iklan pada 50% kampanye dengan satu anggaran harian bersama.

Answer key 6.2

- (a) **Interferensi berat** — pengemudi adalah sumber daya terbatas; penumpang treatment mengambil pengemudi dari kontrol. Arah: melebihi-lebihkan. Alternatif: switchback per kota per interval waktu.
- (b) **Tidak ada** (asalkan pelanggan tidak saling meneruskan email dan stok memadai). Desain per pelanggan sah.
- (c) **Interferensi** — badge memindahkan perhatian antar produk di halaman yang sama; produk kontrol dirugikan. Arah: melebihi-lebihkan. Alternatif: acak per sesi/pengguna dengan seluruh katalog konsisten, atau switchback.
- (d) **Efek jaringan** — kontrol menerima undangan dari treatment. Arah: meremehkan (dilusi). Alternatif: cluster randomization berbasis graf sosial.
- (e) **Interferensi + risiko kepercayaan** — pengunjung dapat membandingkan harga; selain bias, ada risiko reputasi dan kepatuhan. Alternatif: geo experiment atau RDD pada ambang harga (Bab 11).
- (f) **Interferensi anggaran** — kampanye treatment memenangkan lelang internal dan menghabiskan anggaran bersama. Arah: melebihi-lebihkan serius. Alternatif: pisahkan anggaran per kelompok, atau geo experiment (Bab 12).

Exercise 6.3 (Advanced · 90 menit)

Objective: heterogenitas yang sah

EXP-041 (ambang gratis ongkir) memberi lift CM per pengunjung +9,45% secara keseluruhan. Manajemen bertanya apakah ambang baru sebaiknya diterapkan berbeda per kategori.

- (a) Tulis tiga hipotesis heterogenitas dengan mekanisme, sebelum melihat data apa pun. (b) Rancang analisis: uji apa yang dijalankan, koreksi apa yang diterapkan. (c) Andaikan hasilnya: grocery $-2,1\%$ ($p=0,08$), fashion $+14,2\%$ ($p<0,001$), elektronik $+11,0\%$ ($p=0,004$), rumah tangga $+8,1\%$ ($p=0,03$); uji interaksi kategori $\times$ treatment $p=0,002$. Tulis rekomendasi. (d) Apa risiko dari menerapkan ambang berbeda per kategori, dan bagaimana kamu memitigasinya?

Answer key 6.3

(a) Hipotesis dengan mekanisme: **(i)** kategori ber-AOV rendah (grocery, AOV di bawah ambang baru) paling dirugikan karena sebagian besar keranjangnya tidak dapat mencapai Rp 199rb tanpa pembelian yang tidak diinginkan; **(ii)** kategori ber-AOV menengah (fashion) paling diuntungkan karena keranjangnya berada tepat di zona yang bisa didorong naik; **(iii)** kategori ber-AOV tinggi (elektronik) hampir tidak terpengaruh pada conversion karena sudah melampaui ambang — keuntungannya murni dari penurunan subsidi.

(b) Analisis: regresi CM per pengunjung $\sim$ treatment + kategori + treatment $\times$ kategori dengan SE pada tingkat pengguna; laporkan uji-F gabungan atas seluruh suku interaksi; koreksi Benjamini-Hochberg untuk perbandingan per kategori. Empat kategori teregistrasi, tidak ada tambahan.

(c) Rekomendasi: uji interaksi signifikan ($p=0,002$) mengonfirmasi bahwa efeknya *memang* berbeda antar kategori — ini prasyarat sebelum membahas kategori mana pun secara terpisah. Pola sesuai mekanisme yang diduga (gradien mengikuti AOV kategori), yang menguatkan bahwa temuan ini bukan kebetulan. Grocery negatif tetapi tidak signifikan ($p=0,08$) — *tidak konklusif*, bukan bukti kerugian. Rekomendasi: terapkan ambang Rp 199rb untuk fashion, elektronik, rumah tangga; **pertahankan ambang lama untuk grocery** sambil menjalankan tes terarah pada grocery dengan power memadai untuk memastikan apakah kerugiannya nyata.

(d) Risiko: (i) **kebingungan pelanggan** — keranjang campuran kategori membuat aturan sulit dipahami dan berpotensi menurunkan kepercayaan; (ii) **kompleksitas operasional** dan bug pada keranjang lintas kategori; (iii) **arbitrase** — pelanggan menambahkan satu item grocery untuk memicu ambang yang lebih rendah. Mitigasi: aturan berbasis komposisi keranjang yang dijelaskan dengan satu kalimat di halaman keranjang; uji pemahaman lewat survei singkat; dan guardrail atas proporsi keranjang campuran yang memanfaatkan celah tersebut. Jika mitigasi terlalu rumit, keputusan yang lebih baik adalah ambang tunggal pada nilai kompromi — kesederhanaan memiliki nilai yang tidak muncul di metric eksperimen.

Exercise 6.4 (Production Challenge · 5 jam)

Objective: membuktikan manfaat CUPED sendiri

Dengan dataset publik (Olist), bangun simulasi: tetapkan periode pra dan periode eksperimen; acak pelanggan ke dua kelompok; tanamkan efek +3% pada revenue kelompok treatment. Estimasi efeknya dengan (a) perbandingan rata-rata biasa dan (b) CUPED memakai revenue periode pra. Ulangi 1.000 kali. Bandingkan: lebar CI rata-rata, tingkat cakupan CI (harus $\pm 95\%$), dan power empiris. Lalu ulangi dengan winsorization pada persentil ke-99 dan laporkan dampaknya. Tulis laporan singkat berisi tabel hasil dan rekomendasi untuk platform eksperimen.

Answer key 6.4 — rubrik

Hasil yang benar akan menunjukkan: (i) kedua estimator tidak bias (rata-rata estimasi $\approx$ efek yang ditanamkan); (ii) CI CUPED lebih sempit dengan faktor $\approx \sqrt{1-\rho^2}$; (iii) cakupan tetap $\approx 95\%$ untuk keduanya — inilah bukti bahwa penghematan tidak dibayar dengan validitas; (iv) power empiris CUPED lebih tinggi; (v) winsorization mempersempit CI lebih jauh tetapi menggeser estimasi sedikit ke bawah — trade-off yang harus dilaporkan, bukan disembunyikan. Kesalahan umum: menghitung θ dari data eksperimen kelompok treatment saja (harus dari gabungan, atau dari data pra-eksperimen), dan lupa memeriksa cakupan CI — yang merupakan inti dari validasi metode apa pun.

Portfolio idea

★ PORTFOLIO TIP

Laporan simulasi dari Exercise 6.4 — dengan tabel yang menunjukkan CI lebih sempit tanpa kehilangan cakupan — adalah demonstrasi pemahaman metodologis yang sangat kuat. Judul yang bekerja: "Menghemat 40% waktu eksperimen tanpa mengorbankan validitas: replikasi CUPED pada data publik".

Further reading

Deng, Xu, Kohavi & Walker, "Improving the Sensitivity of Online Controlled Experiments by Utilizing Pre-Experiment Data" (WSDM 2013; makalah CUPED asli) · Deng, Knoblich & Lu tentang delta method untuk metric ratio · Blake & Coey tentang interferensi di marketplace · Athey & Imbens tentang estimasi heterogenitas efek.

Next chapter

Bab 7 — menutup Bagian I dengan mengubah lift menjadi rupiah. Incremental contribution margin, nilai informasi sebuah eksperimen, portofolio tes sebagai investasi, dan pertanyaan yang jarang ditanyakan: kapan sebaiknya kita *tidak* menguji.

Bab 7 — Ekonomi Eksperimen: dari Lift menjadi Rupiah

Lift 3,1% bukan hasil. Hasil adalah angka rupiah yang bisa masuk ke dalam rencana, beserta keyakinan yang menyertainya.

Learning objectives	Menerjemahkan lift menjadi incremental contribution margin tahunan dengan asumsi yang eksplisit; menghitung dan menyampaikan rentang nilai; menghitung nilai informasi sebuah eksperimen (EVPI); memutuskan kapan menguji dan kapan tidak; menghitung ROI program eksperimentasi; mengenali sumber kebocoran antara lift yang diklaim dan dampak yang terwujud
Prerequisites	Bab 3 dan Bab 5; Vol 3 Bab 4 (contribution margin, break-even, unit economics)
Estimasi waktu	Baca 2 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	Impact sizing, expected value of information, test/no-test decision, program ROI, business case writing
Business domain	Retail omnichannel — perhitungan dampak EXP-041 dan EXP-052 sampai ke rencana anggaran

Mengapa penerjemahan ini menjadi tanggung jawab analyst

Ketika analyst berhenti pada "lift 3,1%, $p=0,003$ ", pekerjaan penerjemahan tetap terjadi — hanya saja dilakukan oleh orang lain, biasanya tanpa akses ke asumsi yang benar. Hasilnya adalah angka rupiah yang terlalu besar, masuk ke rencana anggaran, dan tidak pernah terwujud. Setelah beberapa siklus, kepercayaan pada program eksperimen runtuh.

Menerjemahkan sendiri, dengan asumsi yang tertulis dan rentang yang jujur, adalah cara paling efektif melindungi kredibilitas jangka panjang seorang analyst.

Kerangka penerjemahan lima langkah

1. LIFT PADA METRIC YANG DIUJI
+3,13% conversion (CI 95%: +1,07% s/d +5,18%)
2. KONVERSI KE UNIT EKONOMI
Bukan revenue. Contribution margin — satu-satunya angka yang mencerminkan uang yang benar-benar tersisa (Vol 3 Bab 4).
3. SKALAKAN KE POPULASI YANG BENAR
Berapa banyak pengguna/kunjungan yang akan menerima perubahan? Populasi eksperimen $\neq$ populasi rollout. Sertakan pertumbuhan yang wajar, jangan pertumbuhan yang diharapkan.
4. TERAPKAN FAKTOR PELURUHAN
Novelty (Bab 4), winner's curse (Bab 3), interferensi (Bab 6), kejenuhan pasar. Setiap faktor ditulis sebagai angka, bukan "kami sudah konservatif".
5. KURANGI BIAYA

Implementasi, pemeliharaan, biaya operasional tambahan, dan biaya kesempatan sumber daya rekayasa.

Penerapan penuh: EXP-052

LANGKAH 1 – Lift terukur

Conversion 3,2000% → 3,3000% (+3,13% relatif)

CI 95% relatif: +1,07% s/d +5,18%

LANGKAH 2 – Konversi ke contribution margin

CM per order (Vol 3) Rp 69.700

CM per pengunjung kontrol $0,0320 \times 69.700 = \text{Rp } 2.230,4$

CM per pengunjung treatment $0,0330 \times 69.700 = \text{Rp } 2.300,1$

Selisih Rp 69,7

Catatan penting: AOV tidak berubah pada tes ini (diperiksa, selisih +0,3%, $p=0,71$). Bila AOV berubah, CM per order harus dihitung ulang, BUKAN diasumsikan tetap.

LANGKAH 3 – Skala populasi

Kunjungan mobile web/tahun = $2,4 \text{ jt} \times 12 \times 62\% \text{ mobile}$

= 17,86 juta kunjungan

Dampak kasar = $17,86 \text{ jt} \times \text{Rp } 69,7 = \text{Rp } 1,245 \text{ miliar/tahun}$

LANGKAH 4 – Faktor peluruhan (masing-masing dengan alasan)

Novelty: lift minggu-4 = 3,2% vs keseluruhan 3,13% → tidak ada peluruhan terdeteksi $\times 1,00$

Winner's curse: power tes 82% pada MDE 2%; koreksi kecil $\times 0,95$

Interferensi: tidak ada sumber daya bersama $\times 1,00$

Cakupan rollout: 6% traffic memakai versi aplikasi lama yang tidak menerima perubahan $\times 0,94$

Faktor gabungan $\times 0,893$

Dampak setelah peluruhan = $1,245 \times 0,893 = \text{Rp } 1,112 \text{ miliar}$

LANGKAH 5 – Biaya

Implementasi (sudah dikeluarkan; sunk) Rp 0

Pemeliharaan tahunan Rp 180 juta

NILAI BERSIH TAHUNAN Rp 932 juta

RENTANG YANG DILAPORKAN (dari CI conversion)

Batas bawah (+1,07%): $1,245 \times (1,07/3,13) \times 0,893 - 0,18$
 $= 0,380 - 0,18 = \text{Rp } 200 \text{ juta}$

Titik estimasi = Rp 932 juta

Batas atas (+5,18%) = Rp 1,66 miliar

ANGKA YANG MASUK RENCANA ANGGARAN: Rp 200 juta (batas bawah)

ANGKA YANG DILAPORKAN KE DIREKSI : "Rp 0,2–1,7 miliar, dengan estimasi terbaik Rp 0,9 miliar"

✓ BEST PRACTICE — Rencanakan dengan batas bawah, laporkan dengan rentang

Dua angka berbeda untuk dua tujuan berbeda. **Rencana anggaran dan komitmen target** memakai batas bawah CI setelah peluruhan — angka yang hampir pasti terlampaui. **Komunikasi ke direksi** memakai rentang penuh dengan titik estimasi, karena menyembunyikan potensi atas juga merupakan bentuk ketidakjujuran. Analyst yang konsisten melampaui angkanya sendiri membangun modal kredibilitas yang bisa dipakai saat harus menyampaikan berita buruk.

Mengapa jumlah lift tidak pernah sama dengan pertumbuhan perusahaan

Setiap program eksperimen matang menghadapi pertanyaan yang sama dari CFO: "kalian mengklaim total +34% tahun ini; metric perusahaan naik 6%. Jelaskan." Berikut dekomposisi jawabannya.

Sumber kebocoran	Besaran tipikal	Penjelasan
Winner's curse	-15% s/d -40%	Estimasi dari tes yang menang sistematis terlalu tinggi (Bab 3)
False positive	-10% s/d -35%	Sebagian kemenangan adalah kebisingan (tabel PPV, Bab 5)
Novelty yang meluruh	-10% s/d -30%	Efek awal tidak bertahan (Bab 4)
Efek tidak aditif	-10% s/d -25%	Dua perbaikan pada funnel yang sama tidak menjumlah; keduanya memperbaiki drop-off yang sama
Cakupan rollout tidak penuh	-5% s/d -15%	Versi lama, platform yang tidak diperbarui, pengecualian
Kejenuhan & respons kompetitor	bervariasi	Keunggulan terkikis seiring waktu

► EXECUTIVE PERSPECTIVE — cara menjawab CFO tanpa merusak program

Jawaban yang salah: "eksperimen memang begitu". Jawaban yang bekerja: "*Kami sudah mengukurnya. Holdout global 2% menunjukkan program menghasilkan +7,1% dibanding tanpa perubahan apa pun — itu angka yang sebenarnya. Selisih dengan jumlah klaim per tes berasal dari empat sumber yang bisa saya rinci, dan tiga di antaranya sedang kami kurangi dengan menaikkan power minimum.*" Perhatikan: memiliki **holdout global** mengubah percakapan ini dari pembelaan menjadi laporan. Itulah alasan sesungguhnya keberadaannya.

Nilai informasi: kapan menguji itu layak

Eksperimen adalah pembelian informasi. Seperti pembelian lain, ia layak hanya bila nilainya melebihi harganya. Kerangkanya adalah **expected value of perfect information** (EVPI) — batas atas dari nilai pengujian apa pun.

Kasus: personalisasi halaman depan
Biaya implementasi + pemeliharaan tahunan = Rp 1,0 miliar
CM online tahunan = Rp 64,2 miliar
Bila berhasil (+4%) = Rp 2,569 miliar
Keyakinan awal berhasil = 45%

TANPA MENGUJI, LUNCURKAN LANGSUNG

$$EV = 0,45 \times 2,569 + 0,55 \times 0 - 1,0 = \text{Rp } +0,156 \text{ miliar}$$

TANPA MENGUJI, TIDAK MELUNCURKAN

$$EV = 0$$

DENGAN INFORMASI SEMPURNA (luncurkan hanya bila berhasil)

$$EV = 0,45 \times (2,569 - 1,0) = \text{Rp } +0,706 \text{ miliar}$$

$$EVPI = 0,706 - 0,156 = \text{Rp } 550 \text{ juta}$$

Biaya eksperimen (3 minggu, 1 analyst, 2 engineer, slot traffic) $\approx$ Rp 85 juta

Biaya penundaan 3 minggu bila ternyata berhasil
 $= 2,569 \times (3/52) \approx \text{Rp } 148 \text{ juta}$
 Total biaya menguji $\approx \text{Rp } 233 \text{ juta}$
 233 juta $\ll$ 550 juta $\rightarrow$ MENGUJI JELAS LAYAK

■ TECHNICAL NOTE — EVPI adalah batas atas, bukan nilai sebenarnya

Eksperimen nyata tidak memberi informasi sempurna; ia memberi informasi yang tunduk pada α dan β . Nilai sesungguhnya (expected value of sample information) selalu *lebih kecil* dari EVPI, dan besarnya bergantung pada power tes. Konsekuensi praktis: **bila EVPI saja sudah lebih kecil dari biaya menguji, tidak perlu perhitungan lebih lanjut — jangan menguji.** Perhitungan penuh EVSI beserta decision tree-nya dibahas di Volume 5; untuk keperluan Bab ini, EVPI sudah cukup sebagai penyaring.

Empat situasi di mana menguji bukan keputusan terbaik

Situasi	Alasan	Yang dilakukan sebagai gantinya
Keputusan sudah pasti terlepas dari hasil	Kepatuhan hukum, perbaikan bug, keputusan strategis yang sudah diambil	Rilis; pantau guardrail; ukur dampaknya untuk pembelajaran, bukan untuk keputusan
Nilai keputusan jauh lebih kecil dari biaya menguji	$EVPI < \text{biaya tes}$	Ambil keputusan berdasarkan penilaian; catat asumsinya
Biaya penundaan melebihi nilai informasi	Jendela musiman yang akan hilang; tekanan kompetitif	Luncurkan dengan holdout kecil sehingga dampaknya tetap terukur
Tes tidak akan pernah cukup powered	MDE tercapai jauh di atas efek realistis (Bab 3)	Metode observasional (Bagian II), rollout bertahap dengan pemantauan, atau keputusan berbasis penilaian yang dinyatakan terbuka

✗ COMMON MISTAKE — Menguji hal yang tidak akan mengubah keputusan

Gejala: tim menghabiskan tiga minggu menguji perubahan yang akan tetap dirilis apa pun hasilnya, karena "kita harus berbasis data".

Mengapa terjadi: eksperimen menjadi ritual kepatuhan, bukan alat keputusan.

Perbaikan: satu pertanyaan wajib di formulir desain — "Apa yang akan kita lakukan berbeda jika hasilnya *no*?" Bila jawabannya "tidak ada", tes dibatalkan dan slot traffic-nya dipakai untuk pertanyaan yang benar-benar terbuka.

Cara senior menghindarinya: memperlakukan slot traffic sebagai anggaran yang langka, sehingga setiap tes harus bersaing memperebutkannya.

ROI program eksperimentasi

Pertanyaan yang akan diajukan kepada siapa pun yang mengusulkan pembentukan atau perluasan program eksperimen. Berikut kerangka jawabannya dengan angka TokoNusa.

BIAYA PROGRAM (per tahun)
 $40 \text{ eksperimen} \times \text{Rp } 85 \text{ juta} = \text{Rp } 3,40 \text{ miliar}$
 (mencakup waktu analyst, engineer, dan biaya kesempatan traffic)

NILAI YANG DIHASILKAN
 Kemenangan: 13 tes menang (33%),
 rata-rata CM tahunan Rp 1,2 miliar setelah peluruhan
 $= \text{Rp } 15,6 \text{ miliar}$
 Kerugian yang dicegah: 13 tes menunjukkan efek NEGATIF

yang tanpa pengujian akan dirilis;	
rata-rata kerugian dihindari Rp 0,8 miliar	= Rp 10,4 miliar
14 tes netral: nilai berupa penghentian investasi	
lanjutan pada arah yang tidak berbuah	(tidak dihitung)
TOTAL NILAI	= Rp 26,0 miliar
ROI = 26,0 / 3,40	= 7,6x

◆ BUSINESS INSIGHT — separuh nilai program adalah kerugian yang dicegah

Baris "kerugian yang dicegah" hampir selalu dilupakan dalam bisnis case eksperimentasi, padahal ia menyumbang 40% dari total nilai pada perhitungan di atas. Argumennya sederhana dan sulit dibantah: tanpa pengujian, ide-ide itu tetap dirilis — organisasi hanya tidak akan pernah tahu bahwa mereka merugikan. Kalimat yang bekerja di ruang rapat: *"Program ini bukan mesin pembuat kemenangan. Ia adalah mesin pencegah kerugian yang kebetulan juga menemukan kemenangan."*

Untuk membuat klaim ini kredibel, program harus **mencatat tes yang kalah** beserta estimasi kerugian yang dihindari. Program yang hanya mempublikasikan kemenangannya kehilangan separuh dari argumen nilainya sendiri.

Menulis business case dari hasil eksperimen

BUSINESS CASE — EXP-041 Ambang gratis ongkir Rp 199rb

REKOMENDASI Terapkan ambang Rp 199.000 untuk kategori fashion, elektronik, dan rumah tangga. Pertahankan Rp 150.000 untuk grocery sampai tes terarah selesai.

DAMPAK

- Rentang : Rp 3,9 – 8,2 miliar CM/tahun
- Titik estimasi : Rp 6,1 miliar
- Untuk rencana : Rp 3,9 miliar (batas bawah CI)
- Setara +5,9% terhadap EBITDA FY2025 (Rp 104 miliar)

DASAR BUKTI Eksperimen terkontrol, 21 hari, 1,12 juta pengguna, randomisasi per pengguna, SRM bersih, tidak ada novelty terdeteksi. Tingkat bukti 1 (Bab 1).

ASUMSI

- (a) Traffic tumbuh 0% (konservatif; aktual +8% YoY)
- (b) Efek tidak meluruh di luar 21 hari – akan diverifikasi holdout 2% pada bulan ke-3 dan ke-6
- (c) Perilaku kompetitor tidak berubah; bila kompetitor menurunkan ambangnya, efek dapat terkikis

RISIKO Conversion turun 1,56% (CI -3,59% s/d +0,47%). Skenario terburuk pada batas bawah CI conversion dan batas bawah CI margin tetap positif: Rp 2,1 miliar. Risiko kepercayaan pelanggan dipantau lewat NPS.

BIAYA Implementasi Rp 40 juta (perubahan konfigurasi), komunikasi pelanggan Rp 120 juta, pemeliharaan nihil.

VERIFIKASI Holdout 2% selama 6 bulan. Jika lift holdout pada bulan ke-3 di bawah +4%, kaji ulang keputusan.

KEPUTUSAN YANG DIMINTA

- Persetujuan rollout dan anggaran komunikasi Rp 120 juta.
- Pemilik keputusan: VP Commerce.

✓ **BEST PRACTICE — Sertakan skenario terburuk yang tetap positif**

Baris "skenario terburuk" dalam contoh di atas melakukan pekerjaan yang tidak bisa dilakukan bagian lain: ia menunjukkan bahwa rekomendasi tidak bergantung pada asumsi optimistis mana pun. Cara menghitungnya: ambil batas bawah CI pada *semua* komponen sekaligus, lalu tunjukkan hasilnya masih positif. Bila ternyata tidak positif, itu informasi yang harus disampaikan — dan biasanya berarti rekomendasi perlu disertai mitigasi, bukan dibatalkan.

Checklist ekonomi eksperimen

- ✓ Dampak dihitung pada contribution margin, bukan revenue
- ✓ Populasi rollout dibedakan dari populasi eksperimen; cakupan aktual diperhitungkan
- ✓ Setiap faktor peluruhan ditulis sebagai angka beserta alasannya
- ✓ Tiga angka dilaporkan: batas bawah untuk rencana, titik estimasi, batas atas
- ✓ Asumsi pertumbuhan bersifat konservatif dan dinyatakan terbuka
- ✓ Biaya pemeliharaan dan operasional tambahan dikurangkan
- ✓ EVPI dihitung sebelum memutuskan menguji, terutama untuk tes berbiaya tinggi
- ✓ Pertanyaan "apa yang berubah jika hasilnya nol" dijawab sebelum tes dijalankan
- ✓ Holdout dipasang untuk memverifikasi dampak yang diklaim
- ✓ Tes yang kalah dicatat beserta estimasi kerugian yang dicegah

Ending Card — Bab 7

What you learned

Kerangka lima langkah dari lift ke rupiah beserta penerapan penuh pada EXP-052; enam sumber kebocoran antara lift yang diklaim dan pertumbuhan yang terwujud; peran holdout global dalam percakapan dengan CFO; perhitungan EVPI dan penggunaannya sebagai penyaring keputusan menguji; empat situasi di mana menguji bukan pilihan terbaik; perhitungan ROI program eksperimentasi termasuk komponen kerugian yang dicegah; struktur business case dari hasil eksperimen.

Skills mastered

Impact sizing yang dapat dipertahankan · analisis nilai informasi · keputusan uji/tidak uji · penulisan business case · argumentasi nilai program.

Real business value

Ini adalah bab yang mengubah analyst dari pelapor hasil menjadi peserta dalam keputusan alokasi modal. Kemampuan menyampaikan "rentangnya sekian, saya merencanakan dengan angka terendah, dan berikut cara kita memverifikasinya" adalah bahasa yang membuat rekomendasi analyst diperlakukan setara dengan rekomendasi finance.

Interview readiness

● INTERVIEW QUESTIONS

1. "Tesmu menang 3%. Berapa nilainya bagi perusahaan?" (Jalankan lima langkah dengan lantang; sebutkan faktor peluruhan; berikan tiga angka.)
2. "Mengapa jumlah lift tim kalian tidak terlihat di P&L?" (Enam sumber kebocoran; usulkan holdout global.)
3. "Kapan kamu menyarankan untuk TIDAK menguji?" (Empat situasi; sebutkan EVPI.)
4. "Bagaimana kamu membenarkan biaya program eksperimentasi ke CFO?" (ROI dengan komponen kerugian yang dicegah; holdout global sebagai bukti.)
5. "Angka mana yang kamu masukkan ke rencana anggaran — titik estimasi atau batas bawah?" (Batas bawah; jelaskan mengapa melampaui target lebih bernilai daripada meleset.)

Exercises

Exercise 7.1 (Beginner · 25 menit)

Objective: penerjemahan dasar

Sebuah tes menaikkan AOV dari Rp 312.000 menjadi Rp 318.000 (+1,92%, CI +0,6% s/d +3,2%); conversion tidak berubah. COGS tetap 70% dari nilai barang; biaya lain per order tidak berubah. Order online per tahun 921.600.

(a) Hitung perubahan CM per order. (b) Hitung dampak tahunan pada titik estimasi dan batas bawah. (c) Biaya pemeliharaan Rp 250 juta/tahun — apakah layak? (d) Apa satu asumsi yang paling berisiko dalam perhitunganmu?

Answer key 7.1

- (a) Kenaikan AOV Rp 6.000; karena COGS 70%, margin kotor tambahan = $6.000 \times 0,30 = \text{Rp } 1.800 \text{ per order}$. Biaya lain tidak berubah, sehingga CM per order naik Rp 1.800 (dari Rp 69.700 menjadi Rp 71.500).
- (b) Titik estimasi: $921.600 \times 1.800 = \text{Rp } 1,659 \text{ miliar/tahun}$. Batas bawah (+0,6%): kenaikan AOV = $312.000 \times 0,006 = \text{Rp } 1.872 \rightarrow \text{margin Rp } 561,6 \rightarrow 921.600 \times 561,6 = \text{Rp } 518 \text{ juta/tahun}$.
- (c) Layak: bahkan pada batas bawah (Rp 518 juta) nilainya dua kali lipat biaya pemeliharaan Rp 250 juta. Rekomendasi rilis dapat diberikan tanpa bergantung pada skenario optimistis.
- (d) Asumsi paling berisiko: **COGS tetap 70% pada barang tambahan**. Jika kenaikan AOV berasal dari kategori bermargin lebih rendah (misalnya elektronik), margin tambahannya jauh lebih kecil. Pemeriksaan yang harus dilakukan: dekomposisi kenaikan AOV per kategori — persis keterampilan mix-rate dari Vol 3 Bab 11.

Exercise 7.2 (Intermediate · 45 menit)

Objective: keputusan menguji atau tidak

Untuk tiap kasus, hitung atau perkirakan EVPI dan berikan rekomendasi menguji/tidak menguji beserta alasannya:

- (a) Mengubah teks tombol checkout. Biaya implementasi Rp 5 juta. Dampak potensial $\pm \text{Rp } 80 \text{ juta/tahun}$. Keyakinan berhasil 50%. Biaya tes Rp 85 juta.
- (b) Mengganti penyedia pembayaran. Biaya migrasi Rp 3 miliar, penghematan biaya Rp 1,8 miliar/tahun bila conversion tidak turun; risiko conversion turun 2% (kerugian Rp 1,3 miliar/tahun) dengan peluang 30%.
- (c) Mematuhi peraturan baru tentang tampilan harga. Wajib per 1 Januari.
- (d) Fitur baru yang membutuhkan investasi Rp 12 miliar; peluang berhasil ditaksir 35%; nilai bila berhasil Rp 40 miliar/tahun.

Answer key 7.2

- (a) EV luncurkan = $0,5 \times 80 + 0,5 \times (-80) - 5 = -5 \text{ juta}$; EV tidak luncurkan = 0. EVPI = $0,5 \times (80 - (-5)) - 0 = \text{Rp } 37,5 \text{ juta} < \text{biaya tes Rp } 85 \text{ juta}$. **Jangan menguji dan jangan meluncurkan** berdasarkan perhitungan; bila tetap ingin, ambil keputusan berbasis penilaian. Ini contoh penting: perubahan kecil sering tidak layak diuji karena biaya pengujiannya melebihi seluruh taruhannya.
- (b) Nilai keputusan besar dan asimetris. EV migrasi tanpa informasi = $0,7 \times 1,8 + 0,3 \times (1,8 - 1,3) - \text{amortisasi } 3 \text{ miliar}/3 \text{ tahun (Rp } 1,0 \text{ miliar)} = 1,26 + 0,15 - 1,0 = +0,41 \text{ miliar}$. Dengan informasi sempurna, migrasi hanya bila conversion aman: $0,7 \times (1,8 - 1,0) = 0,56$. EVPI = **Rp 150 juta**. Biaya menguji conversion penyedia pembayaran pada porsi kecil traffic jauh di bawah itu → **uji dulu dengan rollout bertahap 5%**. Ini juga contoh di mana tesnya bukan A/B klasik melainkan rollout terpantau.
- (c) **Jangan menguji untuk keputusan** — kepatuhan bersifat wajib. Tetap ukur dampaknya (dengan rollout bertahap bila memungkinkan) untuk pembelajaran dan untuk memperkirakan dampak pada rencana.
- (d) EV luncurkan = $0,35 \times 40 - 12 = +2,0 \text{ miliar}$; EVPI = $0,35 \times (40 - 12) = 9,8 \text{ miliar}$ dikurangi 2,0 = **Rp 7,8 miliar**. Sangat besar → **investasi dalam pengujian bertahap sangat dibenarkan**: bangun versi minimal, uji pada segmen, dan putuskan investasi penuh setelahnya. Pola ini — memecah keputusan besar menjadi tahap dengan titik keputusan — adalah penerapan langsung dari nilai informasi, dan menjadi pokok bahasan Volume 5.

Exercise 7.3 (Advanced · 90 menit)

Objective: rekonsiliasi klaim dengan kenyataan

Program eksperimen TokoNusa mengklaim total kenaikan conversion +18% sepanjang FY2025 dari 22 tes yang menang. Conversion aktual bergerak dari 3,05% ke 3,20% (+4,9%). Holdout global 2% menunjukkan pengguna holdout memiliki conversion 3,08%.

(a) Berapa kenaikan yang benar-benar disebabkan program? (b) Rekonsiliasi selisih antara +18% dan angka sebenarnya: alokasikan ke sumber-sumber kebocoran dengan estimasi kuantitatif. (c) Tulis satu paragraf untuk CFO. (d) Usulkan tiga perubahan proses yang akan mempersempit selisih ini tahun depan, beserta dampak yang diharapkan.

Answer key 7.3

(a) Perbandingan yang benar adalah populasi penuh versus holdout: 3,20% vs 3,08% = **+3,9% relatif** yang disebabkan program. Kenaikan total +4,9% berarti sekitar 1,0 pp relatif berasal dari faktor lain (bauran traffic, musiman, perbaikan non-eksperimen).

(b) Rekonsiliasi 18% → 3,9%, yaitu faktor 0,217. Alokasi yang masuk akal: *false positive* — dengan power rata-rata rendah dan prior 20%, sekitar 25% kemenangan adalah kebisingan ($\times 0,75$); *winner's curse* pada 22 tes yang menang ($\times 0,70$); *efek tidak aditif* karena banyak tes menyentuh funnel checkout yang sama ($\times 0,60$); *cakupan rollout* tidak penuh ($\times 0,90$); peluruhan novelty ($\times 0,85$). Hasil gabungan: $0,75 \times 0,70 \times 0,60 \times 0,90 \times 0,85 = \mathbf{0,241}$ — sangat dekat dengan 0,217 yang teramati. Kesesuaian ini penting: ia menunjukkan selisih dapat dijelaskan mekanisme yang dikenal, bukan oleh kesalahan pengukuran atau kecurangan.

(c) Paragraf untuk CFO: "Program menghasilkan +3,9% conversion terhadap kelompok holdout yang tidak menerima perubahan apa pun — ini angka yang saya rekomendasikan untuk dipakai dalam perencanaan, dan setara dengan Rp X miliar CM. Angka +18% adalah penjumlahan lift per tes, yang secara metodologis tidak pernah setara dengan dampak agregat: tes yang menang cenderung melebih-lebihkan efeknya, sebagian kemenangan adalah kebisingan statistik, dan perbaikan pada bagian funnel yang sama tidak dapat dijumlahkan. Kami sudah merinci keempat faktornya dan mereka menjelaskan hampir seluruh selisih. Mulai kuartal depan kami melaporkan angka holdout sebagai metric resmi program."

(d) Tiga perubahan: **(i)** naikkan power minimum ke 80% pada MDE yang realistis — mengurangi false positive dan winner's curse sekaligus, dampak terbesar; **(ii)** laporkan hanya angka holdout sebagai dampak program, sementara lift per tes dipakai untuk keputusan rilis saja — menghapus masalah aditivitas secara definisi; **(iii)** wajibkan holdout 6 bulan untuk setiap kemenangan bernilai di atas ambang tertentu — menangkap peluruhan sebelum masuk ke rencana.

Exercise 7.4 (Production Challenge · 4 jam)

Objective: business case lengkap

Susun proposal pembentukan program eksperimentasi untuk sebuah perusahaan (boleh TokoNusa atau perusahaan tempatmu). Muat: masalah yang diselesaikan, biaya program (orang, alat, traffic), estimasi nilai dengan komponen kemenangan dan kerugian yang dicegah, tiga skenario (pesimistis/dasar/optimistis), rencana pengukuran keberhasilan program itu sendiri (holdout global), tahapan 12 bulan, dan risiko utama beserta mitigasinya. Maksimum 3 halaman.

Answer key 7.4 — rubrik

Proposal yang kuat: memuat komponen "kerugian yang dicegah" dengan argumen yang jelas; mengukur program dengan holdout global sejak bulan pertama (bukan dengan jumlah tes yang dijalankan — metric yang langsung memicu Goodhart, Vol 3 Bab 13); memiliki skenario pesimistis yang tetap dapat dipertahankan; dan menyebut risiko organisasi (perlawanan terhadap hasil yang tidak menyenangkan, tekanan menghentikan tes lebih awal) bukan hanya risiko teknis. Kesalahan umum: menjanjikan jumlah kemenangan tertentu — janji yang tidak bisa dikendalikan dan akan menjadi beban.

Portfolio idea

★ PORTFOLIO TIP

Business case program eksperimentasi (Exercise 7.4) adalah dokumen tingkat manajer, bukan tingkat analyst. Membawanya ke wawancara untuk peran senior menunjukkan kesiapan pada tingkat berikutnya. Pastikan halaman pertamanya bisa dibaca dalam 90 detik dan memuat satu angka ROI beserta cara memverifikasinya.

Further reading

Douglas Hubbard, *How to Measure Anything* (nilai informasi untuk keputusan bisnis) · Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* (Bab 5: kecepatan iterasi dan nilai program) · Ron Kohavi tentang "Twyman's law" dan hasil yang terlalu bagus untuk dipercaya · Vol 5 buku ini (decision tree, EVSI, Monte Carlo).

Next chapter

Bab 8 membuka Bagian II. Randomisasi tidak selalu tersedia: harga sudah terlanjur naik, promo sudah berjalan, pelanggan memilih sendiri. Bab 8 mengajarkan cara memetakan struktur kausal dengan DAG, mengenali confounder dari collider, dan — yang paling penting — memutuskan metode mana yang sah dipakai.

Bab 8 — Peta Kausal: DAG & Identifikasi

Sebelum memilih metode, gambarkan dulu bagaimana dunia bekerja. Variabel mana yang harus dikendalikan — dan mana yang justru merusak analisis bila dikendalikan.

Learning objectives	Menggambar DAG dari pengetahuan domain; membedakan confounder, mediator, collider, dan proxy; menerapkan backdoor criterion untuk memilih variabel kontrol; menjelaskan mengapa mengendalikan variabel yang salah menambah bias; memilih metode identifikasi dengan pohon keputusan; menulis pernyataan asumsi identifikasi yang dapat diaudit
Prerequisites	Bab 1 (potential outcomes); Vol 2 Bab 6 (regresi berganda); Vol 3 Bab 11 (dekomposisi)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	Causal diagrams, backdoor criterion, collider & mediator detection, pemilihan metode identifikasi
Business domain	Retail omnichannel — kasus keterlambatan pengiriman dianalisis dari struktur kausalnya

Mengapa "kendalikan semua variabel yang tersedia" adalah nasihat yang salah

Refleks yang diajarkan di banyak kursus regresi: masukkan sebanyak mungkin variabel kontrol agar estimasi "bersih". Refleks ini menyebabkan tiga kelas kesalahan yang tidak dapat dideteksi dari output regresi mana pun, karena R^2 justru naik dan p-value justru mengecil.

Jenis variabel	Perannya dalam struktur kausal	Akibat bila dikendalikan
Confounder	Penyebab bersama treatment dan outcome	HARUS dikendalikan — menghapus bias
Mediator	Berada <i>di jalur</i> antara treatment dan outcome	Menghapus sebagian efek yang justru ingin diukur
Collider	Akibat bersama dari treatment dan outcome (atau dari penyebab keduanya)	MENCIPTAKAN asosiasi palsu yang sebelumnya tidak ada
Instrumen	Mempengaruhi treatment, tidak menyentuh outcome secara langsung	Menaikkan variance dan memperbesar bias sisa; jangan dikendalikan — dipakai sebagai instrumen (Bab 11)
Prediktor outcome murni	Mempengaruhi outcome saja	Aman dan berguna — menurunkan variance (dasar CUPED, Bab 6)

Tidak ada satu pun dari kategori ini yang bisa dibedakan dari korelasi dalam data. Perbedaannya hanya ada pada **pengetahuan tentang bagaimana dunia bekerja**. DAG adalah alat untuk menuliskan pengetahuan itu sehingga bisa diperdebatkan, diaudit, dan diperbaiki.

Membaca DAG: tiga struktur dasar

(1) RANTAI — mediator

$$X \rightarrow M \rightarrow Y$$

Contoh: keterlambatan $\rightarrow$ kekecewaan $\rightarrow$ churn

- Mengendalikan M MEMBLOKIR sebagian efek X pada Y.
Bila M adalah SATU-SATUNYA jalur, efek X menjadi nol.
- Kendalikan M hanya bila kamu memang ingin mengukur efek LANGSUNG X (mediation analysis) — dan sadari bahwa itu pertanyaan berbeda.

(2) GARPU — confounder

$$X \leftarrow C \rightarrow Y$$

Contoh: keterlambatan $\leftarrow$ wilayah luar Jawa $\rightarrow$ churn

- C membuka "jalur belakang" (backdoor) antara X dan Y.
- WAJIB dikendalikan (atau diblokir dengan desain).

(3) COLLIDER — akibat bersama

$$X \rightarrow K \leftarrow Y$$

Contoh: keterlambatan $\rightarrow$ komplain $\leftarrow$ ketidakpuasan produk

- Tanpa dikendalikan, jalur ini SUDAH TERBLOKIR: tidak ada asosiasi palsu.
- Mengendalikan K (atau memilih sampel berdasarkan K) MEMBUKA jalur dan MENCIPTAKAN asosiasi palsu.

■ TECHNICAL NOTE — collider bias diperagakan dengan angka

Simulasi 500.000 pelanggan. Keterlambatan (18% pelanggan) dan masalah kualitas produk (9%) dibuat *sepenuhnya independen*. Keduanya menaikkan peluang komplain ke customer service.

Korelasi telat vs masalah kualitas, SELURUH pelanggan = +0,0001

Korelasi telat vs masalah kualitas, HANYA yang komplain = -0,6046

P(masalah kualitas | telat, komplain) = 14,8%

P(masalah kualitas | tidak telat, komplain) = 75,6%

Di antara pelanggan yang komplain, keterlambatan dan masalah kualitas tampak berkorelasi kuat *negatif* — seolah-olah keterlambatan "melindungi" dari masalah kualitas. Logikanya sederhana setelah terlihat: jika seseorang komplain dan pengirimannya tepat waktu, pasti ada alasan lain, dan alasan itu kemungkinan besar kualitas produk. Asosiasi ini sepenuhnya artefak dari pemilihan sampel.

Inilah alasan mengapa **analisis yang dibatasi pada pelanggan yang komplain, yang menghubungi CS, yang mengisi survei, atau yang membatalkan langganan** hampir selalu mengandung collider bias. Kondisi masuk ke sampel adalah akibat dari banyak hal sekaligus.

✗ COMMON MISTAKE — Menganalisis hanya "pelanggan yang terdampak"

Gejala: "Di antara pelanggan yang mengajukan komplain, keterlambatan tidak berkaitan dengan churn — jadi keterlambatan bukan masalah."

Mengapa terjadi: membatasi analisis pada subset yang "relevan" terasa seperti fokus yang baik; padahal syarat masuk subset itu adalah collider.

Perbaikan: definisikan populasi analisis dari kondisi yang terjadi *sebelum* treatment, bukan sesudahnya. Semua penyaringan pasca-treatment harus diperlakukan sebagai potensi collider.

Cara senior menghindarinya: menggambar DAG dan menandai setiap variabel yang dipakai untuk menyaring sampel; bila variabel itu berada setelah treatment dalam urutan waktu, alarm menyala.


Backdoor criterion: aturan formal memilih variabel kontrol

Untuk mengestimasi efek kausal X pada Y dari data observasional, himpunan variabel kontrol Z harus memenuhi dua syarat:

1. **Z memblokir semua jalur belakang** dari X ke Y — yaitu semua jalur yang berawal dengan panah menuju X .
2. **Z tidak memuat keturunan X** — tidak ada mediator, dan tidak ada collider yang terletak setelah X .

Bila himpunan Z semacam itu ada dan seluruh anggotanya terukur, efek kausal *teridentifikasi* dan dapat diestimasi dengan regresi, matching, atau weighting (Bab 10). Bila tidak ada, tidak ada teknik statistik yang menyelamatkan — yang dibutuhkan adalah desain berbeda (Bab 9, 11, 12).

Penerapan: DAG untuk kasus keterlambatan → churn



Jalur belakang yang harus diblokir:

- Keterlambatan ← wilayah → churn → kendalikan wilayah ✓
- Keterlambatan ← kategori/berat → churn → kendalikan kategori ✓
- Keterlambatan ← nilai order → churn → kendalikan nilai ✓
- Keterlambatan ← niat berhenti → churn → TIDAK BISA (tak terukur) ✗

KESIMPULAN IDENTIFIKASI:

Backdoor criterion TIDAK terpenuhi. Regresi/matching akan tetap bias ke atas. Diperlukan instrumen — dan kapasitas hub kurir adalah kandidatnya (Bab 11).

◆ BUSINESS INSIGHT — DAG sebagai alat percakapan, bukan alat matematika

Nilai terbesar DAG bukan pada teoremanya, melainkan pada apa yang terjadi ketika digambar bersama tim operasional. Pertanyaan "apa yang menentukan sebuah order menjadi terlambat?" dijawab oleh manajer logistik dalam dua menit dengan daftar yang tidak akan pernah ditemukan seorang analyst dari data saja — termasuk keberadaan variabel "niat berhenti" yang tidak tercatat di mana pun.

DAG mengubah asumsi yang tersembunyi di dalam spesifikasi regresi menjadi gambar yang bisa dibantah oleh orang yang paling tahu bisnisnya. Itu adalah pemindahan yang sangat menguntungkan.

Empat kesalahan pengendalian variabel yang paling mahal

Kesalahan	Contoh nyata	Akibat
Mengendalikan mediator	Mengukur efek program loyalitas pada revenue sambil mengendalikan frekuensi	Efek terlihat mendekati nol; kesimpulan "program tidak bekerja" salah total

	kunjungan — padahal program bekerja <i>lewat</i> frekuensi	
Mengendalikan collider	Membatasi analisis pada pelanggan yang mengisi survei, komplain, atau yang membeli	Menciptakan asosiasi yang tidak ada; arah bias tidak dapat diprediksi
Mengendalikan variabel pasca-treatment apa pun	Mengendalikan "apakah pelanggan menggunakan fitur" saat mengukur efek peluncuran fitur	Bentuk umum dari dua kesalahan di atas; aturan praktis: variabel yang terjadi setelah treatment tidak boleh menjadi kontrol
Melewatkan confounder tak terukur	Niat berhenti, motivasi, informasi privat pelanggan atau manajer	Bias sisa yang tidak terlihat; ini alasan utama metode Bab 10 harus dilaporkan sebagai "asosiasi setelah penyesuaian"

⚠ WARNING — "Tabel 2 fallacy"

Dalam satu regresi, hanya koefisien *satu* variabel yang dapat ditafsirkan secara kausal — yaitu variabel yang untuknya himpunan kontrolnya dipilih. Koefisien variabel kontrol lain di tabel yang sama **tidak** memiliki tafsir kausal, karena himpunan kontrol untuk mereka berbeda. Melaporkan seluruh kolom koefisien seolah-olah semuanya efek kausal adalah kesalahan yang sangat umum di laporan bisnis dan skripsi. Aturan praktis: satu regresi menjawab satu pertanyaan kausal.

Memilih metode identifikasi

Setelah DAG digambar, pemilihan metode menjadi mekanis. Pohon berikut adalah versi lengkap dari peta di halaman pembuka volume ini.

MULAI: Apakah kita bisa mengacak penugasan X? (sekarang atau ke depan)

— YA —————→ A/B TEST / RCT Bab 2–7
(bukti tingkat 1)

— TIDAK. Lanjutkan:

— Apakah X mulai berlaku pada WAKTU tertentu untuk sekelompok unit, sementara unit lain tidak?

— YA → DIFFERENCE-IN-DIFFERENCES Bab 9

Syarat: tren paralel pra-treatment

Bila unit treatment sedikit (1–5):

— SYNTHETIC CONTROL Bab 9

Bila semua unit terkena serentak:

— INTERRUPTED TIME SERIES Bab 9
(asumsi lebih berat)

— Apakah X ditentukan oleh AMBANG TAJAM pada suatu skor?

— YA → REGRESSION DISCONTINUITY Bab 11

Syarat: tidak ada manipulasi skor di ambang
(uji densitas WAJIB)

— Adakah variabel Z yang menggeser X tetapi tidak menyentuh Y kecuali lewat X?

— YA → INSTRUMENTAL VARIABLES Bab 11

Syarat: relevansi ($F > 10$), exclusion, independensi. Estimand = LATE.

— Apakah X bocor antar unit / bersaing atas sumber daya?

— YA → GEO EXPERIMENT / SWITCHBACK Bab 12

— Apakah SEMUA confounder terukur dan tercatat?

— YA (jarang benar) → PROPENSITY SCORE /
REGRESI / DOUBLY ROBUST Bab 10

Wajib: analisis sensitivitas

└ TIDAK satu pun terpenuhi

└ JANGAN mengklaim kausal.

└ Laporkan asosiasi + arah bias yang diperkirakan + rancang eksperimen atau instrumentasi ke depan.

Menulis pernyataan asumsi identifikasi

Setiap analisis kausal observasional harus memuat satu paragraf eksplisit yang dapat diaudit. Formatnya tetap dan pendek.

PERNYATAAN IDENTIFIKASI – analisis keterlambatan → churn

ESTIMAND ATT: efek keterlambatan pada probabilitas churn 180 hari, pada order yang benar-benar mengalami keterlambatan.

STRATEGI Instrumental variable. Instrumen: kapasitas hub kurir pada hari pemesanan (deviasi dari rata-rata musiman).

ASUMSI YANG DIPERLUKAN

1. RELEVANSI Kapasitas hub mempengaruhi keterlambatan. DAPAT DIUJI: first-stage $F = 15.598$ (syarat >10). ✓
2. EXCLUSION Kapasitas hub tidak mempengaruhi churn kecuali lewat keterlambatan. TIDAK DAPAT DIUJI. Argumen: pelanggan tidak mengetahui kapasitas hub; tidak ada perubahan harga, promosi, atau komunikasi yang terkait. ANCAMAN: bila kapasitas rendah juga menyebabkan kesalahan pengemasan, exclusion dilanggar. PEMERIKSAAN: tingkat kesalahan pengemasan tidak berkorelasi dengan kapasitas hub ($r = 0,03$). ✓
3. INDEPENDENSI Kapasitas hub tidak berkaitan dengan karakteristik pelanggan. DAPAT DIPERIKSA sebagian: keseimbangan kovariat pelanggan antar tingkat kapasitas. ✓
4. MONOTONISITAS Tidak ada order yang justru lebih cepat karena kapasitas rendah. Masuk akal secara operasional. ✓

APA YANG MEMBATALKAN KESIMPULAN INI

Bukti bahwa hub berkapasitas rendah juga menurunkan kualitas layanan lain (pengemasan, akurasi, komunikasi). Bila ditemukan, estimasi menjadi batas atas, bukan efek keterlambatan murni.

✓ BEST PRACTICE — Baris "apa yang membatalkan kesimpulan ini"

Menuliskan sendiri kondisi yang akan meruntuhkan analisismu melakukan tiga hal sekaligus: memaksa berpikir tentang ancaman secara serius, mencegah orang lain menemukannya lebih dulu di forum publik, dan memberi tim cara konkret untuk memperkuat atau menolak temuan. Ini adalah kebiasaan tunggal yang paling membedakan analisis kausal profesional dari analisis yang sekadar memakai nama teknik yang mengesankan.

Front-door dan strategi lain ketika backdoor tertutup

Ketika confounder tidak terukur, masih ada beberapa jalan keluar selain menyerah — meski semuanya menuntut struktur khusus.

Strategi	Struktur yang dibutuhkan	Contoh
----------	--------------------------	--------

Front-door	Ada mediator M yang menangkap seluruh efek X pada Y, dan M tidak terkonfound dengan Y	Efek iklan → ingatan merek → pembelian, di mana ingatan merek diukur dan tidak dipengaruhi confounder yang sama
Negative control	Ada outcome yang seharusnya <i>tidak</i> terpengaruh treatment	Jika keterlambatan menyebabkan churn, ia seharusnya tidak mempengaruhi churn pada periode <i>sebelum</i> keterlambatan terjadi — memeriksanya mengungkap bias sisa
Bounding / analisis sensitivitas	Tidak butuh struktur; menghitung seberapa kuat confounder tak terukur harus agar kesimpulan berubah	E-value (Bab 10)
Triangulasi	Beberapa metode dengan asumsi <i>berbeda</i> memberi jawaban serupa	Kasus keterlambatan: regresi, propensity, IV, dan eksperimen SLA — bila semua menunjuk arah dan besaran yang mirip, keyakinan naik jauh

► **EXECUTIVE PERSPECTIVE — triangulasi adalah argumen yang paling meyakinkan**

Satu estimasi dari satu metode canggih jarang mengubah keyakinan seorang eksekutif. Tiga estimasi dari tiga metode dengan kelemahan yang berbeda, yang semuanya berkumpul di kisaran yang sama, hampir selalu berhasil. Struktur presentasi yang bekerja: "Angka mentah 19,1 pp jelas terlalu besar. Setelah penyesuaian confounder terukur: 8,2 pp. Dengan instrumen yang tidak bergantung pada asumsi itu: 4,0 pp. Ketiganya positif dan arah biasanya konsisten dengan teori. Saya merekomendasikan bekerja dengan angka 4 pp — yang paling konservatif dan paling dapat dipertahankan."

Checklist analisis kausal observasional

- ✓ DAG digambar sebelum model apa pun dijalankan, dan didiskusikan dengan pemilik domain
- ✓ Setiap variabel kontrol diklasifikasikan: confounder, mediator, collider, instrumen, atau prediktor outcome
- ✓ Tidak ada variabel pasca-treatment yang masuk sebagai kontrol
- ✓ Penyaringan sampel diperiksa terhadap collider bias
- ✓ Confounder tak terukur diidentifikasi dan disebut namanya, bukan diabaikan
- ✓ Metode dipilih lewat pohon keputusan, bukan lewat kebiasaan atau ketersediaan library
- ✓ Pernyataan asumsi identifikasi ditulis, termasuk asumsi yang tidak dapat diuji
- ✓ Baris "apa yang membatalkan kesimpulan ini" ada dan spesifik
- ✓ Minimal satu negative control atau falsification test dijalankan
- ✓ Bila memungkinkan, triangulasi dua metode dengan asumsi berbeda

Ending Card — Bab 8

What you learned

Lima peran variabel dan akibat mengendalikannya masing-masing; tiga struktur DAG (rantai, garpu, collider) dan aturan bloknya; peragaan numerik collider bias; backdoor criterion dan penerapannya pada kasus keterlambatan; empat kesalahan pengendalian variabel; Tabel 2 fallacy; pohon keputusan pemilihan metode identifikasi; format pernyataan asumsi identifikasi; front-door, negative control, bounding, dan triangulasi.

Skills mastered

Pemodelan kausal dengan DAG · pemilihan variabel kontrol yang benar · pemilihan metode identifikasi · penulisan asumsi yang dapat diaudit.

Real business value

DAG mencegah dua kesalahan yang sama-sama mahal: gagal mengendalikan confounder (melebih-lebihkan efek) dan mengendalikan mediator (menghapus efek yang nyata). Keduanya rutin terjadi di analisis bisnis, dan keduanya tidak terlihat dari output model.

Interview readiness

● INTERVIEW QUESTIONS

1. "Kapan menambahkan variabel kontrol memperburuk analisis?" (Mediator, collider, variabel pasca-treatment, instrumen. Jawaban yang lengkap menyebut keempatnya.)
2. "Apa itu collider bias — beri contoh dari pekerjaan analytics." (Analisis pada pelanggan yang komplain/mengisi survei/membeli; jelaskan mekanisme dengan angka bila bisa.)
3. "Kami mengukur efek program loyalitas dan mengendalikan frekuensi kunjungan. Ada masalah?" (Frekuensi adalah mediator; efek akan hilang.)
4. "Bagaimana kamu memutuskan metode kausal mana yang dipakai?" (Jalankan pohon keputusan dengan lantang; sebutkan syarat masing-masing.)
5. "Apa yang kamu lakukan bila confounder utamanya tidak terukur?" (Cari instrumen atau desain quasi-eksperimental; jika tidak ada, analisis sensitivitas dan pelaporan sebagai asosiasi; usulkan instrumentasi ke depan.)

Exercises

Exercise 8.1 (Beginner · 25 menit)

Objective: klasifikasi peran variabel

Kita ingin mengukur efek **diskon** pada **revenue per pelanggan**. Klasifikasikan tiap variabel (confounder / mediator / collider / prediktor outcome / instrumen) dan tentukan apakah harus dikendalikan:

- (a) musim (Ramadan, Harbolnas) · (b) jumlah item dalam keranjang · (c) segmen pelanggan berdasarkan riwayat tahun lalu · (d) apakah pelanggan mengklik email promo · (e) kesalahan sistem yang menyebabkan sebagian pelanggan tidak menerima diskon · (f) apakah pelanggan mengajukan retur.

Answer key 8.1

(a) **Confounder** — musim mempengaruhi kebijakan diskon dan revenue. Kendalikan. (b) **Mediator** — diskon menaikkan jumlah item, yang menaikkan revenue. Jangan dikendalikan bila ingin efek total. (c) **Prediktor outcome** (dan mungkin confounder bila menentukan penargetan diskon). Aman dan berguna; kendalikan. (d) **Mediator** — klik terjadi setelah diskon ditawarkan. Jangan dikendalikan. (e) **Instrumen** — kesalahan sistem menggeser penerimaan diskon tanpa alasan yang berkaitan dengan pelanggan. Jangan dikendalikan; pakai sebagai instrumen (Bab 11). Ini contoh "eksperimen alami" yang sangat bernilai dan sering terlewat. (f) **Collider** — retur dipengaruhi diskon dan juga oleh hal-hal yang mempengaruhi revenue. Jangan disaring atasnya.

Exercise 8.2 (Intermediate · 50 menit)

Objective: menggambar DAG dan menerapkan backdoor

TokoNusa ingin mengetahui apakah **pemasangan aplikasi mobile** menyebabkan **kenaikan frekuensi belanja**. Variabel yang tersedia: usia akun, kota, riwayat belanja 12 bulan, jenis perangkat, apakah pernah menerima kampanye instalasi, apakah pelanggan mengaktifkan notifikasi, jumlah kunjungan situs setelah instalasi.

(a) Gambarkan DAG-nya (ASCII cukup), termasuk minimal satu confounder tak terukur yang kamu namai. (b) Tentukan himpunan kontrol yang memenuhi backdoor criterion, atau jelaskan mengapa tidak ada. (c) Tentukan variabel mana yang tidak boleh dikendalikan dan mengapa. (d) Usulkan strategi identifikasi yang lebih baik.

Answer key 8.2

(a) DAG inti: *minat/loyalitas laten* (tak terukur) → instalasi aplikasi, dan → frekuensi belanja. Riwayat belanja 12 bulan adalah **proxy** untuk minat laten (berguna tapi tidak sempurna). Kampanye instalasi → instalasi (kandidat instrumen bila penargetannya tidak berdasarkan minat). Notifikasi dan kunjungan pasca-instalasi adalah **mediator**.

(b) Backdoor **tidak terpenuhi**: minat laten tidak terukur, dan riwayat belanja hanya menangkap sebagiannya. Penyesuaian atas riwayat akan mengurangi bias tetapi tidak menghapusnya — estimasi tetap batas atas.

(c) Tidak boleh dikendalikan: **notifikasi** dan **kunjungan setelah instalasi** (mediator — mereka adalah cara aplikasi bekerja); dan **kampanye instalasi** bila akan dipakai sebagai instrumen.

(d) Strategi lebih baik: **encouragement design** — acak siapa yang menerima kampanye instalasi, lalu gunakan penugasan acak itu sebagai instrumen untuk instalasi (Bab 11). ITT-nya sekaligus menjawab pertanyaan keputusan yang sebenarnya ("apakah membiayai kampanye instalasi menguntungkan?"), yang sering lebih relevan daripada efek instalasi itu sendiri. Alternatif tanpa eksperimen: RDD bila ada ambang dalam aturan penargetan kampanye.

Exercise 8.3 (Advanced · 90 menit)

Objective: audit analisis orang lain

Sebuah tim melaporkan: "Regresi churn terhadap keterlambatan, dengan kontrol wilayah, kategori, nilai order, frekuensi historis, jumlah komplain, dan skor kepuasan survei, menunjukkan efek keterlambatan +3,1 pp ($p < 0,001$). Kami merekomendasikan investasi Rp 40 miliar untuk perbaikan logistik."

(a) Identifikasi minimal tiga masalah struktural dalam spesifikasi ini. (b) Perkirakan arah bias masing-masing. (c) Tulis versi analisis yang benar beserta himpunan kontrolnya. (d) Tulis paragraf tanggapan kepada tim tersebut yang konstruktif namun jelas.

Answer key 8.3

(a) Tiga masalah: **(i) Jumlah komplain adalah collider dan sekaligus mediator** — ia dipengaruhi keterlambatan dan juga oleh ketidakpuasan yang menyebabkan churn; mengendalikannya memblokir jalur sebab sekaligus menciptakan asosiasi palsu. **(ii) Skor kepuasan survei** terjadi setelah treatment (mediator) dan hanya tersedia untuk responden (selection/collider ganda). **(iii) Confounder tak terukur** (niat berhenti) tidak disebut sama sekali, sehingga asumsi identifikasi tidak dinyatakan.

(b) Arah bias: mengendalikan komplain dan kepuasan **menurunkan** estimasi (memblokir mekanisme), sehingga 3,1 pp kemungkinan *terlalu kecil* untuk efek total; sementara confounder tak terukur **menaikkan** estimasi. Kedua bias berlawanan arah — itulah sebabnya angka yang kebetulan "masuk akal" tidak boleh dianggap benar. Ketidaktahuan tentang besaran relatif kedua bias adalah alasan analisis ini tidak dapat dipakai untuk keputusan Rp 40 miliar.

(c) Analisis yang benar: kontrol hanya pra-treatment — wilayah, kategori/berat, nilai order, frekuensi dan recency historis, tenure. Hilangkan komplain dan skor kepuasan. Laporkan hasilnya sebagai *asosiasi setelah penyesuaian* (8,2 pp pada data kita). Lalu jalankan IV dengan kapasitas hub (4,0 pp) dan bandingkan. Sertakan analisis sensitivitas (E-value) dan negative control (efek keterlambatan pada churn periode *sebelumnya* harus nol).

(d) Tanggapan konstruktif: "Analisis ini menangkap masalah nyata dan arah temuannya saya yakini benar. Tiga variabel kontrol — komplain, kepuasan, dan implicitly apa pun yang terjadi setelah pengiriman — perlu dikeluarkan karena berada setelah treatment; keberadaannya justru menutupi sebagian efek yang ingin kita ukur. Saya sudah menjalankan versi tanpa ketiganya dan dengan instrumen kapasitas hub; hasilnya berkisar 4–8 pp. Untuk keputusan Rp 40 miliar saya sarankan memakai batas bawah 4 pp — dan nilai bisnisnya tetap kuat: Rp 6,9 miliar CLV per tahun. Mari kita rapikan bersama sebelum masuk ke komite investasi."

Exercise 8.4 (Production Challenge · 4 jam)

Objective: portfolio causal audit

Pilih satu pertanyaan bisnis nyata dari pekerjaan atau dataset publik. Hasilkan: (1) DAG lengkap dengan minimal 8 variabel termasuk yang tak terukur; (2) klasifikasi peran setiap variabel; (3) analisis backdoor beserta kesimpulan identifikasi; (4) pemilihan metode dengan pohon keputusan; (5) pernyataan asumsi identifikasi lengkap dengan baris pembatal; (6) rancangan negative control. Ini adalah perluasan dari Exercise 1.4 dan menjadi inti portfolio "causal audit".

Answer key 8.4 — rubrik

Dokumen yang kuat: DAG memuat variabel tak terukur yang *dinamai secara spesifik* (bukan "faktor lain"); kesimpulan identifikasi berani menyatakan "tidak teridentifikasi" bila memang demikian; metode yang dipilih konsisten dengan struktur DAG, bukan dengan preferensi penulis; dan negative control-nya dapat benar-benar dijalankan dari data yang ada. Kesalahan umum: menggambar DAG setelah memilih metode, sehingga DAG hanya menjadi pembenaran — urutannya harus terbalik, dan kejujuran urutan ini akan terlihat dari apakah dokumennya pernah menyimpulkan "metode favorit saya ternyata tidak sah di sini".

Portfolio idea

★ PORTFOLIO TIP

Gabungkan Exercise 1.4 dan 8.4 menjadi satu dokumen "Causal Audit Portfolio": lima klaim yang diaudit, satu di antaranya dianalisis penuh dengan DAG dan strategi identifikasi. Dokumen ini menempatkan kandidat pada kelompok yang sangat kecil — sebagian besar pelamar analytics tidak pernah menulis DAG sekali pun.

Further reading

Judea Pearl, *Causality* (rujukan formal) dan *The Book of Why* (pengantar) · Cinelli, Forney & Pearl, "A Crash Course in Good and Bad Controls" (esai pendek yang wajib dibaca) · Scott Cunningham, *Causal Inference: The Mixtape* (bab DAG) · Hernán & Robins, *Causal Inference: What If* (versi daring gratis) · alat DAGitty untuk menggambar dan menguji backdoor secara otomatis.

Next chapter

Bab 9 — metode paling banyak dipakai di dunia bisnis untuk pertanyaan kausal tanpa randomisasi. Difference-in-differences, event study, dan synthetic control; dengan kasus flash sale TokoNusa yang dijanjikan sejak Volume 3.

Bab 9 — Difference-in-Differences, Event Study, dan Synthetic Control

Metode yang paling sering dipakai untuk menjawab "apa dampak kebijakan yang sudah terlanjur berjalan" — beserta asumsi yang menentukan apakah jawabannya berarti.

Learning objectives	Menghitung dan menafsirkan estimator difference-in-differences; menguji asumsi tren paralel lewat event study; mengenali situasi di mana DiD gagal (ancaman, adopsi bertahap, komposisi berubah); membangun synthetic control dan menjalankan uji placebo; memilih antara DiD, synthetic control, dan interrupted time series; menerjemahkan hasilnya menjadi keputusan bisnis
Prerequisites	Bab 8 (DAG, identifikasi); Vol 2 Bab 6 (regresi); Vol 3 Bab 4 (contribution margin)
Estimasi waktu	Baca 3 jam · Praktik 5 jam
Difficulty	● Advanced
Skills covered	DiD estimation, parallel trends testing, event study, synthetic control, placebo inference, cluster-robust SE
Business domain	Retail — flash sale mingguan di 39 dari 85 toko TokoNusa (kasus yang dijanjikan sejak Vol 3 Bab 9 dan 11)

Masalah yang diselesaikan DiD

TokoNusa meluncurkan program flash sale mingguan di 39 toko mulai minggu ke-14. Pertanyaan direksi: berapa dampaknya terhadap penjualan dan margin? Dua jawaban naif yang keduanya salah:

NAIF 1 – Before/after pada toko yang menerima flash sale
revenue sesudah – revenue sebelum = +8,53%
MASALAH: tren umum, musim, dan inflasi ikut terhitung.

NAIF 2 – Perbandingan lintas toko pada periode sesudah
toko flash sale – toko lain = +28,40%
MASALAH: toko flash sale memang dipilih karena LEBIH BESAR.
Perbedaan ini sebagian besar sudah ada sebelumnya.

DiD – mengurangi kedua sumber bias sekaligus
(sesudah – sebelum)_{treatment} – (sesudah – sebelum)_{kontrol}
= +6,39% (CI 95%: +5,42% s/d +7,36%)

Gagasan DiD sederhana: kelompok kontrol tidak dipakai untuk mengukur *tingkat* penjualan (yang memang berbeda), melainkan untuk mengukur *perubahan* yang akan terjadi pada kelompok treatment seandainya tidak ada treatment. Perbedaan permanen antar toko lenyap saat dikurangkan; yang tersisa adalah selisih perubahan.

Bentuk regresi

$$Y_{it} = \alpha_i + \lambda_t + \beta \cdot D_{it} + \varepsilon_{it}$$

α_i = efek tetap unit (toko) – menyerap semua perbedaan

permanen antar toko
 λ_t = efek tetap waktu (minggu) – menyerap tren dan musim
 yang menimpa semua toko
 $D_{it} = 1$ bila toko i pada minggu t sedang menerima treatment
 β = estimasi DiD (ATT)

Standard error WAJIB di-cluster pada tingkat unit (toko),
 karena observasi dari toko yang sama berkorelasi antar waktu.
 Mengabaikan ini adalah kesalahan paling umum pada DiD dan
 dapat mengecilkan SE beberapa kali lipat.

⚠ WARNING — Cluster-robust standard error bukan opsi

Panel 85 toko $\times$ 26 minggu memberi 2.210 baris. Tanpa clustering, software akan memperlakukannya sebagai 2.210 informasi independen; kenyataannya hanya ada 85 unit yang benar-benar independen. Akibatnya SE terlalu kecil dan hampir semua hasil tampak signifikan. Aturan: **cluster pada tingkat di mana treatment ditugaskan**. Bila jumlah klaster kecil (di bawah ± 40), pertimbangkan wild cluster bootstrap karena aproksimasi asimtotik menjadi tidak akurat.

Asumsi kunci: tren paralel

DiD valid bila — *seandainya tidak ada flash sale* — penjualan toko treatment akan bergerak paralel dengan toko kontrol. Asumsi ini tidak dapat diuji secara langsung (ia tentang dunia yang tidak terjadi), tetapi dapat **diperiksa** pada periode sebelum treatment.


Event study: cara memeriksa yang benar

Alih-alih satu koefisien β , estimasi satu koefisien untuk setiap periode relatif terhadap awal treatment, dengan periode $t-1$ sebagai acuan.

Koefisien event study – log revenue toko, % relatif thd $t-1$
 (85 toko, 26 minggu, SE cluster pada toko)

t-6 : +0,29	(SE 1,23)	} PRA-TREATMENT semua dekat nol dan tidak signifikan → tren paralel TIDAK TERBANTAHKAN ✓
t-5 : +0,41	(SE 1,18)	
t-4 : +2,08	(SE 1,27)	
t-3 : -0,61	(SE 1,13)	
t-2 : -0,74	(SE 1,08)	
t-1 : 0	(acuan)	
t+0 : +7,62	(SE 1,22)	} PASCA-TREATMENT lompatan tajam pada $t=0$, lalu stabil di 6–7%
t+1 : +7,43	(SE 1,20)	
t+2 : +7,55	(SE 1,20)	
t+3 : +6,57	(SE 1,13)	
t+4 : +7,04	(SE 1,23)	
t+5 : +6,33	(SE 1,25)	
t+6 : +6,38	(SE 1,05)	

Grafik yang sama, digambar:



✓ **BEST PRACTICE — Grafik event study adalah bukti, bukan pelengkap**

Sertakan grafik ini di setiap laporan DiD, sebelum angka β . Ia melakukan tiga hal sekaligus: menunjukkan bahwa tren paralel masuk akal, menunjukkan kapan efek mulai (dan bahwa ia mulai *tepat* saat treatment, bukan sebelumnya), dan menunjukkan apakah efeknya bertahan atau meluruh. Analisis DiD tanpa event study harus diperlakukan dengan kecurigaan — koefisien tunggal dapat menyembunyikan pra-tren yang meruntuhkan seluruh klaim.

Ancaman terhadap tren paralel

Ancaman	Contoh	Cara mendeteksi / menangani
Pra-tren yang berbeda	Toko treatment memang sedang tumbuh lebih cepat sebelum program	Event study; bila terdeteksi, DiD tidak sah. Pertimbangkan synthetic control atau DiD dengan tren spesifik unit (dengan hati-hati)
Ashenfelter's dip	Program diberikan justru pada toko yang baru saja turun kinerjanya → pemulihan alami terhitung sebagai efek	Terlihat sebagai penurunan pada $t-1$, $t-2$ di event study; ini pola yang harus dicari secara khusus
Guncangan bersamaan	Kompetitor buka gerai di wilayah toko treatment pada minggu yang sama	Wawancara lapangan; periksa apakah efek terkonsentrasi pada wilayah tertentu
Komposisi berubah	Toko baru dibuka atau ditutup selama periode analisis	Gunakan panel seimbang (unit yang sama sepanjang periode) sebagai analisis utama
Limpahan ke kontrol	Pelanggan berpindah dari toko kontrol ke toko flash sale terdekat	Analisis terpisah untuk toko kontrol berdasarkan jarak ke toko treatment terdekat; bila kontrol yang dekat memburuk, ada kanibalisasi
Antisipasi	Toko mulai menahan diskon sebelum program dimulai	Kecualikan beberapa periode sebelum treatment dari acuan; periksa $t-1$, $t-2$ secara khusus
Adopsi bertahap	Toko masuk program pada waktu berbeda-beda	Estimator DiD dua arah klasik bisa bias serius; gunakan estimator modern (Callaway-Sant'Anna, Sun-Abraham)

■ **TECHNICAL NOTE — masalah adopsi bertahap (staggered adoption)**

Ketika unit menerima treatment pada waktu berbeda, regresi two-way fixed effects membandingkan sebagian unit yang *sudah* di-treat dengan unit yang *baru* di-treat. Bila efek treatment berubah seiring waktu, perbandingan itu memasukkan bobot negatif dan estimasi β dapat berlawanan tanda dengan efek sebenarnya pada setiap unit. Ini temuan metodologis penting yang menjadi standar sejak akhir 2010-an. Gejala yang harus memicu kewaspadaan: **tanggal mulai treatment berbeda antar unit**. Penanganannya: estimator yang membandingkan unit yang baru di-treat hanya dengan unit yang belum pernah di-treat, lalu mengagregasi dengan bobot yang benar.

Kasus lengkap: flash sale TokoNusa

Desain analisis

UNIT	85 toko × 26 minggu (panel seimbang)
TREATMENT	39 toko menerima flash sale mingguan mulai minggu 14 (seluruhnya serentak – tidak ada masalah adopsi bertahap)
OUTCOME 1	log(revenue mingguan per toko)
OUTCOME 2	gross margin % per toko-minggu

SPEKIFIKASI $Y \sim D + \text{efek tetap toko} + \text{efek tetap minggu}$

SE cluster pada toko

ESTIMAND ATT – efek pada toko yang menerima program

HASIL

Revenue : +6,39% (SE 0,49; CI 95% +5,42% s/d +7,36%)

Gross margin : -1,095 pp (SE 0,099; CI -1,289 s/d -0,900 pp)

EVENT STUDY pra-tren datar; lompatan tepat pada minggu treatment;
efek stabil selama 6 minggu berikutnya (tidak meluruh)

Ekonomi keputusan – inilah bagian yang menentukan

Basis: 39 toko treatment, revenue pra-program Rp 367 juta/toko/minggu

Revenue tahunan basis = $367 \times 39 \times 52 = \text{Rp } 744,3 \text{ miliar}$

A. Tambahan revenue $744,3 \times 6,39\% = \text{Rp } 47,6 \text{ M}$

B. Margin baru $30,2\% - 1,095 \text{ pp} = 29,105\%$

Gross profit TANPA program $744,3 \times 30,2\% = \text{Rp } 224,8 \text{ M}$

Gross profit DENGAN $(744,3 + 47,6) \times 29,105\% = \text{Rp } 230,4 \text{ M}$

Selisih gross profit = Rp +5,6 M

C. Biaya operasional tambahan (lembur gudang & toko,
pengemasan, beban sistem – konsisten dengan temuan
Vol 3 Bab 11 tentang kenaikan gaji gudang) = Rp -4,2 M

DAMPAK BERSIH TAHUNAN = Rp +1,4 M

Terhadap EBITDA FY2025 (Rp 104 M): +1,3%. Nyaris impas.

◆ BUSINESS INSIGHT — jawaban atas pertanyaan yang digantung sejak Volume 3

Vol 3 Bab 11 menemukan bahwa 71% penurunan EBITDA dijelaskan kenaikan intensitas diskon dari 4,1% ke 5,3% — kenaikan 1,2 pp — dan menutup dengan rekomendasi: "uji terkontrol flash sale dengan matematika CM; lanjut hanya jika incremental CM > 0."

DiD di sini menjawabnya, dan sekaligus memberi konfirmasi silang yang menyenangkan: erosi margin yang diestimasi secara independen dengan metode kausal (**-1,095 pp**) hampir persis sama dengan kenaikan intensitas diskon yang ditemukan lewat dekomposisi akuntansi (**+1,2 pp**). Dua metode dengan asumsi yang sama sekali berbeda menunjuk angka yang sama — inilah triangulasi yang disebut di Bab 8.

Kesimpulan bisnis: flash sale menghasilkan volume yang nyata (bukan sekadar memindahkan penjualan antar toko — dibuktikan oleh pemeriksaan limpahan) tetapi menukarnya dengan margin hampir setara. Dampak bersihnya +Rp 1,4 miliar, di dalam rentang ketidakpastian dari nol. Rekomendasi yang jujur: *program ini bukan mesin pertumbuhan; ia netral secara ekonomi*. Keputusan melanjutkan harus didasarkan pada tujuan lain yang dinyatakan terbuka — akuisisi pelanggan baru, pertahanan pangsa pasar terhadap kompetitor — bukan pada keyakinan bahwa ia menaikkan laba.

► EXECUTIVE PERSPECTIVE — menyampaikan hasil yang "netral"

Hasil netral adalah hasil yang paling sulit disampaikan karena tidak ada yang menang. Struktur yang bekerja: mulai dengan apa yang *berhasil* ("program menaikkan penjualan 6,4% — itu nyata dan terukur"), lalu tunjukkan trade-off-nya dengan angka, lalu berikan pertanyaan keputusan yang tepat ("pertanyaannya bukan apakah program bekerja, melainkan apakah menukar 1,1 pp margin dengan 6,4% volume adalah pertukaran yang kita inginkan — dan itu bergantung pada apakah tujuan kita laba atau pangsa pasar"). Analyst yang mengubah hasil netral menjadi pertanyaan strategis yang tajam memberi nilai lebih besar daripada analyst yang membawa kemenangan.

Synthetic control: ketika unit treatment hanya satu atau sedikit

DiD membutuhkan cukup banyak unit di kedua sisi. Ketika hanya satu kota, satu toko unggulan, atau satu lini produk yang menerima treatment, tidak ada kelompok kontrol yang memadai — tetapi kontrol dapat dibangun.

IDE: cari kombinasi tertimbang dari unit-unit donor sehingga gabungannya menyerupai unit treatment SEBELUM treatment. Kombinasi itu menjadi counterfactual setelahnya.

$$\text{Kota treatment} \approx 0,45 \times \text{Kota C} + 0,32 \times \text{Kota H} + 0,13 \times \text{Kota N} + \text{bobot kecil lainnya}$$

Bobot dipilih untuk meminimumkan selisih pada periode PRA.
Bobot dibatasi non-negatif dan berjumlah 1 → mencegah ekstrapolasi di luar rentang data donor.

Contoh terverifikasi: 20 kota donor, 40 minggu, treatment mulai minggu 29

Bobot terpilih : kota #2 = 0,447 · kota #7 = 0,316 · kota #13 = 0,132
(sisanya bobot kecil; 15 dari 20 donor berbobot nol)

RMSE pra-treatment = 0,913
Selisih rata-rata pasca-treatment = -4,618
Efek yang sebenarnya ditanamkan = -4,500 ✓ pulih dengan baik

UJI PLACEBO IN-SPACE

Ulangi prosedur dengan memperlakukan tiap kota donor sebagai "treatment" palsu. Bandingkan besar selisihnya dengan selisih kota sungguhan.

15 kota lolos filter kecocokan pra-treatment.

p-value permutasi = 0,062

■ TECHNICAL NOTE — inferensi pada synthetic control

Dengan satu unit treatment, tidak ada standard error dalam pengertian biasa. Inferensinya dilakukan lewat **permutasi**: jika efek pada unit sungguhan tidak lebih besar daripada efek "palsu" pada unit donor, temuan itu tidak dapat dibedakan dari kebisingan. p-value permutasi minimum yang dapat dicapai adalah $1/(\text{jumlah donor} + 1)$ — dengan 20 donor, p tidak bisa lebih kecil dari 0,048. Konsekuensi praktis: **synthetic control membutuhkan donor pool yang besar**, dan hasil dengan sedikit donor tidak akan pernah mencapai signifikansi konvensional betapapun besar efeknya.

Diagnostik wajib untuk synthetic control

- **Kecocokan pra-treatment.** RMSE pra harus kecil relatif terhadap efek yang diklaim. Bila kecocokan buruk, seluruh analisis tidak berarti.
- **Panjang periode pra.** Minimal 10-15 periode; kecocokan pada periode pendek mudah terjadi secara kebetulan.
- **Kualitas donor pool.** Donor harus unit yang tidak terkena treatment maupun limbahnya, dan berasal dari lingkungan yang serupa.
- **Placebo in-space** (donor sebagai treatment palsu) dan **placebo in-time** (memajukan tanggal treatment ke periode pra — efeknya harus nol).
- **Leave-one-out.** Hapus donor berbobot terbesar dan hitung ulang; hasil yang bergantung pada satu donor rapuh.

Memilih di antara ketiga metode panel

Metode	Kapan dipakai	Asumsi utama	Kelemahan
Difference-in-differences	Banyak unit treatment dan banyak unit kontrol; treatment serentak	Tren paralel	Rusak bila pra-tren berbeda atau adopsi bertahap
Synthetic control	Satu atau sedikit unit treatment; banyak donor; periode pra panjang	Kecocokan pra-treatment mencerminkan hubungan yang stabil	Inferensi lemah; butuh donor pool besar
Interrupted time series	Semua unit terkena serentak; tidak ada kontrol sama sekali	Tanpa treatment, deret akan melanjutkan tren yang sama	Asumsi paling berat; tidak dapat memisahkan guncangan bersamaan. Bukti tingkat 5-6
Synthetic DiD	Beberapa unit treatment dengan pra-tren yang tidak sepenuhnya paralel	Gabungan: bobot unit dan bobot waktu	Lebih rumit dijelaskan ke pemangku kepentingan

✗ COMMON MISTAKE — Menyebut before/after sebagai "difference-in-differences"

Gejala: laporan menyebut "analisis DiD" tetapi hanya membandingkan periode sebelum dan sesudah pada kelompok yang menerima program.

Mengapa terjadi: istilah DiD dipakai sebagai label kredibilitas; kelompok kontrol dianggap "tidak tersedia" tanpa pencarian serius.

Perbaikan: DiD memerlukan *dua* selisih. Bila tidak ada kelompok kontrol, sebut analisisnya interrupted time series dan nyatakan asumsinya yang jauh lebih berat.

Cara senior menghindarinya: selalu mencari kelompok pembanding lebih dulu — toko yang belum masuk program, kota yang belum di-rollout, kategori yang tidak terkena kebijakan. Kelompok kontrol yang tidak sempurna hampir selalu lebih baik daripada tidak ada kelompok kontrol sama sekali.

Checklist analisis DiD dan synthetic control

- ✓ Kelompok kontrol dicari secara serius sebelum menyimpulkan tidak ada
- ✓ Panel seimbang dipakai sebagai analisis utama; perubahan komposisi diperiksa
- ✓ Event study dijalankan dan grafiknya disertakan sebelum koefisien tunggal dilaporkan
- ✓ Pra-tren datar dan tidak signifikan; Ashenfelter's dip diperiksa secara khusus
- ✓ Standard error di-cluster pada tingkat penugasan treatment
- ✓ Adopsi bertahap diperiksa; bila ada, estimator modern dipakai
- ✓ Limpahan ke kelompok kontrol diperiksa (mis. berdasarkan jarak)
- ✓ Untuk synthetic control: RMSE pra kecil, placebo in-space dan in-time dijalankan, leave-one-out diperiksa
- ✓ Hasil diterjemahkan menjadi contribution margin, bukan berhenti pada persentase
- ✓ Pernyataan asumsi identifikasi ditulis, termasuk apa yang akan membatalkannya

Ending Card — Bab 9

What you learned

Estimator DiD dan mengapa ia mengalahkan dua perbandingan naif; bentuk regresi dengan efek tetap dan keharusan cluster-robust SE; asumsi tren paralel dan pemeriksaannya lewat event study; tujuh ancaman terhadap tren paralel termasuk Ashenfelter's dip dan adopsi bertahap; kasus flash sale TokoNusa lengkap sampai keputusan ekonomi; synthetic control beserta bobot, uji placebo, dan diagnostik wajibnya; tabel pemilihan antar metode panel.

Skills mastered

Estimasi DiD · pengujian tren paralel · event study · synthetic control · inferensi permutasi · penerjemahan hasil kebijakan menjadi rupiah.

Real business value

Sebagian besar pertanyaan kausal di perusahaan menyangkut kebijakan yang sudah berjalan: promo, perubahan harga, rollout fitur per wilayah, program pelatihan, perubahan SLA. DiD adalah alat standar untuk mengevaluasinya, dan kemampuan menjalankannya dengan diagnostik yang benar membuat analyst menjadi rujukan untuk keputusan lanjut/hentikan pada program bernilai puluhan miliar.

Interview readiness

● INTERVIEW QUESTIONS

1. "Jelaskan DiD dan asumsinya kepada seorang manajer non-teknis." (Dua selisih; kontrol dipakai untuk mengukur perubahan, bukan tingkat; asumsi tren paralel.)
2. "Bagaimana kamu menguji tren paralel?" (Event study; pra-tren datar; sebutkan bahwa asumsinya tetap tidak dapat dibuktikan, hanya tidak terbantahkan.)
3. "Program di-rollout ke toko secara bertahap sepanjang tahun. Apa kekhawatiranmu dengan DiD biasa?" (Staggered adoption; bobot negatif; estimator modern. Pertanyaan yang membedakan kandidat yang mengikuti perkembangan metodologi.)
4. "Hanya satu kota yang menerima kebijakan. Apa yang kamu lakukan?" (Synthetic control; jelaskan bobot, placebo, dan keterbatasan inferensi.)
5. "Kenapa SE harus di-cluster?" (Korelasi dalam unit; jumlah unit independen jauh lebih kecil dari jumlah baris.)
6. "Hasil DiD kamu menunjukkan revenue naik tapi margin turun. Rekomendasimu?" (Terjemahkan ke gross profit dan CM; nyatakan bahwa keputusannya bergantung pada tujuan strategis, bukan pada tanda satu metric.)

Exercises

Exercise 9.1 (Beginner · 25 menit)

Objective: menghitung DiD tangan

Revenue rata-rata per toko per minggu (juta Rp):

Toko program : sebelum 340 · sesudah 379

Toko lain : sebelum 268 · sesudah 284

(a) Hitung estimasi DiD absolut dan relatif. (b) Hitung kedua estimasi naif dan jelaskan bias masing-masing. (c) Apa yang harus kamu periksa sebelum mempercayai angka DiD ini?

Answer key 9.1

(a) Δ treatment = $379 - 340 = +39$. Δ kontrol = $284 - 268 = +16$. DiD = $39 - 16 = +23$ juta/toko/minggu, atau $23/340 = +6,8\%$ relatif terhadap basis toko program.

(b) Naif before/after = $+39 (+11,5\%)$ — memasukkan tren umum sebesar $+16$ yang juga dialami toko lain, sehingga **melebih-lebihkan**. Naif lintas toko pada periode sesudah = $379 - 284 = +95 (+33\%)$ — memasukkan perbedaan permanen antar toko yang sudah ada sebelumnya (340 vs 268), sehingga **sangat melebih-lebihkan**.

(c) Sebelum percaya: event study untuk memeriksa pra-tren; apakah toko program dipilih karena sedang tumbuh; apakah ada guncangan yang khusus mengenai salah satu kelompok; apakah pelanggan berpindah dari toko kontrol ke toko program (limpahan); dan apakah SE sudah di-cluster pada toko.

Exercise 9.2 (Intermediate · 60 menit)

Objective: membaca event study

Empat pola event study (koefisien per periode relatif, acuan $t-1$). Untuk masing-masing, tentukan apakah DiD sah dan apa yang terjadi:

A: $t-4..t-2 = +0,2, -0,4, +0,1$; $t0..t3 = +5,1, +5,3, +4,9, +5,0$

B: $t-4..t-2 = -2,1, -3,4, -4,8$; $t0..t3 = +1,2, +2,8, +4,1, +5,6$

C: $t-4..t-2 = +1,9, +3,8, +5,7$; $t0..t3 = +7,8, +9,6, +11,5, +13,3$

D: $t-4..t-2 = +0,1, -0,2, +0,3$; $t0..t3 = +8,9, +5,2, +2,1, +0,4$

Answer key 9.2

A: Pra-tren datar, lompatan tajam, efek stabil. **DiD sah**; efek $\approx +5\%$. Ini pola ideal.

B: Pra-tren menurun tajam lalu pulih setelah treatment — **Ashenfelter's dip** klasik. Program kemungkinan diberikan kepada unit yang sedang jatuh; sebagian atau seluruh "efek" adalah pemulihan alami (regression to the mean). **DiD tidak sah**. Alternatif: synthetic control dengan pencocokan pada periode pra yang panjang, atau cari unit kontrol yang mengalami penurunan serupa.

C: Pra-tren naik $\pm 1,9$ per periode dan berlanjut dengan kemiringan yang sama setelah treatment. **Tren paralel dilanggar**; "efek" hanyalah kelanjutan tren yang sudah ada. Perhatikan bahwa koefisien pasca terlihat besar dan signifikan — inilah mengapa event study wajib. **DiD tidak sah**.

D: Pra-tren datar (sah), tetapi efek meluruh cepat menuju nol. **DiD sah secara identifikasi**, tetapi kesimpulan bisnisnya berbeda: efeknya sementara. Melaporkan rata-rata pasca ($+4,15\%$) akan sangat menyesatkan untuk perencanaan. Yang benar: laporkan pola peluruhan dan estimasi efek jangka panjang mendekati nol — kemungkinan pull-forward (pemindahan pembelian ke depan), bukan penciptaan permintaan.

Exercise 9.3 (Advanced · 2 jam)

Objective: DiD penuh dengan diagnostik

Bangun panel simulasi (atau gunakan data publik dengan struktur panel): minimal 60 unit, 24 periode, treatment pada sebagian unit mulai periode tertentu. Jalankan: (1) DiD dengan efek tetap dua arah dan SE cluster; (2) event study lengkap dengan grafik; (3) uji placebo in-time (majukan tanggal treatment ke periode pra — efeknya harus nol); (4) pemeriksaan limpahan; (5) analisis sensitivitas terhadap pilihan periode. Tulis laporan satu halaman dengan pernyataan asumsi identifikasi.

Answer key 9.3 — rubrik

Kriteria: SE dengan clustering minimal dua kali lebih besar dari tanpa clustering (bila tidak, periksa apakah clustering benar-benar diterapkan); event study memakai $t-1$ sebagai acuan dan menampilkan pita CI; placebo in-time menghasilkan koefisien yang tidak signifikan (bila signifikan, ada pra-tren yang terlewat); dan laporan menyebut secara eksplisit apa yang akan membatalkan kesimpulan. Kesalahan umum: memasukkan efek tetap unit *dan* variabel yang tidak berubah antar waktu (kolinear sempurna), serta menafsirkan koefisien efek tetap waktu sebagai temuan.

Exercise 9.4 (Production Challenge · 6 jam)

Objective: evaluasi kebijakan end-to-end

Pilih satu kebijakan nyata yang dapat dievaluasi dengan data publik — kenaikan upah minimum per provinsi, kebijakan pembatasan mobilitas, perubahan tarif, pembukaan gerai kompetitor. Kerjakan penuh: DAG, pemilihan metode, DiD dan/atau synthetic control, seluruh diagnostik, terjemahan ke dampak ekonomi, dan memo keputusan satu halaman. Sertakan bagian "mengapa saya tidak memakai metode X" untuk minimal dua metode alternatif.

Answer key 9.4 — rubrik

Proyek yang kuat: DAG dibuat sebelum metode dipilih; alasan penolakan metode alternatif spesifik (bukan "datanya tidak ada" melainkan "asumsi exclusion tidak dapat dipertahankan karena..."); diagnostik lengkap dan hasilnya dilaporkan apa adanya termasuk yang tidak menguntungkan; dan memo keputusan memuat rentang, bukan satu angka. Bagian "mengapa saya tidak memakai metode X" adalah pembeda utama — ia menunjukkan penguasaan seluruh peta, bukan satu teknik.

Portfolio idea

★ PORTFOLIO TIP

Proyek Exercise 9.4 adalah artefak portfolio paling substansial dari Bagian II. Sajikan dengan grafik event study sebagai gambar utama — grafik itu langsung dikenali oleh siapa pun yang pernah mengerjakan causal inference, dan berfungsi sebagai sinyal kompetensi bahkan sebelum teksnya dibaca.

Further reading

Angrist & Pischke, *Mostly Harmless Econometrics* (Bab 5: DiD) · Callaway & Sant'Anna (2021) dan Sun & Abraham (2021) tentang adopsi bertahap · Goodman-Bacon (2021), dekomposisi estimator two-way fixed effects · Abadie, Diamond & Hainmueller tentang synthetic control · Arkhangelsky et al. tentang synthetic difference-in-differences · Scott Cunningham, *Causal Inference: The Mixtape* (bab DiD dan synthetic control).

Next chapter

Bab 10 — metode yang paling banyak dipakai dan paling banyak disalahgunakan. Propensity score matching dan weighting: cara kerjanya, apa yang benar-benar dijaminnya, dan demonstrasi bahwa keseimbangan kovariat yang sempurna sekalipun tidak menjamin estimasi yang benar.

Bab 10 — Propensity Score: Matching, Weighting, dan Batas Kejujurannya

Metode paling populer dalam causal inference bisnis — dan yang paling sering dipakai untuk membuat analisis terlihat kausal padahal tidak.

Learning objectives	Menjelaskan asumsi unconfoundedness dan overlap; mengestimasi propensity score dan memeriksa keseimbangan kovariat; menerapkan matching, weighting (IPW), stratifikasi, dan doubly robust; menafsirkan hasil dengan bahasa yang tepat; menjalankan analisis sensitivitas (E-value); mengenali kapan propensity score tidak boleh dipakai
Prerequisites	Bab 8 (DAG, backdoor criterion); Vol 2 Bab 6 (regresi logistik)
Estimasi waktu	Baca 2,5 jam · Praktik 5 jam
Difficulty	● Advanced
Skills covered	Propensity score estimation, balance diagnostics, IPW, matching, doubly robust, sensitivity analysis
Business domain	Retail — keterlambatan pengiriman → churn, dianalisis dengan data 214.000 pelanggan

Ide dasar dan janji yang diberikannya

Ketika treatment tidak diacak, kelompok treatment dan kontrol berbeda pada banyak variabel sekaligus. Propensity score memampatkan seluruh perbedaan itu menjadi satu angka: **peluang sebuah unit menerima treatment, berdasarkan karakteristik pra-treatment-nya.**

$$e(X) = P(T = 1 \mid X)$$

Teorema (Rosenbaum & Rubin, 1983):

Bila penugasan treatment tidak terkonfound setelah mengkondisikan pada X , maka ia juga tidak terkonfound setelah mengkondisikan hanya pada $e(X)$.

Konsekuensi praktis: alih-alih mencocokkan pada 20 variabel sekaligus (mustahil), cukup mencocokkan pada SATU angka.

⚠ **WARNING — Teorema ini bersyarat, dan syaratnya adalah segalanya**

Kalimat "bila penugasan tidak terkonfound setelah mengkondisikan pada X " adalah asumsi **unconfoundedness**: seluruh confounder harus ada di dalam X dan terukur. Propensity score tidak membuat asumsi ini menjadi benar; ia hanya membuat penyesuaiannya menjadi praktis *bila* asumsi itu benar. Seluruh perdebatan tentang validitas terletak pada asumsi ini, bukan pada teknik pencocokannya.

Dua asumsi yang harus dipenuhi

Asumsi	Isi	Dapat diuji?
--------	-----	--------------

Unconfoundedness (ignorability, selection on observables)	Setelah mengkondisikan pada X, penugasan treatment independen dari potential outcomes	TIDAK. Hanya dapat diargumentasikan dari pengetahuan domain (DAG) dan diuji ketahanannya lewat analisis sensitivitas
Overlap / positivity	Untuk setiap nilai X, ada peluang positif menerima maupun tidak menerima treatment: $0 < e(X) < 1$	YA. Periksa distribusi propensity score kedua kelompok; wilayah tanpa tumpang tindih harus dikeluarkan atau dilaporkan

Alur kerja lengkap

1. DAG dulu	Tentukan variabel mana yang MASUK model propensity: hanya confounder dan prediktor outcome pra-treatment. JANGAN masukkan mediator, collider, atau instrumen.
2. Estimasi $e(X)$	Regresi logistik (default; transparan dan mudah diaudit) atau model ML bila hubungannya kompleks.
3. Periksa OVERLAP	Plot distribusi $e(X)$ per kelompok. Buang wilayah tanpa tumpang tindih (trimming) dan LAPORKAN berapa unit yang dibuang.
4. Terapkan penyesuaian	matching / IPW / stratifikasi / doubly robust
5. Periksa KESEIMBANGAN	Standardized mean difference tiap kovariat setelah penyesuaian. Target $ SMD < 0,10$. GAGAL → kembali ke langkah 2, jangan lanjut.
6. Estimasi efek	Dengan SE yang memperhitungkan prosedur penyesuaian (bootstrap atau rumus khusus).
7. SENSITIVITAS	Seberapa kuat confounder tak terukur harus agar kesimpulan berubah? (E-value)
8. Bahasa pelaporan	"Asosiasi setelah penyesuaian", bukan "menyebabkan" — kecuali ada argumen kuat bahwa unconfoundedness terpenuhi.

Empat cara memakai propensity score

Metode	Cara kerja	Estimand	Catatan
Matching (nearest neighbour)	Untuk tiap unit treatment, cari unit kontrol dengan $e(X)$ terdekat	ATT	Intuitif dan mudah dijelaskan; membuang banyak data kontrol; SE perlu perhatian khusus
Stratifikasi	Bagi ke 5–200 strata berdasarkan $e(X)$; bandingkan dalam strata; rata-ratakan dengan bobot	ATT atau ATE	Sangat transparan; mudah diperiksa; pilihan yang baik untuk audiens bisnis
IPW (inverse probability weighting)	Timbang unit kontrol dengan $e/(1-e)$ untuk ATT; dengan $1/(1-e)$ untuk ATE	ATT atau ATE	Memakai seluruh data; rentan terhadap bobot ekstrem bila e mendekati 0 atau 1 — potong bobot dan laporkan
Doubly robust (AIPW)	Gabungkan model propensity dan model outcome	ATE atau ATT	Konsisten bila <i>salah satu</i> model benar; rekomendasi default untuk analisis serius

■ TECHNICAL NOTE — mengapa doubly robust layak menjadi default

Estimator doubly robust memberi dua kesempatan untuk benar: bila model propensity salah tetapi model outcome benar, estimasi tetap konsisten — dan sebaliknya. Ini bukan jaminan terhadap confounder tak terukur (tidak ada metode yang memberi jaminan itu), melainkan perlindungan terhadap kesalahan spesifikasi model. Karena biayanya hampir nol dalam implementasi modern, tidak ada alasan bagus untuk tidak memakainya sebagai analisis utama, dengan IPW dan matching sebagai pemeriksaan ketahanan.

Kasus penuh: keterlambatan pengiriman → churn

Data: 214.000 pelanggan TokoNusa, periode Januari–Juni 2025

TREATMENT mengalami minimal satu keterlambatan (melewati SLA 4 hari) selama periode. Prevalensi: 36,3% pelanggan.
OUTCOME churn 180 hari (definisi Vol 3: tidak ada order selama 180 hari). Prevalensi keseluruhan: 23,9%.
KOVARIAT wilayah (luar Jawa), kategori/berat barang, log nilai order, frekuensi belanja historis
– semuanya PRA-treatment.
TIDAK TERUKUR niat berhenti (disposisi laten pelanggan)

Hasil bertingkat

Metode	Estimasi efek pada churn	Catatan
Perbandingan mentah	+19,10 pp	Tidak ada penyesuaian sama sekali
Regresi dengan kovariat	+8,17 pp (SE 0,20)	Kovariat pra-treatment saja
Stratifikasi propensity (156 strata)	+8,48 pp	ATT
IPW (bobot ATT)	+8,49 pp	ATT
Instrumental variable (Bab 11)	+4,01 pp (SE 0,70)	LATE; asumsi berbeda total

Diagnostik keseimbangan – standardized mean difference

Kovariat	sebelum	sesudah IPW
luar Jawa	+0,834	−0,002
kategori besar	+0,471	−0,003
frekuensi historis	+0,003	−0,001
log nilai order	+0,139	−0,003

Overlap propensity score:
treatment [0,101 ; 0,910]
kontrol [0,087 ; 0,894]
→ tumpang tindih baik; tidak ada wilayah yang perlu dibuang

✗ COMMON MISTAKE — Menyimpulkan bahwa keseimbangan sempurna berarti estimasi benar

Gejala: laporan menampilkan tabel keseimbangan yang mengesankan (semua $|SMD| < 0,01$) dan menyimpulkan "setelah matching, keterlambatan *menyebabkan* kenaikan churn 8,5 pp".

Mengapa terjadi: tabel keseimbangan terlihat seperti bukti validitas; secara psikologis ia sangat meyakinkan.

Kenyataannya: pada kasus ini, keseimbangan pada empat kovariat terukur mencapai kesempurnaan — dan estimasinya tetap **meleset lebih dari dua kali lipat** dibanding estimasi instrumental variable (8,5 vs 4,0 pp). Penyebabnya satu: confounder "niat berhenti" tidak pernah masuk ke dalam model karena tidak pernah tercatat di sistem mana pun.

Perbaikan: tabel keseimbangan membuktikan bahwa penyesuaian *berhasil pada variabel yang dimasukkan*. Ia tidak mengatakan apa pun tentang variabel yang tidak dimasukkan. Selalu sertakan analisis sensitivitas.

Cara senior menghindarinya: menuliskan di memo, dengan nama, confounder yang tidak terukur dan arah biasnya — sebelum menampilkan hasil apa pun.

◆ BUSINESS INSIGHT — konsekuensi Rp 15 miliar dari selisih 8,5 vs 4,0 pp

Basis: 1,48 juta pelanggan aktif; 36,3% mengalami keterlambatan = 537 ribu pelanggan; CLV Rp 496 ribu.

Pada estimasi propensity (8,5 pp) : $537\text{rb} \times 8,5\% \times 496\text{rb} = \text{Rp } 22,6 \text{ M}$
Pada estimasi IV (4,0 pp) : $537\text{rb} \times 4,0\% \times 496\text{rb} = \text{Rp } 10,7 \text{ M}$
Pada batas bawah IV (2,6 pp) : $537\text{rb} \times 2,6\% \times 496\text{rb} = \text{Rp } 6,9 \text{ M}$

Selisih Rp 15,7 miliar antara angka propensity dan batas bawah IV adalah selisih antara dua keputusan investasi yang sangat berbeda. Bila perusahaan menyetujui investasi logistik Rp 20 miliar berdasarkan angka propensity, proyek itu akan gagal memenuhi janjinya — dan yang disalahkan biasanya bukan metodenya, melainkan tim logistik.

Analisis sensitivitas: seberapa rapuh kesimpulan ini?

Karena unconfoundedness tidak dapat diuji, pertanyaan yang dapat dijawab adalah: *seberapa kuat confounder tak terukur harus, agar kesimpulan berubah?* Alat paling praktis untuk audiens bisnis adalah **E-value**.

$$E\text{-value} = RR + \sqrt{(RR \times (RR - 1))}$$

RR = risk ratio setelah penyesuaian

Arti: confounder tak terukur harus berasosiasi dengan treatment DAN dengan outcome, masing-masing dengan risk ratio minimal sebesar E-value, agar seluruh efek yang teramati bisa dijelaskan olehnya.

Perhitungan untuk kasus keterlambatan (estimasi IPW):
churn kelompok treatment = 36,1%
churn kontra-faktual setelah IPW = 27,6%
RR teradjust = $0,361 / 0,276 = 1,309$
E-value = $1,309 + \sqrt{(1,309 \times 0,309)} = 1,94$

INTERPRETASI:

Sebuah confounder tak terukur harus menaikkan peluang mengalami keterlambatan sebesar 1,94x DAN menaikkan peluang churn sebesar 1,94x — setelah semua kovariat lain diperhitungkan — untuk menghapus seluruh efek.

Apakah itu masuk akal? "Niat berhenti" pada pelanggan yang sudah berencana pergi sangat mungkin memenuhi ambang ini. Kesimpulannya: estimasi 8,5 pp TIDAK KUAT terhadap confounding tak terukur – persis yang kemudian dikonfirmasi oleh instrumental variable.

✓ **BEST PRACTICE — Terjemahkan E-value menjadi pertanyaan yang bisa dijawab bisnis**

Angka 1,94 tidak berarti apa-apa bagi eksekutif. Yang berarti adalah pertanyaannya: "Adakah sesuatu tentang pelanggan — yang tidak kita catat — yang membuat mereka 2× lebih mungkin mengalami keterlambatan sekaligus 2× lebih mungkin berhenti berbelanja?" Ajukan pertanyaan ini kepada tim operasional dan CRM. Jawaban mereka adalah bukti yang tidak ada di dalam data — dan jauh lebih informatif daripada satu p-value.

Kapan propensity score tidak boleh dipakai

Situasi	Alasan & alternatif
Confounder utama tidak terukur dan penting	Asumsi inti dilanggar. Cari instrumen (Bab 11), ambang batas (RDD), atau struktur panel (DiD, Bab 9)
Overlap buruk — kelompok hampir tidak berpotongan	Tidak ada pembanding yang sah; penyesuaian berubah menjadi ekstrapolasi model. Batasi ke wilayah tumpang tindih dan akui perubahan populasi estimand
Treatment ditentukan oleh informasi privat yang tidak tercatat	Manajer memilih toko berdasarkan penilaian yang tidak terdokumentasi; kasus klasik unconfoundedness yang gagal
Variabel yang tersedia sebagian besar pasca-treatment	Memasukkannya menciptakan bias baru (Bab 8). Bila kovariat pra-treatment hampir tidak ada, propensity score tidak dapat menolong
Tersedia desain yang lebih kuat	Bila eksperimen atau eksperimen alami mungkin, propensity score adalah pilihan kedua yang tidak perlu

► **EXECUTIVE PERSPECTIVE — nilai propensity score yang sebenarnya**

Meskipun bab ini berulang kali menekankan batasnya, propensity score tetap bernilai tinggi — bukan sebagai bukti kausal, melainkan sebagai **penyempit rentang**. Pada kasus keterlambatan, ia memindahkan diskusi dari 19,1 pp (yang jelas absurd) ke 8,5 pp, sebelum instrumen memindahkannya lagi ke 4,0 pp. Setiap langkah menghilangkan bias yang dapat dihilangkan dan memperjelas berapa banyak yang tersisa.

Cara menyampaikannya: "Angka mentahnya 19 pp. Setelah mengendalikan semua yang kita catat, tersisa 8,5 pp. Kita tahu ada faktor yang tidak kita catat, dan perhitungan sensitivitas menunjukkan faktor itu bisa menjelaskan sebagian besar sisanya. Karena itu saya mencari bukti yang tidak bergantung pada asumsi tersebut." Rangkaian kalimat ini membangun kepercayaan justru karena mengakui keterbatasan setiap langkah.

Catatan tentang skor churn dan janji Volume 6

Vol 3 Bab 6 membangun skor churn dan menjanjikan evaluasi model formal di Volume 6. Ada perbedaan mendasar yang layak ditegaskan di sini, karena keduanya sering tertukar:

Aspek	Model prediksi (Volume 6)	Model kausal (Volume ini)
Pertanyaan	Siapa yang akan churn?	Apa yang menyebabkan churn, dan apa dampak intervensi?

Kriteria keberhasilan	AUC, precision, recall	Bias, identifikasi, ketahanan asumsi
Variabel pasca-treatment	Boleh dan sering berguna	Dilarang — menciptakan bias
Kesalahan fatal	Kebocoran data (leakage)	Confounding
Kegunaan	Menentukan siapa yang ditargetkan	Menentukan apakah intervensi berhasil dan berapa nilainya

Model dengan AUC 0,89 dapat memprediksi churn dengan sangat baik dan tetap tidak memberi tahu satu pun tindakan yang akan menurunkannya. Kedua kemampuan itu saling melengkapi: prediksi memilih *siapa*, kausal menentukan *apa* yang dilakukan pada mereka — dan hanya eksperimen yang dapat memastikan bahwa kombinasi keduanya benar-benar bekerja.

Checklist propensity score

- ✓ DAG dibuat lebih dulu; hanya confounder dan prediktor outcome pra-treatment yang masuk model
- ✓ Tidak ada mediator, collider, atau instrumen di dalam model propensity
- ✓ Overlap diperiksa secara visual dan numerik; unit di luar wilayah tumpang tindih dilaporkan
- ✓ Keseimbangan diperiksa dengan standardized mean difference, target $|SMD| < 0,10$
- ✓ Bobot ekstrem diperiksa dan dipotong bila perlu, dengan pelaporan
- ✓ Analisis utama memakai doubly robust; matching dan IPW sebagai pemeriksaan ketahanan
- ✓ SE memperhitungkan prosedur penyesuaian (bootstrap atau rumus khusus)
- ✓ Analisis sensitivitas dijalankan dan E-value diterjemahkan menjadi pertanyaan bisnis
- ✓ Confounder tak terukur disebut namanya beserta arah biasanya
- ✓ Bahasa pelaporan memakai "asosiasi setelah penyesuaian", bukan "menyebabkan"

Ending Card — Bab 10

What you learned

Teorema propensity score dan syaratnya; asumsi unconfoundedness dan overlap beserta apa yang dapat dan tidak dapat diuji; alur kerja delapan langkah; empat cara pemakaian (matching, stratifikasi, IPW, doubly robust); kasus penuh keterlambatan → churn dengan hasil bertingkat 19,1 → 8,5 → 4,0 pp; demonstrasi bahwa keseimbangan sempurna tidak menjamin estimasi benar; E-value dan penerjemahannya; lima situasi di mana propensity score tidak boleh dipakai; perbedaan model prediksi dan model kausal.

Skills mastered

Estimasi propensity score · diagnostik keseimbangan dan overlap · IPW dan doubly robust · analisis sensitivitas · kalibrasi bahasa klaim.

Real business value

Metode ini akan menjadi permintaan rutin: "kami tidak bisa A/B test, tolong analisis saja datanya". Kemampuan menjalankannya dengan benar *dan* menyampaikan batasnya dengan jelas mencegah organisasi mengambil keputusan besar berdasarkan angka yang dua kali lipat terlalu besar — sambil tetap memberi jawaban yang berguna alih-alih menolak.

Interview readiness

● INTERVIEW QUESTIONS

1. "Apa yang dijamin dan tidak dijamin oleh propensity score matching?" (Menjamin keseimbangan pada kovariat yang dimasukkan; tidak menjamin apa pun tentang confounder tak terukur.)
2. "Bagaimana kamu memeriksa apakah matching berhasil?" ($SMD < 0,10$, overlap, dan — jawaban yang membedakan — menegaskan bahwa keberhasilan ini tidak menyelesaikan masalah identifikasi.)
3. "Variabel apa yang kamu masukkan ke model propensity?" (Confounder dan prediktor outcome pre-treatment; jelaskan mengapa mediator, collider, dan instrumen dikeluarkan.)
4. "Apa itu doubly robust dan mengapa memakainya?" (Dua kesempatan untuk benar terhadap kesalahan spesifikasi model.)
5. "Bagaimana kamu meyakinkan direksi bahwa hasilmu bisa dipercaya?" (Triangulasi dengan metode berasumsi berbeda; analisis sensitivitas yang diterjemahkan ke pertanyaan bisnis; rekomendasi memakai estimasi paling konservatif.)
6. "Apa bedanya model prediksi churn dan model kausal churn?" (Tabel perbandingan di bab ini; pertanyaan yang sangat sering muncul di wawancara data science.)

Exercises

Exercise 10.1 (Beginner · 25 menit)

Objective: memilih variabel model propensity

Kita mengukur efek **program membership berbayar** pada **belanja 12 bulan**. Untuk tiap variabel, tentukan masuk atau tidak ke model propensity dan alasannya: (a) belanja 12 bulan sebelum mendaftar; (b) usia akun; (c) jumlah kupon membership yang ditebus; (d) kota; (e) apakah pernah menghubungi CS setelah mendaftar; (f) skor niat beli dari survei sebelum periode analisis; (g) apakah pelanggan mendapat tawaran diskon membership karena kesalahan sistem.

Answer key 10.1

(a) **Masuk** — confounder dan prediktor outcome kuat, dan pra-treatment. (b) **Masuk** — confounder. (c) **Tidak** — pasca-treatment dan mediator (cara program bekerja). (d) **Masuk** — confounder. (e) **Tidak** — pasca-treatment, kemungkinan collider. (f) **Masuk** — ini justru variabel paling berharga karena mendekati confounder laten "minat"; keberadaan data survei semacam ini sering menjadi pembeda antara analisis yang dapat dipercaya dan tidak. (g) **Tidak masuk sebagai kovariat** — ini instrumen; memasukkannya menghapus variasi eksogen yang justru paling berguna (Bab 11).

Exercise 10.2 (Intermediate · 60 menit)

Objective: membaca diagnostik dan sensitivitas

Sebuah analisis melaporkan: efek program pelatihan karyawan pada produktivitas = +12,4% setelah IPW; seluruh $|SMD| < 0,03$; overlap baik; RR teradjust = 1,18.

(a) Hitung E-value. (b) Sebutkan tiga confounder tak terukur yang masuk akal dan taksir apakah masing-masing dapat mencapai ambang E-value. (c) Rancang satu negative control. (d) Tulis kalimat kesimpulan yang jujur untuk memo.

Answer key 10.2

(a) $E\text{-value} = 1,18 + \sqrt{(1,18 \times 0,18)} = 1,18 + \sqrt{0,2124} = 1,18 + 0,461 = \mathbf{1,64}$.

(b) Confounder yang masuk akal: **(i) motivasi/ambisi karyawan** — karyawan yang mendaftar pelatihan cenderung lebih termotivasi; asosiasinya dengan mengikuti pelatihan bisa jauh di atas $1,64\times$ dan dengan produktivitas juga; **sangat mungkin melampaui ambang**. **(ii) Dukungan manajer** — manajer yang baik mengirim timnya ke pelatihan *dan* meningkatkan produktivitas lewat jalur lain; **mungkin melampaui**. **(iii) Beban kerja** — karyawan yang tidak terlalu sibuk bisa ikut pelatihan; hubungannya dengan produktivitas ambigu arahnya; **kemungkinan di bawah ambang**. Kesimpulan: E-value 1,64 tergolong rendah; temuan ini rapuh.

(c) Negative control: ukur "efek" pelatihan pada produktivitas **periode sebelum pelatihan berlangsung**. Bila muncul efek positif di sana, itu bukti langsung adanya seleksi. Alternatif: ukur efek pada outcome yang tidak mungkin terpengaruh pelatihan (misalnya tingkat kehadiran rekan kerja di departemen lain).

(d) Kalimat memo: "Setelah menyesuaikan seluruh karakteristik yang kami catat, peserta pelatihan menunjukkan produktivitas 12,4% lebih tinggi. Estimasi ini tidak kuat terhadap faktor tak terukur: motivasi karyawan atau kualitas manajer yang berasosiasi $1,6\times$ dengan keikutsertaan dan produktivitas sudah cukup menjelaskan seluruh perbedaan. Kami merekomendasikan uji terkontrol pada gelombang pelatihan berikutnya — dengan mengacak *undangan*, bukan kepesertaan — sebelum memperluas program."

Exercise 10.3 (Advanced · 2 jam)

Objective: replikasi kasus bab ini

Bangun dataset simulasi dengan struktur: 3–4 confounder terukur, 1 confounder **tak terukur** yang kuat, treatment biner, outcome biner, dan efek kausal sebenarnya yang kamu tetapkan. Jalankan: perbandingan mentah, regresi, PSM, IPW, dan doubly robust. Tampilkan tabel keseimbangan sebelum dan sesudah. Bandingkan semua estimasi dengan efek sebenarnya. Hitung E-value. Tulis satu paragraf tentang apa yang latihan ini ajarkan mengenai batas metode observasional.

Answer key 10.3 — rubrik

Hasil yang benar akan menunjukkan pola yang sama dengan bab ini: seluruh metode propensity memberi jawaban yang *hampir identik satu sama lain* (8,4–8,5 pp pada kasus kita) dan *semuanya sama-sama bias*. Ini pelajaran terpenting: kesepakatan antar metode observasional bukan bukti kebenaran, karena semuanya bersandar pada asumsi yang sama. Kesalahan umum peserta: memasukkan confounder tak terukur ke dalam model "untuk membandingkan" lalu menyimpulkan metodenya bekerja — yang justru menghilangkan inti latihan. Paragraf penutup yang kuat menyebutkan bahwa satu-satunya jalan keluar adalah desain yang tidak bergantung pada unconfoundedness.

Exercise 10.4 (Production Challenge · 5 jam)

Objective: analisis observasional lengkap dengan data nyata

Dengan dataset Olist, ukur asosiasi antara keterlambatan pengiriman dan probabilitas pelanggan memesan lagi dalam 180 hari. Kerjakan penuh: DAG, pemilihan kovariat pra-treatment, propensity score, overlap, keseimbangan, empat estimator, E-value, dua negative control, dan memo satu halaman dengan bahasa klaim yang tepat. Tutup dengan usulan desain eksperimen yang akan menjawab pertanyaan ini secara definitif beserta perkiraan biayanya.

Answer key 10.4 — rubrik

Kriteria: kovariat seluruhnya pra-treatment (perhatikan bahwa banyak kolom Olist bersifat pasca-pengiriman — review score adalah collider klasik dan tidak boleh dikendalikan); overlap dilaporkan dengan jumlah unit yang dibuang; memo memakai kata "berasosiasi", bukan "menyebabkan"; dan usulan eksperimen bersifat operasional dan realistis (misalnya mengacak prioritas pengiriman pada sebagian order, bukan "mengacak keterlambatan" yang tidak etis dan tidak mungkin disetujui). Bagian terakhir ini penting: analyst yang mengusulkan eksperimen yang tidak akan pernah disetujui menunjukkan kurangnya pemahaman operasional.

Portfolio idea

★ PORTFOLIO TIP

Exercise 10.3 menghasilkan artefak yang tidak biasa dan sangat kuat: demonstrasi bahwa *metode favorit industri gagal dalam kondisi yang diketahui*. Judul yang bekerja: "Empat estimator, satu jawaban salah: mengapa keseimbangan kovariat bukan bukti kausal". Dokumen semacam ini menandai penulis sebagai orang yang memahami metode, bukan sekadar menjalankannya.

Further reading

Rosenbaum & Rubin (1983), makalah asli propensity score · Imbens & Rubin, *Causal Inference* (bagian matching dan weighting) · VanderWeele & Ding (2017) tentang E-value · King & Nielsen, "Why Propensity Scores Should Not Be Used for Matching" (kritik yang penting dipahami) · Chernozhukov et al. tentang double machine learning.

Next chapter

Bab 11 — dua metode yang tidak bergantung pada asumsi unconfoundedness sama sekali. Instrumental variables menjawab elastisitas harga; regression discontinuity menjawab efek ambang — dan menunjukkan mengapa ambang gratis ongkir justru *tidak* dapat dianalisis dengan RDD.

Bab 11 — Instrumental Variables & Regression Discontinuity

Dua cara memperoleh variasi yang seolah-olah acak dari dunia yang tidak pernah mengacak apa pun.

Learning objectives

Menjelaskan tiga syarat instrumen dan mana yang dapat diuji; menjalankan dan menafsirkan 2SLS; menghitung estimasi Wald; memahami LATE dan siapa complier-nya; mendeteksi instrumen lemah; menjalankan regression discontinuity beserta uji densitas dan sensitivitas bandwidth; mengenali kapan RDD tidak sah; menerapkan keduanya pada elastisitas harga dan ambang program

Prerequisites

Bab 8 (DAG); Bab 10 (batas propensity score); Vol 3 Bab 9 (elastisitas harga)

Estimasi waktu

Baca 3 jam · Praktik 5 jam

Difficulty

● **Advanced**

Skills covered

2SLS, instrument validity assessment, LATE interpretation, RDD, density test, bandwidth sensitivity


Business domain

Retail & e-commerce — elastisitas harga, keterlambatan → churn, ambang program loyalitas, ambang gratis ongkir

Bagian I — Instrumental Variables

Ide dasar

Bab 10 berakhir dengan masalah yang tidak dapat dipecahkan dari dalam: confounder tak terukur. Instrumental variable menyelesaikannya dengan cara yang sama sekali berbeda — alih-alih mencoba mengukur semua confounder, ia mencari **sepotong variasi dalam treatment yang tidak berkaitan dengan confounder apa pun**.



Logikanya: jika Z hanya bisa mempengaruhi Y lewat X, maka seluruh perubahan Y yang disebabkan Z pasti berasal dari perubahan X yang disebabkan Z. Bagi keduanya, dan diperoleh efek X pada Y — dibersihkan dari U.

Tiga syarat instrumen

Syarat	Isi	Dapat diuji?
1. Relevansi		

	Z benar-benar mempengaruhi X, cukup kuat	YA — first-stage F-statistic. Syarat praktis: $F > 10$; untuk keputusan penting, $F > 100$
2. Exclusion restriction	Z tidak mempengaruhi Y kecuali lewat X	TIDAK. Ini asumsi murni; harus dipertahankan dengan argumen substantif dan diperiksa secara tidak langsung
3. Independensi	Z tidak berkaitan dengan confounder U	Sebagian — periksa keseimbangan kovariat teramati antar tingkat Z
4. Monotonisitas (untuk tafsir LATE)	Tidak ada unit yang bereaksi berlawanan arah terhadap Z	TIDAK. Umumnya dipertahankan dengan alasan operasional

⚠ **WARNING — Exclusion restriction adalah tempat hampir semua analisis IV gagal**

Instrumen yang relevan mudah ditemukan; instrumen yang benar-benar memenuhi exclusion restriction jarang. Uji cepat yang sering menyelamatkan: *tuliskan semua cara Z bisa mempengaruhi Y selain lewat X, sebanyak yang bisa kamu pikirkan*. Bila daftarnya lebih dari nol dan tidak ada yang bisa disingkirkan dengan bukti, instrumen itu tidak sah — dan estimasinya bisa lebih bias daripada regresi biasa, karena bias IV diperbesar oleh pembagian dengan koefisien first stage yang kecil.

Cara menghitung: estimasi Wald dan 2SLS

ESTIMASI WALD (instrumen biner, tanpa kovariat)

$$\beta_{IV} = \frac{E[Y | Z=1] - E[Y | Z=0]}{E[X | Z=1] - E[X | Z=0]} = \frac{\text{efek Z pada Y (reduced form)}}{\text{efek Z pada X (first stage)}}$$

TWO-STAGE LEAST SQUARES (umum, dengan kovariat)

Tahap 1 : $X = \pi_0 + \pi_1 Z + \text{kovariat} + v$ → ambil $\hat{X}$


Tahap 2 : $Y = \beta_0 + \beta_1 \hat{X} + \text{kovariat} + \epsilon$ → β_1 adalah estimasi

CATATAN: jangan menjalankan dua regresi terpisah secara manual — standard error-nya akan salah. Gunakan rutin 2SLS yang mengoreksi ketidakpastian dari tahap pertama.

Kasus 1: elastisitas harga TokoNusa

Vol 3 Bab 9 mengestimasi elastisitas harga dari data historis dan menutup dengan peringatan: angka itu tidak boleh dipercaya. Alasannya sekarang dapat dinyatakan dengan tepat.

MENGAPA REGRESI HARGA-KUANTITAS SELALU BIAS



Perusahaan menaikkan harga justru ketika permintaan tinggi (musim, tren, kelangkaan). Akibatnya harga dan kuantitas tampak bergerak bersama, dan elastisitas terlihat JAUH LEBIH KECIL (kurang elastis) daripada sebenarnya.

INSTRUMEN: guncangan BIAYA — kurs mata uang, harga pengadaan, biaya logistik. Biaya menggeser harga jual, tetapi tidak mempengaruhi keinginan pelanggan untuk membeli.

Hasil terverifikasi pada data simulasi dengan elastisitas sebenarnya $-1,85$

OLS $\log(\text{kuantitas}) \sim \log(\text{harga}) = -0,794$ (SE 0,012)
→ sangat bias ke arah nol; menyarankan permintaan hampir tidak elastis (SALAH)

First stage: $\log(\text{harga}) \sim \text{guncangan biaya}$
koefisien = $0,417 \cdot F = 3.187$ → instrumen kuat ✓

Reduced form: $\log(\text{kuantitas}) \sim \text{guncangan biaya} = -0,775$

Wald / 2SLS = $-0,775 / 0,417 = -1,860$
→ dekat dengan elastisitas sebenarnya ($-1,85$) ✓

◆ BUSINESS INSIGHT — konsekuensi harga dari elastisitas yang salah

Dengan elastisitas $-0,79$ (hasil OLS bias), aturan penetapan harga akan menyimpulkan bahwa menaikkan harga 5% hanya menurunkan volume 4% — revenue naik, kenaikan harga direkomendasikan. Dengan elastisitas sebenarnya $-1,85$, kenaikan harga 5% menurunkan volume 9,3% dan *menurunkan* revenue. Dua rekomendasi yang berlawanan dari data yang sama.

Inilah alasan mengapa keputusan penetapan harga tidak boleh diambil dari regresi historis. Urutan preferensinya: **(1)** eksperimen harga terkendali (geo experiment, karena A/B harga per pengguna bermasalah — Bab 2 dan 12); **(2)** instrumental variable dengan guncangan biaya; **(3)** RDD bila ada ambang harga yang tajam; **(4)** regresi historis — hanya sebagai orientasi kasar, dengan pernyataan eksplisit bahwa ia bias ke arah nol.

Kasus 2: keterlambatan → churn, dengan kapasitas hub sebagai instrumen

INSTRUMEN	Deviasi kapasitas hub kurir pada hari pemesanan dari rata-rata musimannya. Kapasitas ditentukan oleh jadwal armada, cuti pengemudi, dan alokasi pusat — tidak oleh karakteristik pelanggan yang memesan.
RELEVANSI	First-stage $F = 15.598$. Kapasitas rendah menaikkan peluang keterlambatan secara substansial. ✓
EXCLUSION	Argumen: pelanggan tidak mengetahui kapasitas hub; tidak ada perbedaan harga, promo, atau komunikasi yang terkait dengannya. ANCAMAN: bila hub yang penuh juga membuat lebih banyak kesalahan pengemasan, exclusion dilanggar. PEMERIKSAAN: korelasi kapasitas dengan tingkat kesalahan pengemasan = $0,03$ → ancaman kecil. ✓
HASIL	2SLS = $+4,01$ pp (SE 0,70; CI 95% $+2,64$ s/d $+5,38$ pp)
BANDINGKAN	mentah $19,10$ pp · regresi $8,17$ pp · IPW $8,49$ pp

■ TECHNICAL NOTE — siapa complier di sini, dan mengapa itu penting

Estimasi IV adalah LATE: efek pada **complier** — dalam kasus ini, order yang statusnya berubah dari tepat waktu menjadi terlambat *karena* kapasitas hub turun. Kelompok ini bukan seluruh order yang terlambat.

Order yang selalu terlambat apa pun kapasitasnya (*always-taker*: alamat sangat terpencil, barang sangat besar) tidak berkontribusi pada estimasi. Demikian pula order yang tidak pernah terlambat (*never-taker*). Konsekuensi untuk keputusan: **estimasi 4,01 pp berlaku untuk keterlambatan yang disebabkan kendala kapasitas** — dan kebetulan itulah jenis keterlambatan yang dapat diperbaiki dengan investasi kapasitas. Kesesuaian antara populasi complier dan populasi yang akan terkena intervensi adalah hal yang harus diperiksa dan dinyatakan, bukan diasumsikan.

Sumber instrumen yang nyata di dunia bisnis

Instrumen	Untuk mengukur efek	Ancaman terhadap exclusion
Penugasan acak dalam encouragement design	Efek penggunaan fitur/program pada outcome	Hampir tidak ada — instrumen ini <i>dirancang</i> acak; standar emas untuk IV
Kesalahan sistem / bug yang tidak disengaja	Efek fitur, promo, atau komunikasi	Bila bug juga merusak pengalaman lain
Kapasitas operasional (hub, gudang, kurir)	Efek kecepatan/SLA pada retensi	Kapasitas rendah dapat menurunkan kualitas layanan lain
Guncangan biaya, kurs, harga pengadaan	Elastisitas harga	Guncangan biaya dapat berkorelasi dengan kondisi makro yang mempengaruhi permintaan
Jarak ke fasilitas (toko, gudang, cabang)	Efek akses fisik	Jarak berkorelasi dengan demografi wilayah — sering fatal
Perubahan kebijakan yang berlaku sebagian	Efek kebijakan	Kebijakan jarang berlaku secara acak
Antrian / penugasan agen secara bergilir	Efek kualitas layanan pada retensi	Penugasan sering tidak sepenuhnya acak dalam praktik

✗ COMMON MISTAKE — Instrumen lemah yang memperbesar bias

Gejala: first-stage $F = 4,2$; estimasi IV jauh lebih besar dari OLS dan sangat tidak stabil terhadap perubahan spesifikasi kecil.

Mengapa terjadi: instrumen yang secara teori menarik tetapi secara empiris hampir tidak menggerakkan treatment.

Akibatnya: pembagian dengan koefisien first stage yang kecil memperbesar bias apa pun yang ada, dan estimasi IV dapat *lebih buruk* daripada OLS biasa. Interval kepercayaan konvensional juga menjadi tidak akurat.


Perbaiki: laporkan first-stage F selalu; bila $F < 10$, jangan pakai instrumen itu; bila F antara 10 dan 100 untuk keputusan penting, gunakan metode inferensi yang tahan terhadap instrumen lemah (Anderson-Rubin).

Cara senior menghindarinya: menjalankan first stage *sebelum* melihat hasil tahap kedua, dan memutuskan kelayakan instrumen berdasarkan itu saja.

Bagian II — Regression Discontinuity

Ide dasar

Banyak keputusan bisnis dibuat dengan aturan ambang: pelanggan dengan skor ≥ 700 masuk program prioritas; order di atas Rp 199.000 dapat gratis ongkir; karyawan dengan penilaian ≥ 4 mendapat bonus. Unit tepat di atas dan tepat di bawah ambang hampir identik dalam segala hal — kecuali satu mendapat treatment dan satu tidak.



Asumsi identifikasi: SEMUA HAL LAIN berubah secara mulus (kontinu) di sekitar ambang. Hanya treatment yang melompat.

Kasus valid: ambang skor loyalitas 700

TokoNusa memberikan prioritas pengiriman gratis kepada pelanggan dengan skor loyalitas internal ≥ 700 . Skor dihitung dari algoritma dengan komponen yang tidak diketahui pelanggan — sehingga tidak dapat dimanipulasi secara presisi.

Uji densitas (McCrary): jumlah pelanggan pada bin 695–699 vs 700–704 = 1.382 vs 1.272; rasio 0,92 → tidak ada penumpukan di satu sisi ambang. ✓ Tidak ada manipulasi.

Estimasi efek pada retensi 12 bulan, per bandwidth:

±60 poin	: +5,01 pp	(SE 0,63)	n = 27.188
±40 poin	: +5,29 pp	(SE 0,76)	n = 19.644
±25 poin	: +4,83 pp	(SE 0,95)	n = 12.863

→ Estimasi stabil di kisaran 4,8–5,3 pp lintas bandwidth;
SE membesar saat bandwidth menyempit (sampel berkurang).
Kestabilan ini adalah bukti ketahanan yang harus dilaporkan.

■ TECHNICAL NOTE — trade-off bandwidth

Bandwidth sempit mengurangi bias (unit makin sebanding) tetapi menaikkan variance (sampel makin kecil). Bandwidth lebar sebaliknya. Praktik yang benar: laporkan estimasi untuk beberapa bandwidth dan tunjukkan bahwa kesimpulan tidak bergantung pada satu pilihan. Bila estimasi berubah tanda atau besaran secara dramatis antar bandwidth, temuan itu tidak dapat dipercaya. Pemilihan bandwidth optimal secara algoritmik tersedia (Imbens-Kalyanaraman, Calonico-Cattaneo-Titiunik) dan sebaiknya dipakai sebagai titik acuan, bukan sebagai satu-satunya angka yang dilaporkan.

Kasus tidak valid: ambang gratis ongkir Rp 150.000

Godaan yang sangat besar: TokoNusa memiliki ambang gratis ongkir yang tajam, dan RDD tampak seperti cara sempurna mengukur efeknya tanpa eksperimen. Analisisnya gagal pada langkah pertama.

Uji densitas pada nilai keranjang:

bin Rp 140.000–149.999	: 1.337 keranjang
bin Rp 150.000–159.999	: 6.344 keranjang

rasio = 4,74x

→ PENUMPUKAN MASIF tepat di atas ambang.

Penyebabnya jelas dan sepenuhnya rasional: pelanggan MENAMBAH ITEM agar keranjangnya melewati Rp 150.000 dan mendapat gratis ongkir. Running variable dimanipulasi oleh unit itu sendiri.

KONSEKUENSI: pelanggan tepat di atas ambang SISTEMATIS BERBEDA dari pelanggan tepat di bawahnya — mereka adalah orang-orang yang cukup peduli untuk menambah item. Asumsi kontinuitas dilanggar. RDD TIDAK SAH di sini.

◆ BUSINESS INSIGHT — kegagalan yang justru merupakan temuan

Uji densitas yang gagal bukan jalan buntu; ia adalah pengukuran yang berharga. Penumpukan 4,74x membuktikan bahwa **pelanggan benar-benar merespons ambang dengan menambah item** — persis mekanisme yang dihipotesiskan dalam desain EXP-041 (Bab 2). Besarnya penumpukan bahkan dapat dipakai untuk memperkirakan berapa banyak keranjang yang akan naik bila ambang digeser.

Dan inilah alasan mengapa EXP-041 harus berupa eksperimen, bukan analisis observasional: satu-satunya cara mengukur dampak menggeser ambang adalah dengan benar-benar menggesernya untuk sebagian pengguna. Bab 2, Bab 5, dan Bab 11 kini bertemu di satu titik — keputusan desain yang diambil di Bab 2 terbukti tidak hanya benar, tetapi *satu-satunya* yang sah.

Diagnostik wajib untuk RDD

- **Uji densitas** (McCrary) — penumpukan di satu sisi ambang membatalkan analisis.
- **Kontinuitas kovariat** — variabel pra-treatment (usia akun, wilayah, riwayat) tidak boleh melompat di ambang. Bila melompat, ada seleksi.
- **Ambang palsu (placebo cutoff)** — jalankan RDD pada nilai ambang buatan di sebelah kiri dan kanan; efeknya harus nol.
- **Sensitivitas bandwidth** — minimal tiga bandwidth dilaporkan.
- **Bentuk fungsional** — bandingkan polinomial derajat 1 dan 2; hindari polinomial derajat tinggi yang menciptakan lompatan artifisial.
- **Donut hole** — buang observasi yang sangat dekat ambang; bila hasil berubah drastis, ada masalah pada pengukuran atau pembulatan di ambang.

Fuzzy RDD

Sering kali ambang tidak menentukan treatment secara mutlak: pelanggan dengan skor ≥ 700 *ditawari* program, tetapi hanya sebagian yang menerima. Ini disebut fuzzy RDD, dan penanganannya menyatukan kedua bagian bab ini: **ambang dipakai sebagai instrumen** untuk penerimaan treatment, dan estimasinya adalah LATE pada complier di sekitar ambang.

$$\beta_{\text{fuzzy}} = \frac{\text{lompatan pada OUTCOME di ambang}}{\text{lompatan pada TREATMENT di ambang}}$$

Bentuk yang sama persis dengan estimasi Wald. Fuzzy RDD adalah IV dengan instrumen berupa indikator "di atas ambang".

Membandingkan IV dan RDD

Aspek	Instrumental Variables	Regression Discontinuity
Sumber variasi	Instrumen eksternal yang menggeser treatment	Aturan ambang yang tajam
Asumsi utama	Exclusion restriction (tidak dapat diuji)	Kontinuitas di ambang (sebagian dapat diperiksa)
Kredibilitas	Bergantung sepenuhnya pada argumen substantif	Lebih tinggi — diagnostiknya lebih banyak dan lebih meyakinkan
Estimand	LATE pada complier — populasi sering sulit dikarakterisasi	Efek lokal di sekitar ambang — populasi jelas dan mudah dijelaskan
Generalisasi	Terbatas pada complier	Terbatas pada unit di dekat ambang; efek jauh dari ambang tidak diketahui
Kebutuhan data	Instrumen yang tercatat dan bervariasi	Running variable yang presisi dan ambang yang benar-benar ditegakkan
Tingkat bukti (Bab 1)	5	3

► EXECUTIVE PERSPECTIVE — menjelaskan RDD dalam satu kalimat

RDD adalah metode kausal observasional yang paling mudah dijelaskan kepada non-teknis, dan itu adalah keunggulan praktis yang nyata: *"Pelanggan dengan skor 699 dan 701 pada dasarnya orang yang sama. Satu-satunya perbedaan mereka adalah aturan kita memberi program kepada yang satu dan tidak kepada yang lain. Perbedaan hasil di antara mereka adalah dampak program."* Kalimat ini diterima dalam sepuluh detik dan tidak memerlukan pemahaman statistik apa pun — nilai komunikasi yang layak diperhitungkan saat memilih metode.

Checklist IV dan RDD

- ✓ **IV:** first-stage F dilaporkan; instrumen dengan $F < 10$ ditolak
- ✓ **IV:** semua jalur alternatif dari instrumen ke outcome ditulis dan dibantah satu per satu
- ✓ **IV:** keseimbangan kovariat antar tingkat instrumen diperiksa
- ✓ **IV:** estimand dinyatakan sebagai LATE; populasi complier dikarakterisasi dan dibandingkan dengan populasi intervensi
- ✓ **IV:** reduced form dilaporkan berdampingan — bila reduced form nol, tidak ada yang bisa diselamatkan oleh pembagian
- ✓ **RDD:** uji densitas dijalankan dan hasilnya dilaporkan apa pun kesimpulannya
- ✓ **RDD:** kontinuitas kovariat pra-treatment diperiksa di ambang
- ✓ **RDD:** minimal tiga bandwidth dan dua bentuk fungsional dilaporkan
- ✓ **RDD:** ambang palsu diuji dan menghasilkan efek nol
- ✓ **Keduanya:** pernyataan asumsi identifikasi ditulis lengkap dengan baris pembatal

Ending Card — Bab 11

What you learned

Logika instrumental variable dan diagram jalurnya; empat syarat instrumen dan mana yang dapat diuji; estimasi Wald dan 2SLS; kasus elastisitas harga dengan bukti numerik bahwa OLS bias ke arah nol; kasus keterlambatan → churn dengan kapasitas hub sebagai instrumen dan karakterisasi complier; tujuh sumber instrumen nyata beserta ancamannya; bahaya instrumen lemah; logika RDD, kasus valid pada ambang skor loyalitas, dan kasus tidak valid pada ambang gratis ongkir; enam diagnostik wajib RDD; fuzzy RDD sebagai IV; tabel perbandingan IV dan RDD.

Skills mastered

2SLS dan penilaian validitas instrumen · interpretasi LATE · RDD lengkap dengan diagnostik · uji densitas · pemilihan metode berdasarkan struktur keputusan bisnis.

Real business value

Kedua metode ini membuka pertanyaan yang sebelumnya dianggap tidak terjawab tanpa eksperimen: elastisitas harga, dampak SLA, efek program berbasis ambang. Sekaligus, kemampuan menyatakan bahwa sebuah metode *tidak sah* — seperti pada ambang gratis ongkir — mencegah analisis yang tampak canggih tetapi menghasilkan angka yang salah.

Interview readiness

● INTERVIEW QUESTIONS

1. "Apa itu instrumental variable dan apa syaratnya?" (Tiga syarat; tegaskan mana yang dapat diuji dan mana yang tidak — jawaban yang menyebut perbedaan ini langsung menonjol.)
2. "Beri contoh instrumen dari pekerjaan analytics." (Encouragement design, bug sistem, kapasitas operasional, guncangan biaya.)
3. "Mengapa regresi harga terhadap kuantitas memberi elastisitas yang terlalu kecil?" (Simultanitas; perusahaan menaikkan harga saat permintaan tinggi; tunjukkan dengan angka $-0,79$ vs $-1,85$.)
4. "Apa itu LATE dan mengapa penting?" (Efek pada complier; keputusan bisnis harus memeriksa apakah complier sama dengan populasi yang akan diintervensi.)
5. "Kapan RDD tidak sah?" (Manipulasi running variable; tunjukkan uji densitas dan contoh ambang gratis ongkir.)
6. "First-stage F kamu 6. Apa yang kamu lakukan?" (Tolak instrumen; jelaskan bahwa instrumen lemah memperbesar bias, bukan hanya menaikkan variance.)

Exercises

Exercise 11.1 (Beginner · 25 menit)

Objective: menilai validitas instrumen

Untuk tiap pasangan, nilai apakah Z adalah instrumen yang sah untuk X dalam mengukur pengaruhnya pada Y. Sebutkan syarat mana yang terpenuhi atau dilanggar:

- (a) Z = penugasan acak undangan program; X = mengikuti program; Y = belanja.
- (b) Z = jarak rumah ke toko; X = frekuensi kunjungan toko; Y = total belanja tahunan.
- (c) Z = cuaca hujan; X = kunjungan toko fisik; Y = belanja online.
- (d) Z = nomor urut antrian CS (bergilir); X = agen yang menangani; Y = kepuasan.
- (e) Z = kenaikan biaya bahan bakar; X = ongkos kirim; Y = jumlah order.

Answer key 11.1

- (a) **Sah — standar emas.** Relevansi diuji lewat tingkat penerimaan; exclusion masuk akal karena undangan itu sendiri hampir tidak mempengaruhi belanja selain lewat keikutsertaan (perhatikan: bila undangan berisi informasi promosi, exclusion bisa dilanggar).
- (b) **Tidak sah.** Jarak berkorelasi dengan demografi wilayah (pendapatan, kepadatan) yang mempengaruhi belanja lewat banyak jalur lain. Exclusion dilanggar.
- (c) **Menarik tetapi berisiko.** Relevansi kuat. Exclusion dipertanyakan: hujan juga mempengaruhi suasana hati, waktu luang di rumah, dan kecepatan pengiriman — semuanya jalur langsung ke belanja online. Bisa dipakai bila dilengkapi pemeriksaan, tetapi harus dinyatakan sebagai bukti yang lebih lemah.
- (d) **Sah bila penugasannya benar-benar bergilir.** Ini instrumen klasik untuk mengukur efek kualitas agen. Ancaman praktis: penugasan sering tidak sepenuhnya acak (kasus sulit diarahkan ke agen senior) — periksa keseimbangan karakteristik kasus antar agen.
- (e) **Sah dengan catatan.** Relevansi kuat. Ancaman: kenaikan bahan bakar bersamaan dengan kondisi makro yang menekan daya beli — jalur langsung ke jumlah order. Mitigasi: kendalikan indikator makro, atau gunakan variasi biaya yang spesifik rute/wilayah.

Exercise 11.2 (Intermediate · 50 menit)

Objective: menghitung dan menafsirkan estimasi Wald

Sebuah encouragement design: 100.000 pelanggan diacak; 50.000 menerima undangan program loyalitas, 50.000 tidak.

Penerima undangan : 18.500 bergabung (37,0%); belanja rata-rata Rp 1.284.000

Tidak diundang : 4.000 bergabung (8,0%); belanja rata-rata Rp 1.212.000

- (a) Hitung ITT (intention to treat). (b) Hitung first stage. (c) Hitung estimasi Wald (LATE). (d) Siapa complier di sini dan berapa proporsinya? (e) Manajemen bertanya: "berapa dampaknya bila semua pelanggan kita daftarkan otomatis?" — bagaimana kamu menjawab?

Answer key 11.2

- (a) $ITT = 1.284.000 - 1.212.000 = \text{Rp } 72.000$ per pelanggan yang diundang. Ini adalah efek dari kampanye undangan — dan sering kali justru angka yang paling relevan untuk keputusan anggaran.
- (b) First stage = $0,370 - 0,080 = 0,290$ (29 pp kenaikan keanggotaan akibat undangan).
- (c) Wald = $72.000 / 0,290 = \text{Rp } 248.276$ per anggota complier.
- (d) Complier = pelanggan yang bergabung karena diundang, yaitu **29% dari populasi**. Selain itu ada always-taker (8% yang bergabung meski tanpa undangan) dan never-taker (63% yang tidak bergabung meski diundang). Estimasi Rp 248.276 hanya berlaku untuk 29% ini.
- (e) Jawaban: "Data ini tidak dapat menjawab pertanyaan itu. Angka Rp 248 ribu berlaku untuk pelanggan yang bersedia bergabung ketika diundang — 29% dari basis. 63% pelanggan menolak bergabung bahkan setelah diundang; kita tidak memiliki informasi tentang efek program pada mereka, dan alasan mereka menolak (minat rendah) menunjukkan efeknya kemungkinan jauh lebih kecil. Untuk menjawab pertanyaan pendaftaran otomatis, kita perlu eksperimen yang benar-benar mendaftarkan sebagian pelanggan secara otomatis. Yang bisa saya sampaikan sekarang: kampanye undangan menghasilkan Rp 72.000 per pelanggan yang diundang, dan itulah angka yang relevan untuk memutuskan apakah kampanye diperluas."
- Perhatikan struktur jawaban: menolak melakukan ekstrapolasi yang tidak sah, tetapi tetap memberikan angka yang berguna untuk keputusan yang benar-benar dihadapi.

Exercise 11.3 (Advanced · 2 jam)

Objective: RDD lengkap dengan diagnostik

Bangun simulasi RDD: running variable, ambang, efek treatment yang kamu tetapkan, dan hubungan mulus antara running variable dan outcome. Jalankan: (1) estimasi pada tiga bandwidth; (2) uji densitas; (3) kontinuitas kovariat; (4) ambang palsu di dua titik; (5) polinomial derajat 1 dan 2; (6) donut hole. Lalu **tanamkan manipulasi** (sebagian unit menggeser diri ke atas ambang) dan ulangi seluruh diagnostik — tunjukkan diagnostik mana yang berhasil mendeteksinya dan seberapa besar bias yang dihasilkan.

Answer key 11.3 — rubrik

Yang harus muncul: pada versi bersih, estimasi stabil lintas bandwidth dan uji densitas lolos; pada versi term manipulasi, **uji densitas gagal secara mencolok** sementara estimasi RDD tetap terlihat "bagus" (presisi tinggi, signifikan) — inilah pelajaran utamanya: *output RDD tidak menunjukkan tanda-tanda kerusakan; hanya diagnostik yang menunjukkannya*. Bonus untuk peserta yang menunjukkan bahwa kontinuitas kovariat juga gagal (unit yang memanipulasi berbeda karakteristiknya) dan bahwa donut hole mengubah estimasi secara substansial.

Exercise 11.4 (Production Challenge · 6 jam)

Objective: elastisitas harga dengan tiga metode

Dengan data publik berisi harga dan kuantitas (Online Retail II atau data harga komoditas), estimasi elastisitas harga dengan: (1) OLS naif; (2) OLS dengan efek tetap produk dan waktu; (3) IV dengan instrumen biaya atau harga di pasar lain. Bandingkan ketiganya, jelaskan arah bias masing-masing, dan tulis rekomendasi penetapan harga beserta rentang ketidakpastiannya. Tutup dengan rancangan geo experiment yang akan menguji rekomendasimu, lengkap dengan perkiraan MDE dan durasi (Bab 3).

Answer key 11.4 — rubrik

Kriteria: ketiga estimasi dilaporkan berdampingan dengan arah bias yang dijelaskan (OLS naif paling bias ke nol; efek tetap mengurangi sebagian; IV paling dekat bila instrumennya sah); first-stage F dilaporkan; rekomendasi harga memakai rentang, bukan titik; dan rancangan eksperimen realistis secara operasional. Kesalahan umum: melaporkan elastisitas IV tanpa memeriksa apakah instrumennya memenuhi exclusion — pada data ritel, harga di pasar lain sering dipengaruhi guncangan permintaan bersama, yang membatalkan exclusion. Peserta yang menyadari dan membahas ini mendapat nilai tertinggi.

Portfolio idea

★ PORTFOLIO TIP

Proyek elastisitas harga (Exercise 11.4) menyentuh keputusan bisnis yang paling langsung bernilai uang. Sajikan sebagai satu halaman: tiga angka elastisitas, penjelasan mengapa berbeda, dan rekomendasi harga dengan rentang. Tambahkan grafik RDD dari Exercise 11.3 sebagai lampiran metodologis — kombinasi keduanya menunjukkan penguasaan dua metode identifikasi sekaligus.

Further reading

Angrist & Pischke, *Mostly Harmless Econometrics* (Bab 4: IV; Bab 6: RD) · Imbens & Angrist (1994) tentang LATE · Stock & Yogo tentang instrumen lemah · Lee & Lemieux, "Regression Discontinuity Designs in Economics" · Calonico, Cattaneo & Titiunik tentang inferensi RDD yang robust · Cattaneo, Idrobo & Titiunik, *A Practical Introduction to Regression Discontinuity Designs*.

Next chapter

Bab 12 — penerapan seluruh Bagian II pada masalah yang paling banyak membakar uang di perusahaan mana pun: mengukur apakah belanja iklan benar-benar menghasilkan penjualan tambahan. Geo experiment, switchback, ghost ads, dan mengapa dashboard attribution hampir selalu salah.

Bab 12 — Incrementality Marketing: Geo Experiment, Switchback, MMM

Dashboard attribution mengatakan iklan menghasilkan 220 ribu pelanggan baru. Eksperimen mengatakan 73 ribu. Bab ini tentang selisih itu — dan Rp 32 miliar yang bergantung padanya.

Learning objectives	Menjelaskan mengapa attribution bukan kausalitas; merancang dan menganalisis geo experiment termasuk pemilihan pasangan kota dan power; menjalankan switchback test; memahami ghost ads dan PSA test; menempatkan MMM secara benar dalam bauran metode; menghitung incremental CAC dan CLV:CAC yang jujur; menyusun program pengukuran incrementality berkelanjutan
Prerequisites	Bab 3 (power), Bab 6 (interferensi), Bab 9 (DiD); Vol 3 Bab 5 (funnel, CAC, attribution) dan Bab 6 (CLV)
Estimasi waktu	Baca 2,5 jam · Praktik 5 jam
Difficulty	● Advanced
Skills covered	Geo experiment design, matched-pair randomization, switchback, ghost ads, MMM interpretation, incremental CAC
Business domain	Marketing retail omnichannel — anggaran Rp 54 miliar, 620 ribu pelanggan baru per tahun

Mengapa attribution selalu melebihi-lebihkan

Vol 3 Bab 5 memperkenalkan model attribution (last-click, first-click, linear, time-decay) dan menutup dengan peringatan: semuanya menjawab pertanyaan "sentuhan mana yang terjadi sebelum pembelian", bukan "pembelian mana yang *tidak akan terjadi* tanpa sentuhan itu". Bab ini menjelaskan besarnya perbedaan.

PERTANYAAN ATTRIBUTION

"Dari 100 pembeli, berapa yang melewati iklan berbayar?"
→ jawaban: 65. Maka iklan "menghasilkan" 65 pembeli.

PERTANYAAN INCREMENTALITY

"Dari 100 pembeli, berapa yang TIDAK AKAN membeli seandainya iklan tidak ada?"
→ jawaban: mungkin 20. Sisanya akan tetap membeli lewat pencarian organik, aplikasi, atau kunjungan langsung.

Selisih 45 pembeli adalah pembelian yang DIKLAIM iklan padahal akan terjadi juga. Inilah yang dibayar setiap bulan.

Empat mekanisme yang menciptakan selisih

Mekanisme	Penjelasan	Besaran tipikal
Permintaan yang sudah ada	Iklan pencarian bermerek muncul di depan orang yang sudah mengetik	Paling besar; sering 50–90% dari klik iklan bermerek

	nama tokomu — mereka akan datang tanpa iklan	
Kanibalisasi organik	Klik berbayar menggantikan klik organik yang gratis	Beberapa studi menemukan sebagian besar klik berbayar bermerek dapat digantikan organik
Kredit ganda antar platform	Setiap platform mengklaim konversi yang sama; jumlah klaim melebihi total order	Rutin 120–200% dari order sebenarnya
Targeting yang memilih pembeli	Algoritma platform menargetkan orang yang paling mungkin membeli — lalu mengklaim pembelian mereka	Struktural; makin canggih targeting, makin besar overclaim

⚠ **WARNING — "Total konversi terklaim melebihi total order" adalah tes lima menit**

Jumlahkan konversi yang diklaim seluruh platform iklan, lalu bandingkan dengan jumlah order sebenarnya di sistem internal. Bila totalnya melebihi 100%, sebagian klaim pasti salah — dan itu argumen paling cepat dan paling sulit dibantah untuk memulai program incrementality. Lakukan pemeriksaan ini sebelum rapat anggaran marketing berikutnya.

Geo experiment: standar emas untuk marketing

Iklan tidak dapat diacak per pengguna: penargetan platform tidak bekerja pada tingkat itu, iklan luar ruang dan televisi tidak dapat disegmentasi, dan pengguna saling terpapar. Unit yang tepat adalah **wilayah geografis**.

Desain

1. PILIH PASAR 40–80 kota/DMA dengan data historis ≥ 6 bulan
2. PASANGKAN Bentuk pasangan kota dengan pola historis paling mirip (korelasi deret waktu, ukuran, bauran kanal). Matched-pair jauh lebih kuat daripada pengacakan sederhana.
3. ACAK DALAM PASANGAN Satu dari tiap pasangan menjadi treatment
4. TENTUKAN ARAH
 - HOLDOUT (matikan iklan): mengukur berapa yang hilang → langsung menjawab "apakah layak"
 - LIFT (naikkan anggaran): mengukur marginal return → menjawab "berapa anggaran optimal"
5. PRA-PERIODE Minimal 8 minggu untuk kalibrasi & pemeriksaan
6. PERIODE TES 6–12 minggu (efek iklan butuh waktu terakumulasi dan meluruh)
7. ANALISIS DiD dengan efek tetap kota & minggu, SE cluster pada kota (Bab 9)

■ TECHNICAL NOTE — power adalah kendala utama geo experiment

Empat puluh kota berarti 20 unit per kelompok. Dengan variasi antar kota $CV = 0,45$, MDE tanpa penyesuaian mencapai **39,9% relatif** — tidak berguna untuk pertanyaan apa pun.

40 kota, CV 0,45, tanpa kontrol pra-periode → MDE 39,9%
40 kota, dengan kontrol pra-periode $p=0,85$ → MDE 21,0%
40 kota, dengan kontrol pra-periode $p=0,93$ → MDE 14,7%
60 kota, dengan kontrol pra-periode $p=0,90$ → MDE 14,2%

Kesimpulan operasional: **geo experiment tanpa pemasangan dan kontrol pra-periode hampir selalu sia-sia**. Kualitas pemasangan kota (yang menghasilkan p tinggi) adalah faktor tunggal paling menentukan keberhasilan desain ini — lebih penting daripada pilihan estimator mana pun.

Kasus TokoNusa: geo holdout iklan berbayar

DESAIN 40 kota, matched-pair berdasarkan ukuran & pola historis
20 kota treatment: seluruh iklan berbayar DIMATIKAN
20 kota kontrol : anggaran normal
8 minggu pra-periode + 8 minggu tes
OUTCOME log(pelanggan baru per kota per minggu)
ANALISIS DiD, efek tetap kota & minggu, SE cluster kota

HASIL -11,83% (SE 1,65; CI 95% -15,07% s/d -8,59%)

INTERPRETASI: mematikan seluruh iklan berbayar menurunkan akuisisi pelanggan baru 11,8%. Maka kontribusi inkremental iklan berbayar adalah 11,8% dari akuisisi — bukan 35,5% yang diklaim model last-click.

Ekonomi yang berubah total

Basis TokoNusa (Vol 3): 620.000 pelanggan baru/tahun;
anggaran paid Rp 32 miliar dari total marketing Rp 54 miliar.

	ATRIBUSI	INCREMENTALITY
Pelanggan baru dari paid	220.000 (35,5% dari total)	73.160 (11,8% dari total)
CAC	Rp 145.455	Rp 437.397
CLV (Vol 3)	Rp 496.000	Rp 496.000
CLV : CAC	3,41	1,13
Penilaian	"sehat, perluas"	"nyaris impas"

◆ BUSINESS INSIGHT — apa yang harus dilakukan dengan temuan seperti ini

Rasio CLV:CAC 1,13 berarti setiap rupiah yang dibelanjakan menghasilkan sedikit di atas satu rupiah nilai seumur hidup — sebelum memperhitungkan biaya modal dan waktu pengembalian. Ini bukan alasan untuk menghentikan seluruh belanja iklan; ini alasan untuk mengubah pertanyaannya.

Langkah yang benar setelah temuan ini:

- **Pisahkan per kanal dan per jenis kampanye.** Angka agregat menyembunyikan variasi besar: iklan pencarian bermerek biasanya paling rendah incrementality-nya; kampanye prospecting ke audiens baru biasanya paling tinggi. Geo test berikutnya harus per kanal.
- **Cari kurva respons, bukan satu titik.** Holdout mengukur efek dari *seluruh* anggaran. Yang dibutuhkan untuk keputusan alokasi adalah efek marginal — dan itu memerlukan tes lift bertingkat (anggaran +20%, +50%) yang membentuk kurva hasil yang menurun.
- **Jangan potong anggaran dalam satu langkah besar.** Efek iklan meluruh perlahan; pemotongan drastis dapat merusak brand yang butuh tahunan dibangun. Turunkan bertahap sambil terus mengukur.
- **Ubah metric tim marketing.** Selama tim dinilai berdasarkan CAC atribusi, mereka akan mengoptimalkan hal yang salah — bukan karena tidak jujur, melainkan karena itulah yang diukur (Goodhart, Vol 3 Bab 13).

► EXECUTIVE PERSPECTIVE — menyampaikan hasil yang menyerang pekerjaan tim lain

Temuan ini menyatakan bahwa angka yang dilaporkan tim marketing selama bertahun-tahun terlalu besar tiga kali lipat. Cara menyampaikan menentukan apakah ia menghasilkan perbaikan atau perang.

Yang bekerja: *"Model attribution kita bekerja persis seperti yang dirancang — ia mengukur sentuhan sebelum pembelian. Masalahnya bukan pada timnya atau alatnya, melainkan pada pertanyaan yang dijawabnya. Untuk keputusan anggaran kita membutuhkan pertanyaan yang berbeda, dan itu hanya bisa dijawab dengan eksperimen. Saya mengusulkan kita menjalankannya bersama, per kanal, dan memakai hasilnya untuk merancang ulang target tim — bukan untuk menilai kinerja masa lalu."*

Tiga elemen yang membuatnya diterima: tidak menyalahkan orang, membingkai sebagai pertanyaan yang berbeda alih-alih kesalahan, dan menawarkan kepemilikan bersama atas langkah berikutnya.

Metode lain dalam bauran incrementality

Ghost ads dan PSA test

Metode	Cara kerja	Kekuatan & batas
Ghost ads	Platform mencatat siapa yang <i>akan</i> melihat iklan di kelompok kontrol, tanpa benar-benar menayangkannya	Perbandingan sangat presisi karena kedua kelompok melewati proses lelang yang sama; hanya tersedia bila platform menyediakannya
PSA test	Kelompok kontrol melihat iklan layanan masyarakat sebagai pengganti	Mudah diterapkan; tetapi lelang berubah — iklan PSA sering memenangkan pengguna yang berbeda dari iklan komersial, sehingga kelompok tidak sepenuhnya sebanding
Intent-to-treat pada audiens	Acak daftar audiens yang diunggah ke platform	Sederhana; tetapi pencocokan audiens tidak sempurna dan dilusi besar
Conversion lift bawaan platform	Platform menjalankan eksperimennya sendiri	Murah dan cepat; tetapi platform mengukur dan menilai dirinya sendiri — perlakukan sebagai indikasi, bukan bukti independen

✗ COMMON MISTAKE — Mempercayai conversion lift study platform sebagai bukti akhir

Gejala: keputusan anggaran diambil berdasarkan laporan lift yang disediakan platform iklan itu sendiri.

Mengapa terjadi: laporannya gratis, cepat, dan memakai bahasa eksperimen yang benar.

Masalahnya: pihak yang diukur adalah pihak yang mengukur; definisi konversi, jendela atribusi, dan komposisi kelompok kontrol ditentukan oleh mereka; dan hasil yang tidak menguntungkan tidak selalu dipublikasikan.

Perbaikan: gunakan sebagai sinyal awal dan untuk membandingkan kampanye *di dalam* platform yang sama; verifikasi keputusan besar dengan geo experiment yang dikendalikan sendiri.

Cara senior menghindarinya: menetapkan aturan bahwa keputusan anggaran di atas ambang tertentu memerlukan bukti yang dihasilkan secara internal.

Switchback untuk marketplace dan layanan on-demand

Ketika treatment mempengaruhi seluruh sistem — algoritma pencocokan, harga dinamis, alokasi kurir — tidak ada pengguna yang benar-benar berada di kelompok kontrol. Switchback memindahkan randomisasi ke dimensi waktu.

```
Kota A: [ T ][ C ][ C ][ T ][ T ][ C ][ C ][ T ] ...
Kota B: [ C ][ T ][ T ][ C ][ C ][ T ][ T ][ C ] ...
        ← interval 2–6 jam, diacak per kota per interval →
```

Unit analisis = kota × interval waktu

SYARAT KELAYAKAN

- Carryover kecil: efek interval sebelumnya tidak merembes (bila ada, buang periode "washout" di awal tiap interval)
- Interval cukup panjang agar sistem mencapai keseimbangan, cukup pendek agar jumlah unit memadai
- Analisis memperhitungkan autokorelasi antar interval (cluster pada kota × hari, atau SE Newey-West)

Marketing mix modeling (MMM)

MMM adalah regresi deret waktu agregat: penjualan sebagai fungsi dari belanja tiap kanal, harga, musim, dan variabel eksternal, dengan transformasi adstock (efek tertunda) dan saturasi (hasil menurun).

Kekuatan MMM	Keterbatasan yang harus dinyatakan
Mencakup kanal offline (TV, luar ruang, sponsorship) yang tidak dapat dilacak	Bersifat korelasional; belanja iklan bergerak bersama musim, promo, dan keputusan bisnis lain (confounding)
Tidak bergantung pada cookie atau identitas pengguna	Kolinearitas antar kanal yang dibelanjakan bersamaan membuat pemisahan kontribusi tidak stabil
Memberi gambaran alokasi jangka panjang	Sangat sensitif terhadap pilihan spesifikasi; hasil dapat berubah besar dengan perubahan asumsi adstock
Dapat dijalankan dari data historis yang sudah ada	Tidak dapat memvalidasi dirinya sendiri tanpa eksperimen

✓ BEST PRACTICE — Kalibrasi MMM dengan eksperimen

Praktik yang kini menjadi standar di perusahaan besar: jalankan geo experiment pada beberapa kanal, lalu **paksa MMM menghasilkan koefisien yang konsisten dengan hasil eksperimen** untuk kanal-kanal itu. MMM kemudian dipakai untuk mengekstrapolasi ke kanal yang tidak dieksperimenkan dan untuk perencanaan alokasi.

Pembagian peran yang tepat: *eksperimen memberi kebenaran pada beberapa titik; MMM menghubungkan titik-titik itu menjadi kurva*. MMM tanpa kalibrasi eksperimen adalah bukti tingkat 6-7 (Bab 1) yang rutin dipakai untuk keputusan miliaran rupiah — dan itu adalah salah satu kesenjangan terbesar antara praktik umum dan praktik yang benar.

Program incrementality berkelanjutan

KUARTALAN

- └ Geo holdout pada 1-2 kanal bergilir (rotasi tahunan)
- └ Selalu-aktif: holdout 3-5% audiens pada kanal berbasis audiens (email, notifikasi, retargeting) — biayanya kecil dan memberi pengukuran terus-menerus
- └ Rekonsiliasi: total konversi terklaim vs order aktual

TAHUNAN

- └ Refresh MMM, dikalibrasi dengan seluruh hasil eksperimen
- └ Kurva respons per kanal untuk perencanaan anggaran
- └ Revisi target tim marketing ke metric inkremental

SETIAP KEPUTUSAN ANGGARAN BESAR

- └ Wajib disertai estimasi incrementality beserta sumbernya dan tanggal pengukurannya (hasil dua tahun lalu tidak berlaku — platform, algoritma, dan kompetisi berubah)

Checklist incrementality marketing

- ✓ Rekonsiliasi konversi terklaim vs order aktual dijalankan dan dilaporkan
- ✓ Geo experiment memakai matched-pair, bukan pengacakan sederhana
- ✓ Pra-periode minimal 8 minggu; kualitas pemasangan diukur dengan korelasi historis
- ✓ MDE dihitung sebelum tes; desain tanpa kontrol pra-periode ditolak
- ✓ Analisis memakai DiD dengan SE cluster pada unit geografis
- ✓ Arah tes (holdout vs lift) dipilih sesuai pertanyaan keputusan
- ✓ Hasil dipecah per kanal dan per jenis kampanye, tidak berhenti pada agregat
- ✓ Incremental CAC dan CLV:CAC dihitung dan dibandingkan dengan versi atribusi
- ✓ MMM dikalibrasi dengan hasil eksperimen sebelum dipakai untuk keputusan
- ✓ Studi lift dari platform diperlakukan sebagai indikasi, bukan bukti independen
- ✓ Estimasi incrementality diberi tanggal dan diperbarui berkala

Ending Card — Bab 12

What you learned

Perbedaan fundamental antara attribution dan incrementality serta empat mekanisme yang menciptakan selisihnya; tes rekonsiliasi lima menit; desain geo experiment lengkap dengan matched-pair dan tabel MDE yang menunjukkan mengapa kontrol pra-periode wajib; kasus TokoNusa dengan CAC yang berubah dari Rp 145 ribu menjadi Rp 437 ribu dan CLV:CAC dari 3,41 menjadi 1,13; ghost ads, PSA test, dan batas studi lift platform; switchback untuk sistem yang saling terhubung; peran dan keterbatasan MMM serta kalibrasi dengan eksperimen; rancangan program incrementality berkelanjutan.

Skills mastered

Desain dan analisis geo experiment · switchback · penilaian metode incrementality · perhitungan CAC inkremental · komunikasi temuan yang menantang tim lain.

Real business value

Anggaran marketing adalah salah satu pos pengeluaran diskresioner terbesar di perusahaan konsumen. Selisih antara CAC atribusi dan CAC inkremental pada kasus ini setara dengan penilaian yang keliru atas Rp 32 miliar per tahun. Tidak banyak analisis tunggal yang memiliki taruhan sebesar ini.

Interview readiness

● INTERVIEW QUESTIONS

1. "Apa bedanya attribution dan incrementality?" (Sentuhan sebelum pembelian versus pembelian yang tidak akan terjadi tanpanya; sebutkan empat mekanisme selisih.)
2. "Bagaimana kamu mengukur apakah iklan Facebook kami bekerja?" (Geo holdout dengan matched-pair; jelaskan power sebagai kendala utama; sebutkan ghost ads bila tersedia; jangan langsung mengandalkan laporan platform.)
3. "Kami tidak bisa mematikan iklan — kehilangan pendapatannya terlalu besar." (Holdout parsial pada sedikit kota, tes lift alih-alih holdout, atau holdout audiens 3-5% yang biayanya kecil.)
4. "Apa pendapatmu tentang MMM?" (Berguna untuk kanal offline dan perencanaan; korelasional; wajib dikalibrasi dengan eksperimen.)
5. "Total konversi yang diklaim platform 160% dari order kami. Apa artinya?" (Kredit ganda; bukti langsung bahwa attribution tidak dapat dijumlahkan; usulkan program incrementality.)
6. "CAC inkremental kalian 3× lipat CAC atribusi. Haruskah kami menghentikan iklan?" (Tidak serta-merta; pecah per kanal; cari efek marginal lewat kurva respons; turunkan bertahap; ubah metric tim.)

Exercises

Exercise 12.1 (Beginner · 25 menit)

Objective: menghitung incremental CAC

Sebuah e-commerce membelanjakan Rp 18 miliar setahun pada iklan pencarian. Model last-click mengatakan iklan ini menghasilkan 140.000 pelanggan baru dari total 400.000. Geo holdout menunjukkan mematikan iklan pencarian menurunkan akuisisi total 6,5%.

- (a) Hitung CAC atribusi dan CAC inkremental. (b) Dengan CLV Rp 520.000, hitung kedua rasio CLV:CAC. (c) Apa rekomendasimu, dan informasi tambahan apa yang kamu minta sebelum memutuskan?

Answer key 12.1

(a) CAC atribusi = 18 miliar / 140.000 = **Rp 128.571**. Pelanggan inkremental = $6,5\% \times 400.000 = 26.000$. CAC inkremental = 18 miliar / 26.000 = **Rp 692.308**.

(b) CLV:CAC atribusi = $520.000/128.571 = 4,04$. CLV:CAC inkremental = $520.000/692.308 = 0,75$ — *di bawah satu*, artinya setiap rupiah yang dibelanjakan menghasilkan kurang dari satu rupiah nilai seumur hidup.

(c) Rekomendasi: jangan memotong seluruhnya sekaligus. Minta informasi: **(i)** pemecahan antara pencarian *bermerek* dan *non-merek* — hampir pasti *bermerek* yang menghancurkan rata-rata, karena orang yang mengetik nama toko akan datang tanpa iklan; **(ii)** kurva respons: apakah pengurangan 30% anggaran menurunkan akuisisi secara proporsional atau jauh lebih kecil; **(iii)** efek jangka panjang pada pangsa pencarian dan kompetitor yang mungkin mengambil posisi yang ditinggalkan. Langkah konkret: geo test terpisah untuk pencarian *bermerek* — tes ini sering menghasilkan temuan paling dramatis dan paling mudah ditindaklanjuti.

Exercise 12.2 (Intermediate · 60 menit)

Objective: merancang geo experiment

TokoNusa ingin menguji incrementality iklan media sosial. Tersedia data mingguan 52 kota selama 2 tahun. Variasi antar kota $CV = 0,52$; korelasi pra-pasca per kota $\rho = 0,88$. Anggaran kanal ini Rp 9 miliar/tahun; efek yang dianggap penting: bila incrementality di bawah 8%, anggaran akan dipotong.

(a) Hitung MDE dengan 52 kota dan kontrol pra-periode. (b) Apakah desain ini layak? (c) Rancang desain lengkap: pemasangan, durasi, arah tes, outcome, analisis. (d) Sebutkan tiga ancaman validitas dan mitigasinya.

Answer key 12.2

(a) $n = 26$ per kelompok; $\sigma \text{ efektif} = 0,52 \times \sqrt{(1-0,88^2)} = 0,52 \times 0,475 = 0,247$. $MDE = 2,8016 \times \sqrt{(2 \times 0,247^2/26)} = 2,8016 \times 0,0685 = 19,2\% \text{ relatif}$.

(b) **Tidak layak untuk ambang 8%** — MDE 19,2% jauh di atas efek yang perlu dideteksi. Opsi perbaikan: (i) tambah kota bila tersedia; (ii) perbaiki pemasangan untuk menaikkan ρ ($\rho=0,95$ menurunkan MDE ke $\pm 12,6\%$); (iii) perpanjang periode pengukuran agar kebisingan mingguan tereratakan; (iv) ubah pertanyaan menjadi holdout *penuh* yang efeknya lebih besar dan lebih mudah dideteksi, lalu turunkan kesimpulannya ke ambang keputusan.

(c) Desain: pasang kota berdasarkan korelasi deret waktu akuisisi 12 bulan *dan* ukuran; acak dalam pasangan; pra-periode 12 minggu; tes 10 minggu (media sosial memiliki efek tertunda); arah **holdout penuh** untuk memaksimalkan efek yang terdeteksi; outcome $\log(\text{pelanggan baru per kota-minggu})$ dengan outcome sekunder $\log(\text{revenue})$; analisis DiD efek tetap kota & minggu, SE cluster kota, plus event study untuk memeriksa pra-tren dan pola peluruhan.

(d) Ancaman: **(i) Limpahan antar kota** — iklan media sosial tidak berhenti tepat di batas kota, dan pengguna bepergian. Mitigasi: pilih kota yang berjauhan; kecualikan kota yang berbatasan langsung dengan kota treatment. **(ii) Realokasi anggaran otomatis** — platform memindahkan anggaran dari kota yang dimatikan ke kota lain, mencemari kontrol. Mitigasi: kunci anggaran per kampanye dan verifikasi belanja aktual per kota selama tes. **(iii) Efek yang meluruh perlahan** — brand yang dibangun bertahun-tahun tidak hilang dalam 10 minggu, sehingga holdout jangka pendek *meremehkan* efek jangka panjang. Mitigasi: nyatakan keterbatasan ini secara eksplisit; pertimbangkan holdout yang lebih panjang di sebagian kota sebagai tindak lanjut.

Exercise 12.3 (Advanced · 2 jam)

Objective: menganalisis geo experiment

Bangun simulasi geo experiment: 40 kota matched-pair, 8 minggu pra + 8 minggu tes, efek treatment yang kamu tetapkan. Jalankan analisis DiD dengan SE cluster, event study, dan uji placebo in-time. Lalu ulangi dengan (a) pengacakan sederhana alih-alih matched-pair dan (b) tanpa periode pra. Bandingkan lebar CI ketiga desain dan tulis rekomendasi desain untuk tim marketing beserta angkanya.

Answer key 12.3 — rubrik

Hasil yang diharapkan: matched-pair dengan kontrol pra-periode menghasilkan CI paling sempit; pengacakan sederhana menghasilkan CI jauh lebih lebar dan sesekali estimasi yang meleset jauh (karena ketidakseimbangan antar kelompok pada 20 unit sangat mungkin terjadi); tanpa periode pra, seluruh manfaat variance reduction hilang. Rekomendasi yang kuat menyebut angka konkret: "matched-pair menghemat X minggu tes atau setara Y kota tambahan". Kesalahan umum: lupa cluster SE, yang membuat ketiga desain tampak sama-sama presisi dan menghapus seluruh pelajaran latihan.

Exercise 12.4 (Production Challenge · 6 jam)

Objective: rencana pengukuran marketing satu tahun

Susun rencana pengukuran incrementality 12 bulan untuk sebuah perusahaan dengan 5 kanal marketing dan anggaran tertentu. Muat: rekonsiliasi awal konversi terklaim vs order; kalender eksperimen per kuartal dengan alasan prioritas; desain untuk tiap tes termasuk MDE; holdout selalu-aktif untuk kanal berbasis audiens; rencana kalibrasi MMM; usulan perubahan metric dan target tim marketing; serta anggaran dan biaya kesempatan program pengukuran itu sendiri. Tutup dengan satu halaman ringkasan untuk CMO.

Answer key 12.4 — rubrik

Rencana yang kuat: memprioritaskan kanal berdasarkan *anggaran × ketidakpastian*, bukan berdasarkan kemudahan pengukuran; menghitung biaya kesempatan holdout secara eksplisit (pendapatan yang hilang selama tes) dan membandingkannya dengan nilai informasi (Bab 7); memuat holdout selalu-aktif yang biayanya rendah; dan mengusulkan perubahan metric tim yang realistis secara politik (transisi bertahap, bukan penggantian mendadak). Halaman ringkasan untuk CMO harus dapat dibaca dalam 90 detik dan memuat satu angka: berapa besar anggaran yang saat ini dialokasikan tanpa bukti kausal.

Portfolio idea

★ PORTFOLIO TIP

Rencana pengukuran incrementality (Exercise 12.4) adalah dokumen yang langsung relevan untuk peran marketing analytics, growth, dan performance marketing. Bila memungkinkan, lengkapi dengan analisis geo experiment tersimulasi sebagai lampiran teknis — kombinasi dokumen strategis dan bukti kemampuan teknis sangat jarang ditemukan dalam satu portfolio.

Further reading

Blake, Nosko & Tadelis (2015), "Consumer Heterogeneity and Paid Search Effectiveness" (eksperimen eBay pada iklan pencarian bermerek) · Lewis & Rao, "The Unfavorable Economics of Measuring the Returns to Advertising" · Johnson, Lewis & Nubbemeyer tentang ghost ads · dokumentasi Google Meridian dan Meta Robyn untuk MMM sumber terbuka · Bojinov, Simchi-Levi & Zhao tentang desain switchback.

Next chapter

Bab 13 menutup Bagian III. Metode yang benar di organisasi yang salah tetap menghasilkan keputusan buruk. Bagaimana membangun program eksperimentasi dari nol, tata kelola yang mencegah manipulasi, etika eksperimen pada manusia, dan budaya yang membuat hasil negatif diterima alih-alih dikubur.

Bab 13 — Program Eksperimentasi, Governance & Etika

Metode yang benar di dalam organisasi yang salah tetap menghasilkan keputusan yang buruk. Bab ini tentang kelembagaan.

Learning objectives	Menilai kematangan program eksperimentasi dan merancang jalur peningkatannya; membangun tata kelola yang mencegah manipulasi hasil; menetapkan peran, kepemilikan keputusan, dan aturan penghentian; merancang experiment log dan knowledge base; menerapkan prinsip etika eksperimen pada manusia; mengenali dan menangani patologi budaya yang merusak program
Prerequisites	Seluruh Bab 1–12; Vol 3 Bab 13 (Goodhart's Law & metric governance)
Estimasi waktu	Baca 2 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	Program design, experimentation governance, experiment log, research ethics, organizational change
Business domain	Lintas industri — dengan penerapan pada TokoNusa

Mengapa kelembagaan menentukan hasil

Dua perusahaan dengan kemampuan statistik identik dapat memperoleh nilai yang sangat berbeda dari eksperimentasi. Pembedanya bukan metode, melainkan jawaban atas pertanyaan-pertanyaan berikut:

- Siapa yang berhak menghentikan eksperimen, dan atas dasar apa?
- Apa yang terjadi ketika hasil bertentangan dengan keyakinan orang paling senior di ruangan?
- Apakah eksperimen yang kalah dicatat, atau menghilang?
- Apakah tim diukur dari jumlah tes yang dijalankan, atau dari dampak yang terverifikasi?

Jawaban atas empat pertanyaan itu menentukan apakah program menghasilkan keputusan yang lebih baik atau sekadar menghasilkan slide yang lebih meyakinkan untuk keputusan yang sudah diambil.

Model kematangan program eksperimentasi

Tkt	Nama	Ciri	Langkah berikutnya
0	Tidak ada	Keputusan berdasarkan pendapat; "kami tahu pelanggan kami"	Jalankan satu tes bernilai tinggi sampai selesai; publikasikan hasilnya apa pun jawabannya
1	Ad hoc	Beberapa tes per tahun; tidak ada standar; hasil diperdebatkan setelah muncul	Wajibkan dokumen desain satu halaman dan pre-registration
2	Terstandar	Template desain, OEC, guardrail; SRM diperiksa; tes berjalan sesuai durasi rencana	Bangun experiment log dan knowledge base; mulai holdout global
3	Terukur		

		Holdout global; dampak program dilaporkan dengan angka yang terverifikasi; power minimum ditegakkan	Variance reduction (CUPED); analisis heterogenitas; naikan throughput
4	Terlembaga	Eksperimen menjadi default untuk perubahan berdampak; platform mandiri; tim non-analytics menjalankan sendiri dengan pengawasan	Perluas ke domain sulit: harga, logistik, marketing incrementality
5	Kapabilitas strategis	Kecepatan belajar menjadi keunggulan kompetitif; keputusan besar dipecah menjadi tahap dengan titik keputusan berbasis bukti	Pertahankan; lawan erosi ke tingkat lebih rendah saat tekanan meningkat

◆ BUSINESS INSIGHT — lompatan yang paling bernilai adalah dari 1 ke 2

Godaan yang umum adalah mengejar kecanggihan teknis (bandit, inferensi Bayesian, platform mahal) sebelum dasar-dasarnya kokoh. Kenyataannya, sebagian besar nilai berasal dari hal-hal yang tidak canggih sama sekali: dokumen desain satu halaman, OEC yang disepakati di muka, durasi yang tidak dinegosiasikan ulang, dan pemeriksaan SRM. Perusahaan pada tingkat 1 yang naik ke tingkat 2 biasanya memperoleh peningkatan kualitas keputusan yang lebih besar daripada perusahaan tingkat 3 yang membeli platform baru.

Tata kelola: aturan yang harus tertulis

Peran dan kepemilikan

Peran	Tanggung jawab	Batas kewenangan
Pengusul (product/marketing)	Hipotesis, mekanisme, nilai bisnis yang diharapkan	Tidak berwenang menghentikan tes lebih awal atau mengubah OEC setelah tes berjalan
Analyst	Desain, power, OEC, guardrail, analisis, memo	Berwenang <i>membatalkan</i> tes karena alasan validitas; tidak berwenang memutuskan rilis
Pemilik keputusan (VP/direktur)	Keputusan rilis; dapat meng- <i>override</i> pelanggaran guardrail secara tertulis	Override harus tercatat beserta alasannya; tidak boleh diam-diam
Penjaga platform	Kesehatan platform, A/A berkelanjutan, standar metric	Berwenang menghentikan tes yang merusak platform atau melanggar etika

Aturan yang tidak dapat dinegosiasikan

1. Dokumen desain di-pre-register sebelum data pertama masuk.
2. OEC, guardrail, durasi, dan aturan keputusan tidak dapat diubah setelah tes berjalan. Perubahan = tes baru.
3. Tes tidak dihentikan lebih awal kecuali:
 - (a) guardrail dilanggar, atau
 - (b) metode sequential dipakai sejak desain.
4. SRM $p < 0,001 \rightarrow$ tes dibatalkan, tidak dianalisis, tidak dilaporkan sebagai hasil.
5. Semua tes dicatat di experiment log – termasuk yang kalah, yang dibatalkan, dan yang tidak konklusif.
6. Segmen yang tidak diregistrasi dilaporkan sebagai hipotesis, dengan jumlah segmen yang diperiksa disebutkan.

7. Klaim dampak bisnis memakai batas bawah CI setelah peluruhan.
8. Kemenangan bernilai material wajib disertai holdout.

✓ BEST PRACTICE — Override yang tercatat lebih baik daripada aturan yang dilanggar diam-diam

Aturan yang terlalu kaku akan dilanggar; aturan yang dilanggar diam-diam merusak seluruh sistem. Desain yang bekerja: sediakan mekanisme **override eksplisit** yang mengharuskan pemilik keputusan menuliskan alasannya di experiment log. Ini menjaga fleksibilitas bisnis sekaligus menjaga jejak audit. Setelah setahun, tinjau seluruh override — polanya akan menunjukkan aturan mana yang perlu direvisi dan siapa yang perlu diajak bicara.

Experiment log dan knowledge base

Aset terbesar dari program eksperimentasi bukan tes yang sedang berjalan, melainkan akumulasi dari semua tes yang pernah dijalankan. Tanpa pencatatan, organisasi mengulang tes yang sama setiap dua tahun karena orang-orangnya berganti.

STRUKTUR EXPERIMENT LOG — satu baris per eksperimen

ID · nama · tanggal mulai/selesai · pengusul · analyst · pemilik keputusan · hipotesis + mekanisme · estimand · unit randomisasi · OEC · guardrail + ambang · MDE rencana · durasi rencana vs aktual · status validitas (SRM, dsb) · hasil OEC + CI · hasil guardrail · KEPUTUSAN · alasan · override (bila ada) + siapa · dampak rupiah (batas bawah) · holdout dipasang? · tautan ke memo lengkap · KATA KUNCI (area produk, jenis perubahan, segmen)

YANG SERING DILUPAKAN DAN PALING BERHARGA:

- tes yang DIBATALKAN dan mengapa
- tes yang TIDAK KONKLUSIF (agar tidak disalahartikan sebagai "sudah dicoba dan tidak berhasil")
- prediksi tim sebelum tes (kalibrasi organisasi, Bab 2)

■ TECHNICAL NOTE — meta-analisis atas experiment log

Setelah 50–100 eksperimen tercatat, log itu sendiri menjadi sumber data yang berharga. Analisis yang layak dijalankan setiap tahun: distribusi ukuran efek (memberi prior realistis untuk menetapkan MDE tes berikutnya); tingkat kemenangan per area produk (menunjukkan di mana ide masih berbuah); akurasi prediksi tim (kalibrasi); rasio antara jumlah lift yang diklaim dan hasil holdout global; dan proporsi tes yang dibatalkan karena validitas (kesehatan platform). Perusahaan yang menjalankan meta-analisis ini menetapkan MDE dan prioritas berdasarkan bukti internalnya sendiri, bukan berdasarkan intuisi.

Etika eksperimen pada manusia

Eksperimen A/B adalah penelitian pada manusia, dijalankan tanpa persetujuan individual, oleh organisasi yang memiliki kepentingan komersial atas hasilnya. Kerangka etika yang matang diperlukan — dan bukan hanya untuk menghindari masalah hukum.

Prinsip	Penerapan dalam eksperimen produk	Pertanyaan uji
Tidak merugikan		Apakah varian terburuk dapat menyebabkan kerugian nyata bagi pengguna?

	Guardrail atas kerugian; ramp bertahap; penghentian cepat bila terdeteksi	
Kesetaraan	Beban dan manfaat tersebar adil; tidak menargetkan kelompok rentan untuk menanggung risiko	Apakah kelompok tertentu menanggung beban lebih besar?
Transparansi	Kebijakan yang menyatakan bahwa perusahaan menjalankan eksperimen; hasil yang mempengaruhi pengguna dapat dijelaskan bila ditanya	Apakah kita nyaman bila desain ini dimuat di media?
Proporsionalitas	Risiko sepadan dengan nilai pengetahuan yang diperoleh	Apakah pertanyaan ini cukup penting untuk membenarkan eksperimen?
Privasi	Data minimal yang diperlukan; agregasi; kepatuhan pada regulasi perlindungan data	Apakah kita mengumpulkan lebih dari yang dibutuhkan analisis?

Kategori yang memerlukan tinjauan khusus

- **Manipulasi emosi atau kondisi psikologis.** Eksperimen yang sengaja mengubah suasana hati pengguna menuntut pembenaran yang jauh lebih kuat.
- **Perbedaan harga antar pengguna.** Selain risiko hukum dan reputasi, ini menyentuh rasa keadilan secara langsung. Gunakan variasi geografis atau temporal, bukan variasi antar individu yang dapat saling membandingkan.
- **Kelompok rentan.** Anak-anak, pengguna dengan kesulitan keuangan, pengguna dalam situasi krisis (kesehatan, kehilangan).
- **Menahan manfaat yang jelas.** Kelompok kontrol yang tidak menerima perbaikan keselamatan atau aksesibilitas yang sudah diketahui bermanfaat.
- **Pola gelap (dark patterns).** Menguji apakah membuat pembatalan lebih sulit meningkatkan retensi adalah eksperimen yang berhasil secara metric dan gagal secara etika.

⚠ **WARNING — Metric dapat menang sementara pengguna dirugikan**

Sebagian besar cara merugikan pengguna *menaikkan* metric jangka pendek: urgensi palsu, langganan yang sulit dibatalkan, biaya yang disembunyikan sampai langkah terakhir, notifikasi berlebihan. Eksperimen akan melaporkan kemenangan dengan jujur, karena metric memang naik.

Perlindungannya tidak bisa berupa statistik. Ia harus berupa **guardrail etika yang ditetapkan di luar kerangka metric**: daftar hal yang tidak diuji, tinjauan untuk kategori sensitif, dan pertanyaan wajib di formulir desain — "*apakah perubahan ini membuat pengguna lebih mampu mencapai tujuan mereka sendiri, atau hanya membuat mereka lebih sulit menghindari tujuan kita?*"

► **EXECUTIVE PERSPECTIVE — biaya reputasi lebih besar daripada lift mana pun**

Beberapa perusahaan besar telah menghadapi krisis publik karena eksperimen yang secara teknis sah tetapi secara sosial tidak dapat diterima. Kerugiannya — kepercayaan pengguna, perhatian regulator, moral karyawan — jauh melampaui nilai lift apa pun yang diperoleh. Uji sederhana yang menyelamatkan: *bagaimana desain ini terbaca bila dijelaskan lengkap di halaman depan surat kabar nasional?* Bila jawabannya membuat tidak nyaman, tidak ada perhitungan statistik yang memperbaikinya.

Patologi budaya dan penanganannya

Patologi	Gejala	Penanganan
HiPPO (highest paid person's opinion)	Hasil yang bertentangan dengan pendapat senior "dipertanyakan metodologinya"; hasil yang mendukung diterima tanpa pemeriksaan	Pre-registration dan aturan keputusan yang ditulis sebelum hasil; minta prediksi tertulis dari semua pihak sebelum tes
Kuburan hasil negatif	Hanya kemenangan yang dipresentasikan; tes yang kalah tidak pernah muncul lagi	Experiment log wajib; sesi rutin "apa yang kita pelajari dari tes yang kalah"; hitung nilai kerugian yang dicegah (Bab 7)
Teater eksperimen	Tes dijalankan untuk membenarkan keputusan yang sudah diambil	Pertanyaan wajib: "apa yang berubah jika hasilnya nol?"; tolak tes yang jawabannya "tidak ada"
Metric velocity	Tim dinilai dari jumlah tes yang dijalankan → banyak tes kecil yang tidak bermakna	Ukur dampak terverifikasi lewat holdout global, bukan jumlah tes (Goodhart, Vol 3 Bab 13)
Optimisme lokal	Setiap tim mengklaim kemenangan; metric perusahaan tidak bergerak	Holdout global; rekonsiliasi tahunan (Bab 7)
Kelumpuhan analisis	Semua hal harus diuji, termasuk yang jelas dan yang tidak layak diuji	Kerangka nilai informasi (Bab 7); daftar keputusan yang tidak memerlukan tes
Perpindahan tanggung jawab	"Datanya yang memutuskan" dipakai untuk menghindari akuntabilitas atas keputusan	Tegaskan bahwa eksperimen memberi bukti; manusia tetap memutuskan dan bertanggung jawab

✗ COMMON MISTAKE — Menjadikan jumlah eksperimen sebagai KPI tim

Gejala: target "50 eksperimen tahun ini" tercapai; sebagian besar berupa perubahan sepele dengan power rendah; dampak terverifikasi mendekati nol.

Mengapa terjadi: jumlah tes mudah dihitung dan terasa seperti kemajuan; dampak sulit diukur dan lambat muncul.

Perbaikan: ukur *dampak inkremental terverifikasi* (holdout global) sebagai metric utama program; jumlah tes menjadi metric pendukung, persis struktur tiga lapis dari Bab 2 yang diterapkan pada program itu sendiri.

Cara senior menghindarinya: menetapkan sejak awal bahwa program akan dinilai dari holdout global, dan memasang holdout itu di bulan pertama sebelum ada yang berkepentingan menolaknya.

Membangun program dari nol: 12 bulan pertama

BULAN 1–2 FONDASI

- Pilih satu pertanyaan bernilai tinggi yang benar-benar terbuka
- Tulis dokumen desain satu halaman; pre-register
- Pasang holdout global 2% SEKARANG (paling sulit dipasang belakangan, saat sudah ada yang berkepentingan menolak)
- Sepakati definisi metric inti dan cara menghitungnya

BULAN 3–5 STANDARDISASI

- Template desain + daftar guardrail standar + ambangnya
- Pemeriksaan SRM otomatis; A/A berkelanjutan
- Experiment log dimulai dari tes pertama

- Publikasikan hasil pertama APA PUN jawabannya – ini momen yang menentukan kredibilitas program

BULAN 6–8 KAPASITAS

- Latih 3–5 orang di luar tim analytics untuk mendesain tes
- Kalkulator power tersedia mandiri
- Aturan prioritasasi traffic-minggu (Bab 3)
- Review desain mingguan sebagai forum tetap

BULAN 9–12 PENGUKURAN & PERLUASAN

- Baca holdout global; laporkan dampak program yang terverifikasi ke direksi
- Terapkan CUPED; ukur kenaikan throughput
- Meta-analisis atas experiment log; tetapkan MDE standar
- Perluas ke domain sulit: geo experiment marketing, harga

✓ **BEST PRACTICE — Publikasikan hasil pertama apa pun jawabannya**

Tes pertama sebuah program memiliki nilai simbolis yang jauh melampaui nilai statistiknya. Bila hasilnya bertentangan dengan harapan dan tetap dipublikasikan apa adanya, organisasi belajar bahwa program ini menghasilkan kebenaran, bukan membenaran. Bila hasil pertama yang tidak menyenangkan dikubur, seluruh program akan diperlakukan sebagai alat politik selama bertahun-tahun — dan reputasi itu hampir tidak mungkin diperbaiki.

Checklist kelembagaan

- ✓ Tingkat kematangan dinilai; langkah berikutnya yang spesifik ditetapkan
- ✓ Peran dan batas kewenangan tertulis, termasuk siapa yang boleh menghentikan tes
- ✓ Delapan aturan tidak-dapat-dinegosiasikan diadopsi dan diketahui semua pihak
- ✓ Mekanisme override eksplisit tersedia dan tercatat
- ✓ Experiment log mencakup tes yang kalah, dibatalkan, dan tidak konklusif
- ✓ Holdout global terpasang dan dibaca berkala
- ✓ Program dinilai dari dampak terverifikasi, bukan jumlah tes
- ✓ Guardrail etika ditetapkan di luar kerangka metric; kategori sensitif memiliki jalur tinjauan
- ✓ Pertanyaan "apa yang berubah jika hasilnya nol" wajib di formulir desain
- ✓ Meta-analisis tahunan atas experiment log dijalankan

Ending Card — Bab 13

What you learned

Model kematangan enam tingkat dan langkah peningkatannya; struktur peran dan batas kewenangan; delapan aturan tata kelola yang tidak dapat dinegosiasikan beserta mekanisme override; struktur experiment log dan meta-analisis atasnya; lima prinsip etika eksperimen dan lima kategori yang memerlukan tinjauan khusus; tujuh patologi budaya beserta penanganannya; rencana 12 bulan membangun program dari nol.

Skills mastered

Desain program eksperimentasi · tata kelola · manajemen pengetahuan · penilaian etika · diagnosis patologi organisasi.

Real business value

Kemampuan ini memindahkan seorang analyst dari pelaksana menjadi pembangun kapabilitas. Program eksperimentasi yang berfungsi adalah aset yang menghasilkan nilai setiap tahun tanpa perlu dibangun ulang — dan orang yang membangunnya menjadi rujukan organisasi jauh melampaui satu analisis.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagaimana kamu membangun budaya eksperimentasi di perusahaan yang belum punya?" (Rencana 12 bulan; tekankan holdout global sejak bulan pertama dan publikasi hasil pertama apa pun jawabannya.)
2. "VP tidak setuju dengan hasil tesmu dan meminta analisis ulang. Apa yang kamu lakukan?" (Rujuk pre-registration; tawarkan analisis tambahan yang *sudah* direncanakan; bedakan pertanyaan validitas yang sah dari penolakan hasil; usulkan tes replikasi bila keyakinannya kuat.)
3. "Eksperimen apa yang tidak akan kamu jalankan?" (Kategori etika; jelaskan pertanyaan ujinya.)
4. "Bagaimana kamu mengukur keberhasilan program eksperimentasi?" (Holdout global dan dampak terverifikasi; jelaskan mengapa jumlah tes adalah metric yang memicu Goodhart.)
5. "Bagaimana kamu memastikan pengetahuan dari eksperimen tidak hilang?" (Experiment log lengkap termasuk yang kalah; meta-analisis tahunan; kata kunci agar dapat dicari.)

Exercises

Exercise 13.1 (Beginner · 25 menit)

Objective: penilaian etika

Untuk tiap eksperimen, tentukan: jalankan / jalankan dengan modifikasi / tolak — beserta alasannya.

- (a) Menguji apakah menyembunyikan tombol "batalkan langganan" di dalam menu meningkatkan retensi.
- (b) Menguji apakah menampilkan "hanya 2 tersisa" (angka sebenarnya) meningkatkan konversi.
- (c) Menguji apakah menampilkan "12 orang sedang melihat produk ini" (angka dibuat-buat) meningkatkan konversi.
- (d) Menguji harga berbeda untuk pengguna yang terdeteksi memakai perangkat mahal.
- (e) Menguji apakah menunda notifikasi selama 3 jam mempengaruhi keterlibatan.
- (f) Menguji pesan pengingat pembayaran dengan nada yang lebih mendesak pada pelanggan yang menunggak.

Answer key 13.1

- (a) **Tolak** — dark pattern; menaikkan metric dengan menyulitkan pengguna mencapai tujuan mereka sendiri. Uji ujinya gagal: tidak nyaman bila dijelaskan di publik.
- (b) **Jalankan** — informasi yang benar dan berguna bagi keputusan pengguna. Tambahkan guardrail refund untuk memastikan tidak mendorong pembelian yang disesali.
- (c) **Tolak** — informasi palsu; masalah kejujuran, bukan optimasi. Selain itu berisiko hukum di banyak yurisdiksi.
- (d) **Tolak dalam bentuk ini** — diskriminasi harga berdasarkan proxy kemakmuran, dapat dibandingkan antar pengguna, dan berisiko regulasi serta reputasi. Alternatif yang dapat diterima: variasi harga geografis atau temporal yang diumumkan, atau diskon yang ditawarkan secara transparan.
- (e) **Jalankan** — risiko rendah, dan hasilnya dapat mengurangi gangguan bagi pengguna. Perhatikan kategori notifikasi kritis (keamanan, transaksi) yang harus dikecualikan.
- (f) **Jalankan dengan modifikasi** — pengingat pembayaran adalah komunikasi yang sah, tetapi pelanggan yang menunggak dapat berada dalam kesulitan keuangan (kelompok rentan). Modifikasi: batasi rentang nada yang diuji agar tidak ada varian yang bersifat menekan atau mempermalukan; tambahkan guardrail berupa tingkat keluhan dan tingkat kontak ke layanan bantuan; kecualikan pelanggan yang sudah mengajukan keringanan.

Exercise 13.2 (Intermediate · 45 menit)

Objective: diagnosis patologi organisasi

Sebuah perusahaan melaporkan: 62 eksperimen dijalankan tahun lalu (target 60 tercapai); 41 dinyatakan menang; total lift conversion yang diklaim +29%; conversion aktual naik dari 2,80% ke 2,91% (+3,9%); tidak ada holdout global; rata-rata durasi tes 6 hari; experiment log berisi 41 entri.

- (a) Identifikasi minimal empat masalah. (b) Jelaskan bagaimana masing-masing berkontribusi pada selisih 29% vs 3,9%. (c) Susun tiga rekomendasi berdampak tertinggi beserta urutan pelaksanaannya.

Answer key 13.2

- (a) Empat masalah: **(i)** Log berisi 41 entri sementara 62 tes dijalankan — *21 tes hilang*, hampir pasti yang kalah dan yang dibatalkan (kuburan hasil negatif). **(ii)** Durasi rata-rata 6 hari — bukan kelipatan minggu penuh dan hampir pasti terlalu pendek; kemungkinan besar tes dihentikan saat signifikan (peeking) dan hasilnya mengandung novelty effect. **(iii)** Tingkat kemenangan 66% jauh di atas norma program matang ($\pm 33\%$) — indikasi kuat false positive akibat peeking dan power rendah. **(iv)** Tidak ada holdout global sehingga tidak ada cara memverifikasi klaim. **(v)** Target berupa jumlah tes — metric velocity yang memicu Goodhart.
- (b) Kontribusi terhadap selisih: peeking dan power rendah menghasilkan false positive (mengembungkan jumlah kemenangan) dan winner's curse (mengembungkan besar tiap kemenangan); durasi 6 hari memasukkan novelty yang meluruh setelah rilis; hilangnya 21 tes membuat gambaran keseluruhan bias positif; efek yang tidak aditif pada funnel yang sama; dan tanpa holdout tidak ada koreksi apa pun. Kombinasi ini mudah menjelaskan faktor $29/3,9 \approx 7,4\times$.
- (c) Tiga rekomendasi berurutan: **(1) Pasang holdout global 2% sekarang** — tanpa ini tidak ada dasar untuk percakapan apa pun, dan ia paling sulit dipasang setelah ada yang berkepentingan. **(2) Tetapkan durasi minimum 14 hari dan power minimum 80%, dengan OEC disembunyikan sampai tanggal analisis** — menyerang peeking dan novelty sekaligus, dan merupakan perubahan proses yang tidak memerlukan teknologi baru. **(3) Ganti target dari jumlah tes menjadi dampak terverifikasi holdout** — tanpa ini, dua rekomendasi pertama akan dilawan karena menurunkan jumlah tes. Urutan ini penting: langkah 3 yang paling politis sebaiknya diajukan setelah holdout memberi data pertama.

Exercise 13.3 (Advanced · 90 menit)

Objective: menghadapi penolakan hasil

Tesmu menunjukkan bahwa fitur unggulan yang dibangun selama 8 bulan oleh tim beranggota 12 orang tidak memberi dampak (CI sempit, mencakup nol, tidak mencakup MDE — pola D pada Bab 5). VP Produk yang mensponsori fitur ini meminta: (1) analisis ulang dengan metric berbeda; (2) analisis per segmen; (3) memperpanjang tes 4 minggu lagi.

Tulis tanggapanmu: mana yang kamu setuju, mana yang kamu tolak, bagaimana kamu menyampaikannya, dan apa yang kamu tawarkan sebagai jalan ke depan. Sertakan pertimbangan tentang bagaimana menjaga hubungan kerja jangka panjang.

Answer key 13.3 (jalur kuat)

Permintaan (1) — metric berbeda: tolak sebagai dasar keputusan, setuju sebagai eksplorasi. "OEC sudah disepakati sebelum tes; menggantinya sekarang membuat hasil tidak dapat ditafsirkan. Tapi saya akan menghitung metric yang kamu maksud dan melaporkannya sebagai analisis eksploratif dengan status hipotesis."

Permintaan (2) — analisis segmen: setuju dengan syarat. Segmen yang *sudah diregistrasi* dilaporkan sebagai hasil; segmen tambahan dilaporkan sebagai hipotesis dengan jumlah segmen yang diperiksa disebutkan. Ini justru bermanfaat: jika ada segmen dengan alasan mekanistik kuat, ia menjadi arah tes konfirmasi.

Permintaan (3) — perpanjang 4 minggu: tolak. CI sudah sempit dan tidak mencakup MDE — ini bukan masalah presisi. Perpanjangan tidak akan mengubah kesimpulan dan merupakan bentuk peeking. Jelaskan dengan angka: "Kita sudah dapat menyingkirkan efek sebesar ambang kelayakan. Empat minggu lagi hanya akan mempersempit CI dari $\pm 0,4\%$ menjadi $\pm 0,35\%$ — tidak ada keputusan yang berubah karenanya."

Penyampaian: mulai dari apa yang berhasil ("fitur ini dibangun dengan baik dan tidak merusak apa pun — guardrail seluruhnya aman"), lalu bingkai temuan sebagai pengetahuan yang mahal diperoleh, bukan sebagai kegagalan tim. Hindari bahasa yang menempatkan diri sebagai hakim.

Jalan ke depan yang ditawarkan: (i) sesi bersama untuk membedah mekanisme — mengapa hipotesis tidak terwujud, dan apa yang ditunjukkan metric pendukung tentang perilaku pengguna; temuan ini sering lebih bernilai daripada fitur itu sendiri. (ii) Dua varian turunan yang lebih terarah berdasarkan pembelajaran itu. (iii) Menawarkan agar VP menjadi rekan penulis memo pembelajaran — memindahkan kepemilikan dari "temuanku tentang kegagalanmu" menjadi "yang kita pelajari bersama".

Jangka panjang: sikap ini yang menentukan apakah kamu akan dilibatkan sejak awal pada proyek berikutnya. Analyst yang menang argumen tetapi kehilangan akses akan berhenti memberi dampak.

Exercise 13.4 (Production Challenge · 5 jam)

Objective: playbook program eksperimentasi

Susun playbook program eksperimentasi lengkap untuk sebuah organisasi (maksimum 10 halaman): penilaian kematangan saat ini, peran dan kewenangan, aturan tata kelola, template desain, daftar guardrail standar, skema experiment log, kebijakan etika beserta kategori yang memerlukan tinjauan, rencana 12 bulan, dan definisi keberhasilan program beserta cara mengukurnya. Playbook harus dapat dipakai langsung oleh orang yang tidak pernah bertemu denganmu.

Answer key 13.4 — rubrik

Playbook yang kuat: setiap aturan disertai *alasan* singkat (aturan tanpa alasan akan dilanggar saat ditekan); guardrail berupa angka; template muat satu halaman; kebijakan etika memuat daftar konkret hal yang tidak diuji, bukan prinsip umum; dan definisi keberhasilan program memakai holdout global. Uji kegunaan yang sebenarnya: berikan kepada seseorang yang tidak terlibat dan minta mereka merancang satu eksperimen hanya dengan membaca dokumen itu. Bila mereka bisa, playbook berhasil.

Portfolio idea

★ PORTFOLIO TIP

Playbook (Exercise 13.4) adalah artefak tingkat kepemimpinan. Untuk pelamar peran senior atau lead, dokumen ini sering menjadi bahan diskusi paling lama dalam wawancara — karena ia menunjukkan kemampuan membangun sistem, bukan hanya menjalankan analisis. Sertakan satu halaman "tiga hal yang akan saya lakukan berbeda bila memulai ulang".

Further reading

Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* (Bab 4: kematangan program; Bab 9: etika) · Fabijan et al., "The Evolution of Continuous Experimentation" (model kematangan) · Laporan Belmont dan penerapannya pada penelitian daring · Kramer, Guillory & Hancock (2014) beserta perdebatan publik yang mengikutinya — studi kasus etika yang penting dipahami · Vol 3 Bab 13 buku ini tentang Goodhart's Law.

Next chapter

Bab 14 — capstone. Seluruh volume dipakai sekaligus untuk satu keputusan nyata: menyusun causal evidence package bagi program retensi TokoNusa, melanjutkan skenario Head of CRM yang berjalan sejak Volume 2.

Bab 14 — Capstone Semester 4

Causal Evidence Package untuk program retensi TokoNusa senilai Rp 28 miliar. Seluruh volume dipakai sekaligus, untuk satu keputusan nyata.

Learning objectives	Mengintegrasikan seluruh kemampuan Volume 4 menjadi satu paket bukti kausal yang dapat dipertahankan di komite investasi; memilih metode identifikasi yang tepat untuk tiap pertanyaan; merancang eksperimen konfirmasi; menerjemahkan bukti menjadi keputusan alokasi anggaran; menulis dokumen tingkat direksi
Prerequisites	Seluruh Bab 1–13; Vol 2 capstone (skor churn); Vol 3 Bab 6 dan capstone (business health assessment)
Estimasi waktu	Baca 1,5 jam · Pengerjaan 20–30 jam
Difficulty	● Advanced / Production Ready
Skills covered	Seluruh Layer 4 terintegrasi + komunikasi eksekutif + perencanaan pengukuran
Business domain	Retail omnichannel — program retensi lintas fungsi (CRM, logistik, loyalty)

Skenario

Cerita yang dimulai di Volume 2 kini mencapai titik keputusannya. Head of CRM TokoNusa mengajukan program retensi terpadu senilai **Rp 28 miliar per tahun** ke komite investasi. Proposalnya bersandar pada tiga klaim yang seluruhnya berasal dari analisis observasional volume-volume sebelumnya:

KLAIM DALAM PROPOSAL (apa adanya)

- "Pelanggan yang mengalami keterlambatan pengiriman memiliki churn 19 pp lebih tinggi. Perbaikan SLA logistik akan menurunkan churn secara proporsional."
[sumber: Vol 2, capstone]
- "Anggota program tier memiliki retensi 2,4× lebih tinggi. Memperluas keanggotaan akan menaikkan retensi."
[sumber: Vol 3, Bab 6]
- "Kampanye win-back email menghasilkan 42% lebih banyak pembelian ulang pada penerimanya."
[sumber: dashboard CRM]

ANGGARAN YANG DIMINTA

Perbaikan SLA logistik (kapasitas hub, kurir)	Rp 16,0 M
Perluasan program tier	Rp 7,5 M
Kampanye win-back & CRM otomatis	Rp 4,5 M
	Rp 28,0 M

CFO menahan persetujuan dan meminta satu hal:

"Buktikan bahwa ketiga klaim ini kausal, bukan korelasi.

Berapa kenaikan retensi yang benar-benar akan kita peroleh?"

◆ BUSINESS INSIGHT — aritmetika yang membingkai seluruh capstone

Pelanggan aktif	1.480.000
CLV berbasis contribution margin	Rp 496.000
Nilai 1 percentage point retensi = $1.480.000 \times 1\% \times \text{Rp } 496.000$	= Rp 7,341 miliar
Anggaran program	Rp 28,0 miliar
KENAIKAN RETENSI TITIK IMPAS = $28,0 / 7,341$	= 3,81 pp

Angka 3,81 pp adalah ambang yang harus dilampaui. Seluruh pekerjaan capstone ini pada akhirnya menjawab satu pertanyaan: *apakah bukti kausal yang tersedia mendukung kenaikan retensi sebesar itu?*

Deliverable

No	Dokumen	Isi minimum
D1	Audit klaim (2 halaman)	Ketiga klaim dibedah: estimand apa yang sebenarnya diukur, mekanisme bias dominan, arah bias, tingkat bukti (Bab 1)
D2	Peta kausal (2 halaman)	DAG untuk tiap lever; klasifikasi peran variabel; analisis backdoor; kesimpulan identifikasi per lever; pemilihan metode (Bab 8)
D3	Analisis kausal (6–10 halaman)	Estimasi per lever dengan metode yang dipilih, seluruh diagnostik, analisis sensitivitas, triangulasi (Bab 9–12)
D4	Rancangan eksperimen konfirmasi (3 halaman)	Dokumen desain EXP-067 lengkap: hipotesis, unit, OEC, guardrail, power/MDE, durasi, aturan keputusan (Bab 2–3)
D5	Model ekonomi (2 halaman)	Nilai tiap lever pada titik estimasi dan batas bawah; faktor peluruhan; biaya; skenario; nilai informasi (Bab 7)
D6	Memo keputusan (1 halaman)	Rekomendasi alokasi anggaran, dampak dengan rentang, asumsi, risiko, rencana verifikasi
D7	Rencana pengukuran (1 halaman)	Holdout, kalender pembacaan, kriteria yang memicu kaji ulang, tata kelola (Bab 13)

Panduan pengerjaan per tahap

Tahap 1 — Audit klaim (D1)

Untuk tiap klaim, jawab: siapa yang menentukan masuk ke kelompok treatment; apakah penentuan itu berkaitan dengan outcome; apakah urutan waktunya benar; dan apa estimand yang sebenarnya terukur. Kesimpulan tahap ini seharusnya menurunkan pangkat ketiga klaim — dan itu adalah hasil yang benar, bukan sikap negatif.

■ TECHNICAL NOTE — petunjuk untuk klaim 3 (win-back email)

Klaim ketiga mengandung bias yang sama dengan contoh pembuka Bab 1: daftar penerima email biasanya disaring berdasarkan aktivitas. Periksa aturan seleksi daftar sebelum apa pun yang lain. Bila daftar disaring pada "aktif dalam 90 hari", perbandingan itu membandingkan pelanggan aktif dengan pelanggan tidak aktif, dan angka 42% hampir seluruhnya artefak. Ini juga lever yang paling mudah diperbaiki: kampanye email adalah kandidat sempurna untuk holdout acak yang biayanya hampir nol.

Tahap 2 — Peta kausal dan pemilihan metode (D2)

LEVER 1 — SLA logistik → churn
Confounder terukur : wilayah, kategori/berat, nilai order, frekuensi historis
Confounder tak terukur: niat berhenti
Backdoor : TIDAK terpenuhi
Metode terpilih : IV (kapasitas hub) + PSM sebagai pembanding + eksperimen SLA sebagai konfirmasi [Bab 10, 11]

LEVER 2 — Program tier → retensi
Masalah utama : self-selection ekstrem
Struktur yang tersedia: AMBANG SKOR 700 yang tajam
Metode terpilih : RDD (efek lokal di ambang) + encouragement design untuk efek di luar ambang [Bab 11]

LEVER 3 — Win-back email → reaktivasi
Masalah utama : seleksi daftar penerima
Struktur yang tersedia: email dapat diacak dengan biaya nol
Metode terpilih : EKSPERIMEN. Tidak ada alasan memakai metode observasional untuk lever ini. [Bab 2, 3]

Perhatikan bahwa ketiga lever memerlukan metode berbeda karena strukturnya berbeda. Salah satu penilaian terpenting dalam capstone ini adalah apakah peserta memilih metode berdasarkan struktur masalah, atau memaksakan satu metode untuk semuanya.

Tahap 3 — Analisis kausal (D3)

Hasil rujukan untuk lever 1, yang telah dibangun sepanjang volume ini:

Metode	Estimasi	Status
Perbandingan mentah	+19,10 pp	Tingkat bukti 7 — tidak dipakai
Regresi kovariat pra-treatment	+8,17 pp (SE 0,20)	Tingkat bukti 6 — asosiasi setelah penyesuaian
IPW / stratifikasi propensity	+8,49 pp	Tingkat bukti 6; E-value 1,94 → rapuh
IV (kapasitas hub), first-stage F = 15.598	+4,01 pp (CI 95% +2,64 s/d +5,38)	Tingkat bukti 5 — LATE pada keterlambatan akibat kapasitas

Angka yang dipakai untuk keputusan adalah **4,01 pp**, dengan batas bawah 2,64 pp untuk perencanaan. Alasannya bukan karena IV lebih canggih, melainkan karena asumsinya tidak bergantung pada ketersediaan seluruh confounder — dan karena populasi complier-nya (keterlambatan yang disebabkan kendala kapasitas) persis populasi yang akan terkena intervensi investasi kapasitas.

Tahap 4 — EXP-067, eksperimen konfirmasi (D4)

EXP-067 · Prioritas SLA untuk pelanggan bernilai tinggi

HIPOTESIS Menaikkan prioritas pengiriman (kurir premium + alokasi slot gudang lebih awal) pada pelanggan segmen atas akan menurunkan tingkat keterlambatan dari 36% menjadi $\pm 12\%$, dan menurunkan churn 180 hari sebesar $4,0 \text{ pp} \times (0,36 - 0,12)/0,36 \approx 2,7 \text{ pp}$.
Mekanisme: keterlambatan → kekecewaan → churn; diverifikasi lewat metric antara (skor kepuasan pasca-pengiriman, tingkat komplain).

ESTIMAND	ATE pada pelanggan segmen sasaran.
UNIT ACAK	pelanggan (efek bersifat kumulatif dan personal)
POPULASI	420.000 pelanggan dengan frekuensi ≥ 3 /tahun di wilayah dengan tingkat keterlambatan di atas median
ALOKASI	50/50
OEC	retensi 180 hari (biner, per pelanggan)
SUPPORTING	tingkat keterlambatan aktual, lead time median & P95, skor kepuasan pasca-pengiriman, komplain per 1.000 order
GUARDRAIL	SRM · biaya pengiriman per order (ambang +Rp 6.000) · SLA pelanggan NON-sasaran tidak memburuk (kapasitas adalah sumber daya bersama – risiko interferensi, Bab 6) · tingkat pembatalan
POWER	Baseline retensi 180 hari 76,1%. MDE 2,7 pp absolut (3,5% relatif). n per kelompok pada $\alpha=0,05$, power 80%: $2 \times 7,8489 \times 0,761 \times 0,239 / 0,027^2 \approx 3.916$. Tersedia 210.000 per kelompok – power sangat memadai. MDE yang benar-benar tercapai: $\pm 0,37$ pp. CATATAN: pengikat di sini BUKAN ukuran sampel, melainkan DURASI – outcome membutuhkan 180 hari.
DURASI	6 bulan paparan + 6 bulan jendela outcome = 12 bulan. Pembacaan sementara pada bulan ke-3 dan ke-6 menggunakan metric antara (keterlambatan, kepuasan), BUKAN OEC – pemisahan peran pemantauan dan analisis (Bab 4). Rencana sequential ditetapkan di muka bila pembacaan awal OEC diinginkan (Bab 5).
KEPUTUSAN	CI bawah retensi $> +1,5$ pp & guardrail aman → perluas ke seluruh basis yang memenuhi syarat CI mencakup nol tetapi tidak mencakup $+2,7$ pp → efek yang layak dapat disingkirkan; hentikan investasi kapasitas berbasis retensi dan evaluasi ulang atas dasar biaya operasi saja Guardrail SLA non-sasaran memburuk → BATALKAN; ini tanda kapasitas hanya dipindahkan, bukan ditambah (interferensi, Bab 6)

⚠ WARNING — Lever ini memiliki risiko interferensi yang harus diantisipasi

Kapasitas pengiriman adalah sumber daya bersama. Memberi prioritas kepada 210.000 pelanggan treatment berarti mengambil slot dari pelanggan lain — termasuk kelompok kontrol. Bila itu terjadi, efek yang terukur akan *melebih-lebihkan* dampak rollout penuh, persis seperti kasus notifikasi stok di Bab 6.

Dua mitigasi wajib: **(1)** guardrail eksplisit atas SLA pelanggan non-sasaran, dengan ambang yang memicu pembatalan; **(2)** pastikan investasi kapasitas benar-benar menambah kapasitas total sebelum tes dimulai, bukan hanya mengubah aturan prioritas. Peserta yang mengenali risiko ini tanpa diberi tahu menunjukkan pemahaman yang matang.

Tahap 5 — Model ekonomi (D5)

LEVER 1 — SLA logistik

Pelanggan terdampak keterlambatan: $1,48 \text{ jt} \times 36,3\% = 537.240$

Efek IV titik $4,01 \text{ pp} \rightarrow 21.543 \text{ pelanggan} \rightarrow \text{Rp } 10,69 \text{ M}$

Efek IV batas bawah $2,64 \text{ pp} \rightarrow 14.183 \text{ pelanggan} \rightarrow \text{Rp } 7,03 \text{ M}$

Setara kenaikan retensi total: $1,46 \text{ pp (titik)} / 0,96 \text{ pp (bawah)}$

Biaya: Rp 16,0 M

► Pada batas bawah, lever ini MERUGI (7,03 vs 16,0).

Pada titik estimasi, masih merugi (10,69 vs 16,0).

Sebagai pembanding: bila angka IPW 8,49 pp yang dipakai,

nilainya Rp 22,62 M dan lever tampak sangat menguntungkan.
INILAH konsekuensi Rp 15,6 miliar dari memilih metode yang benar (Bab 10).

LEVER 2 – Program tier

RDD di ambang: +5,0 pp retensi (stabil 4,83–5,29 lintas bandwidth); populasi di sekitar ambang ± 210.000

Nilai: $210.000 \times 5,0\% \times \text{Rp } 496.000 = \text{Rp } 5,21 \text{ M}$

Biaya: Rp 7,5 M

- Merugi pada populasi ambang saja. CATATAN PENTING: efek RDD bersifat LOKAL. Efek pada pelanggan jauh di bawah ambang TIDAK diketahui dan kemungkinan lebih kecil – sehingga ekstrapolasi ke seluruh basis TIDAK SAH.

LEVER 3 – Win-back email

Belum ada bukti kausal apa pun. Klaim 42% berasal dari perbandingan yang terkonfound.

Biaya menguji: hampir nol (holdout acak 20% dari daftar).

- Rekomendasi: JANGAN danai berdasarkan bukti saat ini; jalankan holdout selama satu siklus kampanye (4 minggu) sebelum keputusan anggaran. Nilai informasi sangat tinggi relatif terhadap biayanya (Bab 7).

REKAPITULASI

Total nilai terbukti (titik estimasi) = Rp 15,90 M

Total nilai terbukti (batas bawah) = Rp 12,24 M

Total anggaran diminta = Rp 28,00 M

Kenaikan retensi yang didukung bukti = 2,17 pp (titik)

Kenaikan retensi titik impas = 3,81 pp

- PROPOSAL DALAM BENTUK SEKARANG TIDAK DIDUKUNG BUKTI.

► EXECUTIVE PERSPECTIVE — cara menyampaikan "tidak" yang tetap membangun

Kesimpulan capstone ini menolak proposal senilai Rp 28 miliar dari seorang eksekutif senior. Cara menyampaikannya menentukan apakah analisis ini menghasilkan keputusan yang lebih baik atau sekadar permusuhan.

Yang tidak bekerja: "klaim Anda salah". Yang bekerja adalah menawarkan **proposal tandingan yang lebih kecil, bertahap, dan dapat diverifikasi**:

REKOMENDASI ALTERNATIF – Rp 9,5 miliar tahap pertama

- Rp 0,3 M Holdout win-back email (4 minggu). Biaya hampir nol, nilai informasi sangat tinggi. Jalankan minggu ini.
- Rp 6,2 M EXP-067 pada 420.000 pelanggan – investasi kapasitas terbatas pada wilayah tes, bukan nasional.
- Rp 3,0 M Encouragement design program tier: acak undangan upgrade untuk mengukur efek di luar ambang.

KOMITMEN Rp 9,5 M dengan tiga hasil terukur dalam 12 bulan.

KEPUTUSAN Sisa Rp 18,5 M dialokasikan setelah bukti tersedia, pada lever yang terbukti – bukan dibagi rata.

Struktur ini mengubah percakapan dari "setuju atau tolak Rp 28 miliar" menjadi "beli informasi dulu dengan Rp 9,5 miliar, lalu belanjakan sisanya dengan tepat" — penerapan langsung nilai informasi dari Bab 7, dan bingkai yang jarang ditolak oleh CFO.

Tahap 6 — Memo keputusan dan rencana pengukuran (D6, D7)

Memo mengikuti struktur Bab 5 dan Bab 7. Rencana pengukuran mengikuti Bab 13: holdout yang terpasang, kalender pembacaan, kriteria yang memicu kaji ulang, dan siapa pemilik keputusan pada tiap titik.

Rubrik penilaian — enam reviewer

Reviewer	Yang dinilai	Pertanyaan penentu
Senior Data Analyst	Ketepatan teknis: pemilihan metode sesuai struktur, diagnostik lengkap, perhitungan benar, SE dan CI ditangani dengan tepat	"Apakah saya akan menandatangani analisis ini dengan nama saya?"
Analytics Manager	Kejelasan, kelengkapan deliverable, kelayakan rencana, manajemen ketidakpastian, apakah rekomendasi dapat dieksekusi	"Bisakah tim saya menjalankan ini besok tanpa bertanya lagi?"
BI Consultant	Nilai bisnis, komunikasi eksekutif, kualitas trade-off yang disajikan, apakah proposal tandingan realistis secara politik	"Apakah klien akan membayar untuk dokumen ini?"
Hiring Manager	Kesiapan kerja: penilaian, inisiatif, kejujuran intelektual, kemampuan berkata tidak dengan konstruktif	"Apakah saya akan mempercayakan keputusan Rp 28 miliar kepada orang ini?"
University Professor	Kebenaran metodologis, pernyataan asumsi, penanganan estimand, apakah keterbatasan dinyatakan dengan tepat	"Apakah klaim kausal di sini dapat dipertahankan?"
Technical Editor	Struktur, konsistensi terminologi, keterbacaan, apakah setiap angka dapat dilacak sumbernya	"Bisakah pembaca merekonstruksi setiap angka dari dokumen ini?"

SKORING (total 100)

Audit klaim & identifikasi bias	12
DAG dan kesimpulan identifikasi per lever	15
Ketepatan pemilihan metode	15
Kelengkapan diagnostik & sensitivitas	15
Rancangan eksperimen (power, guardrail, aturan keputusan, antisipasi interferensi)	15
Model ekonomi & penanganan ketidakpastian	13
Memo keputusan & rencana pengukuran	10
Kejujuran intelektual (keterbatasan, proposal tandingan, apa yang membatalkan)	5

AMBANG

≥85 : setara pekerjaan senior analyst – layak portfolio utama
 70–84: kuat; biasanya kurang pada diagnostik atau ekonomi
 55–69: memahami metode tetapi belum menyatukannya menjadi keputusan
 <55 : ulangi; periksa apakah metode dipilih dari struktur masalah

✗ COMMON MISTAKE — Kesalahan yang paling sering muncul di capstone ini

- (1) Memakai satu metode untuk semua lever.** Ketiga lever memiliki struktur berbeda; memaksakan propensity matching pada ketiganya menunjukkan bahwa metode dipilih dari kebiasaan, bukan dari DAG.
- (2) Mengekstrapolasi hasil RDD ke seluruh populasi.** Efek di ambang tidak berlaku jauh dari ambang. Ini kesalahan estimand, dan reviewer akademik akan langsung menangkapnya.
- (3) Memakai titik estimasi untuk rencana anggaran.** Bab 7 sudah menetapkan: rencana memakai batas bawah.
- (4) Tidak mengantisipasi interferensi pada EXP-067.** Kapasitas adalah sumber daya bersama; melewati ini berarti melewati pelajaran Bab 6.
- (5) Berhenti pada penolakan.** Menyatakan proposal tidak didukung bukti tanpa menawarkan jalan ke depan bukan analisis, melainkan hambatan.

Simulasi interview — Layer 4

Sesi 45 menit yang menguji seluruh volume. Jawaban rujukan disediakan dalam bentuk poin kunci; kekuatan jawaban terletak pada kemampuan menghubungkan, bukan menghafal.

MENIT 0–5 PEMBUKA

"Ceritakan analisis kausal yang pernah kamu kerjakan."

- Kunci: sebutkan estimand, metode, asumsi, dan APA YANG MEMBATALKANNYA. Kandidat yang menyebut keterbatasan tanpa diminta langsung dibedakan dari yang tidak.

MENIT 5–15 DESAIN EKSPERIMEN

"Rancang tes untuk fitur X."

- Kunci: hipotesis + mekanisme → estimand → unit randomisasi (dan alasannya) → OEC berbasis margin → guardrail dengan ambang → power/MDE → durasi kelipatan minggu → aturan keputusan untuk TIGA hasil.

MENIT 15–25 INTERPRETASI

"Hasilnya: lift +2,1%, CI [-0,3%; +4,5%], MDE rencana +2%. Apa rekomendasimu?"

- Kunci: pola C (tidak konklusif) – CI mencakup nol DAN MDE. Jangan simpulkan "tidak berdampak". Opsi: tambah presisi (CUPED), perpanjang dengan rencana baru, atau hentikan berdasarkan nilai informasi.

MENIT 25–35 CAUSAL INFERENCE

"Kami tidak bisa A/B test perubahan harga. Bagaimana?"

- Kunci: jalankan pohon keputusan Bab 8 dengan lantang. Geo experiment sebagai pilihan pertama; IV dengan guncangan biaya; RDD bila ada ambang; sebutkan mengapa regresi historis bias ke arah nol dan berikan angkanya.

MENIT 35–45 PENILAIAN & ORGANISASI

"Hasil tesmu bertentangan dengan keyakinan VP. Apa yang kamu lakukan?"

- Kunci: rujuk pre-registration; bedakan pertanyaan validitas yang sah dari penolakan hasil; tawarkan analisis yang sudah direncanakan; usulkan replikasi; jaga hubungan kerja.

"Eksperimen apa yang TIDAK akan kamu jalankan?"

- Kunci: kategori etika Bab 13; uji "halaman depan surat kabar".

● INTERVIEW — sepuluh pertanyaan yang paling membedakan

1. Apa bedanya ATE, ATT, dan LATE — dan kapan salah memilihnya berakibat mahal?
2. Kapan menambahkan variabel kontrol memperburuk analisis? (empat kategori)
3. Mengapa berhenti saat signifikan itu salah, dan berapa besar inflasinya?
4. Apa yang dijamin propensity score matching, dan apa yang tidak?
5. Bagaimana kamu menguji asumsi tren paralel?
6. Sebutkan satu instrumen dari pekerjaan analytics dan ancaman terhadap exclusion-nya.
7. Bagaimana kamu tahu apakah A/B test kalian dapat dipercaya? (A/A, SRM, distribusi p-value)
8. Mengapa jumlah lift program eksperimen tidak pernah terlihat di P&L?
9. Apa bedanya attribution dan incrementality, dan berapa besar selisihnya biasanya?
10. Bagaimana kamu mengukur keberhasilan program eksperimentasi itu sendiri?

Checklist penyerahan capstone

- ✓ Ketiga klaim diaudit dengan estimand, mekanisme bias, dan tingkat bukti
- ✓ DAG dibuat per lever, lengkap dengan confounder tak terukur yang dinamai
- ✓ Metode dipilih dari struktur masalah, dan alasan menolak metode alternatif ditulis
- ✓ Seluruh diagnostik dijalankan dan dilaporkan apa adanya, termasuk yang tidak menguntungkan
- ✓ Triangulasi minimal dua metode dengan asumsi berbeda pada lever utama
- ✓ Analisis sensitivitas diterjemahkan menjadi pertanyaan yang dapat dijawab bisnis
- ✓ Dokumen desain eksperimen lengkap dengan power, guardrail, dan aturan keputusan tiga hasil
- ✓ Risiko interferensi pada EXP-067 diantisipasi beserta mitigasinya
- ✓ Model ekonomi memakai batas bawah untuk perencanaan; faktor peluruhan ditulis sebagai angka
- ✓ Memo keputusan memuat rentang, asumsi, risiko, dan rencana verifikasi
- ✓ Proposal tandingan yang lebih kecil dan bertahap disertakan
- ✓ Rencana pengukuran memuat holdout, kalender pembacaan, dan pemilik keputusan

Ending Card — Volume 4

What you learned

Seluruh Layer 4: kerangka potential outcomes dan hierarki bukti; desain eksperimen dari hipotesis sampai guardrail; power, MDE, dan kelayakan tes; pelaksanaan yang tahan SRM, novelty, dan kebocoran; interpretasi yang tahan peeking dan multiple testing; variance reduction, heterogenitas, dan interferensi; ekonomi eksperimen dan nilai informasi; DAG dan pemilihan metode identifikasi; DiD, event study, synthetic control; propensity score dan batasnya; instrumental variables dan regression discontinuity; incrementality marketing; serta kelembagaan, tata kelola, dan etika.

Skills mastered

Causal reasoning · desain dan analisis eksperimen · quasi-experimental methods · penerjemahan bukti menjadi keputusan · komunikasi eksekutif atas ketidakpastian · pembangunan program eksperimentasi.

Real business value

Layer ini menentukan apakah sumber daya perusahaan dialokasikan berdasarkan sebab atau berdasarkan korelasi. Pada satu capstone, selisihnya adalah Rp 18,5 miliar yang tidak jadi dibelanjakan sebelum buktinya ada. Kemampuan ini juga yang paling konsisten diuji dalam wawancara untuk peran product analyst, data scientist, growth, dan analytics lead di perusahaan teknologi maupun konsumen.

Portfolio readiness

★ PORTFOLIO — apa yang dihasilkan volume ini

Enam artefak yang seluruhnya berdiri sendiri: **(1)** causal audit portfolio (Bab 1 & 8); **(2)** template dan playbook desain eksperimen (Bab 2 & 13); **(3)** kalkulator power dan dokumen prioritisasi (Bab 3); **(4)** experiment readout dari data nyata (Bab 5); **(5)** evaluasi kebijakan dengan DiD/synthetic control (Bab 9); **(6)** capstone causal evidence package (bab ini). Kombinasi ketiga terakhir sudah cukup untuk melamar peran analyst senior; capstone sendiri adalah dokumen yang dapat dibawa ke wawancara tingkat lead.

Interview readiness

Sepuluh pertanyaan pembeda di atas mencakup hampir seluruh permukaan wawancara analytics untuk Layer 4. Latih sampai setiap jawaban dapat disampaikan lisan dalam 2–3 menit, dengan satu angka konkret dan satu keterbatasan yang disebut tanpa diminta.

Further reading

Kohavi, Tang & Xu, *Trustworthy Online Controlled Experiments* · Angrist & Pischke, *Mostly Harmless Econometrics* dan *Mastering 'Metrics* · Cunningham, *Causal Inference: The Mixtape* · Hernán & Robins, *Causal Inference: What If* · Pearl & Mackenzie, *The Book of Why* · Imbens & Rubin, *Causal Inference for Statistics, Social, and Biomedical Sciences*.

Next volume

Volume 5 — Decision Science & Optimization. Volume ini berhenti pada bukti; volume berikutnya melanjutkan ke keputusan di bawah ketidakpastian. Problem framing, decision tree dan expected value, analisis sensitivitas, simulasi Monte Carlo (dijanjikan sejak Vol 2 Bab 3), NPV dan discounting (Vol 3 Bab 6), EOQ dan safety stock (Vol 3 Bab 8), optimasi alokasi sumber daya dan harga, serta expected value of sample information yang di volume ini baru disentuh permukaannya.

Cerita TokoNusa berlanjut: dengan bukti kausal di tangan, bagaimana Rp 18,5 miliar yang tersisa dialokasikan secara optimal di antara lever yang bersaing — di bawah ketidakpastian, kendala kapasitas, dan preferensi risiko yang harus dinyatakan terbuka.