

THE ANALYST HANDBOOK SERIES

AI for Analytics & Machine Learning

Volume 6 — Semester 6 dari Kurikulum 7-Layer Analytics

Memperbesar daya analitis tanpa kehilangan disiplinnya. Regresi, pohon dan boosting, evaluasi model, ambang keputusan, uplift, clustering, deteksi anomali, peramalan — lalu AI generatif dan tata kelolanya. Setiap model dinilai dari satu hal: apakah ia mengubah keputusan menjadi lebih baik.

- ✓ LAYER 1 — DATA (Volume 1, selesai)
- ✓ LAYER 2 — STATISTICS (Volume 2, selesai)
- ✓ LAYER 3 — BUSINESS (Volume 3, edisi 2)
- ✓ LAYER 4 — EXPERIMENTATION (Volume 4, selesai)
- ✓ LAYER 5 — DECISION SCIENCE (Volume 5, selesai)
- **LAYER 6 — AI & MACHINE LEARNING (volume ini)**
- LAYER 7 — DOMAIN EXPERTISE

Tentang Volume 6

Layer tempat kemampuan analitis dilipatgandakan — dan tempat disiplin lima volume sebelumnya diuji

Pertanyaan yang dijawab volume ini

Lima volume sebelumnya membangun kemampuan berurutan. Volume 1: *apa yang terjadi?* Volume 2: *seberapa kuat buktinya?* Volume 3: *mengapa ini penting bagi bisnis?* Volume 4: *apakah X menyebabkan Y?* Volume 5: *jadi apa yang sebaiknya kita lakukan?*

Volume ini menjawab pertanyaan yang berbeda jenisnya: **bagaimana melipatgandakan kemampuan itu?** Machine learning memungkinkan satu analyst memberi skor kepada 1,48 juta pelanggan setiap malam. AI generatif memungkinkan pekerjaan yang dulu memakan sehari selesai dalam sepuluh menit.

Keduanya adalah pengali. Dan pengali bekerja dua arah: *ia memperbesar kualitas pekerjaan yang baik, dan memperbesar kerusakan dari pekerjaan yang buruk*. Model yang salah dapat mengambil keputusan buruk jauh lebih cepat daripada manusia mana pun.

Utang yang jatuh tempo di volume ini

Janji yang tertunda	Asalnya	Dijawab di
Evaluasi model formal: precision, recall, ROC-AUC	Vol 3 ed2 Bab 6; Vol 4 Bab 10	Bab 8
Imputasi berbasis model	Vol 1 Bab 6	Bab 3
Lanjutan regresi logistik → pohon dan boosting	Vol 2 Bab 6	Bab 5–6
Skor churn yang dibangun dengan benar	Vol 2 capstone	Bab 2–8
Ambang keputusan sebagai critical ratio	Vol 5 Bab 11 (newsvendor)	Bab 9
Peramalan permintaan & forecast value added	Vol 3 ed2 Bab 12; Vol 5 Bab 11	Bab 12
Segmentasi otomatis versus RFM manual	Vol 3 ed2 Bab 6	Bab 11
Tata kelola metrik diperluas ke model	Vol 3 ed2 Bab 13; Vol 5 Bab 14	Bab 14

Prinsip yang berlaku di seluruh volume

Prinsip	Isi
Model memprediksi, bukan menjelaskan	Fitur dengan kontribusi terbesar dalam model bukan penyebab terbesar. Volume 4 dibutuhkan untuk pertanyaan sebab-akibat; volume ini tidak menggantikannya (Bab 1).
Prediksi tanpa intervensi bernilai nol	Mengetahui siapa yang akan berhenti tidak bernilai apa pun sampai ada tindakan yang mengubah hasilnya — dan tindakan itu harus diukur secara inkremental (Bab 10).
Ambang adalah keputusan bisnis, bukan setelan default	Angka 0,5 tidak memiliki dasar apa pun. Ambang yang benar berasal dari biaya kesalahan, dan bentuknya persis critical ratio newsvendor (Bab 9).
Baseline lebih dulu, selalu	Model yang tidak dibandingkan dengan aturan sederhana tidak dapat dinilai. Sering aturan sederhana sudah cukup (Bab 2, 12).

Kecanggihan bukan keunggulan	Pada data volume ini, XGBoost <i>tidak</i> mengalahkan regresi logistik. Volume ini menunjukkan kapan ia menang dan kapan tidak (Bab 6).
Kebocoran data adalah kegagalan paling mahal	Ia menghasilkan model yang tampak luar biasa di laptop dan tidak berguna di produksi (Bab 2).
AI mempercepat, verifikasi tetap milik manusia	Output AI generatif diperlakukan seperti pekerjaan magang cerdas: cepat, sering benar, tidak pernah dipercaya tanpa diperiksa (Bab 13).

Empat bagian yang membentuk volume ini

BAGIAN I – FONDASI (Bab 1–3)

Kapan ML layak dipakai, anatomi proyek ML dan kebocoran data, feature engineering. Bagian yang menentukan apakah seluruh pekerjaan setelahnya menjawab pertanyaan yang benar.

BAGIAN II – MODEL (Bab 4–7)

Regresi dan regularisasi, klasifikasi logistik, pohon keputusan sampai gradient boosting, dan interpretasi model. Setiap bab dengan kode lengkap dan output yang benar-benar dijalankan.

BAGIAN III – EVALUASI & KEPUTUSAN (Bab 8–10)

Validasi dan metrik, ambang keputusan optimal, dan nilai bisnis model. Bagian yang membedakan pekerjaan ML yang menghasilkan uang dari yang hanya menghasilkan notebook.

BAGIAN IV – PERLUASAN & TATA KELOLA (Bab 11–15)

Clustering, deteksi anomali, peramalan permintaan, AI generatif, tata kelola AI/ML, dan capstone.

Peta pemilihan alat

PERTANYAAN: "Bisakah ML menolong di sini?"

- Apakah pertanyaannya SEBAB-AKIBAT? ("apakah X menyebabkan Y")
 - ↳ BUKAN pekerjaan ML. Kembali ke Volume 4. Bab 1
- Apakah ada KEPUTUSAN yang akan berubah karena prediksi?
 - ↳ TIDAK ADA → jangan bangun modelnya. Bab 1
- Apakah label tersedia dan dapat diamati sebelum keputusan?
 - ↳ TIDAK → unsupervised / aturan bisnis. Bab 11
- Target berupa ANGKA
 - ↳ satu titik waktu → REGRESI Bab 4, 8
 - ↳ berurutan waktu → PERAMALAN Bab 12
- Target berupa KELAS
 - ↳ perlu ditafsirkan / diaudit → LOGISTIK Bab 5
 - ↳ ada interaksi & non-linear → POHON/BOOSTING Bab 6
 - ↳ kelas sangat langka → PR-AUC + ambang Bab 8–9
- Tidak ada target, ingin struktur → CLUSTERING / PCA Bab 11
- Mencari yang "aneh" → DETEKSI ANOMALI Bab 11
- Ingin tahu SIAPA YANG BERUBAH karena tindakan
 - ↳ UPLIFT MODELING (butuh eksperimen, Vol 4) Bab 10

Perusahaan berjalan dan datanya

TokoNusa tetap menjadi konteks: retail omnichannel, 85 toko, 4,74 juta order per tahun, revenue Rp 1.480 miliar, 1,48 juta pelanggan aktif.

Berbeda dari volume sebelumnya, volume ini bekerja di atas *dataset nyata yang dapat dijalankan ulang*. Seluruh angka — setiap AUC, setiap koefisien, setiap rupiah — dihasilkan oleh skrip yang disertakan.

Dataset: 200.000 pelanggan, 22 kolom (src/vol6/gen_data.py)

TARGET UTAMA	churn_180h	– berhenti membeli dalam 180 hari setelah tanggal snapshot
Prevalensi	44,19%	(retensi 55,8%, sejalan Vol 3)
TARGET LAIN	belanja_90h abuse_promo	– nilai belanja 90 hari ke depan (regresi) – penyalahgunaan promo, prevalensi 1,85% (kelas sangat tak seimbang)
FITUR (19)	RFM hubungan layanan loyalitas komersial kategorikal	recency, frekuensi, monetary, AOV tenure, keteraturan, ragam kategori pernah_terlambat, n_keterlambatan, n_keluhan, retur_rate skor_loyalitas, anggota_tier promo_rate, diskon_rata kanal, wilayah, metode_bayar
FITUR BOCOR (jebakan Bab 2)	status_akun_ditutup	– sengaja disertakan; dicatat SETELAH tanggal snapshot

■ TECHNICAL NOTE — mengapa dataset ini disimulasikan, dan mengapa itu justru diperlukan

Dataset dibangun dari proses yang diketahui, dengan satu tujuan yang tidak dapat dicapai data nyata: **kebenaran nya diketahui**.

Struktur confounding-nya sengaja disamakan dengan DGP Volume 4 — ada variabel laten "niat berhenti" yang mempengaruhi paparan keterlambatan pengiriman *dan* churn. Akibatnya dapat diverifikasi secara langsung:

Selisih MENTAH churn (pernah terlambat vs tidak)	18,82 pp
EFEK KAUSAL keterlambatan yang sebenarnya	4,00 pp

Model prediktif mana pun akan menemukan asosiasi 18,82 pp dan tidak memiliki cara untuk mengetahui bahwa yang benar adalah 4,00 pp. Inilah pelajaran terpenting Bab 1, dan hanya dapat ditunjukkan dengan meyakinkan pada data yang kebenarannya diketahui.

Angka bisnis yang dipakai di sepanjang volume ini

CLV (berbasis contribution margin)	Rp 495.644
CM per order online / toko	Rp 69.700 / Rp 80.122
Nilai 1 pp retensi	Rp 7,341 miliar/tahun
Biaya kontak kampanye retensi	Rp 42.000 per pelanggan
Uplift retensi kampanye win-back	19% (rata-rata; heterogen)
Kapasitas kontak tim CRM	120.000 pelanggan/tahun
Biaya modal (WACC)	12%

Daftar isi Volume 6

BAGIAN I — FONDASI

Bab 1 Kapan Machine Learning Layak Dipakai — prediksi, kausalitas, dan keputusan

Bab 2 Anatomi Proyek ML — target, split, baseline, dan kebocoran data

Bab 3 Feature Engineering — dari data mentah ke fitur yang sah secara waktu

BAGIAN II — MODEL

Bab 4 Regresi dan Regularisasi — prediksi angka, ridge dan lasso

Bab 5 Klasifikasi dengan Regresi Logistik — model dasar yang sering menang

Bab 6 Pohon, Random Forest, dan Gradient Boosting — dan kapan mereka menang

Bab 7 Interpretasi Model — importance, permutation, SHAP, dan jebakannya

BAGIAN III — EVALUASI & KEPUTUSAN

Bab 8 Validasi dan Metrik — CV, ROC vs PR, kalibrasi, dan memilih metrik yang benar

Bab 9 Dari Skor ke Keputusan — ambang optimal sebagai critical ratio

Bab 10 Nilai Bisnis Model dan Uplift — mengapa menargetkan risiko tertinggi sering salah

BAGIAN IV — PERLUASAN & TATA KELOLA

Bab 11 Clustering, PCA, dan Deteksi Anomali — belajar tanpa label

Bab 12 Peramalan Permintaan — musiman, baseline, dan forecast value added

Bab 13 AI Generatif untuk Analytics — prompting, structured output, RAG, agent

Bab 14 Tata Kelola AI dan ML — bias, privasi, explainability, drift, human-in-the-loop

Bab 15 Capstone Semester 6 — sistem retensi berbasis model, dari data sampai tata kelola

Cara membaca volume ini

Bagian I wajib dan berurutan. Bab 2 berisi satu-satunya kesalahan dalam volume ini yang dapat menghancurkan seluruh proyek tanpa terdeteksi, dan tidak boleh dilewati.

Bagian II dapat dibaca melompat bila kamu sudah terbiasa dengan scikit-learn, tetapi Bab 7 tidak boleh dilewati — ia menjelaskan mengapa dua metode "pentingnya fitur" pada model yang sama memberi peringkat yang bertentangan.

Bagian III adalah inti volume ini. Bila waktu terbatas dan hanya tiga bab yang dapat dibaca, bacalah Bab 2, Bab 9, dan Bab 10.

Seluruh kode dapat dijalankan ulang. Skrip pembangkit data, skrip model, dan skrip verifikasi seluruh angka berada di folder yang sama dengan sumber buku ini.

Bab 1 — Kapan Machine Learning Layak Dipakai

Tiga pertanyaan yang tampak mirip tetapi membutuhkan alat yang sama sekali berbeda: prediksi, sebab-akibat, dan keputusan

Learning objectives	Membedakan masalah prediksi dari masalah kausal dan masalah keputusan; mengenali kapan ML adalah alat yang tepat dan kapan ia keliru; memahami mengapa model prediktif tidak dapat menjawab "mengapa"; menilai kelayakan proyek ML sebelum menulis kode; menyatakan nilai bisnis prediksi sebelum membangunnya
Prerequisites	Vol 4 Bab 1 (hierarki bukti, korelasi vs kausalitas); Vol 5 Bab 1 (problem framing)
Estimasi waktu	Baca 2 jam · Praktik 3 jam
Difficulty	● Intermediate
Skills covered	Problem framing untuk ML, prediksi vs kausalitas, penilaian kelayakan, estimasi nilai bisnis prediksi
Business domain	Retail omnichannel — permintaan model dari CRM, merchandising, dan operasi

Tiga pertanyaan yang sering tertukar

PERTANYAAN 1 — PREDIKSI

"Siapa yang akan berhenti membeli dalam 180 hari ke depan?"

Yang dibutuhkan : pola yang stabil antara masa lalu dan masa depan

Alat : MACHINE LEARNING ◀ volume ini

Cukup dijawab : bila urutan skornya benar

PERTANYAAN 2 — SEBAB-AKIBAT

"Apakah keterlambatan pengiriman MENYEBABKAN pelanggan berhenti?"

Yang dibutuhkan : identifikasi kausal — randomisasi atau struktur yang menirunya

Alat : EKSPERIMEN / CAUSAL INFERENCE ◀ Volume 4

TIDAK dapat dijawab oleh model prediktif, seakurat apa pun

PERTANYAAN 3 — KEPUTUSAN

"Siapa yang sebaiknya kita hubungi, dengan anggaran segini?"

Yang dibutuhkan : prediksi + biaya + nilai + kendala kapasitas

Alat : DECISION SCIENCE + ML ◀ Volume 5 + 6

Jawabannya SERING BUKAN "yang skornya tertinggi" ◀ Bab 9–10

Sebagian besar kegagalan proyek ML dalam bisnis bukan kegagalan teknis. Ia terjadi karena pertanyaan nomor 2 atau 3 dijawab dengan alat untuk pertanyaan nomor 1.

WHY — mengapa perbedaan ini menentukan

Dataset volume ini dibangun dari proses yang kebenarannya diketahui. Ini memungkinkan sesuatu yang tidak dapat dilakukan pada data nyata: membandingkan apa yang *ditemukan model* dengan apa yang *sebenarnya benar*.

Kode – asosiasi mentah antara keterlambatan dan churn

```
import pandas as pd

df = pd.read_csv('tokonusa_ml.csv')

# churn rate pada pelanggan yang PERNAH mengalami keterlambatan
# dibandingkan dengan yang tidak pernah
churn_telat      = df[df.pernah_terlambat == 1].churn_180h.mean()
churn_tidak      = df[df.pernah_terlambat == 0].churn_180h.mean()

print(f"churn | pernah terlambat : {churn_telat:.4f}")
print(f"churn | tidak pernah      : {churn_tidak:.4f}")
print(f"selisih                    : {(churn_telat-churn_tidak)*100:.2f} pp")
```

Output

```
churn | pernah terlambat : 0.5616
churn | tidak pernah     : 0.3734
selisih                  : 18.82 pp
```

⚠ **WARNING — angka 18,82 pp adalah asosiasi, dan efek sebenarnya 4,00 pp**

Karena data ini dibangun dari proses yang diketahui, efek kausal sebenarnya dapat dihitung langsung: bandingkan probabilitas churn setiap pelanggan bila ia mengalami keterlambatan dengan bila ia tidak, dengan segala hal lain dipertahankan.

Selisih MENTAH (yang ditemukan data)	18,82 pp
EFEK KAUSAL sebenarnya (diketahui dari DGP)	4,00 pp
BIAS	14,82 pp – 4,7 kali lipat

Penyebabnya adalah variabel laten "niat berhenti" yang tidak tercatat di database mana pun: pelanggan yang sudah berniat berhenti cenderung memesan dengan pola yang lebih rentan terlambat, dan juga cenderung berhenti. Keterlambatan dan churn sama-sama akibat, bukan sebab dan akibat.

Tidak ada model prediktif yang dapat mendeteksi hal ini. Model yang lebih canggih justru akan menangkap asosiasi 18,82 pp dengan lebih rapi. Akurasi tinggi bukan pelindung terhadap kesalahan kausal — ia justru membuatnya lebih meyakinkan.

Angka 4,00 pp pada dataset ini sengaja disamakan dengan estimasi IV di Volume 4 (4,01 pp), sehingga kedua volume menceritakan satu kasus yang sama dari dua sisi.

Konsekuensi bisnisnya nyata dan besar

KEPUTUSAN: berapa yang layak diinvestasikan untuk memperbaiki SLA?

Bila memakai asosiasi model (18,82 pp):

nilai = 1,48 juta × 36,4% terpapar × 18,82 pp × Rp 495.644
= Rp 50,2 miliar per tahun
→ proposal Rp 16 miliar tampak sangat menguntungkan

Bila memakai efek kausal (4,00 pp):

nilai = 1,48 juta × 36,4% terpapar × 4,00 pp × Rp 495.644
= Rp 10,7 miliar per tahun
→ proposal Rp 16 miliar MERUGI Rp 5,3 miliar

Model yang sama. Angka yang sama. Dua keputusan yang berlawanan.

◆ BUSINESS INSIGHT — pertanyaan yang harus ditanyakan sebelum menyerahkan model

Ketika seseorang meminta model prediksi churn, ia hampir tidak pernah benar-benar menginginkan prediksi. Yang ia inginkan adalah *menurunkan churn*. Keduanya berbeda, dan jarak di antaranya adalah tempat sebagian besar nilai hilang.

Satu pertanyaan yang memisahkan keduanya: **"Setelah model memberi tahu siapa yang akan berhenti, apa yang akan kita lakukan kepada mereka — dan apakah tindakan itu terbukti mengubah perilaku?"**

Bila jawabannya "kami akan kirim promo", pertanyaan berikutnya adalah apakah promo itu pernah diuji secara acak. Bila belum, model prediksi hanya memindahkan ketidaktahuan ke tempat yang lebih rapi. Bab 10 menunjukkan bahwa pada kasus TokoNusa, menargetkan pelanggan berskor tertinggi justru menghasilkan nilai *negatif*.

WHAT — apa yang sebenarnya dilakukan machine learning

DEFINISI KERJA

Machine learning adalah cara menemukan fungsi f sehingga $f(\text{fitur})$ mendekati target, dengan f dipilih dari keluarga fungsi yang besar berdasarkan data, bukan ditulis manusia.

data historis (fitur, label) $\rightarrow$ algoritma pembelajaran $\rightarrow$ f $\rightarrow$ prediksi

YANG DIJAMIN : f bekerja pada data yang MIRIP data latih

YANG TIDAK DIJAMIN:

- f bekerja bila dunia berubah (Bab 14)
- f menjelaskan mekanisme (Bab 7)
- f bekerja bila kita BERTINDAK atas prediksinya (Bab 10)
- f bernilai secara bisnis (Bab 9–10)

Jenis	Bentuk masalah	Contoh di TokoNusa
Supervised — klasifikasi	Label berupa kelas yang diketahui di data historis	Churn 180 hari; penyalahgunaan promo; gagal bayar B2B
Supervised — regresi	Label berupa angka	Belanja 90 hari ke depan; waktu pengiriman; permintaan SKU
Peramalan deret waktu	Label berupa angka yang berurutan waktu	Revenue harian; permintaan mingguan per SKU
Unsupervised — clustering	Tidak ada label; mencari struktur	Segmentasi pelanggan; pengelompokan SKU
Deteksi anomali	Tidak ada label; mencari yang menyimpang	Transaksi ganjil; kesalahan data; penyalahgunaan
Uplift / causal ML	Butuh data eksperimen	Siapa yang <i>berubah</i> karena kampanye (Bab 10)

WHEN — kapan ML layak dipakai

LIMA SYARAT — seluruhnya harus terpenuhi

1. ADA KEPUTUSAN yang akan berbeda karena prediksi. Bila tindakannya sama apa pun hasil prediksinya, modelnya tidak bernilai berapa pun akurasinya.
2. KEPUTUSANNYA BERULANG dan berskala besar. Keputusan yang diambil tiga kali setahun lebih baik ditangani analisis manual (Volume 5), bukan model.
3. LABEL TERSEDIA, cukup banyak, dan dapat diamati SEBELUM keputusan harus diambil.
4. POLA MASA LALU MASIH BERLAKU di masa depan. Bila proses bisnisnya baru saja berubah total, data historis justru menyesatkan.
5. NILAINYA MELEBIHI BIAYANYA — termasuk biaya pemeliharaan, pemantauan, dan tata kelola.

Situasi	ML layak?	Alasan dan alternatif
Memberi skor churn 1,48 juta pelanggan tiap malam	YA	Berulang, berskala, label tersedia, tindakan jelas
Memutuskan membuka satu toko baru	TIDAK	Keputusan tunggal; pakai NPV dan simulasi (Vol 5 Bab 3, 7)
Mengetahui apakah program tier menaikkan retensi	TIDAK	Pertanyaan kausal; pakai RDD atau eksperimen (Vol 4 Bab 11)
Meramalkan permintaan 2.400 SKU per minggu	YA	Berulang, berskala — tetapi baseline sederhana sering menang (Bab 12)
Menetapkan harga optimal	TIDAK LANGSUNG	Butuh elastisitas kausal (Vol 4 Bab 11), lalu optimasi (Vol 5 Bab 12)
Mendeteksi transaksi janggal	MUNGKIN	Aturan bisnis sering lebih baik; lihat hasil mengejutkan di Bab 11
Menjelaskan mengapa margin turun kuartal ini	TIDAK	Dekomposisi dan root-cause analysis (Vol 3 Bab 11)
Memilih pelanggan untuk kampanye retensi	YA, TETAPI	Butuh model <i>uplift</i> , bukan model churn (Bab 10)

✗ COMMON MISTAKE — membangun model untuk keputusan yang tidak ada

Gejala: proyek "prediksi churn" yang selesai, akurat, dipresentasikan, lalu tidak pernah dipakai.

Mengapa terjadi: tidak ada yang menanyakan di awal siapa yang akan bertindak atas prediksi itu, dengan anggaran berapa, dan tindakan apa. Prediksi tanpa tindakan adalah informasi tanpa nilai — persis prinsip nilai informasi di Vol 5 Bab 5: *informasi hanya bernilai bila ia mengubah keputusan*.

Perbaikan: sebelum menulis baris kode pertama, tuliskan satu kalimat: "Bila model ini bekerja, [siapa] akan [melakukan apa] kepada [berapa banyak orang] dengan biaya [berapa], dan kami akan tahu berhasil dari [ukuran apa]." Bila kalimat itu tidak dapat dilengkapi, proyeknya belum siap.

Cara senior menghindarinya: menghitung nilai bisnis prediksi *sempurna* lebih dulu. Bila model sempurna pun hanya bernilai Rp 200 juta sementara biaya membangun dan memelihara Rp 800 juta, tidak perlu ada eksperimen model sama sekali. Ini persis EVPI dari Vol 5 Bab 5, diterapkan pada ML.

HOW — menilai kelayakan sebelum menulis kode

Langkah 1: hitung batas atas nilai

Kode — nilai prediksi sempurna sebagai batas atas

```
# Batas atas: bila kita TAHU PERSIS siapa yang akan churn,  
# dan kampanye retensi menyelamatkan 19% dari mereka.  
CLV          = 495_644      # contribution-margin based (Vol 3 Bab 6)  
UPLIFT       = 0.19        # uplift retensi kampanye (harus dari eksperimen)  
BIAYA_KONTAK = 42_000  
N_PELANGGAN  = 1_480_000  
CHURN_RATE   = 0.4419  
  
n_churn      = N_PELANGGAN * CHURN_RATE  
nilai_kotor  = n_churn * CLV * UPLIFT  
biaya        = n_churn * BIAYA_KONTAK      # hanya menghubungi yang akan churn  
nilai_bersih = nilai_kotor - biaya  
  
print(f"Pelanggan yang akan churn : {n_churn:,.0f}")  
print(f"Nilai kotor          : Rp {nilai_kotor/1e9:,.1f} miliar")  
print(f"Biaya kontak         : Rp {biaya/1e9:,.1f} miliar")  
print(f"BATAS ATAS nilai model : Rp {nilai_bersih/1e9:,.1f} miliar/tahun")
```

Output

```
Pelanggan yang akan churn : 654,012  
Nilai kotor              : Rp 61,6 miliar  
Biaya kontak             : Rp 27,5 miliar  
BATAS ATAS nilai model   : Rp 34,1 miliar/tahun
```

■ TECHNICAL NOTE — cara membaca batas atas ini dengan benar

Rp 34,1 miliar adalah nilai *prediksi sempurna tanpa kendala apa pun*. Ia bukan target dan bukan proyeksi. Ia adalah plafon.

Tiga hal akan memotongnya secara berurutan, dan masing-masing dibahas di volume ini:

(1) Model tidak sempurna. AUC 0,80 berarti urutan skornya jauh dari sempurna (Bab 8). **(2) Kapasitas terbatas.** Tim CRM hanya dapat menghubungi 120.000 pelanggan per tahun, bukan 654.012 (Bab 9). **(3) Uplift heterogen.** Angka 19% adalah rata-rata; pada pelanggan berisiko tertinggi uplift-nya jauh lebih kecil, dan inilah pemotong terbesar (Bab 10).

Nilai akhir yang dapat dipertahankan pada kasus ini ternyata sekitar **Rp 4,6 miliar per tahun** — 13,5% dari plafon. Itu masih proyek yang sangat layak, tetapi angkanya harus dinyatakan dengan jujur sejak awal, bukan setelah ditagih.

Langkah 2: periksa apakah pertanyaannya benar-benar prediktif

UJI TIGA KALIMAT

Tuliskan pertanyaannya, lalu periksa kata kerjanya:

"SIAPA yang akan..."	→ prediksi	✓ ML
"BERAPA banyak yang..."	→ prediksi	✓ ML
"KAPAN akan terjadi..."	→ prediksi	✓ ML
"APAKAH X menyebabkan..."	→ kausal	x Volume 4

"MENGAPA terjadi..."	→ kausal/dekomp	x Volume 3–4
"BERAPA dampaknya bila kita mengubah X..."	→ kausal	x Volume 4
"APA yang sebaiknya kita lakukan..."	→ keputusan	x Volume 5 (+ ML)

Kata "sebaiknya" dan "menyebabkan" adalah tanda paling andal bahwa ML BUKAN alat utamanya.

Langkah 3: periksa ketersediaan label pada waktu yang benar

Ini syarat yang paling sering dilanggar, dan pelanggaran ini menghasilkan model yang tampak sempurna di laptop dan tidak berguna di produksi. Bab 2 membahasnya secara penuh, tetapi pemeriksaan awalnya sederhana:

GARIS WAKTU YANG SAH



ATURAN: setiap fitur harus dapat diketahui pada tanggal SNAPSHOT.
Bila sebuah kolom hanya terisi setelah tanggal itu, ia BOCOR.

BEST PRACTICE — kanvas kelayakan proyek ML

SATU HALAMAN, DIISI SEBELUM MENULIS KODE

1. KEPUTUSAN Keputusan apa yang berubah? Siapa pemiliknya?
2. TINDAKAN Apa yang dilakukan atas prediksi? Terbukti efektif?
3. SKALA Berapa kali per tahun? Berapa unit?
4. KENDALA Kapasitas, anggaran, waktu tunggu keputusan
5. LABEL Definisi persis, sumber, jeda waktu, kualitas
6. FITUR Tersedia pada saat inferensi? Bukan hanya saat latih?
7. BASELINE Aturan sederhana apa yang harus dikalahkan?
8. METRIK Metrik teknis DAN metrik bisnis
9. NILAI Batas atas, estimasi realistis, biaya total
10. RISIKO Apa yang terjadi bila model salah? Siapa dirugikan?

Bila tiga dari sepuluh tidak dapat diisi, proyeknya belum siap.
Bila nomor 1, 2, atau 9 tidak dapat diisi, proyeknya tidak layak.

► EXECUTIVE PERSPECTIVE — kalimat yang menyelamatkan banyak kuartal

Ketika pimpinan meminta "kita butuh AI untuk ini", respons yang paling bernilai bukan penolakan dan bukan persetujuan. Ia adalah satu pertanyaan:

"Setelah sistemnya berjalan, keputusan apa yang akan kita ambil berbeda dari hari ini?"

Bila jawabannya jelas dan spesifik, proyeknya kemungkinan besar layak dan kamu baru saja memperoleh definisi keberhasilan yang dapat diukur. Bila jawabannya kabur, kamu baru saja menghemat enam bulan bagi tim.

Pertanyaan ini tidak menolak apa pun. Ia hanya memindahkan percakapan dari teknologi ke keputusan — dan itu selalu percakapan yang lebih produktif.

COMMON MISTAKE — empat kekeliruan kerangka berpikir

× 1. Menafsirkan pentingnya fitur sebagai sebab

Gejala: slide berjudul "faktor penyebab churn" yang isinya feature importance.

Mengapa merusak: pada dataset ini, model akan menempatkan recency sebagai fitur terpenting. Tetapi menghubungkan pelanggan agar "recency-nya turun" adalah tidak masuk akal — recency adalah *gejala*, bukan sebab. Bertindak atas feature importance berarti bertindak atas gejala.

Perbaikan: beri label eksplisit pada setiap keluaran model: "ini prediktor, bukan penyebab". Bab 7 membahas cara menyajikannya tanpa mengundang salah tafsir.

Cara senior menghindarinya: memisahkan dua dokumen sejak awal — *dokumen model* (siapa yang berisiko) dan *dokumen kausal* (apa yang berhasil bila diubah). Keduanya tidak pernah digabung dalam satu slide.

× 2. Mengoptimalkan akurasi alih-alih nilai

Gejala: tiga minggu dihabiskan menaikkan AUC dari 0,80 ke 0,81, sementara ambang keputusan masih 0,5 karena itu default.

Mengapa merusak: pada kasus di Bab 9, memperbaiki ambang bernilai jauh lebih besar daripada memperbaiki model, dan biayanya nol.

Perbaikan: selesaikan rantai keputusan lebih dulu — ambang, kapasitas, tindakan — baru kembali menyempurnakan model bila masih sepadan.

× 3. Memakai model untuk memutuskan intervensi tanpa bukti kausal

Gejala: "model menunjukkan keterlambatan adalah prediktor kuat, maka kita investasikan Rp 16 miliar untuk SLA."

Mengapa merusak: selisihnya 18,82 pp versus 4,00 pp — keputusan yang tampak menguntungkan Rp 34 miliar sebenarnya merugi Rp 5,3 miliar.

Perbaikan: setiap kali prediktor akan diubah menjadi intervensi, pertanyaannya berpindah ke Volume 4. Tidak ada jalan pintas.

× 4. Mengira ML menggantikan pemahaman bisnis

Gejala: "masukkan semua kolom, biar model yang menentukan."

Mengapa merusak: pendekatan ini adalah cara tercepat memasukkan fitur bocor (Bab 2), fitur yang tidak tersedia saat inferensi, dan fitur yang melanggar aturan privasi (Bab 14). Pada dataset ini, memasukkan semua kolom menaikkan AUC dari 0,8000 ke 0,9244 — dan modelnya sepenuhnya tidak berguna.

Perbaikan: setiap fitur harus lolos satu pertanyaan: "apakah nilai ini diketahui pada saat kita harus memutuskan?"

Checklist kelayakan ML

- ✓ Pertanyaan diklasifikasikan: prediksi, kausal, atau keputusan
- ✓ Keputusan yang akan berubah dinyatakan beserta pemilikinya
- ✓ Tindakan atas prediksi ada, dan efektivitasnya sudah atau akan diuji
- ✓ Skala dan frekuensi keputusan membenarkan otomasi
- ✓ Definisi label persis, termasuk jendela waktunya
- ✓ Setiap fitur diperiksa ketersediaannya pada saat inferensi
- ✓ Batas atas nilai dihitung sebelum membangun model
- ✓ Baseline sederhana ditetapkan sebagai pembanding wajib

- ✓ Metrik bisnis ditetapkan berdampingan dengan metrik teknis
- ✓ Risiko bila model salah dinyatakan, termasuk siapa yang dirugikan

Ending Card — Bab 1

What you learned

Tiga jenis pertanyaan yang sering tertukar dan alat yang berbeda untuk masing-masing; demonstrasi kuantitatif bahwa model prediktif menangkap asosiasi 18,82 pp sementara efek kausal sebenarnya 4,00 pp, dan konsekuensi bisnisnya Rp 34 miliar versus rugi Rp 5,3 miliar; definisi kerja machine learning dan apa yang tidak dijaminnya; enam jenis masalah ML; lima syarat kelayakan; delapan situasi bisnis dan penilaiannya; cara menghitung batas atas nilai model sebelum membangunnya; uji tiga kalimat; kanvas kelayakan sepuluh butir; dan empat kekeliruan kerangka berpikir yang paling mahal.

Skills mastered

Problem framing untuk ML · membedakan prediksi, kausalitas, dan keputusan · penilaian kelayakan proyek · estimasi batas atas nilai model.

Real business value

Menghitung batas atas nilai sebelum membangun model mencegah proyek yang biayanya melebihi manfaat maksimalnya. Dan memisahkan pertanyaan prediktif dari pertanyaan kausal pada kasus SLA ini adalah selisih antara keputusan yang menciptakan nilai dan keputusan yang menghancurkan Rp 5,3 miliar.

Interview readiness

● INTERVIEW QUESTIONS

1. "Kapan kamu TIDAK memakai machine learning?" — keputusan tunggal, pertanyaan kausal, tidak ada tindakan, skala kecil; beri contoh konkret.
2. "Model kami menunjukkan keterlambatan adalah prediktor churn terkuat. Berapa yang layak kita investasikan?" — jebakan; pisahkan asosiasi dari efek kausal.
3. "Bagaimana kamu memutuskan apakah proyek ML layak?" — batas atas nilai, baseline, kapasitas, biaya pemeliharaan.
4. "Apa bedanya prediksi churn dan mengurangi churn?" — prediksi tanpa intervensi yang terbukti bernilai nol.
5. "Stakeholder minta 'AI'. Apa pertanyaan pertamamu?" — keputusan apa yang akan berbeda.
6. "Model kamu AUC 0,92. Bagus?" — tanyakan fiturnya; AUC yang melompat sering tanda kebocoran (Bab 2).

Exercises

Exercise 1.1 (Beginner · 30 menit)

Objective: mengklasifikasikan jenis pertanyaan

Untuk sepuluh permintaan berikut, tentukan jenisnya (prediksi / kausal / keputusan), alat yang tepat, dan volume rujukannya:

- (a) "Siapa pelanggan yang akan berhenti bulan depan?" (b) "Apakah program tier menaikkan retensi?" (c) "Berapa stok yang harus dipesan untuk SKU musiman?" (d) "Mengapa margin turun 0,5 pp kuartal ini?" (e) "SKU mana yang akan kehabisan stok minggu depan?" (f) "Apakah menaikkan harga 5% akan menaikkan laba?" (g) "Berapa lama pengiriman ke Luar Jawa akan memakan waktu?" (h) "Toko mana yang sebaiknya ditutup?" (i) "Transaksi mana yang mencurigakan?" (j) "Apakah kampanye email menaikkan pembelian ulang?"

Answer key 1.1

(a) **Prediksi** — ML klasifikasi (Vol 6). (b) **Kausal** — RDD atau eksperimen (Vol 4 Bab 11). (c) **Keputusan** — newsvendor (Vol 5 Bab 11), memakai *peramalan permintaan* dari Vol 6 Bab 12 sebagai masukan. (d) **Kausal/dekomposisi** — mix-rate dan root-cause (Vol 3 Bab 11). (e) **Prediksi** — Vol 6 Bab 12. (f) **Kausal** lalu **keputusan** — elastisitas dari IV atau geo experiment (Vol 4 Bab 11-12), lalu optimasi harga (Vol 5 Bab 12). (g) **Prediksi** — regresi (Vol 6 Bab 4). (h) **Keputusan** — NPV per toko dan nilai opsi (Vol 5 Bab 3, 8). (i) **Deteksi anomali** — tetapi periksa dulu apakah aturan bisnis cukup (Vol 6 Bab 11). (j) **Kausal** — holdout acak; contoh sempurna karena biayanya nol (Vol 4 Bab 2).

Pola yang layak diperhatikan: dari sepuluh permintaan yang semuanya terdengar seperti "pekerjaan data", hanya empat yang benar-benar pekerjaan ML.

Exercise 1.2 (Intermediate · 50 menit)

Objective: menghitung batas atas nilai

Tim merchandising meminta model yang memprediksi SKU mana yang akan kehabisan stok dalam 14 hari ke depan. Data: 2.400 SKU aktif, 6% mengalami kehabisan stok per bulan, rata-rata kehilangan contribution margin per kejadian Rp 4,2 juta, biaya tindakan pencegahan (pemesanan darurat) Rp 850 ribu per SKU, tingkat substitusi 45%.

(a) Hitung batas atas nilai prediksi sempurna per tahun. (b) Bila tindakan pencegahan hanya berhasil 70% kali, bagaimana batas atasnya berubah? (c) Berapa presisi minimum yang membuat model bernilai positif? (d) Apa baseline yang harus dikalahkan?

Answer key 1.2

(a) Kejadian per tahun = $2.400 \times 6\% \times 12 = 1.728$. Kerugian per kejadian setelah substitusi = $4,2 \text{ jt} \times (1 - 0,45) = \text{Rp } 2,31 \text{ juta}$. Nilai kotor = $1.728 \times 2,31 \text{ jt} = \text{Rp } 3,99 \text{ miliar}$; biaya = $1.728 \times 850 \text{ rb} = \text{Rp } 1,47 \text{ miliar}$. **Batas atas = Rp 2,52 miliar per tahun.**

(b) Dengan keberhasilan 70%: nilai kotor = $3,99 \times 0,70 = \text{Rp } 2,79 \text{ miliar}$; biaya tetap Rp 1,47 miliar. **Batas atas = Rp 1,32 miliar** — turun 48%. Perhatikan bahwa efektivitas tindakan memotong nilai jauh lebih tajam daripada yang biasanya diperkirakan, dan angka itu *harus berasal dari pengukuran*, bukan asumsi.

(c) Nilai positif memerlukan: $\text{presisi} \times 2,31 \text{ jt} \times 0,70 > 850 \text{ rb} \rightarrow \text{presisi} > 52,6\%$. Ini angka yang sangat berguna untuk disampaikan di awal: bila model tidak dapat mencapai presisi 53%, proyeknya merugi. Ini adalah bentuk lain dari ambang keputusan di Bab 9.

(d) Baseline wajib: (i) SKU dengan *days of inventory* terendah; (ii) aturan "stok saat ini < permintaan rata-rata 14 hari $\times 1,2$ "; (iii) SKU kelas A dengan variabilitas tertinggi. Aturan (ii) biasanya sudah menangkap sebagian besar kasus, dan model harus mengalahkannya — bukan mengalahkan tebakan acak.

Exercise 1.3 (Advanced · 90 menit)

Objective: kanvas kelayakan lengkap

Pilih satu permintaan model dari organisasi kamu (atau susun yang realistis). Isi seluruh sepuluh butir kanvas kelayakan. Untuk butir yang tidak dapat diisi, tuliskan siapa yang harus ditanya dan pertanyaan persisnya. Akhiri dengan rekomendasi: lanjutkan, tunda sampai informasi X tersedia, atau tolak dengan alasan.

Answer key 1.3 — rubrik

Pengisian yang kuat: butir 2 (tindakan) menyebut apakah efektivitasnya sudah diukur secara kausal, bukan diasumsikan; butir 7 (baseline) berisi aturan yang benar-benar dipakai bisnis hari ini, bukan tebakan acak; butir 9 (nilai) berisi batas atas *dan* estimasi realistis setelah kapasitas dan efektivitas tindakan; butir 10 menyebut kelompok yang dapat dirugikan oleh kesalahan model, bukan hanya kerugian perusahaan. Rekomendasi "tunda" adalah jawaban yang sah dan sering paling tepat — terutama ketika efektivitas tindakan belum pernah diukur. Dalam kasus itu, urutan yang benar adalah menjalankan holdout acak lebih dulu (biaya hampir nol), baru membangun model.

Portfolio idea

★ PORTFOLIO TIP

Kanvas kelayakan yang terisi lengkap untuk satu proyek nyata, *berakhir dengan rekomendasi menolak atau menunda*, adalah artefak portofolio yang jauh lebih menonjol daripada notebook model. Ia menunjukkan penilaian, dan penilaian jauh lebih langka daripada kemampuan memanggil `fit()`.

Further reading

Kleinberg, Ludwig, Mullainathan & Obermeyer, "Prediction Policy Problems" — perbedaan formal antara masalah prediksi dan masalah kausal · Provost & Fawcett, *Data Science for Business* · Ajay Agrawal dkk., *Prediction Machines* — ekonomi prediksi · Vol 4 Bab 1 dan Vol 5 Bab 1 buku ini.

Next chapter

Bab 2 — anatomi proyek ML dari definisi target sampai baseline, dan satu kesalahan yang dapat menghancurkan seluruh proyek tanpa terdeteksi: kebocoran data. Pada dataset ini, kebocoran menaikkan AUC dari 0,8000 ke 0,9244 dan membuat model sepenuhnya tidak berguna.

Bab 2 — Anatomi Proyek ML

Definisi target, pembagian data, baseline — dan satu kesalahan yang menghancurkan proyek tanpa terdeteksi

Learning objectives	Mendefinisikan target dengan presisi termasuk jendela waktunya; merancang pembagian data yang sah; membangun baseline yang wajib dikalahkan; mengenali dan mencegah kebocoran data dalam enam bentuknya; menafsirkan gejala kebocoran; menyusun urutan kerja proyek ML yang benar
Prerequisites	Bab 1; Vol 1 Bab 6 (kualitas data); Vol 2 Bab 4 (sampling)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Intermediate
Skills covered	Definisi target, train/test/validation split, time-based split, baseline, deteksi kebocoran data
Business domain	Retail omnichannel — model retensi pelanggan TokoNusa

Urutan kerja yang benar

- | | |
|-----------------------|---|
| 1. DEFINISI TARGET | apa persisnya yang diprediksi, dalam jendela waktu berapa |
| 2. GARIS WAKTU | kapan fitur diketahui, kapan keputusan diambil, kapan label diamati |
| 3. PEMBAGIAN DATA | train / validation / test – dan alasan pembagiannya |
| 4. BASELINE | aturan sederhana yang harus dikalahkan |
| 5. MODEL | mulai dari yang paling sederhana |
| 6. EVALUASI | metrik teknis DAN metrik bisnis |
| 7. AMBANG & KEPUTUSAN | cara skor diubah menjadi tindakan |
| 8. PEMANTAUAN | bagaimana kita tahu model rusak |

Langkah 1–4 menentukan apakah proyeknya benar.
Langkah 5 adalah yang paling sedikit menentukan – dan paling sering memakan waktu paling banyak.

Langkah 1 — Definisi target

"Prediksi churn" bukan definisi target. Ia adalah judul. Definisi target harus dapat diterjemahkan langsung menjadi kueri SQL tanpa ruang tafsir.

Komponen	Pertanyaan yang harus dijawab	Pilihan TokoNusa
Unit	Satu baris mewakili apa?	Satu pelanggan aktif pada tanggal snapshot
Peristiwa	Apa yang dianggap terjadi?	Tidak ada transaksi sama sekali

Jendela waktu	Dalam periode berapa?	180 hari setelah tanggal snapshot
Populasi	Siapa yang masuk, siapa yang dikecualikan?	Pelanggan dengan ≥ 1 transaksi dalam 12 bulan terakhir; karyawan dan akun uji dikecualikan
Titik pengamatan	Kapan snapshot diambil?	Akhir bulan; label diamati 180 hari kemudian
Penanganan kasus tepi	Pelanggan meninggal, akun digabung, pindah kota?	Dikeluarkan dan dicatat jumlahnya

◆ BUSINESS INSIGHT — definisi target adalah keputusan bisnis, bukan teknis

Jendela 180 hari bukan pilihan statistik. Ia berasal dari pertanyaan operasional: *berapa lama sebelum pelanggan yang tidak bertransaksi masih dapat dipulihkan?*


Jendela yang terlalu pendek (30 hari) menghasilkan target yang penuh derau — banyak pelanggan hanya sedang tidak membutuhkan apa-apa. Jendela yang terlalu panjang (365 hari) menghasilkan prediksi yang datang terlambat untuk ditindaklanjuti.

Aturan praktis yang bekerja: **jendela label harus sedikit lebih panjang daripada waktu yang dibutuhkan tindakan untuk bekerja**. Kampanye retensi TokoNusa butuh 8-12 minggu untuk menunjukkan efek; 180 hari memberi ruang yang cukup tanpa membuat prediksi menjadi ramalan jangka panjang yang tidak dapat ditindaklanjuti.

Konsekuensi yang sering terlewat: mengubah jendela label mengubah prevalensi, mengubah metrik, dan membuat seluruh perbandingan historis tidak berlaku. Ubah sekali di awal, lalu kunci.

Langkah 2 — Garis waktu dan kebocoran data

GARIS WAKTU YANG SAH



ATURAN TUNGGAL YANG MENENTUKAN SEGALANYA:

Setiap nilai fitur harus sudah ADA dan TERCATAT pada tanggal snapshot — bukan pada tanggal kita menarik data untuk melatih model.

Kesalahan yang paling umum: menarik seluruh tabel pelanggan hari ini, lalu memakai kolom apa adanya. Banyak kolom di tabel produksi diperbarui terus-menerus, sehingga nilainya hari ini mencerminkan masa DEPAN dari sudut pandang snapshot.

Demonstrasi: apa yang terjadi ketika data bocor

Dataset volume ini memuat satu kolom yang sengaja bocor: `status_akun_ditutup`. Kolom ini terisi setelah pelanggan berhenti — yaitu setelah label terjadi.

Kode — membandingkan model bersih dan model bocor

```

import pandas as pd
import xgboost as xgb
from sklearn.model_selection import train_test_split
from sklearn.metrics import roc_auc_score

df = pd.read_csv('tokonusa_ml.csv')
  
```

```

FITUR_BERSIH = ['tenure_bulan', 'frekuensi_12bln', 'recency_hari', 'aov',
                'monetary_12bln', 'n_kategori', 'skor_loyalitas', 'anggota_tier',
                'pernah_terlambat', 'n_keterlambatan', 'n_keluhan', 'retur_rate',
                'promo_rate', 'diskon_rata', 'keteraturan',
                'kanal', 'wilayah', 'metode_bayar']

def latih_dan_nilai(kolom, label):
    X = pd.get_dummies(df[kolom], drop_first=True) # kategorikal -> 0/1
    y = df['churn_180h']
    # stratify menjaga proporsi churn sama di train dan test
    Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.30,
                                          random_state=42, stratify=y)
    m = xgb.XGBClassifier(n_estimators=400, max_depth=4, learning_rate=0.05,
                          subsample=0.8, colsample_bytree=0.8,
                          eval_metric='logloss', random_state=42, n_jobs=-1).fit(Xtr, ytr)
    auc = roc_auc_score(yte, m.predict_proba(Xte)[:, 1])
    imp = pd.Series(m.feature_importances_, index=X.columns).nlargest(3)
    print(f"{label:<28} AUC {auc:.4f}")
    print(f"  importance teratas: " +
          ", ".join(f"{k} {v:.3f}" for k, v in imp.items()))

latih_dan_nilai(FITUR_BERSIH, "model bersih")
latih_dan_nilai(FITUR_BERSIH + ['status_akun_ditutup'], "model + fitur BOCOR")

```

Output

```

model bersih          AUC 0.8000
  importance teratas: anggota_tier 0.379, frekuensi_12bln 0.186,
                    recency_hari 0.100

model + fitur BOCOR   AUC 0.9244
  importance teratas: status_akun_ditutup 0.757, anggota_tier 0.101,
                    frekuensi_12bln 0.038

```

⚠ WARNING — inilah bentuk kegagalan paling mahal dalam machine learning

Model kedua terlihat jauh lebih baik pada setiap metrik: AUC 0,9244 versus 0,8000, akurasi 86,1% versus 72,3%, presisi 92,5%. Ia akan lolos setiap pemeriksaan teknis, disetujui, dan diluncurkan.

Lalu ia gagal total di produksi, karena pada saat model harus memberi skor kepada pelanggan yang *belum* berhenti, kolom `status_akun_ditutup` selalu bernilai 0. Model yang menggantungkan 75,7% kekuatannya pada kolom itu tiba-tiba kehilangan hampir seluruh kemampuannya.

Yang membuat kesalahan ini begitu mahal bukan besarnya, melainkan **arahnya**: kebocoran selalu membuat model terlihat *lebih baik*. Tidak ada mekanisme alami yang membunyikan alarm. Satu-satunya pertahanan adalah pemeriksaan yang disengaja.

Enam bentuk kebocoran data

Bentuk	Contoh nyata	Cara mendeteksi
1. Kebocoran waktu	Kolom yang diperbarui setelah label terjadi: status akun, tanggal penutupan, catatan CS terakhir	Untuk tiap kolom, tanyakan: kapan nilainya terakhir berubah? Bila jawabannya "terus-menerus", curigai
2. Proxy target	Kolom yang hampir merupakan label itu sendiri: "alasan berhenti",	Korelasi tunggal fitur dengan target sangat tinggi (AUC satu fitur > 0,85)

	"segmen at-risk" yang dihitung ulang tiap hari	
3. Kebocoran praproses	Melakukan scaling, imputasi, atau seleksi fitur pada SELURUH data sebelum split	Periksa apakah <code>fit</code> pernah dipanggil pada data uji; gunakan <code>Pipeline</code>
4. Kebocoran kelompok	Beberapa baris dari pelanggan yang sama tersebar di train dan test	Pastikan pembagian dilakukan per <i>entitas</i> , bukan per baris
5. Kebocoran duplikat	Baris identik muncul di train dan test karena data digandakan	Hitung duplikat penuh sebelum split
6. Kebocoran masa depan agregat	Fitur "rata-rata pembelian kategori X" dihitung dari seluruh periode, termasuk periode label	Semua agregat harus dihitung dengan batas waktu eksplisit (Bab 3)

✓ BEST PRACTICE — tiga pemeriksaan yang menangkap sebagian besar kebocoran

- 1. Uji fitur tunggal.** Latih model dengan satu fitur saja, satu per satu. Fitur apa pun yang sendirian menghasilkan AUC di atas 0,85 hampir pasti bocor atau merupakan proxy target. Pada dataset ini, fitur bersih terbaik (recency) hanya mencapai AUC 0,6817 — wajar dan sehat.
- 2. Uji tanggal.** Untuk setiap kolom, tuliskan satu kalimat: "nilai ini terakhir berubah pada saat ____". Bila kalimatnya menyebut peristiwa yang terjadi setelah snapshot, kolomnya bocor.
- 3. Uji lompatan.** Bila menambahkan satu fitur menaikkan AUC lebih dari 0,05, hentikan dan selidiki. Kenaikan sebesar itu dari satu kolom hampir tidak pernah nyata. Pada contoh di atas, lompatannya 0,1244 — sepuluh kali lebih besar daripada kenaikan wajar.

Langkah 3 — Pembagian data

TIGA CARA MEMBAGI, DAN KAPAN MASING-MASING BENAR

- A. ACAK (random split)**
 Kapan benar : baris saling independen, tidak ada urutan waktu yang relevan pada saat penggunaan
 Bahaya : melebih-lebihkan kinerja bila ada tren waktu
- B. BERBASIS WAKTU (time-based split)**
 Latih pada bulan 1–9, uji pada bulan 10–12
 Kapan benar : model akan dipakai pada data MASA DEPAN — yaitu hampir selalu, dalam bisnis
 Manfaat : satu-satunya cara mendeteksi bahwa pola bergeser (Bab 14)
- C. BERBASIS KELOMPOK (group split)**
 Seluruh baris satu pelanggan berada di sisi yang sama
 Kapan benar : ada beberapa baris per entitas

KOMBINASI YANG PALING SERING BENAR DALAM PRAKTIK:
 berbasis waktu untuk test, berbasis kelompok untuk validasi.

Kode — tiga pembagian, dengan penjelasan tiap baris

```
from sklearn.model_selection import train_test_split, GroupShuffleSplit

# A. ACAK, dengan stratifikasi agar proporsi churn sama di kedua sisi
Xtr, Xte, ytr, yte = train_test_split(
```

```

X, y,
test_size=0.30,      # 30% untuk uji
random_state=42,     # agar hasil dapat direproduksi
stratify=y)          # proporsi kelas dipertahankan

# B. BERBASIS WAKTU – tidak ada pengacakan sama sekali
batas = df['bulan_snapshot'] <= 9
Xtr, ytr = X[batas], y[batas]      # bulan 1-9 : latih
Xte, yte = X[~batas], y[~batas]   # bulan 10-12: uji

# C. BERBASIS KELOMPOK – satu pelanggan tidak boleh berada di dua sisi
gss = GroupShuffleSplit(n_splits=1, test_size=0.30, random_state=42)
itr, ite = next(gss.split(X, y, groups=df['customer_id']))
Xtr, Xte = X.iloc[itr], X.iloc[ite]

```

■ TECHNICAL NOTE — mengapa tiga bagian, bukan dua

Pembagian train/test saja tidak cukup begitu kita mulai memilih di antara beberapa model atau menyetel hyperparameter. Setiap kali keputusan diambil berdasarkan data uji, data uji berhenti menjadi uji dan berubah menjadi bagian dari proses pelatihan.

TRAIN	melatih parameter model
VALIDATION	memilih model dan hyperparameter
TEST	DIBUKA SATU KALI, di akhir, untuk melaporkan kinerja

Dalam praktik, cross-validation pada bagian train sering menggantikan validation set terpisah, dan itu sah. Yang tidak sah adalah melihat data uji berkali-kali lalu melaporkan angka terbaiknya.

Gejala pelanggaran ini mudah dikenali: model yang "sudah dicoba lima belas konfigurasi" dan dilaporkan dengan angka uji terbaik akan menunjukkan kinerja lebih rendah di produksi — persis pola multiple testing tanpa koreksi dari Vol 4 Bab 5, hanya berpindah konteks.

Langkah 4 — Baseline

Model tanpa baseline tidak dapat dinilai. Angka AUC 0,80 tidak bermakna apa pun sampai diketahui berapa yang dicapai aturan yang sudah dipakai bisnis hari ini.

Kode – empat baseline wajib

```

import numpy as np
from sklearn.metrics import roc_auc_score, accuracy_score, brier_score_loss

# 1. Kelas mayoritas – semua diprediksi "tidak churn"
p1 = np.full(len(yte), ytr.mean())      # prediksi = prevalensi latih
print(f"mayoritas : akurasi {max(1-yte.mean(), yte.mean()):.4f} | "
      f"AUC 0.5000 | Brier {brier_score_loss(yte, p1):.4f}")

# 2. Aturan bisnis yang dipakai hari ini: "tidak belanja > 90 hari"
p2 = (Xte['recency_hari'] > 90).astype(float)
print(f"recency>90 : AUC {roc_auc_score(yte, p2):.4f}")

# 3. Satu fitur terbaik saja
# 4. Regresi logistik – baseline model, bukan baseline aturan

```

Output – seluruh tangga baseline sampai model akhir

Pendekatan	AUC	Catatan
tebak kelas mayoritas	0.5000	akurasi 55,8%
aturan "recency > 90 hari"	0.6186	dipakai bisnis hari ini
satu fitur: recency	0.6817	model, satu kolom
RFM dasar (3 kolom)	0.7662	◀ 81% dari total kenaikan
+ sinyal layanan	0.7838	
+ loyalitas & keteraturan	0.7990	
+ kategorikal	0.7999	
regresi logistik (semua fitur)	0.8007	◀ TERBAIK
XGBoost (semua fitur)	0.8000	

◆ BUSINESS INSIGHT — tangga baseline mengubah percakapan anggaran

Tangga di atas menyampaikan sesuatu yang tidak dapat disampaikan satu angka AUC: **di mana nilai sebenarnya berada.**

Dari 0,6186 (aturan yang dipakai hari ini) ke 0,8007 (model terbaik), kenaikannya 0,1821. Dari jumlah itu, **0,1476 — atau 81% — sudah diperoleh hanya dengan tiga kolom RFM.** Seluruh sisa pekerjaan, seluruh fitur tambahan, dan seluruh kecanggihan algoritma menyumbang 19% sisanya.

Bagi seorang manajer analytics, ini adalah informasi alokasi sumber daya yang langsung dapat dipakai: proyek model dapat memberikan sebagian besar nilainya dalam dua minggu, bukan dua kuartal. Sisa waktunya lebih baik dipakai untuk hal yang lebih menentukan — ambang keputusan (Bab 9) dan pengukuran uplift (Bab 10).

Kesalahan umum

✗ COMMON MISTAKE — praproses sebelum membagi data

Gejala: kode yang memanggil `StandardScaler().fit_transform(X)` pada seluruh data, lalu membaginya.

Mengapa merusak: rata-rata dan simpangan baku dihitung dari data uji juga, sehingga informasi dari data uji merembes ke pelatihan. Efeknya biasanya kecil pada scaling (0,001–0,005 AUC), tetapi bisa besar pada imputasi dan sangat besar pada seleksi fitur.

Perbaikan: bungkus seluruh praproses dalam `Pipeline` sehingga `fit` hanya pernah menyentuh data latih:

```
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer

pre = ColumnTransformer([
    ('num', StandardScaler(), KOLOM_NUMERIK),
    ('cat', OneHotEncoder(drop='first', handle_unknown='ignore'), KOLOM_KATEGORI)])

model = Pipeline([('pre', pre), ('m', LogisticRegression(max_iter=2000))])
model.fit(Xtr, ytr)      # seluruh praproses dipelajari HANYA dari Xtr
```

Cara senior menghindarinya: menetapkan aturan tim bahwa tidak ada `fit_transform` di luar `Pipeline`. Aturan yang sederhana dan dapat ditegakkan lewat code review jauh lebih efektif daripada kewaspadaan.

✗ COMMON MISTAKE — memakai akurasi pada masalah tak seimbang

Gejala: "model kami akurat 98,2%" pada deteksi penyalahgunaan promo yang prevalensinya 1,85%.

Mengapa merusak: menebak "tidak ada penyalahgunaan" untuk semua orang memberi akurasi 98,15%. Model dengan akurasi 98,2% praktis tidak menambah apa pun. Pada dataset ini, model dengan ambang default menemukan **19 dari 1.110** kasus — akurasinya 98,16%, recall-nya 1,7%.

Perbaikan: pada kelas tak seimbang, gunakan PR-AUC dan metrik biaya, bukan akurasi (Bab 8).

Checklist anatomi proyek ML

- ✓ Definisi target tertulis lengkap: unit, peristiwa, jendela, populasi, kasus tepi
- ✓ Jendela label disesuaikan dengan waktu kerja tindakan, dan dikunci
- ✓ Garis waktu digambar; setiap fitur diperiksa terhadap tanggal snapshot
- ✓ Uji fitur tunggal dijalankan; tidak ada fitur dengan AUC sendirian $> 0,85$
- ✓ Uji lompatan dijalankan; kenaikan $> 0,05$ dari satu fitur diselidiki
- ✓ Pembagian data dipilih dengan alasan tertulis (acak / waktu / kelompok)
- ✓ Data uji dibuka satu kali saja, di akhir
- ✓ Seluruh praproses berada di dalam Pipeline
- ✓ Tangga baseline lengkap dibuat, termasuk aturan bisnis yang berlaku hari ini
- ✓ Metrik dipilih sesuai keseimbangan kelas dan biaya kesalahan

Ending Card — Bab 2

What you learned

Urutan kerja delapan langkah dan mengapa pemodelan adalah langkah yang paling sedikit menentukan; enam komponen definisi target dan mengapa jendela label adalah keputusan bisnis; garis waktu yang sah dan aturan tunggal yang mencegah kebocoran; demonstrasi kebocoran yang menaikkan AUC dari 0,8000 ke 0,9245; enam bentuk kebocoran data dan cara mendeteksi masing-masing; tiga pemeriksaan praktis (fitur tunggal, tanggal, lompatan); tiga cara membagi data dan kapan masing-masing benar; mengapa dibutuhkan tiga bagian bukan dua; tangga baseline lengkap yang menunjukkan 81% kenaikan berasal dari tiga kolom RFM; serta dua kesalahan umum yang paling sering lolos review.

Skills mastered

Definisi target · perancangan split · deteksi kebocoran data · pembangunan tangga baseline · penggunaan Pipeline yang benar.

Real business value

Mendeteksi satu kebocoran sebelum peluncuran menghemat seluruh biaya proyek plus biaya kepercayaan yang jauh lebih mahal untuk dipulihkan. Dan tangga baseline menunjukkan bahwa 81% nilai model dapat diperoleh dalam dua minggu — informasi yang mengubah rencana kuartal tim analytics.

Interview readiness

● INTERVIEW QUESTIONS

1. "Apa itu kebocoran data dan bagaimana kamu mendeteksinya?" — sebutkan bentuknya dan tiga pemeriksaan; beri contoh angka.
2. "AUC model kamu 0,95. Apa yang kamu periksa pertama?" — kebocoran; jelaskan uji lompatan dan uji fitur tunggal.
3. "Kapan kamu memakai time-based split?" — hampir selalu untuk model produksi; jelaskan alasannya.
4. "Berapa banyak kamu melihat data uji?" — satu kali; jelaskan hubungannya dengan multiple testing.
5. "Baseline apa yang kamu pakai?" — aturan bisnis yang berlaku hari ini, bukan tebakan acak.
6. "Mengapa scaling harus di dalam Pipeline?" — mencegah kebocoran praproses; jelaskan besaran efeknya.

Exercises

Exercise 2.1 (Beginner · 40 menit)

Objective: audit kebocoran

Berikut sepuluh kolom yang diusulkan untuk model prediksi gagal bayar B2B, dengan snapshot pada akhir bulan dan label diamati 90 hari kemudian. Tentukan mana yang bocor dan mengapa:

(a) rata-rata hari keterlambatan pembayaran 12 bulan terakhir; (b) status kredit saat ini; (c) jumlah tagihan tertunggak hari ini; (d) tanggal penagihan terakhir; (e) limit kredit pada akhir bulan snapshot; (f) skor risiko internal (dihitung ulang tiap malam); (g) jumlah karyawan perusahaan klien; (h) catatan hasil kunjungan penagihan; (i) rasio pembayaran tepat waktu 12 bulan terakhir; (j) segmen "watchlist" (ditetapkan tim risiko).

Answer key 2.1

Bersih: (a) agregat historis dengan batas waktu jelas ✓; (e) nilai pada tanggal snapshot ✓; (g) atribut yang jarang berubah ✓; (i) sama dengan (a) ✓.

Bocor: (b) "saat ini" berarti nilai hari ini, bukan pada snapshot — bocor kecuali ada versi historisnya; (c) "hari ini" — sama; (d) tanggal penagihan terakhir kemungkinan besar terjadi *karena* gagal bayar — bocor kuat; (f) dihitung ulang tiap malam, sehingga versi yang tersimpan mencerminkan masa depan — bocor, dan ini bentuk paling licin karena namanya terdengar sah; (h) kunjungan penagihan terjadi setelah masalah muncul — bocor kuat; (j) watchlist ditetapkan setelah tim risiko melihat gejala — bocor, dan sering juga merupakan proxy target.

Pelajaran: enam dari sepuluh kolom bocor, dan empat di antaranya memiliki nama yang terdengar seperti fitur yang sah. Kata-kata yang harus memicu kecurigaan: "saat ini", "terakhir", "dihitung ulang", dan nama segmen yang ditetapkan manusia.

Exercise 2.2 (Intermediate · 70 menit)

Objective: membangun tangga baseline

Dengan dataset TokoNusa, bangun tangga baseline lengkap untuk target `churn_180h`: (a) kelas mayoritas; (b) tiga aturan bisnis berbeda yang masuk akal; (c) model satu fitur untuk lima fitur teratas; (d) regresi logistik dengan RFM saja; (e) model penuh. Sajikan sebagai satu tabel dengan AUC dan satu metrik bisnis. (f) Tuliskan satu paragraf rekomendasi: berapa banyak pekerjaan tambahan yang layak setelah RFM?

Answer key 2.2

(b) Tiga aturan yang layak diuji: $\text{recency} > 90$ hari (AUC 0,6186); frekuensi ≤ 2 dalam 12 bulan; kombinasi "recency > 60 DAN frekuensi ≤ 3 ". Aturan gabungan biasanya lebih baik daripada aturan tunggal, dan penting untuk diuji karena itulah yang sebenarnya dipakai tim CRM.

(c) Model satu fitur: recency 0,6817 adalah yang tertinggi. Tidak ada fitur yang melampaui 0,85 — sehat.

(d) RFM saja: 0,7662. (e) Penuh: 0,8007.

(f) Rekomendasi yang kuat menyebut angka: dari aturan yang berlaku hari ini (0,6186) ke RFM (0,7662) diperoleh 0,1476 AUC dengan tiga kolom; dari RFM ke model penuh hanya 0,0345 lagi dengan enam belas kolom tambahan. Kesimpulannya: bangun versi RFM lebih dulu dan luncurkan; alihkan usaha berikutnya ke ambang keputusan dan pengukuran uplift, bukan ke fitur tambahan. Menyertakan *apan berhenti menyempurnakan model* adalah bagian dari jawaban yang membedakan pekerjaan senior.

Exercise 2.3 (Advanced · 2 jam)

Objective: merancang split yang benar untuk kasus sulit

Rancang strategi pembagian data untuk empat kasus, dengan alasan tertulis: (a) model churn pelanggan dengan snapshot bulanan selama 24 bulan (satu pelanggan muncul berkali-kali); (b) peramalan permintaan harian per SKU; (c) deteksi penyalahgunaan promo di mana kasus positif berkelompok dalam waktu; (d) model prediksi keterlambatan pengiriman di mana ada perubahan penyedia logistik pada bulan ke-18.

Answer key 2.3 — kerangka jawaban

(a) **Kombinasi waktu dan kelompok**: uji pada bulan-bulan terakhir, dan pastikan satu pelanggan tidak muncul di kedua sisi pada periode yang sama. Split acak murni akan sangat melebih-lebihkan kinerja karena baris pelanggan yang sama sangat mirip.

(b) **Berbasis waktu, dengan validasi bergulir** (rolling origin): latih pada $1..t$, uji pada $t+1..t+h$, geser, ulangi. Split acak pada deret waktu adalah kesalahan serius karena memakai masa depan untuk memprediksi masa lalu.

(c) **Berbasis waktu dengan jeda (embargo)**: karena kasus positif berkelompok, blok waktu di sekitar batas split harus dibuang agar kejadian yang sama tidak muncul di dua sisi.

(d) **Berbasis waktu, dengan uji HANYA pada periode setelah perubahan penyedia**. Ini kasus paling penting: melatih pada data sebelum perubahan lalu menguji secara acak akan menghasilkan angka yang tidak berarti, karena proses yang menghasilkan data sudah berbeda. Bila periode setelah perubahan terlalu pendek, jawaban yang benar adalah *menunda proyek* sampai datanya cukup — bukan memaksakan model. Ini penerapan langsung dari syarat keempat kelayakan di Bab 1.

Portfolio idea

★ PORTFOLIO TIP

Notebook yang *menemukan dan mendokumentasikan kebocoran* pada dataset publik jauh lebih berkesan daripada notebook dengan AUC tinggi. Tunjukkan model bocor, jelaskan gejalanya, perbaiki, dan laporkan penurunan AUC sebagai keberhasilan — karena memang begitulah.

Further reading

Kaufman, Rosset & Perlich, "Leakage in Data Mining" — rujukan utama tentang kebocoran · Dokumentasi scikit-learn tentang *common pitfalls* dan *Pipeline* · Vol 4 Bab 5 (multiple testing) buku ini.

Next chapter

Bab 3 — feature engineering: dari data mentah ke fitur yang sah secara waktu. Termasuk temuan yang mengejutkan pada dataset ini — fitur turunan yang biasanya diandalkan ternyata tidak menambah apa pun.

Bab 3 — Feature Engineering

Dari data mentah ke fitur yang sah secara waktu — dan berapa nilainya sebenarnya

Learning objectives	Membangun fitur dari data transaksional dengan batas waktu yang benar; menerapkan point-in-time correctness; memilih strategi penanganan nilai hilang berdasarkan mekanismenya; melakukan encoding kategorikal tanpa kebocoran; menilai kontribusi setiap kelompok fitur secara kuantitatif; mengetahui kapan berhenti menambah fitur
Prerequisites	Bab 2; Vol 1 Bab 5 (SQL agregasi) dan Bab 6 (kualitas data, nilai hilang)
Estimasi waktu	Baca 2,5 jam · Praktik 5 jam
Difficulty	● Intermediate
Skills covered	Feature engineering, point-in-time correctness, imputasi, encoding kategorikal, ablation study
Business domain	Retail omnichannel — membangun tabel fitur pelanggan TokoNusa

WHY — mengapa fitur lebih menentukan daripada algoritma

Kalimat "fitur lebih penting daripada model" sering diucapkan tanpa angka. Volume ini dapat memberi angkanya, karena seluruh percobaan dijalankan pada data yang sama.

Output — kontribusi bertahap tiap kelompok fitur (ablation study, model XGBoost sama)		
Kelompok fitur yang ditambahkan	AUC	Δ dari langkah
1. hanya recency	0.6817	—
2. + frekuensi, monetary (RFM lengkap)	0.7662	+0.0845
3. + tenure, AOV, ragam kategori	0.7663	+0.0001
4. + sinyal layanan (telat, keluhan, retur)	0.7838	+0.0175
5. + loyalitas, promo, keteraturan	0.7990	+0.0152
6. + kategorikal (kanal, wilayah, metode bayar)	0.7999	+0.0009
7. + fitur turunan (rasio, normalisasi)	0.7997	-0.0002
Perbandingan: mengganti algoritma dari regresi logistik ke XGBoost pada kumpulan fitur yang sama:		-0.0007

◆ BUSINESS INSIGHT — tiga temuan yang mengubah cara mengalokasikan waktu

Pertama, RFM mendominasi. Tiga kolom yang dapat dihitung dengan satu kueri SQL menyumbang 0,0845 dari total kenaikan 0,1182 — yaitu 71%. Sisanya membutuhkan integrasi data layanan, loyalitas, dan komersial.

Kedua, sinyal layanan bernilai nyata. Menambahkan data keterlambatan, keluhan, dan retur menyumbang 0,0175 — dua puluh lima kali lebih besar daripada mengganti algoritma. Bila ada satu proyek integrasi data yang layak diperjuangkan, ini kandidatnya.

Ketiga, fitur turunan tidak menambah apa pun. Rasio frekuensi per bulan, recency relatif terhadap jarak pembelian normal, keterlambatan per order — seluruhnya masuk akal secara bisnis dan seluruhnya memberi $-0,0002$. Penyebabnya: model berbasis pohon dapat menemukan pembagian itu sendiri bila memang berguna.

Kesimpulan alokasi waktu: *satu hari untuk RFM, satu minggu untuk integrasi sinyal layanan, dan nol hari untuk rasio kreatif.*

■ TECHNICAL NOTE — kapan fitur turunan TETAP berguna

Temuan $-0,0002$ di atas berlaku untuk model berbasis pohon. Pada model linear, kesimpulannya berbeda secara mendasar.

Regresi logistik tidak dapat menemukan bahwa yang penting adalah *rasio* dua kolom; ia hanya dapat menjumlahkan kontribusi masing-masing. Bila hubungan sebenarnya berbentuk rasio, interaksi, atau ambang, fitur turunan adalah satu-satunya cara memberi tahu model linear tentang hal itu.

Aturan praktisnya: **fitur turunan adalah cara memindahkan pengetahuan domain ke dalam model yang tidak dapat menemukannya sendiri.** Pada boosting, sebagian besar sudah ditemukan sendiri; pada model linear, ia menentukan. Bab 6 menunjukkan kuantifikasinya — pada target dengan interaksi, selisih antara keduanya mencapai 0,1414 AUC.

WHAT — anatomi tabel fitur

TABEL FITUR (feature table) — satu baris per unit per snapshot

kunci : customer_id + tanggal_snapshot
fitur : dihitung HANYA dari data sebelum tanggal_snapshot
label : diamati SETELAH tanggal_snapshot

EMPAT KELOMPOK FITUR YANG HAMPIR SELALU ADA

1. AGREGAT PERILAKU : jumlah, rata-rata, maksimum atas jendela waktu: 30 / 90 / 365 hari
2. RESENSI & RITME : hari sejak peristiwa terakhir, keteraturan jarak antar peristiwa
3. ATRIBUT STATIS : wilayah, kanal utama, tenure, segmen
4. SINYAL NEGATIF : keluhan, retur, keterlambatan, pembatalan — sering paling bernilai dan paling sering terlupakan karena berada di sistem yang berbeda

SQL — tabel fitur dengan batas waktu eksplisit (point-in-time)

-- Setiap agregat DIBATASI oleh tanggal snapshot.
-- Tanpa baris WHERE ini, fitur akan memuat masa depan.

```

WITH snapshot AS (
    SELECT '2026-01-31'::date AS tgl
),
trx AS (
    SELECT t.customer_id, t.tanggal, t.nilai, t.kategori
    FROM transaksi t, snapshot s
    WHERE t.tanggal <= s.tgl -- < batas waktu
    AND t.tanggal > s.tgl - INTERVAL '365 day' -- jendela 12 bln
),
agg AS (
    SELECT customer_id,
        COUNT(*) AS frekuensi_12bln,
        SUM(nilai) AS monetary_12bln,
        AVG(nilai) AS aov,
        COUNT(DISTINCT kategori) AS n_kategori,
        MAX(tanggal) AS tgl_terakhir,
        -- keteraturan: 1 - (SD jarak / rata-rata jarak), dibatasi 0..1
        STDDEV(EXTRACT(epoch FROM tanggal)/86400) AS sd_hari
    FROM trx
    GROUP BY customer_id
)
SELECT a.customer_id,
    s.tgl AS tanggal_snapshot,
    a.frekuensi_12bln, a.monetary_12bln, a.aov, a.n_kategori,
    (s.tgl - a.tgl_terakhir) AS recency_hari
FROM agg a, snapshot s;

```

⚠ WARNING — point-in-time correctness adalah sumber kebocoran paling halus

Kueri di atas terlihat berlebihan sampai kamu melihat versi yang salah, yang jauh lebih sering ditulis:

```

SELECT customer_id, COUNT(*) AS frekuensi_12bln
FROM transaksi
WHERE tanggal > CURRENT_DATE - INTERVAL '365 day' -- < SALAH
GROUP BY customer_id

```

Perbedaannya satu kata: `CURRENT_DATE` alih-alih tanggal snapshot. Akibatnya, fitur untuk snapshot Januari dihitung dari data sampai hari ini — termasuk seluruh periode label.

Kesalahan ini tidak menghasilkan pesan error, tidak terlihat pada pemeriksaan data, dan menghasilkan model yang tampak bagus. Ia hanya terdeteksi bila seseorang membaca kuerinya dengan pertanyaan yang benar.

Pertahanan yang bekerja: jadikan tanggal snapshot sebagai parameter wajib pada setiap fungsi pembangun fitur, sehingga tidak mungkin menulis kueri tanpa menyebutkannya. Yang dicegah bukan kesalahan, melainkan *kemungkinan* membuat kesalahan.

HOW — nilai hilang

Volume 1 Bab 6 memperkenalkan tiga mekanisme nilai hilang. Di sini kita mengukur konsekuensinya terhadap model.

Mekanisme	Arti	Contoh di TokoNusa
MCAR	Hilang secara acak, tidak berkaitan dengan apa pun	Kegagalan pencatatan sistem selama dua jam
MAR		

	Hilang bergantung pada variabel lain yang <i>teramati</i>	Recency hilang lebih sering pada pelanggan berfrekuensi rendah
MNAR	Hilang bergantung pada nilai yang hilang itu sendiri, atau pada label	Data hilang lebih sering pada pelanggan yang sedang berhenti

Output – kasus MAR: recency hilang 13,7%, bergantung pada frekuensi

Strategi	AUC
buang kedua kolom	0.7941
imputasi rata-rata	0.7941
imputasi median	0.7937
imputasi median + penanda hilang	0.7938
imputasi iteratif (berbasis model)	0.7939
imputasi iteratif + penanda hilang	0.7940
XGBoost menangani NaN sendiri	0.7941

Selisih terbesar antar strategi: 0,0004 AUC.

◆ BUSINESS INSIGHT — pada kasus MAR, pilihan metode imputasi hampir tidak penting

Tujuh strategi, selisih 0,0004. Ini temuan yang membebaskan, dan bertentangan dengan banyak diskusi tentang imputasi yang menghabiskan waktu tim.

Penyebabnya dapat dijelaskan: ketika mekanismenya MAR, informasi yang hilang *masih ada di kolom lain*. Recency yang hilang bergantung pada frekuensi, dan frekuensi ada di dalam model. Imputasi secanggih apa pun hanya merekonstruksi informasi yang sudah tersedia.

Rekomendasi praktis: **gunakan median untuk numerik, kategori "tidak diketahui" untuk kategorikal, dan berhenti di situ** — kecuali kasusnya MNAR.

Output – kasus MNAR: recency hilang 39,8% pada churner, 5,1% pada non-churner

Strategi	AUC
imputasi median saja	0.8520
imputasi median + PENANDA hilang	0.8543
XGBoost menangani NaN sendiri	0.8543

Bandingkan model bersih tanpa nilai hilang: 0.8000

⚠ WARNING — AUC yang naik karena nilai hilang adalah gejala, bukan prestasi

Perhatikan angka yang mengganggu: model dengan 39,8% data hilang mencapai AUC 0,8543 — *lebih tinggi* daripada model dengan data lengkap (0,8000).

Ini terjadi karena pola kehilangannya sendiri mengandung informasi tentang label. Model belajar "bila recency tidak tercatat, pelanggan ini kemungkinan besar churn" — yang benar dalam data historis, dan berbahaya dalam produksi.

Pertanyaannya selalu sama: **apakah pola kehilangan ini akan berlaku pada saat inferensi?** Bila data hilang karena akun sudah nonaktif, maka pada saat kita *harus* memberi skor kepada pelanggan yang masih aktif, kolomnya tidak akan hilang — dan kemampuan itu menguap. Ini adalah kebocoran data (Bab 2) yang menyamar sebagai masalah kualitas data.

Ketika MNAR terdeteksi, urutan yang benar adalah: cari tahu *mengapa* data hilang, perbaiki di sumbernya bila mungkin, dan bila tidak, uji model pada periode terpisah untuk melihat apakah kemampuannya bertahan.

HOW — encoding variabel kategorikal

Metode	Cara kerja	Kapan dipakai
One-hot	Satu kolom biner per kategori	Default. Aman. Kardinalitas rendah (< 30 kategori)
Ordinal	Kategori diganti angka berurutan	Hanya bila urutannya bermakna (kecil/sedang/besar)
Target encoding	Kategori diganti rata-rata target	Kardinalitas tinggi — <i>hanya</i> dengan cross-fitting yang benar
Frequency encoding	Kategori diganti frekuensi kemunculannya	Kardinalitas tinggi, aman, tidak memakai label
Native (LightGBM/CatBoost)	Algoritma menangani kategorikal langsung	Kardinalitas tinggi; sering pilihan terbaik

Output — target encoding pada kolom acak murni (tidak memuat informasi apa pun)

Kategori	Baris per kategori	Encoding dari SELURUH data		Encoding dari TRAIN saja	
		AUC train	AUC test	AUC train	AUC test
800	250	0.7798	0.7634	0.7804	0.7598
20.000	10	0.8168	0.8060	0.8332	0.6907
50.000	4	0.8691	0.8654	0.8987	0.6009

Pembanding tanpa kolom kode sama sekali: AUC test 0.7648

✗ COMMON MISTAKE — target encoding tanpa cross-fitting

Gejala: kolom berkardinalitas tinggi (kode pos, ID produk, ID toko) di-encode dengan rata-rata target dari seluruh data, lalu AUC melonjak.

Mengapa merusak: tabel di atas memakai kolom yang isinya *angka acak murni* — tidak memuat informasi apa pun tentang churn. Dengan 4 baris per kategori, encoding dari seluruh data menghasilkan AUC uji 0,8654, jauh di atas baseline 0,7648. Seluruh kelebihan itu palsu: nilai encoding untuk baris uji dihitung dari label baris uji itu sendiri.

Yang lebih halus: versi yang "benar" (encoding hanya dari train) menghasilkan AUC train 0,8987 dan test 0,6009 — *lebih buruk* daripada tidak memakai kolom itu sama sekali. Ia jujur, tetapi tetap merusak karena overfitting berat.

Perbaikan: gunakan cross-fitting (hitung encoding untuk tiap fold dari fold lainnya) dengan smoothing terhadap rata-rata global, atau lebih sederhana: pakai frequency encoding atau algoritma yang menangani kategorikal secara native.

Cara senior menghindarinya: memeriksa rasio baris per kategori sebelum memilih metode. Di bawah 50 baris per kategori, target encoding hampir selalu lebih merugikan daripada menolong.

BEST PRACTICE — urutan kerja feature engineering

1. MULAI DARI RFM. Selalu. Tiga kolom, satu kueri.
Ukur AUC-nya. Itu baseline fitur.
2. TAMBAHKAN SATU KELOMPOK, UKUR, CATAT.
Ablation study bukan pekerjaan tambahan — ia satu-satunya cara mengetahui apakah proyek integrasi data berikutnya layak dikerjakan.
3. PRIORITASKAN SINYAL NEGATIF.
Keluhan, retur, keterlambatan, pembatalan. Biasanya berada di sistem lain dan biasanya bernilai (+0,0175 di sini).
4. JANGAN MEMBUAT RASIO UNTUK MODEL POHON.
Buat rasio hanya untuk model linear, atau ketika rasio itu sendiri yang dipakai manusia untuk mengambil keputusan.
5. UKUR BIAYA PEMELIHARAAN SETIAP FITUR.
Fitur yang bergantung pada sistem yang sering berubah adalah utang teknis. Bila kontribusinya 0,0009, buang.
6. KUNCI DEFINISI FITUR DI SATU TEMPAT.
Definisi yang berbeda antara pelatihan dan inferensi adalah penyebab kegagalan produksi nomor satu setelah kebocoran.

■ TECHNICAL NOTE — training/serving skew

Kegagalan yang paling sulit didiagnosis dalam ML produksi bukan model yang buruk, melainkan *fitur yang dihitung berbeda* di dua tempat.

Contoh nyata yang berulang: saat pelatihan, `recency_hari` dihitung dengan SQL sebagai selisih tanggal; saat inferensi, ia dihitung dengan Python sebagai selisih timestamp — dan menghasilkan nilai yang tergeser satu hari, atau memakai zona waktu berbeda. Model tetap berjalan, tidak ada error, dan kinerjanya turun tanpa penjelasan.

Tiga pertahanan, berurutan dari yang paling murah: **(1)** satu fungsi pembangun fitur yang dipakai oleh kedua jalur; **(2)** pengujian yang membandingkan fitur pelatihan dan fitur inferensi untuk sekelompok unit yang sama; **(3)** feature store bila skalanya membenarkan biayanya.

Pertahanan nomor 2 murah dan menangkap sebagian besar kasus. Ia layak dipasang bahkan pada proyek kecil.

Checklist feature engineering

- ✓ Tanggal snapshot menjadi parameter wajib pada setiap fungsi pembangun fitur
- ✓ Semua agregat memiliki batas waktu eksplisit; tidak ada `CURRENT_DATE`
- ✓ Ablation study dijalankan per kelompok fitur, hasilnya dicatat
- ✓ Sinyal negatif (keluhan, retur, keterlambatan) dicari secara aktif di sistem lain
- ✓ Mekanisme nilai hilang diidentifikasi sebelum memilih strategi imputasi
- ✓ Kasus MNAR diselidiki sebagai kemungkinan kebocoran, bukan hanya masalah kualitas
- ✓ Rasio baris per kategori diperiksa sebelum memilih metode encoding
- ✓ Target encoding hanya dipakai dengan cross-fitting dan smoothing
- ✓ Fitur dengan kontribusi di bawah ambang dibuang, dengan biaya pemeliharaan sebagai pertimbangan
- ✓ Definisi fitur dikunci di satu tempat; kesesuaian pelatihan-inferensi diuji

Ending Card — Bab 3

What you learned

Ablation study yang menunjukkan RFM menyumbang 71% kenaikan sementara mengganti algoritma menyumbang $-0,0007$; mengapa fitur turunan tidak menolong model pohon tetapi menentukan pada model linear; anatomi tabel fitur dan empat kelompok fitur yang hampir selalu ada; SQL point-in-time dengan batas waktu eksplisit dan versi salahnya yang hanya berbeda satu kata; tiga mekanisme nilai hilang dan pengukuran konsekuensinya — MAR membuat pilihan imputasi hampir tidak penting (selisih $0,0004$), MNAR menaikkan AUC secara palsu dari $0,8000$ ke $0,8543$; lima metode encoding kategorikal dan demonstrasi bahwa target encoding pada kolom acak murni dapat menghasilkan AUC $0,8654$; serta enam langkah urutan kerja dan pertahanan terhadap training/serving skew.

Skills mastered

Pembangunan tabel fitur point-in-time · ablation study · pemilihan strategi imputasi berdasarkan mekanisme · encoding kategorikal tanpa kebocoran · pencegahan training/serving skew.

Real business value

Ablation study mengubah percakapan integrasi data dari opini menjadi angka: integrasi sinyal layanan bernilai $+0,0175$ AUC, sementara enam belas fitur turunan bernilai $-0,0002$. Itu adalah dasar yang dapat dipertahankan untuk memutuskan proyek data mana yang dibiayai kuartal depan.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagaimana kamu memastikan fitur tidak memuat masa depan?" — tanggal snapshot sebagai parameter wajib; tunjukkan versi SQL yang benar dan yang salah.
2. "Metode imputasi apa yang kamu pakai?" — tanyakan mekanismenya dulu; pada MAR pilihannya hampir tidak penting.
3. "AUC naik setelah kami menambahkan data yang banyak kosongnya. Bagus?" — curigai MNAR sebagai kebocoran.
4. "Bagaimana kamu meng-encode kolom dengan 50.000 kategori?" — frequency encoding atau native; target encoding hanya dengan cross-fitting.
5. "Berapa fitur yang ideal?" — sebanyak yang kontribusinya melebihi biaya pemeliharannya; tunjukkan ablation study.
6. "Model bagus saat latih, buruk di produksi, dan datanya sama. Apa dugaanmu?" — training/serving skew.

Exercises

Exercise 3.1 (Beginner · 45 menit)

Objective: menulis SQL point-in-time

Tulis kueri yang menghasilkan tabel fitur untuk model prediksi keterlambatan pengiriman, dengan snapshot pada saat order dibuat. Fitur yang diminta: jumlah order kurir tersebut dalam 7 hari terakhir, rata-rata waktu kirim kurir tersebut dalam 30 hari terakhir, jumlah keterlambatan kurir tersebut dalam 90 hari terakhir, dan beban gudang pada hari order.

(a) Tulis kuerinya. (b) Tandai baris mana yang mencegah kebocoran. (c) Fitur mana yang paling berisiko dihitung salah saat inferensi, dan mengapa?

Answer key 3.1

(a) Kunci strukturnya: setiap agregat memakai `WHERE tanggal < o.tanggal_order` — bukan `<=`, karena order yang sedang diprediksi tidak boleh ikut menghitung. Ini kesalahan satu karakter yang sering terjadi.

(b) Baris pencegah kebocoran: batas atas (`< tanggal_order`) dan batas bawah jendela pada setiap agregat kurir; serta pastikan "beban gudang pada hari order" memakai beban *pada saat order masuk*, bukan total beban hari itu — total hari itu memuat order yang datang setelahnya.

(c) Yang paling berisiko adalah **beban gudang**. Saat pelatihan ia mudah dihitung dari data historis lengkap; saat inferensi, order masih terus berdatangan sehingga nilainya berubah tergantung kapan model dipanggil. Ini contoh klasik training/serving skew, dan penanganannya adalah mendefinisikan fitur itu sebagai "beban gudang pada jam sebelumnya" — nilai yang stabil dan dapat direproduksi di kedua jalur.

Exercise 3.2 (Intermediate · 90 menit)

Objective: ablation study lengkap

Dengan dataset TokoNusa, jalankan ablation study kamu sendiri untuk target `belanja_90h` (regresi). Kelompokkan fitur menjadi minimal lima kelompok, tambahkan bertahap, dan catat MAE serta R^2 pada setiap langkah.

(a) Buat tabelnya. (b) Kelompok mana yang paling bernilai? (c) Bandingkan urutan kepentingannya dengan hasil pada target churn — apakah sama? (d) Apa implikasinya untuk prioritas integrasi data?

Answer key 3.2

(c) Ini bagian terpenting dari latihan. Untuk churn, sinyal layanan bernilai tinggi; untuk nilai belanja, fitur monetary dan frekuensi mendominasi jauh lebih kuat dan sinyal layanan hampir tidak menambah apa pun. **Kepentingan fitur bergantung pada target, bukan pada datanya.**

(d) Implikasi praktis: pertanyaan "data apa yang paling berharga untuk dikumpulkan" tidak memiliki jawaban tunggal. Jawabannya harus dinyatakan per keputusan. Jawaban yang kuat menyusun matriks kecil: baris = kelompok data, kolom = model/keputusan yang direncanakan, isi = kontribusi terukur. Matriks itu adalah dasar prioritas data engineering yang jauh lebih baik daripada daftar keinginan.

Exercise 3.3 (Advanced · 2,5 jam)

Objective: menemukan kebocoran point-in-time

Buat versi bocor dari tabel fitur secara sengaja: hitung `frekuensi_12bln` memakai jendela yang berakhir 90 hari *setelah* snapshot (meniru kesalahan `CURRENT_DATE`).

(a) Bangun keduanya dan bandingkan AUC. (b) Rancang satu pemeriksaan otomatis yang akan menangkap kesalahan ini pada pipeline nyata. (c) Rancang pemeriksaan kedua yang menangkapnya bahkan bila kode SQL-nya tidak dapat dibaca (misalnya berasal dari sistem lain).

Answer key 3.3 — kerangka jawaban

(b) Pemeriksaan berbasis kode: uji unit yang memanggil fungsi pembangun fitur dua kali untuk snapshot yang sama tetapi dengan data yang berisi tambahan transaksi *setelah* snapshot. Bila hasilnya berbeda, ada kebocoran. Uji ini sederhana, cepat, dan menangkap hampir semua kesalahan batas waktu.

(c) Pemeriksaan berbasis data, untuk fitur yang asalnya tidak terlihat: bandingkan distribusi fitur pada dua snapshot yang berdekatan untuk unit yang sama, atau periksa apakah fitur berkorelasi dengan label secara mencurigakan tinggi pada periode di mana secara logis ia belum bisa tahu. Pendekatan lain yang praktis: bekukan salinan data pada tanggal snapshot, lalu bangun ulang fitur dari salinan itu dan bandingkan. Bila nilainya berbeda dari yang ada di tabel fitur, sesuatu memakai data yang lebih baru.

Portfolio idea

★ PORTFOLIO TIP

Ablation study yang disajikan sebagai satu tabel dengan kolom "kontribusi AUC" dan "biaya integrasi (hari kerja)" adalah artefak yang langsung dapat dipakai manajer untuk memutuskan. Ia jauh lebih berkesan daripada daftar fitur, karena ia menjawab pertanyaan yang benar-benar ditanyakan: *apa yang layak dikerjakan berikutnya?*

Further reading

Zheng & Casari, *Feature Engineering for Machine Learning* · Dokumentasi scikit-learn tentang praproses dan `ColumnTransformer` · Little & Rubin, *Statistical Analysis with Missing Data* — rujukan formal untuk MCAR/MAR/MNAR · Vol 1 Bab 5–6 buku ini.

Next chapter

Bab 4 — model pertama: regresi untuk memprediksi angka, regularisasi ridge dan lasso, dan mengapa memilih metrik regresi menentukan model mana yang terlihat menang.

Bab 4 — Regresi dan Regularisasi

Memprediksi angka — dan mengapa pilihan metrik menentukan model mana yang terlihat menang

Learning objectives	Membangun model regresi untuk prediksi nilai bisnis; memilih metrik regresi yang sesuai dengan biaya kesalahan; menerapkan dan menafsirkan ridge dan lasso; mengenali kapan regularisasi menolong dan kapan tidak; menangani target yang miring; menafsirkan koefisien dengan benar
Prerequisites	Bab 2-3; Vol 2 Bab 5 (regresi linear, asumsi, residual)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Intermediate
Skills covered	Regresi, MAE/RMSE/R ² /MAPE/WAPE, ridge, lasso, transformasi target, interpretasi koefisien
Business domain	Retail omnichannel — prediksi nilai belanja 90 hari ke depan

Masalah bisnis

PERTANYAAN

"Berapa nilai belanja setiap pelanggan dalam 90 hari ke depan?"

SIAPA YANG MEMBUTUHKAN

- Merchandising — perencanaan stok per wilayah
- CRM — alokasi anggaran kampanye per segmen
- Keuangan — proyeksi arus kas triwulan (Vol 3 Bab 3)

KEPUTUSAN YANG BERUBAH

Anggaran kampanye per pelanggan dibatasi persentase dari nilai yang diperkirakan. Kesalahan prediksi berbiaya nyata: terlalu tinggi -> belanja marketing terbuang; terlalu rendah -> pelanggan bernilai diabaikan.

CATATAN PENTING

Target ini SANGAT MIRING: banyak pelanggan bernilai kecil, sedikit yang bernilai sangat besar. Kemiringan itu yang membuat pemilihan metrik menjadi keputusan, bukan formalitas.

WHAT — lima metrik regresi dan apa yang masing-masing hargai

Metrik	Rumus dan arti	Menghargai / menghukum
MAE	Rata-rata aktual – prediksi . Dalam satuan asli	Menghukum semua kesalahan secara proporsional. Optimal bila biaya kesalahan linear. Diminimalkan oleh <i>median</i>
RMSE	Akar rata-rata kuadrat kesalahan	Menghukum kesalahan besar jauh lebih keras. Dipilih bila satu kesalahan besar lebih buruk daripada banyak kesalahan kecil. Diminimalkan oleh <i>rata-rata</i>
R²	Proporsi varians yang dijelaskan	Tanpa satuan; berguna untuk perbandingan. Menyesatkan pada target miring karena didominasi ekor

MAPE	Rata-rata $ kesalahan \div \text{aktual}$	Menghukum kesalahan pada nilai kecil secara ekstrem. Tidak terdefinisi bila aktual nol. Hampir selalu keliru untuk data ritel
WAPE	$\sum kesalahan \div \sum \text{aktual}$	MAE dinormalisasi terhadap total. Tanpa satuan, stabil, bermakna bisnis. Default yang baik untuk peramalan permintaan

HOW — membangun model, langkah demi langkah

Kode — dari data ke model, dengan penjelasan tiap bagian

```
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression, Ridge, Lasso
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import xgboost as xgb

df = pd.read_csv('tokonusa_ml.csv')

NUM = ['tenure_bulan', 'frekuensi_12bln', 'recency_hari', 'aov',
       'monetary_12bln', 'n_kategori', 'skor_loyalitas', 'anggota_tier',
       'pernah_terlambat', 'n_keterlambatan', 'n_keluhan', 'retur_rate',
       'promo_rate', 'diskon_rata', 'keteraturan']
CAT = ['kanal', 'wilayah', 'metode_bayar']

X = pd.get_dummies(df[NUM + CAT], columns=CAT, drop_first=True)
y = df['belanja_90h']

Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.30, random_state=42)

# Scaling HANYA dipelajari dari data latih (lihat Bab 2)
sc = StandardScaler().fit(Xtr)
Xs = sc.transform(Xtr)
Xts = sc.transform(Xte)

def evaluasi(nama, pred):
    """Menghitung lima metrik sekaligus agar perbandingannya jujur."""
    mae = mean_absolute_error(yte, pred)
    rmse = mean_squared_error(yte, pred) ** 0.5
    r2 = r2_score(yte, pred)
    wape = np.abs(yte - pred).sum() / yte.sum() # MAE / rata-rata aktual
    nz = yte > 0 # MAPE tidak terdefinisi di nol
    mape = (np.abs(yte[nz] - pred[nz]) / yte[nz]).mean()
    print(f"{nama:<22} MAE {mae:>12,.0f} | RMSE {rmse:>12,.0f} | "
          f"R2 {r2:+.4f} | WAPE {wape:.4f} | MAPE {mape:8.2f}")

# BASELINE lebih dulu — selalu (Bab 2)
evaluasi("baseline rata-rata", np.full(len(yte), ytr.mean()))
evaluasi("baseline median", np.full(len(yte), ytr.median()))

evaluasi("linear regression", LinearRegression().fit(Xs, ytr).predict(Xts))
for a in [1.0, 100.0, 10000.0]:
    evaluasi(f"ridge alpha={a:g}", Ridge(alpha=a).fit(Xs, ytr).predict(Xts))
evaluasi("lasso alpha=10000", Lasso(alpha=10000).fit(Xs, ytr).predict(Xts))

xr = xgb.XGBRegressor(n_estimators=400, max_depth=5, learning_rate=0.05,
                      subsample=0.8, colsample_bytree=0.8, random_state=42, n_jobs=-1)
evaluasi("xgboost", xr.fit(Xtr, ytr).predict(Xte))

# Target miring: latih pada log(1+y), lalu kembalikan ke skala asli
```

```
xrl = xgb.XGBRegressor(n_estimators=400, max_depth=5, learning_rate=0.05,
                      subsample=0.8, colsample_bytree=0.8, random_state=42, n_jobs=-1)
xrl.fit(Xtr, np.log1p(ytr))
evaluasi("xgboost target log", np.expml(xrl.predict(Xte)))
```

Output

Model	MAE	RMSE	R2	WAPE	MAPE
baseline rata-rata	270,561	449,759	-0.0000	0.9576	7.60
baseline median	237,019	475,210	-0.1164	0.8388	3.38
linear regression	181,687	317,658	+0.5012	0.6430	4.53
ridge alpha=1	181,687	317,658	+0.5012	0.6430	4.53
ridge alpha=100	181,670	317,644	+0.5012	0.6430	4.53
ridge alpha=10000	183,063	320,039	+0.4937	0.6479	4.61
lasso alpha=10000	181,586	319,045	+0.4968	0.6427	4.65
xgboost	175,699	318,810	+0.4975	0.6218	4.24
xgboost target log	174,262	343,971	+0.4151	0.6167	2.28

◆ BUSINESS INSIGHT — empat model berbeda "menang", tergantung metriknya

Bacalah tabel di atas kolom per kolom, dan perhatikan bahwa pemenangnya berubah:

```
MAE terbaik : xgboost target log (174.262)
RMSE terbaik : linear regression (317.658)
R2 terbaik : linear regression (+0,5012)
WAPE terbaik : xgboost target log (0,6167)
MAPE terbaik : xgboost target log (2,28) — jauh lebih baik
```

Ini bukan keanehan data. Ini konsekuensi langsung dari apa yang dihargai tiap metrik. Transformasi log membuat model memperhatikan pelanggan bernilai kecil (banyak jumlahnya) dan mengabaikan kesalahan besar pada pelanggan bernilai besar — sehingga MAE dan MAPE membaik sementara RMSE memburuk 8,3%.

Kesimpulan yang harus dibawa: **pilih metrik sebelum melihat hasil, dan pilih berdasarkan biaya kesalahan bisnis**. Bila kesalahan pada pelanggan besar berbiaya jauh lebih mahal (perencanaan stok), RMSE benar dan regresi linear menang. Bila setiap rupiah kesalahan sama biayanya (alokasi anggaran per kepala), MAE atau WAPE benar dan model log menang.

Memilih metrik *setelah* melihat hasil adalah bentuk halus dari kecurangan pada diri sendiri, dan setara dengan memilih segmen setelah melihat data (Vol 4 Bab 5).

Membaca baseline dengan benar

■ TECHNICAL NOTE — mengapa baseline median memiliki R² negatif

Baseline median menghasilkan R² = -0,1164. R² negatif berarti prediksi lebih buruk daripada sekadar memakai rata-rata — dan itu benar, karena R² dihitung terhadap rata-rata.

Tetapi perhatikan bahwa baseline median memiliki MAE *lebih baik* (237.019 versus 270.561) dan MAPE jauh lebih baik (3,38 versus 7,60). Ini bukan kontradiksi: **median meminimalkan MAE, rata-rata meminimalkan RMSE dan memaksimalkan R²**.

Konsekuensi praktis yang penting: pada target yang miring, melaporkan R² saja dapat membuat model yang berguna terlihat buruk, dan sebaliknya. Selalu laporkan minimal satu metrik dalam satuan asli (MAE) berdampingan dengan satu metrik relatif (WAPE).

⚠ WARNING — MAPE hampir selalu keliru untuk data ritel

Perhatikan nilai MAPE pada tabel: 7,60 untuk baseline rata-rata, berarti kesalahan rata-rata 760 persen. Angka itu tidak masuk akal secara bisnis, dan penyebabnya struktural.

MAPE membagi kesalahan dengan nilai aktual. Ketika ada pelanggan yang belanja 90 hari ke depannya Rp 5.000, kesalahan Rp 50.000 menghasilkan kontribusi 1.000% ke rata-rata. Beberapa pelanggan kecil dapat mendominasi seluruh metrik.

Akibatnya, mengoptimalkan MAPE mendorong model untuk memprediksi terlalu rendah secara sistematis — karena memprediksi rendah pada pelanggan kecil lebih "aman" menurut metrik ini. Bias ini nyata dan terukur.

Gunakan WAPE. Ia memberi manfaat yang sama (tanpa satuan, dapat dibandingkan antar segmen) tanpa cacatnya, karena membagi dengan *total* alih-alih membagi per baris. Vol 3 Bab 12 sudah menggunakannya untuk peramalan; alasannya sama.

HOW — regularisasi: ridge dan lasso

MASALAH YANG DISELESAIKAN REGULARISASI

Regresi biasa meminimalkan: $\sum (\text{aktual} - \text{prediksi})^2$

Bila fitur banyak atau saling berkorelasi, koefisien menjadi besar dan tidak stabil: sedikit perubahan data mengubah koefisien secara drastis, dan model tidak dapat digeneralisasi.

RIDGE (L2) minimalkan $\sum (\text{error})^2 + \alpha \sum \beta_j^2$

- mengecilkan seluruh koefisien secara proporsional
- tidak pernah membuatnya tepat nol
- baik ketika banyak fitur berkorelasi dan semuanya relevan

LASSO (L1) minimalkan $\sum (\text{error})^2 + \alpha \sum |\beta_j|$

- dapat membuat koefisien TEPAT NOL -> seleksi fitur otomatis
- baik ketika hanya sebagian fitur yang relevan
- pada fitur berkorelasi, memilih satu dan membuang lainnya secara agak sembarang

ELASTIC NET kombinasi keduanya; dipakai ketika ragu

α (alpha) mengendalikan kekuatan: $\alpha = 0$ sama dengan regresi biasa; α sangat besar membuat seluruh koefisien mendekati nol.

■ TECHNICAL NOTE — mengapa regularisasi hampir tidak mengubah apa pun di sini

Pada tabel hasil, ridge dengan $\alpha = 1$ dan $\alpha = 100$ memberi angka yang praktis identik dengan regresi biasa, dan $\alpha = 10.000$ justru sedikit memperburuk. Ini bukan kegagalan metode; ia hasil yang dapat diprediksi dari kondisi datanya.

Regularisasi menolong ketika **jumlah fitur besar relatif terhadap jumlah baris**, atau ketika fitur sangat berkorelasi. Di sini ada 20 fitur dan 140.000 baris — rasio 1:7.000. Model tidak memiliki ruang untuk overfitting yang perlu ditahan.

Kapan regularisasi benar-benar menentukan: teks yang di-vektorkan (ribuan fitur), data genomik, model dengan banyak interaksi eksplisit, atau dataset kecil (di bawah beberapa ribu baris). Pada tabel pelanggan yang lebar-normal, ia adalah asuransi murah yang jarang terpakai.

Tetap gunakan ridge dengan α kecil sebagai default — biayanya nol dan ia melindungi dari kasus yang tidak terduga. Yang tidak sepadan adalah menghabiskan waktu menyetelnya.

Kode – memakai lasso untuk seleksi fitur, dan membaca hasilnya

```
from sklearn.linear_model import LassoCV

# LassoCV memilih alpha secara otomatis lewat cross-validation
las = LassoCV(cv=5, random_state=42, n_jobs=-1).fit(Xs, ytr)

koef = pd.Series(las.coef_, index=X.columns)
print(f"alpha terpilih : {las.alpha_:.1f}")
print(f"fitur dipakai : {(koef != 0).sum()} dari {len(koef)}")
print("\nKoefisien bukan nol, diurutkan:")
print(koef[koef != 0].sort_values(key=abs, ascending=False).round(0).to_string())
```

✗ COMMON MISTAKE — menafsirkan koefisien sebagai efek kausal

Gejala: "koefisien pernah_terlambat adalah +0,245 dalam satuan terstandardisasi, jadi mengurangi keterlambatan akan menurunkan churn sebesar itu."

Mengapa merusak: koefisien regresi mengukur asosiasi *setelah menyesuaikan variabel lain dalam model* — dan hanya variabel yang ada di dalam model. Variabel laten "niat berhenti" tidak ada di sana, sehingga koefisiennya tetap terkontaminasi. Bab 1 sudah menunjukkan besaran kesalahannya: 18,82 pp versus 4,00 pp.

Perbaikan: gunakan koefisien untuk *memahami model*, bukan untuk memahami dunia. Untuk memahami dunia, kembali ke Volume 4.

Cara senior menghindarinya: menuliskan kalimat baku pada setiap tabel koefisien: "Angka-angka ini menjelaskan bagaimana model membentuk prediksinya. Mereka bukan estimasi efek dari mengubah variabel."

Menangani target yang miring

TIGA PILIHAN, DENGAN KONSEKUENSI YANG BERBEDA

1. BIARKAN APA ADANYA

Model akan fokus pada pelanggan bernilai besar (karena merekalah yang menghasilkan kesalahan kuadrat terbesar). Tepat bila keputusannya memang tentang nilai total.

2. TRANSFORMASI LOG: latih pada $\log(1+y)$, prediksi lalu $\exp m1$

Model memperlakukan kesalahan secara RELATIF.

MAE dan MAPE membaik; RMSE dan R2 memburuk.

Tepat bila keputusannya per pelanggan.

■ CATATAN: $\exp m1(\text{prediksi log})$ memberi estimasi MEDIAN, bukan rata-rata. Total prediksi akan lebih rendah dari total aktual — bias yang harus dinyatakan bila angkanya akan dijumlahkan untuk proyeksi keuangan.

3. PEMODELAN DUA TAHAP

Tahap 1: klasifikasi — apakah pelanggan akan belanja sama sekali dalam 90 hari?

Tahap 2: regresi nilai, HANYA pada yang diprediksi belanja
Prediksi akhir = $P(\text{belanja}) \times E[\text{nilai} \mid \text{belanja}]$

Tepat bila banyak nilai nol, dan memberi dua angka yang masing-masing dapat ditindaklanjuti secara terpisah.

✓ **BEST PRACTICE — laporkan bias agregat, bukan hanya kesalahan rata-rata**

Ketika prediksi akan dijumlahkan — proyeksi arus kas, perencanaan stok, target penjualan — metrik per baris tidak cukup. Yang menentukan adalah apakah *totalnya* benar.

$$\text{bias} = (\sum \text{prediksi} - \sum \text{aktual}) / \sum \text{aktual}$$

Model dapat memiliki MAE sangat baik dan bias agregat -8% , yang berarti seluruh perencanaan yang dibangun di atasnya kekurangan 8% . Sebaliknya, model dengan MAE lebih buruk tetapi bias mendekati nol sering lebih berguna untuk perencanaan.

Ini persis pemisahan akurasi dan bias pada peramalan di Vol 3 Bab 12, dan berlaku sama untuk model ML. Laporkan keduanya, selalu.

Checklist model regresi

- ✓ Metrik dipilih sebelum melihat hasil, berdasarkan biaya kesalahan bisnis
- ✓ Minimal satu metrik satuan asli (MAE) dan satu metrik relatif (WAPE) dilaporkan
- ✓ MAPE dihindari pada data dengan nilai kecil atau nol
- ✓ Baseline rata-rata dan median dihitung dan dilaporkan
- ✓ Distribusi target diperiksa; kemiringan ditangani secara sadar
- ✓ Bias agregat dilaporkan bila prediksi akan dijumlahkan
- ✓ Regularisasi dipakai sebagai default ringan, tidak disetel berlebihan
- ✓ Koefisien ditafsirkan sebagai penjelasan model, bukan efek kausal
- ✓ Residual diperiksa terhadap fitur utama untuk menemukan pola yang tersisa

Ending Card — Bab 4

What you learned

Lima metrik regresi dan apa yang dihargai masing-masing; demonstrasi bahwa empat model berbeda "menang" tergantung metrik yang dipilih; mengapa baseline median memiliki R^2 negatif tetapi MAE lebih baik; mengapa MAPE hampir selalu keliru untuk data ritel dan mengapa ia mendorong bias ke bawah; ridge versus lasso dan mengapa keduanya hampir tidak mengubah apa pun pada rasio fitur-baris 1:7.000; kapan regularisasi benar-benar menentukan; tiga cara menangani target miring beserta konsekuensinya, termasuk bias median pada transformasi log; dan pentingnya melaporkan bias agregat berdampingan dengan kesalahan rata-rata.

Skills mastered

Pemodelan regresi · pemilihan metrik berbasis biaya · ridge dan lasso · penanganan target miring · pelaporan bias agregat.

Real business value

Memilih metrik yang benar sebelum melihat hasil mencegah pemilihan model yang optimal untuk metrik yang salah. Pada kasus ini, memilih RMSE ketika keputusannya per pelanggan akan mengarahkan tim ke regresi linear, sementara model yang tepat memberikan MAE 4,1% lebih baik dan MAPE tiga kali lebih baik.

Interview readiness

● INTERVIEW QUESTIONS

1. "MAE atau RMSE?" — tergantung apakah satu kesalahan besar lebih buruk daripada banyak kesalahan kecil; kaitkan ke biaya bisnis.
2. "Mengapa kamu tidak memakai MAPE?" — nilai kecil mendominasi; tidak terdefinisi di nol; mendorong bias ke bawah.
3. " R^2 model kamu 0,50. Bagus?" — tanpa baseline dan konteks, angka itu tidak bermakna; bandingkan dengan baseline.
4. "Kapan ridge menolong?" — banyak fitur relatif terhadap baris; fitur berkorelasi; dataset kecil.
5. "Ridge atau lasso?" — lasso bila diduga hanya sebagian fitur relevan dan seleksi diinginkan; ridge bila semua relevan.
6. "Prediksi kamu akan dijumlahkan untuk proyeksi kas. Apa yang kamu periksa?" — bias agregat, bukan MAE.

Exercises

Exercise 4.1 (Beginner · 40 menit)

Objective: memilih metrik dari biaya bisnis

Untuk lima kasus berikut, tentukan metrik utama dan alasannya:

- (a) memprediksi permintaan SKU untuk pemesanan (kelebihan dan kekurangan berbiaya berbeda); (b) memprediksi waktu pengiriman yang ditampilkan ke pelanggan; (c) memprediksi nilai belanja untuk alokasi anggaran kampanye per pelanggan; (d) memprediksi total revenue bulanan untuk proyeksi kas; (e) memprediksi jumlah staf yang dibutuhkan per shift.

Answer key 4.1

(a) **Bukan MAE maupun RMSE** — biaya kelebihan dan kekurangan tidak simetris, sehingga metrik yang benar adalah *biaya harapan* dengan pinball loss atau langsung newsvendor (Vol 5 Bab 11). Ini jebakan yang disengaja: metrik simetris salah untuk masalah asimetris.

(b) **Kuantil, bukan rata-rata**. Menampilkan estimasi tengah berarti setengah pengiriman terlambat dari janji. Yang benar adalah memprediksi persentil ke-80 atau ke-90 — dan metrik evaluasinya pinball loss pada kuantil itu.

(c) **MAE atau WAPE**. Setiap rupiah kesalahan sama biayanya karena keputusannya per kepala.

(d) **Bias agregat lebih dulu, lalu WAPE**. Untuk proyeksi kas, total yang benar jauh lebih penting daripada akurasi per baris.

(e) **Asimetris lagi** — kekurangan staf berbiaya lebih besar daripada kelebihan. Pinball loss dengan kuantil di atas 0,5, atau optimasi biaya langsung (Vol 5 Bab 13).

Pelajaran: dari lima kasus, hanya satu yang metrik regresi standar benar-benar tepat.

Exercise 4.2 (Intermediate · 80 menit)

Objective: pemodelan dua tahap

Bangun model dua tahap untuk `belanja_90h`: (1) klasifikasi apakah belanja > 0 dalam 90 hari; (2) regresi nilai pada yang belanja. Gabungkan menjadi prediksi akhir.

(a) Bandingkan seluruh metrik dengan model satu tahap. (b) Hitung bias agregat keduanya. (c) Kapan pendekatan dua tahap lebih baik? (d) Apa kerugiannya?

Answer key 4.2

(a) Model dua tahap biasanya memperbaiki MAE dan WAPE pada data dengan banyak nilai kecil, karena ia tidak memaksa satu fungsi menjelaskan dua proses yang berbeda (apakah membeli, dan berapa bila membeli).

(b) Bias agregat pendekatan dua tahap biasanya lebih baik, karena $P(\text{belanja}) \times E[\text{nilai}|\text{belanja}]$ adalah estimasi ekspektasi yang tepat, sementara model log satu tahap memberi median.

(c) Lebih baik ketika: proporsi nol tinggi; dua proses dipengaruhi faktor berbeda; dan ketika *kedua angkanya berguna secara terpisah* — probabilitas belanja dapat dipakai untuk kampanye, nilai bersyarat untuk perencanaan stok.

(d) Kerugiannya: dua model untuk dipelihara, dua sumber drift, dan kesalahan yang berlipat. Bila selisih kinerjanya kecil, satu model lebih baik. Ini pertukaran yang sama dengan kompleksitas versus pemeliharaan di seluruh volume ini.

Exercise 4.3 (Advanced · 2 jam)

Objective: analisis residual

Untuk model regresi terbaik kamu: (a) plot residual terhadap prediksi dan terhadap lima fitur utama; (b) hitung MAE per desil nilai aktual; (c) hitung bias per segmen (kanal, wilayah, tier); (d) identifikasi minimal dua kelompok di mana model bekerja jauh lebih buruk daripada rata-rata; (e) usulkan perbaikan spesifik untuk masing-masing.

Answer key 4.3 — kerangka jawaban

(b) MAE per desil hampir selalu menunjukkan pola yang sama: kesalahan absolut jauh lebih besar pada desil teratas. Ini wajar dan bukan masalah dengan sendirinya — yang menjadi masalah adalah bila *kesalahan relatif* juga jauh lebih besar di sana.

(c) Bias per segmen adalah bagian paling bernilai. Model yang secara sistematis meremehkan satu wilayah akan menyebabkan alokasi stok yang salah secara berulang di wilayah itu, dan tidak akan terdeteksi oleh metrik agregat. Ini juga pemeriksaan keadilan yang paling praktis — lihat Bab 14.

(e) Perbaikan yang biasanya tepat: menambahkan fitur khusus segmen yang bermasalah; melatih model terpisah bila segmen cukup besar dan perilakunya benar-benar berbeda; atau menerapkan koreksi bias per segmen bila penyebabnya tidak dapat dimodelkan. Pilihan ketiga adalah yang paling sering dipakai dalam praktik dan paling jarang didokumentasikan — dokumentasikan.

Portfolio idea

★ PORTFOLIO TIP

Sertakan tabel "metrik mana yang memilih model mana" seperti pada bab ini. Ia menunjukkan bahwa kamu memahami evaluasi sebagai keputusan, bukan sebagai langkah otomatis — dan itu topik yang hampir selalu muncul dalam wawancara senior.

Further reading

Hastie, Tibshirani & Friedman, *The Elements of Statistical Learning* — bab 3 tentang regresi dan penyusutan · Dokumentasi scikit-learn tentang *linear models* · Hyndman & Koehler tentang pemilihan metrik akurasi peramalan · Vol 2 Bab 5 dan Vol 3 Bab 12 buku ini.

Next chapter

Bab 5 — regresi logistik untuk klasifikasi: model yang paling sering dianggap terlalu sederhana, dan yang pada data ini justru menghasilkan AUC tertinggi.

Bab 5 — Klasifikasi dengan Regresi Logistik

Model yang paling sering dianggap terlalu sederhana — dan yang pada data ini menghasilkan AUC tertinggi

Learning objectives	Membangun model klasifikasi dengan regresi logistik; menafsirkan koefisien dan odds ratio dengan benar; memahami mengapa keluarannya berupa probabilitas dan mengapa itu penting; menerapkan regularisasi pada klasifikasi; mengenali kekuatan dan batas model linear; menjelaskan model kepada auditor dan regulator
Prerequisites	Bab 2-4; Vol 2 Bab 6 (regresi logistik dasar, odds)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Intermediate
Skills covered	Regresi logistik, odds ratio, probabilitas terkalibrasi, regularisasi klasifikasi, penjelasan model
Business domain	Retail omnichannel — model churn 180 hari TokoNusa

WHY — mengapa memulai dari model linear

EMPAT ALASAN YANG BERTAHAN DI DUNIA NYATA

1. KELUARANNYA PROBABILITAS YANG BERMAKNA
Skor 0,73 berarti "sekitar 73% pelanggan seperti ini akan churn". Ini yang dibutuhkan untuk menghitung nilai harapan dan ambang keputusan (Bab 9).
2. DAPAT DIJELASKAN BARIS PER BARIS
"Skor pelanggan ini tinggi karena recency 210 hari (+0,88 log-odds) dan frekuensi hanya 1 (+0,54)."
Beberapa industri MEWAJIBKAN ini.
3. STABIL DAN MURAH
Latih dalam hitungan detik, jalankan di mana saja, tidak ada hyperparameter yang perlu disetel.
4. SERING SUDAH CUKUP
Pada data TokoNusa: AUC 0,8007 — sedikit LEBIH TINGGI daripada XGBoost (0,8000).

◆ BUSINESS INSIGHT — biaya kompleksitas yang jarang dihitung

Ketika dua model memberi kinerja setara, perbedaannya bukan nol — ia hanya berpindah dari kolom akurasi ke kolom biaya.

Dimensi	Regresi logistik	Gradient boosting
AUC pada data ini	0,8007	0,8000
Waktu latih	± 3 detik	± 25 detik
Hyperparameter yang perlu disetel	1 (kekuatan regularisasi)	5-8
Penjelasan per individu	Langsung dari koefisien	Butuh SHAP (Bab 7)
Ukuran artefak model	Beberapa kilobyte	Beberapa megabyte
Risiko kegagalan senyap saat drift	Lebih rendah, lebih mudah dipantau	Lebih tinggi
Kemampuan menangkap interaksi	Tidak, kecuali dibuat manual	Otomatis

Kesimpulannya bukan "selalu pakai model linear". Kesimpulannya adalah: **mulai dari sini, dan pindah ke model yang lebih kompleks hanya ketika selisih kinerjanya membenarkan biayanya.** Bab 6 menunjukkan bahwa ketika interaksi benar-benar ada, selisihnya bisa mencapai 0,1414 AUC — dan pada saat itu perpindahannya jelas sepadan.

WHAT — cara kerja regresi logistik

DARI KOMBINASI LINEAR KE PROBABILITAS

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k \quad (\text{log-odds, rentang } -\infty..+\infty)$$

$$p = \frac{1}{1 + e^{(-z)}} \quad (\text{probabilitas, rentang } 0..1)$$

MENAFSIRKAN KOEFISIEN

β_j = perubahan LOG-ODDS per satu satuan x_j
 e^{β_j} = ODDS RATIO – faktor pengali terhadap odds

Contoh: $\beta_j = +0,2451 \rightarrow e^{0,2451} = 1,278$
 "Odds churn 27,8% lebih tinggi, dengan variabel lain tetap"

PENTING: odds ratio BUKAN risk ratio.

Odds naik 27,8% TIDAK berarti probabilitas naik 27,8%.

Pada $p = 0,44$, odds ratio 1,278 menaikkan p menjadi 0,50 – yaitu +6 pp, bukan +12 pp.

Kode – membangun dan menafsirkan model logistik

```
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score, brier_score_loss
```



```

df = pd.read_csv('tokonusa_ml.csv')
NUM = ['tenure_bulan', 'frekuensi_12bln', 'recency_hari', 'aov',
       'monetary_12bln', 'n_kategori', 'skor_loyalitas', 'anggota_tier',
       'pernah_terlambat', 'n_keterlambatan', 'n_keluhan', 'retur_rate',
       'promo_rate', 'diskon_rata', 'keteraturan']
CAT = ['kanal', 'wilayah', 'metode_bayar']

X, y = df[NUM + CAT], df['churn_180h']
Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.30,
                                       random_state=42, stratify=y)

# Standardisasi WAJIB untuk regresi logistik dengan regularisasi:
# tanpa itu, penalti menghukum fitur berskala besar lebih keras.
pre = ColumnTransformer([
    ('num', StandardScaler(), NUM),
    ('cat', OneHotEncoder(drop='first', handle_unknown='ignore'), CAT)])

# C adalah KEBALIKAN kekuatan regularisasi: C kecil = penalti besar
lr = Pipeline([('pre', pre),
               ('m', LogisticRegression(max_iter=2000, C=1.0))]).fit(Xtr, ytr)

p = lr.predict_proba(Xte)[:, 1] # kolom 1 = probabilitas kelas positif
print(f"AUC {roc_auc_score(yte, p):.4f}")
print(f"Brier {brier_score_loss(yte, p):.4f}") # kualitas probabilitas (Bab 8)

# Menyusun tabel koefisien yang dapat dibaca manusia
nama = NUM + list(lr.named_steps['pre'].named_transformers_['cat'].get_feature_names_out(CAT))
koef = pd.Series(lr.named_steps['m'].coef_[0], index=nama)
tabel = pd.DataFrame({'koefisien': koef,
                     'odds_ratio': np.exp(koef)})
print(tabel.reindex(koef.ascending().sort_values(ascending=False).index).head(10).round(4))

```

Output

AUC 0.8007
Brier 0.1799

Fitur (skala terstandardisasi)	koefisien	odds ratio
frekuensi_12bln	-0.7629	0.466
recency_hari	+0.7534	2.124
keteraturan	-0.4209	0.656
metode_bayar_kartu	-0.2699	0.763
metode_bayar_transfer	-0.2571	0.773
metode_bayar_ewallet	-0.2535	0.776
pernah_terlambat	+0.2451	1.278
n_keluhan	+0.2326	1.262
anggota_tier	-0.1649	0.848
monetary_12bln	-0.1422	0.867
intercept	-0.1058	

■ TECHNICAL NOTE — membaca tabel ini dengan benar

Koefisien pada skala terstandarisasi. Karena seluruh fitur numerik distandardisasi, koefisien menyatakan perubahan log-odds per *satu simpangan baku*, bukan per satu satuan asli. Ini membuat besaran antar fitur dapat dibandingkan langsung — dan itulah sebabnya standardisasi berguna bahkan di luar keperluan regularisasi.

Frekuensi dan recency mendominasi dengan besaran hampir sama dan tanda berlawanan. Satu SD lebih banyak pembelian mengalikakan odds churn dengan 0,466 (memotongnya lebih dari setengah); satu SD lebih lama tidak membeli mengalikannya dengan 2,124.

Tiga koefisien metode bayar hampir identik (−0,270, −0,257, −0,254). Kategori rujukan yang dibuang adalah COD. Artinya bukan "kartu lebih baik daripada transfer", melainkan *ketiganya sama-sama berbeda dari COD*. Ini pola yang layak dikenali: ketika koefisien beberapa kategori berdekatan, yang sebenarnya ditemukan model adalah pengelompokan biner, dan menyederhanakannya menjadi satu fitur "bayar dengan COD" akan memberi model yang lebih ringkas dengan kinerja setara.

Intercept −0,1058 adalah log-odds pada saat seluruh fitur berada di rata-ratanya, yang setara probabilitas 0,4736.

⚠ WARNING — odds ratio bukan perubahan probabilitas

Kesalahan komunikasi paling umum dalam melaporkan model logistik: menyampaikan odds ratio seolah-olah ia perubahan probabilitas.

Odds ratio pernah_terlambat = 1,278

SALAH : "keterlambatan menaikkan peluang churn 27,8%"

BENAR : "odds churn 27,8% lebih tinggi"

Terjemahan ke probabilitas BERGANTUNG pada titik awalnya:

p awal 0,10	->	odds 0,111	->	$x1,278 = 0,142$	->	p 0,124	(+2,4 pp)
p awal 0,44	->	odds 0,786	->	$x1,278 = 1,004$	->	p 0,501	(+6,1 pp)
p awal 0,80	->	odds 4,000	->	$x1,278 = 5,112$	->	p 0,836	(+3,6 pp)

Efek pada probabilitas paling besar di sekitar $p = 0,5$ dan mengecil di kedua ujungnya.

Ketika berbicara dengan pemangku kepentingan non-teknis, terjemahkan ke perubahan probabilitas pada tingkat dasar yang relevan, dan sebutkan tingkat dasarnya. Dan ingat peringatan Bab 4: angka ini tetap asosiasi, bukan efek dari mengubah variabelnya.

HOW — regularisasi pada klasifikasi

PARAMETER C DALAM scikit-learn

$C = 1 / \alpha$ (kebalikan kekuatan regularisasi)

C besar (100) -> regularisasi lemah -> koefisien bebas

C kecil (0,01) -> regularisasi kuat -> koefisien mengecil

penalty='l2' (default) ridge — mengecilkan semua
penalty='l1' lasso — dapat membuat tepat nol
penalty='elasticnet' kombinasi (butuh solver='saga')

CARA MEMILIH: LogisticRegressionCV, atau GridSearchCV dengan metrik yang sudah kamu tetapkan di muka (Bab 4).

PADA DATA INI: rentang C dari 0,01 sampai 100 mengubah AUC kurang dari 0,001 – karena 20 fitur dan 140.000 baris tidak memberi ruang overfitting. Jangan habiskan waktu di sini.

✓ BEST PRACTICE — kapan menyetel dan kapan berhenti

Aturan yang menghemat banyak waktu: **hitung rasio baris terhadap fitur sebelum menyetel apa pun.**

```
baris / fitur > 1.000   penyetelan hampir tidak berpengaruh
baris / fitur   50-1000 penyetelan ringan bermanfaat
baris / fitur <    50   penyetelan menentukan; regularisasi wajib
```

Pada data ini rasionya 7.000. Setiap jam yang dihabiskan menyetel C adalah jam yang tidak dihabiskan untuk Bab 9 dan 10, tempat nilai sebenarnya berada.

Kekuatan tersembunyi: model yang dapat dijelaskan per individu

Kode – menjelaskan satu prediksi kepada tim CRM

```
def jelaskan(model, baris, nama_fitur, top=5):
    """Menguraikan satu prediksi menjadi kontribusi tiap fitur."""
    x = model.named_steps['pre'].transform(baris)          # fitur terstandarisasi
    b = model.named_steps['m'].coef_[0]
    b0 = model.named_steps['m'].intercept_[0]
    kontribusi = pd.Series(np.asarray(x).ravel() * b, index=nama_fitur)
    z = b0 + kontribusi.sum()
    p = 1 / (1 + np.exp(-z))
    print(f"Probabilitas churn: {p:.3f} (log-odds {z:+.3f})")
    print("Pendorong terbesar:")
    for f, v in kontribusi.reindex(
        kontribusi.abs().sort_values(ascending=False).index).head(top).items():
        arah = "menaikkan" if v > 0 else "menurunkan"
        print(f" {f:<22} {v:+.3f} ({arah} risiko)")

jelaskan(lr, Xte.iloc[[0]], nama)
```

Output – satu pelanggan (recency 306 hari, frekuensi 8, tenure 11 bulan)

```
Probabilitas churn: 0.832 (log-odds +1.596)
Pendorong terbesar:
recency_hari          +2.775 (menaikkan risiko)
frekuensi_12bln       -0.960 (menurunkan risiko)
keteraturan           +0.323 (menaikkan risiko)
metode_bayar_kartu     -0.270 (menurunkan risiko)
monetary_12bln        -0.221 (menurunkan risiko)
```

Pelanggan ini menceritakan kisah yang jelas: ia *dulu* pelanggan yang cukup aktif — delapan pembelian dalam 12 bulan, membayar dengan kartu, nilai belanja di atas rata-rata, dan ketiga hal itu menurunkan risikonya. Tetapi ia sudah 306 hari tidak membeli, dan faktor tunggal itu (+2,775) mengalahkan seluruh sinyal positifnya digabung.

Bagi tim CRM, ini bukan pelanggan yang sama dengan seseorang yang skornya 0,832 karena ia memang tidak pernah aktif. Pesan, tawaran, dan prioritasnya berbeda — dan perbedaan itu hanya terlihat karena modelnya dapat menjelaskan diri.

► EXECUTIVE PERSPECTIVE — mengapa kemampuan ini bernilai lebih dari 0,01 AUC

Penjelasan per individu bukan kemewahan akademis. Ia menentukan apakah model dipakai.

Tim CRM yang menerima daftar 120.000 nama tanpa alasan akan menjalankan kampanye seragam. Tim yang menerima daftar dengan tiga pendorong utama per pelanggan dapat menyesuaikan pesan — dan penyesuaian itu sering bernilai lebih besar daripada perbaikan akurasi mana pun.

Di industri yang diatur ketat, ini bahkan bukan pilihan. Keputusan kredit, asuransi, dan sebagian keputusan kepegawaian mensyaratkan alasan yang dapat dijelaskan kepada orang yang terdampak. Model yang tidak dapat menjelaskan dirinya tidak dapat dipakai di sana, seberapa pun akurat.

Bab 7 menunjukkan cara memperoleh penjelasan serupa dari model boosting lewat SHAP — dengan biaya komputasi dan kompleksitas yang jauh lebih tinggi, dan dengan jebakan penafsiran yang tidak dimiliki model linear.

Batas model linear

Batas	Akibatnya	Penanganan
Tidak menangkap interaksi	Bila efek recency berbeda untuk anggota tier dan bukan anggota, model tidak dapat menyatakannya	Buat kolom interaksi eksplisit, atau pindah ke model pohon (Bab 6)
Mengasumsikan hubungan monoton dalam log-odds	Hubungan berbentuk U (misalnya diskon terlalu kecil dan terlalu besar sama-sama buruk) tidak tertangkap	Tambahkan suku kuadrat, atau binning
Sensitif terhadap pencilan	Satu pelanggan dengan monetary ekstrem dapat menarik koefisien	Winsorize, transformasi log, atau binning
Multikolinearitas mengacaukan koefisien	Koefisien menjadi tidak stabil dan tandanya bisa terbalik	Periksa VIF; gabungkan atau buang fitur redundan; ridge
Kategorikal berkardinalitas tinggi merepotkan	One-hot menghasilkan ribuan kolom	Frequency encoding, atau model yang menangani kategorikal secara native

✗ COMMON MISTAKE — membaca koefisien tanpa memeriksa multikolinearitas

Gejala: koefisien `monetary_12bln` bertanda negatif dan `aov` bertanda positif, lalu disimpulkan "pelanggan dengan keranjang besar lebih mudah churn".

Mengapa merusak: $\text{monetary} = \text{frekuensi} \times \text{AOV}$. Ketiganya sangat berkorelasi, sehingga koefisien masing-masing menjadi bagian dari pembagian yang sembarang — tanda dan besarannya dapat berubah drastis bila salah satu fitur dibuang.

Perbaikan: periksa VIF (variance inflation factor) sebelum menafsirkan koefisien apa pun. VIF di atas 5 berarti penafsiran per fitur sudah tidak andal; di atas 10 berarti tidak boleh ditafsirkan sama sekali.

Cara senior menghindarinya: memisahkan dua tujuan sejak awal. Bila tujuannya *prediksi*, multikolinearitas hampir tidak masalah dan koefisien tidak perlu ditafsirkan. Bila tujuannya *pemahaman*, susun model yang lebih ramping dengan fitur yang tidak redundan — dan tetap ingat bahwa hasilnya asosiasi, bukan sebab.

Checklist model logistik

- ✓ Fitur numerik distandardisasi sebelum regularisasi diterapkan
- ✓ Seluruh praproses berada di dalam Pipeline

- ✓ Kategori rujukan (yang dibuang saat one-hot) diketahui dan disebutkan saat menafsirkan
- ✓ Odds ratio dilaporkan sebagai odds, bukan sebagai perubahan probabilitas
- ✓ Terjemahan ke probabilitas disertai tingkat dasar yang relevan
- ✓ VIF diperiksa bila koefisien akan ditafsirkan
- ✓ Kualitas probabilitas diperiksa dengan Brier score dan kurva kalibrasi (Bab 8)
- ✓ Rasio baris terhadap fitur dihitung sebelum menghabiskan waktu menyetel
- ✓ Fungsi penjelasan per individu disediakan bila keluaran akan dipakai manusia
- ✓ Batas model dinyatakan; interaksi penting diuji secara eksplisit

Ending Card — Bab 5

What you learned

Empat alasan memulai dari model linear dan tabel biaya kompleksitas yang membandingkan tujuh dimensi; cara kerja regresi logistik dari log-odds ke probabilitas; pembacaan tabel koefisien terstandarisasi termasuk pola koefisien kategori yang berdekatan; mengapa odds ratio bukan perubahan probabilitas dan cara menerjemahkannya dengan benar pada tiga tingkat dasar; regularisasi pada klasifikasi dan aturan rasio baris-terhadap-fitur untuk memutuskan kapan menyetel; fungsi penjelasan per individu dan mengapa kemampuan itu bernilai lebih dari 0,01 AUC; lima batas model linear dan penanganannya; serta bahaya menafsirkan koefisien tanpa memeriksa multikolinearitas.

Skills mastered

Regresi logistik · interpretasi odds ratio · regularisasi klasifikasi · penjelasan prediksi per individu · penilaian batas model linear.

Real business value

Pada data ini, model yang dapat dilatih dalam tiga detik dan dijelaskan baris per baris mengungguli gradient boosting. Memulai dari sini berarti tim memiliki model produksi yang berfungsi dalam hari pertama, dan sisa waktunya tersedia untuk pekerjaan yang benar-benar menentukan nilai: ambang keputusan dan pengukuran uplift.

Interview readiness

● INTERVIEW QUESTIONS

1. "Jelaskan odds ratio 1,278 kepada manajer pemasaran." — odds versus probabilitas; sebutkan tingkat dasar.
2. "Mengapa memulai dari regresi logistik?" — probabilitas bermakna, dapat dijelaskan, murah, sering sudah cukup; beri angka.
3. "Koefisien monetary negatif. Apa artinya?" — periksa multikolinearitas dulu; jangan tafsirkan sebelum VIF diperiksa.
4. "Kapan kamu berhenti menyetel hyperparameter?" — rasio baris terhadap fitur; tunjukkan aturan praktisnya.
5. "Model kamu tidak menangkap bahwa efek recency berbeda per segmen. Apa yang kamu lakukan?" — interaksi eksplisit atau pindah ke model pohon.
6. "Regulator meminta alasan penolakan. Model mana yang kamu pakai?" — model yang dapat menjelaskan per individu; jelaskan konsekuensinya.

Exercises

Exercise 5.1 (Beginner · 40 menit)

Objective: menafsirkan dan menerjemahkan koefisien

Dengan tabel koefisien pada bab ini: (a) hitung odds ratio untuk `keteraturan` dan jelaskan artinya dalam satu kalimat bisnis; (b) untuk pelanggan dengan probabilitas dasar 0,30, hitung probabilitas baru bila `n_keluhan` naik satu simpangan baku; (c) jelaskan mengapa tiga koefisien metode bayar hampir sama dan apa yang sebaiknya dilakukan; (d) hitung probabilitas churn pada saat seluruh fitur berada di rata-rata.

Answer key 5.1

(a) $e^{(-0,4209)} = \mathbf{0,656}$. Kalimat bisnis: "Pelanggan yang pola belanjanya lebih teratur sebesar satu simpangan baku memiliki odds churn 34,4% lebih rendah, dengan faktor lain setara." Perhatikan bahwa keteraturan adalah fitur ketiga terkuat sekaligus salah satu yang paling jarang dibangun — kandidat kuat untuk diusulkan ke tim data.

(b) Odds awal = $0,30/0,70 = 0,4286$. Odds ratio $n_keluhan = e^{0,2326} = 1,262$. Odds baru = $0,4286 \times 1,262 = 0,5409$. p baru = $0,5409/1,5409 = \mathbf{0,351}$, yaitu **+5,1 pp**.

(c) Ketiganya diukur relatif terhadap kategori rujukan COD, dan nilainya berdekatan ($-0,270$, $-0,257$, $-0,254$) karena yang sebenarnya membedakan adalah COD versus non-COD. Sebaiknya: ganti tiga kolom dengan satu kolom biner `bayar_cod`. Model menjadi lebih ringkas, koefisiennya lebih mudah dijelaskan, dan kinerjanya praktis sama.

(d) Pada seluruh fitur di rata-rata, $z = \text{intercept} = -0,1058$; $p = 1/(1+e^{0,1058}) = \mathbf{0,4736}$. Bandingkan dengan prevalensi aktual 0,4419 — selisihnya wajar karena fitur kategorikal tidak terpusat pada nol.

Exercise 5.2 (Intermediate · 80 menit)

Objective: menambahkan interaksi secara eksplisit

Model linear tidak dapat menemukan interaksi sendiri. Uji tiga hipotesis interaksi pada data TokoNusa:

(i) efek recency berbeda antara anggota tier dan bukan; (ii) efek keterlambatan berbeda antar wilayah; (iii) efek frekuensi berbeda antar kanal.

(a) Bangun kolom interaksinya. (b) Ukur perubahan AUC untuk masing-masing. (c) Bandingkan dengan XGBoost yang menemukan interaksi sendiri. (d) Apa kesimpulannya tentang data ini?

Answer key 5.2

(b) Ketiga interaksi memberi kenaikan AUC yang sangat kecil, di bawah 0,002. (c) XGBoost pada data yang sama juga tidak mengungguli model linear (0,8000 versus 0,8007).

(d) Kesimpulan yang benar dan penting: **pada data ini interaksi memang tidak ada secara berarti**. Ini bukan kegagalan pencarian — ia temuan tentang struktur data. Proses yang menghasilkan churn di sini memang mendekati aditif dalam log-odds.

Konsekuensi praktisnya besar: setiap upaya menaikkan kinerja lewat model yang lebih ekspresif akan sia-sia, dan tim sebaiknya berhenti. Mengetahui *apan tidak ada lagi yang bisa diperoleh dari pemodelan* adalah keterampilan yang jarang dan sangat berharga. Bab 6 menunjukkan bagaimana data yang benar-benar memiliki interaksi berperilaku sangat berbeda — selisih 0,1414 AUC.

Exercise 5.3 (Advanced · 2 jam)

Objective: model yang siap diaudit

Bangun model churn yang memenuhi syarat audit: (a) maksimal 8 fitur; (b) seluruh VIF di bawah 5; (c) setiap koefisien dapat dijelaskan dalam satu kalimat bisnis; (d) fungsi penjelasan per individu; (e) dokumentasi satu halaman yang mencantumkan definisi fitur, arah yang diharapkan, dan arah aktual. Bandingkan AUC-nya dengan model penuh dan nyatakan berapa kinerja yang dikorbankan demi keterjelasan.

Answer key 5.3 — kerangka jawaban

Delapan fitur yang biasanya cukup: recency, frekuensi, keteraturan, tenure, anggota_tier, n_keluhan, pernah_terlambat, bayar_cod. Kombinasi ini menghindari redundansi monetary/AOV/frekuensi dan menjaga VIF rendah.

Bagian (e) adalah yang paling bernilai dan paling sering dilewatkan: *menuliskan arah yang diharapkan sebelum melihat koefisien*. Bila arah aktual berlawanan dengan harapan bisnis, itu sinyal untuk diselidiki — bisa karena multikolinearitas, bisa karena definisi fitur yang keliru, dan sesekali karena temuan nyata yang menarik. Praktik ini adalah bentuk pre-registration (Vol 4 Bab 13) yang diterapkan pada pemodelan. Kinerja yang dikorbankan biasanya di bawah 0,01 AUC — angka yang, setelah membaca Bab 9, akan terlihat sangat kecil dibandingkan nilai dari menetapkan ambang dengan benar.

Portfolio idea

★ PORTFOLIO TIP

Model yang siap diaudit (Exercise 5.3) beserta dokumen satu halamannya adalah artefak yang sangat relevan untuk peran di perbankan, asuransi, dan kesehatan. Sertakan kolom "arah yang diharapkan" versus "arah aktual" — ia menunjukkan disiplin yang jarang terlihat pada portofolio kandidat.

Further reading

Hosmer, Lemeshow & Sturdivant, *Applied Logistic Regression* · Harrell, *Regression Modeling Strategies* — rujukan mendalam tentang membangun model yang dapat ditafsirkan · Dokumentasi scikit-learn tentang `LogisticRegression` · Vol 2 Bab 6 buku ini.

Next chapter

Bab 6 — pohon keputusan, random forest, dan gradient boosting. Termasuk percobaan yang menunjukkan kapan boosting kalah ($-0,0019$) dan kapan ia menang telak ($+0,1414$).

Bab 6 — Pohon, Random Forest, dan Gradient Boosting


Model yang menemukan interaksi sendiri — dan percobaan yang menunjukkan kapan itu bernilai nol dan kapan bernilai 0,1414 AUC

Learning objectives	Memahami cara pohon keputusan membelah data dan mengapa ia mudah overfitting; membedakan bagging dari boosting; menyetel hyperparameter utama dengan alasan; mengenali gejala overfitting secara kuantitatif; mengetahui kapan model pohon mengungguli model linear dan kapan tidak; memilih antara ketiganya berdasarkan situasi
Prerequisites	Bab 2-5
Estimasi waktu	Baca 3 jam · Praktik 5 jam
Difficulty	● Advanced
Skills covered	Decision tree, random forest, gradient boosting, XGBoost, penyetelan hyperparameter, diagnosis overfitting
Business domain	Retail omnichannel — model churn dan perbandingan keluarga model

WHAT — pohon keputusan

CARA POHON BEKERJA

Pada setiap simpul, algoritma mencari SATU pembelahan (fitur + ambang) yang paling memurnikan kedua sisinya.



UKURAN KEMURNIAN

Gini = $1 - \sum p_i^2$ (default, cepat)
Entropi = $-\sum p_i \log p_i$ (hasil hampir selalu serupa)

SIFAT PENTING

- Menangkap INTERAKSI secara otomatis: cabang kanan dan kiri dapat memakai fitur yang berbeda
- Tidak memerlukan scaling
- Menangani hubungan non-linear tanpa transformasi
- TIDAK STABIL: sedikit perubahan data dapat mengubah seluruh struktur pohon

Output — kedalaman pohon dan overfitting

max_depth	AUC train	AUC test	selisih
3	0.7521	0.7502	+0.0019
4	0.7692	0.7666	+0.0026

6	0.7870	0.7826	+0.0044	
None	1.0000	0.6254	+0.3746	◀ overfitting total

⚠ WARNING — pohon tanpa batas kedalaman menghafal, bukan belajar

Pohon tanpa batas mencapai AUC 1,0000 pada data latih. Ia memisahkan setiap pelanggan ke daunnya sendiri dan menghafal labelnya. Pada data uji ia hanya mencapai 0,6254 — *lebih buruk daripada pohon berkedalaman 3*, dan hampir setara dengan aturan bisnis sederhana "recency > 90 hari" (0,6186).

Selisih 0,3746 antara train dan test adalah gejala paling jelas yang akan kamu temui. Aturan praktis yang berguna:

```
selisih < 0,01    sehat
selisih 0,01–0,05 wajar, terutama pada model kompleks
selisih 0,05–0,15 mulai overfitting; kurangi kompleksitas
selisih > 0,15    overfitting serius; model tidak dapat dipakai
```

Yang membuat ini berbahaya dalam praktik: bila seseorang hanya melaporkan angka latih, model dengan AUC 1,0000 terlihat sempurna. Selalu minta kedua angka.

WHAT — dari satu pohon ke banyak pohon

BAGGING (Random Forest)	BOOSTING (XGBoost, LightGBM)
Banyak pohon DALAM	Banyak pohon BERURUTAN
Setiap pohon dilatih pada sampel bootstrap + subset fitur acak	Setiap pohon memperbaiki KESALAHAN pohon sebelumnya
Prediksi = RATA-RATA seluruh pohon	Prediksi = JUMLAH berbobot seluruh pohon
Tujuan: mengurangi VARIANS	Tujuan: mengurangi BIAS
Pohon dalam (tidak dipangkas)	Pohon dangkal (depth 3–6)
Sulit overfitting	MUDAH overfitting bila terlalu banyak pohon
dengan menambah pohon	Berurutan (walau ada trik)
Dapat diparalelkan penuh	
Biasanya: boosting sedikit lebih akurat, random forest lebih mudah disetel dan lebih sulit dirusak.	

Kode — ketiga keluarga model, dibandingkan secara adil

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier
import xgboost as xgb
from sklearn.metrics import roc_auc_score

# Pohon tunggal — dibatasi kedalamannya agar tidak menghafal
tree = DecisionTreeClassifier(
    max_depth=4,          # batas kedalaman: pengendali utama
    min_samples_leaf=20,  # daun minimal 20 baris
    random_state=42)

# Random forest — banyak pohon dalam, dirata-ratakan
rf = RandomForestClassifier(
    n_estimators=300,      # jumlah pohon: makin banyak makin stabil
    max_depth=12,         # pohon boleh dalam; rata-rata yang menstabilkan
    min_samples_leaf=20,   # mencegah daun yang terlalu spesifik
```

```

n_jobs=-1,                # pakai semua inti CPU
random_state=42)

# Gradient boosting – banyak pohon DANGKAL, berurutan
gbm = xgb.XGBClassifier(
    n_estimators=400,        # jumlah tahap boosting
    max_depth=4,            # DANGKAL – ini yang membedakan dari RF
    learning_rate=0.05,     # kontribusi tiap pohon; kecil = lebih aman
    subsample=0.8,         # 80% baris per pohon: regularisasi
    colsample_bytree=0.8,   # 80% fitur per pohon: regularisasi
    eval_metric='logloss',
    random_state=42, n_jobs=-1)

```

Output – hasil pada data churn TokoNusa (60.000 baris uji)

Model	AUC	PR-AUC	Brier	Akurasi	Presisi	Recall
aturan recency > 90 hari	0.6186	0.5368	0.3496	0.6504	0.7176	0.3445
decision tree (depth 4)	0.7666	0.7032	0.1930	0.6976	0.7137	0.5272
random forest	0.7963	0.7579	0.1824	0.7200	0.6992	0.6429
XGBoost	0.8000	0.7633	0.1802	0.7232	0.7026	0.6481
regresi logistik	0.8007	0.7643	0.1799	0.7239	0.7059	0.6432

◆ BUSINESS INSIGHT — pada data ini, model paling sederhana menang

Urutan hasilnya berlawanan dengan harapan umum: regresi logistik unggul tipis atas XGBoost pada seluruh metrik, dan random forest di bawah keduanya.

Ini bukan kebetulan dan bukan kesalahan penyetelan. Ia konsekuensi dari struktur data: proses yang menghasilkan churn di sini mendekati aditif dalam log-odds, dan itulah persis bentuk yang paling cocok untuk regresi logistik. Model pohon harus *mendekati* hubungan linear dengan tangga bertingkat, dan pendekatan itu selalu sedikit lebih kasar.

Pelajaran yang dapat dibawa ke pekerjaan nyata: **selisih antar algoritma pada data tabular yang bersih biasanya kecil — dalam rentang 0,01 AUC**. Ketika seseorang melaporkan bahwa mengganti algoritma menaikkan kinerja secara dramatis, penjelasan yang lebih mungkin adalah perbedaan praproses, kebocoran, atau perbedaan cara evaluasi — bukan keunggulan algoritma.

Kapan model pohon benar-benar menang

Untuk menjawab ini dengan tegas, kita menjalankan percobaan terkendali: dua target buatan pada fitur yang sama persis, satu bersifat aditif dan satu memuat interaksi serta non-linearitas.

Kode – percobaan terkendali

```

from sklearn.preprocessing import StandardScaler
rng = np.random.default_rng(99)

X = df[['recency_hari', 'frekuensi_12bln', 'monetary_12bln',
        'tenure_bulan', 'aov', 'keteraturan']]
z = StandardScaler().fit_transform(X)

# Target A: ADITIF dalam log-odds – bentuk yang disukai model linear
lin = 0.9*z[:,0] - 0.8*z[:,1] - 0.3*z[:,5]

# Target B: INTERAKSI, ambang, dan non-linear
inter = (1.6*z[:,0]*z[:,1]                # interaksi dua fitur
         - 1.3*(z[:,2]>0.5)*(z[:,0]>0.5))  # interaksi dua ambang

```

```
+ 1.1*np.sin(2.2*z[:,3])          # hubungan bersilasi
- 1.4*(np.abs(z[:,4])>1))        # hubungan berbentuk U

for nama, lg in [("target ADITIF", lin), ("target INTERAKSI", inter)]:
    yy = rng.binomial(1, 1/(1+np.exp(-(lg - lg.mean()))))
    # ... latih regresi logistik dan XGBoost pada fitur yang SAMA
```

Output

Bentuk hubungan sebenarnya	logistik	XGBoost	selisih
ADITIF dalam log-odds	0.7656	0.7637	-0.0019
INTERAKSI & non-linear	0.6607	0.8021	+0.1414

■ TECHNICAL NOTE — ini jawaban paling jelas atas "model mana yang harus saya pakai"

Selisih 0,1414 versus -0,0019 adalah perbedaan tujuh puluh kali lipat, dan seluruhnya ditentukan oleh *bentuk hubungan dalam data*, bukan oleh kualitas algoritma.

Konsekuensi praktis yang dapat langsung dipakai:

1. Jalankan keduanya. Selalu. Biayanya beberapa menit, dan selisihnya memberi tahu sesuatu yang penting tentang data. Selisih besar berarti ada interaksi yang layak dipahami; selisih nol berarti hubungannya sederhana dan model linear sudah cukup.

2. Selisih itu sendiri adalah temuan. Bila boosting unggul jauh, langkah berikutnya bukan "pakai boosting", melainkan *cari tahu interaksi mana* — lewat partial dependence atau SHAP interaction (Bab 7). Interaksi yang ditemukan sering bernilai bisnis lebih besar daripada kenaikan AUC-nya, karena ia menunjukkan bahwa suatu kelompok berperilaku berbeda.

3. Jangan menyimpulkan dari satu dataset. Hasil "logistik menang" pada data TokoNusa adalah sifat data ini, bukan hukum umum. Pada data ritel nyata dengan perilaku musiman, promo, dan efek kanal, interaksi biasanya ada, dan boosting biasanya unggul 0,01–0,03 AUC.

HOW — menyetel gradient boosting

Hyperparameter	Rentang lazim	Peran dan cara memikirkannya
learning_rate	0,01 – 0,3	Kontribusi tiap pohon. Kecil = lebih akurat tetapi butuh lebih banyak pohon. Setel ini <i>bersama</i> <code>n_estimators</code> , tidak sendiri
n_estimators	100 – 2.000	Jumlah pohon. Gunakan early stopping alih-alih menebak
max_depth	3 – 8	Pengendali kompleksitas terkuat. Depth 3 menangkap interaksi dua arah; depth 6 menangkap enam arah dan mudah overfitting
subsample	0,6 – 1,0	Proporsi baris per pohon. Nilai < 1 memberi regularisasi dan mempercepat
colsample_bytree	0,6 – 1,0	Proporsi fitur per pohon. Berguna ketika fitur banyak dan berkorelasi
min_child_weight	1 – 20	Bobot minimum per daun. Naikkan bila overfitting
reg_lambda	0 – 10	Penalti L2 pada nilai daun. Jarang menentukan; naikkan bila perlu
scale_pos_weight	—	Untuk kelas tak seimbang. Hati-hati: merusak kalibrasi probabilitas (Bab 8–9)

Output – pengaruh kompleksitas terhadap overfitting

Konfigurasi	AUC train	AUC test	gap
depth 3, n 200, lr 0,10	0.8056	0.8000	+0.0055
depth 4, n 400, lr 0,05	0.8099	0.8000	+0.0099
depth 6, n 600, lr 0,05	0.8439	0.7970	+0.0469

Menaikkan kompleksitas menaikkan kinerja LATIH secara konsisten dan MENURUNKAN kinerja uji. Konfigurasi termurah menang.

✓ BEST PRACTICE – urutan penyetelan yang efisien

1. Tetapkan `learning_rate = 0,05` dan pakai EARLY STOPPING untuk menentukan `n_estimators`. Jangan menebak keduanya.
2. Setel `max_depth` (3, 4, 6) – pengendali terkuat.
3. Setel `min_child_weight` bila gap train-test masih besar.
4. Setel `subsample` dan `colsample` (0,7 / 0,8 / 1,0).
5. Berhenti. Sisanya jarang memberi lebih dari 0,002 AUC.

Gunakan random search, bukan grid search: pada ruang berdimensi tinggi, random search menemukan konfigurasi setara dengan jauh lebih sedikit percobaan.

Dan pemeriksaan yang menghemat paling banyak waktu: *sebelum menyetel apa pun, bandingkan dengan regresi logistik*. Bila selisihnya di bawah 0,005, penyetelan tidak akan mengubah kesimpulan.

Kode – early stopping, cara yang benar

```
# Bagi data latih lagi menjadi latih dan validasi untuk early stopping.
# Data UJI tidak boleh dipakai untuk ini (lihat Bab 2).
Xa, Xv, ya, yv = train_test_split(Xtr, ytr, test_size=0.2,
                                  random_state=1, stratify=ytr)

m = xgb.XGBClassifier(n_estimators=3000,          # batas atas yang longgar
                      learning_rate=0.05, max_depth=4,
                      subsample=0.8, colsample_bytree=0.8,
                      eval_metric='auc',
                      early_stopping_rounds=50, # berhenti bila 50 ronde tanpa perbaikan
                      random_state=42, n_jobs=-1)
m.fit(Xa, ya, eval_set=[(Xv, yv)], verbose=False)

print(f"pohon optimal: {m.best_iteration}") # bukan tebakan – hasil pengukuran
```

Memilih di antara ketiganya

Situasi	Pilihan	Alasan
Baseline pertama, apa pun masalahnya	Regresi logistik	Cepat, dapat dijelaskan, sering sudah cukup (Bab 5)
		Pohon depth 3–4 dapat digambar utuh di satu halaman

Butuh dijelaskan ke regulator	Logistik atau pohon dangkal	
Data tabular besar, kinerja utama	Gradient boosting	Biasanya terbaik pada data tabular; menangkap interaksi
Waktu penyetelan terbatas	Random forest	Jauh lebih toleran terhadap hyperparameter yang tidak optimal
Banyak kategorikal berkardinalitas tinggi	LightGBM / CatBoost	Menangani kategorikal secara native tanpa one-hot
Butuh probabilitas terkalibrasi	Logistik, atau boosting + kalibrasi	Boosting sering terlalu percaya diri (Bab 8)
Data sangat sedikit (< 1.000 baris)	Logistik dengan regularisasi	Model pohon akan menghafal

✗ COMMON MISTAKE — memakai `scale_pos_weight` lalu menghitung nilai harapan

Gejala: pada kelas tak seimbang, `scale_pos_weight` disetel agar model "lebih memperhatikan" kelas minoritas, lalu keluarannya dipakai untuk menghitung nilai harapan atau ambang optimal.

Mengapa merusak: pembobotan mengubah distribusi yang dipelajari model, sehingga probabilitas keluarannya *tidak lagi mencerminkan probabilitas sebenarnya*. Skor 0,60 mungkin sebenarnya berarti 0,08. Seluruh perhitungan nilai harapan di Bab 9 menjadi salah, dan kesalahannya tidak terlihat pada AUC — karena AUC hanya peduli pada urutan.

Perbaikan: jangan bobot ulang. Latih pada distribusi asli, lalu *atur ambangnya* (Bab 9). Ambang menyelesaikan masalah yang sama tanpa merusak kalibrasi. Bila pembobotan tetap dipakai karena alasan lain, kalibrasi ulang keluarannya sebelum dipakai dalam perhitungan biaya.

Cara senior menghindarinya: memeriksa kalibrasi (Bab 8) sebagai bagian rutin evaluasi, bukan hanya AUC. Kalibrasi yang rusak akan langsung terlihat di tabel bin prediksi.

Checklist model pohon dan boosting

- ✓ AUC latih dan AUC uji dilaporkan berdampingan, selalu
- ✓ Selisih train-test dinilai terhadap ambang praktis (0,01 / 0,05 / 0,15)
- ✓ Pohon tunggal selalu dibatasi kedalaman atau ukuran daun minimum
- ✓ Regresi logistik dijalankan sebagai pembanding wajib
- ✓ Selisih antara model linear dan model pohon ditafsirkan sebagai informasi tentang data
- ✓ Early stopping dipakai untuk menentukan jumlah pohon, bukan tebakan
- ✓ Data validasi untuk early stopping terpisah dari data uji
- ✓ Penyetelan mengikuti urutan prioritas dan berhenti ketika perbaikan di bawah 0,002
- ✓ `scale_pos_weight` dihindari bila probabilitas akan dipakai untuk perhitungan biaya
- ✓ Kalibrasi diperiksa, bukan hanya AUC

Ending Card — Bab 6

What you learned

Cara pohon keputusan membelah data dan sifat-sifatnya; demonstrasi kuantitatif overfitting dari selisih 0,0019 sampai 0,3746 beserta ambang praktis untuk menilainya; perbedaan bagging dan boosting secara mekanis dan tujuan; perbandingan lima model pada data churn yang menempatkan regresi logistik di posisi teratas; percobaan terkendali yang menunjukkan boosting kalah $-0,0019$ pada target aditif dan menang $+0,1414$ pada target dengan interaksi; delapan hyperparameter boosting dan perannya; urutan penyetelan yang efisien serta early stopping yang benar; tujuh situasi dan pilihan model untuk masing-masing; serta mengapa `scale_pos_weight` merusak perhitungan nilai harapan.

Skills mastered

Decision tree · random forest · gradient boosting · penyetelan hyperparameter berbasis prioritas · diagnosis overfitting · pemilihan keluarga model berbasis struktur data.

Real business value

Menjalankan model linear dan model pohon berdampingan memberi dua hal sekaligus: model terbaik, dan informasi tentang apakah data memiliki interaksi yang layak dipahami. Yang kedua sering lebih bernilai — ia menunjukkan bahwa suatu kelompok pelanggan berperilaku berbeda, dan itu dapat langsung ditindaklanjuti.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagging versus boosting?" — varians versus bias; pohon dalam versus dangkal; paralel versus berurutan.
2. "AUC latih 1,00 dan uji 0,63. Apa yang terjadi?" — overfitting total; jelaskan mekanismenya pada pohon.
3. "Kapan XGBoost tidak mengalahkan regresi logistik?" — ketika hubungan aditif; tunjukkan percobaan terkendali.
4. "Hyperparameter mana yang kamu setel lebih dulu?" — learning rate dengan early stopping, lalu `max_depth`.
5. "Kelas kami 2% positif. Pakai `scale_pos_weight`?" — tidak bila probabilitas dipakai untuk keputusan; atur ambang.
6. "Boosting kamu unggul 0,04 AUC. Apa langkah berikutnya?" — cari interaksinya, bukan langsung memakai modelnya.

Exercises

Exercise 6.1 (Beginner · 45 menit)

Objective: mendiagnosis overfitting

Latih pohon keputusan pada data TokoNusa dengan `max_depth` = 2, 3, 5, 8, 12, dan tanpa batas. Untuk masing-masing catat AUC latih, AUC uji, selisihnya, dan jumlah daun.

(a) Buat tabelnya. (b) Pada kedalaman berapa selisih melewati 0,05? (c) Berapa jumlah daun pada titik itu? (d) Apa hubungan antara jumlah daun dan jumlah baris latih yang menjelaskan gejala ini?

Answer key 6.1

(d) Ini bagian yang paling menjelaskan. Jumlah daun menentukan berapa banyak "aturan" yang dihafal model. Ketika rata-rata baris per daun turun di bawah sekitar 20-50, setiap daun mulai menggambarkan kekhususan beberapa pelanggan alih-alih pola.

Rasio yang berguna dipantau: $\text{baris latih} \div \text{jumlah daun}$. Di atas 100 biasanya aman; di bawah 20 hampir selalu overfitting. Ini penjelasan yang sama dengan rasio baris-terhadap-fitur pada Bab 5, hanya dalam bentuk yang sesuai untuk model pohon — dan ia menjelaskan mengapa `min_samples_leaf` sering lebih efektif daripada `max_depth` untuk mengendalikan kompleksitas.

Exercise 6.2 (Intermediate · 90 menit)

Objective: percobaan terkendali sendiri

Rancang percobaanmu sendiri untuk menjawab: seberapa banyak interaksi yang dibutuhkan sebelum boosting mengungguli regresi logistik secara berarti?

(a) Buat lima target buatan dengan proporsi sinyal interaksi 0%, 25%, 50%, 75%, 100%. (b) Untuk masing-masing, latih kedua model dan catat selisih AUC. (c) Plot selisih terhadap proporsi interaksi. (d) Pada proporsi berapa selisihnya melewati 0,01?

Answer key 6.2

Bentuk kurva yang biasanya muncul: selisih tetap mendekati nol sampai proporsi interaksi sekitar 20-30%, lalu naik hampir linear. Ini berarti sinyal interaksi kecil *tidak* membenarkan perpindahan model.

Nilai praktis dari latihan ini: ia memberi kamu intuisi terkalibrasi tentang berapa selisih AUC yang "berarti". Ketika kelak kamu melihat boosting unggul 0,004 pada data nyata, kamu akan tahu bahwa itu kemungkinan besar derau, bukan interaksi. Dan ketika unggul 0,05, kamu akan tahu ada struktur yang layak dicari.

Exercise 6.3 (Advanced · 2,5 jam)

Objective: penyetelan yang disiplin

Setel XGBoost pada data TokoNusa dengan anggaran 40 percobaan menggunakan random search dan validasi silang 5-fold.

(a) Catat konfigurasi terbaik dan AUC validasinya. (b) Bandingkan dengan konfigurasi default. (c) Hitung berapa AUC yang diperoleh per jam waktu komputasi. (d) Bandingkan dengan nilai yang diperoleh dari mengatur ambang keputusan dengan benar (Bab 9 — Rp 0,28 miliar dari perubahan yang memakan waktu lima menit). (e) Tulis rekomendasi alokasi waktu untuk tim.

Answer key 6.3 — kerangka jawaban

(a)–(b) Pada data ini, 40 percobaan random search biasanya memberi perbaikan di bawah 0,002 AUC dibandingkan konfigurasi yang sudah masuk akal. Hasil "tidak ada perbaikan berarti" adalah hasil yang sah dan harus dilaporkan apa adanya.

(d)–(e) Inilah inti latihan. Penyetelan menghabiskan berjam-jam komputasi dan waktu analyst untuk 0,002 AUC yang dampak bisnisnya mendekati nol. Mengatur ambang dari 0,50 ke nilai optimal memakan waktu lima menit dan bernilai Rp 0,28 miliar per tahun; mengganti dasar targeting dari skor churn ke uplift (Bab 10) bernilai Rp 5,20 miliar.

Rekomendasi alokasi waktu yang dapat dipertahankan: *satu hari untuk model, satu minggu untuk rantai keputusan dan pengukuran*. Kandidat yang menuliskan ini dalam wawancara menunjukkan pemahaman yang jarang dimiliki.

Portfolio idea

★ PORTFOLIO TIP

Percobaan terkendali dari Exercise 6.2, disajikan sebagai satu grafik "selisih AUC versus proporsi interaksi", adalah artefak yang menunjukkan cara berpikir eksperimental terhadap pemodelan. Ia juga menjawab pertanyaan wawancara yang sangat umum dengan bukti, bukan opini.

Further reading

Chen & Guestrin, "XGBoost: A Scalable Tree Boosting System" · Hastie, Tibshirani & Friedman, *The Elements of Statistical Learning* bab 10 dan 15 · Grinsztajn dkk., "Why do tree-based models still outperform deep learning on tabular data?" · Dokumentasi XGBoost tentang penyetelan parameter.

Next chapter

Bab 7 — interpretasi model. Termasuk temuan yang mengganggu: dua metode "pentingnya fitur" pada model yang sama memberi peringkat teratas yang berbeda, dan hanya salah satunya yang menjawab pertanyaan yang biasanya dimaksud.

Bab 7 — Interpretasi Model

Dua metode "pentingnya fitur" pada model yang sama memberi jawaban berbeda — dan hanya satu yang menjawab pertanyaan yang dimaksud

Learning objectives

Membedakan tiga jenis pentingnya fitur dan pertanyaan yang dijawab masing-masing; menghitung dan menafsirkan permutation importance; menggunakan SHAP untuk penjelasan global dan per individu; membaca partial dependence dengan benar; mengenali jebakan penafsiran pada fitur berkorelasi; menyajikan interpretasi tanpa mengundang kesimpulan kausal

Prerequisites

Bab 1 (prediksi vs kausalitas), Bab 5–6

Estimasi waktu

Baca 2,5 jam · Praktik 4 jam

Difficulty

● **Advanced**

Skills covered

Feature importance, permutation importance, SHAP, partial dependence, komunikasi hasil model

Business domain

Retail omnichannel — menjelaskan model churn kepada CRM dan direksi

Temuan yang membuka bab ini

Model yang sama. Data yang sama. Dua metode standar untuk mengukur pentingnya fitur. Hasilnya:

Output – XGBoost gain versus permutation importance, model churn yang identik

XGBoost "gain" (perbaikan saat fitur dipakai)

1. anggota_tier	551.6
2. frekuensi_12bln	270.3
3. recency_hari	145.8
4. pernah_terlambat	125.5
5. skor_loyalitas	100.1
6. n_keluhan	66.9
7. keteraturan	65.5
8. n_keterlambatan	31.9

Permutation importance (penurunan AUC saat fitur diacak)

1. recency_hari	0.0783
2. frekuensi_12bln	0.0611
3. keteraturan	0.0316
4. n_keluhan	0.0093
5. pernah_terlambat	0.0076
6. skor_loyalitas	0.0027
7. monetary_12bln	0.0022
8. metode_bayar_ewallet	0.0012

Fitur teratas menurut gain (anggota_tier) TIDAK MASUK delapan besar menurut permutation importance.

⚠ **WARNING** — kedua tabel benar, dan keduanya menjawab pertanyaan yang berbeda

Ini bukan bug. Kedua metode mengukur hal yang berbeda, dan perbedaannya sistematis.

Gain mengukur seberapa besar perbaikan yang diperoleh *ketika model memilih fitur itu untuk membelah*. Fitur biner dengan pemisahan tajam seperti `anggota_tier` memberi perbaikan besar per pembelahan, sehingga gain-nya tinggi — meskipun informasinya sebagian besar sudah tersedia dari `skor_loyalitas` (tier ditentukan oleh skor ≥ 700).

Permutation importance mengukur seberapa banyak kinerja model *hilang* ketika fitur itu diacak. Karena informasi tier masih dapat direkonstruksi dari skor loyalitas, mengacak tier hampir tidak merugikan — dan importance-nya jatuh.

Pertanyaan yang dijawab masing-masing:

```
Gain          : "Fitur mana yang PALING SERING BERGUNA
                  saat model membangun dirinya?"
Permutation    : "Fitur mana yang KEHILANGANNYA PALING MERUGIKAN?"
```

Untuk hampir semua pertanyaan bisnis — data apa yang wajib tersedia, fitur mana yang harus dipantau kualitasnya, integrasi mana yang layak dipertahankan — **permutation importance yang benar**. Gain berguna untuk memahami mekanika model, bukan untuk keputusan.

WHAT — tiga jenis pentingnya fitur

Metode	Cara kerja	Kekuatan dan batas
Bawaan model (gain, split count, koefisien)	Dihitung dari struktur model saat pelatihan	Gratis, cepat. Bias terhadap fitur berkardinalitas tinggi; menyesatkan pada fitur berkorelasi; tidak dapat dibandingkan antar jenis model
Permutation	Acak satu kolom, ukur penurunan metrik pada data uji	Dapat dibandingkan antar model; memakai metrik yang kamu pilih. Meremehkan fitur yang berkorelasi; mahal secara komputasi
SHAP	Membagi prediksi menjadi kontribusi tiap fitur berdasarkan teori permainan	Konsisten secara matematis; memberi penjelasan <i>per individu</i> . Mahal; mudah disalahtafsirkan sebagai kausal

Kode — menghitung ketiganya

```
import numpy as np
import pandas as pd
import xgboost as xgb
from sklearn.inspection import permutation_importance

# 1. BAWAAN MODEL — gratis, tetapi hati-hati menafsirkannya
gain = pd.Series(model.get_booster().get_score(importance_type='gain'))
print(gain.sort_values(ascending=False).head(8))

# 2. PERMUTATION — pada data UJI, dengan metrik yang kita pilih
# n_repeats > 1 karena pengacakan bersifat acak; kita butuh rata-rata
pi = permutation_importance(model, Xte, yte,
                           n_repeats=5,          # 5 pengacakan per fitur
                           scoring='roc_auc',     # metrik yang RELEVAN untuk keputusan
                           random_state=42, n_jobs=-1)
imp = pd.Series(pi.importances_mean, index=Xte.columns)
sd = pd.Series(pi.importances_std, index=Xte.columns)
```

```
print(pd.DataFrame({'penurunan_auc': imp, 'sd': sd})
      .sort_values('penurunan_auc', ascending=False).head(8).round(4))

# 3. SHAP — memakai perhitungan native XGBoost (jauh lebih cepat)
dm = xgb.DMatrix(Xte.iloc[:5000].astype(float))
contrib = model.get_booster().predict(dm, pred_contribs=True)
sv = contrib[:, :-1]      # kolom terakhir = base value
base = contrib[0, -1]     # log-odds dasar, sama untuk semua baris

shap_global = pd.Series(np.abs(sv).mean(0), index=Xte.columns)
print(shap_global.sort_values(ascending=False).head(8).round(4))
```

Output — mean |SHAP| (satuan: log-odds)

recency_hari	0.5514
frekuensi_12bln	0.5156
keteraturan	0.3434
n_keluhan	0.1991
pernah_terlambat	0.1907
skor_loyalitas	0.1223
monetary_12bln	0.0839
metode_bayar_ewallet	0.0601

base value (log-odds) -0.2360 → probabilitas dasar 0,441

■ TECHNICAL NOTE — mengapa SHAP dan permutation sepakat di sini, dan gain tidak

Peringkat SHAP dan permutation importance hampir identik: recency, frekuensi, keteraturan di tiga besar pada keduanya. Gain memberi urutan yang berbeda.

Penyebabnya: SHAP dan permutation keduanya menilai *pengaruh terhadap keluaran*, sementara gain menilai *kegunaan saat membangun struktur*. Ketika dua metode yang mengukur pengaruh keluaran sepakat, keyakinan terhadap peringkatnya naik.

Aturan praktis yang berguna: **hitung dua metode, laporkan yang sepakat, dan selidiki yang tidak**. Ketidakepakatan besar hampir selalu menunjuk pada fitur yang redundan — dan fitur redundan adalah kandidat pertama untuk dibuang demi menyederhanakan pemeliharaan.

HOW — SHAP untuk penjelasan per individu

Kekuatan SHAP yang tidak dimiliki metode lain: ia menguraikan *satu prediksi* menjadi kontribusi tiap fitur, dengan jaminan bahwa kontribusinya berjumlah tepat sama dengan selisih prediksi terhadap nilai dasar.

SIFAT ADITIF SHAP

$$\text{prediksi}(x) = \text{base_value} + \sum \text{shap}_j(x)$$

Pada model churn ini:

base value = -0,2360 log-odds (probabilitas 0,441)

Untuk satu pelanggan dengan prediksi log-odds +1,60:

$$-0,2360 + (\text{jumlah seluruh kontribusi SHAP}) = +1,60$$

Jaminan ini yang membuat SHAP dapat dipakai untuk menjelaskan keputusan kepada orang yang terdampak — tidak ada bagian prediksi yang tidak terjelaskan.

Output – kontribusi rata-rata fitur keterlambatan, dipisah menurut nilainya

```
SHAP rata-rata untuk pernah_terlambat:
pelanggan yang PERNAH terlambat : +0.2606 log-odds
pelanggan yang TIDAK pernah    : -0.1515 log-odds
-----
selisih                          0.4121 log-odds
```

⚠ **WARNING** — angka 0,4121 log-odds ini bukan efek dari memperbaiki SLA

Selisih 0,4121 log-odds pada probabilitas dasar 0,441 setara dengan sekitar **+10 pp** perbedaan probabilitas churn antara kedua kelompok — menurut model.

Angka itu akan sangat menggoda untuk dipakai dalam proposal perbaikan SLA. Dan ia salah untuk tujuan itu. Efek kausal sebenarnya pada dataset ini adalah **4,00 pp** (Bab 1). SHAP menguraikan bagaimana model membentuk prediksinya; ia tidak dan tidak dapat mengetahui bahwa sebagian besar asosiasi itu berasal dari confounder yang tidak terukur.

Ini adalah kesalahpahaman paling umum tentang SHAP, dan ia menyebar luas justru karena visualisasinya sangat meyakinkan. Grafik SHAP terlihat seperti diagram sebab-akibat, dan tidak ada apa pun dalam alatnya yang memperingatkan bahwa ia bukan.

Aturan yang harus dipegang: SHAP menjawab "mengapa *model* memberi skor ini", bukan "mengapa pelanggan ini akan berhenti". Kedua kalimat itu terdengar mirip dan berbeda secara mendasar.

Menyajikan penjelasan yang tidak mengundang salah tafsir

SATU HALAMAN UNTUK TIM CRM – struktur yang bekerja

Pelanggan #10482	Skor risiko: 0,83 (desil 1)
MENGAPA MODEL MENILAI TINGGI	
■ 306 hari sejak pembelian terakhir	(pendorong 1)
■ pola belanja tidak teratur	(pendorong 2)
■ 1 keluhan dalam 6 bulan terakhir	(pendorong 3)
YANG MENAHAN SKOR	
■ 8 pembelian dalam 12 bulan – pelanggan yang dulu aktif	
■ nilai belanja di atas rata-rata	
TINDAKAN YANG TERBUKTI EFEKTIF UNTUK PROFIL INI	
win-back dengan tawaran kategori favorit	
uplift terukur: +16,2 pp (desil 3, eksperimen Q3)	
CATATAN: pendorong di atas menjelaskan skor model.	
Mereka BUKAN penyebab, dan mengubahnya belum tentu	
mengubah perilaku. Tindakan di atas dipilih berdasarkan	
uplift terukur, bukan berdasarkan pendorong skor.	

► EXECUTIVE PERSPECTIVE — paragraf catatan itu adalah bagian terpenting

Tanpa paragraf terakhir, dokumen di atas akan segera berubah menjadi rencana tindakan: "pelanggan ini mengeluh, mari perbaiki penanganan keluhan". Perpindahan dari *pendorong skor* ke *rencana intervensi* terjadi hampir otomatis di ruang rapat, dan hampir tidak pernah dipertanyakan.

Menuliskan catatan itu terasa berlebihan sampai kamu melihat berapa kali ia diperlukan. Dan ia bukan sekadar peringatan hukum: ia mengarahkan perhatian ke tempat yang benar, yaitu *tindakan mana yang uplift-nya sudah terukur*.

Perhatikan bahwa dokumen di atas memuat dua jenis angka dari dua dunia yang berbeda: skor dari model prediktif (volume ini) dan uplift dari eksperimen (Volume 4). Itulah bentuk yang benar. Model memberi tahu *siapa*; eksperimen memberi tahu *apa yang berhasil*.

Partial dependence: bentuk hubungan menurut model

Kode — partial dependence dan ICE

```
from sklearn.inspection import PartialDependenceDisplay

# PDP: rata-rata prediksi ketika satu fitur digeser ke berbagai nilai,
# dengan fitur lain dipertahankan seperti apa adanya di data.
# kind='both' menampilkan PDP (rata-rata) DAN ICE (garis per individu).
PartialDependenceDisplay.from_estimator(
    model, Xte.sample(2000, random_state=1),
    features=['recency_hari', 'frekuensi_12bln',
              ('recency_hari', 'frekuensi_12bln')], # pasangan = interaksi
    kind='both')
```

Alat	Yang ditampilkan	Kapan menyesatkan
PDP	Rata-rata prediksi sebagai fungsi satu fitur	Ketika efeknya berlawanan arah pada subkelompok berbeda, rata-ratanya bisa datar dan menyembunyikan keduanya
ICE	Satu garis per individu	Jarang menyesatkan; gunakan berdampingan dengan PDP untuk melihat keragaman
PDP dua fitur	Permukaan interaksi	Sulit dibaca bila keduanya berkorelasi kuat
ALE	Efek lokal terakumulasi	Lebih andal daripada PDP pada fitur berkorelasi; pilihan yang lebih baik bila korelasi tinggi

✗ COMMON MISTAKE — PDP pada fitur yang sangat berkorelasi

Gejala: PDP untuk `monetary_12bln` dibuat dengan menggeser nilainya dari Rp 100 ribu sampai Rp 20 juta, sementara `frekuensi_12bln` dan `aov` dibiarkan apa adanya.

Mengapa merusak: $\text{monetary} = \text{frekuensi} \times \text{AOV}$. Menggeser `monetary` tanpa mengubah keduanya menciptakan pelanggan yang *tidak mungkin ada* — misalnya frekuensi 2, AOV Rp 300 ribu, `monetary` Rp 20 juta. Model diminta memprediksi untuk kombinasi yang tidak pernah dilihatnya, dan hasilnya tidak bermakna.

Perbaikan: gunakan ALE (accumulated local effects), yang hanya menggeser fitur dalam rentang lokal yang realistis. Atau buang fitur redundan sebelum interpretasi.

Cara senior menghindarinya: memeriksa matriks korelasi sebelum membuat PDP apa pun, dan menandai pasangan dengan korelasi di atas 0,7 sebagai "jangan dibuat PDP-nya secara terpisah". Ini pemeriksaan lima menit yang mencegah grafik yang salah masuk ke presentasi direksi.

Interpretasi untuk tiga audiens berbeda

Audiens	Yang mereka butuhkan	Bentuk penyajian
Tim eksekusi (CRM, operasi)	Mengapa orang ini, dan apa yang harus dilakukan	Kartu per individu: 3 pendorong, 2 penahan, tindakan dengan uplift terukur
Manajemen	Apakah model masuk akal dan aman dipakai	Permutation importance, bentuk hubungan fitur utama, kinerja per segmen, batas penggunaan
Audit / risiko	Dapatkah keputusan dipertanggungjawabkan	Dokumentasi fitur, penjelasan per keputusan, uji keadilan antar kelompok (Bab 14), jejak versi model

✓ **BEST PRACTICE — satu kalimat yang wajib ada di setiap keluaran interpretasi**

Baik grafik SHAP, tabel importance, maupun PDP, semuanya menjawab pertanyaan yang sama: *bagaimana model ini membentuk prediksinya?*

Kalimat yang wajib menyertainya:

"Diagram ini menjelaskan perilaku model, bukan perilaku pelanggan. Untuk mengetahui apa yang terjadi bila kita mengubah sesuatu, diperlukan eksperimen atau analisis kausal."

Satu kalimat, sebelas detik untuk dibaca, dan ia mencegah kelas kesalahan yang pada kasus SLA di Bab 1 bernilai Rp 21 miliar selisih penilaian.

Checklist interpretasi model

- ✓ Minimal dua metode importance dihitung; ketidaksepakatan diselidiki
- ✓ Permutation importance dipakai untuk keputusan tentang data dan pemantauan
- ✓ Permutation dijalankan pada data uji, dengan metrik yang relevan, $n_repeats > 1$
- ✓ Fitur berkorelasi diidentifikasi sebelum interpretasi apa pun
- ✓ PDP dihindari pada fitur berkorelasi; ALE dipakai sebagai gantinya
- ✓ ICE ditampilkan berdampingan dengan PDP untuk melihat keragaman
- ✓ SHAP dipakai untuk penjelasan per individu, bukan untuk klaim kausal
- ✓ Kalimat pembatas kausal disertakan pada setiap keluaran interpretasi
- ✓ Kartu penjelasan per individu memuat tindakan dengan uplift terukur, bukan pendorong skor
- ✓ Penyajian disesuaikan dengan audiens: eksekusi, manajemen, atau audit

Ending Card — Bab 7

What you learned

Demonstrasi bahwa gain dan permutation importance memberi peringkat teratas yang berbeda pada model yang sama, beserta penjelasan mekanismenya lewat redundansi tier dan skor loyalitas; tiga jenis pentingnya fitur dan pertanyaan yang dijawab masing-masing; cara menghitung ketiganya dengan kode; mengapa SHAP dan permutation sepakat sementara gain tidak; sifat aditif SHAP dan mengapa ia memungkinkan penjelasan per individu; peringatan bahwa selisih SHAP 0,4121 log-odds bukan efek kausal 4,00 pp; struktur kartu penjelasan untuk tim eksekusi termasuk paragraf pembatas yang wajib; partial dependence, ICE, dan ALE beserta kapan masing-masing menyesatkan; serta penyesuaian penyajian untuk tiga audiens.

Skills mastered

Permutation importance · SHAP global dan per individu · partial dependence dan ALE · komunikasi hasil model tanpa mengundang klaim kausal.

Real business value

Memakai permutation importance alih-alih gain mengubah daftar "data yang wajib dijaga kualitasnya" secara mendasar — pada kasus ini, fitur yang menempati posisi pertama menurut gain ternyata dapat diacak tanpa kerugian berarti. Menjaga kualitas data untuk fitur yang salah adalah biaya berulang yang tidak menghasilkan apa pun.

Interview readiness

● INTERVIEW QUESTIONS

1. "Dua metode importance memberi jawaban berbeda. Mana yang dipakai?" — tergantung pertanyaannya; jelaskan keduanya dengan contoh.
2. "SHAP menunjukkan keterlambatan berkontribusi besar. Berapa yang layak kita investasikan?" — jebakan kausal; rujuk Volume 4.
3. "Apa kelemahan permutation importance?" — meremehkan fitur berkorelasi; mahal; bergantung pada metrik yang dipilih.
4. "Kapan PDP menyesatkan?" — fitur berkorelasi; efek berlawanan arah antar subkelompok; pakai ALE dan ICE.
5. "Bagaimana kamu menjelaskan skor ke pelanggan yang komplain?" — SHAP per individu dengan kalimat pembatas; rujuk juga Bab 14.
6. "Fitur teratas kamu adalah recency. Rekomendasimu?" — recency adalah gejala; rekomendasi harus berasal dari uplift terukur.

Exercises

Exercise 7.1 (Beginner · 40 menit)

Objective: membandingkan metode importance

Untuk model churn TokoNusa, hitung: (a) gain; (b) permutation importance dengan metrik AUC; (c) permutation importance dengan metrik Brier score; (d) mean |SHAP|.

Bandingkan keempat peringkat. (e) Mengapa (b) dan (c) bisa berbeda? (f) Mana yang akan kamu pakai untuk memutuskan sistem data mana yang wajib dipantau, dan mengapa?

Answer key 7.1

(e) AUC hanya peduli pada *urutan*; Brier peduli pada *nilai probabilitasnya*. Fitur yang menggeser seluruh skor ke atas atau ke bawah tanpa mengubah urutan akan tampak tidak penting menurut AUC dan penting menurut Brier. Bila keluaran model akan dipakai untuk menghitung nilai harapan (Bab 9), Brier lebih relevan.

(f) Permutation importance dengan metrik yang sesuai penggunaan sebenarnya. Alasannya langsung: pertanyaannya adalah "apa yang terjadi bila data ini rusak atau tidak tersedia", dan permutation adalah simulasi persis dari kejadian itu. Gain tidak menjawab pertanyaan itu sama sekali.

Exercise 7.2 (Intermediate · 90 menit)

Objective: menemukan interaksi dari SHAP

Gunakan SHAP interaction values (atau bandingkan SHAP fitur A pada subkelompok berbeda dari fitur B) untuk mencari interaksi pada model churn.

(a) Apakah efek recency berbeda antara anggota tier dan bukan? (b) Apakah efek keterlambatan berbeda antar wilayah? (c) Bandingkan temuanmu dengan hasil Exercise 5.2 yang menguji interaksi secara eksplisit pada model linear. (d) Apakah keduanya konsisten?

Answer key 7.2

(d) Keduanya seharusnya konsisten, dan pada data ini keduanya menunjukkan interaksi yang lemah. Bila SHAP menunjukkan interaksi kuat sementara menambahkan suku interaksi pada model linear tidak menaikkan AUC, salah satunya keliru — dan penyebab paling umum adalah SHAP menangkap struktur yang muncul dari korelasi antar fitur, bukan interaksi sejati.

Pelajaran metodologisnya penting: **gunakan dua pendekatan yang tidak berbagi asumsi**. Interaksi yang muncul pada keduanya layak dipercaya dan layak diselidiki secara bisnis; yang hanya muncul pada satu, layak diperlakukan sebagai hipotesis.

Exercise 7.3 (Advanced · 2,5 jam)

Objective: paket interpretasi untuk tiga audiens

Bangun tiga keluaran dari model yang sama: (a) kartu penjelasan per individu untuk tim CRM (maksimal setengah halaman, memuat tindakan dengan uplift terukur); (b) ringkasan model untuk manajemen (satu halaman: importance, bentuk hubungan, kinerja per segmen, batas penggunaan); (c) dokumen audit (definisi fitur, uji keadilan antar kelompok, jejak versi, prosedur penjelasan keputusan individual). Pastikan ketiganya konsisten dan tidak ada yang mengundang kesimpulan kausal.

Answer key 7.3 — rubrik

Kartu (a) yang kuat memisahkan dengan jelas dua sumber informasi: skor dan pendorongnya berasal dari model; tindakan dan uplift-nya berasal dari eksperimen. Kartu yang lemah menyarankan tindakan yang "sesuai" dengan pendorong skor — misalnya menyarankan perbaikan layanan karena keluhan muncul sebagai pendorong. Itu persis kesalahan yang bab ini cegah.

Ringkasan (b) yang kuat memuat bagian *batas penggunaan*: untuk siapa model tidak boleh dipakai (misalnya pelanggan dengan tenure di bawah tiga bulan, yang datanya terlalu sedikit), dan kapan model harus dievaluasi ulang.

Dokumen (c) yang kuat memuat prosedur konkret untuk menjawab pertanyaan individual — bukan pernyataan bahwa model "dapat dijelaskan", melainkan langkah yang benar-benar dijalankan bila seseorang bertanya mengapa ia menerima perlakuan tertentu.

Portfolio idea

★ PORTFOLIO TIP

Tabel perbandingan gain versus permutation importance dari bab ini, dengan penjelasan mengapa keduanya berbeda pada dataset kamu sendiri, adalah artefak singkat yang langsung menunjukkan kedalaman pemahaman. Sedikit kandidat yang dapat menjelaskan ketidaksepakatan itu dengan mekanismenya.

Further reading

Molnar, *Interpretable Machine Learning* — rujukan paling lengkap dan tersedia bebas · Lundberg & Lee, "A Unified Approach to Interpreting Model Predictions" (SHAP) · Apley & Zhu tentang ALE · Dokumentasi scikit-learn tentang *inspection*.

Next chapter

Bab 8 — validasi dan metrik: cross-validation, ROC versus PR pada kelas tak seimbang, dan kalibrasi. Termasuk kasus di mana model dengan akurasi 98,2% hanya menemukan 19 dari 1.110 kasus yang dicarinya.

Bab 8 — Validasi dan Metrik

Cross-validation, ROC versus PR, dan kalibrasi — memilih metrik yang menjawab pertanyaan yang benar

Learning objectives	Merancang skema validasi yang sesuai struktur data; membaca confusion matrix dan seluruh metrik turunannya; memilih antara ROC-AUC dan PR-AUC berdasarkan keseimbangan kelas; memahami dan mengukur kalibrasi probabilitas; menilai stabilitas hasil lintas fold; melaporkan kinerja model secara jujur
Prerequisites	Bab 2 (split), Bab 4–6; Vol 2 Bab 4 (sampling dan ketidakpastian)
Estimasi waktu	Baca 3 jam · Praktik 5 jam
Difficulty	● Advanced
Skills covered	Cross-validation, confusion matrix, precision/recall/F1, ROC-AUC, PR-AUC, kalibrasi, Brier score
Business domain	Retail omnichannel — churn (seimbang) dan penyalahgunaan promo (sangat tak seimbang)

Bagian I — Validasi

K-FOLD CROSS-VALIDATION (k = 5)

```
fold 1 [ UJI ][      LATIH      ]
fold 2 [  ][ UJI ][      LATIH      ]
fold 3 [    ][ UJI ][      LATIH      ]
fold 4 [      ][ UJI ][      LATIH      ]
fold 5 [      LATIH      ][ UJI ]
```

Setiap baris dipakai sebagai uji tepat satu kali.
Hasil: k estimasi kinerja -> rata-rata DAN sebarannya.

VARIAN YANG PERLU DIKETAHUI

StratifiedKFold	proporsi kelas dijaga di tiap fold	◀ default klasifikasi
GroupKFold	satu entitas tidak terpecah	◀ ada baris berulang
TimeSeriesSplit	hanya melatih pada masa lalu	◀ deret waktu
RepeatedKFold	diulang beberapa kali; estimasi lebih stabil	

Kode — cross-validation dan membaca sebarannya

```
from sklearn.model_selection import StratifiedKFold, cross_val_score

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

skor = cross_val_score(model, Xtr, ytr, cv=cv,
                        scoring='roc_auc', # metrik yang sudah ditetapkan di muka
                        n_jobs=-1)

print(f"AUC per fold : {' '.join(f'{s:.4f}' for s in skor)}")
print(f"rata-rata      : {skor.mean():.4f}")
print(f"simpangan      : {skor.std():.4f}")
print(f"rentang         : {skor.max() - skor.min():.4f}")
```

Output

AUC per fold : 0.8022, 0.8043, 0.8026, 0.7975, 0.7986
rata-rata : 0.8010
simpangan : 0.0026
rentang : 0.0068

◆ BUSINESS INSIGHT — sebaran fold adalah alat pengambil keputusan, bukan sekadar catatan teknis

Simpangan 0,0026 memberi informasi yang jauh lebih berguna daripada rata-rata 0,8010: ia memberi tahu **berapa besar perbedaan yang layak dianggap nyata**.

Bila model B mencapai 0,8035 dan model A 0,8010, selisihnya 0,0025 — kurang dari satu simpangan baku antar fold. Selisih itu tidak dapat dibedakan dari derau. Memilih model B dan mengumumkannya sebagai perbaikan adalah kesalahan yang setara dengan melaporkan hasil eksperimen yang tidak signifikan sebagai kemenangan (Vol 4 Bab 5).

Aturan praktis yang layak dipakai tim: **selisih di bawah dua simpangan baku antar fold diperlakukan sebagai seri**. Ketika dua model seri, pilih yang lebih sederhana, lebih cepat, dan lebih mudah dijelaskan — kriteria dari tabel biaya kompleksitas di Bab 5.

Rentang yang lebar (misalnya di atas 0,05) adalah sinyal berbeda dan lebih serius: ia berarti kinerja model sangat bergantung pada data mana yang kebetulan masuk ke pelatihan. Model seperti itu belum siap dipakai, berapa pun rata-ratanya.

Bagian II — Confusion matrix dan metrik turunannya

		PREDIKSI		
		positif	negatif	
A K T U A L	positif	TP benar	FN terlewat	→ recall = $TP/(TP+FN)$
	negatif	FP salah alarm	TN benar	→ specificity = $TN/(TN+FP)$
		↓		
		precision = $TP/(TP+FP)$		

PRECISION "Dari yang kita tandai, berapa yang benar?"
→ biaya FALSE POSITIVE (usaha terbuang)

RECALL "Dari yang seharusnya ditemukan, berapa yang kita dapat?"
→ biaya FALSE NEGATIVE (peluang hilang)

F1 rata-rata harmonik precision dan recall
→ HANYA masuk akal bila kedua biaya kira-kira SAMA.
Pada hampir semua masalah bisnis, keduanya TIDAK sama.

Output — model churn TokoNusa pada ambang default 0,50

	Prediksi churn	Prediksi bertahan		
Aktual churn	17.182	9.331	recall	0,648
Aktual bertahan	7.274	26.213	specificity	0,783
precision	0,703			

akurasi 0,7232 · F1 0,6742 · AUC 0,8000 · PR-AUC 0,7633 · Brier 0,1802

⚠ **WARNING — F1 menyembunyikan keputusan yang seharusnya dibuat secara sadar**

F1 memperlakukan satu pelanggan yang terlewat sama buruknya dengan satu kontak yang sia-sia. Pada kasus TokoNusa, kedua kesalahan itu berbiaya sangat berbeda:

```
False negative : pelanggan churn tanpa dihubungi
                  → kehilangan CLV × uplift = Rp 94.172
False positive : menghubungi pelanggan yang tidak akan churn
                  → biaya kontak           = Rp 42.000

Rasio biaya: 2,24 : 1
```

Metrik yang memperlakukan keduanya sama akan mengarahkan ke ambang yang salah. Yang benar bukan mengoptimalkan F1, melainkan menghitung ambang dari rasio biaya — dan itulah isi Bab 9.

Gunakan F1 hanya dalam satu situasi: ketika membandingkan model pada tahap awal dan biaya sebenarnya belum diketahui. Begitu biayanya diketahui, F1 tidak lagi berguna.

Bagian III — ROC-AUC versus PR-AUC

KURVA ROC
sumbu x: false positive rate = $FP/(FP+TN)$
sumbu y: recall = $TP/(TP+FN)$

KURVA PRECISION-RECALL
sumbu x: recall
sumbu y: precision

PERBEDAAN YANG MENENTUKAN:

ROC memakai TN di penyebutnya. Pada kelas sangat tak seimbang, TN sangat besar, sehingga penambahan FP hampir tidak menggeser sumbu x. ROC tetap terlihat bagus meskipun sebagian besar yang ditandai model adalah salah alarm.

PR TIDAK memakai TN sama sekali. Ia langsung menunjukkan berapa proporsi tandaan yang benar.

GARIS DASAR (model acak):
ROC-AUC = 0,5 selalu
PR-AUC = prevalensi kelas positif ◀ berubah per masalah

Output — dua masalah pada data yang sama

Masalah	Prevalensi	ROC-AUC	PR-AUC	PR-AUC acak
churn 180 hari	44,19%	0.8000	0.7633	0.4419
penyalahgunaan promo	1,85%	0.7844	0.1271	0.0185

Pada masalah kedua, ROC-AUC 0,7844 terdengar layak.
PR-AUC 0,1271 menunjukkan gambaran sebenarnya.

■ TECHNICAL NOTE — cara membaca PR-AUC 0,1271 dengan benar

Angka mutlak PR-AUC tidak dapat dibandingkan antar masalah, karena garis dasarnya berbeda. Yang bermakna adalah rasionya terhadap prevalensi:

```
churn      : 0,7633 / 0,4419 = 1,73 kali garis dasar
abuse promo : 0,1271 / 0,0185 = 6,87 kali garis dasar
```

Dilihat dengan cara ini, model penyalahgunaan promo sebenarnya *jauh lebih berguna secara relatif* daripada model churn — ia mengangkat kemampuan kita hampir tujuh kali lipat di atas tebakan acak, sementara model churn hanya 1,73 kali.

Kedua sudut pandang itu benar dan keduanya perlu dilaporkan: PR-AUC mutlak memberi tahu seberapa banyak salah alarm yang harus ditanggung, rasio terhadap garis dasar memberi tahu seberapa banyak nilai yang ditambahkan model dibandingkan tidak memakai model sama sekali.

Output — mengapa ambang 0,50 runtuh pada kelas langka

Deteksi penyalahgunaan promo, 60.000 baris uji, 1.110 kasus nyata

Ambang	Ditandai	TP	Precision	Recall	
0,05	4.324	441	0,1020	0,3973	
0,10	1.525	265	0,1738	0,2387	
0,20	445	132	0,2966	0,1189	
0,30	183	70	0,3825	0,0631	
0,50	30	19	0,6333	0,0171	◀ default

Pada ambang default: akurasi 98,16%, dan model menemukan 19 dari 1.110 kasus. Tebakan "tidak ada penyalahgunaan" untuk semua orang memberi akurasi 98,15%.

✗ COMMON MISTAKE — melaporkan akurasi pada masalah kelas langka

Gejala: "model deteksi penyalahgunaan kami akurat 98,2%".

Mengapa merusak: pernyataan itu benar dan tidak bermakna. Menebak "tidak ada" untuk semua orang memberi 98,15%. Model menambahkan 0,01 pp akurasi sambil melewatkan 98,3% kasus yang dicarinya.

Perbaikan: pada masalah kelas langka, laporkan tiga hal: PR-AUC beserta garis dasarnya, tabel precision-recall pada beberapa ambang, dan jumlah kasus yang ditemukan pada kapasitas pemeriksaan yang nyata. Angka terakhir yang paling dipahami pemangku kepentingan: "dengan tim yang dapat memeriksa 1.500 kasus per bulan, model menemukan 265 dari 1.110 penyalahgunaan; tanpa model, pemeriksaan acak akan menemukan 28."

Cara senior menghindarinya: tidak pernah melaporkan akurasi ketika prevalensi di bawah 20%, dan selalu menerjemahkan metrik ke dalam kapasitas operasional yang nyata.

Bagian IV — Kalibrasi

AUC hanya peduli pada urutan. Ia tidak peduli apakah skor 0,70 berarti 70% atau 40%. Untuk pengambilan keputusan berbasis nilai harapan (Bab 9), yang menentukan justru nilai probabilitasnya.

Kode — memeriksa kalibrasi

```
import numpy as np
from sklearn.metrics import brier_score_loss
```

```
# Kelompokkan prediksi ke dalam 10 bin, bandingkan rata-rata prediksi
# dengan proporsi kejadian sebenarnya di tiap bin.
bins = np.linspace(0, 1, 11)
idx = np.digitize(p, bins) - 1

for i in range(10):
    m = idx == i
    if m.sum() > 0:
        print(f"{bins[i]:.1f}-{bins[i+1]:.1f} n={m.sum():>6,} "
              f"prediksi {p[m].mean():.4f} aktual {yte[m].mean():.4f} "
              f"selisih {yte[m].mean()-p[m].mean():+.4f}")

print(f"Brier score: {brier_score_loss(yte, p):.4f}")
```

Output – kalibrasi model XGBoost churn

Bin prediksi	n	Rata-rata prediksi	Churn aktual	Selisih
0,0 – 0,1	6.188	0,0505	0,0509	+0,0004
0,1 – 0,2	6.767	0,1514	0,1563	+0,0050
0,2 – 0,3	7.562	0,2506	0,2588	+0,0082
0,3 – 0,4	7.796	0,3495	0,3571	+0,0076
0,4 – 0,5	7.231	0,4490	0,4449	-0,0041
0,5 – 0,6	6.892	0,5495	0,5463	-0,0032
0,6 – 0,7	5.967	0,6485	0,6390	-0,0095
0,7 – 0,8	4.971	0,7482	0,7459	-0,0023
0,8 – 0,9	3.904	0,8470	0,8458	-0,0012
0,9 – 1,0	2.722	0,9480	0,9530	+0,0050

Brier: XGBoost 0,1802 · logistik 0,1799 · konstanta 0,2466

◆ BUSINESS INSIGHT — model ini terkalibrasi baik, dan itu berarti skornya dapat dipakai sebagai uang

Selisih terbesar antara prediksi dan aktual adalah 0,0095 — kurang dari satu poin persentase pada seluruh rentang. Model dapat dipercaya ketika ia mengatakan 0,65.

Konsekuensi praktisnya besar dan sering tidak disadari: **skor terkalibrasi dapat dikalikan langsung dengan nilai rupiah**. Pelanggan dengan skor 0,65 memiliki nilai harapan kerugian $0,65 \times \text{Rp } 495.644 = \text{Rp } 322.169$. Angka itu dapat masuk ke perhitungan anggaran, ambang keputusan, dan proyeksi.

Model yang tidak terkalibrasi tetap berguna untuk mengurutkan (siapa yang paling berisiko), tetapi tidak dapat dipakai untuk perhitungan nilai. Dan seluruh Bab 9 bergantung pada kemampuan itu.

Catatan penting: *kalibrasi harus diperiksa ulang secara berkala*. Ia adalah hal pertama yang rusak ketika dunia bergeser — Bab 14 menunjukkan bahwa pada pergeseran recency 60%, AUC hampir tidak berubah ($0,8000 \rightarrow 0,7972$) sementara rata-rata prediksi meleset dari 0,4419 menjadi 0,4974.

KETIKA KALIBRASI RUSAK — dan cara memperbaikinya

PENYEBAB UMUM

- `scale_pos_weight` atau `class_weight` (Bab 6)
- `oversampling` / `SMOTE` pada kelas minoritas
- model yang secara alami terlalu percaya diri (SVM, random forest pada ekstrem, jaringan saraf dalam)
- pergeseran distribusi setelah model dilatih (Bab 14)

PERBAIKAN

- Platt scaling memasang regresi logistik pada skor model
→ baik bila distorsinya berbentuk sigmoid
- Isotonic regresi monoton non-parametrik

→ lebih fleksibel, butuh lebih banyak data
(minimal beberapa ribu baris kalibrasi)

PENTING: kalibrasi harus dipasang pada data TERPISAH yang tidak dipakai melatih model. `sklearn.calibration.CalibratedClassifierCV` menangani ini dengan benar.

Memilih metrik: satu tabel keputusan

Situasi	Metrik utama	Alasan
Membandingkan model, kelas seimbang	ROC-AUC	Tidak bergantung ambang; stabil; mudah dibandingkan
Kelas langka (< 10%)	PR-AUC + garis dasar	ROC menyembunyikan salah alarm karena TN mendominasi
Skor akan dikalikan dengan rupiah	Brier + kurva kalibrasi	Urutan yang benar tidak cukup; nilainya harus benar
Kapasitas tindakan terbatas	Precision@k, lift desil	Hanya k teratas yang akan ditindaklanjuti
Biaya kesalahan diketahui	Nilai harapan bersih	Metrik yang benar-benar diinginkan (Bab 9)
Regresi, keputusan per unit	MAE / WAPE	Setiap satuan kesalahan berbiaya sama
Regresi, hasil akan dijumlahkan	Bias agregat	Total yang benar lebih penting daripada akurasi per baris

✓ BEST PRACTICE — laporan kinerja model yang lengkap

SATU HALAMAN, ENAM BAGIAN

1. Kinerja pembeda AUC atau PR-AUC + garis dasar
+ sebaran antar fold
2. Kualitas probabilitas Brier + tabel kalibrasi 10 bin
3. Kinerja pada titik operasi precision, recall pada AMBANG YANG
AKAN DIPAKAI (bukan 0,50)
4. Kinerja per segmen minimal: wilayah, kanal, tenure,
dan kelompok yang relevan secara etis
5. Perbandingan baseline aturan bisnis hari ini + model
termurah yang masuk akal
6. Nilai bisnis diterjemahkan ke rupiah, dengan
kapasitas nyata (Bab 9)

Bagian 4 yang paling sering hilang, dan paling sering menjadi sumber masalah setelah peluncuran.

Checklist validasi dan metrik

- ✓ Skema validasi sesuai struktur data: stratified, group, atau time series
- ✓ Sebaran antar fold dilaporkan; selisih di bawah dua SD diperlakukan sebagai seri
- ✓ Metrik ditetapkan sebelum melihat hasil

- ✓ Akurasi tidak dilaporkan bila prevalensi di bawah 20%
- ✓ PR-AUC dilaporkan bersama garis dasarnya (prevalensi)
- ✓ F1 hanya dipakai bila biaya kedua kesalahan setara
- ✓ Kalibrasi diperiksa dengan tabel bin dan Brier score
- ✓ Kalibrasi dipasang pada data terpisah bila diperlukan
- ✓ Kinerja dilaporkan pada ambang operasi, bukan hanya 0,50
- ✓ Kinerja per segmen diperiksa, termasuk kelompok yang relevan secara etis

Ending Card — Bab 8

What you learned

Skema cross-validation dan variannya; cara memakai sebaran antar fold sebagai alat keputusan dengan aturan dua simpangan baku; confusion matrix dan seluruh metrik turunannya; mengapa F1 menyembunyikan keputusan biaya yang seharusnya sadar, dengan rasio biaya 2,24:1 pada kasus ini; perbedaan mekanis ROC dan PR serta mengapa ROC menyesatkan pada kelas langka; cara membaca PR-AUC relatif terhadap garis dasarnya ($1,73\times$ versus $6,87\times$); demonstrasi bahwa akurasi 98,2% pada deteksi penyalahgunaan hanya menemukan 19 dari 1.110 kasus; kalibrasi, tabel bin, Brier score, dan mengapa skor terkalibrasi dapat dikalikan dengan rupiah; penyebab dan perbaikan kalibrasi yang rusak; serta tabel keputusan pemilihan metrik dan struktur laporan kinerja enam bagian.

Skills mastered

Cross-validation · pembacaan confusion matrix · pemilihan ROC versus PR · pengukuran dan perbaikan kalibrasi · pelaporan kinerja model yang lengkap.

Real business value

Model churn yang terkalibrasi dengan selisih maksimum 0,0095 dapat dipakai langsung untuk perhitungan nilai harapan — dan itulah yang memungkinkan seluruh optimasi keputusan di Bab 9 yang bernilai Rp 14,84 miliar per tahun. Model dengan AUC sama tetapi kalibrasi rusak tidak dapat dipakai untuk itu sama sekali.

Interview readiness

● INTERVIEW QUESTIONS

1. "ROC-AUC atau PR-AUC?" — tergantung prevalensi; jelaskan peran TN di penyebut ROC.
2. "Akurasi model kami 98%. Bagus?" — tanyakan prevalensi; bandingkan dengan tebakan mayoritas.
3. "Apa itu kalibrasi dan mengapa penting?" — probabilitas yang dapat dikalikan dengan rupiah; beri contoh perhitungannya.
4. "Model B unggul 0,003 AUC. Ganti?" — bandingkan dengan sebaran antar fold; kemungkinan besar seri.
5. "Kapan kamu memakai F1?" — hanya bila biaya FP dan FN setara; hampir tidak pernah dalam bisnis.
6. "Apa yang hilang dari laporan model biasa?" — kinerja per segmen dan terjemahan ke rupiah.

Exercises

Exercise 8.1 (Beginner · 40 menit)

Objective: membaca confusion matrix

Sebuah model deteksi kecurangan dengan 100.000 transaksi uji dan 800 kecurangan nyata menghasilkan: TP 320, FP 1.680, FN 480, TN 97.520.

(a) Hitung precision, recall, specificity, akurasi, dan F1. (b) Hitung PR-AUC garis dasar. (c) Bila biaya memeriksa satu transaksi Rp 75.000 dan kerugian rata-rata per kecurangan yang lolos Rp 2,8 juta, hitung biaya total pada titik operasi ini. (d) Bandingkan dengan tidak memakai model sama sekali. (e) Bandingkan dengan memeriksa semua transaksi.

Answer key 8.1

(a) Precision = $320/2.000 = 0,160$; recall = $320/800 = 0,400$; specificity = $97.520/99.200 = 0,983$; akurasi = $97.840/100.000 = 0,978$; $F1 = 2 \times 0,16 \times 0,40 / (0,56) = 0,229$.

(b) Garis dasar PR-AUC = prevalensi = **0,008**. Precision 0,160 adalah 20 kali garis dasar — jauh lebih informatif daripada F1 0,229.

(c) Biaya = $2.000 \times 75.000 + 480 \times 2,8 \text{ jt} = 150 \text{ juta} + 1.344 \text{ juta} = \text{Rp } 1.494 \text{ juta}$.

(d) Tanpa model: $800 \times 2,8 \text{ jt} = \text{Rp } 2.240 \text{ juta}$. Model menghemat **Rp 746 juta**.

(e) Memeriksa semua: $100.000 \times 75.000 = \text{Rp } 7.500 \text{ juta} + 0 \text{ kerugian} = \text{Rp } 7.500 \text{ juta}$ — lima kali lebih buruk daripada tidak melakukan apa-apa.

Pelajaran: akurasi 97,8% dan F1 0,229 keduanya tidak memberi tahu apa pun yang berguna. Perbandingan biaya memberi tahu segalanya — dan menunjukkan bahwa ambang saat ini mungkin belum optimal (Bab 9).

Exercise 8.2 (Intermediate · 80 menit)

Objective: mendiagnosis dan memperbaiki kalibrasi

Latih model churn dengan `scale_pos_weight=3`, lalu: (a) bandingkan AUC dengan model tanpa pembobotan; (b) buat tabel kalibrasi 10 bin untuk keduanya; (c) hitung Brier score keduanya; (d) terapkan `CalibratedClassifierCV` pada model berbobot dan ukur ulang; (e) jelaskan mengapa AUC hampir tidak berubah sementara Brier berubah banyak.

Answer key 8.2

(e) Ini inti latihan. AUC hanya bergantung pada *urutan* skor. Pembobotan menggeser seluruh skor ke atas secara monoton, sehingga urutannya nyaris tidak berubah dan AUC tetap. Brier mengukur jarak antara skor dan kenyataan, sehingga pergeseran sistematis langsung menghukumnya.

Konsekuensi praktis: **AUC tidak dapat mendeteksi kalibrasi yang rusak**. Tim yang hanya memantau AUC dapat menjalankan model dengan probabilitas yang meleset jauh selama berbulan-bulan tanpa menyadarinya — dan setiap perhitungan nilai harapan yang dibangun di atasnya akan salah. Pantau Brier dan rata-rata prediksi versus rata-rata aktual, bukan hanya AUC.

Exercise 8.3 (Advanced · 2,5 jam)

Objective: laporan kinerja lengkap

Susun laporan kinerja enam bagian untuk model churn TokoNusa. Untuk bagian 4 (kinerja per segmen), hitung AUC, precision pada ambang operasi, dan kalibrasi untuk minimal enam segmen: tiga wilayah, tiga kanal, dan pembagian tenure.

(a) Adakah segmen dengan kinerja jauh di bawah rata-rata? (b) Adakah segmen dengan kalibrasi yang meleset? (c) Apa rekomendasimu untuk segmen bermasalah? (d) Bagaimana kamu akan memantau ini setelah peluncuran?

Answer key 8.3 — kerangka jawaban

(a)–(b) Pola yang biasanya muncul: segmen kecil menunjukkan AUC lebih rendah dengan ketidakpastian besar (perhatikan jumlah barisnya sebelum menyimpulkan), dan segmen dengan prevalensi churn yang berbeda dari rata-rata sering menunjukkan kalibrasi yang bergeser.

(c) Tiga pilihan, berurutan dari yang paling murah: menambahkan fitur yang membedakan segmen itu; menerapkan koreksi kalibrasi per segmen; atau melatih model terpisah bila segmennya besar dan perilakunya benar-benar berbeda. Pilihan keempat yang sering paling tepat: *menyatakan bahwa model tidak dipakai untuk segmen itu* dan menetapkan aturan bisnis sebagai gantinya.

(d) Pemantauan yang benar memakai metrik yang sama, dipecah dengan cara yang sama, dilaporkan pada irama tetap. Pemantauan agregat saja akan melewatkan kegagalan pada satu segmen sampai ia cukup besar untuk menggeser angka total — dan pada saat itu kerusakannya sudah berjalan berbulan-bulan.

Portfolio idea

★ PORTFOLIO TIP

Laporan kinerja enam bagian, terutama bagian kinerja per segmen dan terjemahan ke rupiah, adalah artefak yang membedakan portofolio ML tingkat menengah dari tingkat senior. Sebagian besar notebook berhenti pada AUC tunggal.

Further reading

Saito & Rehmsmeier tentang PR versus ROC pada data tak seimbang · Niculescu-Mizil & Caruana, "Predicting Good Probabilities with Supervised Learning" · Dokumentasi scikit-learn tentang *model evaluation* dan *calibration* · Vol 2 Bab 4 buku ini.

Next chapter

Bab 9 — dari skor ke keputusan. Ambang optimal ternyata memiliki bentuk yang persis sama dengan critical ratio newsvendor dari Vol 5 Bab 11, dan menetapkannya dengan benar bernilai Rp 14,84 miliar per tahun.

Bab 9 — Dari Skor ke Keputusan

Ambang optimal ternyata berbentuk persis critical ratio newsvendor — dan angka 0,5 tidak memiliki dasar apa pun

Learning objectives	Menurunkan ambang keputusan optimal dari biaya kesalahan; mengenali bentuknya sebagai critical ratio; menghitung nilai bisnis model dalam rupiah; menangani kendala kapasitas; membaca tabel lift desil; membandingkan model dengan aturan sederhana pada ukuran yang benar
Prerequisites	Bab 8 (kalibrasi); Vol 5 Bab 11 (newsvendor, critical ratio) dan Bab 9–10 (optimasi, kendala mengikat)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	Cost-sensitive thresholding, critical ratio, nilai bisnis model, targeting berkendala kapasitas, lift desil
Business domain	Retail omnichannel — kampanye retensi TokoNusa

WHY — angka 0,5 berasal dari mana

Ambang 0,5 adalah default di hampir semua pustaka machine learning. Asal-usulnya sederhana dan tidak ada hubungannya dengan bisnis: ia adalah titik di mana probabilitas kelas positif melebihi kelas negatif.

Ambang itu optimal dalam tepat satu kasus: **ketika biaya false positive sama persis dengan biaya false negative**. Dalam bisnis, keduanya hampir tidak pernah sama.

KASUS TOKONUSA

FALSE NEGATIVE — pelanggan akan churn, tidak dihubungi

$$\begin{aligned}\text{kerugian} &= \text{CLV} \times \text{uplift kampanye} \\ &= \text{Rp } 495.644 \times 19\% \\ &= \text{Rp } 94.172\end{aligned}$$

FALSE POSITIVE — pelanggan tidak akan churn, tetap dihubungi

$$\begin{aligned}\text{kerugian} &= \text{biaya kontak} \\ &= \text{Rp } 42.000\end{aligned}$$

$$\text{Rasio biaya} = 94.172 : 42.000 = 2,24 : 1$$

Ambang 0,5 memperlakukan keduanya sama, sehingga ia terlalu KONSERVATIF: model menahan diri menghubungi orang yang sebenarnya layak dihubungi.

WHAT — menurunkan ambang optimal

KEPUTUSAN PER PELANGGAN

Hubungi bila nilai harapan menghubungi > nilai harapan tidak

$$\begin{aligned}E[\text{hubungi}] &= p \times (\text{nilai_selamat}) - \text{biaya_kontak} \\ E[\text{tidak}] &= 0\end{aligned}$$

$$\text{Hubungi bila: } p \times V - C > 0$$

$$p > C / V$$

AMBANG OPTIMAL

$$p^* = \frac{C}{V} = \frac{\text{biaya bertindak}}{\text{nilai bila tindakan berhasil}}$$

TokoNusa: $p^* = 42.000 / 94.172 = 0,4460$ (44,60%)

BENTUK YANG SAMA DENGAN NEWSVENDOR (Vol 5 Bab 11)

$$CR = \frac{C_u}{C_u + C_o} = \frac{\text{biaya kekurangan}}{\text{biaya kekurangan + kelebihan}}$$

News vendor : pesan sampai persentil ke-CR dari permintaan
Klasifikasi: bertindak bila probabilitas melebihi p^*

Keduanya adalah masalah yang sama: menyeimbangkan biaya bertindak terlalu banyak terhadap biaya bertindak terlalu sedikit. Yang berbeda hanya bentuk keluarannya – kuantitas pesanan versus daftar nama.

■ TECHNICAL NOTE — bentuk umum dengan matriks biaya penuh

Rumus $p^* = C/V$ adalah kasus khusus. Bentuk umumnya memakai keempat sel confusion matrix:

$$p^* = \frac{\text{biaya(FP)} - \text{biaya(TN)}}{[\text{biaya(FP)} - \text{biaya(TN)}] + [\text{biaya(FN)} - \text{biaya(TP)}]}$$

Pada kasus TokoNusa: biaya(TN) = 0 (tidak berbuat apa-apa pada yang bertahan); biaya(FP) = Rp 42.000; biaya(FN) = Rp 94.172 (nilai yang hilang); biaya(TP) = Rp 42.000 – Rp 94.172 = –Rp 52.172 (keuntungan bersih). Masukkan:

$$p^* = 42.000 / [42.000 + (94.172 - (-52.172))] \dots$$

— dan penyederhanaannya kembali ke $42.000/94.172 = 0,4460$, karena biaya kontak dikeluarkan pada TP maupun FP sehingga saling menghapus. Gunakan bentuk umum ketika biaya tidak simetris seperti itu, misalnya ketika ada biaya tetap program atau ketika tindakan pada pelanggan yang bertahan justru merusak (kelelahan komunikasi).

HOW — menghitung nilai dalam rupiah

Kode — mencari ambang yang memaksimalkan nilai bersih

```
import numpy as np

CLV      = 495_644      # contribution-margin based (Vol 3 Bab 6)
UPLIFT   = 0.19         # uplift kampanye – HARUS dari eksperimen
BIAYA    = 42_000       # biaya kontak per pelanggan
NILAI    = CLV * UPLIFT # nilai per churn yang berhasil dicegah

print(f"ambang teoretis = {BIAYA/NILAI:.4f}")

# Cari ambang terbaik secara empiris pada data uji
grid = np.linspace(0.01, 0.95, 190)
```

```

nilai_bersih = []
for t in grid:
    dipilih = p >= t                                # p = skor model pada data uji
    tp = (yte[dipilih] == 1).sum()                  # churn yang tertangkap
    n = dipilih.sum()                               # total yang dihubungi
    nilai_bersih.append(tp * NILAI - n * BIAYA)

nilai_bersih = np.array(nilai_bersih)
i = nilai_bersih.argmax()
print(f"ambang empiris = {grid[i]:.4f}")
print(f"nilai bersih = Rp {nilai_bersih[i]/1e9:.3f} miliar (sampel 60.000)")

# Diskalakan ke seluruh basis pelanggan
skala = 1_480_000 / 60_000
print(f"skala penuh = Rp {nilai_bersih[i]/1e9*skala:.2f} miliar/tahun")

```

Output

Ambang	Dihubungi	Churn tertangkap	Recall	Precision	Nilai bersih*
0,0500	56.979	26.430	0,997	0,464	+Rp 0,096 M
0,1000	53.812	26.198	0,988	0,487	+Rp 0,207 M
0,2000	47.045	25.140	0,948	0,534	+Rp 0,392 M
0,3000	39.483	23.183	0,874	0,587	+Rp 0,525 M
0,4000	31.687	20.399	0,769	0,644	+Rp 0,590 M
0,4419	28.603	19.133	0,722	0,669	+Rp 0,600 M
0,4626	—	—	—	—	+Rp 0,602 M ← maksimum
0,5000	24.456	17.182	0,648	0,703	+Rp 0,591 M
0,6000	17.564	13.417	0,506	0,764	+Rp 0,526 M
0,7000	11.597	9.604	0,362	0,828	+Rp 0,417 M
0,8000	6.626	5.896	0,222	0,890	+Rp 0,277 M

* pada sampel uji 60.000 pelanggan

DISKALAKAN KE 1,48 JUTA PELANGGAN

ambang optimal 0,4626 → Rp 14,84 miliar/tahun
 ambang default 0,50 → Rp 14,56 miliar/tahun
 hubungi SEMUA → -Rp 0,57 miliar/tahun

◆ BUSINESS INSIGHT — tiga hal yang terbaca dari tabel ini

1. Memindahkan ambang dari 0,50 ke 0,4626 bernilai Rp 0,28 miliar per tahun. Perubahan itu memakan waktu lima menit dan tidak memerlukan model baru. Bandingkan dengan menaikkan AUC dari 0,80 ke 0,81, yang memakan berminggu-minggu dan bernilai jauh lebih kecil.

2. Kurvanya datar di sekitar puncak. Antara ambang 0,40 dan 0,50, nilai bersih hanya bergerak dari Rp 0,590 ke Rp 0,602 miliar — kurang dari 2%. Ini pola yang sama dengan seluruh optimum di Volume 5: *presisi tidak perlu diperjuangkan, penyimpangan besar yang berbahaya*. Menetapkan ambang di 0,45 sudah cukup baik; menetapkannya di 0,80 memotong nilai lebih dari separuh.

3. Menghubungi semua orang merugi. Rp -0,57 miliar. Ini penting dinyatakan karena "kirim ke semua pelanggan" adalah kebijakan default banyak tim CRM ketika kampanye terasa murah. Pada biaya Rp 42.000 per kontak dan churn 44%, ia tidak murah.

⚠ **WARNING** — seluruh tabel di atas bergantung pada satu angka yang belum diuji

Angka Rp 14,84 miliar bersandar pada asumsi bahwa kampanye retensi menyelamatkan **19% dari pelanggan yang akan churn, seragam di seluruh tingkat risiko.**

Asumsi itu memiliki dua bagian, dan keduanya rapuh. Angka 19% sendiri harus berasal dari eksperimen acak (Vol 4), bukan dari perbandingan "yang dihubungi versus tidak" — perbandingan itu bias oleh cara daftar kontak disusun. Dan keseragamannya adalah asumsi yang jauh lebih besar daripada yang terlihat.

Bab 10 menguji bagian kedua dengan data eksperimen, dan hasilnya membalikkan seluruh rekomendasi bab ini: pada pelanggan berisiko tertinggi — persis yang dipilih ambang optimal — uplift-nya jauh di bawah rata-rata, dan nilai nyata targeting berbasis skor ternyata **negatif**.

Bab ini tetap benar sebagai metode. Yang salah adalah salah satu masukannya, dan itulah yang membuatnya menjadi contoh yang baik: *perhitungan yang rapi tidak melindungi dari asumsi yang belum diuji.*

HOW — kapasitas sebagai kendala pengikat

Ambang optimal memilih 27.750 dari 60.000 pelanggan — setara 685.000 kontak per tahun. Tim CRM TokoNusa hanya mampu 120.000. Ambang menjadi tidak relevan; yang berlaku adalah kendala kapasitas.

KETIKA KAPASITAS MENGIKAT, PERTANYAANNYA BERUBAH

Dari : "siapa yang layak dihubungi?" (ambang)
Ke : "siapa k orang terbaik?" (peringkat)

Ini persis pergeseran dari Vol 5 Bab 10: ketika kendala mengikat, yang menentukan bukan nilai absolut melainkan PERINGKAT nilai per unit sumber daya.

Implikasinya untuk model: KALIBRASI menjadi kurang penting, URUTAN menjadi segalanya. AUC kembali menjadi metrik yang tepat — tetapi hanya karena kapasitas mengikat.

Output — 4.865 kontak (setara 120.000/tahun), tiga cara memilih

Cara memilih	Churn tertangkap	Presisi	Nilai bersih*
Skor model tertinggi	4.468	0,918	+Rp 5,34 M
Aturan recency tertinggi	4.123	0,847	+Rp 4,54 M
Acak	2.131	0,438	-Rp 0,09 M

* per tahun, diskalakan ke 1,48 juta pelanggan,
dengan asumsi uplift seragam 19% (lihat Bab 10)

NILAI MODEL DI ATAS ATURAN SEDERHANA = Rp 0,80 miliar/tahun
NILAI MODEL DI ATAS ACAK = Rp 5,43 miliar/tahun

◆ BUSINESS INSIGHT — pembandingan yang benar adalah aturan yang dipakai hari ini

Selisih antara model dan pemilihan acak (Rp 5,43 miliar) adalah angka yang paling sering dikutip dalam presentasi proyek ML. Ia juga hampir selalu menyesatkan, karena tidak ada organisasi yang memilih pelanggan secara acak.

Yang dipakai TokoNusa hari ini adalah aturan recency. Model mengungguli aturan itu dengan **Rp 0,80 miliar per tahun** — angka yang jauh lebih kecil, jauh lebih jujur, dan satu-satunya yang layak dipakai untuk membenarkan biaya membangun serta memelihara model.

Perhatikan juga bahwa aturan recency mencapai presisi 0,847 versus 0,918 milik model. Aturan sederhana menangkap sebagian besar sinyal karena recency memang prediktor terkuat (Bab 7). Ini pola yang berulang: *sebagian besar nilai tersedia dari aturan sederhana; model menambahkan lapisan terakhir.*

Konsekuensi manajerial: bila biaya membangun dan memelihara model melebihi Rp 0,80 miliar per tahun, proyeknya tidak layak — dan itu perhitungan yang harus dilakukan sebelum, bukan sesudah.

Lift desil: bahasa yang dipahami tim komersial

Output — lift per desil skor churn

Desil	n	Churn rate	Lift	Recall kumulatif
1	6.000	0,9010	2,04×	0,204
2	6.000	0,7455	1,69×	0,373
3	6.000	0,6318	1,43×	0,516
4	6.000	0,5493	1,24×	0,640
5	6.000	0,4587	1,04×	0,744
6	6.000	0,3870	0,88×	0,831
7	6.000	0,3167	0,72×	0,903
8	6.000	0,2310	0,52×	0,955
9	6.000	0,1487	0,34×	0,989
10	6.000	0,0492	0,11×	1,000

Basis churn rate: 0,4419

■ TECHNICAL NOTE — cara membaca lift dan batasnya

Lift 2,04× pada desil pertama berarti kelompok itu memiliki tingkat churn dua kali lipat rata-rata. Tabel ini populer karena mudah dipahami tanpa latar belakang statistik.

Dua hal yang perlu diperhatikan. **Pertama, lift maksimum dibatasi prevalensi.** Dengan churn 44,19%, lift tertinggi yang mungkin adalah $1/0,4419 = 2,26×$. Model mencapai 2,04× — yaitu 90% dari yang secara matematis mungkin. Pada masalah dengan prevalensi 2%, lift 10× masih mungkin; membandingkan angka lift antar masalah tanpa memperhatikan ini tidak bermakna.

Kedua, recall kumulatif sering lebih berguna. Tiga desil teratas memuat 51,6% dari seluruh churn. Kalimat itu langsung dapat dipakai: "dengan menghubungi 30% pelanggan, kita menjangkau separuh dari yang akan berhenti."

Yang tidak diberitahukan tabel ini — dan ini pengulangan peringatan yang sama — adalah apakah menghubungi desil 1 *mengubah* perilaku mereka. Desil 1 memuat pelanggan dengan recency 300+ hari yang mungkin sudah pergi sepenuhnya. Bab 10.

Kesalahan umum

✗ COMMON MISTAKE — mengoptimalkan model tanpa menyentuh ambang

Gejala: tiga sprint dihabiskan menaikkan AUC dari 0,800 ke 0,812, sementara ambang tetap 0,5 karena "itu defaultnya".

Mengapa merusak: pada kasus ini, memperbaiki ambang bernilai Rp 0,28 miliar per tahun dan memakan lima menit. Perbaikan AUC 0,012 pada kapasitas terbatas bernilai jauh lebih kecil, karena yang menentukan adalah urutan 4.865 teratas — dan urutan itu hampir tidak berubah.

Perbaikan: selesaikan rantai keputusan sebelum menyempurnakan model. Urutan yang benar: ambang → kapasitas → uplift → baru model.

Cara senior menghindarinya: menuliskan nilai bisnis sebagai metrik utama dalam laporan model sejak hari pertama, di samping AUC. Ketika angka rupiah terlihat di setiap laporan, prioritas bergeser dengan sendirinya.

✗ COMMON MISTAKE — memakai probabilitas yang tidak terkalibrasi untuk menghitung ambang

Gejala: model dilatih dengan `scale_pos_weight` atau oversampling, lalu ambang 0,4460 diterapkan pada keluarannya.

Mengapa merusak: pembobotan menggeser skor sehingga 0,4460 tidak lagi berarti "probabilitas 44,6%". Ambang yang secara teoretis benar diterapkan pada skala yang salah menghasilkan pemilihan yang sewenang-wenang.

Perbaikan: periksa kalibrasi (Bab 8) sebelum menerapkan ambang berbasis biaya. Bila kalibrasi rusak, perbaiki dengan Platt atau isotonic, atau tentukan ambang secara empiris dari kurva nilai — bukan dari rumus.

Checklist dari skor ke keputusan

- ✓ Biaya false positive dan false negative dinyatakan dalam rupiah
- ✓ Ambang optimal dihitung dari rasio biaya, bukan diambil dari default
- ✓ Kalibrasi diperiksa sebelum ambang berbasis biaya diterapkan
- ✓ Ambang juga dicari secara empiris dari kurva nilai sebagai pemeriksaan silang
- ✓ Kedataran kurva nilai diperiksa; presisi ambang tidak diperjuangkan berlebihan
- ✓ Kendala kapasitas diperiksa; bila mengikat, pindah dari ambang ke peringkat
- ✓ Pembanding adalah aturan bisnis yang berlaku hari ini, bukan pemilihan acak
- ✓ Nilai bersih dilaporkan dalam rupiah per tahun pada skala penuh
- ✓ Asumsi uplift dinyatakan eksplisit sebagai sumber ketidakpastian terbesar
- ✓ Lift desil disajikan bersama recall kumulatif untuk komunikasi

Ending Card — Bab 9

What you learned

Asal-usul ambang 0,5 dan satu-satunya kondisi yang membuatnya optimal; penurunan ambang optimal $p^* = C/V$ dan bentuk umumnya dengan matriks biaya penuh; identifikasi bahwa ambang klasifikasi dan critical ratio newsvendor adalah masalah yang sama; perhitungan nilai bisnis dalam rupiah dan tabel nilai bersih per ambang; tiga temuan dari tabel itu — nilai Rp 0,28 miliar dari perubahan lima menit, kedataran kurva, dan kerugian menghubungi semua orang; pergeseran dari ambang ke peringkat ketika kapasitas mengikat; perbandingan model dengan aturan recency yang memberi angka jujur Rp 0,80 miliar alih-alih Rp 5,43 miliar; pembacaan lift desil beserta batas maksimumnya yang ditentukan prevalensi; dan dua kesalahan umum yang paling mahal.

Skills mastered

Cost-sensitive thresholding · perhitungan nilai bisnis model · targetting berkendala kapasitas · analisis lift desil · pemilihan pembanding yang jujur.

Real business value

Menetapkan ambang dari biaya alih-alih memakai default bernilai Rp 0,28 miliar per tahun dengan usaha lima menit. Dan memilih pembanding yang benar — aturan recency, bukan acak — mengubah klaim nilai proyek dari Rp 5,43 miliar menjadi Rp 0,80 miliar, angka yang dapat dipertahankan di hadapan CFO dan yang menentukan apakah proyek ini layak dilanjutkan.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagaimana kamu memilih ambang klasifikasi?" — dari rasio biaya; tunjukkan $p^* = C/V$ dan hubungannya dengan newsvendor.
2. "Model kami AUC 0,80. Berapa nilainya bagi bisnis?" — tidak dapat dijawab tanpa biaya, kapasitas, dan pembanding.
3. "Berapa nilai model ini?" — selalu tanyakan "dibandingkan dengan apa"; pakai aturan yang berlaku hari ini.
4. "Kapasitas kami hanya 120.000 kontak. Apa yang berubah?" — dari ambang ke peringkat; kalibrasi menjadi kurang penting.
5. "Lift desil 1 kami 2,04x. Bagus?" — bandingkan dengan lift maksimum yang mungkin (1/prevalensi).
6. "Apa asumsi paling rapuh dalam perhitungan nilai kamu?" — uplift kampanye dan keseragamannya; jelaskan cara mengujinya.

Exercises

Exercise 9.1 (Beginner · 40 menit)

Objective: menghitung ambang dari biaya

Hitung ambang optimal untuk empat kasus:

- (a) Deteksi kecurangan: biaya memeriksa Rp 75.000; kerugian rata-rata kecurangan yang lolos Rp 2,8 juta.
- (b) Pemeliharaan prediktif: biaya pemeriksaan preventif Rp 12 juta; kerugian kerusakan tak terencana Rp 340 juta.
- (c) Persetujuan kredit: keuntungan pinjaman lancar Rp 4,2 juta; kerugian pinjaman gagal Rp 38 juta.
- (d) Kampanye win-back: biaya kontak Rp 42.000; nilai pemulihan Rp 94.172.

Untuk masing-masing, nyatakan juga apa artinya secara operasional.

Answer key 9.1

- (a) $p^* = 75.000/2.800.000 = 0,0268$ — periksa setiap transaksi dengan risiko di atas 2,7%. Ambang sangat rendah karena biaya memeriksa jauh lebih murah daripada kerugian.
- (b) $p^* = 12/340 = 0,0353$ — periksa mesin dengan risiko kerusakan di atas 3,5%.
- (c) Perhatikan bahwa di sini target biasanya "gagal bayar", sehingga logikanya terbalik: tolak bila $p(\text{gagal})$ melebihi ambang. $p^* = 4,2/(4,2+38) = 0,0995$ — tolak pemohon dengan risiko gagal di atas 10%. Kasus ini juga memerlukan pertimbangan tambahan di luar nilai harapan: keadilan antar kelompok dan kewajiban menjelaskan penolakan (Bab 14).
- (d) $p^* = 0,4460$, seperti dalam bab.

Pola yang terbaca: **ambang optimal hampir selalu jauh di bawah 0,5**, karena dalam sebagian besar masalah bisnis biaya bertindak jauh lebih murah daripada biaya kehilangan. Ambang default 0,5 secara sistematis membuat organisasi bertindak terlalu sedikit.

Exercise 9.2 (Intermediate · 90 menit)

Objective: kurva nilai dan analisis sensitivitas

Untuk model churn TokoNusa: (a) buat kurva nilai bersih terhadap ambang; (b) ulangi untuk tiga nilai uplift: 10%, 19%, 30%; (c) ulangi untuk tiga biaya kontak: Rp 25.000, Rp 42.000, Rp 70.000; (d) buat tabel ambang optimal untuk sembilan kombinasi; (e) parameter mana yang paling mempengaruhi ambang optimal? (f) Berapa uplift minimum agar program ini bernilai positif?

Answer key 9.2

- (d) Ambang optimal = biaya/(CLV × uplift). Tabel 3×3-nya: pada uplift 10% ambangnya 0,504 / 0,847 / 1,412 untuk ketiga biaya (nilai di atas 1 berarti *tidak ada* pelanggan yang layak dihubungi); pada uplift 30% ambangnya 0,168 / 0,282 / 0,471.
- (e) Keduanya berpengaruh proporsional, tetapi **uplift memiliki rentang ketidakpastian yang jauh lebih lebar** — biaya kontak diketahui dengan presisi tinggi dari data akuntansi, sementara uplift adalah estimasi dari eksperimen dengan interval kepercayaan. Karena itu uplift adalah parameter yang layak diinvestasikan untuk diukur lebih baik. Ini persis logika tornado dan nilai kepastian di Vol 5 Bab 7.
- (f) Program bernilai positif hanya bila ada pelanggan dengan p di atas ambang. Dengan skor maksimum model sekitar 0,98, uplift minimum $\approx 42.000/(495.644 \times 0,98) = 8,6\%$. Bila uplift sebenarnya di bawah itu, tidak ada ambang yang menyelamatkan program — dan itu pertanyaan yang harus dijawab dengan eksperimen sebelum program diluncurkan, bukan sesudah.

Exercise 9.3 (Advanced · 2,5 jam)

Objective: alokasi berkendala ganda

Tim CRM memiliki tiga jenis tindakan dengan biaya dan efektivitas berbeda: email (Rp 8.000, uplift 6%), telepon (Rp 42.000, uplift 19%), dan voucher (Rp 120.000, uplift 31%). Kapasitas: 400.000 email, 120.000 telepon, 40.000 voucher per tahun. Anggaran total Rp 12 miliar.

(a) Rumuskan sebagai masalah optimasi. (b) Tentukan tindakan mana untuk desil mana. (c) Hitung nilai totalnya. (d) Kendala mana yang mengikat? (e) Berapa shadow price-nya?

Answer key 9.3 — kerangka jawaban

(a) Variabel keputusan: $x[\text{desil}, \text{tindakan}]$ = jumlah pelanggan desil d yang menerima tindakan a . Maksimalkan $\sum x \times p(d) \times \text{uplift}(a) \times \text{CLV} - \sum x \times \text{biaya}(a)$, dengan kendala kapasitas per tindakan, anggaran total, dan $\sum_a x[d,a] \leq n(d)$.

(b) Pola solusi yang biasanya muncul: tindakan mahal untuk desil dengan probabilitas tertinggi (nilai harapan per kontak paling besar), tindakan murah menyebar lebih luas. Perhatikan bahwa *voucher untuk desil 1 tidak selalu optimal* — bergantung pada apakah kapasitas voucher atau anggaran yang mengikat.

(d)–(e) Ini penerapan langsung Vol 5 Bab 10. Shadow price kapasitas telepon memberi tahu berapa nilai satu kontak telepon tambahan per tahun — angka yang dapat langsung dibandingkan dengan biaya menambah satu staf CRM. Bila shadow price melebihi biaya penambahan kapasitas, rekomendasinya adalah menambah tim, bukan menyempurnakan model.

Peringatan yang harus disertakan: seluruh perhitungan ini memakai uplift per *tindakan* yang seragam antar desil. Bab 10 menunjukkan bahwa asumsi itu keliru, dan versi yang benar memakai uplift per kombinasi desil-tindakan yang diukur dari eksperimen.

Portfolio idea

★ PORTFOLIO TIP

Kurva "nilai bersih terhadap ambang" dengan tiga skenario uplift, ditambah satu kalimat yang menyatakan berapa uplift minimum agar program bernilai positif, adalah satu grafik yang menjawab pertanyaan bisnis paling penting tentang proyek ML. Sertakan ia di halaman pertama, bukan di lampiran.

Further reading

Elkan, "The Foundations of Cost-Sensitive Learning" — penurunan formal ambang optimal · Provost & Fawcett, *Data Science for Business* bab tentang analisis nilai harapan · Vol 5 Bab 11 (newsvendor) dan Bab 10 (shadow price) buku ini.

Next chapter

Bab 10 — menguji asumsi yang menopang seluruh bab ini. Dengan data eksperimen, nilai targeting berbasis skor churn ternyata **–Rp 0,60 miliar**, bukan +Rp 5,34 miliar. Dan cara memperbaikinya bernilai Rp 5,20 miliar.

Bab 10 — Nilai Bisnis Model dan Uplift

Menguji asumsi yang menopang Bab 9 — dan menemukan bahwa menargetkan risiko tertinggi menghasilkan nilai negatif

Learning objectives	Membedakan skor risiko dari uplift; memahami empat tipe respons terhadap intervensi; mengukur uplift dari data eksperimen; menghitung selisih antara nilai semu dan nilai inkremental; merancang program yang menghasilkan data uplift; menyajikan temuan yang membatalkan rekomendasi sebelumnya
Prerequisites	Bab 9; Vol 4 Bab 2-3 (eksperimen), Bab 7 (ekonomi eksperimen), Bab 12 (incrementality)
Estimasi waktu	Baca 2,5 jam · Praktik 5 jam
Difficulty	● Advanced / Production Ready
Skills covered	Uplift modeling, incrementality, evaluasi nilai inkremental, perancangan holdout, komunikasi temuan negatif
Business domain	Retail omnichannel — kampanye retensi TokoNusa

Asumsi yang belum diuji

Bab 9 menyimpulkan bahwa menargetkan 4.865 pelanggan berskor tertinggi bernilai **+Rp 5,34 miliar per tahun**. Perhitungannya benar. Satu masukannya belum diuji: bahwa kampanye menyelamatkan 19% pelanggan yang akan churn, seragam di seluruh tingkat risiko.

TokoNusa menjalankan eksperimen untuk mengujinya: 60.000 pelanggan dibagi acak menjadi kelompok perlakuan dan kontrol, kampanye win-back dijalankan pada kelompok perlakuan, churn diamati 180 hari kemudian.

Output – hasil eksperimen, agregat

Churn kelompok kontrol	0,4461
Churn kelompok perlakuan	0,3654
ATE (average treatment effect)	-8,07 pp

Kampanye BEKERJA. Efeknya nyata dan besar.

Output – hasil yang sama, dipecah per desil skor churn

Desil	Churn rate	Uplift (penurunan churn)
1	0,901	-7,47 pp
2	0,746	-12,75 pp
3	0,632	-16,21 pp
4	0,549	-13,99 pp
5	0,459	-13,48 pp
6	0,387	-10,99 pp
7	0,317	-1,09 pp
8	0,231	-0,76 pp

◀ tertinggi

9	0,149	-0,58 pp
10	0,049	+0,23 pp

Desil dengan RISIKO TERTINGGI (1) memiliki uplift SETENGAH dari desil 3. Kampanye bekerja paling baik pada risiko MENENGAH, bukan pada risiko tertinggi.

⚠ WARNING — inilah pembalikan yang membatalkan rekomendasi Bab 9

Bab 9 memilih 4.865 pelanggan berskor tertinggi — hampir seluruhnya dari desil 1 dan sebagian desil 2. Justru kelompok dengan uplift terendah setelah desil 7-10.

Menghitung ulang dengan uplift terukur alih-alih asumsi seragam:

TARGETING 4.865 SKOR TERTINGGI

Klaim NAIF (churn tertangkap × CLV × uplift rata-rata 19%)
Rp +5,34 miliar/tahun

Nilai NYATA (uplift terukur per desil)
Rp -0,60 miliar/tahun

SELISIH – nilai yang tidak pernah ada Rp 5,94 miliar

Program yang dilaporkan menghasilkan Rp 5,34 miliar sebenarnya *menghancurkan* Rp 0,60 miliar per tahun. Dan tidak ada yang akan mengetahuinya, karena laporan program akan menunjukkan bahwa 91,8% orang yang dihubungi memang berisiko tinggi dan sebagian besar dari mereka tetap bertahan — semuanya benar, dan semuanya tidak relevan.

WHY — empat tipe respons

		DIHUBUNGI?		
		ya	tidak	
BERTAHAN ya	ya	SURE THING	SURE THING	akan bertahan apa pun → kontak = biaya murni
		PERSUAD-ABLE	churn	bertahan HANYA bila dihubungi → SATU-SATUNYA yang menghasilkan nilai
		churn	SLEEPING DOG	
		churn	bertahan	SLEEPING DOG: kontak justru MEMBUAT churn
BERTAHAN tdk	tdk	LOST CAUSE	LOST CAUSE	akan churn apa pun → kontak = biaya murni

MODEL CHURN memberi peringkat berdasarkan $P(\text{churn})$.
Ia menempatkan LOST CAUSE di puncak, bercampur dengan sebagian PERSUADABLE.

MODEL UPLIFT memberi peringkat berdasarkan selisih $P(\text{bertahan} | \text{dihubungi}) - P(\text{bertahan} | \text{tidak})$.
Hanya ia yang memisahkan PERSUADABLE dari LOST CAUSE.

◆ BUSINESS INSIGHT — mengapa polanya berbentuk bukit, dan mengapa itu masuk akal

Uplift TokoNusa memuncak di desil 3 dan turun di kedua ujungnya. Bentuk itu bukan keanehan data; ia mengikuti logika bisnis yang dapat dijelaskan.

Desil 1 (churn rate 0,901). Pelanggan dengan recency 300+ hari yang sudah praktis pergi. Mereka *lost cause* — sebagian besar tidak akan kembali karena sebuah email. Uplift $-7,47$ pp masih ada, tetapi setengah dari puncaknya.

Desil 3 (churn rate 0,632). Pelanggan yang mulai menjauh tetapi belum pergi. Mereka *persuadable*: masih ingat mereknya, masih punya kebutuhan, dan sebuah tawaran yang tepat waktu benar-benar mengubah keputusan.

Desil 7-10 (churn rate di bawah 0,32). Pelanggan setia yang akan bertahan tanpa diapa-apakan. Mereka *sure thing* — setiap rupiah yang dihabiskan untuk mereka adalah biaya murni. Perhatikan desil 10 dengan uplift $+0,23$ pp: sedikit lebih banyak churn pada yang dihubungi. Besarannya kecil dan mungkin derau, tetapi tandanya adalah peringatan tentang *sleeping dog* — mengingatkan pelanggan yang sudah lupa bahwa ia berlangganan.

Pola bukit ini umum dalam retensi, dan konsekuensinya selalu sama: **menargetkan risiko tertinggi adalah kesalahan default yang mahal.**

HOW — menghitung nilai inkremental dengan benar

Kode — dua cara menghitung nilai, satu benar

```
import numpy as np
import pandas as pd

CLV, BIAYA, K = 495_644, 42_000, 4_865 # K = kapasitas kontak
SKALA = 1_480_000 / 60_000 # sampel uji -> basis penuh

# desil berdasarkan skor model; uplift per desil dari EKSPERIMEN
desil = pd.qcut(pd.Series(-p).rank(method='first'), 10, labels=False) + 1
uplift = {d: (y_obs[(desil==d) & (treat==0)].mean()
              - y_obs[(desil==d) & (treat==1)].mean()) for d in range(1, 11)}

pilih = np.argsort(-p)[:K] # K skor tertinggi

# CARA 1 — SALAH: churn tertangkap x CLV x uplift RATA-RATA
# Mengasumsikan setiap churn yang tertangkap dapat diselamatkan 19%.
semu = (yte[pilih].sum() * CLV * 0.19 - K * BIAYA) / 1e9 * SKALA

# CARA 2 — BENAR: jumlahkan uplift TERUKUR dari desil masing-masing
u_terpilih = np.array([uplift[d] for d in desil.values[pilih]])
nyata = (u_terpilih.sum() * CLV - K * BIAYA) / 1e9 * SKALA

print(f"klaim naif : Rp {semu:+.2f} miliar/tahun")
print(f"nilai nyata : Rp {nyata:+.2f} miliar/tahun")
```

Output — tiga strategi targeting, dinilai dengan uplift terukur

Strategi	Nilai inkremental nyata
Targeting skor churn tertinggi	-Rp 0,60 miliar/tahun
Targeting acak	-Rp 0,52 miliar/tahun
Targeting UPLIFT tertinggi	+Rp 4,60 miliar/tahun

⚠ **WARNING — targeting berbasis skor churn hampir sama buruknya dengan acak**

Angka $-\text{Rp } 0,60$ miliar versus $-\text{Rp } 0,52$ miliar layak dibaca dua kali. Model dengan AUC 0,80, yang mengurutkan risiko churn dengan sangat baik, menghasilkan nilai inkremental yang *lebih buruk* daripada memilih pelanggan secara acak.

Ini bukan karena modelnya buruk. Model itu unggul pada tugas yang diberikan kepadanya: memprediksi siapa yang akan churn. Masalahnya adalah tugas itu bukan tugas yang menghasilkan nilai.

Perhatikan bahwa acak juga negatif. Pada uplift rata-rata dan biaya kontak Rp 42.000, program ini *secara keseluruhan* tidak menguntungkan bila targetnya dipilih sembarangan. Yang membuatnya menguntungkan bukan modelnya, melainkan **memilih orang yang tepat untuk dihubungi** — dan "tepat" berarti uplift tertinggi, bukan risiko tertinggi.

WHAT — cara memodelkan uplift

Pendekatan	Cara kerja	Kekuatan dan batas
Two-model (T-learner)	Latih dua model: satu pada kelompok perlakuan, satu pada kontrol. Uplift = selisih prediksinya	Paling sederhana. Kesalahan dua model bertumpuk; uplift kecil mudah tenggelam dalam derau
Single-model (S-learner)	Satu model dengan indikator perlakuan sebagai fitur; uplift = $\text{prediksi}(T=1) - \text{prediksi}(T=0)$	Lebih stabil. Model dapat mengabaikan indikator perlakuan bila efeknya kecil
Class transformation	Target diubah menjadi variabel gabungan perlakuan-hasil, lalu diklasifikasi biasa	Elegan, memakai satu model. Hanya untuk perlakuan biner dan alokasi 50:50
Uplift tree / causal forest	Kriteria pembelahan langsung memaksimalkan perbedaan uplift antar cabang	Dirancang khusus untuk tugas ini. Butuh pustaka khusus dan data eksperimen yang besar
Uplift per segmen	Bagi menjadi desil atau segmen, ukur uplift masing-masing dari eksperimen	Paling kokoh, paling mudah dijelaskan, paling sering cukup. Mulai dari sini

✓ **BEST PRACTICE** — mulai dari uplift per segmen, bukan dari model uplift

Godaan setelah membaca bab ini adalah membangun causal forest. Itu hampir selalu langkah yang salah untuk diambil pertama.

Alasannya statistik: uplift adalah *selisih dua probabilitas*, sehingga deraunya jauh lebih besar daripada probabilitas itu sendiri. Untuk mendeteksi uplift dengan andal pada tingkat individu, dibutuhkan data eksperimen yang jauh lebih besar daripada yang dibutuhkan model prediksi biasa — sering sepuluh sampai seratus kali lipat.

Pendekatan bertahap yang bekerja:

1. Jalankan kampanye dengan HOLDOUT ACAK (biaya $\approx$ nol)
2. Ukur uplift per desil skor churn – tabel sederhana
3. Alihkan targeting ke desil dengan uplift tertinggi
→ pada kasus ini, langkah 1–3 bernilai Rp 5,20 miliar
4. Setelah beberapa siklus, data cukup untuk model uplift
5. Bangun model uplift; ukur perbaikannya terhadap langkah 3

Langkah 1–3 memakan waktu satu kuartal dan menghasilkan sebagian besar nilainya. Langkah 4–5 memakan setahun dan menghasilkan lapisan terakhir.

Merancang program yang menghasilkan datanya sendiri

HOLDOUT PERMANEN – praktik yang membedakan program dewasa

Setiap kampanye menyisihkan 5–10% penerima yang memenuhi syarat sebagai KONTROL ACAK yang tidak dihubungi.

BIAYA : 5–10% dari nilai kampanye

MANFAAT : satu-satunya cara mengetahui apakah kampanye bekerja, dan pada siapa

PADA KASUS INI:

biaya holdout 10%	$\approx$ Rp 0,46 miliar/tahun
nilai yang diungkapnya	$\approx$ Rp 5,20 miliar/tahun
rasio	$\approx$ 11 : 1

Ini adalah investasi nilai informasi (Vol 5 Bab 5) dengan imbal hasil tertinggi yang tersedia bagi tim CRM mana pun.

► EXECUTIVE PERSPECTIVE — menyampaikan temuan yang membatalkan pekerjaan sendiri

Bab 9 menghasilkan rekomendasi. Bab 10 membatalkannya. Dalam pekerjaan nyata, situasi ini terjadi di depan orang-orang yang sudah menyetujui rekomendasi pertama.

Struktur penyampaian yang bekerja:

- 1. Mulai dari yang tidak berubah.** "Model bekerja. Ia mengurutkan risiko churn dengan baik, dan angka-angka di laporan sebelumnya benar."
- 2. Nyatakan asumsi yang diuji, bukan kesalahan yang ditemukan.** "Perhitungan sebelumnya mengasumsikan kampanye bekerja sama baiknya pada semua tingkat risiko. Kami menguji asumsi itu."
- 3. Sampaikan angkanya tanpa dramatisasi.** "Uplift pada desil tertinggi ternyata setengah dari desil ketiga."
- 4. Bawa solusinya, bukan hanya masalahnya.** "Mengalihkan targeting ke desil 3-5 mengubah nilai program dari -Rp 0,60 miliar menjadi +Rp 4,60 miliar. Perubahannya adalah satu baris dalam kueri seleksi."
- 5. Usulkan perubahan proses.** "Kami merekomendasikan holdout permanen 10% agar temuan seperti ini muncul dalam hitungan bulan, bukan setelah program berjalan setahun."

Yang membuat penyampaian ini dapat diterima adalah bahwa ia mengubah percakapan dari "siapa yang salah" menjadi "apa yang sekarang kita ketahui". Dan analyst yang membawa temuan yang membatalkan pekerjaannya sendiri memperoleh kredibilitas yang tidak dapat dibeli dengan cara lain.

Kesalahan umum

✗ COMMON MISTAKE — mengukur keberhasilan kampanye dari tingkat retensi penerimanya

Gejala: "82% pelanggan yang kami hubungi tetap bertahan — kampanye berhasil."

Mengapa merusak: angka itu tidak memiliki pembanding. Berapa yang bertahan bila tidak dihubungi? Tanpa kontrol, tingkat retensi penerima tidak memberi tahu apa pun tentang efek kampanye. Bila daftar penerima disusun dari pelanggan aktif, angkanya akan tinggi bahkan bila kampanye tidak berpengaruh sama sekali — persis bias seleksi daftar pada Vol 4 Bab 1.

Perbaikan: holdout acak. Tidak ada alternatif yang setara.

Cara senior menghindarinya: menolak melaporkan metrik kampanye tanpa kelompok kontrol, dan menjadikan holdout sebagai syarat baku persetujuan anggaran kampanye. Aturan yang ditegakkan di tingkat proses jauh lebih efektif daripada mengingatkan berulang kali.

✗ COMMON MISTAKE — membangun model uplift tanpa data eksperimen

Gejala: model uplift dilatih pada data historis di mana keputusan menghubungi diambil oleh tim CRM berdasarkan kriteria mereka sendiri.

Mengapa merusak: siapa yang dihubungi tidak acak, sehingga selisih antara yang dihubungi dan tidak memuat seluruh bias seleksi. Model uplift yang dilatih di atasnya mempelajari *pola seleksi tim CRM*, bukan efek kampanye. Hasilnya sering terlihat masuk akal dan sepenuhnya salah.

Perbaikan: uplift modeling membutuhkan variasi acak. Bila belum ada, jalankan holdout dulu dan tunggu satu siklus. Bila tidak mungkin, gunakan metode observasional dari Vol 4 (IPW, IV, DiD) dengan seluruh peringatannya — dan nyatakan tingkat buktinya secara eksplisit.

Checklist nilai bisnis dan uplift

- ✓ Nilai program dihitung dari uplift terukur, bukan dari churn tertangkap
- ✓ Uplift berasal dari kelompok kontrol acak, bukan dari perbandingan observasional
- ✓ Uplift diperiksa per segmen; keseragamannya tidak diasumsikan
- ✓ Empat tipe respons dipertimbangkan, termasuk kemungkinan sleeping dog
- ✓ Holdout permanen 5–10% dipasang pada setiap kampanye bernilai material
- ✓ Uplift per segmen dikerjakan lebih dulu; model uplift menyusul
- ✓ Kebutuhan ukuran sampel untuk uplift dihitung, bukan diasumsikan sama dengan model prediksi
- ✓ Nilai inkremental dilaporkan berdampingan dengan klaim naif agar selisihnya terlihat
- ✓ Temuan yang membatalkan rekomendasi sebelumnya disampaikan dengan solusi
- ✓ Metrik kampanye tidak dilaporkan tanpa kelompok kontrol

Ending Card — Bab 10

What you learned

Pengujian asumsi uplift seragam dengan data eksperimen dan pembalikan yang dihasilkannya — dari klaim +Rp 5,34 miliar menjadi nilai nyata -Rp 0,60 miliar; empat tipe respons terhadap intervensi dan mengapa model churn menempatkan lost cause di puncak; pola uplift berbentuk bukit dengan puncak di desil 3 dan penjelasan bisnisnya; perbandingan tiga strategi targeting yang menunjukkan targeting skor hampir sama buruknya dengan acak; lima pendekatan pemodelan uplift dan mengapa uplift per segmen adalah titik mulai yang benar; rancangan holdout permanen dengan rasio manfaat 11:1; struktur lima langkah untuk menyampaikan temuan yang membatalkan pekerjaan sendiri; serta dua kesalahan pengukuran kampanye yang paling umum.

Skills mastered

Uplift measurement · evaluasi nilai inkremental · perancangan holdout · pemilihan pendekatan uplift modeling · komunikasi temuan yang membatalkan rekomendasi.

Real business value

Mengalihkan targeting dari skor churn ke uplift terukur bernilai **Rp 5,20 miliar per tahun** — lebih besar daripada seluruh nilai yang dapat diperoleh dari menyempurnakan model, menetapkan ambang, dan mengoptimalkan kapasitas digabung. Perubahannya adalah satu baris dalam kueri seleksi, dan syaratnya adalah satu holdout acak yang biayanya mendekati nol.

Interview readiness

● INTERVIEW QUESTIONS

1. "Apa bedanya model churn dan model uplift?" — $P(\text{churn})$ versus selisih P ; jelaskan empat tipe respons.
2. "Kami menargetkan pelanggan berisiko tertinggi. Ada masalah?" — lost cause; tunjukkan pola bukit dan angkanya.
3. "82% penerima kampanye bertahan. Berhasil?" — tanpa kontrol, angka itu tidak bermakna.
4. "Bagaimana kamu mengukur uplift?" — holdout acak; uplift per segmen lebih dulu.
5. "Mengapa model uplift butuh data lebih banyak?" — ia mengestimasi selisih dua probabilitas; deraunya jauh lebih besar.
6. "Analisis kamu membatalkan rekomendasi kamu sendiri bulan lalu. Bagaimana kamu menyampaikannya?" — lima langkah; bawa solusinya.

Exercises

Exercise 10.1 (Beginner · 40 menit)

Objective: mengenali tipe respons

Untuk enam profil pelanggan berikut, tentukan tipe respons yang paling mungkin (persuadable, sure thing, lost cause, sleeping dog) dan rekomendasi tindakannya:

- (a) recency 340 hari, frekuensi 1, tenure 4 bulan; (b) recency 45 hari, frekuensi 12, anggota tier; (c) recency 120 hari, frekuensi 5, pernah terlambat, 2 keluhan; (d) recency 200 hari, frekuensi 3, tidak pernah dihubungi selama 2 tahun; (e) recency 20 hari, frekuensi 9, keteraturan tinggi; (f) recency 95 hari, frekuensi 4, tenure 30 bulan, tidak ada keluhan.

Answer key 10.1

- (a) **Lost cause** — satu pembelian, sudah lama pergi, hubungan tidak pernah terbentuk. Jangan hubungi; biaya murni.
- (b) **Sure thing** — akan bertahan tanpa diapa-apakan. Jangan hubungi untuk retensi; sasaran yang tepat untuk penjualan silang.
- (c) **Persuadable**, dan yang terbaik dari daftar ini — hubungan sudah ada, masalah layanan teridentifikasi, belum terlalu jauh. Prioritas tertinggi.
- (d) **Sleeping dog** yang berisiko — pelanggan yang tidak menerima komunikasi selama dua tahun mungkin sudah lupa berlangganan; menghubunginya dapat memicu keputusan berhenti. Uji dengan hati-hati sebelum menghubungi kelompok ini secara massal.
- (e) **Sure thing**. (f) **Persuadable**, tetapi lebih lemah daripada (c) karena tidak ada masalah spesifik yang dapat diperbaiki.

Catatan penting: klasifikasi ini adalah *hipotesis* yang harus diuji dengan eksperimen. Tipe respons tidak dapat diamati pada individu — hanya rata-ratanya pada kelompok yang dapat diukur.

Exercise 10.2 (Intermediate · 90 menit)

Objective: menghitung nilai inkremental

Dengan data eksperimen TokoNusa: (a) hitung nilai inkremental untuk lima strategi targeting — skor tertinggi, uplift tertinggi, desil 3-5 saja, acak, dan seluruh basis; (b) hitung kapasitas optimal: pada berapa jumlah kontak nilai maksimum tercapai bila kapasitas dapat ditambah dengan biaya Rp 42.000 per kontak; (c) hitung shadow price kapasitas kontak; (d) bandingkan dengan biaya menambah satu staf CRM (Rp 96 juta per tahun, kapasitas 8.000 kontak).

Answer key 10.2

- (b) Kapasitas optimal ditentukan oleh titik di mana uplift marginal $\times$ CLV turun di bawah biaya kontak: uplift ambang = $42.000/495.644 = 8,47$ pp. Dari tabel desil, hanya desil 2-6 yang melewati ambang itu (12,75 / 16,21 / 13,99 / 13,48 / 10,99). Desil 1 (7,47 pp) berada *di bawah* ambang — menghubungi mereka merugi bahkan bila kapasitasnya tersedia gratis.
- (c) Shadow price kapasitas = nilai uplift marginal dikurangi biaya kontak, dievaluasi pada desil marginal. Selama masih ada pelanggan di desil 2-6 yang belum dihubungi, shadow price-nya positif dan besar; begitu kelima desil itu habis, shadow price turun menjadi negatif.
- (d) Menambah staf bernilai hanya selama masih ada pelanggan beruplift di atas 8,47 pp yang belum dihubungi. Desil 2-6 memuat 30.000 pelanggan di sampel uji (740.000 pada basis penuh) — jauh melebihi kapasitas 120.000. Jadi **ya, menambah kapasitas menciptakan nilai**, dan perhitungannya adalah penerapan langsung shadow price dari Vol 5 Bab 10. Ini kesimpulan yang berlawanan dengan yang diperoleh Bab 9 sebelum uplift diukur.

Exercise 10.3 (Advanced · 3 jam)

Objective: membangun model uplift

Bangun model uplift dengan tiga pendekatan pada data eksperimen TokoNusa: two-model, single-model dengan indikator perlakuan, dan class transformation.

- (a) Evaluasi ketiganya dengan kurva Qini atau uplift kumulatif. (b) Bandingkan dengan targeting berbasis desil sederhana. (c) Apakah model uplift mengungguli pendekatan desil? (d) Bila tidak, apa penjelasannya, dan apa rekomendasimu?

Answer key 10.3 — kerangka jawaban

(a) Kurva Qini adalah padanan kurva lift untuk uplift: sumbu x proporsi populasi yang ditargetkan, sumbu y akumulasi uplift. Luas di atas garis acak adalah ukuran kualitas model uplift.

(c)–(d) Pada dataset dengan ukuran ini, model uplift sering *tidak* mengungguli pendekatan desil secara berarti. Penjelasan statistiknya: dengan 60.000 baris dan uplift sekitar 8 pp, rasio sinyal terhadap derau untuk estimasi per individu sangat rendah. Model uplift menghabiskan kapasitasnya memodelkan derau.

Rekomendasi yang tepat: **pakai pendekatan desil, kumpulkan data eksperimen selama beberapa siklus, lalu uji ulang**. Dan nyatakan syarat kuantitatifnya — misalnya "kami akan mengevaluasi ulang setelah memiliki 300.000 observasi eksperimen". Menetapkan syarat numerik untuk meninjau ulang keputusan adalah praktik yang sama dengan titik keputusan terjadwal di Vol 5 Bab 14.

Exercise 10.4 (Production Challenge · 8 jam)

Objective: sistem retensi berbasis uplift

Rancang sistem retensi lengkap: seleksi target berbasis uplift per segmen; holdout permanen 10% dengan randomisasi yang benar; dashboard pemantauan uplift per segmen per siklus; aturan penghentian bila uplift turun di bawah ambang; dan laporan bulanan yang membedakan nilai inkremental dari nilai semu. Sertakan perhitungan ukuran sampel untuk mendeteksi perubahan uplift sebesar 3 pp.

Answer key 10.4 — rubrik

Sistem yang kuat: holdout diacak pada tingkat pelanggan dengan seed yang tercatat; dashboard menampilkan uplift *dengan interval kepercayaan*, bukan titik estimasi; aturan penghentian ditetapkan sebelum program berjalan; dan laporan bulanan menampilkan kedua angka berdampingan sehingga selisihnya tidak dapat diabaikan.

Perhitungan ukuran sampel adalah bagian yang paling sering dilewatkan. Untuk mendeteksi perubahan uplift 3 pp dengan power 80% pada tingkat dasar sekitar 13 pp, dibutuhkan puluhan ribu observasi per kelompok per segmen — jauh lebih besar daripada intuisi kebanyakan orang. Menyatakan angka itu di muka mencegah kesimpulan yang diambil dari data yang terlalu sedikit, dan merupakan penerapan langsung Vol 4 Bab 3.

Portfolio idea

★ PORTFOLIO TIP

Analisis yang menunjukkan *model prediktif yang baik menghasilkan nilai negatif ketika dipakai untuk targeting*, lengkap dengan perbaikannya, adalah salah satu artefak portofolio paling kuat yang dapat dibuat seorang analyst. Ia menunjukkan pemahaman yang jarang: bahwa nilai berasal dari keputusan, bukan dari prediksi.

Further reading

Radcliffe & Surry tentang uplift modeling dan kurva Qini · Gutierrez & Gérardy, "Causal Inference and Uplift Modelling: A Review" · Athey & Imbens tentang causal forest · Dokumentasi pustaka *causalm1* dan *scikit-uplift* · Vol 4 Bab 2, 7, dan 12 buku ini.

Next chapter

Bab 11 — belajar tanpa label: clustering, PCA, dan deteksi anomali. Termasuk hasil yang mengganggu — deteksi anomali menemukan pelanggan bernilai tinggi, bukan pelaku penyalahgunaan, dengan lift $0,89\times$ di bawah acak.

Bab 11 — Clustering, PCA, dan Deteksi Anomali

Belajar tanpa label — dan mengapa hasilnya jauh lebih sering menyesatkan daripada supervised learning

Learning objectives	Menjalankan dan menafsirkan k-means; memilih jumlah klaster dengan alasan; membandingkan segmentasi otomatis dengan segmentasi berbasis aturan bisnis; menerapkan PCA dan membaca muatannya; menjalankan deteksi anomali dan menilai apakah ia menemukan hal yang dicari; mengenali kapan unsupervised learning bukan jawabannya
Prerequisites	Bab 3 (fitur); Vol 3 Bab 6 (segmentasi RFM); Vol 2 Bab 2 (distribusi)
Estimasi waktu	Baca 2,5 jam · Praktik 4 jam
Difficulty	● Advanced
Skills covered	K-means, silhouette, PCA, Isolation Forest, evaluasi segmentasi, penilaian nilai bisnis unsupervised
Business domain	Retail omnichannel — segmentasi pelanggan dan deteksi penyalahgunaan promo

WHY — masalah mendasar belajar tanpa label

SUPERVISED

Ada jawaban benar
Kinerja dapat diukur
Data uji memberi vonis

UNSUPERVISED

TIDAK ada jawaban benar
Tidak ada metrik kebenaran
Hanya ada ukuran internal (silhouette, inertia) yang TIDAK memberi tahu apakah hasilnya berguna

KONSEKUENSINYA:

- Selalu ADA hasil. K-means dengan k=4 akan selalu menghasilkan 4 klaster, bahkan pada data acak murni.
- Hasil yang tidak berguna terlihat sama meyakinkannya dengan hasil yang berguna.
- Satu-satunya penilaian yang bermakna adalah PENILAIAN BISNIS: apakah kelompok ini berperilaku berbeda dalam hal yang kita pedulikan, dan apakah kita akan MEMPERLAKUKAN mereka berbeda?

⚠ **WARNING — unsupervised learning tidak dapat gagal, dan itulah bahayanya**

Model klasifikasi yang buruk akan menunjukkan AUC 0,52 dan tidak akan lolos review. Clustering yang tidak bermakna akan menghasilkan empat kelompok dengan nama yang terdengar masuk akal, grafik yang indah, dan tidak ada yang dapat membuktikannya salah.

Ini membuat unsupervised learning sangat mudah dipakai untuk menghasilkan pekerjaan yang tampak berharga tanpa menghasilkan nilai. Pertahanannya adalah satu aturan: **segmentasi hanya sah bila diikuti perlakuan yang berbeda per segmen**. Bila seluruh segmen akan menerima perlakuan yang sama, segmentasinya tidak diperlukan berapa pun silhouette-nya.

HOW — k-means pada data pelanggan TokoNusa

Kode — clustering dengan pemilihan k

```
import pandas as pd
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

FITUR = ['recency_hari', 'frekuensi_12bln', 'monetary_12bln', 'aov',
         'tenure_bulan', 'n_kategori', 'keteraturan']

# Standardisasi WAJIB: k-means memakai jarak Euclidean, sehingga
# fitur berskala besar (monetary dalam jutaan) akan mendominasi
# seluruh perhitungan jarak bila tidak distandardisasi.
Z = StandardScaler().fit_transform(df[FITUR])

for k in [2, 3, 4, 5, 6, 8]:
    km = KMeans(n_clusters=k, n_init=10, random_state=42).fit(Z)
    # silhouette mahal pada 200.000 baris -> hitung pada subsampel
    sil = silhouette_score(Z[:20], km.labels_[:20])
    print(f"k={k} inertia {km.inertia_:.12f} silhouette {sil:.4f}")
```

Output

k=2	inertia	1,129,570	silhouette 0.2751
k=3	inertia	1,005,666	silhouette 0.2103
k=4	inertia	907,269	silhouette 0.1727
k=5	inertia	821,774	silhouette 0.1768
k=6	inertia	750,700	silhouette 0.1599
k=8	inertia	663,096	silhouette 0.1560

■ TECHNICAL NOTE — membaca silhouette 0,17 dengan jujur

Silhouette berkisar dari -1 sampai +1. Panduan yang lazim dipakai:

```
> 0,70    struktur klaster kuat
0,50-0,70 struktur wajar
0,25-0,50 struktur lemah; bisa jadi artefak
< 0,25    praktis tidak ada struktur klaster
```

Pada k=4, silhouette 0,1727. Artinya jelas dan harus dinyatakan: **data pelanggan ini tidak memiliki kelompok alami yang terpisah**. Ia adalah awan kontinu, dan k-means memotongnya menjadi empat bagian yang sama sewenang-wenangnya dengan memotong menjadi lima.

Ini bukan temuan yang aneh — ia adalah temuan yang *normal* pada data pelanggan. Perilaku belanja bervariasi secara kontinu, bukan dalam kelompok terpisah. Kebanyakan laporan segmentasi tidak menyebutkan silhouette-nya, dan itulah sebabnya kebanyakan laporan segmentasi terdengar lebih meyakinkan daripada seharusnya.

Kesimpulan yang benar bukan "jangan lakukan segmentasi", melainkan: *segmentasi di sini adalah alat pengorganisasian, bukan penemuan*. Kelompoknya dibuat, bukan ditemukan — dan bila memang dibuat, membuatnya berdasarkan aturan bisnis yang dapat dijelaskan lebih baik daripada membuatnya dengan algoritma.

Output – profil empat klaster (k=4)

Klaster	Pangsa	Recency	Frekuensi	Monetary	AOV	Tenure	Churn
0	52,3%	39,5	3,55	1.037.589	304.232	16,4	0,447
1	19,7%	45,5	3,73	1.164.554	325.117	47,6	0,445
2	16,3%	39,5	8,78	3.485.117	432.317	22,6	0,143
3	11,7%	203,7	3,19	1.023.647	328.382	21,7	0,829

Yang sebenarnya ditemukan algoritma:

Klaster 3 = "sudah lama tidak belanja" (recency)

Klaster 2 = "belanja banyak" (frekuensi & monetary)

Klaster 0 vs 1 = "baru" vs "lama" (tenure)

Tiga sumbu yang sudah kita ketahui sejak Volume 3.

Perbandingan dengan RFM manual

Output – segmentasi RFM berbasis aturan (Vol 3 Bab 6)

Segmen	Pangsa	Churn rate
Champions	16,07%	0,1196
Loyal	18,36%	0,2743
Regular	20,34%	0,4338
At risk	21,15%	0,5407
One-timer	24,08%	0,7047

Rentang churn: 0,1196 sampai 0,7047 (rasio 5,9×)

Bandingkan k-means k=4:

Rentang churn: 0,143 sampai 0,829 (rasio 5,8×)

tetapi DUA dari empat klaster (0 dan 1, 72% pelanggan)

memiliki churn rate yang praktis identik: 0,447 dan 0,445.

◆ BUSINESS INSIGHT — RFM manual mengalahkan k-means pada ukuran yang penting

Kedua metode menghasilkan rentang churn yang serupa. Perbedaannya ada pada *distribusi*: RFM menghasilkan lima segmen berukuran seimbang dengan churn yang naik bertahap, sementara k-means menempatkan 72% pelanggan ke dalam dua klaster yang tidak dapat dibedakan.

Untuk tim CRM, segmen yang tidak dapat dibedakan tidak dapat ditindaklanjuti. Segmentasi yang menempatkan mayoritas pelanggan ke dalam satu kelompok besar bernama "reguler" mengembalikan mereka ke titik awal.

Empat keunggulan RFM manual yang layak dinyatakan:

- 1. Dapat dijelaskan.** "Champions adalah pelanggan yang skor R, F, dan M-nya di kuintil teratas." K-means memerlukan penjelasan tentang jarak Euclidean pada ruang terstandarisasi.
- 2. Stabil.** Definisinya tetap; pelanggan berpindah segmen hanya bila perilakunya berubah. Klaster k-means dapat berubah seluruhnya bila model dilatih ulang.
- 3. Dapat dibandingkan lintas waktu.** "Champions turun dari 16,5% ke 16,1%" bermakna. Perbandingan klaster antar periode tidak bermakna tanpa pemetaan manual.
- 4. Sudah tertanam dalam bahasa organisasi.** Tim komersial sudah memakai istilahnya.

Kapan k-means tetap lebih baik: ketika jumlah dimensi besar dan tidak ada kerangka bisnis yang mapan, ketika mencari struktur yang belum terpikirkan, atau ketika segmentasi hanya menjadi masukan bagi model lain dan tidak perlu dijelaskan kepada manusia.

HOW — PCA

Output – PCA pada tujuh fitur perilaku

Komponen	Varians dijelaskan	Kumulatif
PC1	0,3211	0,3211
PC2	0,1706	0,4917
PC3	0,1472	0,6389
PC4	0,1428	0,7817
PC5	0,1261	0,9078
PC6	0,0827	0,9905
PC7	0,0095	1,0000

MUATAN PC1

monetary +0,614 · frekuensi +0,570 · n_kategori +0,421
aov +0,272 · keteraturan +0,142 · recency -0,162 · tenure +0,007
→ sumbu "INTENSITAS BELANJA"

MUATAN PC2

aov +0,746 · recency +0,338 · monetary +0,264
n_kategori -0,307 · keteraturan -0,332 · frekuensi -0,235
→ sumbu "BELANJA JARANG TETAPI BESAR"

■ TECHNICAL NOTE — PC1 hanya menjelaskan 32%, dan itu memberi tahu sesuatu

Pada banyak dataset, PC1 menjelaskan 50–70% varians. Di sini hanya 32,1%, dan dibutuhkan lima komponen untuk mencapai 90%.

Artinya: **fitur-fitur ini sebagian besar tidak redundan**. Setiap fitur membawa informasi yang tidak dimiliki fitur lain. Ini konsisten dengan temuan ablation study di Bab 3, di mana setiap kelompok fitur menyumbang kenaikan AUC tersendiri.

Konsekuensi praktisnya: *PCA tidak berguna untuk reduksi dimensi di sini*. Memakai 5 komponen alih-alih 7 fitur asli menghemat dua dimensi sambil kehilangan keterjelasan penuh. Pertukaran yang buruk.

PCA berguna ketika: dimensi sangat banyak (ratusan), fitur sangat berkorelasi, ada kebutuhan visualisasi dua dimensi, atau ada masalah multikolinearitas pada model linear. Tidak satu pun berlaku di sini — dan mengetahui kapan sebuah teknik *tidak* diperlukan sama berharganya dengan mengetahui cara menjalankannya.

HOW — deteksi anomali

Kode – Isolation Forest

```
from sklearn.ensemble import IsolationForest

# contamination = proporsi yang diasumsikan anomali.
# Ini BUKAN hasil pembelajaran – ia parameter yang kita tetapkan,
# dan ia menentukan berapa banyak yang akan ditandai.
iso = IsolationForest(contamination=0.01, random_state=42, n_jobs=-1).fit(Z)
skor = -iso.score_samples(Z)      # makin tinggi makin anomali
flag = iso.predict(Z) == -1       # True = ditandai anomali

print(f"Ditandai: {flag.sum():,} ({flag.mean():.2%})")
for f in ['recency_hari', 'frekuensi_12bln', 'monetary_12bln', 'aov']:
    print(f"  {f:<18} anomali {df[f][flag].mean():>12,.2f} | "
          f"normal {df[f][~flag].mean():>12,.2f}")
```

```
# PERTANYAAN YANG MENENTUKAN: apakah yang ditandai adalah
# hal yang benar-benar kita cari?
print(f"Tingkat penyalahgunaan pada yang ditandai : {df.abuse_promo[flag].mean():.4f}")
print(f"Tingkat penyalahgunaan basis : {df.abuse_promo.mean():.4f}")
```

Output

Ditandai: 2.000 (1,00%)

Fitur	Anomali	Normal
recency_hari	65,44	59,84
frekuensi_12bln	14,21	4,30
monetary_12bln	7.039.389	1.403.415
aov	574.272	329.594
retur_rate	0,06	0,06

Tingkat penyalahgunaan pada yang ditandai : 0,0165
Tingkat penyalahgunaan basis : 0,0185

LIFT: 0,89× – LEBIH BURUK DARIPADA MEMILIH ACAK

⚠ WARNING — deteksi anomali menemukan pelanggan terbaik, bukan pelaku penyalahgunaan

Isolation Forest bekerja persis seperti seharusnya: ia menemukan 2.000 pelanggan yang paling menyimpang secara statistik. Mereka berbelanja 14 kali setahun (versus 4,3), menghabiskan Rp 7,0 juta (versus Rp 1,4 juta), dengan keranjang 74% lebih besar.

Mereka adalah pelanggan terbaik TokoNusa. Dan tingkat penyalahgunaan promo di antara mereka *lebih rendah* daripada rata-rata — lift 0,89×, yaitu **lebih buruk daripada memilih pelanggan secara acak untuk diperiksa**.

Pelajaran yang harus dibawa: **"tidak biasa" dan "bermasalah" adalah dua hal yang berbeda**. Deteksi anomali tanpa label mencari yang pertama. Bila yang dicari adalah yang kedua, dan ada label meski sedikit, gunakan supervised learning.

Perbandingannya tegas. Model supervised pada target `abuse_promo` (Bab 8) mencapai PR-AUC 0,1271 dengan lift 6,87× di atas garis dasar, dan pada 1% skor teratasnya mencapai lift **13,97×**. Isolation Forest mencapai 0,89×. Selisihnya bukan 20% — ia lebih dari lima belas kali lipat.

Output – pembandingan: aturan sederhana

Metode	Ditandai	Tingkat abuse	Lift
Isolation Forest (1%)	2.000	0,0165	0,89×
Aturan z-score monetary > 3	3.797	0,0150	0,81×
Acak	2.000	0,0185	1,00×
Model supervised (1% teratas)	600	0,2583	13,97×

Catatan: model supervised dinilai pada data uji (60.000 baris), sehingga 1% teratasnya berjumlah 600 – bukan 2.000. Perbandingan yang adil adalah pada LIFT, bukan pada jumlah absolut.

✓ **BEST PRACTICE — kapan deteksi anomali benar-benar tepat**

Deteksi anomali unsupervised memiliki tempat yang jelas, dan tempat itu lebih sempit daripada yang biasanya diasumsikan:

TEPAT bila:

- TIDAK ADA label sama sekali, dan tidak akan ada
- Yang dicari memang "apa pun yang tidak biasa" — misalnya pemantauan kualitas data, deteksi kerusakan sensor, atau pemantauan kesehatan sistem
- Pola masalahnya BERUBAH terus sehingga label historis tidak berguna (beberapa jenis penipuan)
- Sebagai LAPISAN PERTAMA untuk menghasilkan kandidat yang kemudian diberi label manusia

TIDAK TEPAT bila:

- Ada label, meski sedikit → pakai supervised
- Yang dicari punya definisi bisnis yang jelas → pakai aturan bisnis, seringkali lebih baik
- Belum ada yang menetapkan apa yang dianggap "masalah"

Pemakaian yang paling produktif dalam praktik adalah yang terakhir: memakai deteksi anomali untuk menghasilkan kandidat pemeriksaan pada bulan pertama, memberi label pada hasil pemeriksaannya, lalu *beralih ke supervised* begitu ada beberapa ratus label. Menjadikannya solusi permanen ketika label sudah tersedia adalah pemborosan.

Checklist unsupervised learning

- ✓ Fitur distandardisasi sebelum clustering berbasis jarak
- ✓ Silhouette dilaporkan dan ditafsirkan dengan jujur, bukan disembunyikan
- ✓ Hasil dibandingkan dengan segmentasi berbasis aturan bisnis yang sudah ada
- ✓ Segmentasi dinilai dari rentang perilaku antar segmen, bukan dari keindahan grafik
- ✓ Ukuran segmen diperiksa; segmen yang tidak dapat dibedakan dianggap gagal
- ✓ Stabilitas segmentasi antar periode diuji sebelum dipakai untuk pelaporan berkala
- ✓ Segmentasi hanya dipakai bila akan diikuti perlakuan yang berbeda
- ✓ PCA dinilai dari varians kumulatif; tidak dipakai bila tidak menghemat dimensi berarti
- ✓ Deteksi anomali dinilai terhadap target bisnis yang sebenarnya, bukan hanya "keanehan"
- ✓ Bila ada label meski sedikit, supervised diuji sebagai pembanding wajib

Ending Card — Bab 11

What you learned

Masalah mendasar belajar tanpa label dan mengapa unsupervised learning tidak dapat gagal secara terlihat; k-means pada data TokoNusa dengan silhouette 0,1727 yang menunjukkan tidak adanya kelompok alami; profil empat klaster yang ternyata mengulang tiga sumbu yang sudah diketahui; perbandingan dengan RFM manual yang menunjukkan k-means menempatkan 72% pelanggan ke dua klaster yang tidak dapat dibedakan; empat keunggulan segmentasi berbasis aturan; PCA yang hanya menjelaskan 32% pada PC1 dan implikasinya bahwa fitur tidak redundan; deteksi anomali yang menemukan pelanggan terbaik dengan lift $0,89\times$ — lebih buruk daripada acak — dibandingkan model supervised dengan lift $7,08\times$; serta kondisi sempit di mana deteksi anomali unsupervised benar-benar tepat.

Skills mastered

K-means dan pemilihan k · pembacaan silhouette · PCA dan muatan komponen · Isolation Forest · evaluasi segmentasi terhadap kriteria bisnis · penilaian kapan unsupervised bukan jawabannya.

Real business value

Menguji deteksi anomali terhadap target bisnis yang sebenarnya mengungkap bahwa ia bekerja lebih buruk daripada pemeriksaan acak — temuan yang mencegah tim pemeriksaan menghabiskan kapasitasnya pada 2.000 pelanggan terbaik perusahaan. Beralih ke model supervised menaikkan lift dari $0,89\times$ ke $13,97\times$ pada 1% teratas, yaitu lebih dari lima belas kali lipat efektivitas pada kapasitas pemeriksaan yang sama.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagaimana kamu memilih jumlah klaster?" — silhouette dan elbow, tetapi kriteria akhirnya adalah kebergunaan bisnis.
2. "Silhouette kami 0,17. Apa artinya?" — praktis tidak ada struktur klaster; nyatakan itu, jangan sembunyikan.
3. "K-means atau RFM?" — RFM bila ada kerangka bisnis; sebutkan empat keunggulannya.
4. "Kapan PCA berguna?" — dimensi banyak, fitur berkorelasi, visualisasi; bukan sekadar kebiasaan.
5. "Kami pakai Isolation Forest untuk deteksi penipuan. Bagaimana kamu mengevaluasinya?" — terhadap kasus yang terkonfirmasi; jangan hanya melihat "keanehan".
6. "Kami punya 300 kasus penipuan berlabel. Unsupervised atau supervised?" — supervised; pada kasus ini selisihnya lebih dari lima belas kali lipat.

Exercises

Exercise 11.1 (Beginner · 45 menit)

Objective: menilai kualitas segmentasi

Jalankan k-means dengan $k = 3, 4, 5, 6$ pada data TokoNusa. Untuk masing-masing hitung: (a) silhouette; (b) ukuran tiap klaster; (c) rentang churn rate antar klaster; (d) jumlah klaster yang churn rate-nya berselisih kurang dari 5 pp dari klaster lain. (e) Berdasarkan keempat ukuran itu, k berapa yang kamu pilih, dan apakah kamu akan merekomendasikan memakai k-means sama sekali?

Answer key 11.1

(d) Ukuran keempat adalah yang paling berguna dan paling jarang dihitung. Kluster yang perilakunya tidak dapat dibedakan dari kluster lain tidak menambah apa pun — pada $k=4$, kluster 0 dan 1 berselisih 0,2 pp dan seharusnya digabung.

(e) Rekomendasi yang kuat menyebut bahwa *tidak ada k yang memuaskan*: silhouette tertinggi pada $k=2$ (0,2751) tetapi dua segmen terlalu kasar untuk ditindaklanjuti, sementara k yang lebih besar menghasilkan silhouette lebih rendah dan kluster yang tumpang tindih. Kesimpulan yang tepat adalah memakai RFM berbasis aturan, dan menyertakan alasannya dengan angka. Merekomendasikan untuk *tidak* memakai teknik yang diminta, dengan bukti, adalah jawaban terbaik untuk latihan ini.

Exercise 11.2 (Intermediate · 90 menit)

Objective: menguji stabilitas segmentasi

Segmentasi yang dipakai untuk pelaporan berkala harus stabil. Uji stabilitas k-means: (a) latih pada dua subsampel acak 50% dan bandingkan penugasan kluster untuk pelanggan yang sama; (b) hitung berapa persen pelanggan berpindah kluster; (c) ulangi dengan seed berbeda; (d) lakukan hal yang sama untuk segmentasi RFM berbasis aturan; (e) bandingkan dan simpulkan.

Answer key 11.2

(b)–(c) K-means pada data tanpa struktur kluster yang jelas akan menunjukkan perpindahan yang substansial — sering 15–30% pelanggan berpindah antar pelatihan. Penyebabnya langsung: ketika data adalah awan kontinu, batas kluster ditentukan oleh inisialisasi dan sampel, bukan oleh struktur data.

(d) Segmentasi RFM berbasis kuintil berpindah hanya karena batas kuintil bergeser sedikit antar sampel — biasanya di bawah 5%.

(e) Kesimpulan yang penting untuk pelaporan: **segmentasi yang tidak stabil tidak dapat dipakai untuk melacak perubahan dari waktu ke waktu**. Bila 20% pelanggan berpindah kluster hanya karena model dilatih ulang, laporan "Champions turun 3%" tidak dapat dibedakan dari derau pelatihan. Ini alasan praktis paling kuat untuk memilih segmentasi berbasis aturan pada konteks pelaporan berkala.

Exercise 11.3 (Advanced · 2,5 jam)

Objective: membangun sistem deteksi yang benar

Rancang sistem deteksi penyalahgunaan promo yang lengkap: (a) mulai dengan aturan bisnis yang masuk akal dan ukur lift-nya; (b) tambahkan Isolation Forest sebagai lapisan kandidat dan ukur lift-nya; (c) latih model supervised pada label yang tersedia dan ukur lift-nya; (d) rancang alur kerja yang menggabungkan ketiganya, termasuk cara label baru dihasilkan dari hasil pemeriksaan; (e) hitung nilai bisnis pada kapasitas pemeriksaan 1.500 kasus per bulan.

Answer key 11.3 — kerangka jawaban

(d) Alur kerja yang baik adalah *berlapis dan menghasilkan datanya sendiri*: aturan bisnis menangkap kasus yang jelas; model supervised memberi peringkat sisanya; sebagian kecil kapasitas pemeriksaan (misalnya 10%) dialokasikan secara **acak** untuk menghasilkan label yang tidak bias.

Alokasi acak itu adalah bagian yang paling sering dilewatkan dan paling penting. Tanpa itu, label hanya ada pada kasus yang dipilih model, sehingga pelatihan ulang berikutnya akan memperkuat bias model saat ini — sistem menjadi buta terhadap pola yang tidak pernah dipilihnya. Ini masalah yang sama dengan bias seleksi daftar pada Bab 10, muncul dalam bentuk berbeda.

(e) Nilai bisnis pada kapasitas 1.500/bulan: dari tabel Bab 8, ambang 0,10 menandai 1.525 kasus dan menemukan 265 dari 1.110. Bandingkan dengan pemeriksaan acak yang menemukan sekitar 28. Selisih 237 kasus per periode dikalikan kerugian rata-rata per kasus adalah nilai sistem — dan angka itulah yang layak dibandingkan dengan biaya membangunnya.

Portfolio idea

★ PORTFOLIO TIP

Analisis yang membandingkan deteksi anomali unsupervised dengan model supervised pada target bisnis yang sama, menunjukkan lift $0,89\times$ versus $13,97\times$, adalah artefak yang langsung menjawab pertanyaan yang sering muncul di perusahaan: "bisakah kita pakai AI untuk mendeteksi hal-hal aneh?" Jawabannya bernuansa, dan menunjukkan nuansa itu dengan angka jauh lebih berkesan daripada menyatakannya sebagai opini.

Further reading

Liu, Ting & Zhou, "Isolation Forest" · Dokumentasi scikit-learn tentang *clustering* dan *outlier detection* · Chandola, Banerjee & Kumar, "Anomaly Detection: A Survey" · Vol 3 Bab 6 (segmentasi RFM) buku ini.

Next chapter

Bab 12 — peramalan permintaan. Termasuk temuan bahwa model boosting dengan fitur musiman ternyata kalah dari rata-rata sederhana per hari-pekan, dan bahwa forecast value added-nya hanya +0,23 pp.

Bab 12 — Peramalan Permintaan

Baseline musiman yang sulit dikalahkan, dan mengapa model boosting kalah dari rata-rata per hari-pekan

Learning objectives	Membangun baseline peramalan yang benar; menerapkan validasi bergulir; membedakan peramalan satu langkah dari banyak langkah; mengukur forecast value added; memilih metrik peramalan yang sesuai keputusan; menghubungkan peramalan ke keputusan persediaan; mengenali kapan peramalan tidak perlu diperbaiki
Prerequisites	Bab 4 (metrik regresi), Bab 8 (validasi); Vol 3 Bab 12 (budgeting, FVA, MAPE/WAPE); Vol 5 Bab 11 (newsvendor)
Estimasi waktu	Baca 2,5 jam · Praktik 5 jam
Difficulty	● Advanced
Skills covered	Peramalan deret waktu, baseline musiman, validasi bergulir, FVA, fitur lag, integrasi dengan keputusan persediaan
Business domain	Retail omnichannel — peramalan revenue harian TokoNusa

WHY — peramalan berbeda dari regresi biasa

TIGA PERBEDAAN YANG MENGUBAH SEGALANYA

1. **URUTAN WAKTU BERMAKNA**
Membagi data secara acak berarti memakai masa depan untuk memprediksi masa lalu. Selalu salah.
2. **BASELINE-NYA KUAT**
Pada klasifikasi, baseline adalah tebakan acak (AUC 0,5). Pada peramalan, baseline adalah "besok sama seperti hari yang sama minggu lalu" – dan itu sering sangat baik.
3. **HORIZON MENENTUKAN SEGALANYA**
Meramal 1 hari ke depan dan 30 hari ke depan adalah dua masalah yang berbeda. Fitur lag yang sangat kuat untuk horizon 1 TIDAK TERSEDIA untuk horizon 30.

⚠ **WARNING — kesalahan nomor satu dalam peramalan adalah memakai lag yang tidak akan tersedia**

Model dengan fitur "penjualan kemarin" akan menunjukkan akurasi yang sangat baik dalam pengujian. Lalu ia dipakai untuk merencanakan pemesanan enam minggu ke depan, dan "kemarin" tidak diketahui untuk hari ke-42.

Praktik yang benar: **tentukan horizon lebih dulu, lalu izinkan hanya fitur yang tersedia pada saat peramalan dibuat.** Untuk horizon 30 hari, lag terpendek yang boleh dipakai adalah lag-30.

Ini adalah bentuk kebocoran data (Bab 2) yang khusus pada deret waktu, dan ia jauh lebih sering terjadi karena terasa alami untuk memasukkan nilai kemarin.

HOW — membangun tangga baseline peramalan

Kode — empat baseline wajib

```
import numpy as np
import pandas as pd

# ts: revenue harian TokoNusa, 730 hari
# 640 hari pertama untuk latih, 90 hari terakhir untuk uji
tr, te = ts.iloc[:640], ts.iloc[640:]

def nilai(nama, pred, aktual=te.rev.values):
    mae = np.abs(aktual - pred).mean()
    rmse = ((aktual - pred) ** 2).mean() ** 0.5
    wape = np.abs(aktual - pred).sum() / aktual.sum()
    bias = (pred - aktual).sum() / aktual.sum() # arah kesalahan
    print(f"{nama:<30} MAE {mae/1e6:>7,.1f} jt | WAPE {wape:.4f} | bias {bias:+.4f}")

# 1. NAIF — besok = hari ini
nilai("naif (nilai kemarin)", np.r_[tr.rev.values[-1], te.rev.values[:-1]])

# 2. NAIF MUSIMAN — besok = hari yang sama minggu lalu
# Baseline paling penting untuk data dengan pola mingguan.
nilai("naif musiman (t-7)", ts.rev.values[640-7:len(ts)-7])

# 3. RATA-RATA BERGERAK
nilai("rata-rata bergerak 28 hari", np.full(len(te), tr.rev.values[-28:].mean()))

# 4. RATA-RATA PER HARI-PEKAN — profil mingguan dari data latih
profil = tr.groupby('dow').rev.mean()
nilai("rata-rata per hari-pekan", te.dow.map(profil).values)
```

Output — seluruh tangga, 90 hari uji

Metode	MAE	RMSE	WAPE	Bias	
naif (nilai kemarin)	703,0 jt	910,3 jt	0,1545	-0,0016	
rata-rata bergerak 28 hari	522,1 jt	697,3 jt	0,1148	-0,0536	
naif musiman (t-7)	390,1 jt	491,0 jt	0,0857	-0,0092	
rata-rata per hari-pekan	357,3 jt	481,9 jt	0,0786	-0,0278	← terbaik
XGBoost (dow + promo + tren)	379,6 jt	514,4 jt	0,0835	-0,0628	
XGBoost + fitur lag (h=1)	323,9 jt	409,2 jt	0,0712	-0,0449	

◆ BUSINESS INSIGHT — model boosting kalah dari rata-rata per hari-pekan

XGBoost dengan fitur hari-pekan, promo, dan tren menghasilkan WAPE 0,0835 — *lebih buruk* daripada rata-rata sederhana per hari-pekan (0,0786), dan hampir sama dengan naif musiman (0,0857).

Penjelasannya tidak rumit: seluruh sinyal yang dapat diperoleh model dari fitur-fitur itu **sudah tertangkap oleh profil mingguan**. Model menambahkan kapasitas untuk memodelkan hal yang tidak ada, dan sebagai gantinya menambahkan derau serta bias yang lebih besar (−0,0628 versus −0,0278).

Yang benar-benar menambah nilai adalah fitur lag — nilai aktual beberapa hari terakhir. Dengan lag-1, lag-7, lag-14, dan rata-rata bergerak 7 hari, WAPE turun ke 0,0712. Tetapi perhatikan syaratnya: **fitur itu hanya tersedia untuk horizon satu hari**.

Konsekuensi praktis untuk perencanaan: peramalan yang dipakai untuk pemesanan dengan lead time 7 hari tidak dapat memakai lag-1. Untuk kasus itu, angka yang relevan adalah 0,0835 versus 0,0786 — dan model kalah.

Forecast Value Added

FVA — pertanyaan yang seharusnya selalu ditanyakan

$$\text{FVA} = \text{akurasi metode X} - \text{akurasi baseline naif}$$

Setiap langkah dalam proses peramalan harus membuktikan bahwa ia **MENAMBAH** nilai. Termasuk penyesuaian manual.

PADA KASUS TOKONUSA (horizon > 1 hari)

Baseline naif musiman	WAPE 0,0857	
Rata-rata per hari-pekan	WAPE 0,0786	FVA +0,71 pp
XGBoost (dow + promo + tren)	WAPE 0,0835	FVA +0,23 pp

Model yang membutuhkan pipeline, pelatihan ulang, dan pemantauan menambah 0,23 poin persentase di atas metode yang dapat ditulis dalam satu baris SQL.

► EXECUTIVE PERSPECTIVE — FVA mengubah percakapan tentang investasi peramalan

Volume 3 Bab 12 memperkenalkan FVA untuk menilai penyesuaian manual pada peramalan. Prinsip yang sama berlaku untuk model.

Pertanyaan yang biasanya diajukan: "seberapa akurat peramalan kita?" Pertanyaan yang seharusnya diajukan: "*berapa akurasi yang kita tambahkan di atas metode paling sederhana yang mungkin?*"

Perbedaannya besar dalam praktik. Melaporkan WAPE 8,35% terdengar seperti kinerja yang layak. Melaporkan "kami menambahkan 0,23 poin persentase di atas rata-rata mingguan" menempatkan seluruh investasi dalam perspektif yang benar.

Dan pertanyaan berikutnya menjadi jelas dengan sendirinya: apakah 0,23 pp itu bernilai lebih besar daripada biaya membangun serta memelihara pipeline model? Untuk peramalan revenue agregat, jawabannya biasanya tidak. Untuk peramalan per SKU di mana kesalahan berdampak langsung pada persediaan, jawabannya bisa berbeda — dan cara mengetahuinya adalah menerjemahkan akurasi ke rupiah lewat model persediaan (Vol 5 Bab 11).

HOW — validasi bergulir

ROLLING ORIGIN / TIME SERIES SPLIT

```
fold 1 [ LATIH ][UJI]
```

```
fold 2 [   LATIH   ][UJI]
fold 3 [   LATIH   ][UJI]
fold 4 [   LATIH   ][UJI]
```

Data latih SELALU mendahului data uji. Ukuran latih tumbuh (expanding window) atau bergeser (sliding window).

MENGAPA WAJIB

- Satu periode uji tunggal dapat kebetulan mudah atau sulit
- Rata-rata beberapa fold memberi estimasi yang lebih jujur
- Sebarannya menunjukkan seberapa stabil model antar periode

EXPANDING vs SLIDING

expanding : pakai seluruh sejarah – baik bila pola stabil
 sliding : hanya N periode terakhir – baik bila pola bergeser
 Menjalankan keduanya dan membandingkan adalah cara termurah untuk mendeteksi apakah polanya bergeser.

Kode – validasi bergulir dengan horizon yang benar

```
from sklearn.model_selection import TimeSeriesSplit

# HORIZON = 7 hari: peramalan dibuat untuk 7 hari ke depan sekaligus.
# Karena itu fitur lag terpendek yang boleh dipakai adalah lag-7.
HORIZON = 7

fitur = pd.DataFrame({
    'dow':      ts.hari % 7,
    'promo':    ts.promo,
    'lag7':     ts.rev.shift(HORIZON),          # tersedia saat meramal
    'lag14':    ts.rev.shift(HORIZON + 7),
    'ma28':     ts.rev.shift(HORIZON).rolling(28).mean(),
})
# CATATAN: ts.rev.shift(1) TIDAK boleh dipakai di sini –
# pada saat meramal hari ke-7, nilai hari ke-6 belum diketahui.

tscv = TimeSeriesSplit(n_splits=5, test_size=30)
for i, (itr, ite) in enumerate(tscv.split(fitur.dropna()), 1):
    # latih, prediksi, catat WAPE per fold
    pass
```

Menghubungkan peramalan ke keputusan

PERAMALAN BUKAN TUJUAN – IA MASUKAN BAGI KEPUTUSAN

Vol 5 Bab 11 menunjukkan bahwa keputusan pemesanan optimal memerlukan DUA hal dari peramalan:

1. Estimasi tengah permintaan ← yang biasanya dibuat
2. DISTRIBUSI ketidakpastiannya ← yang biasanya tidak

News vendor memesan pada persentil ke-CR dari distribusi permintaan, bukan pada nilai tengahnya. Untuk SKU TokoNusa dengan critical ratio 0,6250, pesanan optimal adalah persentil ke-62,5 – yaitu 1.080 unit ketika ramalan tengahnya 1.000.

PERAMALAN YANG HANYA MEMBERI SATU ANGKA memaksa perencana menebak sebarannya sendiri.

✓ BEST PRACTICE — hasilkan interval, bukan hanya titik

Tiga cara menghasilkan distribusi peramalan, berurutan dari yang paling sederhana:

1. Dari residual historis. Kumpulkan kesalahan peramalan masa lalu pada horizon yang sama, dan pakai sebarannya sebagai estimasi ketidakpastian. Murah, tidak memerlukan perubahan model, dan sering cukup baik. Syaratnya: residual harus dikumpulkan pada horizon yang benar-benar dipakai.

2. Regresi kuantil. Latih beberapa model untuk memprediksi kuantil yang berbeda secara langsung (misalnya 10%, 50%, 90%). XGBoost mendukung ini lewat `objective='reg:quantileerror'`. Lebih tepat bila ketidakpastiannya bervariasi menurut kondisi.

3. Simulasi. Untuk keputusan besar, hasilkan ribuan jalur peramalan yang mungkin dan hitung distribusi hasilnya — persis pendekatan Monte Carlo di Vol 5 Bab 7.

Pilihan pertama memberi sebagian besar manfaatnya dengan usaha paling kecil, dan hampir tidak pernah dilakukan. Bila hanya satu perbaikan yang dapat dilakukan pada sistem peramalan yang ada, ini kandidat terkuatnya.

Kapan model kompleks benar-benar menang

Kondisi	Model kompleks menang?	Alasan
Deret tunggal, pola musiman stabil	Jarang	Baseline musiman sudah menangkap hampir seluruh sinyal
Ribuan SKU dengan pola berbeda	Ya	Satu model global belajar dari seluruh SKU; menanganikan SKU berdata sedikit jauh lebih baik
Banyak variabel penjelas (promo, harga, cuaca, hari libur)	Ya	Baseline tidak dapat memakainya sama sekali
Permintaan intermiten (banyak nol)	Tergantung	Metode khusus (Croston) sering lebih baik daripada keduanya
Horizon panjang (> 3 bulan)	Jarang	Ketidakpastian didominasi faktor yang tidak ada dalam data historis
Ada perubahan struktural baru-baru ini	Tidak	Semua metode gagal; yang dibutuhkan adalah penilaian manusia dan skenario

✗ COMMON MISTAKE — mengevaluasi peramalan pada horizon yang salah

Gejala: model dievaluasi dengan prediksi satu langkah ke depan (WAPE 0,0712), lalu dipakai untuk perencanaan pemesanan dengan lead time tujuh hari.

Mengapa merusak: akurasi satu langkah jauh lebih baik daripada akurasi tujuh langkah, karena informasi terbaru masih tersedia. Perencanaan yang dibangun di atas ekspektasi WAPE 7,1% padahal kenyataannya 8,4% akan menetapkan safety stock terlalu rendah secara sistematis.

Perbaikan: evaluasi selalu pada horizon yang *sama persis* dengan yang dipakai keputusan. Bila keputusan dibuat mingguan untuk empat minggu ke depan, evaluasi pada horizon 1 sampai 4 minggu, dan laporkan masing-masing.

Cara senior menghindarinya: masukkan horizon ke dalam nama metrik yang dilaporkan — "WAPE@h7" alih-alih "WAPE". Konvensi penamaan yang memaksa kejelasan lebih efektif daripada kehati-hatian.

Checklist peramalan

- ✓ Horizon ditetapkan sebelum membangun fitur; hanya fitur yang tersedia yang dipakai
- ✓ Naif musiman selalu dihitung sebagai baseline wajib
- ✓ FVA dilaporkan untuk setiap metode dan setiap penyesuaian manual
- ✓ Validasi bergulir dipakai, bukan pembagian acak
- ✓ Sebaran WAPE antar fold dilaporkan, bukan hanya rata-ratanya
- ✓ Bias dilaporkan berdampingan dengan akurasi
- ✓ Metrik dinamai dengan horizonnya
- ✓ Distribusi ketidakpastian dihasilkan, bukan hanya titik estimasi
- ✓ Peramalan diterjemahkan ke keputusan persediaan dengan critical ratio
- ✓ Expanding dan sliding window dibandingkan untuk mendeteksi pergeseran pola

Ending Card — Bab 12

What you learned

Tiga perbedaan mendasar peramalan dari regresi biasa; kesalahan lag yang tidak akan tersedia dan cara mencegahnya; tangga baseline peramalan lengkap dengan enam metode dan hasilnya; temuan bahwa XGBoost dengan fitur musiman kalah dari rata-rata per hari-pekan (WAPE 0,0835 versus 0,0786); peran fitur lag dan syarat horizonnya; forecast value added dan bagaimana ia mengubah percakapan investasi; validasi bergulir beserta pilihan expanding versus sliding; hubungan peramalan dengan keputusan persediaan lewat critical ratio; tiga cara menghasilkan distribusi peramalan; enam kondisi yang menentukan apakah model kompleks menang; serta kesalahan mengevaluasi pada horizon yang salah.

Skills mastered

Peramalan deret waktu · baseline musiman · validasi bergulir · FVA · peramalan kuantil · integrasi peramalan dengan keputusan persediaan.

Real business value

Melaporkan FVA +0,23 pp alih-alih WAPE 8,35% mengubah keputusan investasi peramalan dari "bangun pipeline model" menjadi "pakai rata-rata per hari-pekan dan alihkan usaha ke tempat lain". Dan menghasilkan distribusi alih-alih titik estimasi adalah prasyarat untuk seluruh optimasi persediaan di Vol 5 Bab 11 — perbaikan yang biayanya kecil dan hampir selalu terlewat.

Interview readiness

● INTERVIEW QUESTIONS

1. "Baseline apa yang kamu pakai untuk peramalan?" — naif musiman; jelaskan mengapa ia sulit dikalahkan.
2. "WAPE kami 8%. Bagus?" — tanyakan FVA terhadap naif musiman dan horizonnya.
3. "Mengapa tidak boleh membagi data deret waktu secara acak?" — memakai masa depan untuk memprediksi masa lalu.
4. "Model kamu pakai lag-1. Horizonnya berapa?" — jebakan; lag-1 hanya sah untuk horizon 1.
5. "Perencana butuh angka pemesanan. Apa yang kamu berikan?" — distribusi, bukan titik; jelaskan critical ratio.
6. "Kapan model ML mengalahkan metode statistik klasik untuk peramalan?" — banyak deret, banyak variabel penjelas; sebutkan kondisinya.

Exercises

Exercise 12.1 (Beginner · 45 menit)

Objective: membangun tangga baseline

Dengan data revenue harian TokoNusa: (a) hitung WAPE untuk naif, naif musiman, rata-rata bergerak 7/28/91 hari, dan rata-rata per hari-pekan; (b) hitung FVA masing-masing terhadap naif musiman; (c) hitung bias masing-masing; (d) metode mana yang kamu rekomendasikan, dan apa alasannya selain akurasi?

Answer key 12.1

(c) Perhatikan bahwa rata-rata bergerak 28 hari memiliki bias $-5,36\%$ — ia secara sistematis meremehkan. Penyebabnya adalah tren naik pada data: rata-rata masa lalu selalu tertinggal. Untuk perencanaan yang dijumlahkan (proyeksi kas, target penjualan), bias 5% jauh lebih merusak daripada selisih WAPE 3 pp.

(d) Rekomendasi yang kuat menyebut alasan di luar akurasi: rata-rata per hari-pekan menang pada WAPE *dan* memiliki bias yang lebih kecil daripada rata-rata bergerak, *dan* dapat dijelaskan kepada perencana dalam satu kalimat, *dan* tidak memerlukan pipeline. Empat alasan itu bersama-sama jauh lebih meyakinkan daripada selisih WAPE saja.

Exercise 12.2 (Intermediate · 90 menit)

Objective: akurasi menurut horizon

Bangun model peramalan dengan fitur lag, lalu evaluasi pada horizon 1, 3, 7, 14, dan 28 hari — dengan fitur yang disesuaikan agar sah untuk masing-masing horizon.

(a) Buat tabel WAPE per horizon untuk model dan untuk naif musiman. (b) Pada horizon berapa keunggulan model hilang? (c) Apa implikasinya untuk perencanaan dengan lead time berbeda? (d) Bagaimana kamu akan menyajikan ini kepada tim perencanaan?

Answer key 12.2

(b) Pola yang biasanya muncul: keunggulan model besar pada horizon 1 (karena lag-1 sangat informatif), menyusut cepat pada horizon 3-7, dan mendekati nol pada horizon 14+. Alasannya struktural — pada horizon panjang, satu-satunya informasi yang tersisa adalah pola musiman, dan baseline musiman sudah memakainya sepenuhnya.

(c) Implikasi praktis: untuk pemesanan dengan lead time panjang, model tidak menambah nilai dan tidak perlu dibangun. Untuk keputusan operasional harian (penjadwalan staf besok, alokasi kurir), model menambah nilai nyata.

(d) Penyajian yang bekerja adalah satu grafik: WAPE terhadap horizon, dua garis (model dan baseline), dengan garis vertikal menandai lead time yang benar-benar dipakai tiap keputusan. Grafik itu langsung menjawab "untuk keputusan mana model ini layak dipakai" — dan sering jawabannya hanya sebagian.

Exercise 12.3 (Advanced · 3 jam)

Objective: peramalan sampai keputusan persediaan

Bangun rantai lengkap dari peramalan ke pemesanan untuk satu SKU: (a) ramalkan permintaan mingguan dengan horizon sesuai lead time 7 hari; (b) hasilkan distribusi ketidakpastian dari residual historis; (c) hitung kuantitas pesanan optimal dengan critical ratio (Vol 5 Bab 11); (d) simulasikan biaya total selama 52 minggu dengan kebijakan ini; (e) bandingkan dengan kebijakan yang memesan tepat sebesar ramalan tengah; (f) hitung selisih biayanya.

Answer key 12.3 — kerangka jawaban

(e)–(f) Ini inti latihan. Memesan tepat sebesar ramalan tengah adalah kebijakan default di banyak perusahaan, dan ia optimal hanya bila biaya kelebihan sama persis dengan biaya kekurangan. Untuk SKU dengan critical ratio 0,625, kebijakan itu memesan terlalu sedikit secara sistematis, dan selisih biayanya muncul sebagai kehilangan penjualan yang tidak pernah tercatat di mana pun.

Yang membuat latihan ini bernilai: ia menunjukkan bahwa **memperbaiki kebijakan pemesanan sering bernilai lebih besar daripada memperbaiki akurasi peramalan**. Menurunkan WAPE dari 8,4% ke 7,1% memerlukan model, pipeline, dan pemeliharaan; mengubah kuantitas pesanan dari persentil 50 ke persentil 62,5 memerlukan satu perubahan formula. Pola yang sama dengan Bab 9: rantai keputusan lebih dulu, model belakangan.

Portfolio idea

★ PORTFOLIO TIP

Grafik "WAPE terhadap horizon" dengan dua garis dan penanda lead time keputusan adalah artefak satu halaman yang menjawab pertanyaan investasi peramalan dengan tepat. Sertakan tabel FVA di sampingnya. Kombinasi keduanya menunjukkan bahwa kamu menilai model dari kegunaannya, bukan dari kecanggihannya.

Further reading

Hyndman & Athanasopoulos, *Forecasting: Principles and Practice* — tersedia bebas dan menjadi rujukan standar · Makridakis dkk. tentang kompetisi M4 dan M5 — bukti empiris tentang kapan metode kompleks menang · Gilliland tentang FVA · Vol 3 Bab 12 dan Vol 5 Bab 11 buku ini.

Next chapter

Bab 13 — AI generatif untuk analytics: di mana ia benar-benar mempercepat pekerjaan, di mana ia gagal secara sistematis, dan bagaimana memakainya tanpa kehilangan disiplin verifikasi.

Bab 13 — AI Generatif untuk Analytics

Di mana ia benar-benar mempercepat pekerjaan, di mana ia gagal secara sistematis, dan cara memakainya tanpa kehilangan disiplin verifikasi

Learning objectives	Mengenali tugas analitis yang cocok dan tidak cocok untuk model bahasa; menulis prompt yang menghasilkan keluaran yang dapat diverifikasi; memakai structured output dan function calling; memahami arsitektur RAG dan kapan ia diperlukan; merancang alur kerja yang menempatkan verifikasi manusia pada titik yang tepat; menilai biaya dan risiko otomasi berbasis LLM
Prerequisites	Vol 1 (SQL dan Python); seluruh Bab 1–12
Estimasi waktu	Baca 3 jam · Praktik 5 jam
Difficulty	● Intermediate
Skills covered	Prompting, structured output, function calling, RAG, embeddings, agent, otomasi alur kerja analitis
Business domain	Lintas fungsi — pekerjaan harian tim analytics TokoNusa

WHY — cara memikirkan model bahasa dalam pekerjaan analitis

MODEL BAHASA SEBAGAI REKAN KERJA

Bayangkan seorang rekan yang:

- membaca sangat cepat dan mengingat banyak hal
- menulis kode dan teks dengan lancar
- tidak pernah lelah dan tersedia setiap saat
- TIDAK PERNAH mengatakan "saya tidak tahu"
- sesekali salah dengan sangat meyakinkan
- tidak memiliki akses ke data perusahaan kecuali diberikan

Rekan seperti itu sangat berharga – dengan satu syarat:
SETIAP KELUARAN DIVERIFIKASI SEBELUM DIPAKAI.

Nilai yang diperoleh berasal dari KECEPATAN menghasilkan draf, bukan dari kepercayaan pada hasilnya.

◆ BUSINESS INSIGHT — di mana penghematan waktunya sebenarnya

Penghematan terbesar bukan pada tugas yang sulit, melainkan pada tugas yang **mudah tetapi memakan waktu dan mudah diverifikasi**.

Tugas	Penghematan	Mengapa
Menulis draf kueri SQL yang strukturnya lazim	Tinggi	Cepat dihasilkan, langsung dapat diuji dengan menjalankannya
Mengubah kueri antar dialek SQL	Tinggi	Pekerjaan mekanis; kebenarannya mudah diperiksa
Menjelaskan kode warisan yang tidak berkomentar	Tinggi	Membaca kode lambat bagi manusia; hasilnya dapat diperiksa terhadap kodenya
Menulis docstring dan kamus data	Tinggi	Pekerjaan yang sering ditunda; kualitas draf sudah memadai
Membuat kerangka analisis dan daftar hipotesis	Sedang	Membantu kelengkapan; penilaian tetap milik analyst
Menulis ringkasan temuan untuk audiens berbeda	Sedang	Draf cepat; nuansa dan penekanan harus disunting manusia
Menghitung angka dari data	Negatif	Model bahasa tidak menghitung; ia menghasilkan teks yang terlihat seperti perhitungan
Menetapkan angka bisnis (CLV, margin, target)	Negatif	Ia akan menghasilkan angka yang masuk akal dan salah
Menyimpulkan sebab-akibat	Negatif	Ia akan menulis penjelasan kausal yang lancar tanpa dasar identifikasi apa pun

Pola yang terbaca: **gunakan untuk menghasilkan yang mudah diperiksa; jangan gunakan untuk menghasilkan yang sulit diperiksa**. Kueri SQL yang salah akan terlihat saat dijalankan. Angka CLV yang salah akan masuk ke presentasi direksi tanpa hambatan.

HOW — prompting untuk pekerjaan analitis

ANATOMI PROMPT YANG BEKERJA

1. PERAN & KONTEKS siapa yang menjawab, untuk siapa
2. SKEMA struktur tabel, tipe kolom, hubungan
3. ATURAN BISNIS definisi metrik, filter yang selalu berlaku
4. TUGAS satu tugas, dinyatakan tepat
5. FORMAT KELUARAN struktur yang diminta
6. BATASAN apa yang TIDAK boleh dilakukan
7. VERIFIKASI minta model menyatakan asumsinya

Butir 3 dan 7 yang paling sering hilang, dan keduanya yang paling menentukan kualitas keluaran.

Prompt — draf kueri SQL yang dapat diverifikasi

PERAN

Kamu membantu analyst TokoNusa (retail omnichannel) menulis SQL untuk PostgreSQL 15.

SKEMA

transaksi(id, customer_id, tanggal DATE, nilai NUMERIC,

```
kategori TEXT, kanal TEXT, status TEXT)
pelanggan(customer_id, tanggal_daftar DATE, wilayah TEXT,
           segmen TEXT)
pengiriman(transaksi_id, tanggal_kirim DATE, tanggal_tiba DATE,
           kurir TEXT)
```

ATURAN BISNIS

- Transaksi yang sah: status = 'selesai'. Selalu difilter.
- Pengiriman terlambat: tanggal_tiba - tanggal_kirim > 3 hari.
- "Pelanggan aktif": minimal 1 transaksi sah dalam 365 hari terakhir dari tanggal acuan.
- Semua analisis memakai TANGGAL ACUAN eksplisit, bukan CURRENT_DATE.

TUGAS

Hitung, per wilayah, untuk tanggal acuan 2026-01-31: jumlah pelanggan aktif, rata-rata transaksi per pelanggan aktif dalam 12 bulan, dan proporsi pelanggan yang pernah mengalami minimal satu pengiriman terlambat dalam periode itu.

FORMAT KELUARAN

1. Kueri SQL
2. Daftar asumsi yang kamu ambil
3. Satu kueri pemeriksaan untuk memvalidasi hasilnya

BATASAN

- Jangan memakai CURRENT_DATE atau NOW().
- Jangan mengarang nama kolom. Bila kolom yang dibutuhkan tidak ada di skema, KATAKAN dan berhenti.
- Bila tugas ini ambigu, sebutkan ambiguitasnya sebelum menulis SQL.

✓ BEST PRACTICE — tiga instruksi yang paling menaikkan kualitas

1. "Bila kolom yang dibutuhkan tidak ada, katakan dan berhenti." Tanpa instruksi ini, model akan mengarang nama kolom yang masuk akal. Kueri yang gagal karena kolom tidak ada relatif aman — ia error dan terlihat. Yang berbahaya adalah kolom yang *ada* tetapi bukan yang dimaksud.

2. "Sebutkan asumsi yang kamu ambil." Ini mengubah keluaran dari kotak hitam menjadi sesuatu yang dapat ditinjau. Sering daftar asumsinya yang mengungkap bahwa pertanyaannya sendiri ambigu — dan itu temuan yang berguna sebelum satu baris kode dijalankan.

3. "Tulis kueri pemeriksaan untuk memvalidasi hasilnya." Meminta model membuat alat untuk memeriksa pekerjaannya sendiri jauh lebih efektif daripada meminta model "berhati-hati". Kueri pemeriksaan biasanya menghitung total dengan cara yang berbeda, dan ketidakcocokan langsung terlihat.

Ketiganya memindahkan beban dari "percaya keluarannya" ke "verifikasi keluarannya", dan itu satu-satunya pola pemakaian yang aman dalam pekerjaan analitis.

WHAT — structured output dan function calling

TIGA TINGKAT INTEGRASI

1. TEKS BEBAS

Model menghasilkan teks; manusia membaca dan menyalin.
Cocok untuk: draf, penjelasan, brainstorming.

2. STRUCTURED OUTPUT

Model diwajibkan menghasilkan JSON sesuai skema tertentu.
Keluarannya dapat langsung diproses program.
Cocok untuk: klasifikasi, ekstraksi, penilaian berskala.

3. FUNCTION CALLING / TOOL USE

Model diberi daftar fungsi yang boleh dipanggil; ia memilih fungsi dan argumennya, PROGRAM yang menjalankan.
Cocok untuk: menjawab pertanyaan data, menjalankan alur kerja.

PRINSIP YANG BERLAKU DI KETIGANYA:

Model memutuskan APA yang harus dilakukan.
PROGRAM yang MELAKUKANNYA, dengan validasi.
Model TIDAK PERNAH menjadi sumber angka.

Structured output – klasifikasi keluhan pelanggan

```
# Skema keluaran yang WAJIB dipatuhi model.
# Enum membatasi jawaban ke kategori yang kita tetapkan,
# sehingga hasilnya dapat langsung diagregasi.
SKEMA = {
  "type": "object",
  "properties": {
    "kategori": {
      "type": "string",
      "enum": ["pengiriman", "produk", "pembayaran",
              "layanan", "aplikasi", "lainnya"],
    },
    "subkategori": {
      "type": "string",
    },
    "keparahan": {
      "type": "integer",
      "minimum": 1,
      "maximum": 5,
    },
    "perlu_tindak_lanjut": {
      "type": "boolean",
    },
    "keyakinan": {
      "type": "number",
      "minimum": 0,
      "maximum": 1,
    },
    "kutipan": {
      "type": "string",
      "description": "kutipan LANGSUNG dari teks keluhan "
                    "yang mendasari klasifikasi"
    },
  },
  "required": ["kategori", "keparahan", "keyakinan", "kutipan"]
}
```

■ TECHNICAL NOTE — dua bidang yang membuat keluaran dapat diaudit

Bidang **keyakinan** memungkinkan penyaringan: kasus dengan keyakinan rendah dialihkan ke manusia. Ini mengubah sistem dari "otomatis penuh" menjadi "otomatis dengan pengecualian" — bentuk yang jauh lebih dapat dipertahankan.

Bidang **kutipan** jauh lebih penting daripada yang terlihat. Dengan mewajibkan model mengutip *teks aslinya*, halusinasi menjadi terlihat: bila kutipan tidak ada dalam teks asli, klasifikasinya tidak berdasar. Pemeriksaan ini dapat dijalankan otomatis dengan pencocokan string, dan biayanya hampir nol.

Pola ini — **wajibkan model menunjukkan buktinya, lalu periksa buktinya secara program** — adalah salah satu teknik paling efektif untuk memakai model bahasa dalam alur kerja produksi.

Function calling – pola yang benar untuk menjawab pertanyaan data

```
# Fungsi yang boleh dipanggil model. Perhatikan bahwa TIDAK ADA
# fungsi yang menerima SQL bebas – model hanya boleh memilih
# dari kueri yang sudah divalidasi, dengan parameter terbatas.
FUNGSI = [
  {
    "name": "revenue_per_periode",
    "parameters": {
      "tanggal_mulai": "date",
      "tanggal_akhir": "date",
      "granularitas": ["harian", "mingguan", "bulanan"],
      "wilayah": "string|null"
    },
  },
  {
    "name": "metrik_pelanggan",
    "parameters": {
      "tanggal_acuan": "date",
      "metrik": ["aktif", "churn", "clv", "cac"],
      "segmen": "string|null"
    },
  },
]
```

```
# ALUR YANG BENAR:
# 1. Pengguna bertanya dengan bahasa alami
# 2. Model MEMILIH fungsi + argumen      (model memutuskan)
# 3. Program MEMVALIDASI argumen         (program menjaga)
# 4. Program MENJALANKAN kueri           (program menghitung)
# 5. Model MENJELASKAN hasilnya          (model menyusun kata)
#
# Angka SELALU berasal dari langkah 4, tidak pernah dari model.
```

⚠ WARNING — memberi model akses SQL bebas ke basis data produksi

Pola "text-to-SQL langsung ke produksi" tersebar luas dan memiliki empat masalah yang serius:


- 1. Kebenaran tidak terjamin.** Kueri yang salah tetapi berjalan menghasilkan angka yang salah tanpa peringatan. Tidak ada mekanisme yang membedakan kueri benar dari kueri yang kebetulan mengembalikan angka.
- 2. Definisi metrik menyimpang.** "Pelanggan aktif" akan didefinisikan berbeda setiap kali ditanya, sehingga dua orang memperoleh angka berbeda untuk pertanyaan yang sama. Ini persis masalah tata kelola metrik dari Vol 3 Bab 13, diperbesar dan dipercepat.
- 3. Risiko keamanan dan biaya.** Kueri yang memindai seluruh tabel, mengakses kolom sensitif, atau berjalan berjam-jam.
- 4. Tidak dapat diaudit.** Ketika angka dipertanyakan tiga bulan kemudian, tidak ada yang tahu kueri mana yang menghasilkannya.

Pola yang aman: model memilih dari kumpulan kueri terparameter yang sudah ditinjau, atau menghasilkan SQL yang *dijalankan pada lingkungan hanya-baca dengan batas waktu dan ditinjau manusia sebelum masuk ke laporan*. Kebebasan penuh disediakan untuk eksplorasi analyst, bukan untuk pelaporan.

WHAT — RAG dan embeddings

MASALAH: model tidak mengetahui isi dokumen perusahaan.

RETRIEVAL-AUGMENTED GENERATION



EMBEDDING: representasi teks sebagai vektor, sehingga teks yang bermakna serupa berada berdekatan dalam ruang vektor. Pencarian menjadi "cari tetangga terdekat", bukan pencocokan kata kunci.

KAPAN RAG DIPERLUKAN

- Pengetahuan berada di dokumen internal
- Pengetahuan berubah lebih cepat daripada siklus pelatihan
- Jawaban WAJIB dapat dilacak ke sumbernya

KAPAN TIDAK PERLU

- Dokumennya sedikit dan muat seluruhnya dalam prompt
- Jawabannya ada di basis data → pakai function calling
- Pertanyaannya butuh perhitungan → pakai kode

Sebagian besar kegagalan RAG bukan pada tahap pembangkitan, melainkan pada tahap *pencarian*: potongan yang tepat tidak ditemukan, sehingga model menjawab dari potongan yang salah atau dari pengetahuan umumnya.

1. Pemotongan yang buruk. Memotong dokumen setiap 500 karakter memutus tabel, memisahkan definisi dari konteksnya, dan menghasilkan potongan yang tidak bermakna sendirian. Pemotongan berdasarkan struktur dokumen (bagian, subbagian) hampir selalu lebih baik.

3. Tidak ada evaluasi pencarian. Tim mengukur kualitas jawaban tanpa pernah mengukur apakah potongan yang benar berhasil ditemukan. Bangun kumpulan pertanyaan uji dengan potongan yang seharusnya ditemukan, dan ukur recall pencarian secara terpisah.

4. Tidak ada penanganan "tidak ditemukan". Ketika tidak ada potongan yang relevan, sistem tetap menjawab. Instruksi eksplisit untuk mengatakan "informasi ini tidak ada dalam dokumen yang tersedia" adalah perbaikan termurah dengan dampak terbesar.

SPEKTRUM OTONOMI – dan risikonya

ATURAN PENENTU TINGKAT:

murah + mudah dibalik → tingkat 3 dapat diterima
 mahal + sulit dibalik → tingkat 1, selalu

Tingkat 3 : merangkum tiket layanan menjadi laporan mingguan
Tingkat 2 : menghasilkan kueri untuk analisis ad hoc
Tingkat 1 : menulis memo keputusan investasi
TIDAK PERNAH : mengubah definisi metrik, menyetujui anggaran,
mengirim komunikasi ke pelanggan tanpa tinjauan

✓ BEST PRACTICE — alur kerja analitis yang memakai AI dengan benar

CONTOH: laporan bulanan kinerja kategori

1. PROGRAM menjalankan kueri terparameter yang sudah ditinjau
→ angka berasal dari sini, selalu
2. PROGRAM menghitung perubahan, dekomposisi, dan anomali dengan aturan yang ditulis manusia
→ logika bisnis tidak diserahkan ke model
3. AI menyusun narasi dari angka-angka itu
→ tugas yang benar-benar cocok: mengubah tabel menjadi kalimat yang dapat dibaca
4. PROGRAM memverifikasi bahwa setiap angka dalam narasi ada dalam data sumber (pencocokan string)
→ menangkap halusinasi angka secara otomatis
5. MANUSIA meninjau, menambahkan konteks yang tidak ada dalam data, dan menyetujui

Langkah 4 yang membedakan alur kerja produksi dari eksperimen. Ia murah, otomatis, dan menangkap kelas kesalahan yang paling merusak kredibilitas.

Batas yang tidak boleh dilewati

Jangan pakai untuk	Alasan
Menghasilkan angka	Model bahasa menghasilkan teks yang menyerupai perhitungan, bukan hasil perhitungan. Angka selalu dari kode atau kueri
Menyimpulkan sebab-akibat	Ia akan menulis penjelasan kausal yang lancar tanpa dasar identifikasi (Bab 1, Volume 4)
Menetapkan definisi metrik	Definisi metrik adalah keputusan tata kelola (Vol 3 Bab 13), bukan pertanyaan bahasa
Memutuskan tindakan pada pelanggan	Keputusan yang berdampak pada orang membutuhkan alasan yang dapat dipertanggungjawabkan (Bab 14)
Meringkas data yang belum diagregasi	Model tidak dapat "membaca" 200.000 baris; ia akan menyimpulkan dari yang muat dalam konteks
Menilai kualitas pekerjaannya sendiri	Penilaian diri model tidak terkalibrasi; verifikasi harus berasal dari luar

✗ COMMON MISTAKE — meminta model "menganalisis" data mentah

Gejala: menempelkan 500 baris CSV ke dalam prompt dan meminta "temukan pola menarik".

Mengapa merusak: model tidak menghitung; ia menghasilkan pernyataan yang *terdengar* seperti hasil analisis. Sebagian akan kebetulan benar, sebagian salah, dan tidak ada cara membedakannya tanpa menghitung ulang sendiri — yang berarti tidak ada waktu yang dihemat.

Perbaikan: minta model *menulis kode* yang menganalisis data, lalu jalankan kodenya. Keluarannya menjadi dapat diverifikasi dan dapat diulang. Perbedaan antara "analisis data ini" dan "tuliskan kode untuk menganalisis data ini" adalah perbedaan antara pemakaian yang berbahaya dan pemakaian yang produktif.

Cara senior menghindarinya: menetapkan aturan tim bahwa setiap angka dalam dokumen apa pun harus dapat dilacak ke kode yang menghasilkannya. Aturan itu secara otomatis mengecualikan pemakaian model bahasa sebagai sumber angka, tanpa perlu larangan eksplisit.

Checklist pemakaian AI generatif

- ✓ Tugas dinilai: mudah diperiksa atau sulit diperiksa
- ✓ Aturan bisnis dan definisi metrik disertakan dalam prompt
- ✓ Model diminta menyatakan asumsi dan mengaku ketika informasi tidak ada
- ✓ Model diminta menghasilkan alat verifikasi untuk pekerjaannya
- ✓ Structured output dipakai bila keluaran akan diproses program
- ✓ Bidang keyakinan dan kutipan disertakan agar keluaran dapat diaudit
- ✓ Angka selalu berasal dari kode atau kueri, tidak pernah dari model
- ✓ Akses SQL bebas ke produksi dihindari; kueri terparameter dipakai
- ✓ Kualitas pencarian RAG diukur terpisah dari kualitas jawaban
- ✓ Tingkat otonomi ditetapkan dari biaya kesalahan dan kemudahan membalikkannya
- ✓ Verifikasi otomatis angka dipasang pada alur kerja produksi

Ending Card — Bab 13

What you learned

Cara memikirkan model bahasa sebagai rekan kerja yang cepat tetapi tidak pernah mengaku tidak tahu; sembilan tugas analitis dengan penilaian penghematan waktunya dan pola yang mendasarinya; anatomi prompt tujuh bagian dan tiga instruksi yang paling menaikkan kualitas; tiga tingkat integrasi dari teks bebas sampai function calling beserta prinsip bahwa model memutuskan dan program melakukan; structured output dengan bidang keyakinan dan kutipan yang membuat keluaran dapat diaudit; empat masalah serius text-to-SQL langsung ke produksi; arsitektur RAG dan empat penyebab kegagalannya yang paling umum; spektrum otonomi lima tingkat dan aturan penentunya; alur kerja produksi lima langkah dengan verifikasi angka otomatis; serta enam batas yang tidak boleh dilewati.

Skills mastered

Prompting untuk pekerjaan analitis · structured output · function calling · RAG dan evaluasinya · perancangan alur kerja dengan verifikasi · penetapan tingkat otonomi.

Real business value

Penghematan waktu nyata pada penulisan kueri, konversi dialek, dokumentasi, dan penyusunan narasi laporan — tugas yang memakan sebagian besar waktu analyst dan mudah diverifikasi. Dan verifikasi angka otomatis pada alur kerja produksi mencegah kelas kesalahan yang paling cepat merusak kredibilitas tim analytics.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagaimana kamu memakai AI dalam pekerjaan analitis?" — tugas yang mudah diverifikasi; beri contoh konkret dan batasnya.
2. "Bisakah kita pakai text-to-SQL untuk semua pertanyaan bisnis?" — sebutkan empat masalahnya; usulkan kueri terparameter.
3. "Bagaimana kamu mencegah halusinasi?" — wajibkan kutipan, verifikasi otomatis, angka dari kode.
4. "Kapan RAG diperlukan?" — pengetahuan di dokumen internal, berubah cepat, butuh sitasi.
5. "Mengapa RAG kami sering salah?" — periksa pencarian sebelum pembangkitan; empat penyebab umum.
6. "Sampai tingkat otonomi mana kamu nyaman?" — biaya kesalahan dan kemudahan membalikkan; beri contoh per tingkat.

Exercises

Exercise 13.1 (Beginner · 40 menit)

Objective: menyusun prompt yang dapat diverifikasi

Tulis prompt lengkap tujuh bagian untuk tugas: "hitung contribution margin per kanal untuk kuartal terakhir". Gunakan skema TokoNusa. Sertakan seluruh aturan bisnis yang relevan dari Volume 3.

(a) Tulis promptnya. (b) Jalankan pada model yang tersedia. (c) Periksa keluarannya: adakah kolom yang dikarang? adakah asumsi yang tidak dinyatakan? (d) Perbaiki prompt berdasarkan temuanmu dan jalankan ulang.

Answer key 13.1

(c) Kegagalan yang paling umum ditemukan: model mendefinisikan contribution margin sebagai revenue dikurangi HPP saja, mengabaikan biaya variabel lain (ongkir, komisi pembayaran, biaya penanganan) yang di Vol 3 Bab 4 termasuk dalam definisi. Ia tidak salah secara umum — ia salah *untuk perusahaan ini*.

Pelajaran utamanya: **kualitas keluaran hampir seluruhnya ditentukan oleh kelengkapan aturan bisnis dalam prompt**. Model tidak dapat mengetahui definisi internal perusahaan. Ini juga alasan mengapa tim yang memiliki kamus data dan definisi metrik yang terdokumentasi memperoleh manfaat jauh lebih besar dari AI daripada tim yang tidak — dokumentasi yang selama ini terasa birokratis menjadi masukan produktif.

Exercise 13.2 (Intermediate · 90 menit)

Objective: alur kerja dengan verifikasi otomatis

Bangun alur kerja lima langkah untuk laporan bulanan kategori: kueri terparameter, perhitungan program, narasi AI, verifikasi angka otomatis, tinjauan manusia.

(a) Implementasikan langkah 4 — fungsi yang mengekstrak seluruh angka dari narasi dan memeriksa keberadaannya dalam data sumber. (b) Uji dengan narasi yang sengaja memuat satu angka salah. (c) Tangani kasus tepi: angka yang dibulatkan, persentase yang dihitung, dan angka dalam satuan berbeda. (d) Berapa tingkat deteksinya?

Answer key 13.2

(c) Kasus tepi adalah bagian tersulit dan yang menentukan apakah pemeriksaan berguna. Pendekatan yang bekerja: normalisasi seluruh angka ke bentuk kanonik (hilangkan pemisah ribuan, samakan satuan), lalu terima kecocokan dalam toleransi relatif (misalnya 0,5%) untuk mengakomodasi pembulatan. Angka turunan seperti persentase perubahan dihitung ulang dari data sumber dan dibandingkan.

(d) Tingkat deteksi biasanya tinggi untuk angka yang dikutip langsung dan lebih rendah untuk angka turunan. Yang penting bukan mencapai 100%, melainkan menangkap kelas kesalahan yang paling merusak: angka yang *tidak ada sama sekali* dalam data sumber. Pemeriksaan sederhana pun menangkap hampir seluruh kasus itu.

Exercise 13.3 (Advanced · 3 jam)

Objective: RAG untuk kamus data

Bangun sistem RAG sederhana atas dokumentasi data perusahaan (atau kumpulan dokumen yang kamu buat): definisi metrik, kamus tabel, aturan bisnis.

(a) Rancang strategi pemotongan berdasarkan struktur dokumen. (b) Terapkan pencarian hibrida (semantik + kata kunci). (c) Bangun 20 pertanyaan uji dengan potongan yang seharusnya ditemukan; ukur recall pencarian. (d) Bandingkan recall pencarian semantik saja dengan hibrida. (e) Terapkan penanganan "tidak ditemukan" dan uji dengan pertanyaan di luar cakupan.

Answer key 13.3 — kerangka jawaban

(d) Pola yang biasanya muncul: pencarian semantik unggul pada pertanyaan konseptual ("bagaimana kita mendefinisikan pelanggan aktif"), pencarian kata kunci unggul pada istilah persis ("apa itu kolom skor_loyalitas"). Hibrida mengungguli keduanya, dan selisihnya paling besar pada pertanyaan yang memuat nama kolom atau kode.

(e) Uji dengan pertanyaan di luar cakupan adalah bagian yang paling sering dilewatkan dan paling penting untuk sistem produksi. Sistem yang menjawab pertanyaan yang jawabannya tidak ada dalam dokumen akan mengarang, dan pengguna tidak memiliki cara mengetahuinya. Ukur secara eksplisit: dari 10 pertanyaan di luar cakupan, berapa yang dijawab dengan "tidak ditemukan"? Angka di bawah 8 dari 10 berarti sistem belum siap dipakai.

Portfolio idea

★ PORTFOLIO TIP

Alur kerja dengan verifikasi angka otomatis (Exercise 13.2) adalah artefak yang menunjukkan pemahaman tentang bagaimana AI dipakai secara bertanggung jawab dalam produksi — topik yang sedang dicari hampir semua organisasi dan yang sedikit kandidat dapat tunjukkan dengan kode nyata.

Further reading

Dokumentasi penyedia model tentang structured output dan tool use · Lewis dkk., "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks" · Literatur tentang evaluasi sistem RAG (retrieval recall, faithfulness, groundedness) · Vol 3 Bab 13 (tata kelola metrik) buku ini.

Next chapter

Bab 14 — tata kelola AI dan ML: bias, privasi, explainability, drift, dan human-in-the-loop. Termasuk demonstrasi bahwa pergeseran distribusi merusak kalibrasi jauh sebelum ia merusak AUC — sehingga pemantauan yang hanya melihat AUC tidak akan melihat apa pun.

Bab 14 — Tata Kelola AI dan ML

Bias, privasi, explainability, drift — dan mengapa pemantauan yang hanya melihat AUC tidak akan melihat apa pun

Learning objectives	Merancang pemantauan model yang mendeteksi kegagalan sebelum bisnis merasakannya; mengenali dan mengukur bias antar kelompok; menerapkan prinsip privasi pada data pelatihan; menetapkan kewajiban explainability sesuai konteks; merancang human-in-the-loop pada titik yang tepat; menyusun dokumentasi model yang bertahan setelah pembuatnya pergi
Prerequisites	Seluruh Bab 1-13; Vol 3 Bab 13 (Goodhart, tata kelola metrik); Vol 4 Bab 13 (tata kelola eksperimen); Vol 5 Bab 14 (tata kelola keputusan)
Estimasi waktu	Baca 3 jam · Praktik 4 jam
Difficulty	● Advanced / Production Ready
Skills covered	Model monitoring, drift detection, fairness assessment, privasi, explainability, human-in-the-loop, model card
Business domain	Lintas industri — dengan penerapan pada model retensi TokoNusa

Bagian I — Drift, dan mengapa pemantauan biasa gagal

Output — pergeseran distribusi pada fitur, model tidak dilatih ulang

Kondisi	AUC	Rata-rata prediksi	Churn aktual
dasar (tanpa drift)	0.8000	0,4419	0,4419
recency +10%	0.8000	0,4507	0,4419
recency +30%	0.7993	0,4703	0,4419
recency +60%	0.7972	0,4974	0,4419
frekuensi -20%	0.7987	0,4902	0,4419

Pada pergeseran recency 60% — perubahan besar yang akan sangat terlihat pada laporan operasional — AUC hanya turun 0,0028. Rata-rata prediksi meleset 5,55 pp.

⚠ **WARNING — kalibrasi rusak jauh sebelum kemampuan membedakan rusak**

Ini adalah temuan yang menentukan seluruh rancangan pemantauan model, dan ia berlawanan dengan praktik yang paling umum.

Tim yang memantau AUC akan melihat $0,8000 \rightarrow 0,7972$ dan menyimpulkan bahwa model baik-baik saja. Sementara itu, model memperkirakan 49,74% pelanggan akan churn padahal kenyataannya 44,19%. Setiap perhitungan nilai harapan yang dibangun di atasnya — ambang keputusan Bab 9, anggaran kampanye, proyeksi kerugian — meleset 12,6% secara relatif.

Penyebabnya struktural: **AUC hanya mengukur urutan**. Menggeser seluruh fitur ke satu arah menggeser seluruh skor ke satu arah, dan urutannya tetap. Tidak ada pergeseran distribusi yang dapat dideteksi AUC selama urutannya bertahan.

Konsekuensi untuk rancangan pemantauan: **metrik pemantauan utama bukan AUC, melainkan selisih antara rata-rata prediksi dan rata-rata hasil aktual**. Metrik itu murah dihitung, tidak memerlukan label lengkap bila memakai sampel, dan mendeteksi kelas kegagalan yang paling merusak.

TIGA JENIS DRIFT

1. DATA DRIFT (covariate shift)
Distribusi FITUR berubah; hubungan fitur-target tetap.
Contoh: kampanye akuisisi membawa pelanggan yang lebih muda.
Deteksi: bandingkan distribusi fitur antar periode.
Dampak: kalibrasi bergeser, urutan sering bertahan.
2. CONCEPT DRIFT
Hubungan fitur-target BERUBAH.
Contoh: setelah aplikasi baru diluncurkan, recency 60 hari tidak lagi berarti sama seperti dulu.
Deteksi: butuh label — kinerja pada data baru.
Dampak: model rusak secara mendasar; pelatihan ulang wajib.
3. LABEL DRIFT
Distribusi target berubah tanpa perubahan hubungan.
Contoh: churn naik karena kompetitor baru masuk pasar.
Deteksi: pantau prevalensi aktual.
Dampak: kalibrasi bergeser; ambang perlu ditinjau.

YANG PALING BERBAHAYA: concept drift, karena ia hanya terdeteksi setelah label tersedia — dan pada model dengan jendela label 180 hari, itu berarti enam bulan kemudian.

■ TECHNICAL NOTE — memantau ketika label datang terlambat

Model churn TokoNusa memerlukan 180 hari sebelum kebenarannya diketahui. Menunggu label berarti menjalankan model buta selama dua kuartal.

Empat sinyal awal yang tersedia tanpa label, berurutan dari yang paling murah:

1. Distribusi skor. Bandingkan histogram skor bulan ini dengan bulan lalu. Pergeseran besar adalah tanda pertama dan paling cepat.

2. Distribusi fitur. Pantau rata-rata, simpangan baku, proporsi nilai hilang, dan proporsi kategori untuk setiap fitur. Population Stability Index (PSI) adalah ukuran ringkas yang lazim; PSI di atas 0,25 lazim dianggap sebagai pergeseran material.

3. Label antara (proxy label). Untuk churn 180 hari, "tidak ada transaksi dalam 60 hari" tersedia jauh lebih cepat dan berkorelasi kuat. Ia tidak menggantikan label sebenarnya, tetapi memberi peringatan dini.

4. Kinerja pada kohor lama. Pelanggan yang diberi skor delapan bulan lalu sudah memiliki label. Kinerjanya bukan kinerja model hari ini, tetapi penurunan pada kohor lama adalah peringatan bahwa kohor baru kemungkinan lebih buruk.

Sistem pemantauan yang baik memakai keempatnya, dengan ambang yang ditetapkan di muka dan pemilik yang jelas untuk menindaklanjuti.

Bagian II — Keadilan antar kelompok

TIGA DEFINISI KEADILAN – DAN MENGAPA TIDAK BISA SEMUANYA

1. DEMOGRAPHIC PARITY

Proporsi yang diprediksi positif SAMA antar kelompok.
 $P(\hat{y}=1 | A) = P(\hat{y}=1 | B)$

2. EQUAL OPPORTUNITY

Recall SAMA antar kelompok – yang benar-benar positif memiliki peluang sama untuk terdeteksi.
 $P(\hat{y}=1 | y=1, A) = P(\hat{y}=1 | y=1, B)$

3. CALIBRATION PARITY

Skor berarti sama antar kelompok – skor 0,7 berarti 70% di kedua kelompok.
 $P(y=1 | \hat{y}=s, A) = P(y=1 | \hat{y}=s, B)$

HASIL YANG SUDAH DIBUKTIKAN SECARA MATEMATIS:

Bila prevalensi sebenarnya BERBEDA antar kelompok, ketiga kriteria ini TIDAK DAPAT dipenuhi bersamaan.

Artinya: keadilan bukan pemeriksaan teknis yang bisa lolos atau gagal. Ia PILIHAN antara kriteria yang saling bertentangan, dan pilihan itu harus dibuat secara sadar dan dinyatakan.

► **EXECUTIVE PERSPECTIVE — pertanyaan yang benar bukan "apakah model kami adil"**

Pertanyaan "apakah model kami adil?" tidak memiliki jawaban teknis, karena keadilan memiliki definisi yang saling bertentangan dan tidak dapat dipenuhi bersamaan.

Pertanyaan yang dapat dijawab dan harus ditanyakan:

1. Siapa yang terdampak keputusan ini, dan bagaimana? Model retensi memberi sebagian pelanggan tawaran yang tidak diberikan kepada yang lain. Dampaknya kecil. Model kredit menentukan siapa yang memperoleh pinjaman. Dampaknya besar dan permanen. Tingkat kehati-hatian harus sebanding dengan dampaknya.

2. Kriteria keadilan mana yang kita pilih, dan mengapa? Untuk keputusan yang memberi manfaat (tawaran, promosi), equal opportunity biasanya paling relevan. Untuk keputusan yang membatasi akses (kredit, asuransi), calibration parity dan tinjauan hukum menjadi pusat.

3. Bagaimana kinerja model berbeda antar kelompok, dan apakah selisih itu dapat kita pertahankan? Ini pertanyaan empiris yang dapat dijawab dengan tabel — dan tabel itu harus ada dalam setiap laporan model, seperti pada laporan enam bagian di Bab 8.

4. Apa yang terjadi pada orang yang dirugikan oleh kesalahan model? Adakah jalur banding? Adakah manusia yang dapat meninjau? Pertanyaan ini sering lebih menentukan diterima tidaknya sistem daripada metrik keadilan mana pun.

Kode — pemeriksaan keadilan yang rutin dijalankan

```
import pandas as pd
from sklearn.metrics import roc_auc_score

def audit_kelompok(y, skor, kelompok, ambang):
    """Kinerja model dipecah menurut kelompok. Jalankan pada
    setiap peluncuran DAN setiap pelatihan ulang."""
    hasil = []
    for g in kelompok.unique():
        m = kelompok == g
        pred = skor[m] >= ambang
        hasil.append({
            'kelompok':    g,
            'n':            m.sum(),
            'prevalensi':   y[m].mean(),          # tingkat dasar sebenarnya
            'auc':          roc_auc_score(y[m], skor[m]),
            'rata_skor':    skor[m].mean(),        # kalibrasi: bandingkan
            'selisih_kal':  y[m].mean() - skor[m].mean(), # dengan prevalensi
            'proporsi_positif': pred.mean(),      # demographic parity
            'recall':       pred[y[m] == 1].mean(), # equal opportunity
            'presisi':       y[m][pred].mean() if pred.sum() else float('nan'),
        })
    return pd.DataFrame(hasil).round(4)

# WAJIB dipecah menurut: wilayah, kanal, tenure, dan setiap
# atribut yang relevan secara etis atau hukum di konteks kamu.
```


⚠ **WARNING — menghapus atribut sensitif tidak menghapus bias**

Respons pertama yang paling umum terhadap kekhawatiran keadilan adalah membuang kolom yang sensitif dari data pelatihan. Ia terasa tepat dan hampir selalu tidak memadai.

Penyebabnya: atribut sensitif dapat direkonstruksi dari kombinasi fitur lain. Kode pos berkorelasi dengan wilayah dan kelompok sosial-ekonomi; jenis perangkat berkorelasi dengan pendapatan; pola waktu berbelanja berkorelasi dengan jenis pekerjaan. Model tidak perlu melihat atribut sensitif untuk memakainya.

Yang lebih merugikan: dengan membuang kolomnya, kamu kehilangan kemampuan *mengukur* apakah ada perbedaan perlakuan. Bias tetap ada, dan sekarang tidak terlihat.

Praktik yang lebih baik: simpan atribut sensitif untuk keperluan *audit*, keluarkan dari *fitur model* bila hukum atau kebijakan mensyaratkannya, dan ukur perbedaan kinerja antar kelompok secara rutin. Memisahkan "data yang dipakai model" dari "data yang dipakai untuk mengaudit model" adalah rancangan yang benar.

Bagian III — Privasi

Prinsip	Penerapan pada ML	Pemeriksaan konkret
Minimisasi data	Hanya kumpulkan fitur yang benar-benar menambah nilai	Ablation study (Bab 3): fitur dengan kontribusi di bawah ambang dibuang, terutama yang sensitif
Pembatasan tujuan	Data yang dikumpulkan untuk A tidak otomatis boleh dipakai untuk B	Catat tujuan pengumpulan tiap sumber data; tinjau saat model baru dibangun
Anonimisasi dan agregasi	Pakai agregat bila cukup; hindari pengidentifikasi langsung sebagai fitur	Periksa apakah model dapat berjalan tanpa ID; biasanya bisa
Retensi terbatas	Data pelatihan tidak disimpan selamanya	Tetapkan masa simpan; hapus snapshot lama secara terjadwal
Hak individu	Penghapusan data harus tercermin pada model	Rencana pelatihan ulang berkala; catat versi data tiap model
Data pihak ketiga	Data yang dibeli sering memiliki batasan pemakaian	Tinjau lisensi sebelum memasukkannya sebagai fitur

■ **TECHNICAL NOTE — model dapat membocorkan data pelatihan**

Risiko privasi tidak berhenti pada data; model itu sendiri dapat membocorkan informasi tentang orang-orang yang datanya dipakai melatihnya.

Membership inference: penyerang dapat menentukan apakah seseorang termasuk dalam data pelatihan dengan memeriksa seberapa yakin model pada data orang itu. Risiko ini meningkat pada model yang overfitting — alasan tambahan untuk mengendalikan kompleksitas (Bab 6).

Memorisasi: model dengan kapasitas besar dapat menghafal contoh individual, terutama yang jarang atau ekstrem. Pada model tabular dengan puluhan fitur, risikonya rendah; pada model bahasa yang dilatih atas teks internal, risikonya nyata dan memerlukan penanganan khusus.

Pertahanan yang praktis untuk konteks analytics: hindari overfitting, jangan memakai pengidentifikasi langsung sebagai fitur, agregasikan bila memungkinkan, dan batasi akses ke keluaran model per individu sama ketatnya dengan akses ke data mentahnya.

Bagian IV — Explainability dan human-in-the-loop

TINGKAT KEWAJIBAN MENJELASKAN — ditentukan oleh DAMPAK

DAMPAK RENDAH — rekomendasi produk, urutan tampilan

- tidak ada kewajiban formal
- tetap sediakan penjelasan agar tim dapat menilai

DAMPAK SEDANG — siapa yang menerima tawaran, prioritas layanan

- penjelasan per individu tersedia bila diminta
- audit kelompok rutin

DAMPAK TINGGI — kredit, asuransi, kepegawaian, kesehatan

- penjelasan WAJIB dan harus dapat dipahami penerima
- jalur banding ke manusia
- dokumentasi lengkap dan tinjauan berkala
- sering ada kewajiban hukum yang spesifik per yurisdiksi

HUMAN-IN-THE-LOOP: DI MANA MANUSIA DITEMPATKAN

SEBELUM manusia menyetujui tiap keputusan

- dampak tinggi, volume rendah

PENGECUALIAN manusia menangani kasus berkeyakinan rendah

- pola paling praktis untuk sebagian besar kasus

SESUDAH manusia meninjau sampel keputusan

- dampak rendah, volume tinggi

BANDING manusia meninjau bila ada keberatan

- wajib untuk dampak tinggi, apa pun polanya

✓ BEST PRACTICE — pola "otomatis dengan pengecualian"

Pola yang paling sering tepat bukan otomatis penuh maupun tinjauan penuh, melainkan penyaringan berdasarkan keyakinan:

skor $> 0,80$ atau $< 0,20$ → otomatis (keyakinan tinggi)

$0,20 \leq \text{skor} \leq 0,80$ → antrean tinjauan manusia

kasus yang ditandai aturan → selalu manusia

Manfaatnya berlapis. Volume yang harus ditinjau manusia turun drastis sementara kasus yang paling mungkin salah tetap ditangani manusia. Dan keputusan manusia pada zona abu-abu menghasilkan *label berkualitas tinggi* pada kasus yang paling sulit — persis data yang paling berguna untuk pelatihan ulang.

Yang harus dijaga: alokasikan sebagian kecil kasus berkeyakinan tinggi ke tinjauan manusia secara **acak**. Tanpa itu, tidak ada yang pernah tahu apakah model salah pada kasus yang ia yakini — dan sistem menjadi buta terhadap kesalahannya sendiri. Ini masalah yang sama dengan bias seleksi label pada Bab 11.

Model card: dokumentasi yang bertahan

MODEL CARD — satu halaman, sepuluh bagian

1. IDENTITAS nama, versi, tanggal, pemilik, kontak
2. TUJUAN keputusan apa yang didukung; siapa penggunanya
3. DATA sumber, periode, ukuran, cara pembagian
4. FITUR daftar, definisi, sumber, dan yang SENGAJA TIDAK dipakai beserta alasannya
5. KINERJA metrik utama, per segmen, dengan baseline
6. AMBANG nilai operasi dan dasar penetapannya
7. BATAS PAKAI untuk siapa model TIDAK boleh dipakai
8. KEADILAN kriteria yang dipilih, hasil audit kelompok
9. PEMANTAUAN metrik, ambang alarm, irama, pemilik
10. RIWAYAT versi sebelumnya, alasan perubahan, insiden yang pernah terjadi

Bagian 7 dan 10 yang paling sering hilang dan paling sering dibutuhkan – bagian 7 saat model dipakai di luar konteks aslinya, bagian 10 saat terjadi masalah.

◆ BUSINESS INSIGHT — biaya sebenarnya dari model tanpa dokumentasi

Model tanpa model card tetap berjalan dengan baik — sampai orang yang membangunnya pindah. Setelah itu, tiga hal terjadi secara berurutan dan dapat diprediksi.

Pertama, tidak ada yang berani mengubahnya. Model menjadi kotak hitam yang dibiarkan berjalan karena mengubahnya berisiko. Ia terus dipakai jauh setelah kondisi yang mendasarinya berubah.

Kedua, ia dipakai di luar konteks aslinya. Model yang dibangun untuk memilih target kampanye dipakai untuk menilai kelayakan kredit internal, karena "skornya kan sudah ada". Tanpa bagian "batas pakai", tidak ada yang menghentikannya.

Ketiga, ketika akhirnya bermasalah, tidak ada yang dapat menjelaskan. Pertanyaan direksi "mengapa sistem menolak pelanggan ini" tidak terjawab, dan responsnya biasanya mematikan seluruh sistem — termasuk bagian yang bekerja dengan baik.

Model card memakan waktu dua jam untuk ditulis dan mencegah ketiganya. Ia adalah pekerjaan dengan rasio nilai terhadap usaha tertinggi dalam seluruh siklus hidup model, dan hampir selalu ditunda karena tidak terasa mendesak.

Sistem tata kelola AI/ML yang lengkap

Artefak	Pemilik	Irama
Model card	Pembuat model	Diperbarui setiap versi
Registri model (semua model produksi)	Analytics lead	Ditinjau triwulan
Dashboard pemantauan (skor, fitur, kalibrasi)	Data engineering	Harian otomatis, ditinjau mingguan
Laporan audit kelompok	Pembuat model	Setiap peluncuran dan pelatihan ulang
Log keputusan model (untuk banding)	Pemilik sistem	Berjalan terus; disimpan sesuai kebijakan retensi
Tinjauan model berkala	Komite	Semesteran untuk model berdampak tinggi
Catatan insiden	Analytics lead	Setiap kejadian; ditinjau tahunan

✗ COMMON MISTAKE — tidak ada yang memiliki model setelah diluncurkan

Gejala: model berjalan di produksi selama delapan belas bulan tanpa satu kali pun ditinjau, karena proyeknya sudah "selesai" dan tim berpindah ke proyek berikutnya.

Mengapa merusak: model adalah sistem yang berjalan, bukan proyek yang selesai. Ia menurun kinerjanya seiring dunia berubah, dan penurunannya senyap — pada kasus drift di awal bab ini, AUC hampir tidak bergerak sementara kalibrasi meleset 5,55 pp.

Perbaikan: setiap model produksi memiliki pemilik bernama, dashboard pemantauan, ambang alarm yang ditetapkan di muka, dan jadwal tinjauan. Bila tidak ada yang bersedia menjadi pemilik, itu sinyal kuat bahwa modelnya sebaiknya dimatikan.

Cara senior menghindarinya: menjadikan "siapa pemiliknya setelah peluncuran" sebagai pertanyaan yang harus dijawab *sebelum* proyek disetujui — sejajar dengan pertanyaan nilai bisnis di Bab 1. Model tanpa pemilik adalah utang teknis yang berbunga.

Checklist tata kelola AI dan ML

- ✓ Metrik pemantauan utama mencakup kalibrasi, bukan hanya AUC
- ✓ Selisih rata-rata prediksi terhadap hasil aktual dipantau berkala
- ✓ Sinyal awal tanpa label dipasang: distribusi skor, distribusi fitur, label antara
- ✓ Ambang alarm ditetapkan di muka dengan pemilik yang jelas
- ✓ Kriteria keadilan dipilih secara sadar dan dinyatakan, bukan diasumsikan
- ✓ Audit kelompok dijalankan setiap peluncuran dan pelatihan ulang
- ✓ Atribut sensitif disimpan untuk audit meski dikeluarkan dari fitur
- ✓ Prinsip minimisasi data diterapkan; fitur berkontribusi rendah dibuang
- ✓ Tingkat kewajiban explainability ditetapkan dari dampak keputusan
- ✓ Human-in-the-loop ditempatkan pada zona keyakinan rendah, dengan sampel acak pada zona tinggi
- ✓ Model card lengkap sepuluh bagian, termasuk batas pakai dan riwayat
- ✓ Setiap model produksi memiliki pemilik bernama dan jadwal tinjauan

Ending Card — Bab 14

What you learned

Demonstrasi bahwa pergeseran recency 60% menurunkan AUC hanya 0,0028 sementara rata-rata prediksi meleset 5,55 pp, dan implikasinya bahwa pemantauan berbasis AUC buta terhadap kegagalan yang paling merusak; tiga jenis drift dan cara mendeteksi masing-masing; empat sinyal awal untuk model dengan label yang datang terlambat; tiga definisi keadilan dan bukti bahwa ketiganya tidak dapat dipenuhi bersamaan; empat pertanyaan yang menggantikan "apakah model kami adil"; kode audit kelompok yang rutin dijalankan; mengapa menghapus atribut sensitif memperburuk keadaan; enam prinsip privasi dan penerapannya; risiko membership inference dan memorisasi; tingkat kewajiban explainability menurut dampak; pola otomatis-dengan-pengecualian beserta sampel acak yang menjaganya; model card sepuluh bagian; dan biaya sebenarnya dari model tanpa dokumentasi atau pemilik.

Skills mastered

Model monitoring dan deteksi drift · audit keadilan antar kelompok · penerapan prinsip privasi · perancangan human-in-the-loop · penulisan model card · perancangan sistem tata kelola model.

Real business value

Memantau kalibrasi alih-alih AUC mendeteksi kegagalan model berbulan-bulan lebih awal — pada kasus ini, selisih 5,55 pp pada rata-rata prediksi berarti seluruh perhitungan nilai harapan meleset 12,6% relatif, dan tidak ada satu pun yang terlihat pada dashboard AUC. Dan model card yang memakan dua jam mencegah model dipakai di luar konteksnya, yang merupakan sumber insiden model paling umum di organisasi besar.

Interview readiness

● INTERVIEW QUESTIONS

1. "Bagaimana kamu memantau model di produksi?" — kalibrasi lebih dulu, bukan AUC; tunjukkan angkanya.
2. "Label kami baru tersedia 6 bulan kemudian. Bagaimana?" — empat sinyal awal tanpa label.
3. "Apakah model kamu adil?" — tanyakan definisi mana; jelaskan bahwa ketiganya tidak dapat dipenuhi bersamaan.
4. "Kami hapus kolom gender. Sudah aman?" — tidak; proxy; dan kamu kehilangan kemampuan mengukur.
5. "Di mana kamu menempatkan manusia?" — zona keyakinan rendah, plus sampel acak pada zona tinggi.
6. "Siapa yang bertanggung jawab atas model ini enam bulan lagi?" — jika tidak terjawab, model tidak seharusnya diluncurkan.

Exercises

Exercise 14.1 (Beginner · 45 menit)

Objective: merancang pemantauan

Untuk model churn TokoNusa, rancang dashboard pemantauan: (a) daftar metrik dengan irama dan ambang alarm masing-masing; (b) untuk tiap metrik, tentukan apakah ia memerlukan label; (c) simulasikan tiga skenario kegagalan (data drift, concept drift, pipeline rusak) dan tentukan metrik mana yang akan mendeteksi masing-masing; (d) berapa lama sampai terdeteksi pada tiap skenario?

Answer key 14.1

(c)–(d) Pemetaannya: *pipeline rusak* (misalnya kolom menjadi kosong) terdeteksi paling cepat — dalam hitungan jam — lewat pemantauan proporsi nilai hilang. *Data drift* terdeteksi dalam hitungan hari sampai minggu lewat distribusi fitur dan distribusi skor. *Concept drift* adalah yang paling lambat: tanpa label, ia hanya terdeteksi lewat label antara, dan itu pun dengan keyakinan terbatas.

Kesimpulan rancangan yang penting: **waktu deteksi berbanding terbalik dengan keseriusan masalah**. Masalah yang paling merusak terdeteksi paling lambat. Ini alasan mengapa label antara dan tinjauan kohor lama layak dibangun meski terasa tidak langsung berguna.

Exercise 14.2 (Intermediate · 90 menit)

Objective: audit keadilan

Jalankan audit kelompok lengkap pada model churn TokoNusa untuk wilayah, kanal, metode bayar, dan pembagian tenure.

(a) Hitung seluruh metrik dalam fungsi audit. (b) Adakah kelompok dengan recall jauh lebih rendah? (c) Adakah kelompok dengan kalibrasi yang meleset? (d) Bila ditemukan perbedaan, tentukan apakah ia berasal dari perbedaan prevalensi atau dari kinerja model. (e) Tulis satu paragraf rekomendasi.

Answer key 14.2

(d) Ini bagian yang paling menentukan kualitas jawaban. Perbedaan proporsi yang diprediksi positif antar kelompok *tidak dengan sendirinya* menunjukkan masalah — bila prevalensi churn di suatu wilayah memang lebih tinggi, model yang benar akan memberi skor lebih tinggi di sana.

Cara membedakannya: bandingkan **selisih kalibrasi** (prevalensi aktual dikurangi rata-rata skor) antar kelompok. Bila kalibrasinya baik di semua kelompok, perbedaan proporsi positif mencerminkan perbedaan nyata, bukan bias model. Bila kalibrasinya meleset ke arah berbeda antar kelompok, ada masalah yang harus ditangani.

(e) Rekomendasi yang kuat menyatakan kriteria keadilan yang dipilih beserta alasannya, melaporkan temuan terhadap kriteria itu, dan mengusulkan tindakan spesifik — bukan pernyataan umum bahwa model "sudah diaudit".

Exercise 14.3 (Advanced · 2,5 jam)

Objective: model card lengkap

Tulis model card sepuluh bagian untuk model churn TokoNusa. Untuk bagian 7 (batas pakai), tuliskan minimal lima situasi di mana model ini tidak boleh dipakai, masing-masing dengan alasannya. Untuk bagian 9 (pemantauan), sertakan tabel metrik-ambang-pemilik-irama yang lengkap.

Answer key 14.3 — kerangka jawaban

Lima batas pakai yang layak muncul: (1) tidak untuk pelanggan dengan tenure di bawah tiga bulan — data terlalu sedikit dan kalibrasi tidak diuji di sana; (2) tidak untuk pelanggan B2B — model dilatih pada perilaku ritel; (3) tidak untuk menentukan intervensi — skor churn bukan uplift (Bab 10); (4) tidak untuk keputusan yang membatasi akses pelanggan (misalnya menolak layanan) — dampaknya berbeda kelas dan tidak ada jalur banding; (5) tidak untuk periode setelah perubahan besar pada aplikasi atau kebijakan pengiriman sampai divalidasi ulang.

Batas nomor 3 adalah yang paling penting dan paling sering dilanggar, dan menuliskannya secara eksplisit dalam dokumen resmi adalah cara paling efektif mencegahnya — jauh lebih efektif daripada menjelaskannya berulang kali dalam rapat.

Exercise 14.4 (Production Challenge · 6 jam)

Objective: sistem tata kelola lengkap

Rancang sistem tata kelola ML untuk organisasi dengan lima model produksi: registri model, template model card, dashboard pemantauan bersama, prosedur tinjauan berkala, jalur banding, dan prosedur penanganan insiden. Sertakan rencana penerapan bertahap 12 bulan yang realistis terhadap kapasitas tim.

Answer key 14.4 — rubrik

Rancangan yang kuat bertahap dan dimulai dari yang paling mudah: registri model dan model card lebih dulu (biaya rendah, manfaat langsung), lalu pemantauan otomatis, lalu tinjauan berkala. Rancangan yang lemah menetapkan komite dan proses tinjauan lengkap pada bulan pertama, yang tidak akan berjalan.

Bagian yang paling sering hilang: *prosedur penanganan insiden*. Ia harus menjawab siapa yang dapat mematikan model, dalam kondisi apa, apa yang menggantikannya sementara (biasanya aturan bisnis yang lebih sederhana), dan bagaimana pelanggan yang terdampak ditangani. Menyiapkan aturan pengganti sebelum insiden terjadi adalah pekerjaan satu hari yang mencegah kepanikan berhari-hari — pola yang sama dengan daftar pemotongan persediaan di Vol 5 Bab 11.

Portfolio idea

★ PORTFOLIO TIP

Model card lengkap dengan bagian "batas pakai" yang serius adalah artefak yang sangat menonjol, karena ia menunjukkan pemahaman tentang siklus hidup model setelah peluncuran — fase yang tidak muncul sama sekali di sebagian besar portofolio, dan yang paling menentukan apakah model menciptakan nilai jangka panjang.

Further reading

Mitchell dkk., "Model Cards for Model Reporting" · Kleinberg, Mullainathan & Raghavan tentang ketidakmungkinan memenuhi beberapa kriteria keadilan sekaligus · Barocas, Hardt & Narayanan, *Fairness and Machine Learning* — tersedia bebas · Sculley dkk., "Hidden Technical Debt in Machine Learning Systems" · Vol 3 Bab 13, Vol 4 Bab 13, dan Vol 5 Bab 14 buku ini.

Next chapter

Bab 15 — capstone. Membangun sistem retensi lengkap dari data sampai tata kelola, dan menjawab pertanyaan yang menjadi ujian sebenarnya: apakah sistem ini menciptakan nilai, dan bagaimana kita akan tahu bila ia berhenti melakukannya.

Bab 15 — Capstone Semester 6

Sistem retensi lengkap: dari data mentah sampai tata kelola, dengan satu ujian — apakah ia menciptakan nilai, dan bagaimana kita tahu bila ia berhenti

Learning objectives	Mengintegrasikan seluruh kemampuan Volume 6 menjadi satu sistem produksi; membangun rantai lengkap dari fitur sampai keputusan; mengukur nilai inkremental alih-alih nilai semu; merancang pemantauan dan tata kelola; menyajikan sistem kepada direksi dan kepada auditor; menyatakan batas dan risiko secara jujur
Prerequisites	Seluruh Bab 1–14; Vol 4 capstone (bukti kausal); Vol 5 capstone (alokasi modal)
Estimasi waktu	Baca 1,5 jam · Pengerjaan 30–40 jam
Difficulty	● Advanced / Production Ready
Skills covered	Seluruh Layer 6 terintegrasi + komunikasi eksekutif + tata kelola model
Business domain	Retail omnichannel — sistem retensi pelanggan TokoNusa

Skenario

Volume 5 berakhir dengan alokasi Rp 18,5 miliar. Salah satu inisiatif yang terpilih dalam portofolio optimal adalah program win-back dengan biaya Rp 0,30 miliar dan nilai batas bawah Rp 0,80 miliar. Program itu kini akan dijalankan, dan tim analytics diminta membangun sistem yang menentukan siapa yang dihubungi.

PENUGASAN DARI CHIEF COMMERCIAL OFFICER

"Kita punya kapasitas 120.000 kontak per tahun dan anggaran program Rp 5,04 miliar. Saya ingin sistem yang memutuskan siapa yang dihubungi, dan saya ingin tiga hal:

1. Angka nilai yang bisa saya pertahankan di rapat direksi.
Bukan angka yang terdengar besar — angka yang benar.
2. Kejelasan tentang apa yang sistem ini TIDAK bisa lakukan.
Saya sudah pernah melihat sistem yang dipakai untuk hal-hal yang bukan tujuannya.
3. Cara kita tahu kalau sistemnya rusak, sebelum pelanggan yang memberi tahu kita."

◆ BUSINESS INSIGHT — ketiga permintaan itu adalah ujian yang berbeda

Permintaan pertama menguji kejujuran kuantitatif. Volume ini menunjukkan bahwa angka nilai yang sama dapat dilaporkan sebagai +Rp 5,34 miliar atau -Rp 0,60 miliar tergantung apakah uplift diukur atau diasumsikan. Kandidat yang melaporkan angka pertama tidak berbohong — ia hanya belum menguji asumsinya.

Permintaan kedua menguji pemahaman tentang batas. Model churn tidak dapat menjawab pertanyaan kausal (Bab 1), tidak dapat dipakai untuk memilih intervensi (Bab 10), dan tidak berlaku untuk segmen yang tidak diwakili data latih (Bab 14).

Permintaan ketiga menguji pemahaman tentang siklus hidup. Dan jawabannya berlawanan dengan intuisi: metrik yang paling penting dipantau bukan AUC, melainkan selisih antara rata-rata prediksi dan hasil aktual (Bab 14).

Ketiganya adalah pertanyaan yang diajukan eksekutif berpengalaman, dan ketiganya jarang terjawab dalam proyek ML biasa.

Bahan yang tersedia

Sumber	Isi yang relevan
Dataset TokoNusa	200.000 pelanggan, 19 fitur, tiga target; satu fitur sengaja bocor
Vol 3 Bab 6	CLV Rp 495.644; segmentasi RFM; definisi churn 180 hari
Vol 4 capstone	Bukti kausal: keterlambatan → churn 4,01 pp (bukan 18,82 pp); win-back belum pernah diuji secara acak
Vol 5 Bab 10 dan capstone	Portofolio inisiatif; kapasitas eksekusi mengikat; win-back terpilih dengan biaya Rp 0,30 miliar
Vol 6 Bab 8–9	Model AUC 0,8007 (logistik) / 0,8000 (XGBoost); terkalibrasi dengan selisih maksimum 0,0095; ambang optimal 0,4460
Vol 6 Bab 10	Uplift per desil dari eksperimen; puncak di desil 3 (−16,21 pp), desil 1 hanya −7,47 pp
Vol 6 Bab 14	Drift recency 60% → AUC turun 0,0028, kalibrasi meleset 5,55 pp

Deliverable

No	Dokumen atau artefak	Isi minimum
D1	Kanvas kelayakan (1 halaman)	Sepuluh butir Bab 1; batas atas nilai; baseline yang harus dikalahkan; keputusan lanjut atau tidak
D2	Pipeline fitur (kode)	Point-in-time correctness; tanggal snapshot sebagai parameter; uji yang membuktikan tidak ada kebocoran (Bab 2–3)
D3	Tangga baseline dan model (2 halaman)	Dari aturan bisnis sampai model penuh; ablation study per kelompok fitur; perbandingan minimal tiga keluarga model
D4	Laporan kinerja enam bagian (2 halaman)	Struktur Bab 8 lengkap, termasuk kinerja per segmen dan kalibrasi
D5	Analisis keputusan (2 halaman)	Ambang dari biaya; kendala kapasitas; nilai dibandingkan aturan yang berlaku hari ini (Bab 9)
D6	Analisis uplift (2 halaman)	Rancangan holdout; uplift per segmen; nilai inkremental versus nilai semu; strategi targeting yang direkomendasikan (Bab 10)

D7	Model card (1 halaman)	Sepuluh bagian Bab 14, dengan minimal lima batas pakai
D8	Rancangan pemantauan (1 halaman)	Metrik, ambang alarm, pemilik, irama; sinyal awal tanpa label; prosedur insiden
D9	Memo eksekutif (1 halaman)	Jawaban atas ketiga permintaan CCO, dalam bahasa yang dapat dibawa ke rapat direksi

Panduan pengerjaan

Tahap 1 — Kelayakan sebelum kode

PERTANYAAN YANG HARUS DIJAWAB LEBIH DULU

- Berapa batas atas nilai bila prediksi sempurna?
(Bab 1: Rp 34,1 miliar tanpa kendala apa pun)
- Berapa setelah kendala kapasitas 120.000 kontak?
- Berapa setelah uplift heterogen diperhitungkan?
- Aturan apa yang dipakai bisnis HARI INI, dan berapa nilainya? Itu yang harus dikalahkan, bukan tebakan acak.
- Apakah uplift kampanye sudah pernah diukur secara acak?
Bila belum, apakah membangun model harus MENUNGGU pengukuran itu, atau berjalan paralel?

■ TECHNICAL NOTE — jawaban atas pertanyaan terakhir menentukan urutan seluruh proyek

Godaan yang wajar: bangun model dulu karena itu pekerjaan yang jelas, ukur uplift belakangan.

Urutan yang benar hampir selalu terbalik. Holdout acak biayanya mendekati nol dan dapat dipasang pada kampanye yang *sudah berjalan* minggu ini. Model membutuhkan berminggu-minggu dan nilainya bergantung sepenuhnya pada hasil pengukuran uplift.

Bila uplift ternyata seragam, model churn adalah alat targeting yang tepat dan proyeknya berjalan seperti rencana. Bila uplift berbentuk bukit seperti pada Bab 10, seluruh strategi targeting berubah — dan mengetahuinya sebelum model dibangun menghemat pekerjaan yang salah arah.

Rekomendasi yang tepat untuk D1: **jalankan keduanya paralel, dengan holdout dipasang pada minggu pertama**. Pembangunan model tidak perlu menunggu, tetapi *keputusan strategi targeting* harus menunggu.

Tahap 2 — Pipeline dan model

URUTAN YANG BENAR (Bab 2)

definisi target → garis waktu → pipeline fitur → baseline
 pemantauan ← ambang & keputusan ← evaluasi ← model

JEBAKAN YANG SENGAJA DIPASANG DALAM DATASET:

- `status_akun_ditutup` — kolom bocor. Memasukkannya menaikkan AUC dari 0,8000 ke 0,9244 dan menghasilkan model yang tidak berguna di produksi.

- anggota tier dan skor loyalitas – redundan (tier ditentukan oleh skor ≥ 700). Gain menempatkan tier di posisi pertama; permutation importance tidak memasukkannya ke delapan besar (Bab 7).
- Godaan menyetel XGBoost sebelum mencoba regresi logistik. Pada data ini logistik menang (0,8007 vs 0,8000).

Tahap 3 — Dari model ke keputusan ke nilai

RANTAI NILAI LENGKAP – dan di mana nilainya sebenarnya

Batas atas prediksi sempurna, tanpa kendala	Rp 34,1 miliar
↓ kendala kapasitas 120.000 kontak	
Targeting skor tertinggi, uplift diasumsikan	Rp 5,34 miliar
↓ uplift diukur, ternyata heterogen	
Targeting skor tertinggi, uplift terukur	Rp -0,60 miliar
↓ targeting dialihkan ke uplift tertinggi	
Targeting berbasis uplift	Rp 4,60 miliar
↓ dikurangi biaya membangun & memelihara sistem	
NILAI BERSIH YANG DAPAT DIPERTAHANKAN	← hitung sendiri

Perhatikan bahwa langkah yang paling menentukan bukan pemodelan, melainkan PENGUKURAN UPLIFT.

⚠ **WARNING — empat jebakan yang sengaja dipasang dalam capstone ini**

Jebakan 1 — melaporkan nilai versus acak. Selisih model terhadap pemilihan acak (Rp 5,43 miliar pada Bab 9) adalah angka yang paling menggoda untuk dilaporkan dan hampir selalu menyesatkan. TokoNusa tidak memilih pelanggan secara acak; ia memakai aturan recency. Angka yang benar adalah Rp 0,80 miliar.

Jebakan 2 — memakai skor churn sebagai dasar targeting. Ini yang dilakukan hampir semua program retensi, dan pada kasus ini nilainya negatif.

Jebakan 3 — melewati uji kebocoran. Dataset memuat kolom yang menaikkan AUC 0,1244. Kandidat yang melaporkan AUC 0,92 tanpa menyelidiki telah gagal pada bagian yang paling menentukan.

Jebakan 4 — merancang pemantauan berbasis AUC. Bab 14 menunjukkan bahwa AUC hampir tidak bergerak pada drift yang merusak kalibrasi 5,55 pp. Rancangan pemantauan yang hanya melihat AUC memenuhi permintaan ketiga CCO di atas kertas dan gagal dalam praktik.

Tahap 4 — Tata kelola dan penyerahan

► EXECUTIVE PERSPECTIVE — bentuk memo yang menjawab ketiga permintaan

Memo satu halaman yang kuat pada kasus ini memiliki struktur berikut:

Nilai (permintaan 1). Satu angka, dengan pembandingnya dinyatakan: "sistem ini menghasilkan Rp X miliar per tahun di atas aturan seleksi yang kita pakai hari ini, diukur dengan uplift dari eksperimen acak, setelah dikurangi biaya operasional." Sertakan rentang, bukan titik.

Batas (permintaan 2). Lima kalimat, masing-masing dimulai dengan "sistem ini tidak dapat...". Yang paling penting: *sistem ini tidak dapat memberi tahu tindakan apa yang akan berhasil pada seorang pelanggan; ia hanya memberi tahu siapa yang paling mungkin berubah karena tindakan yang sudah kita uji.*

Deteksi kerusakan (permintaan 3). Tiga metrik dengan ambang dan pemiliknya, ditambah satu kalimat tentang apa yang terjadi bila alarm berbunyi — termasuk aturan bisnis pengganti yang sudah disiapkan.

Dan satu bagian yang tidak diminta tetapi selalu dihargai: **apa yang akan kita pelajari dalam enam bulan ke depan.** Holdout permanen menghasilkan pengetahuan baru setiap siklus, dan menyatakan itu mengubah persepsi proyek dari "sistem yang dibangun" menjadi "kemampuan yang tumbuh".

Rubrik penilaian — enam pengulas

Pengulas	Yang diperiksa	Kegagalan yang umum
Senior Data Analyst	Kebocoran diuji; baseline lengkap; split sah; metrik sesuai masalah; kalibrasi diperiksa	AUC 0,92 dilaporkan tanpa penyelidikan
Analytics Manager	Rantai keputusan diselesaikan sebelum model disempurnakan; uplift diukur; pembanding jujur	Berminggu-minggu penyetelan model, ambang tetap 0,5
CCO / eksekutif komersial	Angka nilai dapat dipertahankan; batas dinyatakan; rencana deteksi kerusakan konkret	Nilai dilaporkan terhadap pemilihan acak
ML Engineer	Pipeline dapat dijalankan ulang; fitur konsisten antara latih dan inferensi; versi tercatat	Notebook yang tidak dapat direproduksi
Risk / Compliance	Model card lengkap; audit kelompok; batas pakai; jalur banding; privasi	Bagian "batas pakai" kosong atau generik
Hiring Manager	Memo satu halaman berdiri sendiri; temuan negatif disampaikan dengan solusi	Dokumen panjang tanpa rekomendasi tegas

✗ COMMON MISTAKE — tiga kegagalan yang paling sering pada capstone ini

1. Mengoptimalkan model, mengabaikan rantai keputusan. Enam puluh persen waktu dihabiskan pada pemodelan, yang menyumbang bagian terkecil dari nilai. Alokasi yang benar: 20% model, 80% rantai keputusan, pengukuran, dan tata kelola.

2. Melaporkan nilai tanpa menyebut pembandingnya. Setiap angka nilai harus menjawab "dibandingkan dengan apa". Angka tanpa pembanding tidak dapat dinilai dan tidak dapat dipertahankan.

3. Menyerahkan sistem tanpa pemilik. Model card tanpa nama pada bagian pemilik adalah tanda bahwa sistemnya belum siap diserahkan.

Simulasi wawancara Layer 6

PERTANYAAN PADA WAWANCARA PERAN
DATA SCIENTIST / SENIOR ANALYST / ANALYTICS MANAGER

FONDASI

1. "Kapan kamu TIDAK memakai machine learning?"
2. "Bagaimana kamu tahu ada kebocoran data?"
 - ▶ uji fitur tunggal, uji tanggal, uji lompatan
3. "Model kamu AUC 0,95. Reaksi pertamamu?"
 - ▶ curiga, bukan senang

PEMODELAN

4. "XGBoost atau regresi logistik?"
 - ▶ tergantung apakah ada interaksi; tunjukkan cara mengujinya
5. "Dua metode importance memberi jawaban berbeda. Kenapa?"
6. "Fitur turunan kamu tidak menaikkan AUC. Apa artinya?"

EVALUASI & KEPUTUSAN

7. "Akurasi 98% pada deteksi penipuan. Bagus?"
8. "Bagaimana kamu memilih ambang?"
 - ▶ dari biaya; hubungkan ke critical ratio newsvendor
9. "Berapa nilai model ini bagi bisnis?"
 - ▶ selalu tanyakan "dibandingkan dengan apa"

NILAI & KAUSALITAS

10. "Kami targetkan pelanggan berisiko tertinggi. Ada masalah?"
 - ▶ lost cause; tunjukkan pola uplift berbentuk bukit
11. "Model menunjukkan keterlambatan adalah prediktor terkuat. Berapa yang layak kita investasikan untuk SLA?"
 - ▶ jebakan kausal; 18,82 pp vs 4,00 pp
12. "Bagaimana kamu membuktikan program kamu berhasil?"
 - ▶ holdout acak; tidak ada alternatif

PRODUKSI & TATA KELOLA

13. "Bagaimana kamu memantau model?"
 - ▶ kalibrasi lebih dulu, bukan AUC
14. "Label baru ada 6 bulan lagi. Bagaimana memantau?"
15. "Siapa pemilik model ini tahun depan?"

● INTERVIEW TIP — pola jawaban yang membedakan tingkat

Junior menjawab pertanyaan yang ditanyakan dengan benar secara teknis.

Menengah menambahkan konteks: kapan jawabannya berbeda, apa yang perlu diperiksa lebih dulu.

Senior mempertanyakan pertanyaannya ketika perlu. Pada nomor 11, jawaban senior tidak dimulai dengan angka — ia dimulai dengan "pertanyaan itu kausal, dan model prediktif tidak dapat menjawabnya; izinkan saya jelaskan mengapa dan apa yang bisa kita lakukan."

Perbedaan itu dapat dilatih, dan seluruh volume ini adalah latihannya. Setiap bab memuat minimal satu kasus di mana jawaban yang benar adalah menolak premis pertanyaannya.

Ending Card — Volume 6

What you learned

Volume ini membangun kemampuan machine learning yang tertanam dalam disiplin lima volume sebelumnya. Kapan ML layak dipakai dan kapan pertanyaannya sebenarnya kausal atau keputusan; anatomi proyek ML dan kebocoran data; feature engineering dengan point-in-time correctness; regresi dan regularisasi; klasifikasi logistik; pohon, random forest, dan gradient boosting beserta kondisi yang menentukan pemenangnya; interpretasi model dan perbedaan antar metode importance; validasi, metrik, dan kalibrasi; ambang keputusan sebagai critical ratio; uplift dan nilai inkremental; clustering, PCA, dan deteksi anomali; peramalan permintaan dan forecast value added; AI generatif dan batas pemakaiannya; serta tata kelola model dari pemantauan sampai model card.

Skills mastered

Problem framing untuk ML · pencegahan kebocoran data · feature engineering point-in-time · regresi, klasifikasi, dan boosting · interpretasi model · validasi dan kalibrasi · cost-sensitive thresholding · uplift measurement · unsupervised learning · peramalan · prompting dan alur kerja AI · model monitoring dan tata kelola.

Real business value

Sepanjang volume ini, analisis yang dikerjakan menghasilkan: deteksi kebocoran yang mencegah peluncuran model tidak berguna dengan AUC 0,9244; temuan bahwa 81% nilai model tersedia dari tiga kolom RFM; penetapan ambang dari biaya yang bernilai Rp 0,28 miliar per tahun dengan usaha lima menit; perbandingan jujur yang menurunkan klaim nilai dari Rp 5,43 miliar ke Rp 0,80 miliar; pengukuran uplift yang membalikkan nilai program dari -Rp 0,60 miliar ke +Rp 4,60 miliar; temuan bahwa deteksi anomali bekerja lebih buruk daripada acak sementara model supervised mencapai lift 13,97×; dan rancangan pemantauan yang mendeteksi drift berbulan-bulan sebelum AUC bergerak.

Portfolio readiness

Capstone ini adalah proyek portofolio machine learning yang lengkap secara siklus hidup — dari kelayakan sampai tata kelola. Yang membuatnya menonjol bukan modelnya, melainkan tiga artefak yang jarang ada di portofolio lain: analisis kebocoran, perbandingan nilai semu versus nilai inkremental, dan model card dengan batas pakai yang serius.

Interview readiness

Lima belas pertanyaan Layer 6 di atas mencakup hampir seluruh ruang pertanyaan wawancara ML terapan. Bila ada yang masih terasa sulit, kembali ke bab yang bersangkutan dan kerjakan latihannya — bukan baca ulang.

Next volume

Volume 7 — Domain Expertise & Capstone. Enam volume membangun kemampuan yang berlaku umum: data, statistik, bisnis, kausalitas, keputusan, dan AI. Volume terakhir menempatkannya dalam konteks industri tertentu — ritel, F&B, perbankan, e-commerce — karena rekomendasi yang tepat secara metode dapat tetap keliru bila mekanika industrinya tidak dipahami. Dan capstone akhirnya menggabungkan tujuh layer menjadi satu sistem keputusan bisnis yang utuh.